上 海 交 通 大 学 试 卷（B卷）

（ 20_21_ 至 20_22__ 学年 第__2__学期 ）

班级号_____ 学号_____ 姓名 _____

课程名称 __机器学习（ICE2302）_____ 成绩 _____

一、 选择题（每题 3 分，共 24 分；注：部分题目的答案可能不止一个，多选题的答案多选或少选都不得分）：

1. 关于过拟合与欠拟合，下列说法中错误的是 （ ）。
   A. 样本数量过少或者模型复杂度过高，会导致过拟合
   B. 样本数据的噪声太多，会导致模型学习了噪声特征，忽略了真实特征，从而导致了过拟合
   C. 模型欠拟合时，学习器的拟合能力由方差主导
   D. 增加正则化项、数据扩增、Dropout、Early Stopping，是解决模型过拟合的有效方案

2. 一般来说，下列哪种方法常用来预测连续独立变量？（ ）
   A. 线性回归
   B. 逻辑回归
   C. 线性回归和逻辑回归都行
   D. 以上说法都不对

3. 以下关于测试集训练集划分的相关说法中，正确的是（ ）。
   A. 留出法在划分数据集时，随机划分无需保证数据分布的一致性
   B. K-折交叉验证方法中，实际上所有样本都会参与训练
   C. K-折交叉验证方法相比于留出法更适合于小样本数据
   D. 自助法可能会导致数据分布改变，并引入估计偏差

4. 有关支持向量机（SVM），下列说法中正确的是（ ）。
   A. SVM 是一种具有最大间隔的超平面划分。
   B. 线性可分 SVM 对噪声或异常样本不敏感。
   C. SVM 的代价函数是凸函数，不存在局部最小值。
   D. 非线性 SVM 目的是通过将原空间数据映射到新空间中，再使用线性分类学习方法进行分类。

我承诺，我将严格遵守考试纪律。

承诺人：_____

题号										
得分										
批阅人(流水阅卷教师签名处)										

5. 有关决策树与集成学习，下列说法中错误的是（　　）。

A. 关于决策树的泛化性能，预剪枝优于后剪枝

B. 决策树学习采用的是自顶向下的递归方法

C. Adaboost 中弱分类器通过加权线性相加组成强分类器

D. Adaboost 不容易发生过拟合，但是对异常样本敏感

6. 以下算法中，那些算法不属于无监督学习（　　）。

A. K-means

B. Gaussian Mixture Model (GMM)聚类

C. 逻辑回归

D. SVM

7. AdaBoost 的说法，正确的是（　　）。

A. 改变了训练数据的权值，减少上一轮被正确分类的样本权值，提高被错误分类的样本权值。

B. 所有基本分类起加权投票进行预测，基本分类器的权重和错误率有关

C. 所有基本分类器都参与加权投票，因此对异常样本不敏感

D. 不容易发生过拟合

8. 关于生成模型，以下错误的是（　　）。

A. 建模的是数据 X 和类别 C 的联合概率分布 $P(C,X)$ 和数据的概率分布 P(X)

B. 生成模型也可用于分类任务

C. 高斯判别分析(Guassian Discriminant Analysis)是生成模型

D. 朴素贝叶斯分类器不是生成模型

二、 简答题（每题 8 分，共 32 分）：

1、 神经网络中的激活函数有什么作用？对激活函数的特性有什么要求？你知道的激活函数有哪些（任写三个）？请给出表达式并绘制函数图像。

2、 试简要阐述在回归模型中，若不同特征的尺度差异过大，在梯度下降过程中会产生什么影响？对此，有何解决方法？

3、 SVM 的主要思想是什么？硬间隔 SVM 和软间隔 SVM 有什么区别？引入的核方法有什么作用？

4、 请简述 EM 算法，以混合高斯模型聚类算法为例，指出 E 步骤和 M 步骤。在隐变量模型参数估计时，与用梯度下降法相比，EM 算法有什么优点？

三、 计算题（从以下三个题目中任选两题作答，每题 12 分，共 24 分）：

1、给定含有 5 个样本的集合 X=$\{x_1, x_2, x_3, x_4, x_5\}$=$\{(0,0), (0,3), (1,3), (4,0), (3,3)\}$，使用 K 均值聚类算法将样本聚到 2 个簇中（以x_1和x_2为两个簇的初始中心）。

2、 假设有一个图像分类的任务，需要预测的类别有：人，车，狗三种，现有模型 1 与模型 2 并对三张图片样本给出预测结果如下

模型 1：

ID	预测结果	真实标签	是否正确
1	0.3 0.3 0.4	0 0 1（狗）	正确
2	0.3 0.4 0.3	0 1 0 （车）	正确
3	0.2 0.2 0.6	1 0 0 （人）	错误

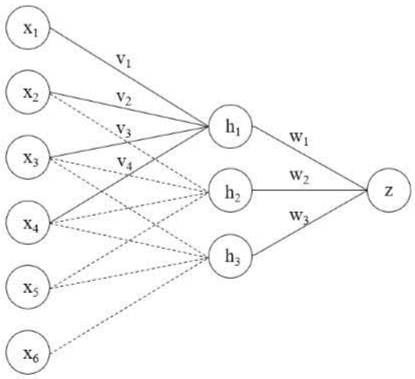
模型 2：

ID	预测结果	真实标签	是否正确
1	0.1 0.3 0.6	0 0 1（狗）	正确
2	0.1 0.8 0.1	0 1 0 （车）	正确
3	0.2 0.5 0.3	1 0 0 （人）	错误

请分别使用均方误差（MSE= $\frac{1}{N}\sum_{i=1}^{N}(\hat{y}_i - y_i)^2$ ）与交叉熵损失（Cross Entropy

Loss=$-\frac{1}{N}\sum_{i=1}^{N}\sum_{c=1}^{C} y_{ic}\log(\hat{y}_{ic})$)作为模型的损失函数，计算 Loss。判断两者谁更适合作为该任务的损失函数，并给出理由。

3、考虑以下的一维卷积和全连接层结合的网络模型：



第一层是一维卷积层，卷积核大小为 4，数量为 1，即$h_i = s\left(\sum_{j=1}^{4} v_j\, x_{i+j-1}\right)$。第二层是全连接层即$z = \sum_{i=1}^{3} w_i h_i$。隐藏层的激活函数为 sigmoid($f(x) = \frac{1}{1+e^{-x}}$)，输出单元没有激活函数，为了方便各层也没有偏置(bias)。设损失函数为$L = (y - z)^2$，其中y表示真实的标签。假设：

$x = [1 \quad 0 \quad 1 \quad 1 \quad 0 \quad 0]^T$，$h = [1/4 \quad 1/2 \quad 3/4]^T$，$w = [2 \quad -1 \quad 1]^T$。

并且$y = 1/2$

1）计算$\frac{\partial L}{\partial w}$。

2）计算$\frac{\partial L}{\partial v}$。

四、论述题（20 分）：请从如下两题中，任选一题进行论述。

题目一、机器学习是实现人工智能的关键。在 Tom Mitchell 给出的机器学习的现代化定义中，有哪三个主要要素？除了这三个要素，机器学习还有哪些要素？结合课堂教学和大作业训练，或者你所了解的人工智能产品与应用，谈谈你对机器学习主要要素及其作用、关系的理解。

题目二：在机器学习算法处理图像等高维数据时，会面临什么样的一些困难？目前机器学习中有哪些高维数据处理的主流技术？通过这些技术是如何缓解高维数据处理遇到的困难？请谈谈你的认识。