上海交通大学
SHANGHAI JIAO TONG UNIVERSITY

SJTU

# 利用AIGC辅助数据分析与挖掘

上海交通大学RFID与物联网研究所

饮 水 思 源 • 爱 国 荣 校

上海交通大學
SHANGHAI JIAO TONG UNIVERSITY

# 目 录




1 AIGC简介

2 AIGC与数据挖掘

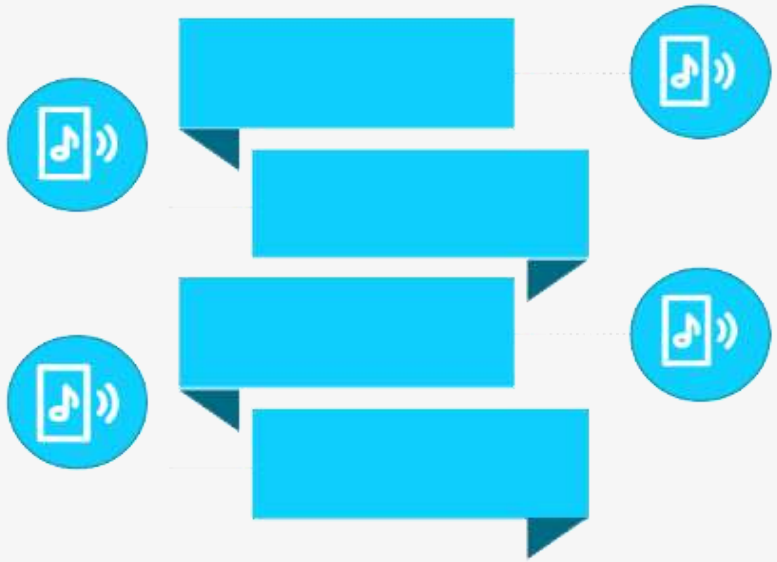
3 数据挖掘与提示词工程

# AIGC简介

## AIGC（Artificial Intelligence Generated Content）：人工智能生成内容

AIGC可以根据用户输入的关键词或要求自动地生成内容，无须人工编辑

AIGC可以利用深度学习和强化学习等技术，不断地学习和优化内容生成策略

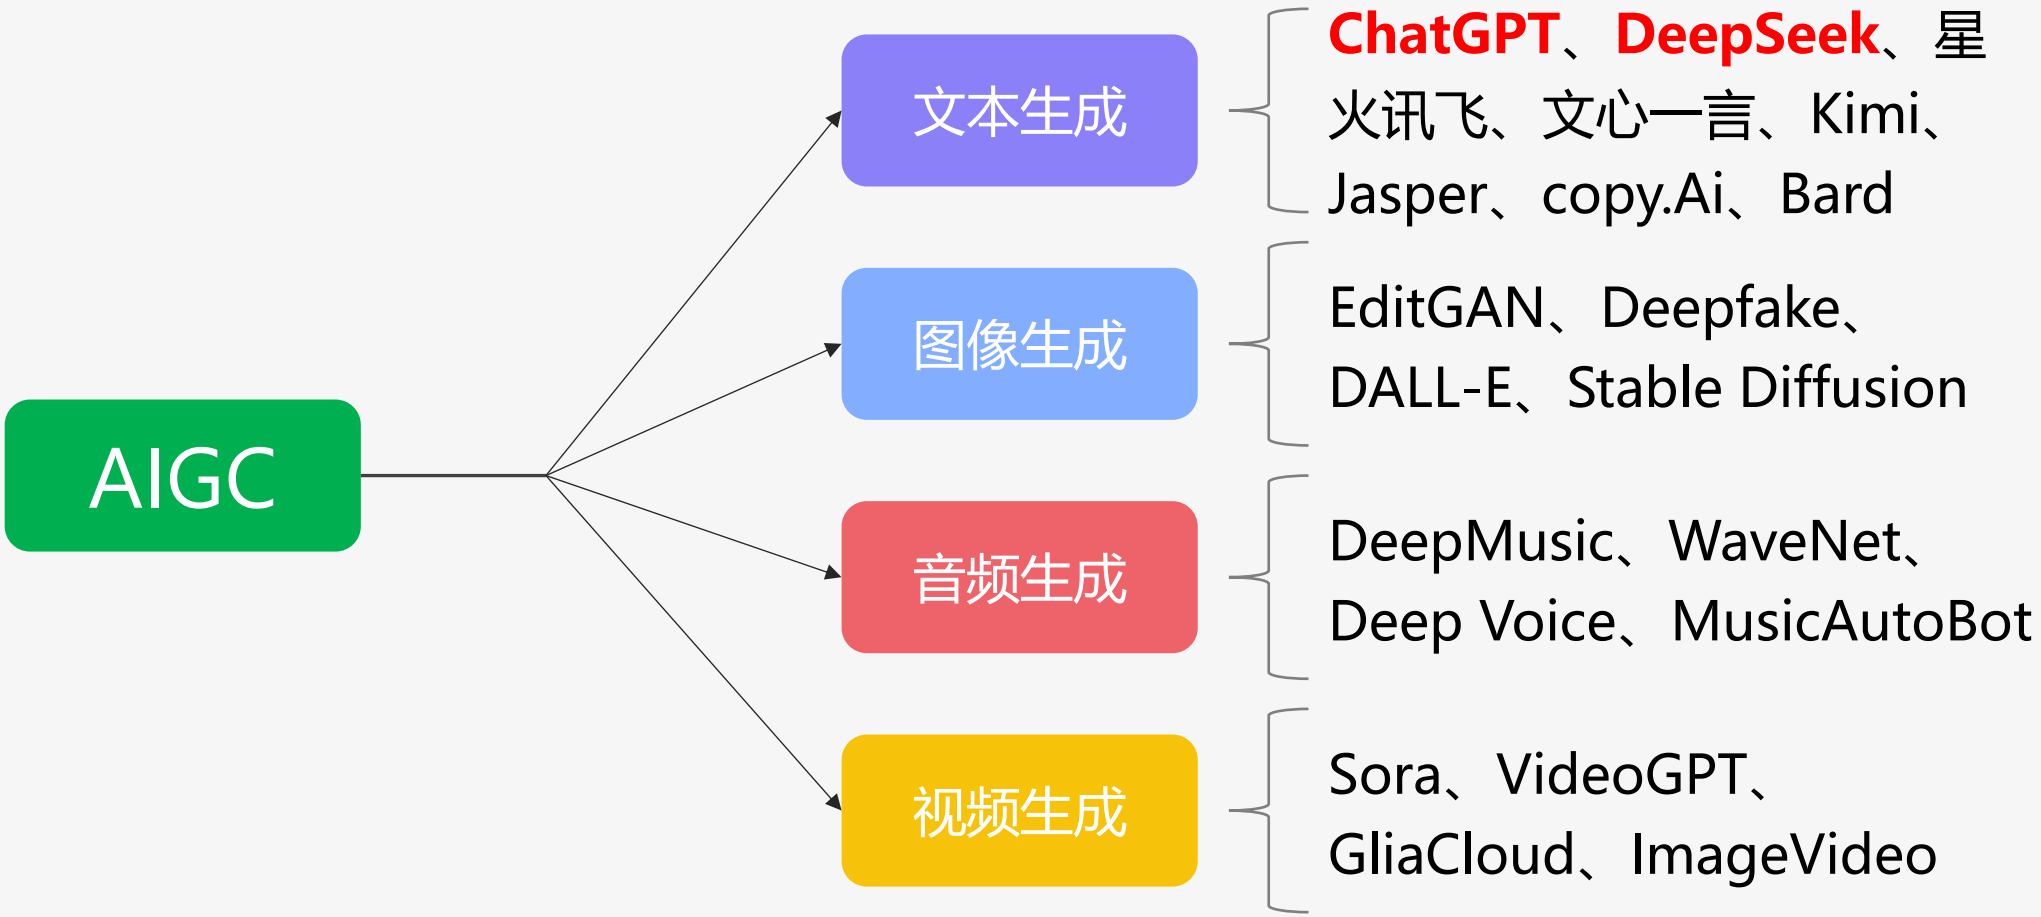


AIGC可以自动生成各种类型的内容，例如文章、视频、图片、音乐、代码等，这样可以满足不同用户的不同需求

AIGC可以利用机器学习和深度学习等技术，不断地更新和改进内容生成的模型和算法

从商业层面看，AIGC本质上是一种AI赋能技术，由于其具有**高质量**、**低门槛**、**高自由度**的生成能力，被广泛应用于各类内容的相关场景，服务于生产者

# AIGC简介


AIGC
文本生成
ChatGPT、DeepSeek、星火讯飞、文心一言、Kimi、Jasper、copy.Ai、Bard
图像生成
EditGAN、Deepfake、DALL-E、Stable Diffusion
音频生成
DeepMusic、WaveNet、Deep Voice、MusicAutoBot
视频生成
Sora、VideoGPT、GliaCloud、ImageVideo

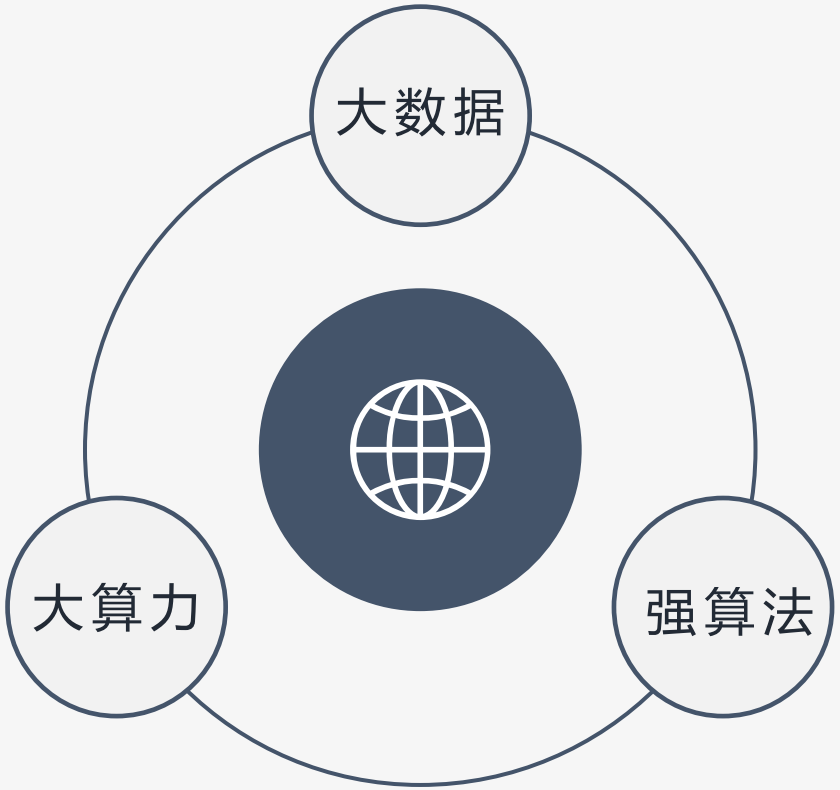
# AIGC与大模型

**大模型**是指通过“大数据+大算力+强算法”相结合来模拟人类思维和创造力的人工智能算法



# AIGC与大模型

规模巨大、多样化的**数据集合**。具有广度和深度的数据可以提供丰富的信息来训练和优化大模型，从而使大模型具备更全面的认知和更准确的预测能力，更好地理解现实世界复杂的现象和问题




指计算机或计算系统具有处理和执行**复杂计算任务**的高度能力。大模型涉及庞大的参数和复杂的计算任务，强大的算力是支撑大模型训练和推理的基石

指在解决特定问题或执行任务方面表现出**高效率**、**高准确率**和**强鲁棒性**的算法，是模型解决问题的机制。强算法能够更好地挖掘大数据中的潜在模式，并将其转化为模型的优化方向

# AIGC与大模型



Q：为什么目前主流的大模型都是文本生成类的大模型（即大语言模型LLM）？

A：
1、文本是最基础的知识表达方式
2、文本数据的可获取性高
3、文本生成技术最成熟
4、商业化落地最快

几乎所有日常工作学习的需求都可以转化为文字类说明，比如“帮我规划工作日程”、“帮我写一段代码”、“帮我整理一下这篇论文的核心内容”等
这也就意味着，我们可以利用大语言模型帮助我们进行数据分析和挖掘

上海交通大學
SHANGHAI JIAO TONG UNIVERSITY

# 目 录




1 AIGC简介

2 AIGC与数据挖掘

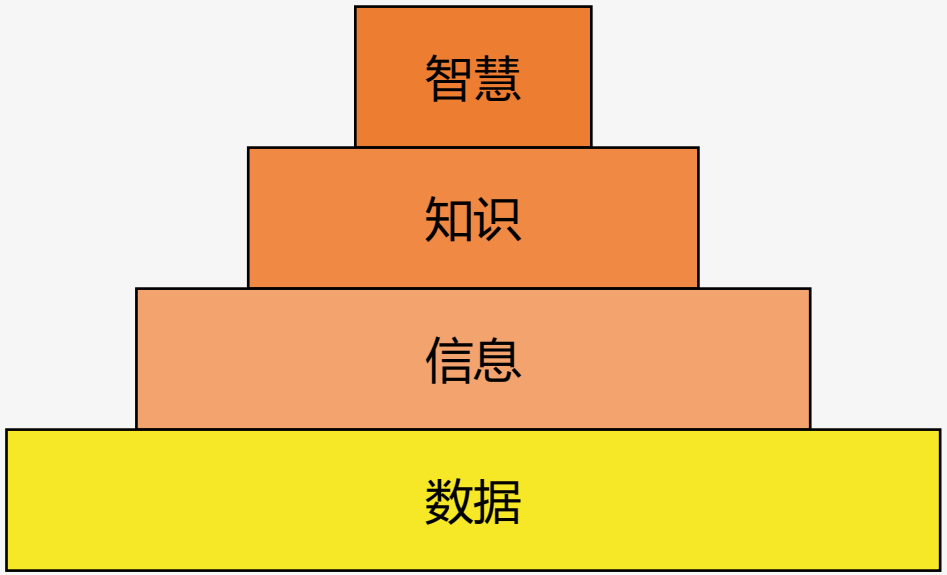
3 数据挖掘与提示词工程

# 数据挖掘简介

上海交通大学 SHANGHAI JIAO TONG UNIVERSITY

## 什么是数据挖掘?

**定义：** 从大量的、有噪声的、不完全的、模糊的和随机的数据中，提取出隐含在其中的、人们事先不知道的、具有潜在利用价值的信息和知识的过程




这个定义包含以下几层含义：

- ✓ 数据源必须是真实的、大量的、含噪声的
- ✓ 发现的是用户感兴趣的知识
- ✓ 发现的知识要可接受、可理解、可运用
- ✓ 不要求发现放之四海皆准的知识，仅支持特定的发现问题

# 数据挖掘流程

上海交通大学 SHANGHAI JIAO TONG UNIVERSITY

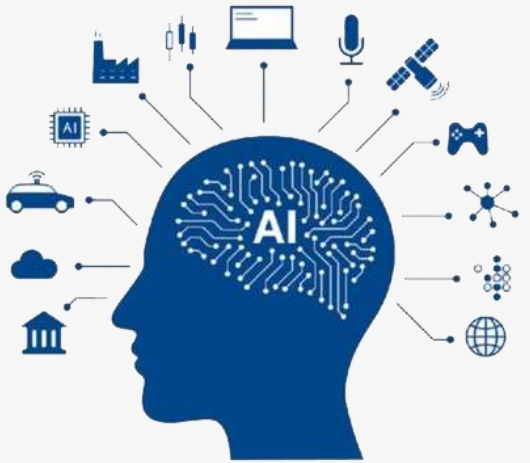
## CRISP-DM方法论

a) **业务理解**：包括目标设定、需求分析和可行性评估
b) **数据理解**：包括数据收集、统计分析、可视化，以及发现数据中的异常值、缺失值或重复值
c) **数据准备**：也叫做**数据预处理**，指对原始数据进行清洗、转换、整合和规约，是数据挖掘中**最关键的步骤**
d) **构建模型**：应用软件工具，选择合适的建模方法，处理准备好的数据，找出数据中隐藏的规律
e) **模型评估**：从业务角度和统计角度使用不同的指标对模型进行评估
f) **模型部署**：将模型的结果可视化，作出一定的业务解释，然后将模型部署集成到应用系统重



# AIGC与数据挖掘

AIGC赋能数据分析与挖掘是指利用AIGC技术，协助分析师高效、准确、全面地获取数据价值和洞察的过程




那AIGC可以用在数据挖掘的哪个阶段呢？

**ALL！**




- ✓ 你可以用大模型评估可行性
- ✓ 你可以用大模型分析你的数据中的缺失值情况
- ✓ 你可以用大模型帮你写一段填充缺失值的代码甚至生成新的数据
- ✓ 你可以让大模型向你推荐合适的算法用于建模
- ✓ 你可以用大模型分析你的评估指标
- ✓ 你可以用大模型生成你的模型的评估报告以及部署方案

# AIGC与数据挖掘



我举个栗子啊

给你一份这样的股评数据，
大模型能帮你做什么？

2017-03-30 09:29:02,股市解散，都回家吧
2017-03-30 09:29:09,外围股市都是收涨的
2017-03-30 09:29:12,全球都在涨...悲催的中国股市...关门吧..坑死人的东西..!
2017-03-30 09:29:16,让我一次跌个狗😄😄😄
2017-03-30 09:29:16,那什么去祭祖!
2017-03-30 09:31:10,无耻
2017-03-30 09:31:12,越跌越买..套越深..!
2017-03-30 09:31:27,清明时节雨纷纷，股海泳者欲断魂
2017-03-30 09:31:52,下行.....跌
2017-03-30 09:32:20,很跌，俺清了
2017-03-30 09:32:24,一睁眼就跌难怪股民骂
2017-03-30 09:32:38,股灾？？？
2017-03-30 09:32:40,[redacted]
2017-03-30 09:32:45,干股跌停要来了！跑吧!
2017-03-30 09:33:11,坑爹啊
2017-03-30 09:33:19,求求你们，把A股关了吧。
2017-03-30 09:33:21,我知道我是爱你的！一万个舍不得
2017-03-30 09:33:26,逃
2017-03-30 09:33:45,今天尼玛该涨点了吧[不赞]
2017-03-30 09:33:47,好，不要再骂了，骂有用吗?
2017-03-30 09:33:51,飞流直下三千尺😄✌[牛]
2017-03-30 09:33:57,尿性十足的A股
2017-03-30 09:34:06,[redacted]
2017-03-30 09:34:06,在中国玩股票 呵呵。[redacted] 施肥三周 一天割完
2017-03-30 09:34:16,大盘开始调整了，我先出来了，不能跟你们比！半月后再见!
2017-03-30 09:34:16,黑色的一周!
2017-03-30 09:34:22,[redacted]
2017-03-30 09:34:22,低开高走。震荡向上趋势不会改变
2017-03-30 09:34:43,差不多就行了，昨天全球大涨，你跌，今天还要继续？[滴汗]

## 情感分析

以下是每条股评的情感值分析，数值区间为[-3, 3]，负数表示负面情绪，正数表示积极情绪：

1. **2017-03-30 09:29:02,股市解散，都回家吧**
   **情感值：-3.0**
   （极端负面，表达对股市的彻底失望。）

2. **2017-03-30 09:29:09,外围股市都是收涨的**
   **情感值：-0.5**
   （陈述事实，但隐含对比下的不满。）

3. **2017-03-30 09:29:12,全球都在涨...悲催的中国股市...关门吧..坑死人的东西..!**
   **情感值：-3.0**
   （强烈负面情绪，直接辱骂和绝望。）

## 分词

以下是每条股评的分词结果（按示例格式处理）：

1. **股市 解散 都 回家吧**
2. 外围 股市 都 是 收涨 的
3. 全球 都 在 涨 悲催 的 中国 股市 关门 吧 坑死人 的 东西
4. 让 我 一次 跌 个 狗

上海交通大學
SHANGHAI JIAO TONG UNIVERSITY

# 目 录




1 AIGC简介

2 AIGC与数据挖掘

3 数据挖掘与提示词工程

# 数据预处理简介

数据预处理是对原始数据进行清洗、转换、整合和规约，旨在提高数据质量，为后续数据分析和挖掘提供更好的基础，因此数据预处理是数据挖掘中最关键的步骤




## 提高数据质量

通过数据预处理，可以去除或修正错误、异常或不完整的数据，提高数据的准确性和可靠性




## 提高分析效果

高质量的数据能够使分析结果更准确、可靠，从而提高分析效果和预测精度




## 节省计算资源

通过数据预处理，可以减少无效或错误数据的计算量，提高计算效率和资源利用率

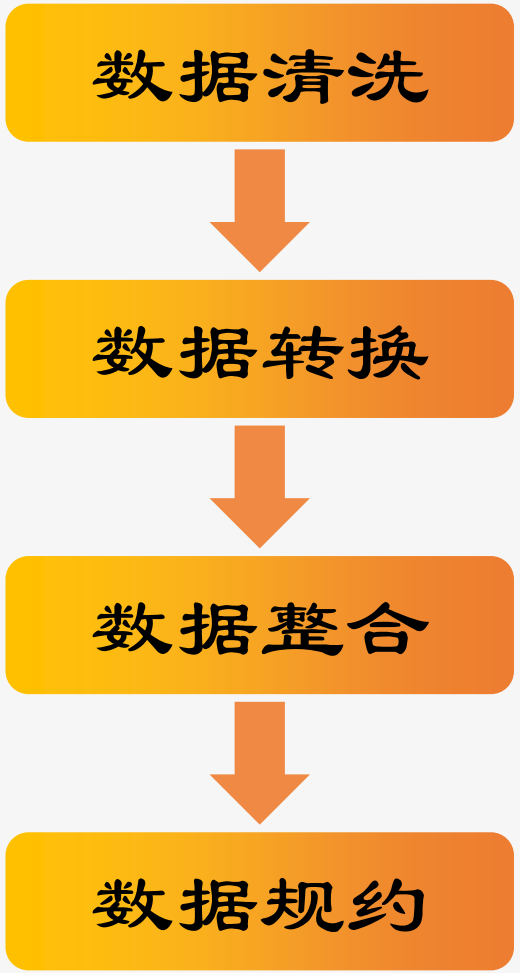
# 数据预处理流程

① **数据清洗**：去除重复、错误或不完整的数据，对缺失值进行填充或删除

② **数据转换**：将数据转换为适合分析和挖掘的格式或类型，如将分类数据转换为数值型数据

③ **数据整合**：将多个数据源进行整合，形成一个统一、完整的数据集

④ **数据规约**：对数据进行规约和降维处理，减少数据的维度和计算量



# 提示词工程

上海交通大学 SHANGHAI JIAO TONG UNIVERSITY

请简要介绍数据清洗，300字左右

数据清洗是数据预处理的关键步骤，旨在提高数据质量，确保其适用于分析和建模。它主要包括以下几个环节：

1. **处理缺失值**：通过删除、填充或插值等方法解决数据缺失问题，确保数据完整性。
2. **处理重复数据**：识别并删除重复记录，避免对分析结果产生干扰。
3. **纠正错误数据**：检测并修正数据中的异常值、格式错误或逻辑矛盾，提升数据准确性。
4. **数据标准化与转换**：将数据转换为统一格式或单位，便于后续分析。例如，日期格式统一、文本数据大小写转换等。
5. **处理不一致数据**：解决数据源之间的不一致问题，确保数据整合后的一致性。
6. **去除噪声数据**：过滤与分析目标无关的冗余信息，保留有效数据。

数据清洗能够显著提升数据质量，为后续分析和建模奠定基础，是数据科学和机器学习项目中不可或缺的环节。

# 提示词工程

这是一份丁香园2019新型冠状病毒的数据集，其中包含2451个样本，每个样本包含21个特征



现在我要求你处理其中的**缺失值**、**重复值**和**异常值**，你应该怎么做？

| | A | B | C | D | E | F | G | H | I |
|---|---|---|---|---|---|---|---|---|---|
| 1563 | 52490 | 59707 | 16067 | 5853 | 1364 | 8204 | | | |
| 1564 | 52490 | 59707 | 16067 | 5853 | 1364 | 8204 | | | |
| 1565 | 52484 | 59700 | 16067 | 5852 | 1364 | 8204 | | | |
| 1566 | 52450 | 59651 | 16067 | 5839 | 1362 | 8204 | | | |
| 1567 | 52450 | 59651 | 16067 | 5839 | 1362 | 8204 | | | |
| 1568 | 52451 | 59650 | 16067 | 5838 | 1361 | 8204 | | | |
| 1569 | 52438 | 59636 | 16067 | 5838 | 1360 | 8204 | | | |
| 1570 | 52420 | 59617 | 16067 | 5838 | 1359 | 8204 | | | |
| 1571 | 38577 | 44777 | 16067 | 5083 | 1117 | 8204 | | | |
| 1572 | 38578 | 44776 | 16067 | 5081 | 1117 | 8204 | | | |
| 1573 | 38584 | 44767 | 16067 | 5066 | 1117 | 8204 | | | |
| 1574 | 38582 | 44765 | 16067 | 5066 | 1117 | 8204 | 889 | 2057 | 3342 |
| 1575 | 38583 | 44765 | 16067 | 5066 | 1116 | 8204 | 890 | 2057 | 3342 |
| 1576 | 38583 | 44765 | 16067 | 5066 | 1116 | 8204 | | 2057 | 3342 |
| 1577 | 38583 | 44765 | 16067 | 5066 | 1116 | 8204 | | 2057 | 3342 |
| 1578 | | 44765 | 16067 | 5066 | 1116 | 8204 | | 2057 | 3342 |
| 1579 | | 44765 | 16067 | 5066 | 1116 | 8204 | | 2057 | 3342 |
| 1580 | | 44765 | 16067 | 5066 | 1116 | 8204 | | 2057 | 3342 |
| 1581 | | 44763 | 16067 | 5064 | 1116 | 8204 | | 2055 | 3342 |
| 1582 | | 44763 | 16067 | 5064 | 1116 | 8204 | | 2055 | 3342 |
| 1583 | | 44763 | 16067 | 5064 | 1116 | 8204 | | 2055 | 3342 |
| 1584 | | 44763 | 16067 | 5034 | 1116 | 8204 | | 2055 | 3342 |
| 1585 | | 44763 | 16067 | 5034 | 1115 | 8204 | | 2055 | 3342 |
| 1586 | | 44763 | 16067 | 5034 | 1115 | 8204 | | 2055 | 3342 |
| 1587 | | 44763 | 16067 | 5015 | 1115 | 8204 | | 2055 | 3342 |
| 1588 | | 44763 | 16067 | 5007 | 1115 | 8204 | | 2055 | 3342 |
| 1589 | | 44763 | 16067 | 5007 | 1115 | 8204 | | 2055 | 3342 |
| 1590 | | 44763 | 16067 | 5007 | 1115 | 8204 | | 2055 | 3342 |
| 1591 | | 44763 | 16067 | 5005 | 1115 | 8204 | | 2055 | 3342 |
| 1592 | | 44763 | 16067 | 5005 | 1115 | 8204 | | 2055 | 3342 |
| 1593 | | 44763 | 16067 | 4979 | 1115 | 8204 | | 2055 | 3342 |
| 1594 | | 44763 | 16067 | 4979 | 1115 | 8204 | | 2055 | 3342 |

DXY-test

# 提示词工程

这是一份丁香园2019新型冠状病毒的数据集，其中包含2451个样本，每个样本包含21个特征。现在我要求你处理其中的缺失值、重复值和异常值，你应该怎么做?

⚠ 超出字数限制，DeepSeek 只阅读了前 14%

**我有**一份丁香园2019新型冠状病毒的数据集，其中包含2451个样本，每个样本包含21个特征。现在我要求你处理其中的缺失值、重复值和异常值，你应该怎么做?

**工具建议**

- 使用 Python 的 `pandas` 处理数据:

**我有**一份丁香园2019新型冠状病毒的数据集，其中包含2451个样本，每个样本包含21个特征。现在我要求你处理其中的缺失值、重复值和异常值，你应该怎么做? **请使用pandas实现**。

# 提示词工程

上海交通大学 SHANGHAI JIAO TONG UNIVERSITY

我有一份csv格式的数据集，名为“DXY-test.csv”。请你处理其中的缺失值、重复值和异常值。要求：1、使用pandas库；2、给出ipynb代码。

好的！以下是使用 `pandas` 库处理 `DXY-test.csv` 数据集中缺失值、重复值和异常值的 Jupyter Notebook 代码示例。你可以将这段代码复制到你的 `.ipynb` 文件中并运行。

python Copy

```python
# 导入必要的库
import pandas as pd
import numpy as np

# 读取CSV文件
df = pd.read_csv('DXY-test.csv')

# 1. 处理缺失值
# 查看缺失值情况
print("缺失值统计：")
print(df.isnull().sum())

# 填充缺失值，这里使用列的中位数填充数值型数据，使用众数填充类别型数据
```



CAN WE DO

BETTER?

That's *Prompt Engineering!*

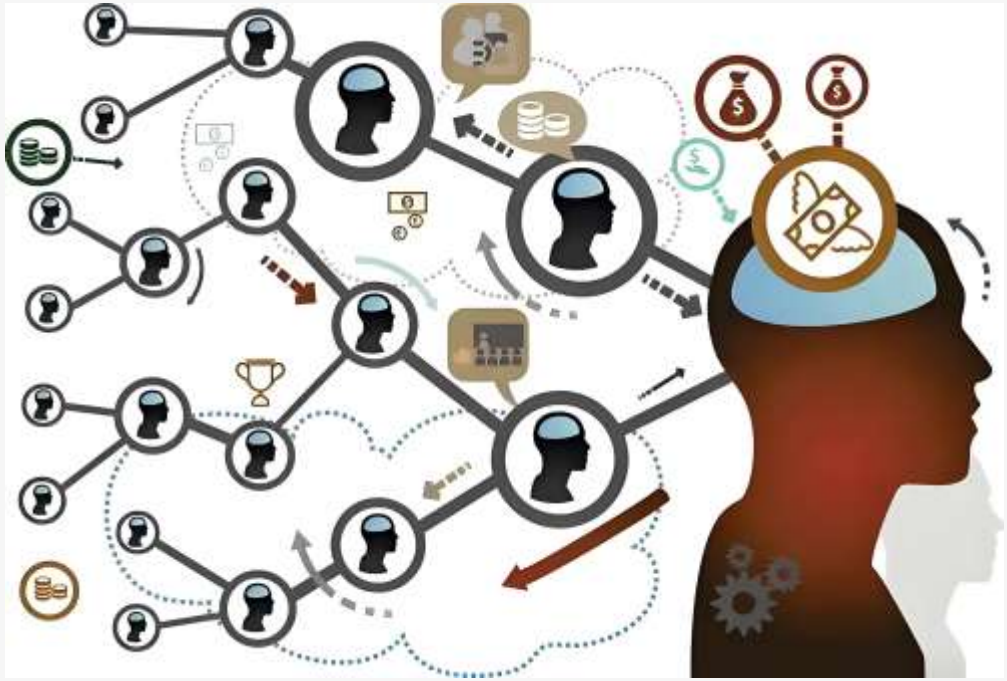
# 提示词工程进阶——思维链

上海交通大学 SHANGHAI JIAO TONG UNIVERSITY

## What is CoT?

**思维链**（Chain-of-Thought, **CoT**）旨在引导大语言模型**逐步**推理复杂问题，从而提高回答的准确性和逻辑性

简单来说，就是在提示词最后加上一句“**让我们一步步思考**”，这样的话大模型就能够生成一个回答问题的思维链。从这个思维链中，它们能够提取更准确的答案



DeepSeek-**V3** VS DeepSeek-**R1**

# 提示词工程进阶——思维链

上海交通大学 SHANGHAI JIAO TONG UNIVERSITY

## 举个栗子

2025年，小明有5颗苹果。他每年买3颗苹果，每年吃掉2颗苹果。到2036年，他还有几颗苹果?

小明在2025年有5颗苹果。从2025年到2036年，他每年买3颗苹果，每年吃2颗苹果。请你**逐步计算每一年的苹果变化情况，并得出最终结果**。



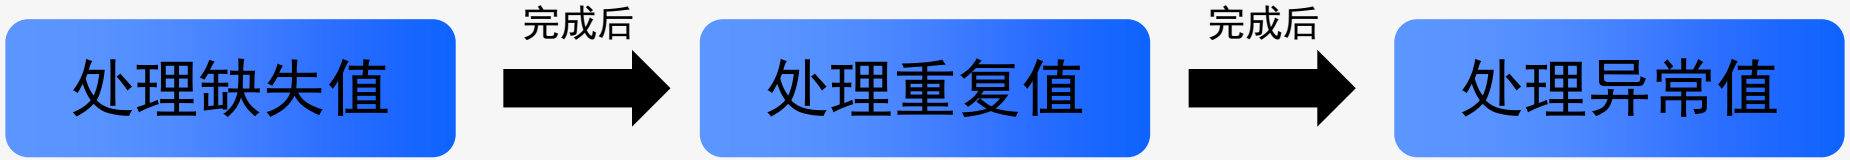
This is CoT!

# 提示词工程进阶——思维链

我有一份csv格式的数据集，名为“DXY-test.csv”。请你**处理**其中的**缺失值**。要求：1、**如果缺失数据超过50%就删除该列，否则仅删除缺失的数据行**；2、使用pandas库；3、给出完整的ipynb代码。

**你已经处理完了缺失值**，现在请你在刚才的代码基础上再**处理**其中的**重复值**。要求：1、**直接删除重复值即可**；2、使用pandas库；3、给出完整的ipynb代码。

**你已经处理完了缺失值和重复值**，现在请你在刚才的代码基础上再**处理**其中的**异常值**。要求：1、**使用IQR方法删除所有异常值**；2、使用pandas库；3、给出完整的ipynb代码。



# 提示词工程进阶——Others

## 角色扮演

**你是一名专业的数据挖掘分析师**。我有一份csv格式的数据集，名为“DXY-test.csv”。请你处理其中的缺失值。要求：1、如果缺失数据超过50%就删除该列，否则仅删除缺失的数据行；2、使用pandas库；3、给出完整的ipynb代码。

## 思维递归（拆分）

请回答如何提高数据清洗的效果。要求：**1、请先解释什么是数据清洗；2、然后列出数据清洗常见的步骤以及常用的方法；3、最后分析哪些哪些步骤或方法可以优化以提高清洗的效果。**

## 少样本学习（举例）

……请你在刚才的代码基础上再删除其中的异常值。要求：1、**像90.5、92.4、95.8这种明显不合逻辑的值属于异常值**；2、使用pandas库；3、给出完整的ipynb代码。

# 提示词工程——思考



## DO WE REALLY NEED

## Prompt Engineering?




# Thanks

饮 水 思 源　爱 国 荣 校