数据挖掘HW1报告

522031910213 朱涵

1 数据抽取

1.1 数据统计

weibo_data.csv的统计数据如下表，其中uid一列的统计数据无太大意义。

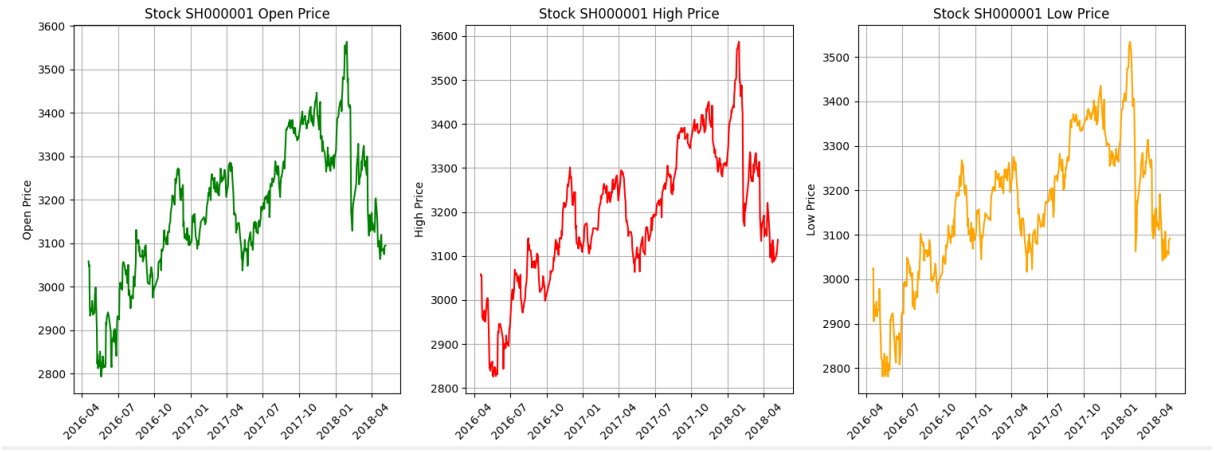
	user_id	post_num	follower_num
count	99	99	99
mean	1522900788	7867.353535	11528386.66
std	226192896.2	21635.94721	18558105.76
min	1041514813	4	5
25%	1272349389	490	802.5
50%	1619323521	1557	516668
75%	1705141505	4373	16679627
max	1781387491	132723	74798328

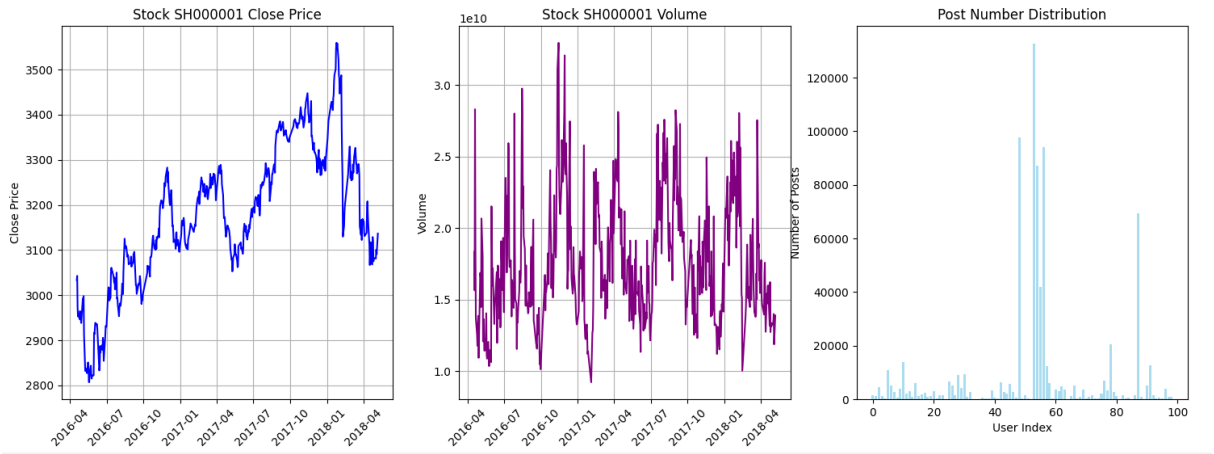
stock_sh000001.csv的统计数据如下表。

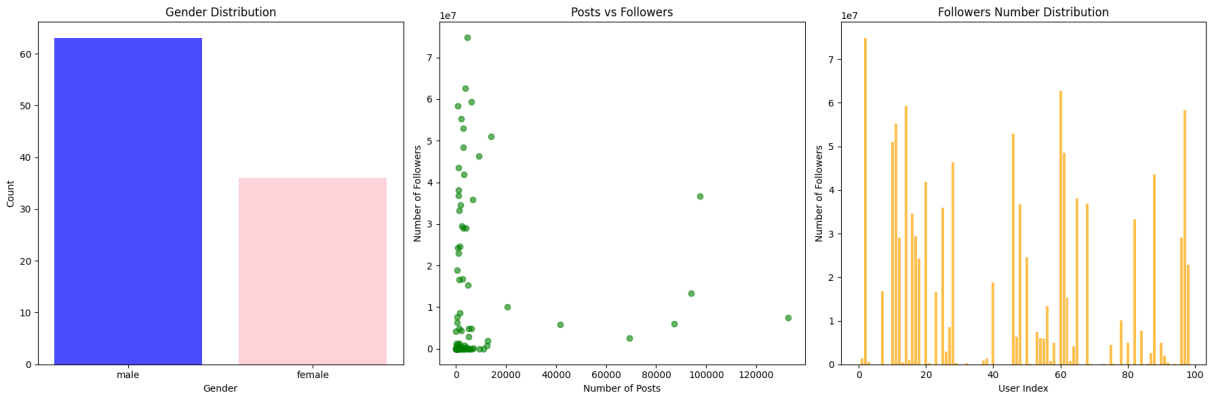
	open	high	low	close	volume
count	500	500	500	500	500
mean	3175.376532	3191.919238	3160.257836	3179.222716	17708952066
std	155.3175752	154.6680383	156.4902561	155.085107	4281599251
min	2792.888	2825.952	2780.763	2806.906	9222473600
25%	3082.75775	3097.08325	3063.9945	3084.65375	14474853900
50%	3173.916	3191.4945	3157.9805	3178.3115	16902985300
75%	3278.79425	3295.4405	3265.8285	3283.45725	20436523050
max	3563.64	3587.032	3534.195	3559.465	32960831300

1.2 数据可视化

如下图。共9张图，展示了2份csv的9列数据统计，包括股票的最高价、最低价、收盘价、开盘价、成交量，微博的发帖数分布、性别分布、粉丝数量与贴纸数量关系、关注数分布。







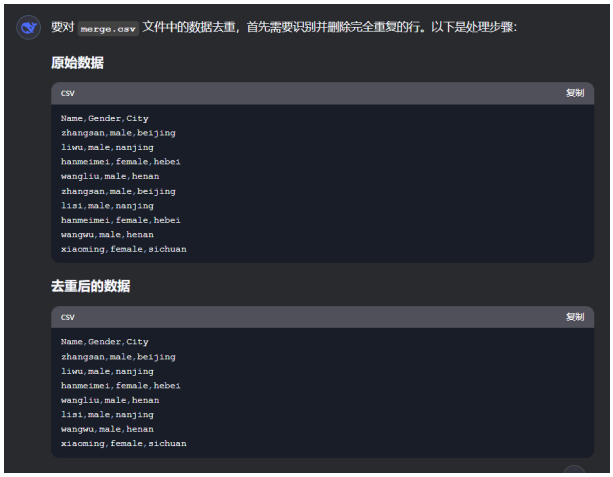
2 清洗与检验

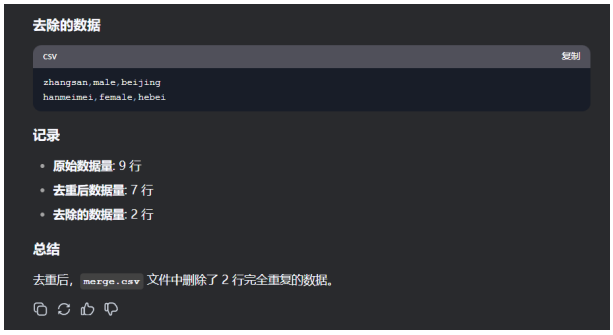
2.1 数据去重

提示词如下：



ds回答如下：





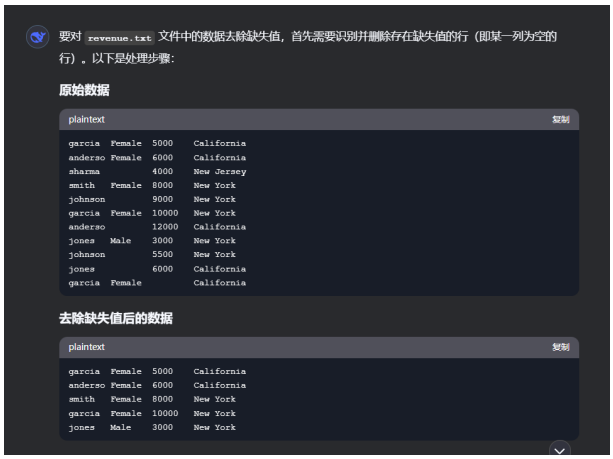
可以看到得到的数据是正确处理过的。

2.2 缺失值去除

提示词如下：



ds回答如下：

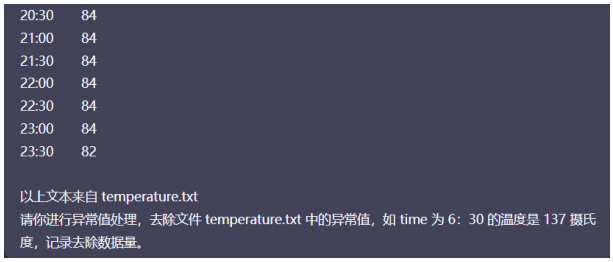




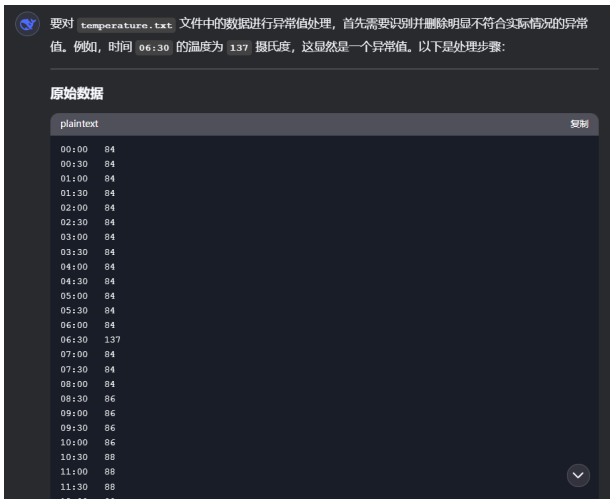
可以看到得到的数据是正确处理过的。

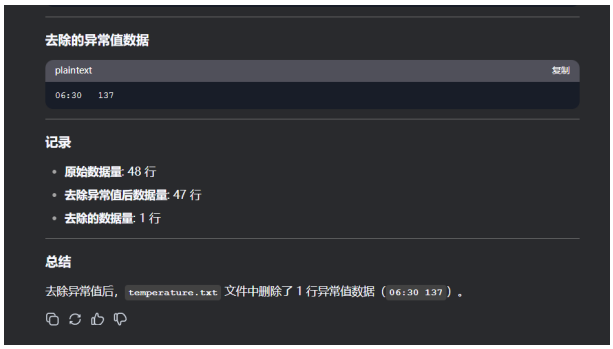
2.3 异常值处理

提示词如下：



ds回答如下：





可以看到得到的数据是正确处理过的。

3 转换与存储

3.1 中文分词

使用AIGC辅助生成处理代码，其推荐使用jieba库进行分词。最终处理结果如下图：

	created_time	title	segmented_comments
2	3/30/2017 9:29	股市解散，都回家吧	股市 解散 ， 都 回家吧
3	3/30/2017 9:29	外围股市都是收涨的	外围 股市 都 是 收涨 的
4	3/30/2017 9:29	全球都在涨...悲催的	全球 都 在 涨 ... 悲 催 的 中国 股市 ... 关门 吧 .. 坑 死 人 的 东西 .. ！
5	3/30/2017 9:29	让我一次跌个狗[大笑	让 我 一次 跌个 狗 [大笑] [大笑] [大笑]
6	3/30/2017 9:29	那什么去祭祖！	那 什么 去 祭祖 ！
7	3/30/2017 9:31	无耻	无耻
8	3/30/2017 9:31	越跌越买..套越深..！	越跌 越 买 .. 套 越深 .. ！
9	3/30/2017 9:31	清明时节雨纷纷，股海	清明 时节 雨 纷纷 ， 股海 泳者 欲 断魂
10	3/30/2017 9:31	下行……跌	下行 … … … … 跌
11	3/30/2017 9:32	很跌，俺清了	很 跌 ， 俺 清 了
12	3/30/2017 9:32	一睁眼就跌难怪股民骂	一 睁眼 就 跌 难怪 股民 骂
13	3/30/2017 9:32	股灾？？？	股灾 ？ ？ ？
14	3/30/2017 9:32	清明节到了，鸡狗和股	清明节 到 了 ， 鸡狗 和 股东 家里 死 了 不少 人 要钱 去 上坟 ， 这个 理由 可以 吧 ， 跌 吧 ！
15	3/30/2017 9:32	千股跌停要来了！跑吧	千股 跌停 要来 了 ！ 跑 吧 ！
16	3/30/2017 9:33	坑爹啊	坑爹 啊

3.2 文件转换

使用AIGC辅助生成处理代码，其推荐使用panda自带的处理函数进行转换。最终处理结果如下图（部分）：



Figure 1: csv转json

	A	B	C
1	0:00	84	
2	0:30	84	
3	1:00	84	
4	1:30	84	
5	2:00	84	
6	2:30	84	
7	3:00	84	
8	3:30	84	

Figure 2: txt转csv

	A	B	C	D	E	F	G
1	field	value	id	timestamp	user_agent	remote_addr	payment_status
2	13776121	Baylor Dallas	59434767	11/21/2011 9:21	Mozilla/5.0 (Windows NT 6.1; WOW64; rv:8.0)	192.168.1.1	
3	13776401	CHF	59434767	11/21/2011 9:21	Mozilla/5.0 (Windows NT 6.1; WOW64; rv:8.0)	192.168.1.1	
4	13777966	John Doe	59434767	11/21/2011 9:21	Mozilla/5.0 (Windows NT 6.1; WOW64; rv:8.0)	192.168.1.1	
5	13776121	Healthsouth,	59474875	11/21/2011 17:01	Mozilla/5.0 (Windows NT 6.1; WOW64; rv:8.0)	192.168.1.1	
6	13776401	Pneumonia	59474875	11/21/2011 17:01	Mozilla/5.0 (Windows NT 6.1; WOW64; rv:8.0)	192.168.1.1	
7	13777966	Jane Doe	59474875	11/21/2011 17:01	Mozilla/5.0 (Windows NT 6.1; WOW64; rv:8.0)	192.168.1.1	

Figure 3: json转csv

其中json转csv部分的代码含特殊处理，即针对原数据，对于其data字段进行了展平，从而得到合适的csv格式。

其余转换结果可见代码中的result文件夹。