

Data Mining and Big Data Anlysis

数据挖掘及大数据分析

Chapter1：Course Introduction and Teaching Arrangement

课程前言与课程教学安排

王东、张谦、丁玥

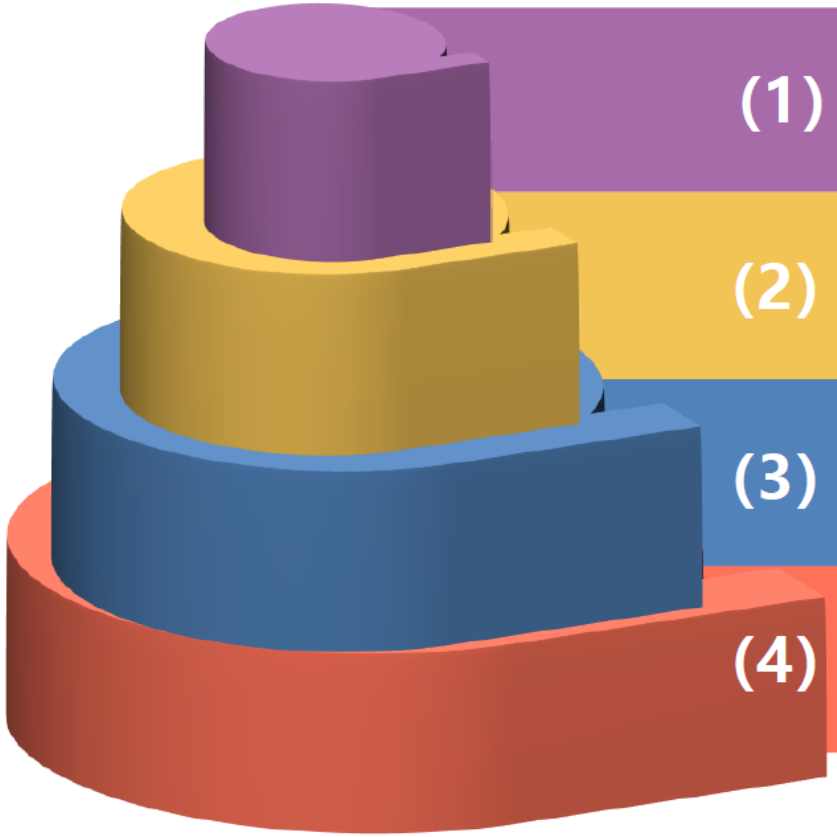
上海交通大学软件学院RFID与物联网实验室

2025年春季

提纲

- ***本课程与数据智能方向其它课程之间的关联、衔接、集成***
- **本课程的主要内容**
- **本课程的教学安排**

数据智能方向课程体系



（1）智能信息系统建模 —— 复杂软件的业务架构

（2）数据挖掘及大数据分析 —— 数据处理与智能算法

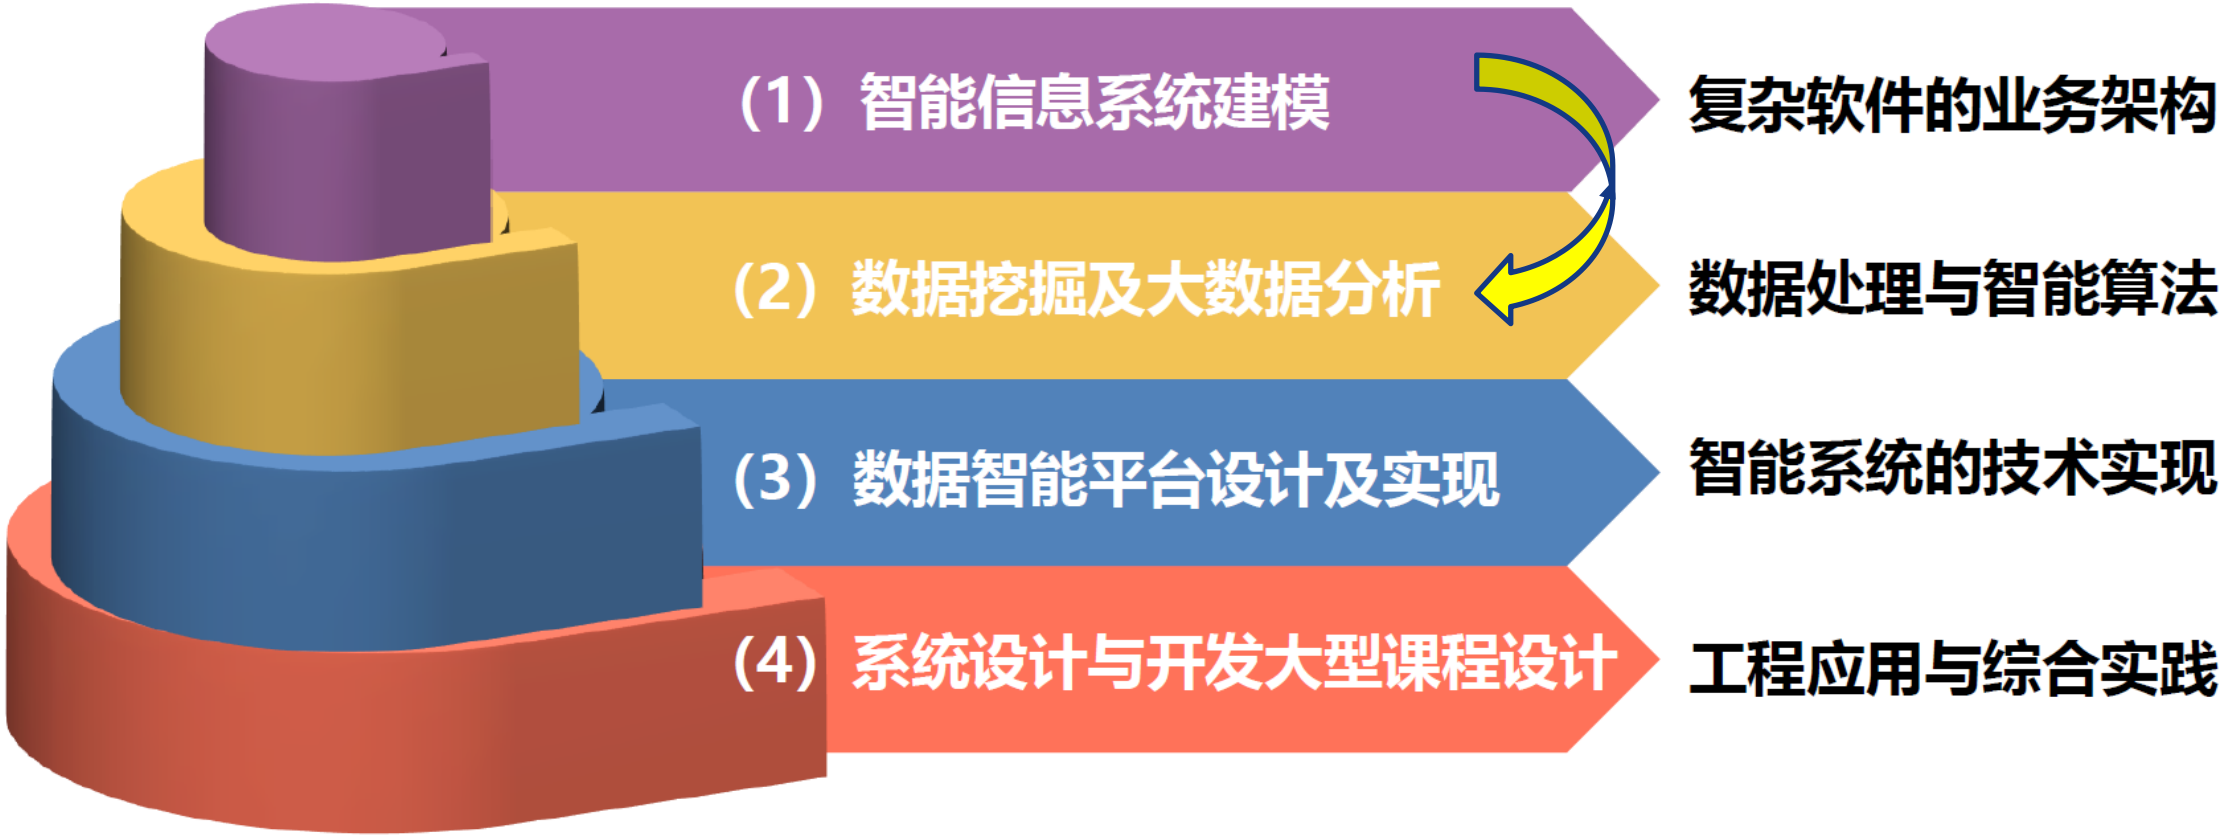
（3）数据智能平台设计及实现 —— 智能系统的技术实现

（4）系统设计与开发大型课程设计 —— 工程应用与综合实践

数据智能方向课程之间的关联、衔接、集成



数据智能方向课程体系和课程衔接设计



本课程与其它课程的内容衔接



《智能信息系统建模》课程“信息架构”与《数据挖掘及大数据分析》课程衔接

《智能信息系统建模》课程“信息架构”

- 信息系统规划设计方法（规划“主题数据库”）
- 行业数据模板（高质量的“主题数据库”）

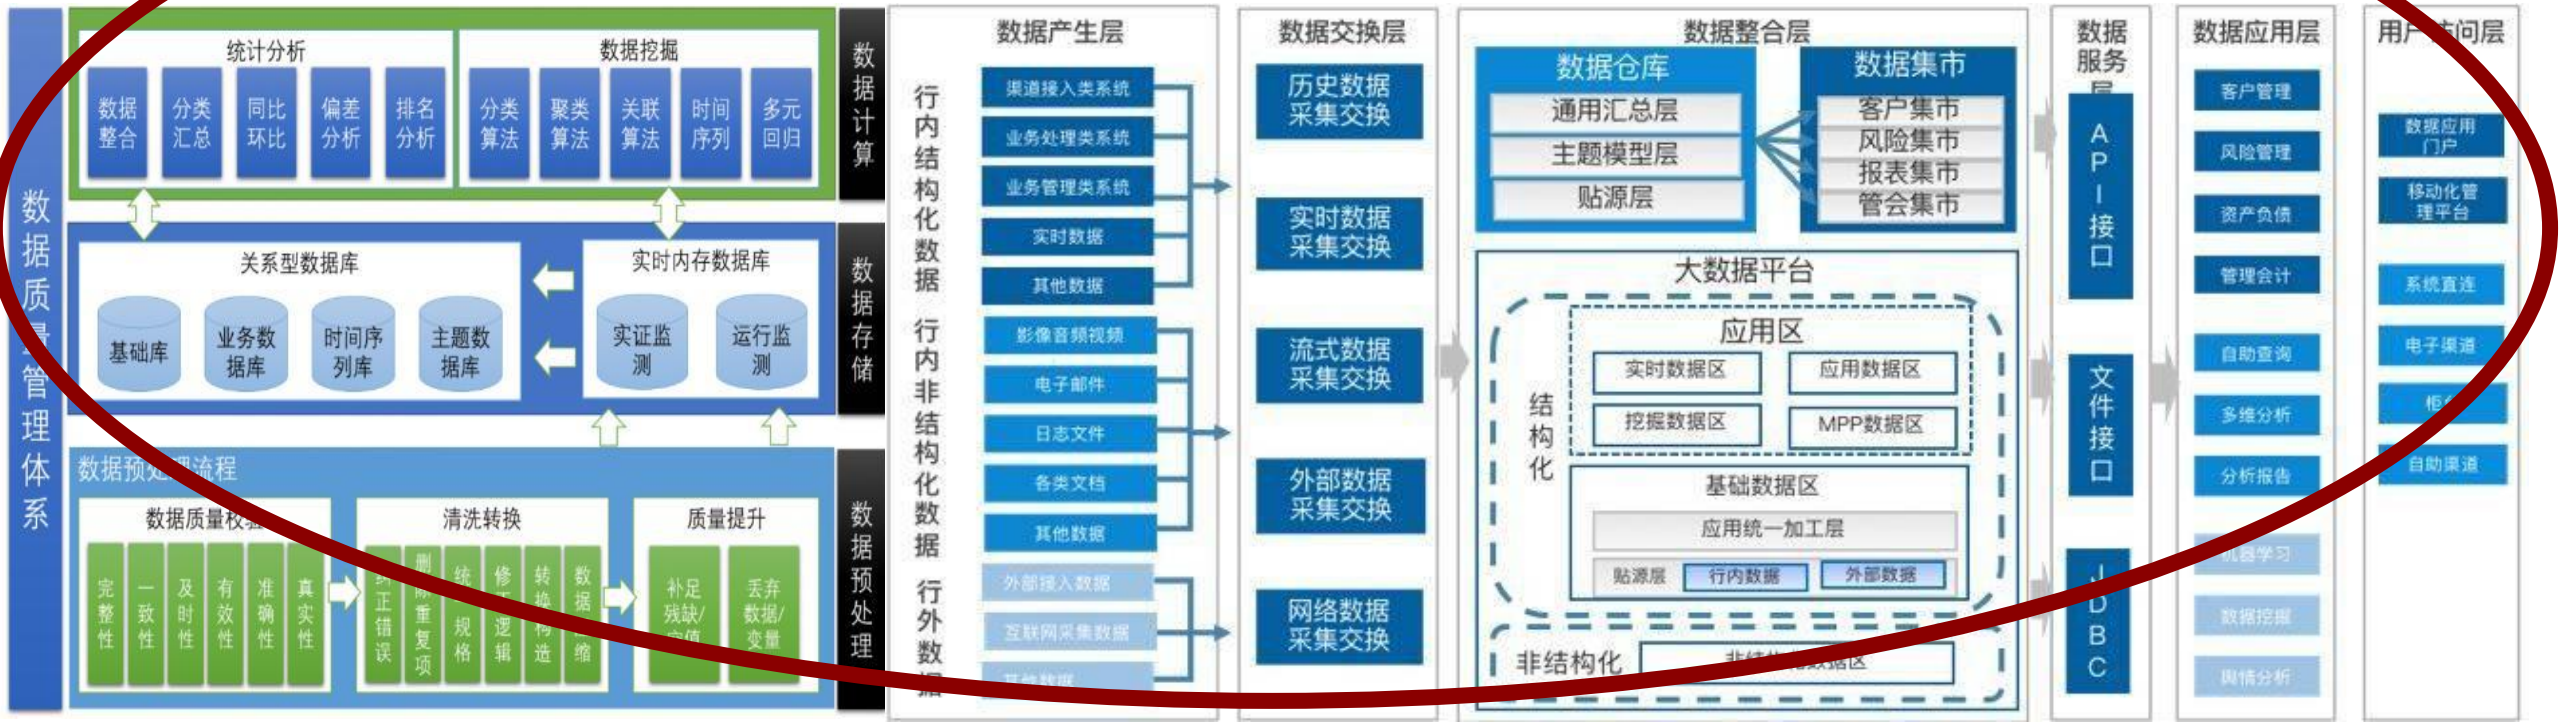
《数据挖掘及大数据分析》课程

- 数据治理（高可用的“数据”）
- 数据挖掘（挖掘数据的价值）

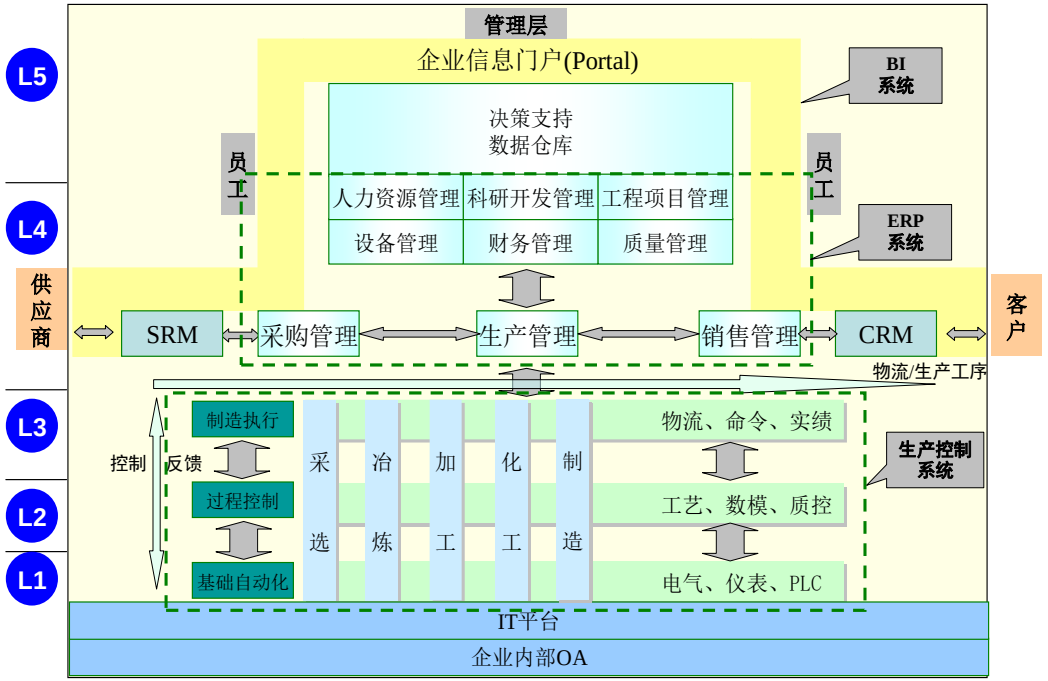
数据智能方向的数据视角：数据规划、数据治理、数据挖掘

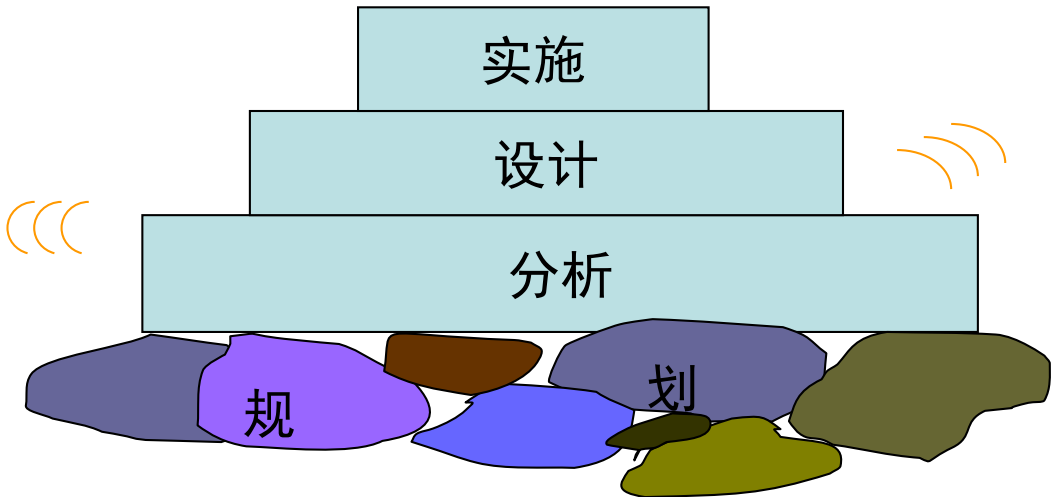
- 信息系统规划设计方法（规划“主题数据库”）
- 行业数据模板（高质量的“主题数据库”）

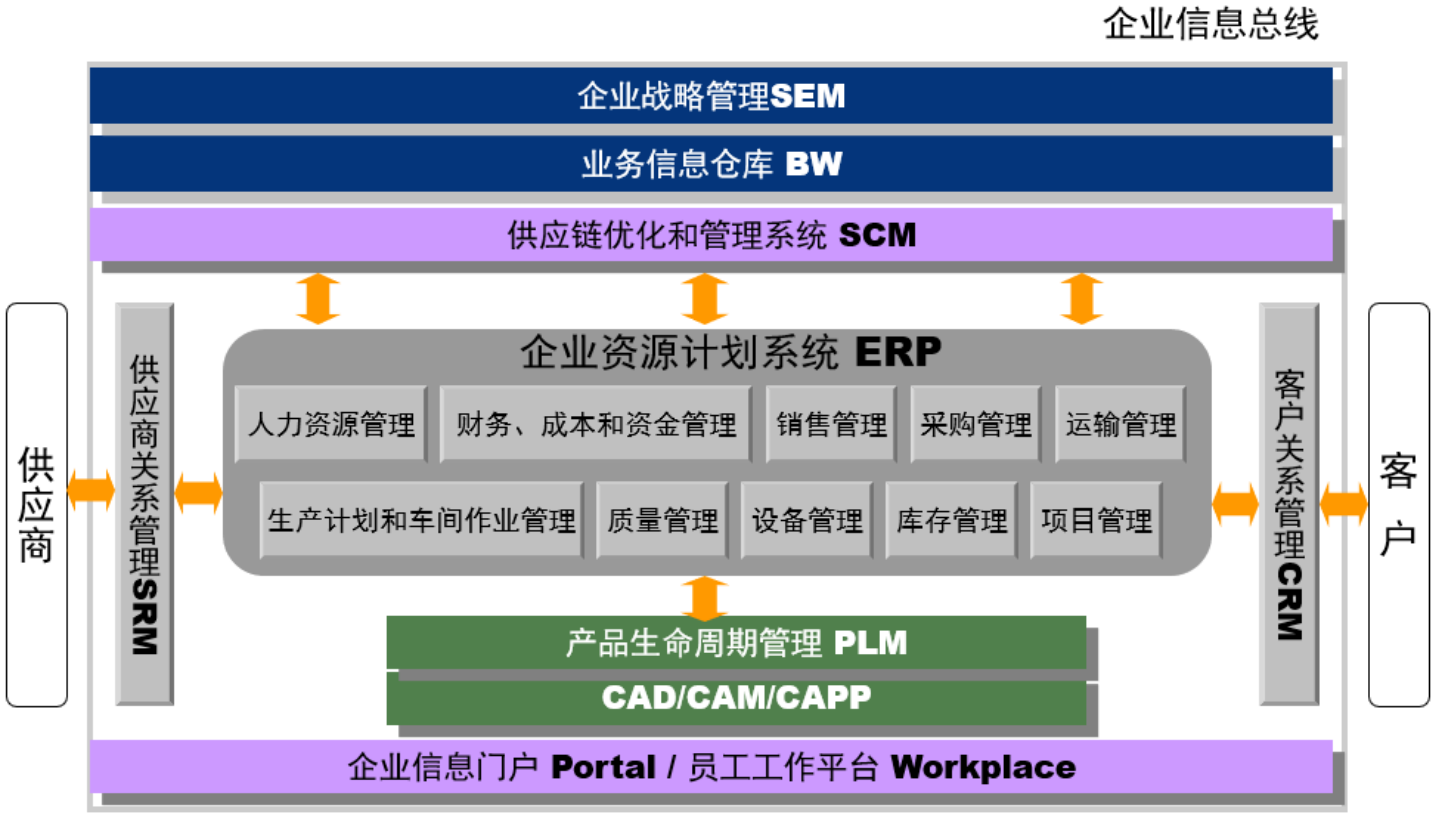
- 数据治理（高可用的“主题数据”）
- 数据挖掘（挖掘数据价值，形成数据资产）



数据智能方向的数据视角：数据规划、数据治理、数据挖掘







数据智能方向的数据视角：数据规划、数据治理、数据挖掘



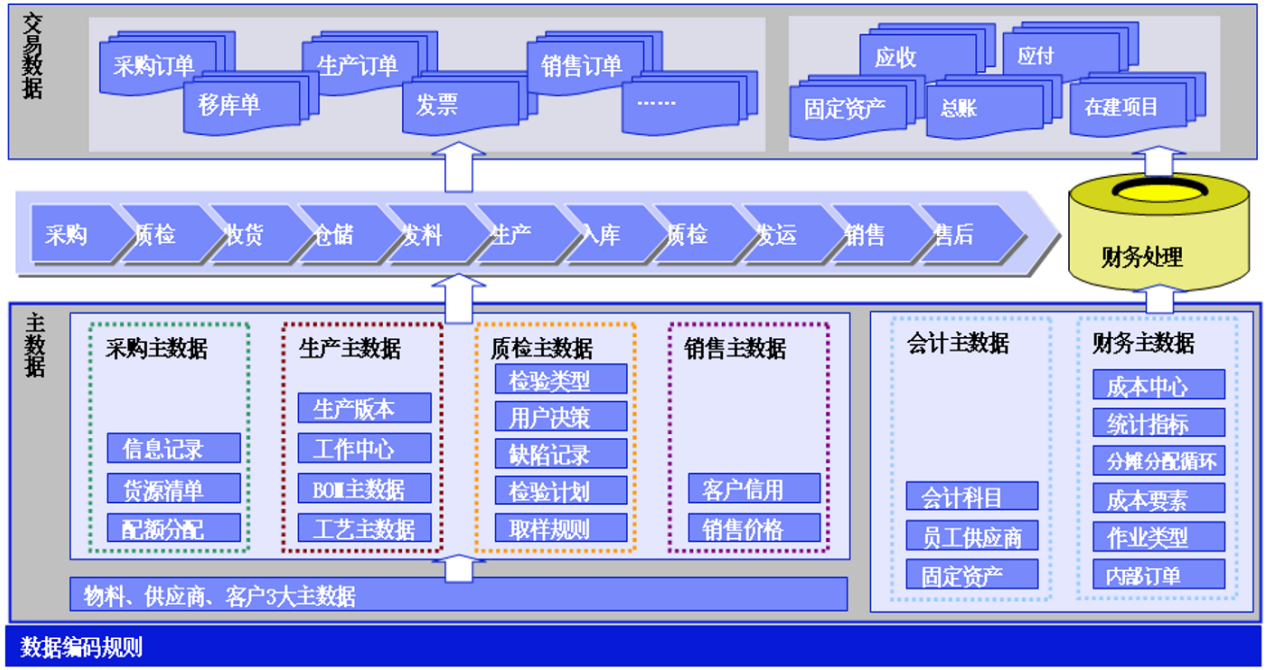
数据资源规划-基础/先导工程

以ERP为代表的—应用系统

Global Business Services

未来有色主数据体系将覆盖到财务、采购、销售、生产、质检等环节

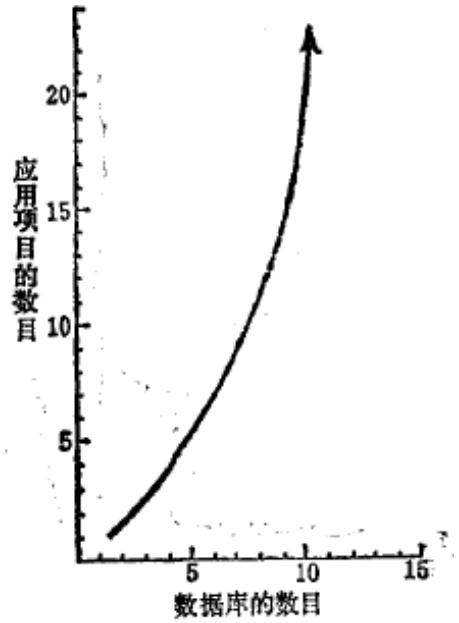
- 使用清晰的技术数据管理方法，有效组织数据收集、整理、清理等工作，以保证进入系统运行的数据的正确性。

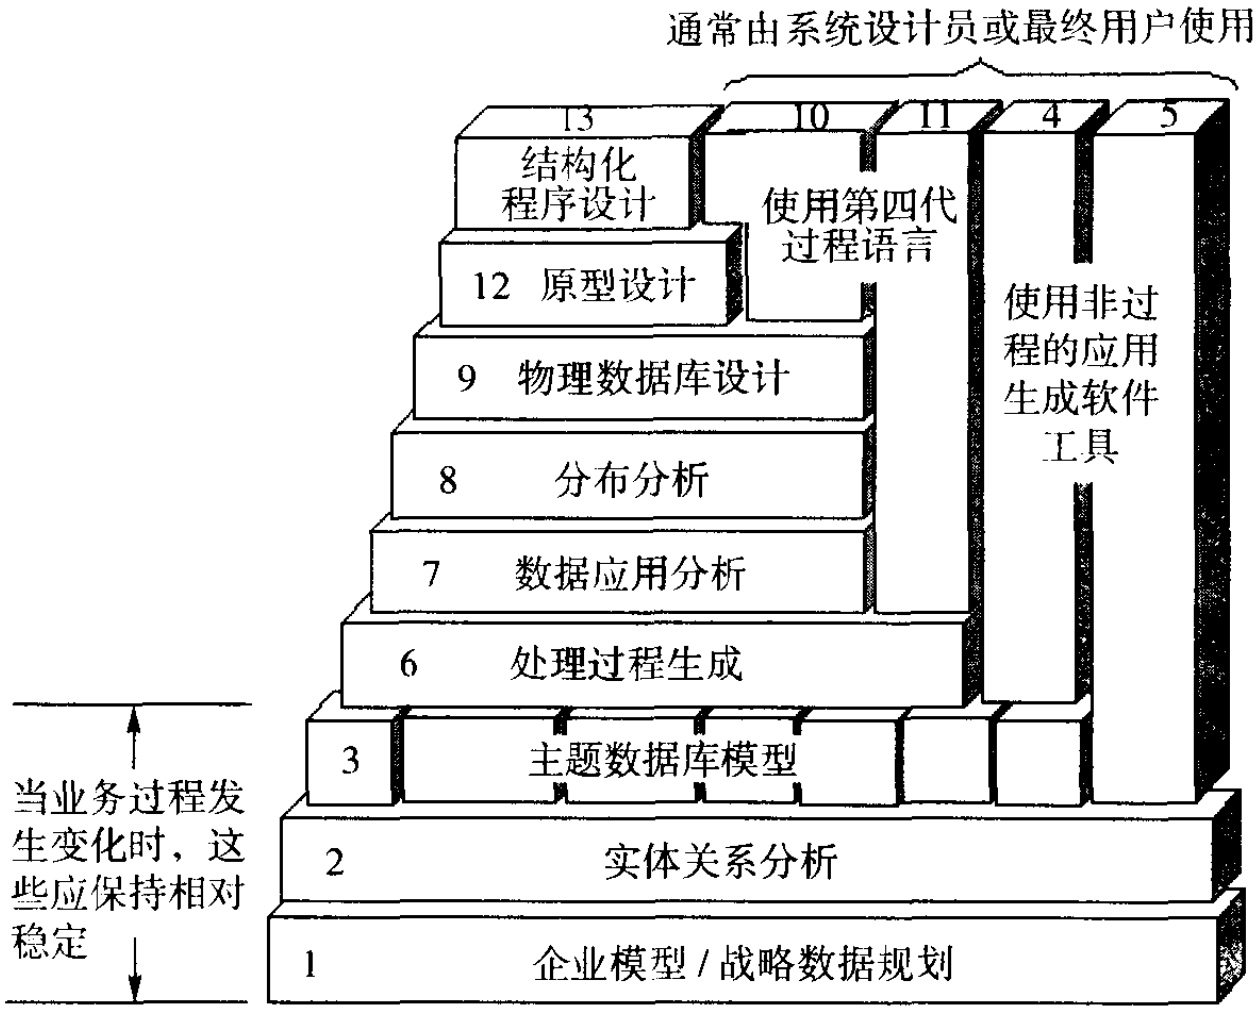


数据智能方向的数据视角：数据规划、数据治理、数据挖掘

方法论1：信息工程方法论（IEM）
詹姆斯·马丁(James Martin)





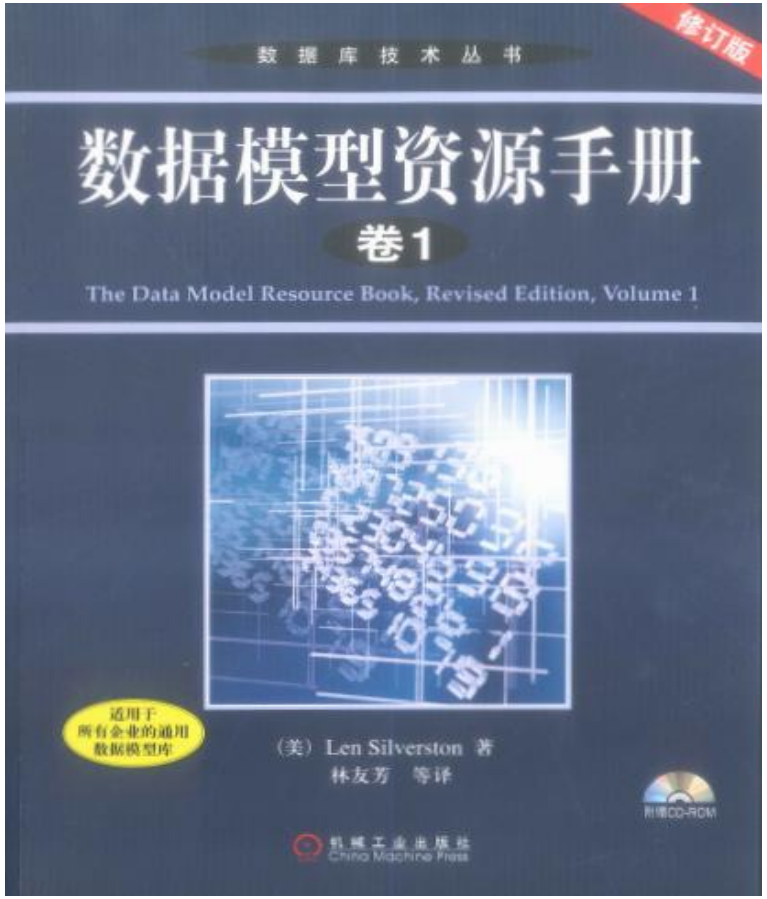


信息工程方法论与总体数据规划

- **步骤1：职能域划分**
  - 研究对象（企业/事业）的事业发展规划
  - 研究对象信息化发展规划
  - 研究并整理对象各部门的职责和主要业务（职责、人员、岗位）
  - 产生全域业务模型，划分职能域
- **步骤2：职能域业务分析**
  - 业务分析：对职能域逐个进行业务分析
    - 按“业务活动”＋“角色”＋“时序”三个元素整理业务流程
  - 业务梳理
    - 业务模型
    - 信息流分析：按用户、功能、数据三个要素进行描述
    - “计算机化”的可行性分析
  - 业务抽象与演绎
    - 功能模型
    - 数据模型
- **步骤3：全域功能模型、数据模型**
  - 全域功能模型
    - 汇总各职能域的功能模型
    - 通过分解、归类、合并，生成全域功能模型
  - 全域数据模型
    - 汇总各职能域数据模型
    - 分析各职能域主题数据库之间的关系，形成全域数据模型

数据智能方向的数据视角：数据规划、数据治理、数据挖掘

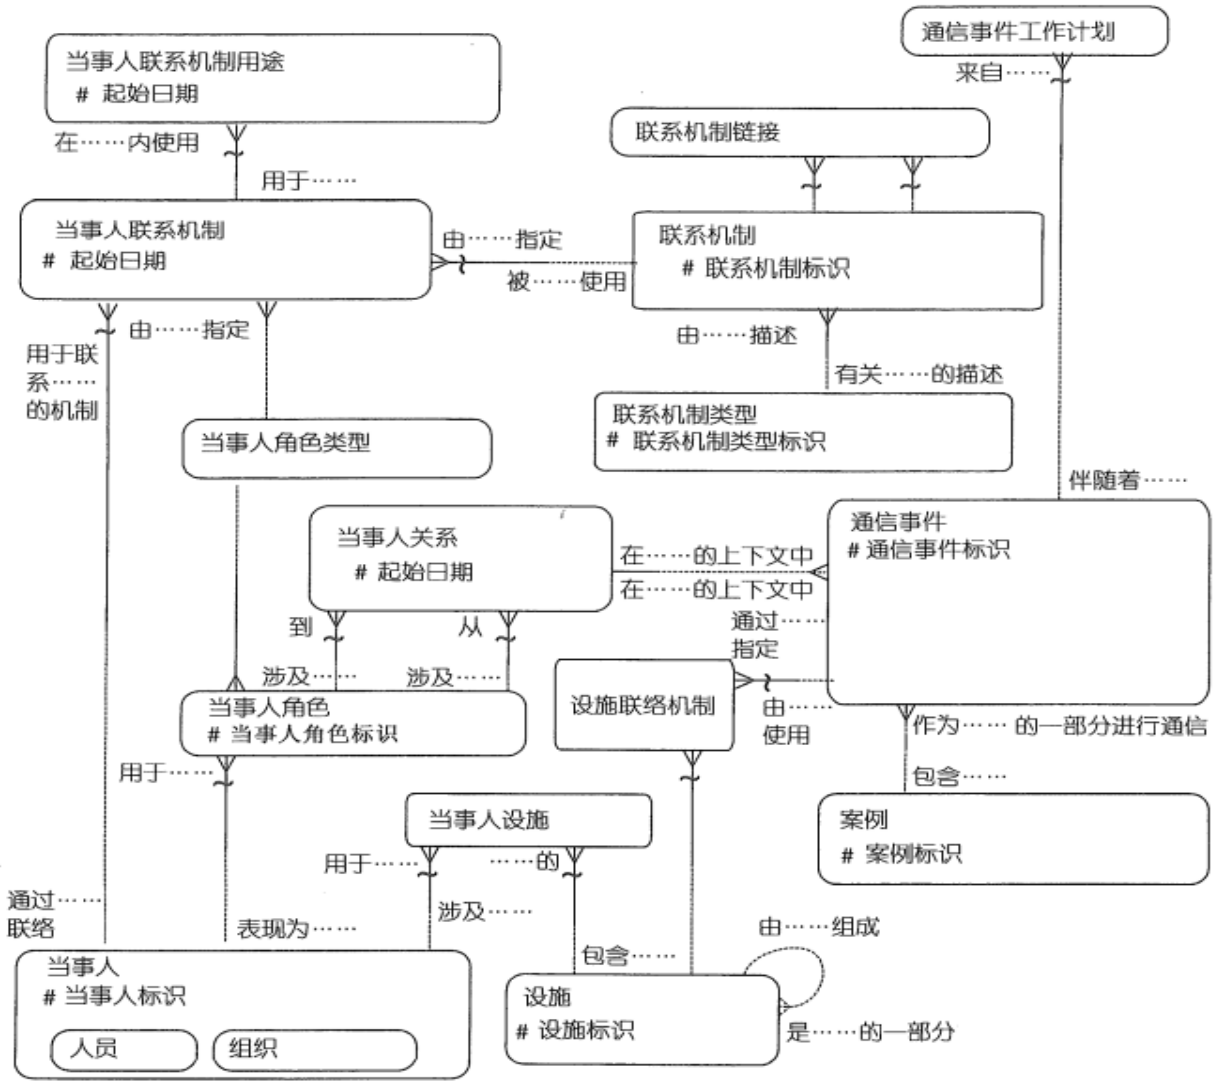
方法论2：行业数据模板



第1章 绪论
第2章 人与组织
第3章 产品模型
第4章 产品订购模型
第5章 装运模型
第6章 工作计划模型
第7章 发票模型
第8章 会计和预算模型
第9章 人力资源模型
第10章 根据企业数据模型建立数据
第11章 一个数据仓库数据模型范例
第12章 销售分析星型模式设计
第13章 人力资源的星型模式设计
第14章 附加的星型模式设计
第15章 实施通用数据模型

- 卷1为一系列的行业提供了企业业务生命周期中每一个阶段所需的通用数据模型
  - 人和组织间交互并形成各种关系
  - 产品（服务或物理上的货物）的定义、供应、定价、成本，可能还有库存
  - 人和／或组织间因购买产品而建立起来的承诺（在不同场合或许会称为订单、协议、合同、金融事务，等等）
  - 装运，将物理货品运输到它们的目的地
  - 工作计划，需要对工作进行计划和跟踪，如维修、制造、项目和服务工作的计划
  - 开发票确定应付款
  - 预算和会计用于管理财务问题
  - 对人力资源进行管理和跟踪
- 卷1 中的数据模型适合于大多数企业，因为上述步骤基本反映了多数行业的运作模式。卷1 所描述的这些数据模型标识出了适合于各种行业的基本的信息需求

当事人整体数据模型



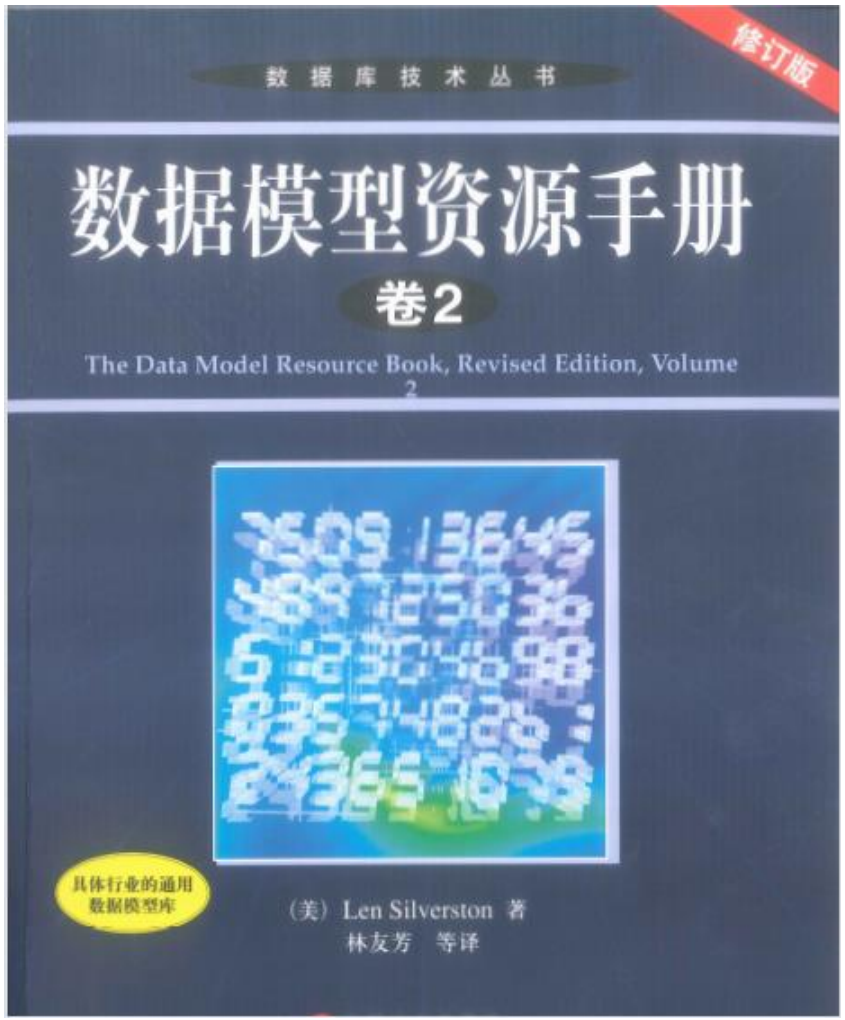
- 最常见的业务信息需求是针对人和组织提出一些问题，并且能针对这些问题给出准确的、可信赖的回答
  - 在办理业务的过程中涉及到的人和组织的属性或特点是什么？
  - 在不同的人之间、在不同的组织之间以及在人和组织之间存在哪些关系？
  - 人以及组织的地址、电话号码和其他联系方式是什么？怎样才能同他们取得联系？
  - 在各种当事人之间发生了哪些类型的通信或联系？为了有效地加强这些通信的后续工作，需要做哪些工作？
- 几乎所有业务应用都要求记录有关人和组织的信息，如客户、供应商、子公司、雇员和承包商等，这些信息在许多不同的系统中是冗余的。因此，确保客户联系方式等关键信息的一致和准确是非常困难的
  - 有关人和组织信息可能应用于销售、市场、采购、订单处理、发票、项目管理和财务中

数据模型资源手册（卷2）

- **卷2将展示卷1中的模型是如何能够满足许多行业的独特信息需求的**
  - —针对每种行业，卷2并不重复给出卷1 中的通用模型，而是在每章的开始处给出一张表，表明如果要将卷1 中的通用数据模型转化成面向行业的数据结构的话，所需进行的一些主要调整以及一些需要增加的内容
- **每章都概略地由在前面8 个主要的主题数据域（当事人、产品、订单、装运、工作计划、发票、会计和人力资源）和行业所特有的主题域组成**
  - —如果不需要太多定制工作的话，一些主题数据域组合起来构成一个单独的区域（例如，对一个特定的行业来说，财务和人力资源通常都不需要太多的定制）
  - —如何为每一个行业定制每个主题域
- **卷1 中的模型与卷2推荐的定制组合，就给用户提供了一个具体行业的通用数据模型，这些模型能在数据模型建模时将用户带到一个更高的起点上**

数据智能方向的数据视角：数据规划、数据治理、数据挖掘

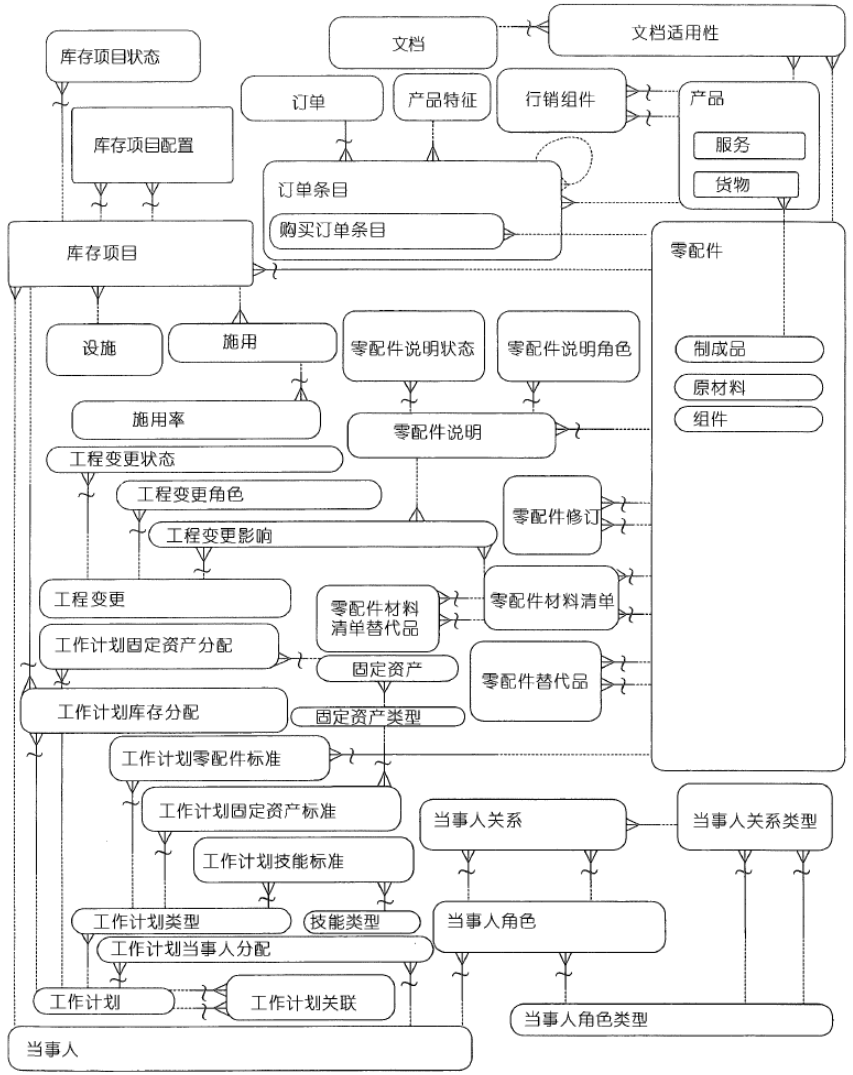
方法论2：行业数据模板



- **卷2将展示卷1中的模型是如何能够满足许多行业的独特信息需求的**
  - 针对每种行业，卷2并不重复给出卷1 中的通用模型，而是在每章的开始处给出一张表，表明如果要将卷1 中的通用数据模型转化成面向行业的数据结构的话，所需进行的一些主要调整以及一些需要增加的内容
- **每章都概略地由在前面8 个主要的主题数据域（当事人、产品、订单、装运、工作计划、发票、会计和人力资源）和行业所特有的主题域组成**
  - 如果不需要太多定制工作的话，一些主题数据域组合起来构成一个单独的区域（例如，对一个特定的行业来说，财务和人力资源通常都不需要太多的定制）
  - 如何为每一个行业定制每个主题域
- **卷1 中的模型与卷2推荐的定制组合，就给用户提供了一个具体行业的通用数据模型，这些模型能在数据模型建模时将用户带到一个更高的起点上**

制造业数据模型

- 针对制造业对通用数据模型所做的修改包括如下几个关键方面
  - —修改当事人角色的类型和名称以及和制造有关的关系
  - —将零配件和产品区别开，维护零配件的信息
  - —添加设计工程数据模型用于说明零配件和产品
  - —添加模型以包括工程的变更
  - —为企业的各种视图添加材料清单结构，它包括工程、制造和行销
  - —为产品（和零配件）替代提供更复杂的模型
  - —为记录实际零配件的变化，添加库存项吕配置数据模型
  - —随时间的变化跟踪产品和零配件的施用和使用情况
  - —改变工作计划和工作计划标准模型的名称，以将焦点集中在生产运行上



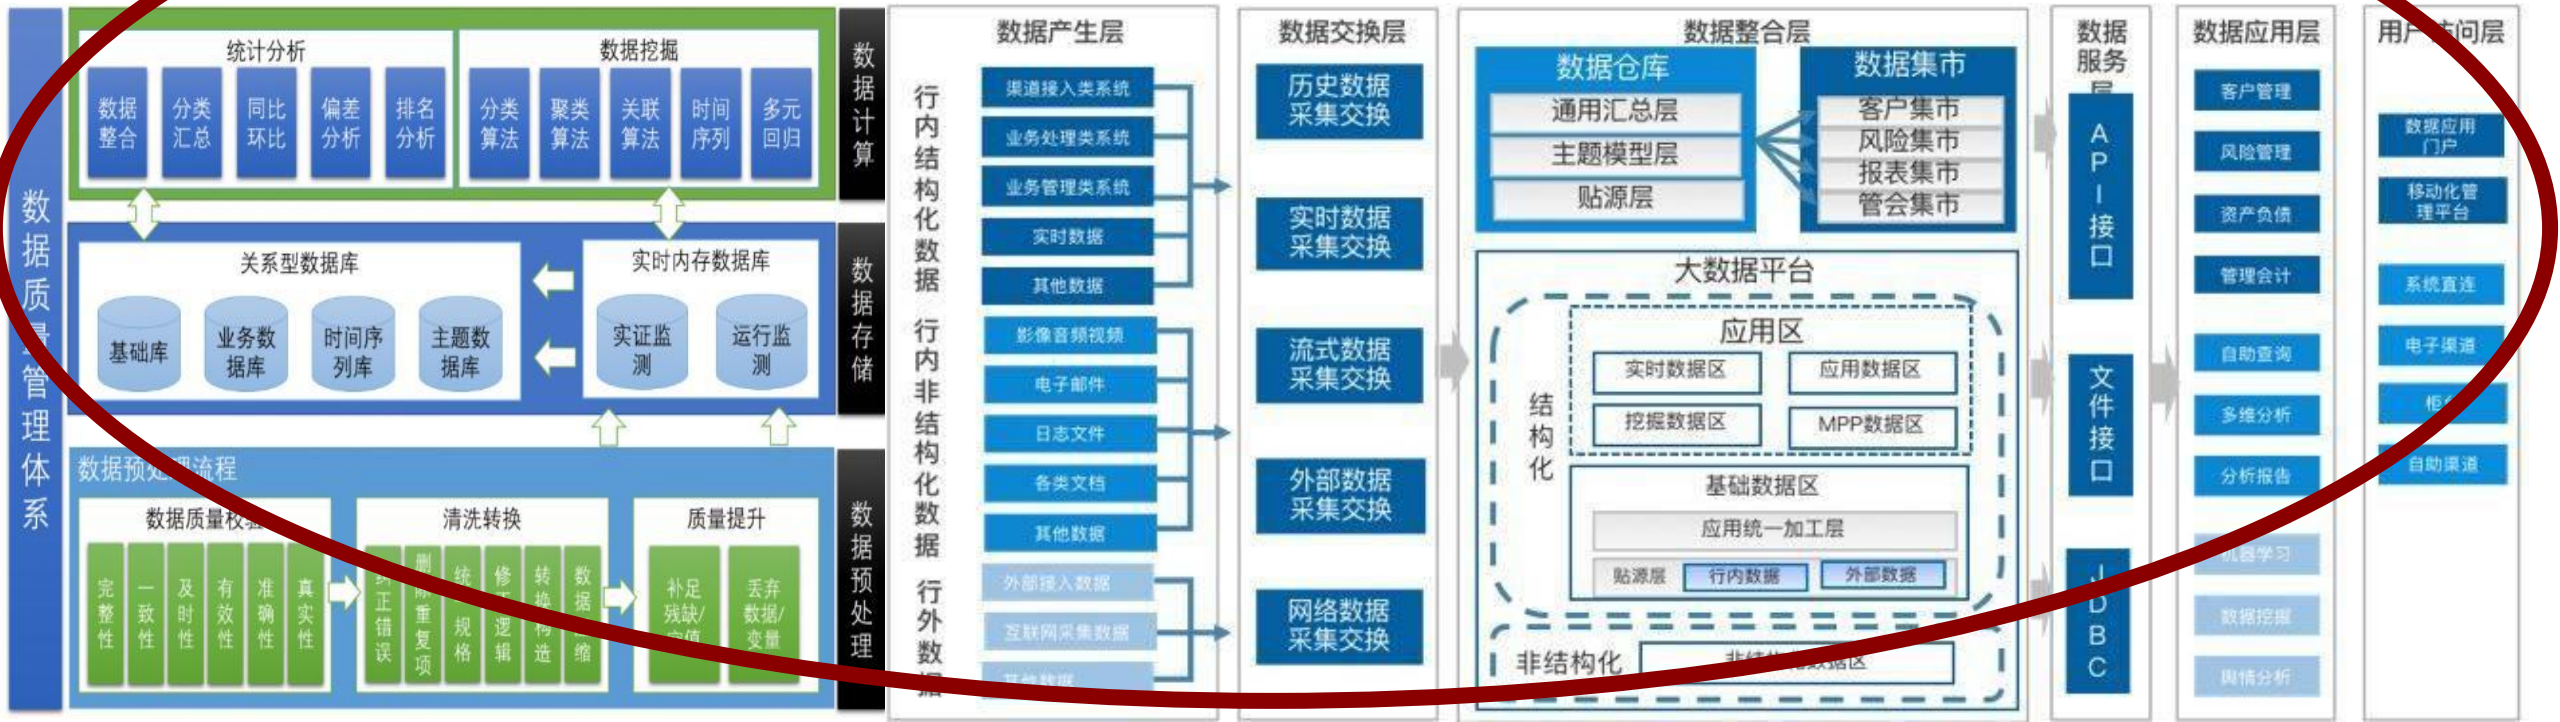
提纲

- 本课程与数据智能方向其它课程之间的关联、衔接、集成
- ***本课程的主要内容***
- 本课程的教学安排

数据智能方向的数据视角：数据规划、数据治理、数据挖掘

- 信息系统规划设计方法（规划“主题数据库”）
- 行业数据模板（高质量的“主题数据库”）

- 数据治理（高可用的“主题数据”）
- 数据挖掘（挖掘数据价值，形成数据资产）



数据智能方向的数据视角：数据规划、数据治理、数据挖掘

内 容 简 介

本书是一本全面关注企业数据标准化方面的工具书，主要分为5篇。第1篇介绍了数据标准化是数据治理的基础，包括数据标准化与数据治理的关系，以及数据标准化主要内容、本书阅读导引。第2篇介绍了数据标准化框架体系，包括架构类数据标准、对象类数据标准、基础类数据标准。第3篇介绍了数据标准化实施流程与方法，包括建立数据标准化保障机制、现状分析及评估、技术平台和工具、数据标准化关键域实施。第4篇介绍了数据标准化评价，包括数据标准化评价方法、数据标准成熟度评价、数据标准化成熟度评价流程。第5篇介绍了数据标准化案例，包括油气行业、多元化集团、装备制造行业、核电行业、汽车行业、金融行业、政务行业、互联网行业等行业的数据治理案例，为读者提供了专业、丰富、可信的数据治理实施范例。

本书是工业大数据应用技术国家工程实验室多年潜心研究的重要科研成果的总结和凝聚，既具有理论高度，也具备面向中国各行业企业的可实操性。参与本书编写的作者均为国内相关领域的专家，所有案例均来自这些企业的实践。

未经许可，不得以任何方式复制或抄袭本书之部分或全部内容。
版权所有，侵权必究。

图书在版编目（CIP）数据

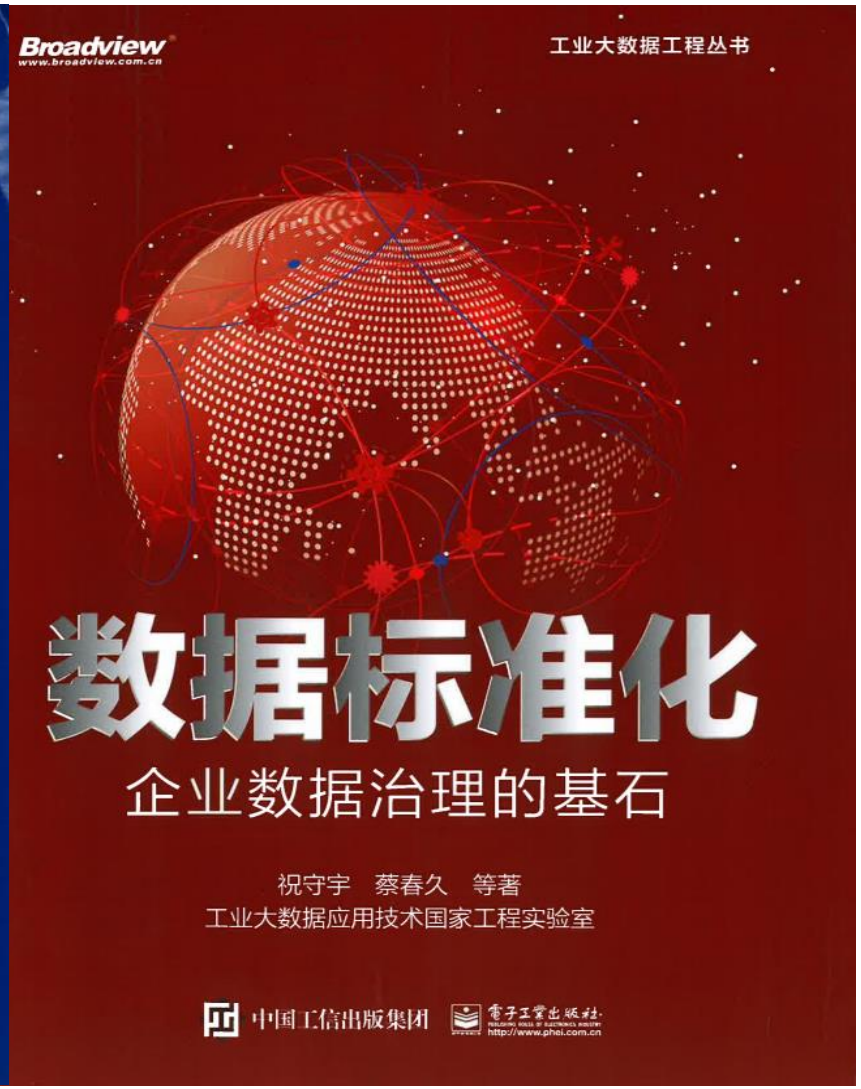
数据标准化：企业数据治理的基石 / 祝守宇等著. —北京：电子工业出版社，2023.1
（工业大数据工程丛书）
ISBN 978-7-121-44398-5

. ①数… II. ①祝… III. ①企业管理—数据管理—研究 IV. ①F272.7

中国版本图书馆 CIP 数据核字（2022）第 192190 号

责任编辑：王　静
印　刷：三河市华成印务有限公司
装　订：三河市华成印务有限公司
出版发行：电子工业出版社
北京市海淀区万寿路 173 信箱　邮编：100036
开　本：787×980　1/16　印张：34.5　字数：721.5 千字
版　次：2023 年 1 月第 1 版
印　次：2023 年 1 月第 1 次印刷
定　价：158.00 元





目录

第 1 篇　概述篇

第 1 章　工业企业需要数据治理 2

1.1　工业革命的演变与发展趋势 2
1.2　工业大数据是第四次工业革命的核心基础 4
1.3　各国的工业大数据战略 6
1.4　工业企业数据的核心价值 7
1.5　我国各行业数据治理现状 10
1.6　数据治理是工业大数据的基础 12
1.7　工业企业数据治理面临的挑战 12
本章精要 14

第 2 章　工业企业数据治理概述 15

2.1　数据治理的相关概念和定义 15
2.2　数据的分类 17
2.3　数据治理的顶层架构 20
2.4　数据治理的核心内容 21
本章精要 22

第 3 章　主流数据治理标准及框架介绍 23

3.1　国际标准 23
3.2　国内标准及模型 24
3.3　专业组织 26
3.4　国内外数据治理体系的对比分析 28
本章精要 30

第 4 章　数据治理的发展趋势 31

4.1　国内外数据治理的演变与发展 31
4.2　数据隐私保护政策 32
4.3　区块链与数据共享 33
4.4　5G 技术与数据安全 38
4.5　新技术与数据治理 39
4.6　数据文化与伦理道德 40
4.7　工业企业数据的运营 41
本章精要 43

第 5 章　本书阅读导引 44

5.1　数据治理是一个系统工程 44
5.2　工具是数据治理的保障 45
5.3　实施数据治理有路线可循 45
5.4　数据治理已在诸多行业成功实施 46
参考资料 47

第 2 篇　体系篇

第 6 章　数据管控 51

6.1　数据管控概述 51
6.2　组织架构 53
6.2.1　数据治理组织架构 53
6.2.2　数据治理组织模式 55
6.2.3　数据治理职责分工 58
6.3　制度规范 61
6.3.1　数据治理制度框架 61
6.3.2　数据治理制度修订 64
6.4　执行流程 65
6.4.1　数据治理总体流程框架 65
6.4.2　数据治理典型场景的流程 67
6.5　设计机制 70
6.6　绩效体系 72
6.7　标准体系 74
本章精要 76

第 7 章　数据战略 77

7.1　数据战略概述 77
7.2　数据战略规划 77
7.2.1　愿景和目标 78
7.2.2　基本原则 79
7.2.3　战略举措选择 80
7.2.4　模型工具 81
7.3　数据战略实施 82
7.3.1　实施策略 83
7.3.2　实施路径 83
7.3.3　实施步骤 83
本章精要 87

第 8 章　数据架构 88

8.1　数据架构概述 89
8.2　框架设计 90
8.2.1　数据分布 90
8.2.2　数据主题域 92
8.2.3　数据关联关系 93
8.3　数据建模 98
8.3.1　概念数据模型 99
8.3.2　逻辑数据模型 100
8.3.3　物理数据模型 101
8.3.4　数据模型开发方法 102
本章精要 105

第 9 章　主数据管理 106

9.1　主数据和主数据管理 106
9.1.1　主数据的特征 106
9.1.2　主数据管理的基本概念 107
9.2　主数据标准管理 108
9.3　主数据全生命周期管理 109

9.4 主数据应用管理 110
9.5 企业常用的几类主数据 112
9.5.1 物料主数据 112
9.5.2 设备主数据 113
9.5.3 资产主数据 114
9.5.4 财务主数据 115
9.5.5 组织机构和员工主数据 116
本章精要 116

第 10 章 元数据管理 117

10.1 元数据的定义 117
10.2 元数据分类 117
10.2.1 业务元数据 118
10.2.2 技术元数据 119
10.2.3 操作元数据 120
10.3 元数据核心能力 120
10.4 元数据的价值 123
本章精要 124

第 11 章 数据指标管理 125

11.1 数据指标管理概述 125
11.1.1 数据指标应用和管理中的挑战 125
11.1.2 设计目的 126
11.1.3 设计思路 126
11.2 体系框架 128
11.2.1 典型的数据指标定义框架 128
11.2.2 指标选取原则及方法 129
11.2.3 指标体系层级设计 130
11.2.4 指标体系评价方法 131
11.3 找指标 132
11.4 理指标 134
11.5 管指标 136
11.6 用指标 137
本章精要 137

第 12 章 时序数据管理 138

12.1 时序数据管理概述 138
12.2 时序数据的特点 139
12.3 时序数据的应用 141
12.3.1 技术挑战 141
12.3.2 典型的技术架构及特点 142
12.3.3 系统核心功能 143
本章精要 143

第 13 章 数据质量管理 144

13.1 数据质量需求 144
13.2 数据质量检查 145
13.3 数据质量分析 146
13.4 数据质量提升 147
13.5 数据质量评估 149
13.5.1 数据质量问题的起因 150
13.5.2 数据质量管理技术指标 151
13.5.3 数据质量管理业务指标 152
本章精要 153

第 14 章 数据安全管理 155

14.1 数据安全管理概述 155
14.2 数据安全体系框架 156
14.3 数据安全防护策略 159
14.4 数据安全审计 161
14.5 数据安全风险评估 162
14.6 数据应急保障 164
本章精要 165

第 15 章 数据交换与服务 166

15.1 数据交换与服务的意义 167
15.2 数据交换与服务技术演进 168
15.2.1 文件共享技术 168
15.2.2 数据库中间表技术 168
15.2.3 点对点接口技术 168
15.2.4 消息队列技术 170
15.2.5 企业服务总线交换技术 171
15.2.6 ETL 数据交换技术 173
15.2.7 物联网数据采集交换技术 173
15.3 工业企业数据交换与服务标准体系架构 175
15.3.1 CPS 信息交换模型 176
15.3.2 设备互联总线 177
15.3.3 应用互联总线 178
15.3.4 数据总线 179
15.3.5 开放互联 API 网关 181
本章精要 182

第 16 章 数据共享与开放 183

16.1 共享与开放概述 183
16.2 数据资源目录 185
16.3 数据资源准备 186
16.3.1 数据采集 186
16.3.2 数据加工 187
16.3.3 数据保密 187
16.3.4 数据装载 189
16.3.5 数据发布 189
16.4 数据服务 190
16.5 共享与开放评价 190
本章精要 191

第 17 章 数据管理成熟度评估 192

17.1 数据管理成熟度评估模型 192
17.2 数据管理成熟度等级定义 195
17.3 开展数据管理成熟度评估 198
17.4 数据管理成熟度评估实施 199
本章精要 200
参考资料 200

第 3 篇 工具篇

第 18 章 数据治理工具概述 203

第 19 章 数据资产运营工具 207

19.1 数据资产目录 207
19.1.1 总体概述 208
19.1.2 数据资产目录系统构建 208
19.1.3 数据资产目录能力评估模型 210
19.2 数据资产价值评估 213
19.2.1 总体概述 213
19.2.2 数据资产价值评估模型 214
19.2.3 数据资产价值评估工具 223
本章精要 224

第 20 章 数据模型管理工具 225

20.1 数据模型管理工具概述 225

20.2 企业级数据模型管控 226
20.3 数据标准管控 228
20.3.1 标准的发布和工具访问 228
20.3.2 模型设计中的应用数据标准 228
20.3.3 数据标准应用情况的自动检核 229
20.3.4 自定义标准的发布管理 229
20.4 数据字典的质量检核 230
本章精要 230

第 21 章 数据指标管理工具 231

21.1 指标库管理 231
21.2 指标体系管理 232
21.3 指标评价管理 233
21.4 指标应用管理 234
本章精要 235

第 22 章 主数据管理工具 236

22.1 主数据提取与整合 236
22.2 主数据模型管理 237
22.3 主数据清洗管理 238
22.3.1 主数据清洗的内容 239
22.3.2 主数据清洗的一般过程 239
22.4 主数据全周期管理 242
22.5 主数据质量管理 244
22.6 主数据发布与共享 246
本章精要 248

第 23 章 元数据管理工具 249

23.1 元数据管理工具概述 249
23.2 元数据在数据架构管理中的应用 250
23.3 元数据在数据资产目录中的应用 251
23.4 元数据在主数据管理中的应用 251
23.5 元数据在数据交换和共享中的应用 251
23.6 元数据在大数据平台中的应用 252
本章精要 253

第 24 章 时序数据处理工具 254

24.1 通用大数据处理工具的不足 254
24.2 时序数据处理工具应具备的功能和特点 255
24.3 时序数据的采集 257
24.4 时序数据处理工具 258
本章精要 260

第 25 章 数据质量管理工具 261

25.1 数据质量管理工具概述 261
25.2 数据质量稽核规则设置 262
25.3 数据质量任务管理 263
25.4 数据质量报告 264
本章精要 264

第 26 章 数据交换与服务工具 265

26.1 数据交换与服务工具概述 265
26.2 数据采集 266
26.3 数据交换 268
26.3.1 前置交换子系统 268
26.3.2 交换传输子系统 269
26.3.3 交换管理子系统 269
26.4 数据加工服务 269
26.5 数据共享服务 271
26.6 工业大数据技术平台 272
26.6.1 工业大数据的采集 272
26.6.2 工业大数据的交换 274
26.6.3 工业大数据的处理 275
本章精要 277

第 27 章 数据安全管理工具 278

27.1 数据安全管理工具概述 278
27.2 数据采集安全管理工具 279
27.2.1 数据分类与分级工具 279
27.2.2 采集内容及策略 279
27.2.3 数据采集人员管理工具 280
27.2.4 数据源鉴别及记录 280
27.3 数据传输安全管理工具 280
27.3.1 加密算法 281
27.3.2 对称加密 281
27.3.3 非对称加密 282
27.4 数据存储安全管理工具 282
27.4.1 数据存储介质管理 283
27.4.2 数据存储安全 283
27.4.3 数据备份和恢复 283
27.4.4 等级划分 284
27.5 数据处理安全管理工具 285
27.6 数据交换安全管理工具 286
27.6.1 数据导入/导出的安全保障 287
27.6.2 数据交换安全 287
27.6.3 数据销毁安全管理 288
27.7 统一的身份认证系统 289
本章精要 290

第 28 章 数据中台 291

28.1 数据中台的概念和定位 291
28.2 数据采集 293
28.2.1 数据采集方式 293
28.2.2 通用数据采集 293
28.2.3 流式数据采集 293
28.3 数据存储 294
28.3.1 分布式数据存储 294
28.3.2 NoSQL 数据存储 294
28.4 数据计算 294
28.4.1 分布式查询 295
28.4.2 分布式计算 295
28.4.3 数据建模 295
28.4.4 数据分析 296
28.5 数据服务 296
28.5.1 API 网关 297
28.5.2 API 生成 298
28.5.3 API 发布 298
28.5.4 API 调用申请 298
28.5.5 API 调用审核 298
28.5.6 API 信息支持 298
28.5.7 API 服务监控 299
28.6 从 ETL 向 ELT 转变 299
本章精要 300
参考资料 300

第 4 篇　实施篇

第 29 章　数据治理实施策略和路径选择 303

29.1　实施内容 303
29.2　路径选择 304
本章精要 306

第 30 章　数据治理顶层架构规划与设计 307

30.1　实施内容 307
30.2　步骤和方法 309
30.2.1　顶层设计总体思路 309
30.2.2　数据治理顶层设计要点 311
30.3　成熟度评估 322
本章精要 324

第 31 章　数据资产运营实施 325

31.1　实施内容 325
31.2　步骤和方法 327
本章精要 328

第 32 章　主数据管理实施 329

32.1　实施内容 329
32.2　步骤和方法 329
32.2.1　实施步骤 329
32.2.2　实施方法 331
本章精要 336

第 33 章　元数据管理实施 337

33.1　实施内容 337
33.2　步骤和方法 337
本章精要 340

第 34 章　数据指标管理实施 341

34.1　实施内容 341
34.2　步骤和方法 342
34.3　模板 344
34.3.1　数据指标项定义 344
34.3.2　形成指标卡片及指标模板 345
34.3.3　数据需求规划 346
本章精要 347

第 35 章　数据质量管理实施 348

35.1　实施内容 348
35.2　步骤和方法 349
35.2.1　数据剖析 349
35.2.2　数据质量诊断 350
35.2.3　数据处理规则 351
35.2.4　数据质量优化 351
35.2.5　数据质量监管 352
35.2.6　实施数据质量管理时需注意的问题 353
本章精要 354

第 36 章　数据安全管理实施 355

36.1　实施内容 355
36.2　实施步骤 355
36.3　实践模式 358
36.3.1　数据安全管理的建设策略 358
36.3.2　数据安全管理的切入方式 359
36.3.3　工业互联网云平台的数据安全 359
本章精要 360

第 37 章　数据治理常见误区 361

本章精要 363
参考资料 363

第 5 篇　案例篇

第 38 章　电力行业：夯实数字化转型基础——南方电网数据资产管理行动实践 365

38.1　背景介绍 365
38.2　项目实施 367
38.3　项目成果 377
38.4　项目亮点和洞察 378
38.5　数据治理愿景 379

第 39 章　电力行业：支撑集团产业数字化转型——国家电投集团数据治理实践 380

39.1　背景介绍 380
39.2　数据治理工作实践 382
39.2.1　五凌电力数据治理实践——水电领域 386
39.2.2　黄河公司数据治理实践——光、风、水领域 390
39.2.3　云南国际数据治理实践——风电领域 392
39.3　经验总结 396
39.4　总结与展望 397

第 40 章　能源化工行业：数据治理助百年油企数字化转型 398

40.1　背景介绍 398
40.2　工作概况 400
40.3　组织保障 404
40.4　主要成果 405
40.5　炼化公司智能工厂数据治理实践案例 408
40.6　建设主要内容 409
40.7　总结与展望 411

第 41 章　钢铁行业：酒钢集团数据治理实践 413

41.1　背景介绍 413
41.2　项目目标 414
41.3　项目实施 414
41.4　项目总结 417
41.5　未来展望 419

第 42 章　汽车行业：数据驱动长安汽车数字化转型 420

42.1　背景介绍 420

42.2 工作概况 422
42.3 组织保障 426
42.4 项目成果 427
42.5 工作价值 431
42.6 交流分享 432

第 43 章 核工业：物料主数据治理助力核电智慧运营 433

43.1 背景介绍 433
43.2 工作概况 435
43.3 组织保障 437
43.4 项目成果 439
43.5 项目总结 440

第 44 章 航天行业：军工企业的“三位一体”数据治理体系建设实践 441

44.1 背景介绍 441
44.2 工作历程 443
44.3 组织保障 447
44.4 实施效果 449
44.5 项目总结 450
44.6 未来展望 453

第 45 章 航空行业：面向航空装备研制生产的数据治理研究与实践 456

45.1 背景介绍 456
45.2 两级数据管控模式 459
45.3 信息分类与编码标准 460
45.4 数据应用场景 462
45.5 总结与展望 466

第 46 章 重型装备制造行业：数据标准，装备中国——中国一重的数据标准化管理项目 468

46.1 背景介绍 468
46.2 数据治理概况 472
46.3 数据治理成果 474
46.4 总结与成效 475

第 47 章 交通物流行业：主数据治理助力中国外运数字化转型 477

47.1 背景介绍 477
47.2 项目实施 479
47.3 主要成果 482
47.4 未来展望 489

第 48 章 建材行业：中国建材集团工业大数据应用实践 490

48.1 背景介绍 490
48.2 工作实施 491
48.3 应用框架与技术路线 493
48.4 工作成果 494

第 49 章 制造行业：威孚集团基于斯欧应用互联平台建设数据通道 501

49.1 背景介绍 501
49.2 项目建设技术方案 505
49.3 项目实施步骤 509
49.4 项目实施效果 511
49.5 项目价值及特点 512

第 50 章 战略投资行业：国投集团的数据标准化管理实践 514

50.1 背景介绍 514
50.2 工作概况 516
50.3 组织保障 519
50.4 项目成果 520
50.5 工作价值 528
50.6 经验分享 529

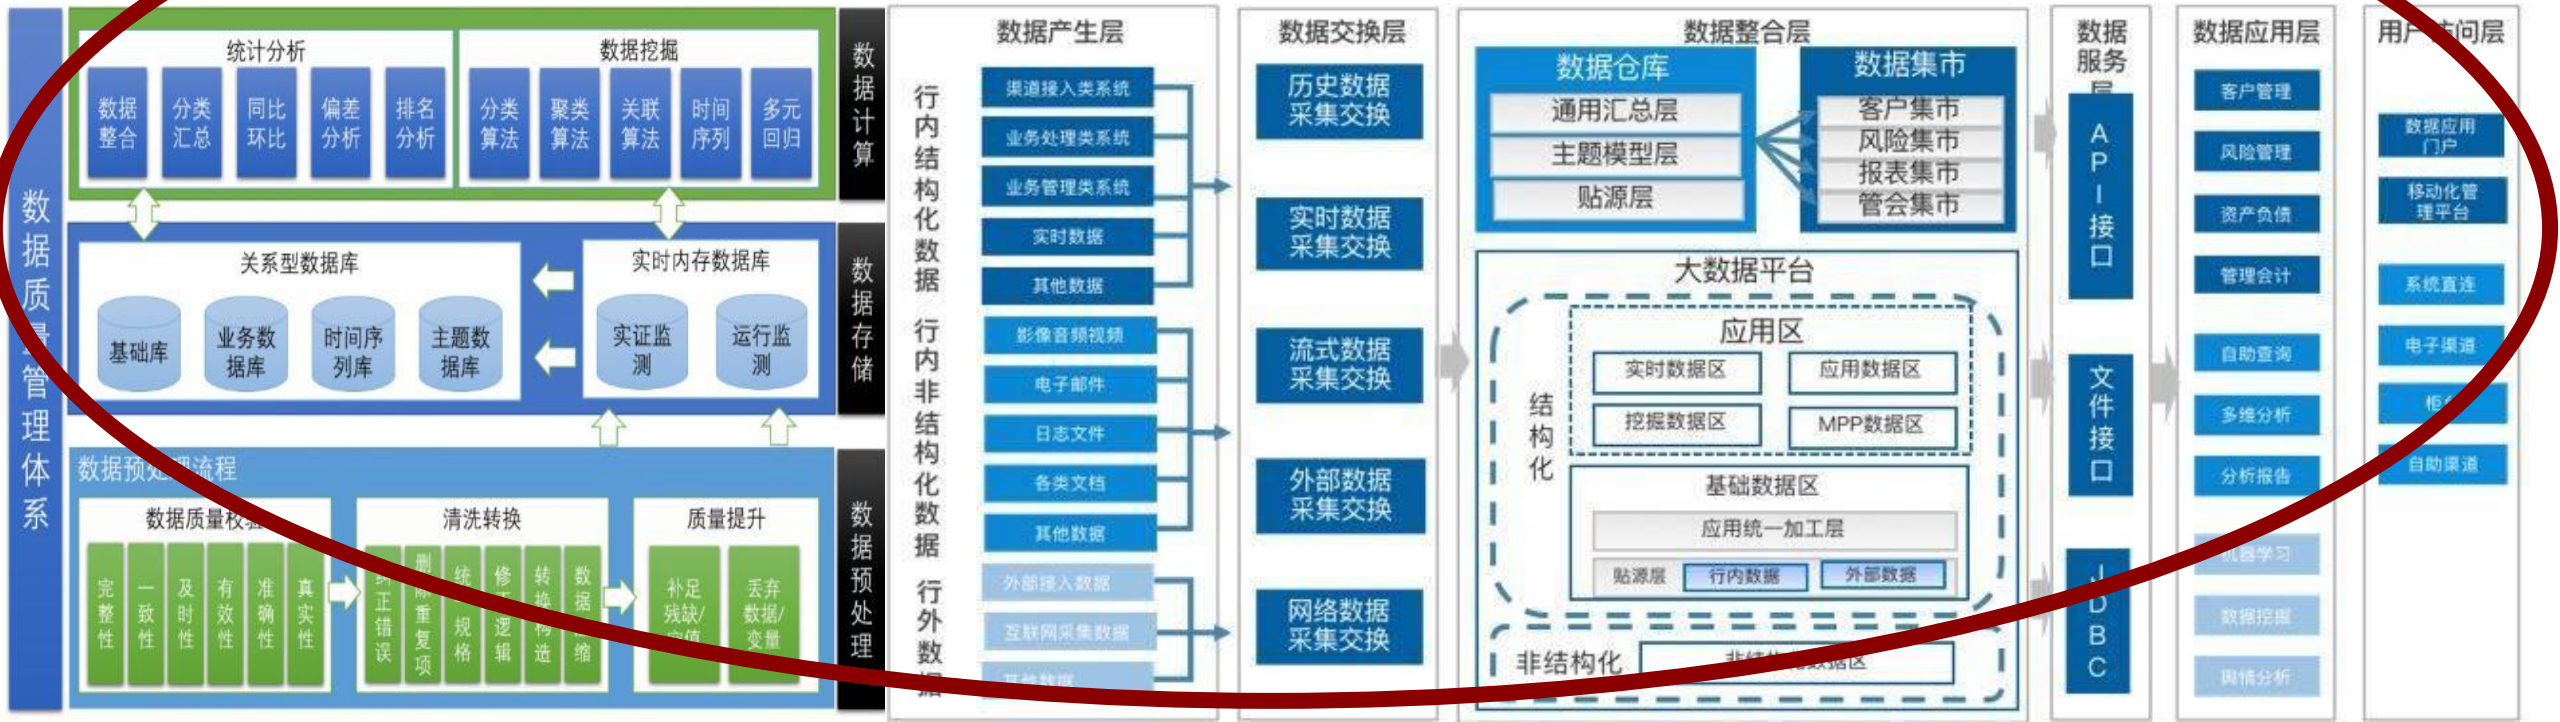
第 51 章 多元化集团：数据治理助力多元化企业集团管控 532

51.1 背景介绍 532
51.2 数据治理概况 534
51.3 组织保障 539
51.4 项目成果 540
51.5 工作价值 543
51.6 项目总结 543

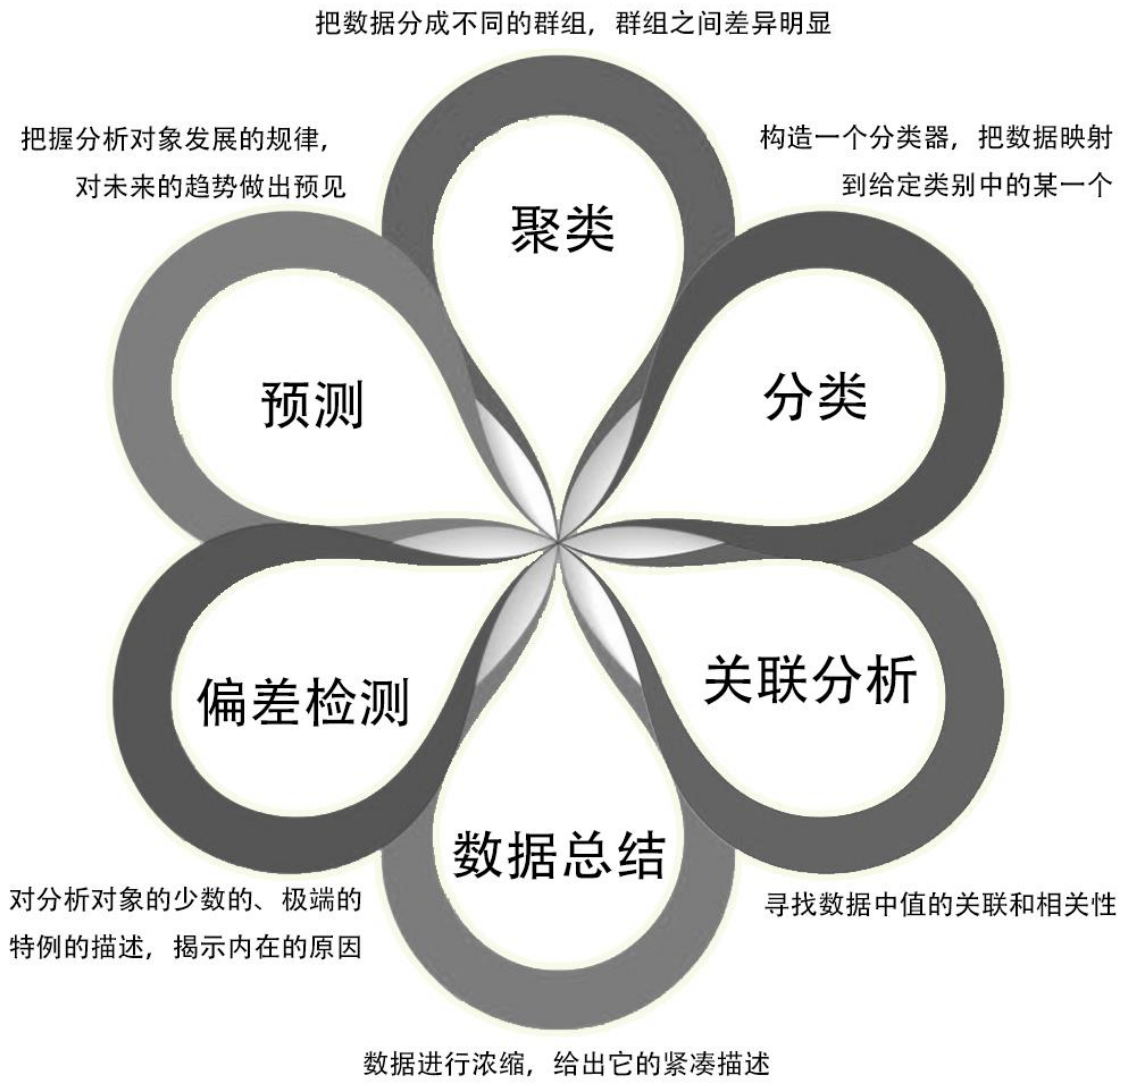
附录 A 工业英文缩写术语表 545

数据智能方向的数据视角：数据规划、数据治理、数据挖掘

- 信息系统规划设计方法（规划“主题数据库”）
- 行业数据模板（高质量的“主题数据库”）
- 数据治理（高可用的“主题数据”）
- 数据挖掘（挖掘数据价值，形成数据资产）



数据挖掘的主要功能分类



数据挖掘的主要功能分类

- 聚类：是一个把数据对象（或观测）划分成子集的过程，每个子集是一个簇
- 分类：是一种重要的数据分析形式，它提取刻画重要数据类的模型
- 关联分析：若两个或多个变量的取值之间存在某种规律性，就称为关联
- 数据总结：继承于数据分析中的统计分析，其目的是对数据进行浓缩，给出它的紧凑描述
- 偏差检测：基本方法是寻找观测结果与参照值之间有意义的差别，对分析对象中少数的、极端的特例进行描述，解释内在原因
- 预测：通过对样本数据（历史数据）的输入值和输出值的关联性学习，得到预测模型，再利用该模型对未来的输入值进行输出值预测

上海交通大学
SHANGHAI JIAO TONG UNIVERSITY



基于校园一卡通消费数据的智慧校园数据挖掘与应用系统设计

指导教师：王东

姓　　名：吴孟维



基于校园网络访问数据集的WIFI网络部署优化与异常上网行为分析

指导教师：王东
姓　　名：钟清娇



电子商务网站用户行为分析

大数据



最早提出“**大数据**”这一概念的是全球知名咨询公司**麦肯锡**，是这样定义大数据的：**一种规模大到在获取、存储、管理、分析方面大大超出了传统数据库软件工具能力范围的数据集合，具有海量的数据规模、快速的数据流转、多样的数据类型以及价值密度四大特征**

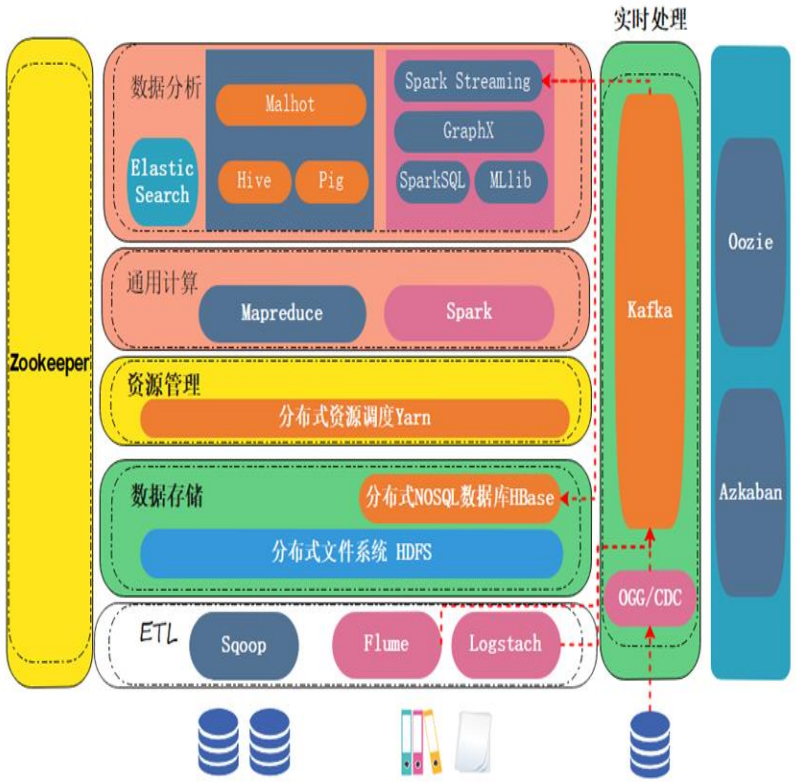
研究机构**Gartner**是这样定义大数据的：**“大数据”是需要新处理模式才能具有更强的决策力、洞察发现力和流转优化能力来适应海量、高增长率和多样化的信息资产**



大数据：利用常规技术不能有效处理的数据

大数据处理技术架构

监测管理（Monitoring） OpenTSDB Amdari	操作框架 （Operational Frameworks）	基准测试（Benchmarking） YCSB Grid Mix Background
数据摄取（Ingest） Flume, Sqoop, Kafka	数据集成 （Data Integration）	序列化（Serialization） Protocol Buffers, Avro
ETL（萃取、转换、加载） Crunch, Falcon, Cascading, Oozie		元数据（Metadata） HCatalog
分析工具（Tools） Pig, Hive, Phoenix	数据分析 （Data Analysis）	分析类库（Libraires） Mllib, SparkR, Mahout
交互式（Interactive） Dremel, Drill, Tez, Impala Shark, Presto, BlinkDB, Dryad	实时（RealTime） Druid, Piot	流式（Streaming） Storm, Samza, Spark Streaming
批处理（Batch） MapReduce	计算框架 （Computational Integration）	迭代式（Iterative） Pregel, Giraph, GraphX, Hama
Spark	引擎（Engines）	Flink
Yarn	资源管理器 （Resource Manager）	Mesos
Paxos Chubby	资源协调器 （Coordination）	ZooKeeper
键值存储（KeyValue） Dynamo, Cassandra, Voldemort	数据存储（Data Stores）	列存储（Column） BigTable, Hbase, Hypertable
图存储（Graph） Neo4j，Titan		文档存储（Graph） CouchDB，MongoDB
Megastore Spanner	ACID	MESA CockroachDB
Google File System Hadoop HDFS	文件系统 （File Systems）	CEPH文件系统 Parquest Tachyon （O）RCFile



2023年10月25日，国家数据局揭牌



刘烈宏担任国家数据局局长

国家数据局组织架构：综合司、政策规划司、数据资源司、数字经济司、数字科技和基础设施建设司

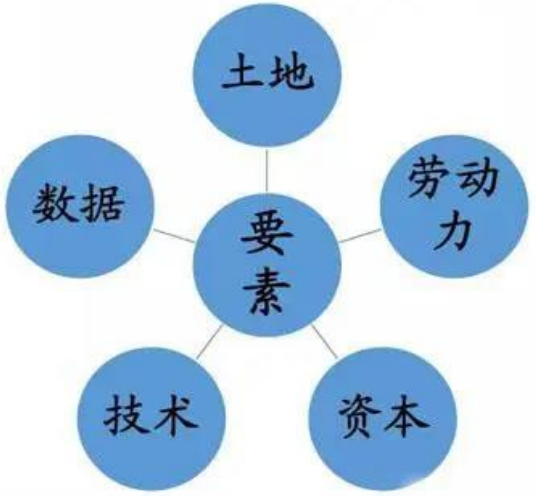
- 负责协调推进数据基础制度建设，统筹数据资源整合共享和开发利用，统筹推进数字中国、数字经济、数字社会规划和建设等，由国家发展和改革委员会管理
  - 将中央网络安全和信息化委员会办公室承担的研究拟订数字中国建设方案、协调推动公共服务和社会治理信息化、协调促进智慧城市建设、协调国家重要信息资源开发利用与共享、推动信息资源跨行业跨部门互联互通等职责等职责划入国家数据局
  - 国家发展和改革委员会的统筹推进数字经济发展、组织实施国家大数据战略、推进数据要素基础制度建设、推进数字基础设施布局建设等职责划入数据局

“数据被定义为生产要素，这本身就体现着重要的理论创新”

习近平总书记强调“要构建以数据为关键要素的数字经济”

- 党的十八大以来，借助超大规模市场优势、海量数据规模、丰富应用场景和领先的数字基础设施，我国数字经济迅猛发展，当前数字经济占GDP的比重已超过四成
- 在此实践基础上，结合对未来生产力变革趋势的科学判断，我国高度重视数据驱动的生产力变革，加快构建有利于释放数据生产力的数据基础制度，并**将数据列为继土地、劳动力、资本和技术后的第五种生产要素**
- **将数据视为一种新型生产要素，并不是简单地在生产函数中增加一个与其他生产要素并列的要素变量，也不是简单地将数据作为劳动资料和劳动对象。**数据生产要素论蕴含着深刻的理论逻辑和重大的理论命题，会对经济学理论创新与发展产生深远影响，对于加快建构中国自主的经济学知识体系意义重大

- 数据不仅是作为一种生产要素在生产过程中独立发挥作用，数据还会推动其他生产要素的重新组合，进而改变生产函数，加快推动技术创新
- 数据除了在生产和交易过程有直接贡献，还对其他生产要素的价值提升以及促进生产函数变革等产生间接贡献



2024年：数据资产的元年

- **2023年8月，国家财政部印发《企业数据资源相关会计处理暂行规定》，明确了数据资源会计处理适用准则及列示和披露要求。该规定2024年1月1日起正式施行**

  ——“数据”正式纳入企业财务三张表之一的“资产负债表”项下，有望批量涌现



中华人民共和国中央人民政府
www.gov.cn

首页 | 简 | 繁 | EN | 登录 | 邮箱 | 无障碍

首页 > 国务院公报 > 2023年第28号

字号：默认 大 超大 | 打印

财政部关于印发《企业数据资源相关会计处理暂行规定》的通知

财会〔2023〕11号

国务院有关部委、有关直属机构，各省、自治区、直辖市、计划单列市财政厅（局），新疆生产建设兵团财政局，财政部各地监管局，有关单位：

为规范企业数据资源相关会计处理，强化相关会计信息披露，根据《中华人民共和国会计法》和相关企业会计准则，我们制定了《企业数据资源相关会计处理暂行规定》，现予印发，请遵照执行。

执行中如有问题，请及时反馈我部。

附件：企业数据资源相关会计处理暂行规定

财 政 部

2023年8月1日



开展数据资产管理需要解决的问题

- 目前关于数据是否能够完全资产化的现实问题和相关争议颇多,但数据资产未来必将成为企业具有关键地位和作用的资产这一观点得到普遍认同
- 数据资产作为新兴产物，如何识别和认定数据资产、如何判断其成本及价值、如何为数据资产进行合理定价，均处于早期研究及摸索阶段

—数据资产识别与认定

—数据资产确权

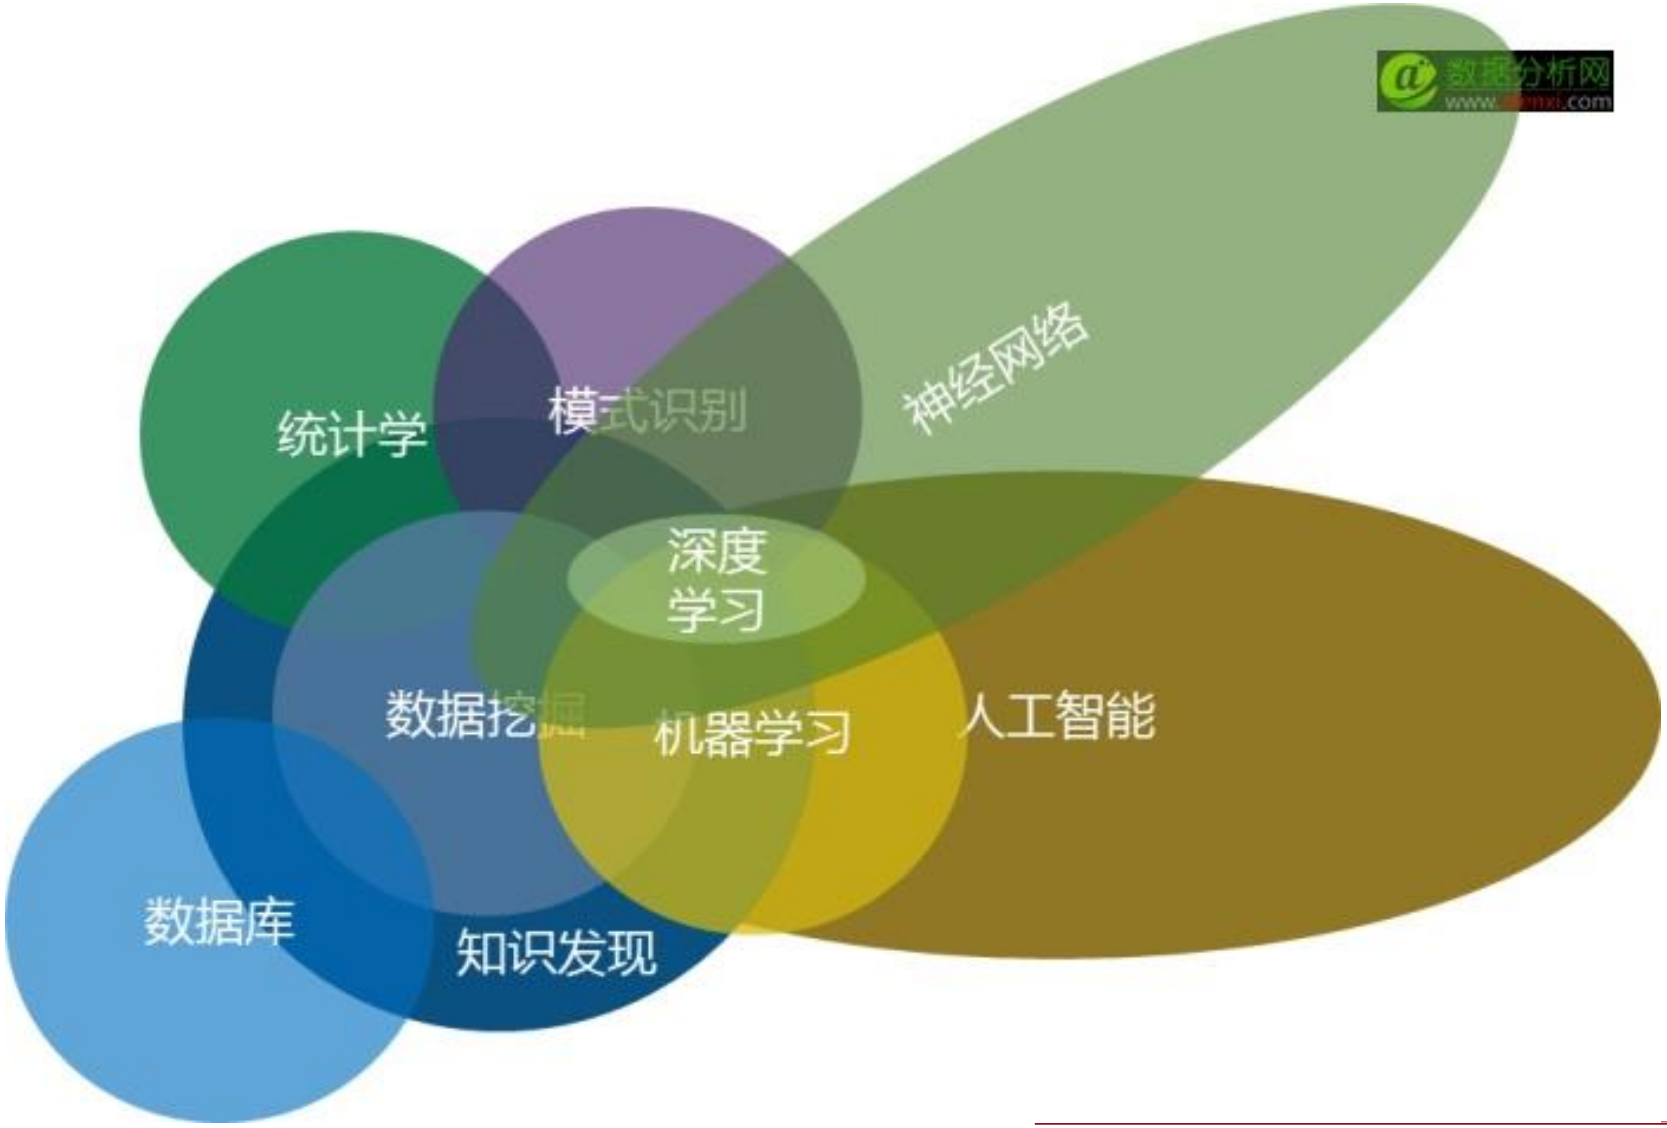
—数据资产评估与计量

—数据资产交易及变现

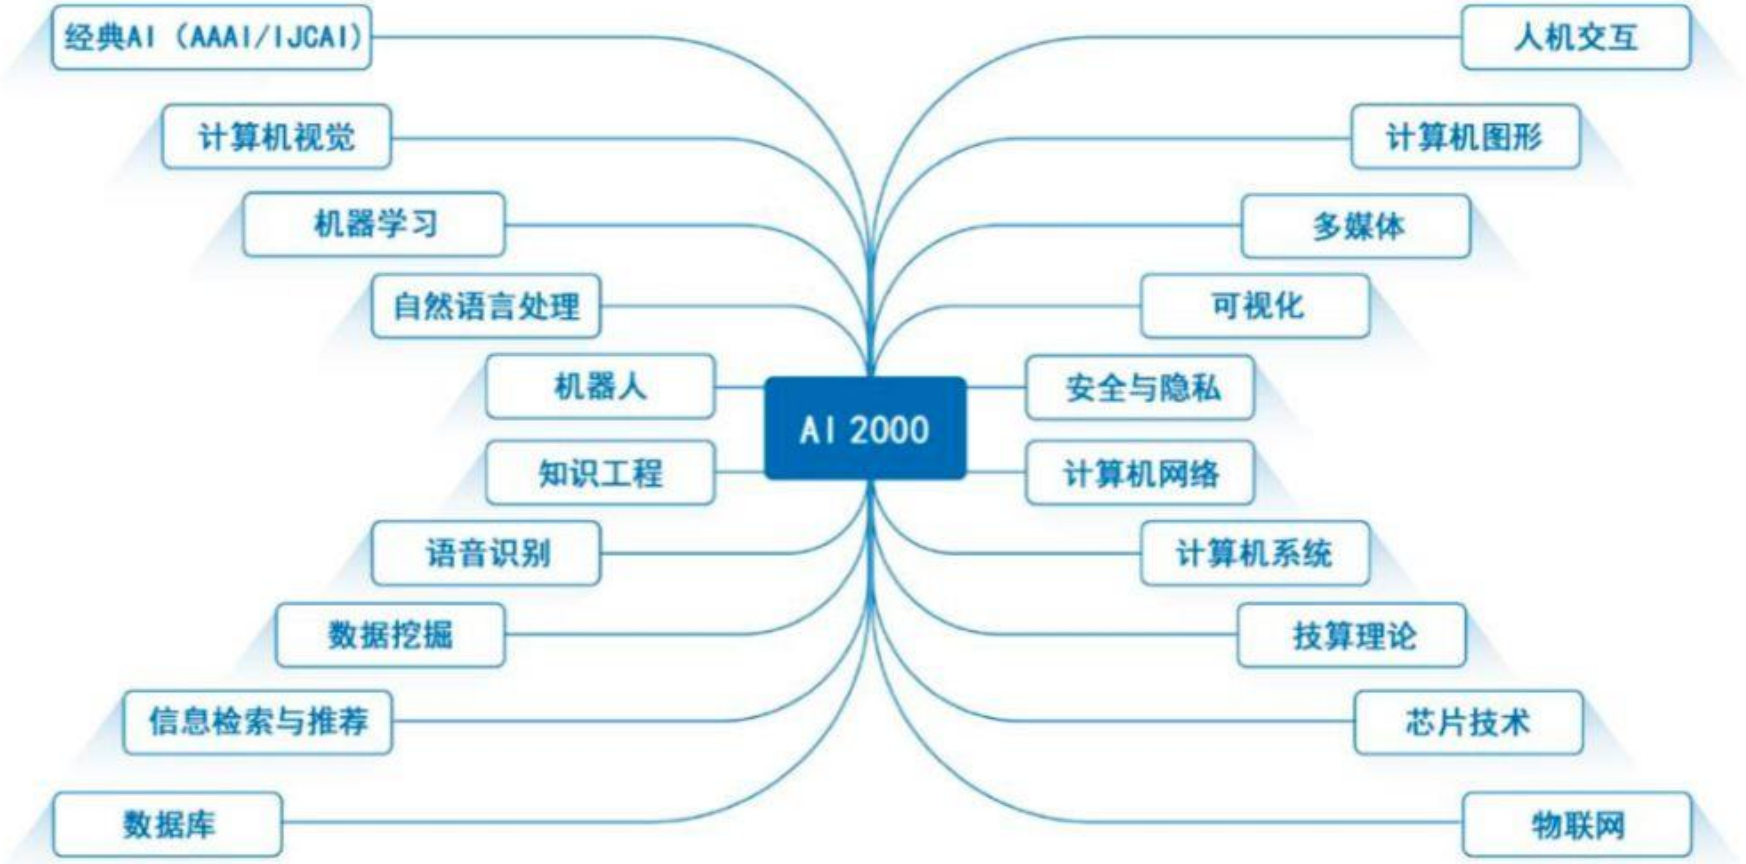
提纲

- 本课程与数据智能方向其它课程之间的关联、衔接、集成
- 本课程的主要内容
- ***本课程的教学安排***

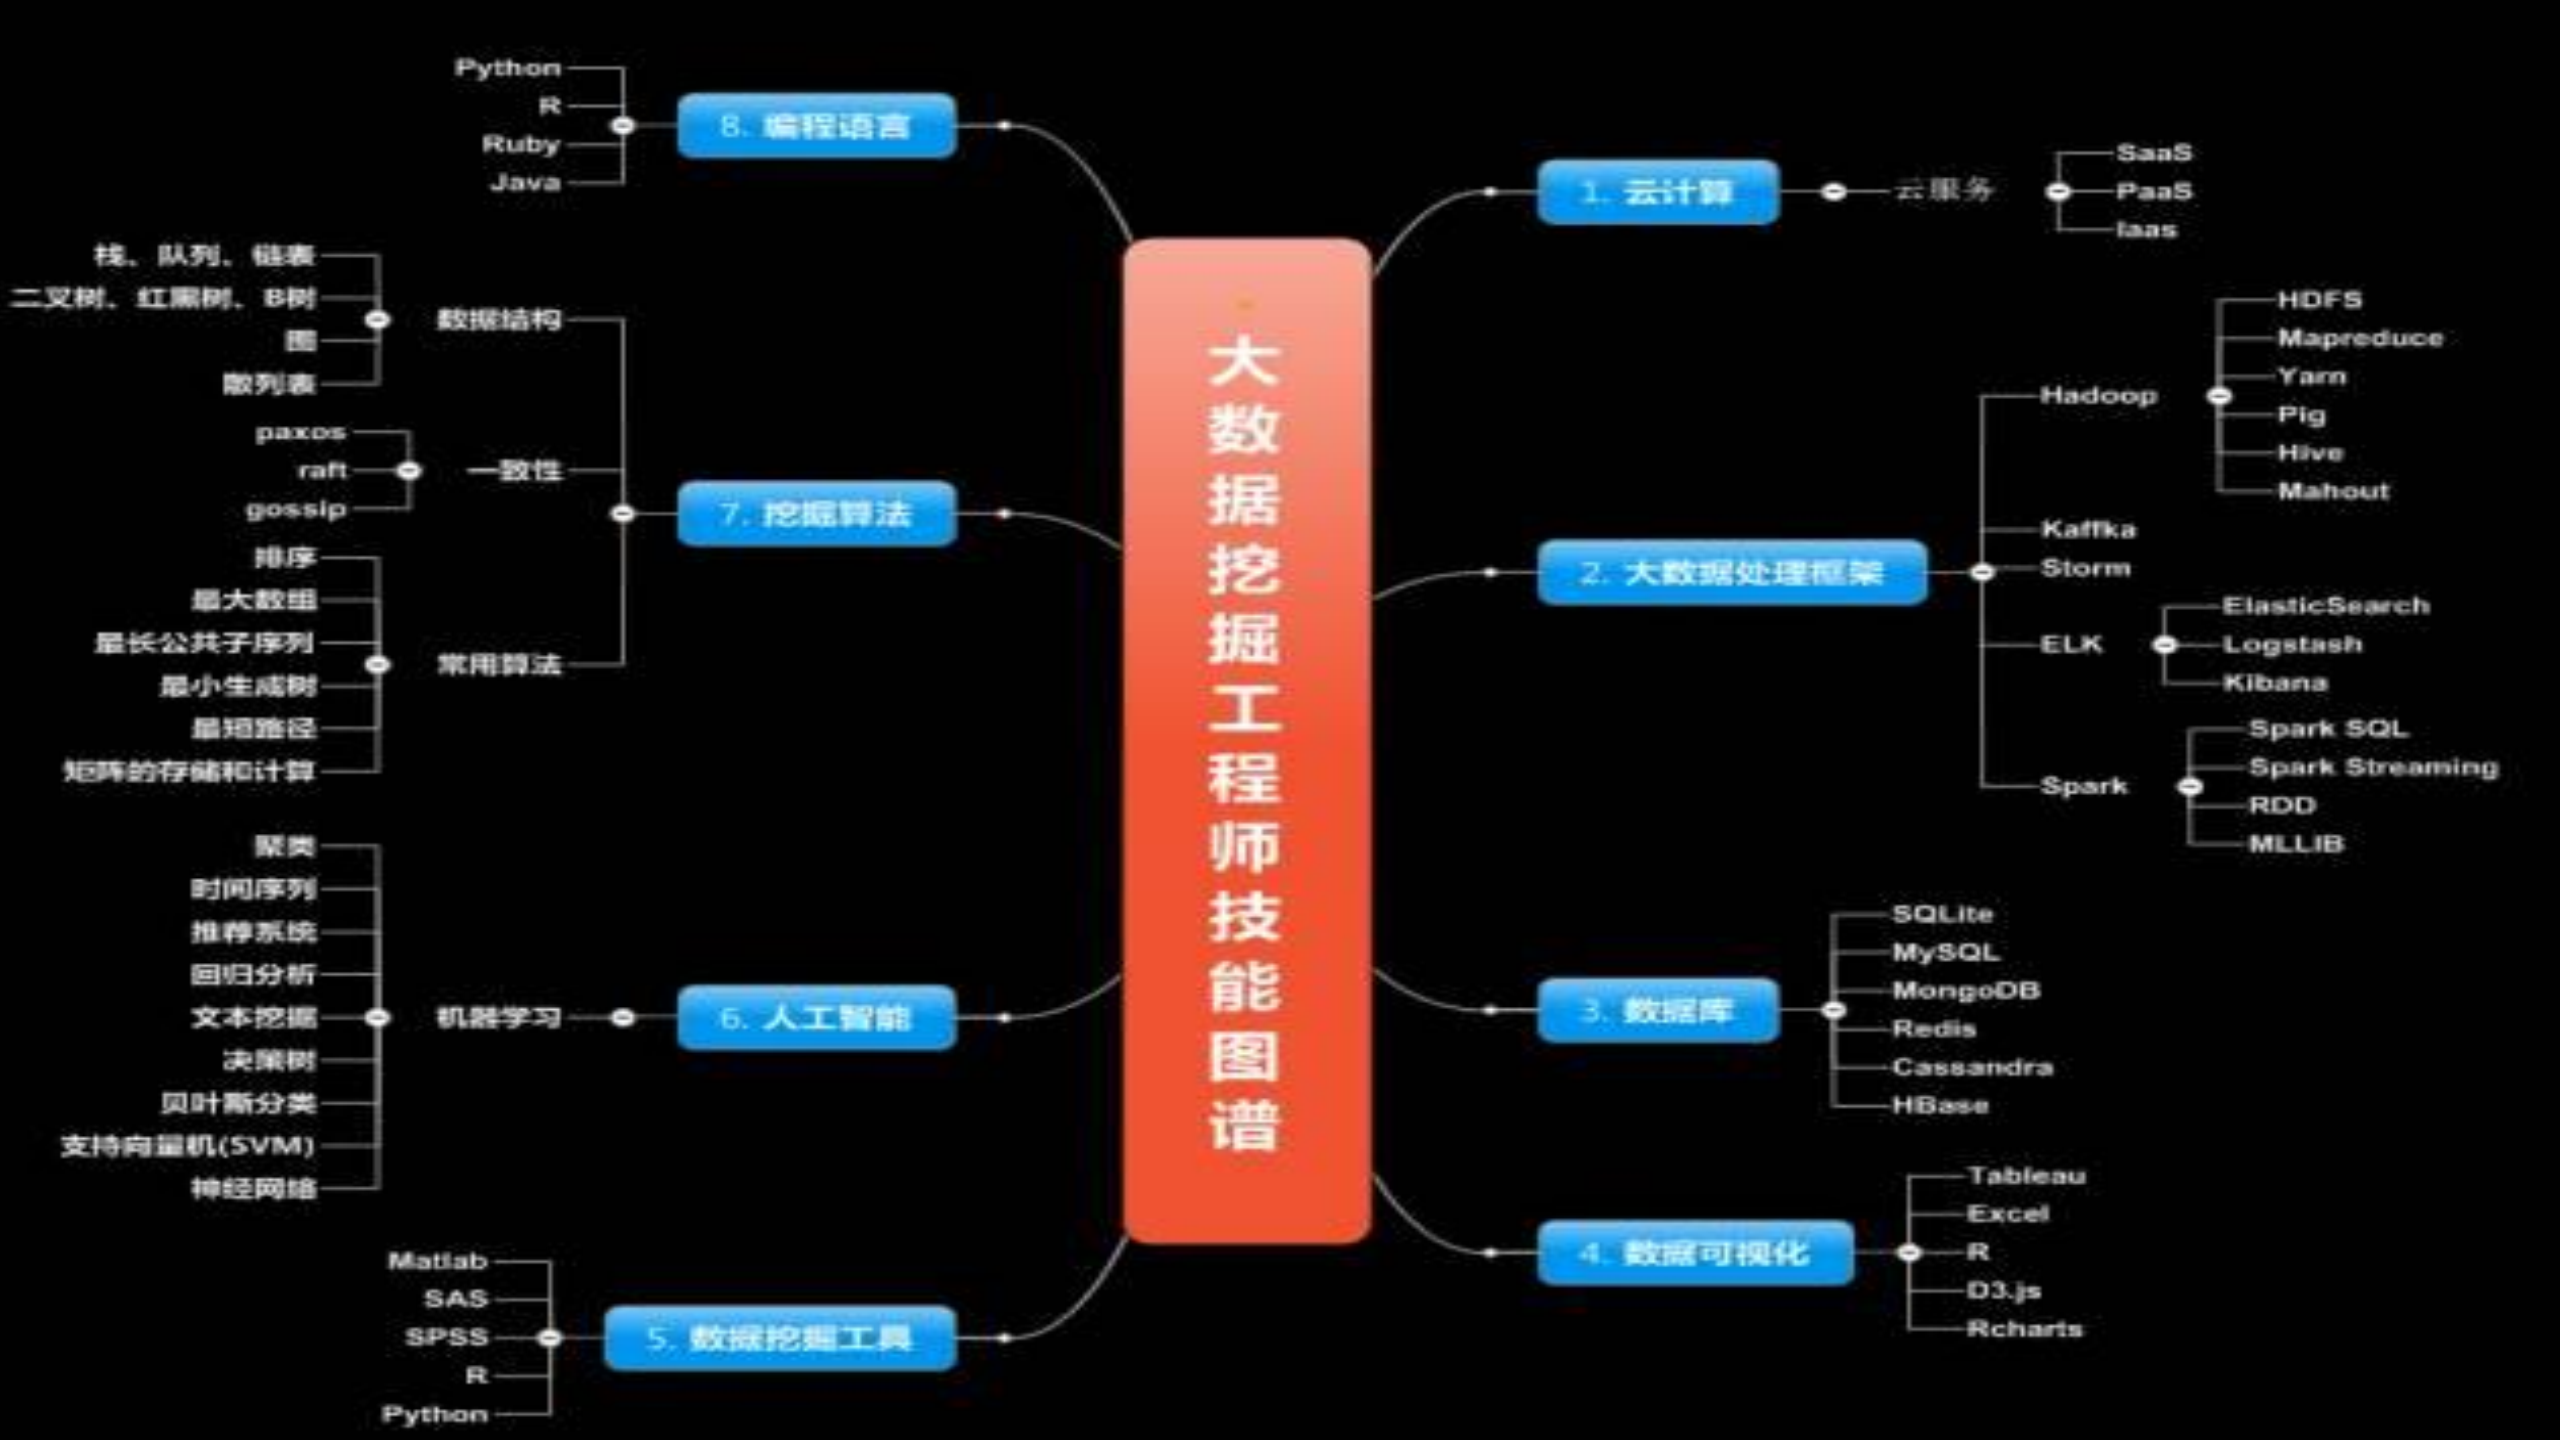
AI时代，数据挖掘过时了吗？



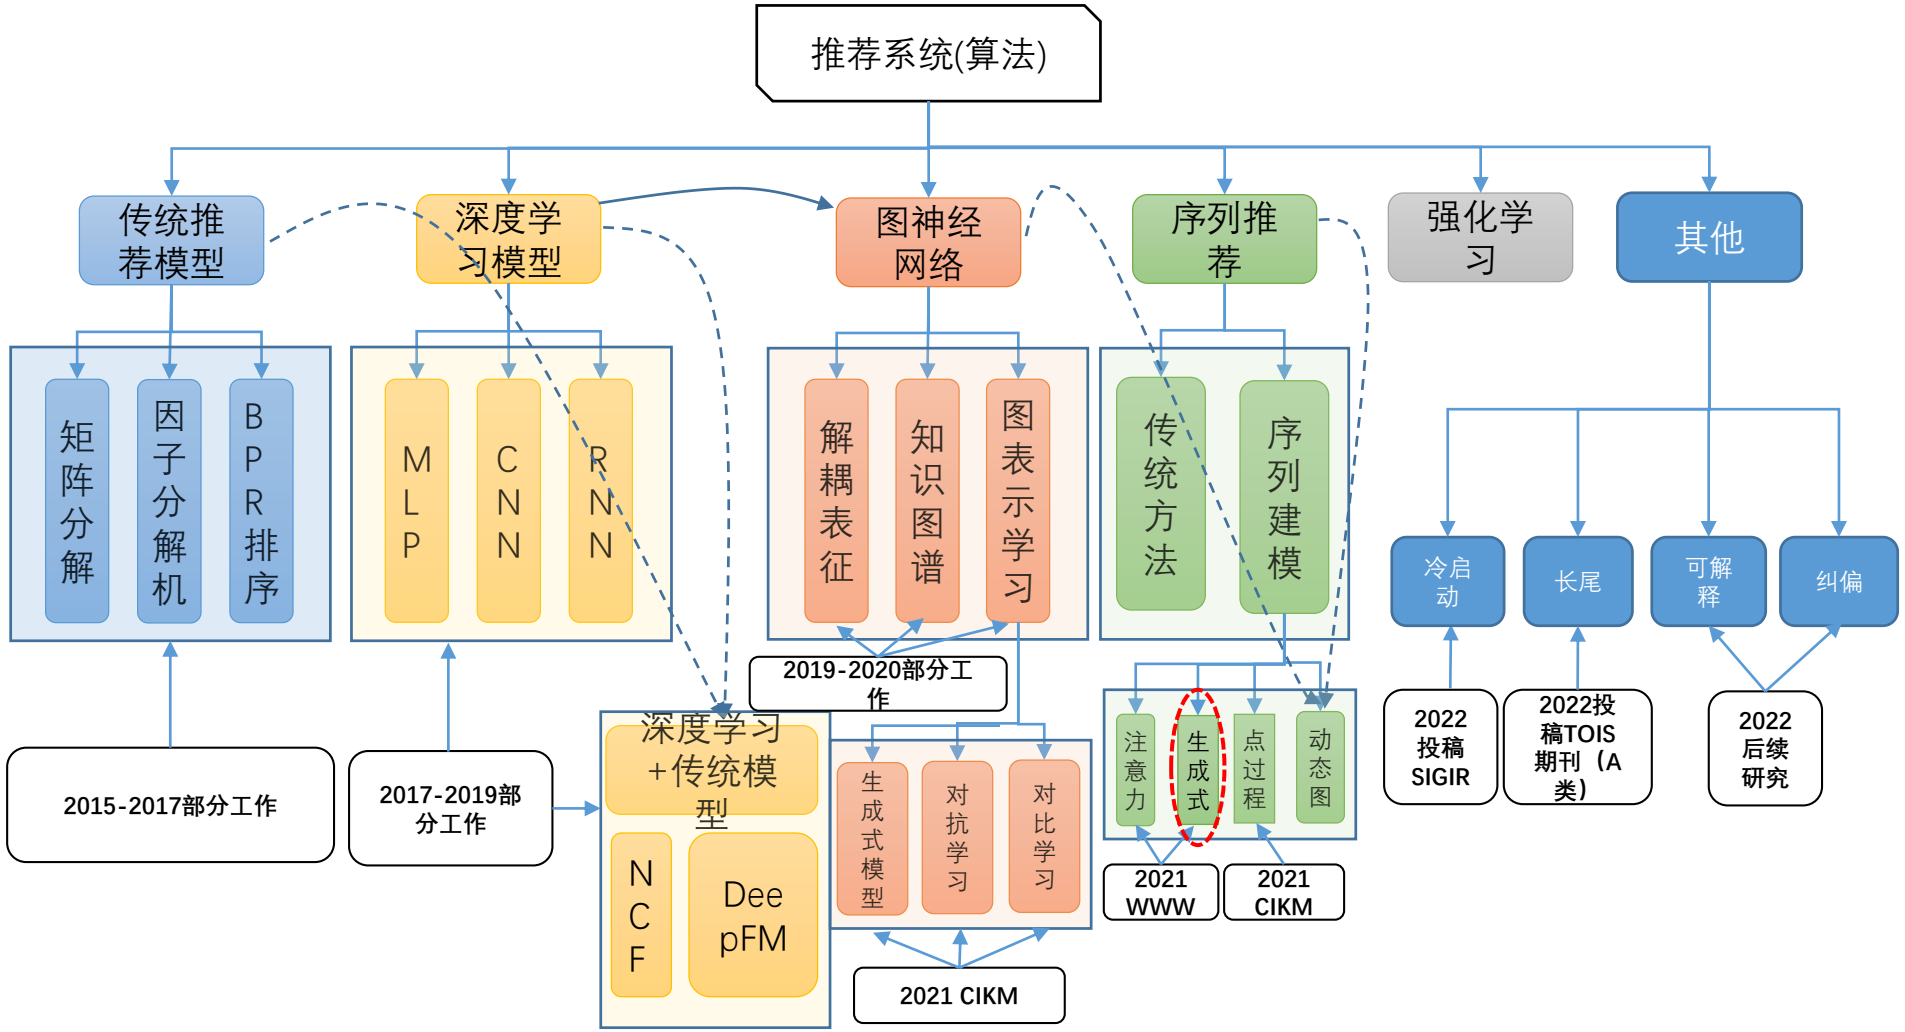
AI时代，数据挖掘过时了吗？



2020年1月，清华—中国工程院知识智能联合研究中心和清华大学人工智能研究院推出了
「 AI 2000人工智能全球 2000 位最具影响力学者榜单（AI 2000 Most Influential Scholar Award）」


大数据挖掘工程师技能图谱
1. 云计算
云服务
SaaS
PaaS
Iaas
2. 大数据处理框架
Hadoop
HDFS
Mapreduce
Yarn
Pig
Hive
Mahout
Kaffka
Storm
ELK
ElasticSearch
Logstash
Kibana
Spark
Spark SQL
Spark Streaming
RDD
MLLIB
3. 数据库
SQLite
MySQL
MongoDB
Redis
Cassandra
HBase
4. 数据可视化
Tableau
Excel
R
D3.js
Rcharts
5. 数据挖掘工具
Matlab
SAS
SPSS
R
Python
6. 人工智能
机器学习
聚类
时间序列
推荐系统
回归分析
文本挖掘
决策树
贝叶斯分类
支持向量机(SVM)
神经网络
7. 挖掘算法
数据结构
栈、队列、链表
二叉树、红黑树、B树
图
散列表
一致性
paxos
raft
gossip
常用算法
排序
最大数组
最长公共子序列
最小生成树
最短路径
矩阵的存储和计算
8. 编程语言
Python
R
Ruby
Java

物联网实验室在数据挖掘领域的研究工作

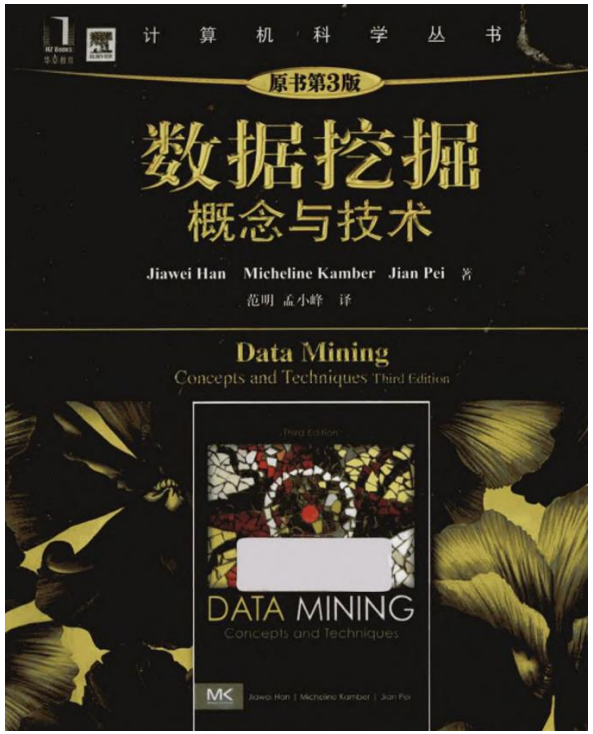


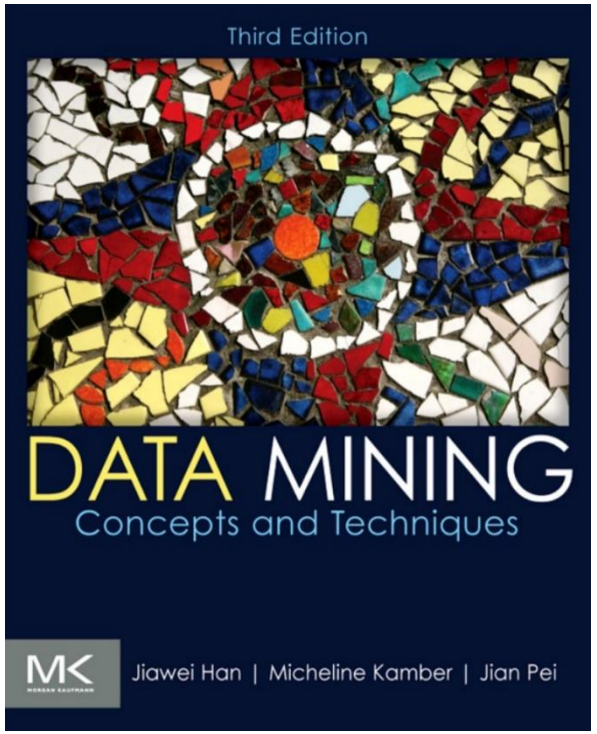
课程概要与学时分配

- 本课程首先从新一代信息技术全景视角认识数据挖掘与大数据分析。然后从数据挖掘方法和大数据分析两个维度阐述数据建模、分析和应用方法。课程目标是使学生通过课程的学习，能够全面掌握数据挖掘的基本理论方法，以及运用大数据计算平台进行大数据分析和应用的能力
- 课程以数据分析和应用为主线，总学时64学时，内容涵盖五大部分
  - —课程前言、新一代信息技术与数据挖掘（6学时）
  - —数据挖掘基本概念、认识数据、数据采集与预处理、数据仓库与OLAP（20学时）
  - —频繁模式挖掘和关联分析、分类分析、聚类分析、离群点分析等经典数据挖掘算法；分析大数据给数据挖掘带来的挑战，介绍了大数据分析和计算平台及其应用方法，并介绍经典数据挖掘算法的大数据处理实现（26学时）
  - —基于AIGC的数据挖掘与大数据分析（6学时）
  - —针对推荐系统等典型大数据应用进行了方法介绍（6学时）
  - —其中：数据挖掘与大数据分析工具及实践（虚拟排课16学时）

课程参考书

- Jiawei Han，Micheline Kamber，Jian Pei著，范明，孟小峰译，数据挖掘：概念与技术，（第三版），2012年8月第1版，机械工业出版社
- Jure Leskovee，Anand Rajaraman，Jeffrey David Ullman著，王斌，王达侃译，斯坦福数据挖掘教程（第三版），2021年4月第1版，人民邮电出版社







课程教学组

- **课程主讲组**
  - —王东
    - wangdong@sjtu.edu.cn，18621365573，软件大楼5313
  - —张谦
    - qwert3472@sjtu.edu.cn，13816047437，软件大楼5313
  - —丁玥
    - dingyue@sjtu.edu.cn，13817112134，软件大楼5313
- **课程助教组**
  - —蓝煜斌
    - lyb10188@sjtu.edu.cn，18965207301
  - —钟鸿琳
    - cong123@sjtu.edu.cn，15960346607，软件大楼5313
  - —郭凯毅
    - gky2023@sjtu.edu.cn，15890193461，软件大楼5313

本课程涉及的相关工具

- 数据预处理（蓝煜斌）
  - —ETL开源工具：Kettle
- 数据仓库与OLAP （蓝煜斌）
  - —MySQL
  - —Hadoop Hive
- 数据挖掘
  - —Weka（钟鸿琳）
  - —Matlab（蓝煜斌）
  - —Hadoop Mahout（钟鸿琳、郭凯毅、蓝煜斌）
  - —Spark Mlib/Spark ML（钟鸿琳、郭凯毅、蓝煜斌）
- 大数据挖掘
  - —Python（蓝煜斌）



上海交通大学RFID与物联网研究所
上海东川路800号交通大学软件大楼5313室

王东
18621365573
wangdong@sjtu.edu.cn

张谦
13816047437
qwert3472@sjtu.edu.cn