

Data Mining and Big Data Anlysis

数据挖掘及大数据分析

Chapter14：Course Summary

课程总结

王东、张谦、丁玥

上海交通大学软件学院RFID与物联网实验室

2025年春季

课程教学执行与学时分配

- 第1讲 课程前言与课程教学安排（2学时，第1-2小时）
- 第2讲 新一代信息技术全景视角下的数据挖掘及大数据分析
- （8学时，第3—8小时，第9-10小时 手机传感器数据采集及应用）
- 第3讲 认识数据（2学时，第11—12小时）
- 第4讲 数据采集和预处理（6学时，第13—18小时）
- 第5讲 数据仓库与联机分析处理（5学时，第19—23小时）
- 第6讲 挖掘频繁模式、关联和相关性（4学时，第24—27小时）
- 第7讲 分类（4学时，第28—31小时）
- 第8讲 聚类（1学时，第32小时）
- 第9讲 离群点检测（没讲）
- 第10讲 大模型与数据挖掘（2学时，第33-34小时）
- 第11讲 数据挖掘案例分析（4学时，第35-38小时）
- 第12讲 推荐系统（2学时，第39-40小时）
- 第13 讲社会网络和社区发现（2学时，第41-42小时）
- 实践作业

课程概述(2)

新一代信息技术与数据挖掘(8)

数据治理(13)

经典数据挖掘算法(9)

大模型与数据挖掘(2)

完整数据挖掘案例(4)

大数据数据挖掘(4)

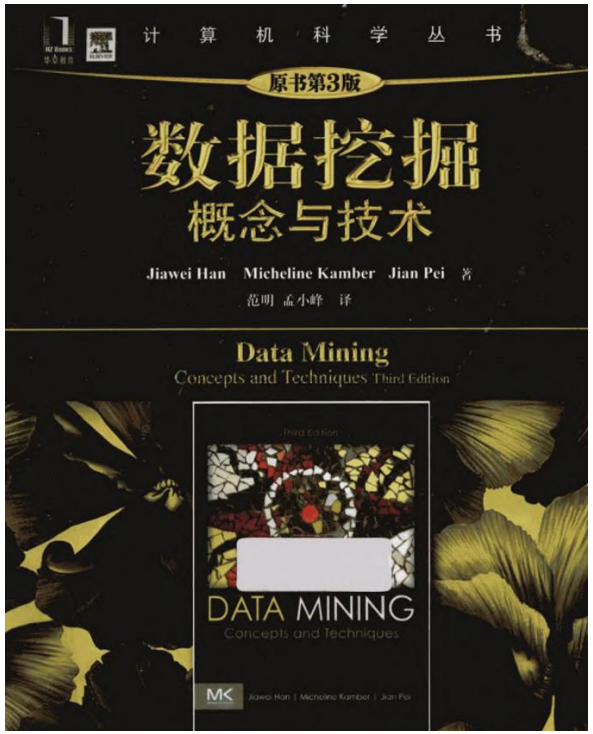
实践作业（虚拟排课16学时）

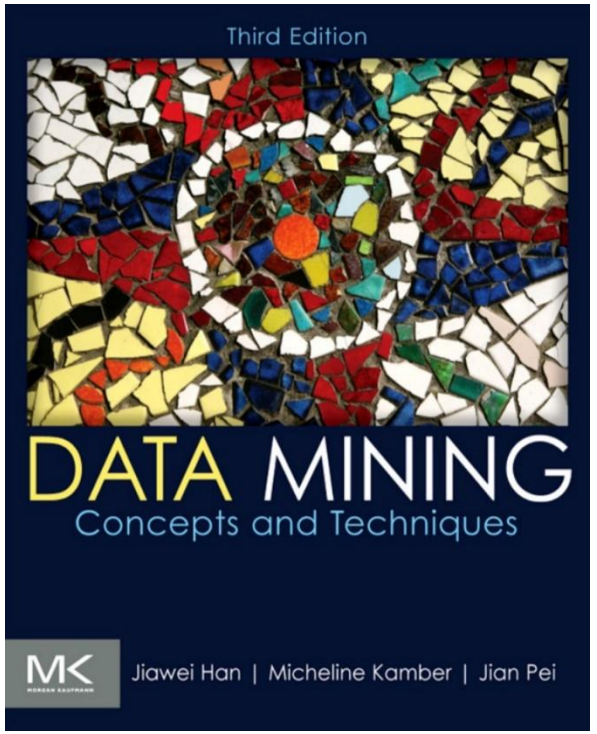
- 随堂小作业：17次
- 课程作业：手机传感器数据采集及应用
- 实验一：数据预处理
- 实践二：数据仓库以及OLAP实验
- 实践三：数据挖掘算法
- 实验四_大模型微调

- 数据预处理（董长飞、蓝煜斌）
  - —Pandas
- 数据仓库与OLAP （吴天宇、蓝煜斌）
  - —MySQL
  - —Hadoop Hive
- 数据挖掘（钟鸿琳、郭凯毅、蓝煜斌）
  - —Scikit-learn
  - —Spark Mlib/Spark ML
- 大数据挖掘（吴天宇、钟鸿琳、蓝煜斌）
  - —PySpark
- AIGC（董长飞、钟鸿琳、蓝煜斌）

课程教学参考书

- Jiawei Han，Micheline Kamber，Jian Pei著，范明，孟小峰译，数据挖掘：概念与技术，（第三版），2012年8月第1版，机械工业出版社
- Jure Leskovee，Anand Rajaraman，Jeffrey David Ullman著，王斌，王达侃译，斯坦福数据挖掘教程（第三版），2021年4月第1版，人民邮电出版社



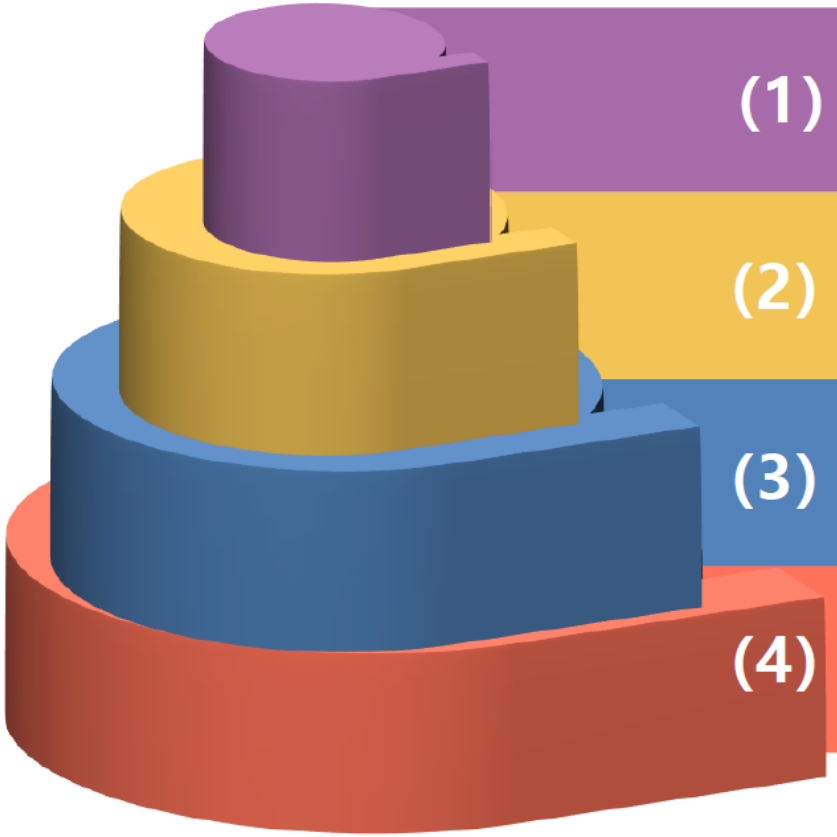




1.课程概述 提纲

- 本课程与数据智能方向其它课程之间的关联、衔接、集成
- 本课程的主要内容
- 本课程的教学安排

数据智能方向课程体系



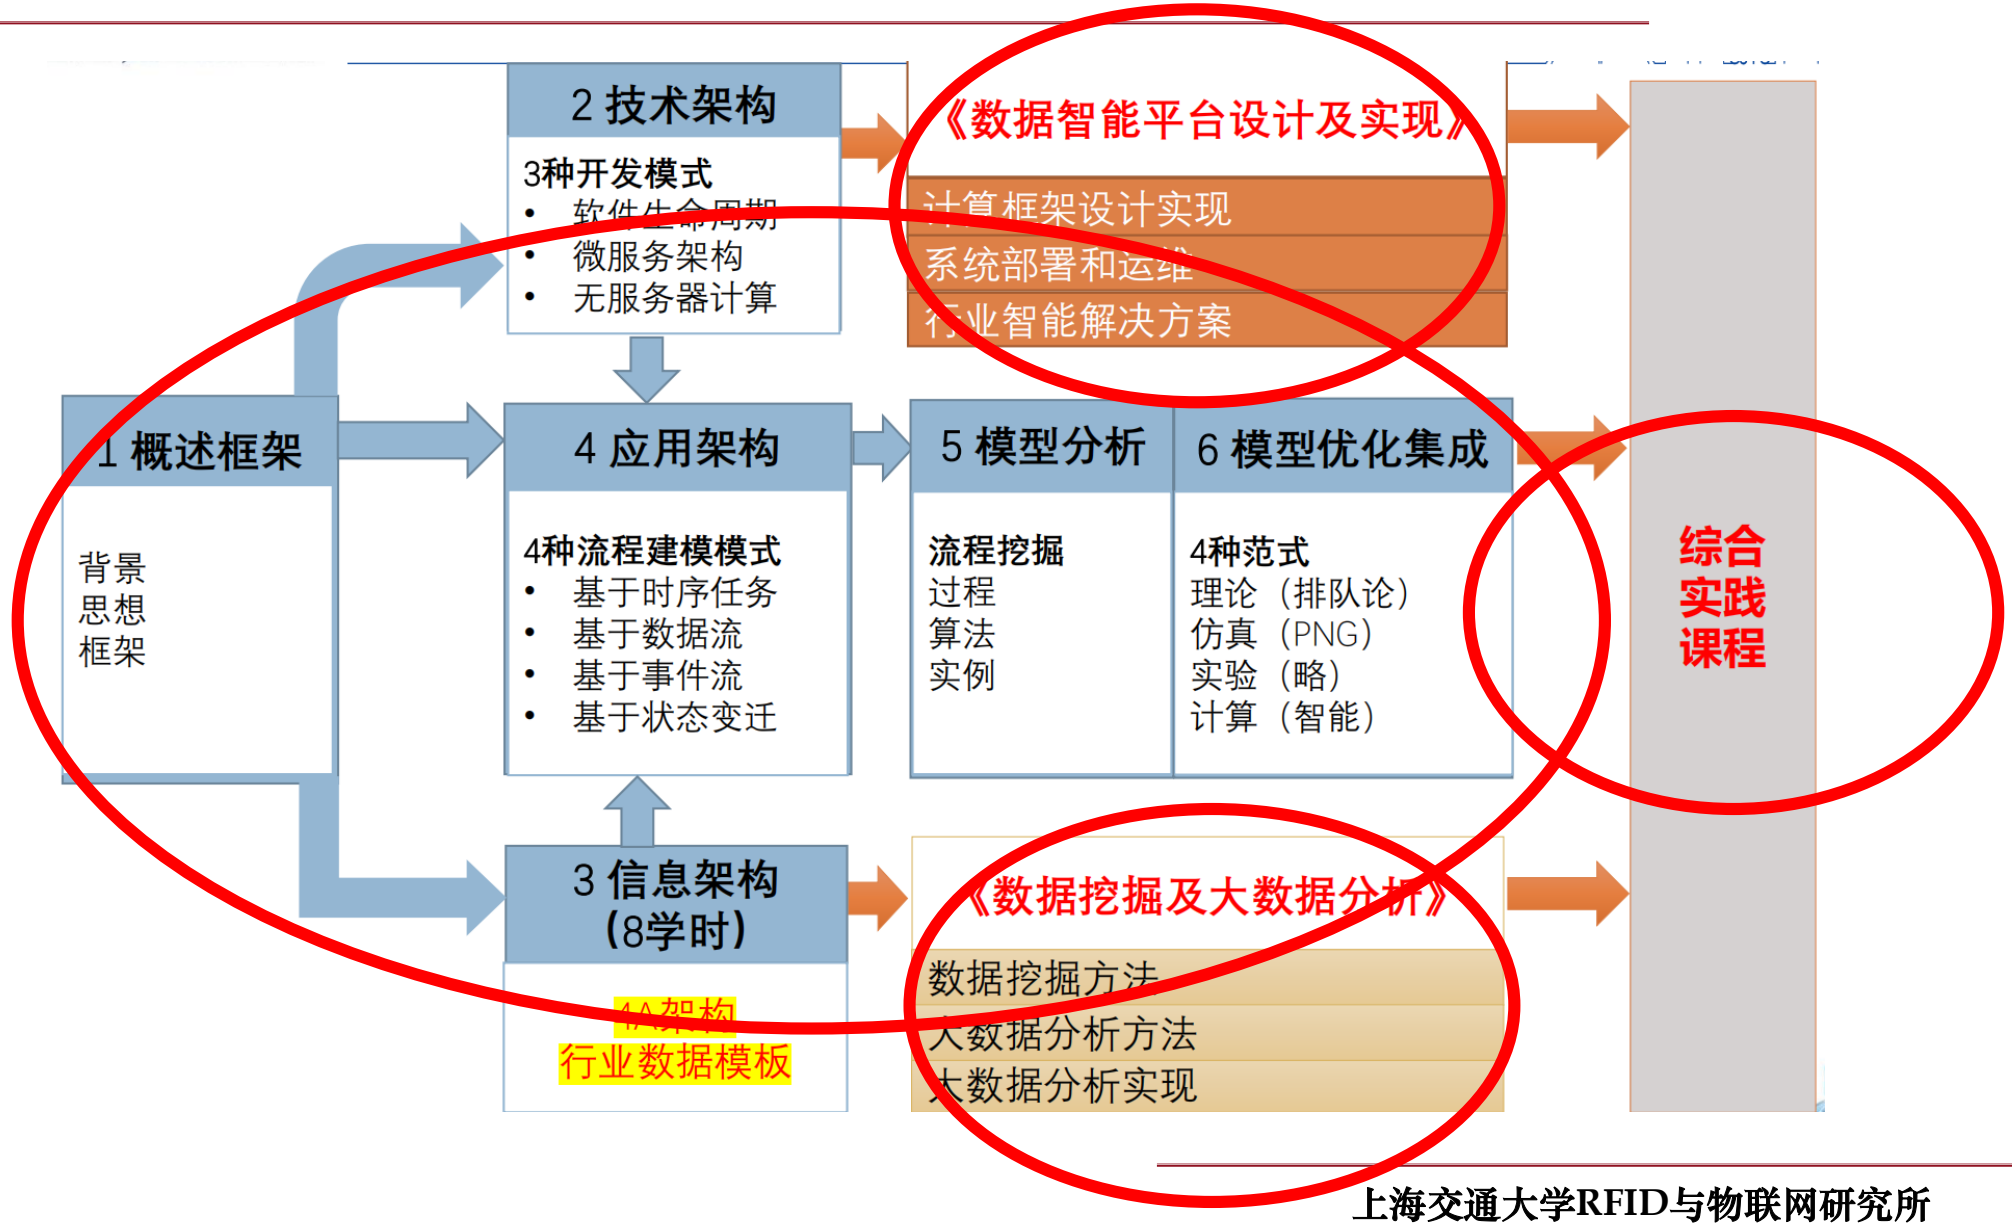
（1）智能信息系统建模 — 复杂软件的业务架构

（2）数据挖掘及大数据分析 — 数据处理与智能算法

（3）数据智能平台设计及实现 — 智能系统的技术实现

（4）系统设计与开发大型课程设计 — 工程应用与综合实践

数据智能方向课程之间的关联、衔接、集成



本课程与其它课程的内容衔接



《智能信息系统建模》课程“信息架构”与《数据挖掘及大数据分析》课程衔接

《智能信息系统建模》课程“信息架构”

- 信息系统规划设计方法（规划“主题数据库”）
- 行业数据模板（高质量的“主题数据库”）

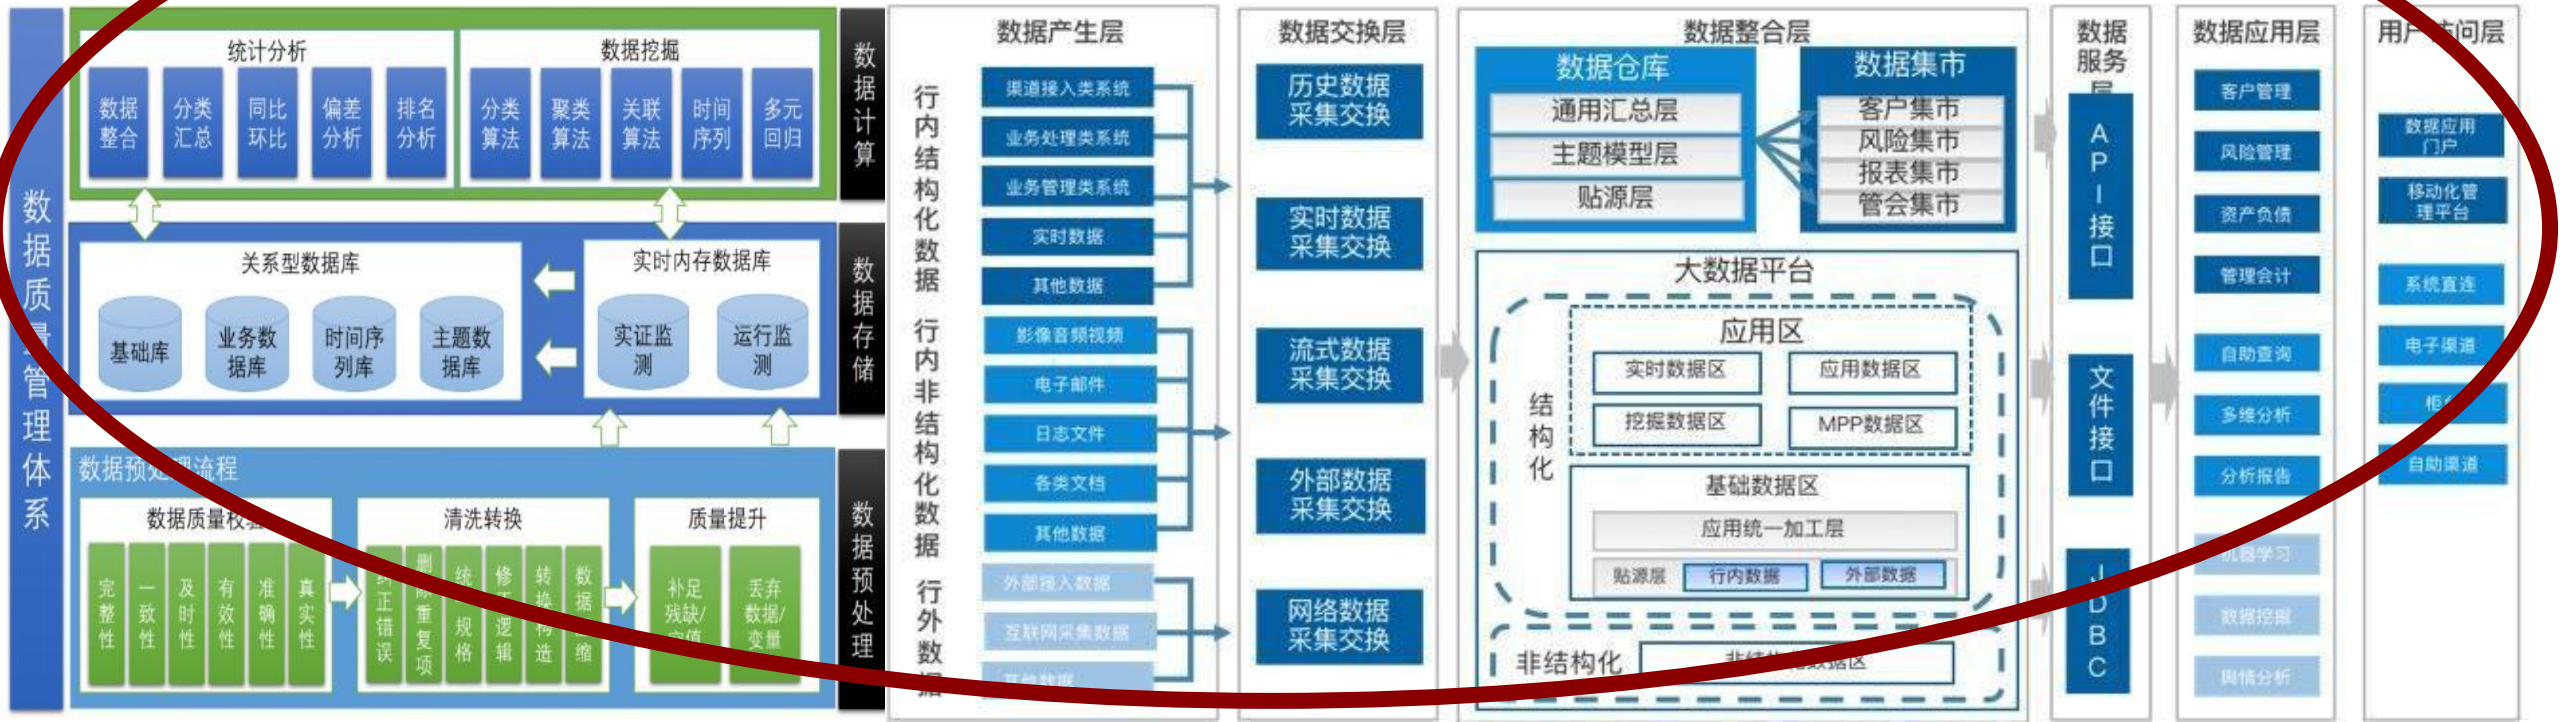
《数据挖掘及大数据分析》课程

- 数据治理（高可用的“数据”）
- 数据挖掘（挖掘数据的价值）

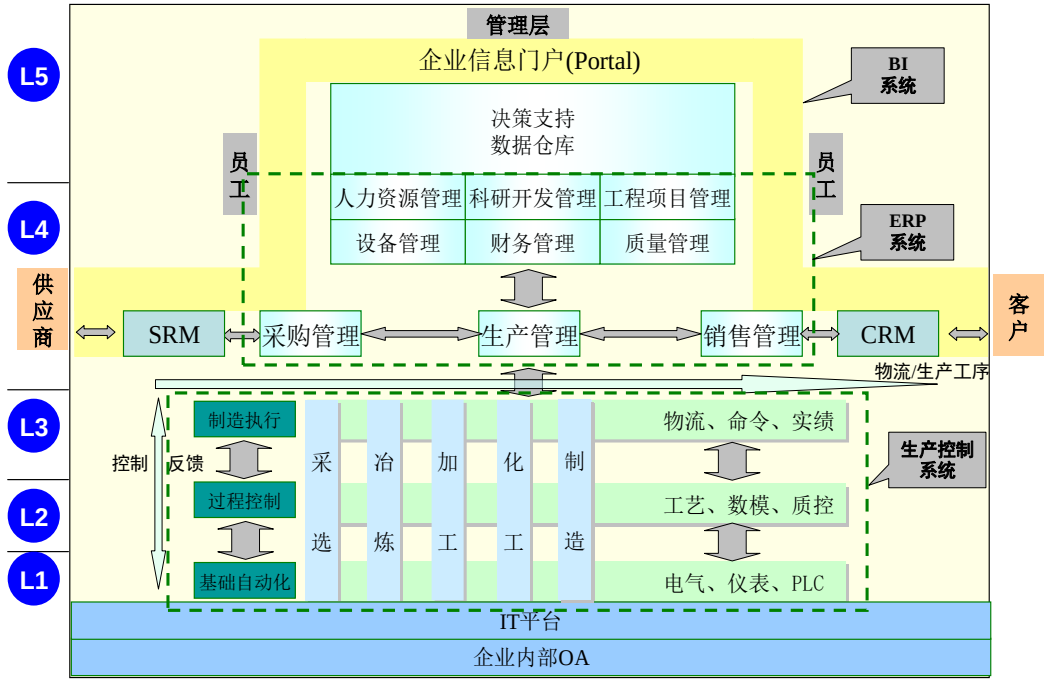
数据智能方向的数据视角：数据规划、数据治理、数据挖掘

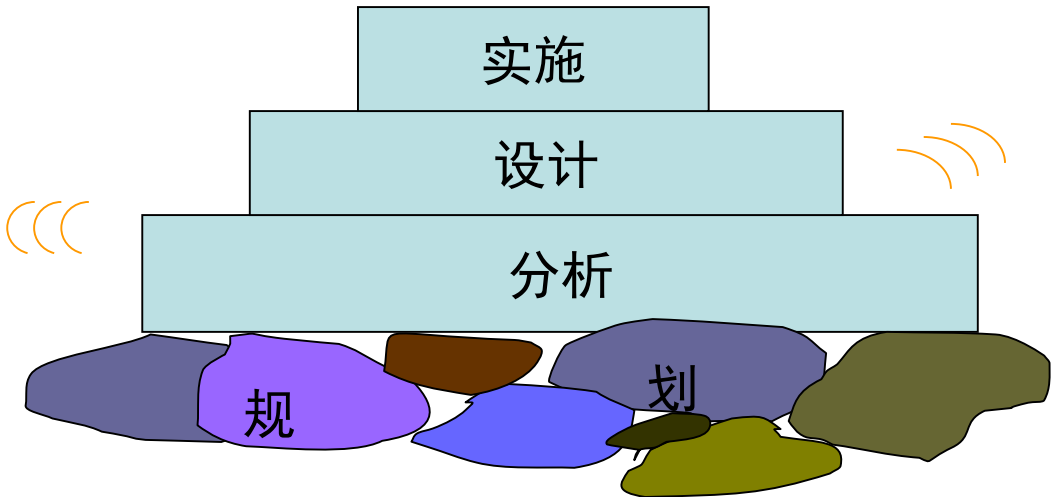
- 信息系统规划设计方法（规划“主题数据库”）
- 行业数据模板（高质量的“主题数据库”）

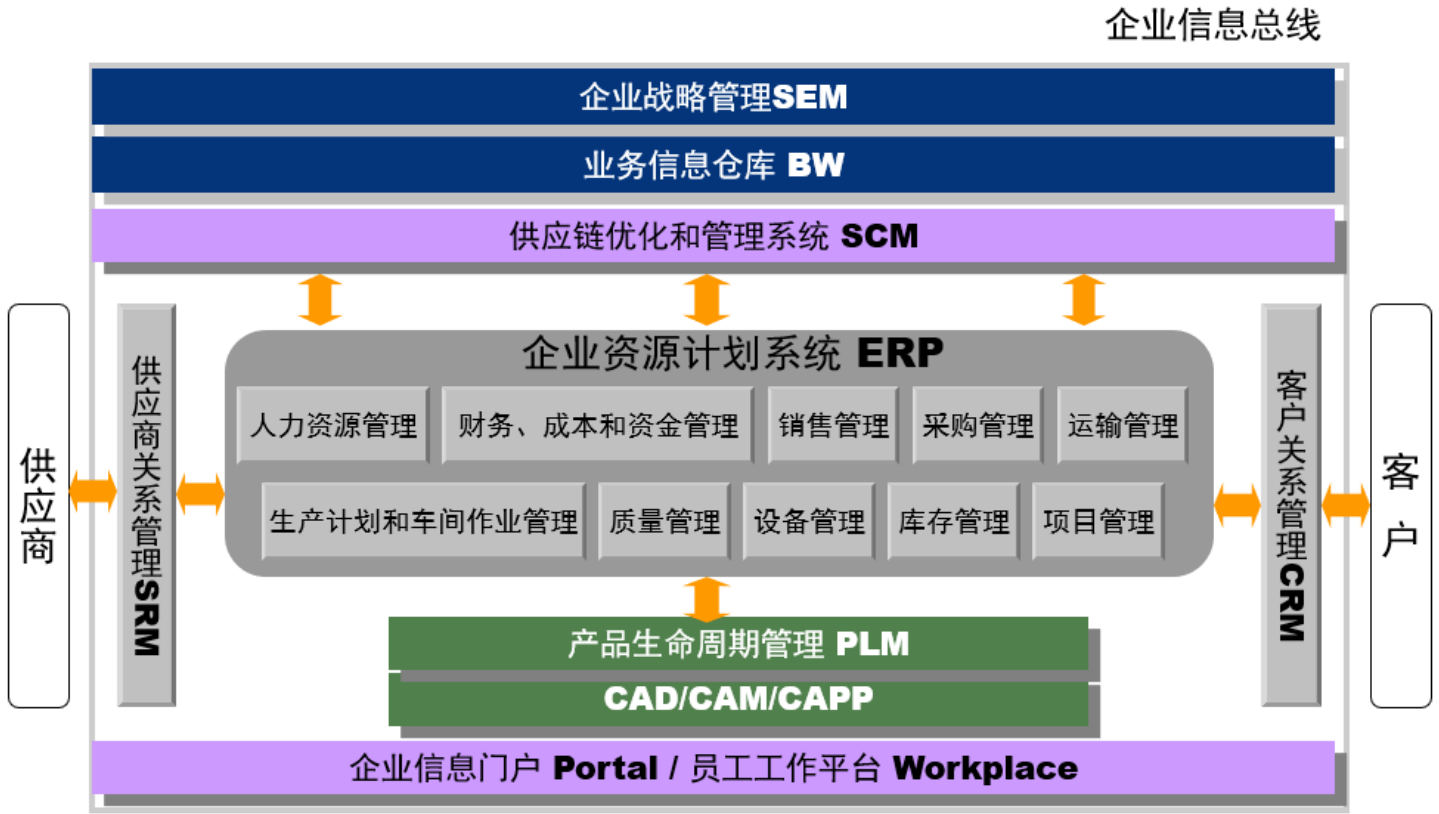
- 数据治理（高可用的“主题数据”）
- 数据挖掘（挖掘数据价值，形成数据资产）



数据智能方向的数据视角：数据规划、数据治理、数据挖掘







数据智能方向的数据视角：数据规划、数据治理、数据挖掘



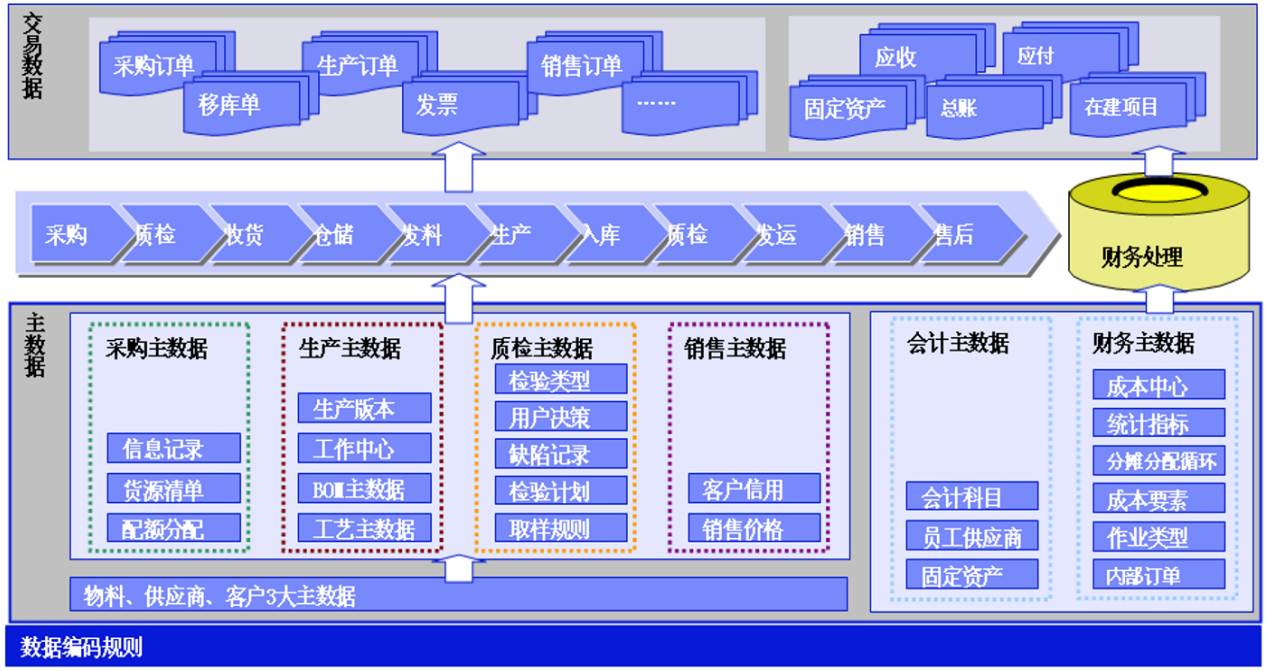
数据资源规划-基础/先导工程

以ERP为代表的一应用系统

Global Business Services

未来有色主数据体系将覆盖到财务、采购、销售、生产、质检等环节

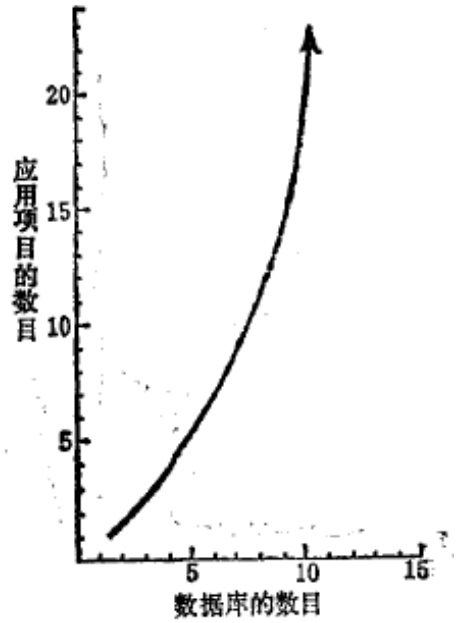
- 使用清晰的技术数据管理方法，有效组织数据收集、整理、清理等工作，以保证进入系统运行的数据的正确性。

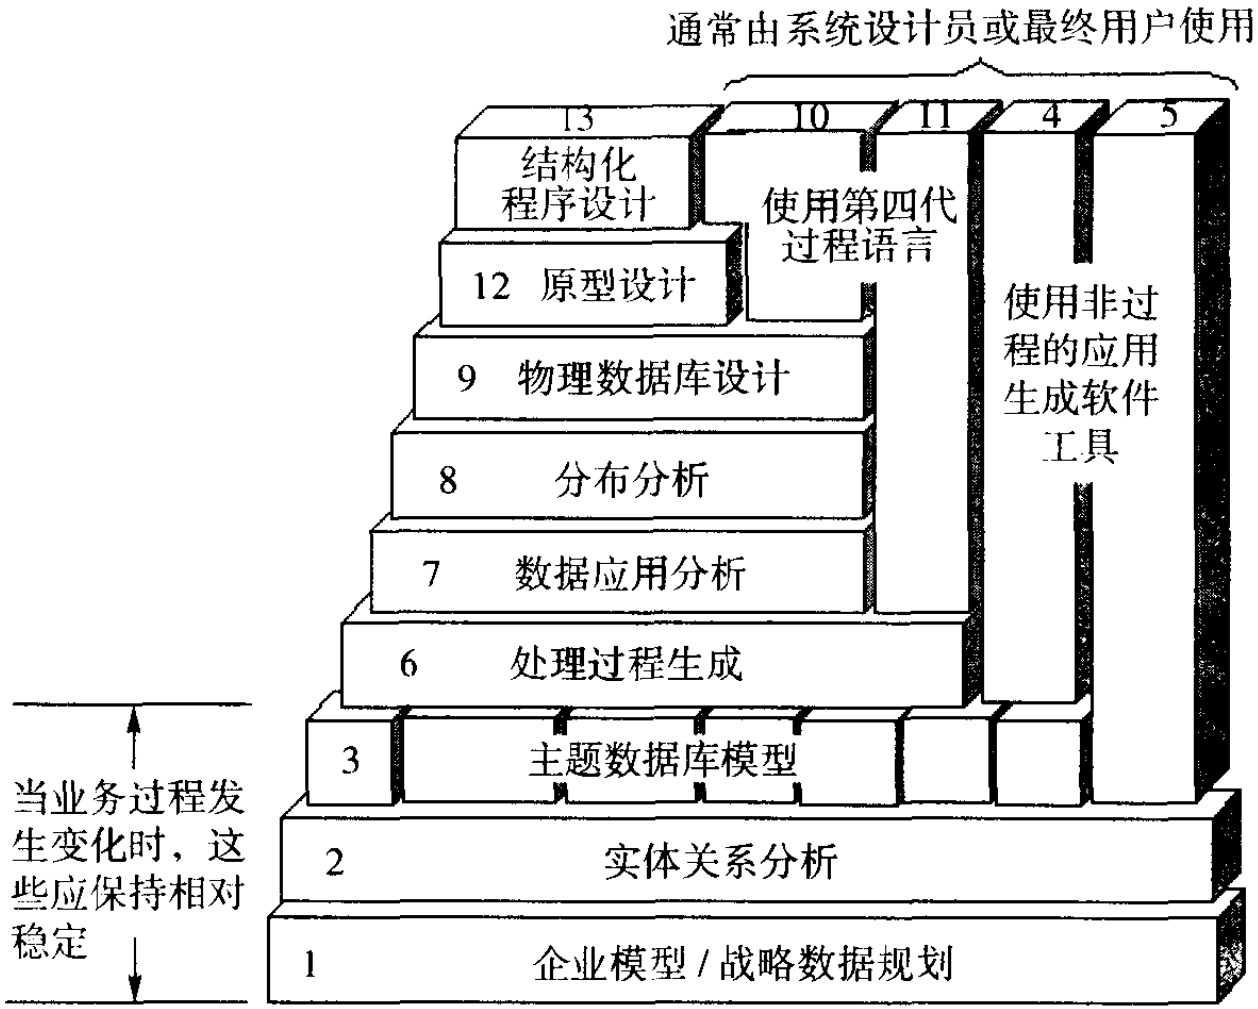


数据智能方向的数据视角：数据规划、数据治理、数据挖掘

方法论1：信息工程方法论（IEM）
詹姆斯·马丁(James Martin)





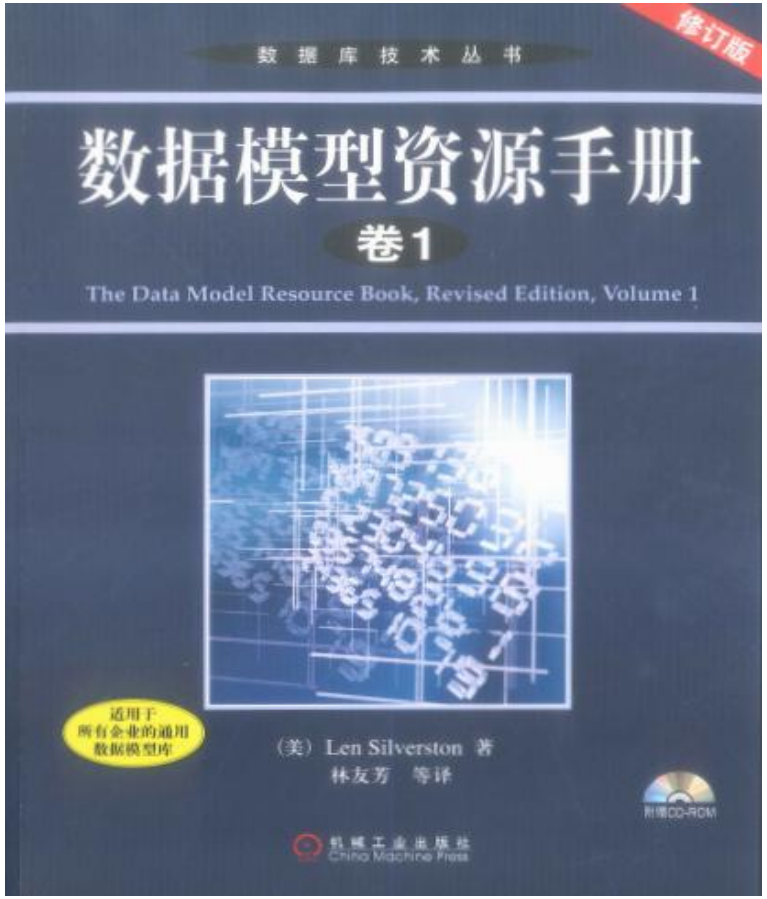


信息工程方法论与总体数据规划

- **步骤1：职能域划分**
  - 研究对象（企业/事业）的事业发展规划
  - 研究对象信息化发展规划
  - 研究并整理对象各部门的职责和主要业务（职责、人员、岗位）
  - 产生全域业务模型，划分职能域
- 步骤2：职能域业务分析
- 步骤3：全域功能模型、数据模型

数据智能方向的数据视角：数据规划、数据治理、数据挖掘

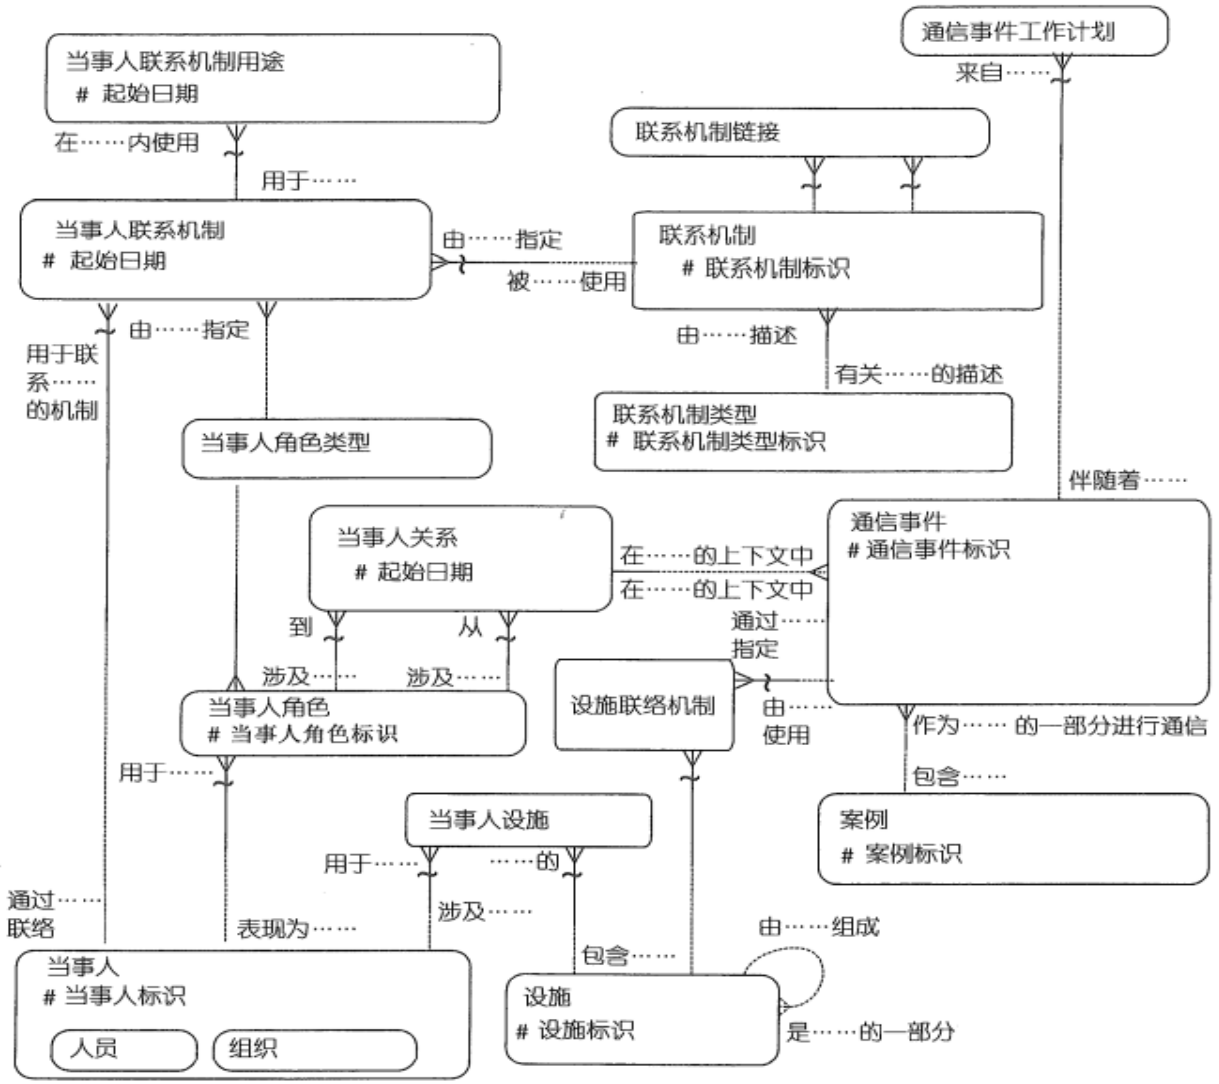
方法论2：行业数据模板



第1章 绪论
第2章 人与组织
第3章 产品模型
第4章 产品订购模型
第5章 装运模型
第6章 工作计划模型
第7章 发票模型
第8章 会计和预算模型
第9章 人力资源模型
第10章 根据企业数据模型建立数据
第11章 一个数据仓库数据模型范例
第12章 销售分析星型模式设计
第13章 人力资源的星型模式设计
第14章 附加的星型模式设计
第15章 实施通用数据模型

- 卷1为一系列的行业提供了企业业务生命周期中每一个阶段所需的通用数据模型
  - 人和组织间交互并形成各种关系
  - 产品（服务或物理上的货物）的定义、供应、定价、成本，可能还有库存
  - 人和／或组织间因购买产品而建立起来的承诺（在不同场合或许会称为订单、协议、合同、金融事务，等等）
  - 装运，将物理货品运输到它们的目的地
  - 工作计划，需要对工作进行计划和跟踪，如维修、制造、项目和服务工作的计划
  - 开发票确定应付款
  - 预算和会计用于管理财务问题
  - 对人力资源进行管理和跟踪
- 卷1 中的数据模型适合于大多数企业，因为上述步骤基本反映了多数行业的运作模式。卷1 所描述的这些数据模型标识出了适合于各种行业的基本的信息需求

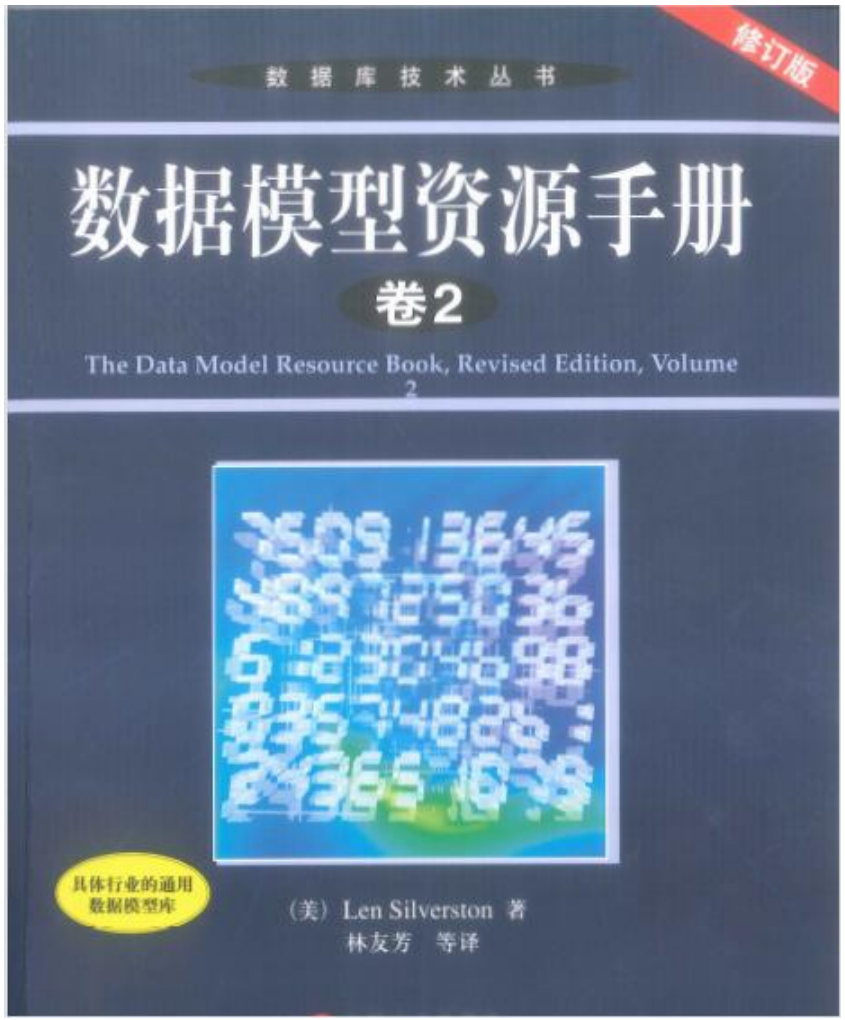
当事人整体数据模型



- 最常见的业务信息需求是针对人和组织提出一些问题，并且能针对这些问题给出准确的、可信赖的回答
  - 在办理业务的过程中涉及到的人和组织的属性或特点是什么？
  - 在不同的人之间、在不同的组织之间以及在人和组织之间存在哪些关系？
  - 人以及组织的地址、电话号码和其他联系方式是什么？怎样才能同他们取得联系？
  - 在各种当事人之间发生了哪些类型的通信或联系？为了有效地加强这些通信的后续工作，需要做哪些工作？
- 几乎所有业务应用都要求记录有关人和组织的信息，如客户、供应商、子公司、雇员和承包商等，这些信息在许多不同的系统中是冗余的。因此，确保客户联系方式等关键信息的一致和准确是非常困难的
  - 有关人和组织信息可能应用于销售、市场、采购、订单处理、发票、项目管理和财务中

数据智能方向的数据视角：数据规划、数据治理、数据挖掘

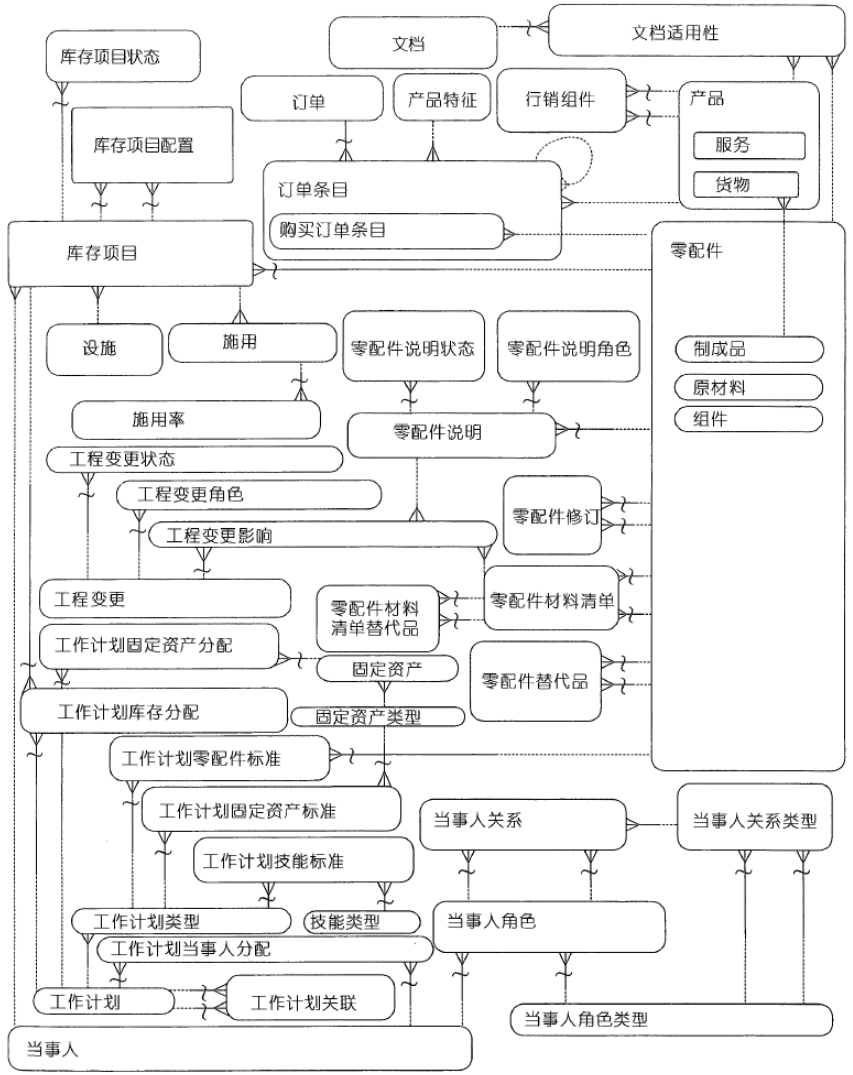
方法论2：行业数据模板



- **卷2将展示卷1中的模型是如何能够满足许多行业的独特信息需求的**
  - 针对每种行业，卷2并不重复给出卷1 中的通用模型，而是在每章的开始处给出一张表，表明如果要将卷1 中的通用数据模型转化成面向行业的数据结构的话，所需进行的一些主要调整以及一些需要增加的内容
- **每章都概略地由在前面8 个主要的主题数据域（当事人、产品、订单、装运、工作计划、发票、会计和人力资源）和行业所特有的主题域组成**
  - 如果不需要太多定制工作的话，一些主题数据域组合起来构成一个单独的区域（例如，对一个特定的行业来说，财务和人力资源通常都不需要太多的定制）
  - 如何为每一个行业定制每个主题域
- **卷1 中的模型与卷2推荐的定制组合，就给用户提供了一个具体行业的通用数据模型，这些模型能在数据模型建模时将用户带到一个更高的起点上**

制造业数据模型

- 针对制造业对通用数据模型所做的修改包括如下几个关键方面
  - —修改当事人角色的类型和名称以及和制造有关的关系
  - —将零配件和产品区别开，维护零配件的信息
  - —添加设计工程数据模型用于说明零配件和产品
  - —添加模型以包括工程的变更
  - —为企业的各种视图添加材料清单结构，它包括工程、制造和行销
  - —为产品（和零配件）替代提供更复杂的模型
  - —为记录实际零配件的变化，添加库存项吕配置数据模型
  - —随时间的变化跟踪产品和零配件的施用和使用情况
  - —改变工作计划和工作计划标准模型的名称，以将焦点集中在生产运行上



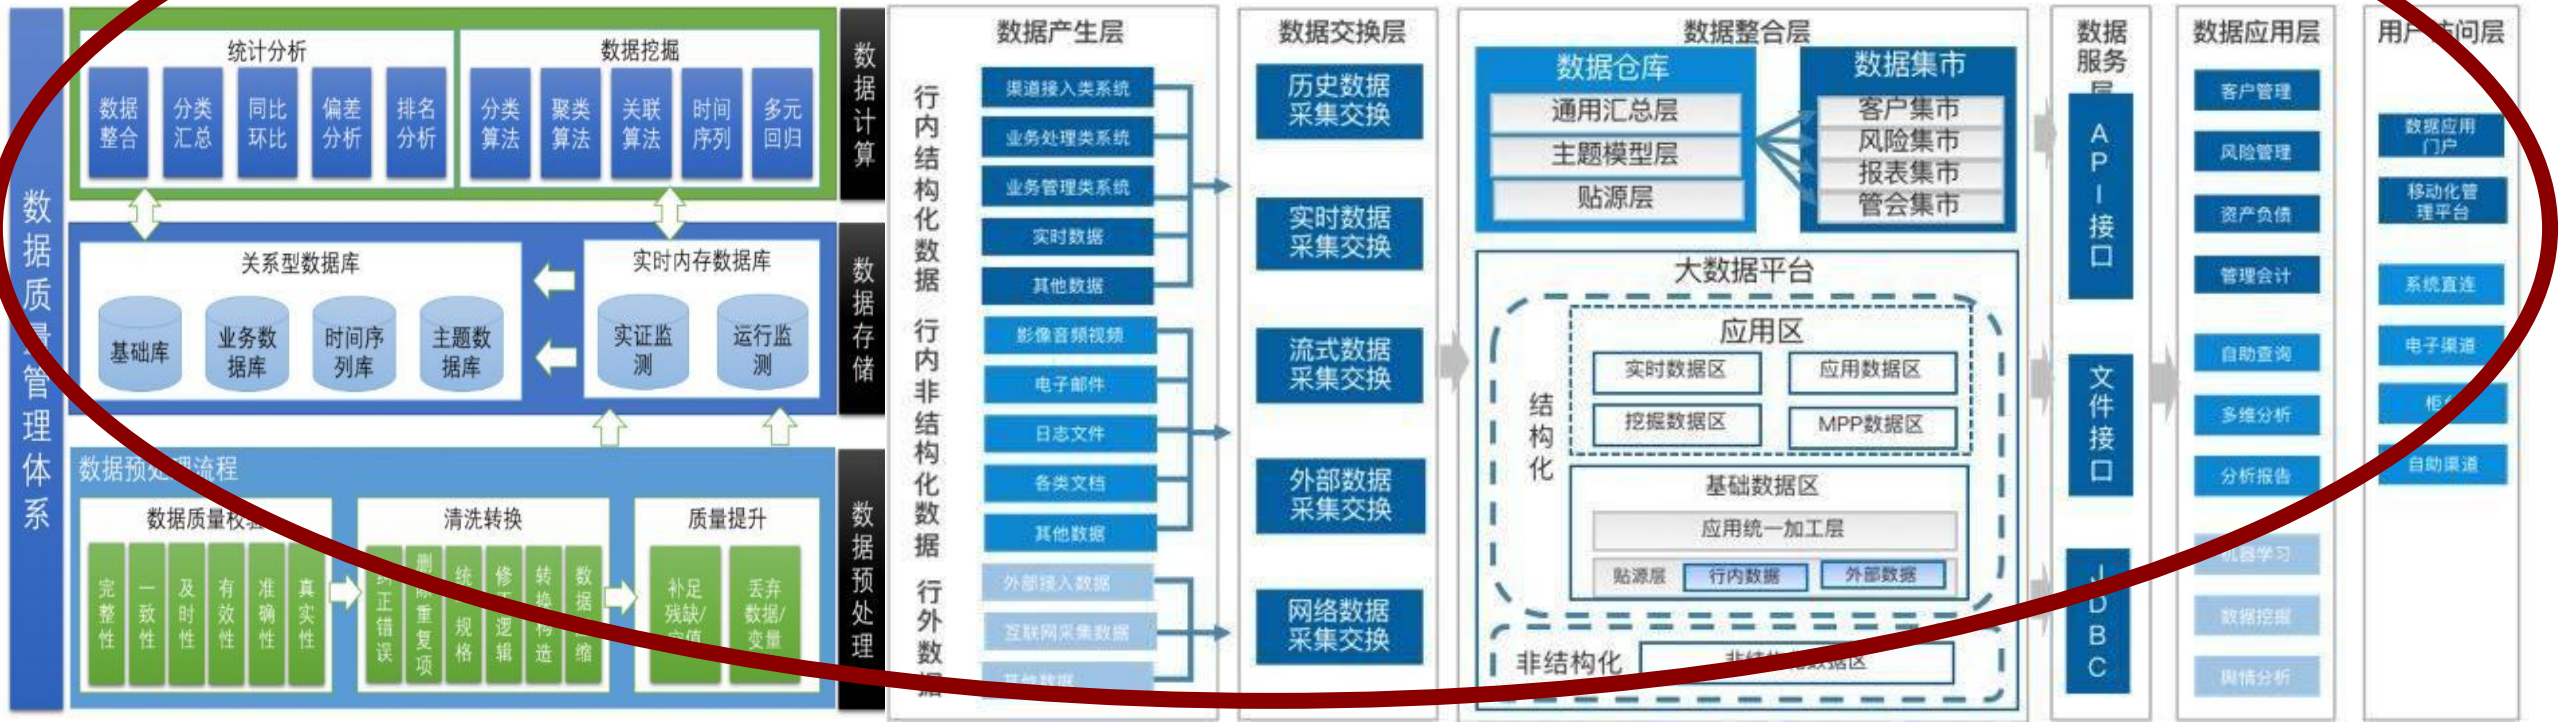
提纲

- 本课程与数据智能方向其它课程之间的关联、衔接、集成
- ***本课程的主要内容***
- 本课程的教学安排

数据智能方向的数据视角：数据规划、数据治理、数据挖掘

- 信息系统规划设计方法（规划“主题数据库”）
- 行业数据模板（高质量的“主题数据库”）

- 数据治理（高可用的“主题数据”）
- 数据挖掘（挖掘数据价值，形成数据资产）



数据智能方向的数据视角：数据规划、数据治理、数据挖掘

内 容 简 介

本书是一本全面关注企业数据标准化方面的工具书，主要分为5篇。第1篇介绍了数据标准化是数据治理的基础，包括数据标准化与数据治理的关系，以及数据标准化主要内容、本书阅读导引。第2篇介绍了数据标准化框架体系，包括架构类数据标准、对象类数据标准、基础类数据标准。第3篇介绍了数据标准化实施流程与方法，包括建立数据标准化保障机制、现状分析及评估、技术平台和工具、数据标准化关键域实施。第4篇介绍了数据标准化评价，包括数据标准化评价方法、数据标准成熟度评价、数据标准化成熟度评价流程。第5篇介绍了数据标准化案例，包括油气行业、多元化集团、装备制造行业、核电行业、汽车行业、金融行业、政务行业、互联网行业等行业的数据治理案例，为读者提供了专业、丰富、可信的数据治理实施范例。

本书是工业大数据应用技术国家工程实验室多年潜心研究的重要科研成果的总结和凝聚，既具有理论高度，也具备面向中国各行业企业的可实操性。参与本书编写的作者均为国内相关领域的专家，所有案例均来自这些企业的实践。

未经许可，不得以任何方式复制或抄袭本书之部分或全部内容。
版权所有，侵权必究。

图书在版编目（CIP）数据

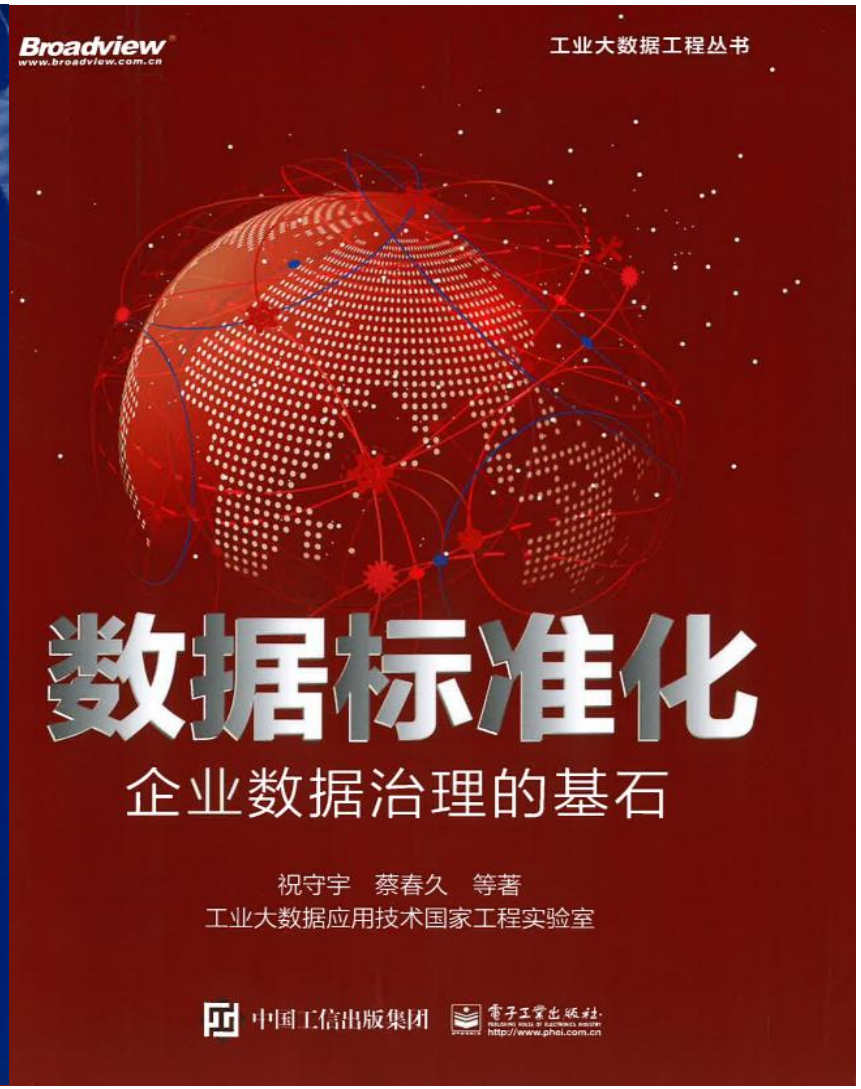
数据标准化：企业数据治理的基石 / 祝守宇等著. —北京：电子工业出版社，2023.1
（工业大数据工程丛书）
ISBN 978-7-121-44398-5

. ①数… II. ①祝… III. ①企业管理—数据管理—研究 IV. ①F272.7

中国版本图书馆 CIP 数据核字（2022）第 192190 号

责任编辑：王　静
印　刷：三河市华成印务有限公司
装　订：三河市华成印务有限公司
出版发行：电子工业出版社
北京市海淀区万寿路 173 信箱　邮编：100036
开　本：787×980　1/16　印张：34.5　字数：721.5 千字
版　次：2023 年 1 月第 1 版
印　次：2023 年 1 月第 1 次印刷
定　价：158.00 元





目录

第 1 篇　概述篇

第 1 章　工业企业需要数据治理 2

1.1　工业革命的演变与发展趋势 2
1.2　工业大数据是第四次工业革命的核心基础 4
1.3　各国的工业大数据战略 6
1.4　工业企业数据的核心价值 7
1.5　我国各行业数据治理现状 10
1.6　数据治理是工业大数据的基础 12
1.7　工业企业数据治理面临的挑战 12
本章精要 14

第 2 章　工业企业数据治理概述 15

2.1　数据治理的相关概念和定义 15
2.2　数据的分类 17
2.3　数据治理的顶层架构 20
2.4　数据治理的核心内容 21
本章精要 22

第 3 章　主流数据治理标准及框架介绍 23

3.1　国际标准 23
3.2　国内标准及模型 24
3.3　专业组织 26
3.4　国内外数据治理体系的对比分析 28
本章精要 30

第 4 章　数据治理的发展趋势 31

4.1　国内外数据治理的演变与发展 31
4.2　数据隐私保护政策 32
4.3　区块链与数据共享 33
4.4　5G 技术与数据安全 38
4.5　新技术与数据治理 39
4.6　数据文化与伦理道德 40
4.7　工业企业数据的运营 41
本章精要 43

第 5 章　本书阅读导引 44

5.1　数据治理是一个系统工程 44
5.2　工具是数据治理的保障 45
5.3　实施数据治理有路线可循 45
5.4　数据治理已在诸多行业成功实施 46
参考资料 47

第 2 篇　体系篇

第 6 章　数据管控 51

6.1　数据管控概述 51
6.2　组织架构 53
6.2.1　数据治理组织架构 53
6.2.2　数据治理组织模式 55
6.2.3　数据治理职责分工 58
6.3　制度规范 61
6.3.1　数据治理制度框架 61
6.3.2　数据治理制度修订 64
6.4　执行流程 65
6.4.1　数据治理总体流程框架 65
6.4.2　数据治理典型场景的流程 67
6.5　设计机制 70
6.6　绩效体系 72
6.7　标准体系 74
本章精要 76

第 7 章　数据战略 77

7.1　数据战略概述 77
7.2　数据战略规划 77
7.2.1　愿景和目标 78
7.2.2　基本原则 79
7.2.3　战略举措选择 80
7.2.4　模型工具 81
7.3　数据战略实施 82
7.3.1　实施策略 83
7.3.2　实施路径 83
7.3.3　实施步骤 83
本章精要 87

第 8 章　数据架构 88

8.1　数据架构概述 89
8.2　框架设计 90
8.2.1　数据分布 90
8.2.2　数据主题域 92
8.2.3　数据关联关系 93
8.3　数据建模 98
8.3.1　概念数据模型 99
8.3.2　逻辑数据模型 100
8.3.3　物理数据模型 101
8.3.4　数据模型开发方法 102
本章精要 105

第 9 章　主数据管理 106

9.1　主数据和主数据管理 106
9.1.1　主数据的特征 106
9.1.2　主数据管理的基本概念 107
9.2　主数据标准管理 108
9.3　主数据全生命周期管理 109

9.4 主数据应用管理 110
9.5 企业常用的几类主数据 112
9.5.1 物料主数据 112
9.5.2 设备主数据 113
9.5.3 资产主数据 114
9.5.4 财务主数据 115
9.5.5 组织机构和员工主数据 116
本章精要 116

第 10 章 元数据管理 117

10.1 元数据的定义 117
10.2 元数据分类 117
10.2.1 业务元数据 118
10.2.2 技术元数据 119
10.2.3 操作元数据 120
10.3 元数据核心能力 120
10.4 元数据的价值 123
本章精要 124

第 11 章 数据指标管理 125

11.1 数据指标管理概述 125
11.1.1 数据指标应用和管理中的挑战 125
11.1.2 设计目的 126
11.1.3 设计思路 126
11.2 体系框架 128
11.2.1 典型的数据指标定义框架 128
11.2.2 指标选取原则及方法 129
11.2.3 指标体系层级设计 130
11.2.4 指标体系评价方法 131
11.3 找指标 132
11.4 理指标 134
11.5 管指标 136
11.6 用指标 137
本章精要 137

第 12 章 时序数据管理 138

12.1 时序数据管理概述 138
12.2 时序数据的特点 139
12.3 时序数据的应用 141
12.3.1 技术挑战 141
12.3.2 典型的技术架构及特点 142
12.3.3 系统核心功能 143
本章精要 143

第 13 章 数据质量管理 144

13.1 数据质量需求 144
13.2 数据质量检查 145
13.3 数据质量分析 146
13.4 数据质量提升 147
13.5 数据质量评估 149
13.5.1 数据质量问题的起因 150
13.5.2 数据质量管理技术指标 151
13.5.3 数据质量管理业务指标 152
本章精要 153

第 14 章 数据安全管理 155

14.1 数据安全管理概述 155
14.2 数据安全体系框架 156
14.3 数据安全防护策略 159
14.4 数据安全审计 161
14.5 数据安全风险评估 162
14.6 数据应急保障 164
本章精要 165

第 15 章 数据交换与服务 166

15.1 数据交换与服务的意义 167
15.2 数据交换与服务技术演进 168
15.2.1 文件共享技术 168
15.2.2 数据库中间表技术 168
15.2.3 点对点接口技术 168
15.2.4 消息队列技术 170
15.2.5 企业服务总线交换技术 171
15.2.6 ETL 数据交换技术 173
15.2.7 物联网数据采集交换技术 173
15.3 工业企业数据交换与服务标准体系架构 175
15.3.1 CPS 信息交换模型 176
15.3.2 设备互联总线 177
15.3.3 应用互联总线 178
15.3.4 数据总线 179
15.3.5 开放互联 API 网关 181
本章精要 182

第 16 章 数据共享与开放 183

16.1 共享与开放概述 183
16.2 数据资源目录 185
16.3 数据资源准备 186
16.3.1 数据采集 186
16.3.2 数据加工 187
16.3.3 数据保密 187
16.3.4 数据装载 189
16.3.5 数据发布 189
16.4 数据服务 190
16.5 共享与开放评价 190
本章精要 191

第 17 章 数据管理成熟度评估 192

17.1 数据管理成熟度评估模型 192
17.2 数据管理成熟度等级定义 195
17.3 开展数据管理成熟度评估 198
17.4 数据管理成熟度评估实施 199
本章精要 200
参考资料 200

第 3 篇 工具篇

第 18 章 数据治理工具概述 203

第 19 章 数据资产运营工具 207

19.1 数据资产目录 207
19.1.1 总体概述 208
19.1.2 数据资产目录系统构建 208
19.1.3 数据资产目录能力评估模型 210
19.2 数据资产价值评估 213
19.2.1 总体概述 213
19.2.2 数据资产价值评估模型 214
19.2.3 数据资产价值评估工具 223
本章精要 224

第 20 章 数据模型管理工具 225

20.1 数据模型管理工具概述 225

20.2 企业级数据模型管控 226
20.3 数据标准管控 228
20.3.1 标准的发布和工具访问 228
20.3.2 模型设计中的应用数据标准 228
20.3.3 数据标准应用情况的自动检核 229
20.3.4 自定义标准的发布管理 229
20.4 数据字典的质量检核 230
本章精要 230

第 21 章 数据指标管理工具 231

21.1 指标库管理 231
21.2 指标体系管理 232
21.3 指标评价管理 233
21.4 指标应用管理 234
本章精要 235

第 22 章 主数据管理工具 236

22.1 主数据提取与整合 236
22.2 主数据模型管理 237
22.3 主数据清洗管理 238
22.3.1 主数据清洗的内容 239
22.3.2 主数据清洗的一般过程 239
22.4 主数据全周期管理 242
22.5 主数据质量管理 244
22.6 主数据发布与共享 246
本章精要 248

第 23 章 元数据管理工具 249

23.1 元数据管理工具概述 249
23.2 元数据在数据架构管理中的应用 250
23.3 元数据在数据资产目录中的应用 251
23.4 元数据在主数据管理中的应用 251
23.5 元数据在数据交换和共享中的应用 251
23.6 元数据在大数据平台中的应用 252
本章精要 253

第 24 章 时序数据处理工具 254

24.1 通用大数据处理工具的不足 254
24.2 时序数据处理工具应具备的功能和特点 255
24.3 时序数据的采集 257
24.4 时序数据处理工具 258
本章精要 260

第 25 章 数据质量管理工具 261

25.1 数据质量管理工具概述 261
25.2 数据质量稽核规则设置 262
25.3 数据质量任务管理 263
25.4 数据质量报告 264
本章精要 264

第 26 章 数据交换与服务工具 265

26.1 数据交换与服务工具概述 265
26.2 数据采集 266
26.3 数据交换 268
26.3.1 前置交换子系统 268
26.3.2 交换传输子系统 269
26.3.3 交换管理子系统 269
26.4 数据加工服务 269
26.5 数据共享服务 271
26.6 工业大数据技术平台 272
26.6.1 工业大数据的采集 272
26.6.2 工业大数据的交换 274
26.6.3 工业大数据的处理 275
本章精要 277

第 27 章 数据安全管理工具 278

27.1 数据安全管理工具概述 278
27.2 数据采集安全管理工具 279
27.2.1 数据分类与分级工具 279
27.2.2 采集内容及策略 279
27.2.3 数据采集人员管理工具 280
27.2.4 数据源鉴别及记录 280
27.3 数据传输安全管理工具 280
27.3.1 加密算法 281
27.3.2 对称加密 281
27.3.3 非对称加密 282
27.4 数据存储安全管理工具 282
27.4.1 数据存储介质管理 283
27.4.2 数据存储安全 283
27.4.3 数据备份和恢复 283
27.4.4 等级划分 284
27.5 数据处理安全管理工具 285
27.6 数据交换安全管理工具 286
27.6.1 数据导入/导出的安全保障 287
27.6.2 数据交换安全 287
27.6.3 数据销毁安全管理 288
27.7 统一的身份认证系统 289
本章精要 290

第 28 章 数据中台 291

28.1 数据中台的概念和定位 291
28.2 数据采集 293
28.2.1 数据采集方式 293
28.2.2 通用数据采集 293
28.2.3 流式数据采集 293
28.3 数据存储 294
28.3.1 分布式数据存储 294
28.3.2 NoSQL 数据存储 294
28.4 数据计算 294
28.4.1 分布式查询 295
28.4.2 分布式计算 295
28.4.3 数据建模 295
28.4.4 数据分析 296
28.5 数据服务 296
28.5.1 API 网关 297
28.5.2 API 生成 298
28.5.3 API 发布 298
28.5.4 API 调用申请 298
28.5.5 API 调用审核 298
28.5.6 API 信息支持 298
28.5.7 API 服务监控 299
28.6 从 ETL 向 ELT 转变 299
本章精要 300
参考资料 300

第 4 篇　实施篇

第 29 章　数据治理实施策略和路径选择 303

29.1　实施内容 303
29.2　路径选择 304
本章精要 306

第 30 章　数据治理顶层架构规划与设计 307

30.1　实施内容 307
30.2　步骤和方法 309
30.2.1　顶层设计总体思路 309
30.2.2　数据治理顶层设计要点 311
30.3　成熟度评估 322
本章精要 324

第 31 章　数据资产运营实施 325

31.1　实施内容 325
31.2　步骤和方法 327
本章精要 328

第 32 章　主数据管理实施 329

32.1　实施内容 329
32.2　步骤和方法 329
32.2.1　实施步骤 329
32.2.2　实施方法 331
本章精要 336

第 33 章　元数据管理实施 337

33.1　实施内容 337
33.2　步骤和方法 337
本章精要 340

第 34 章　数据指标管理实施 341

34.1　实施内容 341
34.2　步骤和方法 342
34.3　模板 344
34.3.1　数据指标项定义 344
34.3.2　形成指标卡片及指标模板 345
34.3.3　数据需求规划 346
本章精要 347

第 35 章　数据质量管理实施 348

35.1　实施内容 348
35.2　步骤和方法 349
35.2.1　数据剖析 349
35.2.2　数据质量诊断 350
35.2.3　数据处理规则 351
35.2.4　数据质量优化 351
35.2.5　数据质量监管 352
35.2.6　实施数据质量管理时需注意的问题 353
本章精要 354

第 36 章　数据安全管理实施 355

36.1　实施内容 355
36.2　实施步骤 355
36.3　实践模式 358
36.3.1　数据安全管理的建设策略 358
36.3.2　数据安全管理的切入方式 359
36.3.3　工业互联网云平台的数据安全 359
本章精要 360

第 37 章　数据治理常见误区 361

本章精要 363
参考资料 363

第 5 篇　案例篇

第 38 章　电力行业：夯实数字化转型基础——南方电网数据资产管理行动实践 365

38.1　背景介绍 365
38.2　项目实施 367
38.3　项目成果 377
38.4　项目亮点和洞察 378
38.5　数据治理愿景 379

第 39 章　电力行业：支撑集团产业数字化转型——国家电投集团数据治理实践 380

39.1　背景介绍 380
39.2　数据治理工作实践 382
39.2.1　五凌电力数据治理实践——水电领域 386
39.2.2　黄河公司数据治理实践——光、风、水领域 390
39.2.3　云南国际数据治理实践——风电领域 392
39.3　经验总结 396
39.4　总结与展望 397

第 40 章　能源化工行业：数据治理助百年油企数字化转型 398

40.1　背景介绍 398
40.2　工作概况 400
40.3　组织保障 404
40.4　主要成果 405
40.5　炼化公司智能工厂数据治理实践案例 408
40.6　建设主要内容 409
40.7　总结与展望 411

第 41 章　钢铁行业：酒钢集团数据治理实践 413

41.1　背景介绍 413
41.2　项目目标 414
41.3　项目实施 414
41.4　项目总结 417
41.5　未来展望 419

第 42 章　汽车行业：数据驱动长安汽车数字化转型 420

42.1　背景介绍 420

42.2 工作概况 422
42.3 组织保障 426
42.4 项目成果 427
42.5 工作价值 431
42.6 交流分享 432

第 43 章 核工业：物料主数据治理助力核电智慧运营 433

43.1 背景介绍 433
43.2 工作概况 435
43.3 组织保障 437
43.4 项目成果 439
43.5 项目总结 440

第 44 章 航天行业：军工企业的“三位一体”数据治理体系建设实践 441

44.1 背景介绍 441
44.2 工作历程 443
44.3 组织保障 447
44.4 实施效果 449
44.5 项目总结 450
44.6 未来展望 453

第 45 章 航空行业：面向航空装备研制生产的数据治理研究与实践 456

45.1 背景介绍 456
45.2 两级数据管控模式 459
45.3 信息分类与编码标准 460
45.4 数据应用场景 462
45.5 总结与展望 466

第 46 章 重型装备制造行业：数据标准，装备中国——中国一重的数据标准化管理项目 468

46.1 背景介绍 468
46.2 数据治理概况 472
46.3 数据治理成果 474
46.4 总结与成效 475

第 47 章 交通物流行业：主数据治理助力中国外运数字化转型 477

47.1 背景介绍 477
47.2 项目实施 479
47.3 主要成果 482
47.4 未来展望 489

第 48 章 建材行业：中国建材集团工业大数据应用实践 490

48.1 背景介绍 490
48.2 工作实施 491
48.3 应用框架与技术路线 493
48.4 工作成果 494

第 49 章 制造行业：威孚集团基于斯欧应用互联平台建设数据通道 501

49.1 背景介绍 501
49.2 项目建设技术方案 505
49.3 项目实施步骤 509
49.4 项目实施效果 511
49.5 项目价值及特点 512

第 50 章 战略投资行业：国投集团的数据标准化管理实践 514

50.1 背景介绍 514
50.2 工作概况 516
50.3 组织保障 519
50.4 项目成果 520
50.5 工作价值 528
50.6 经验分享 529

第 51 章 多元化集团：数据治理助力多元化企业集团管控 532

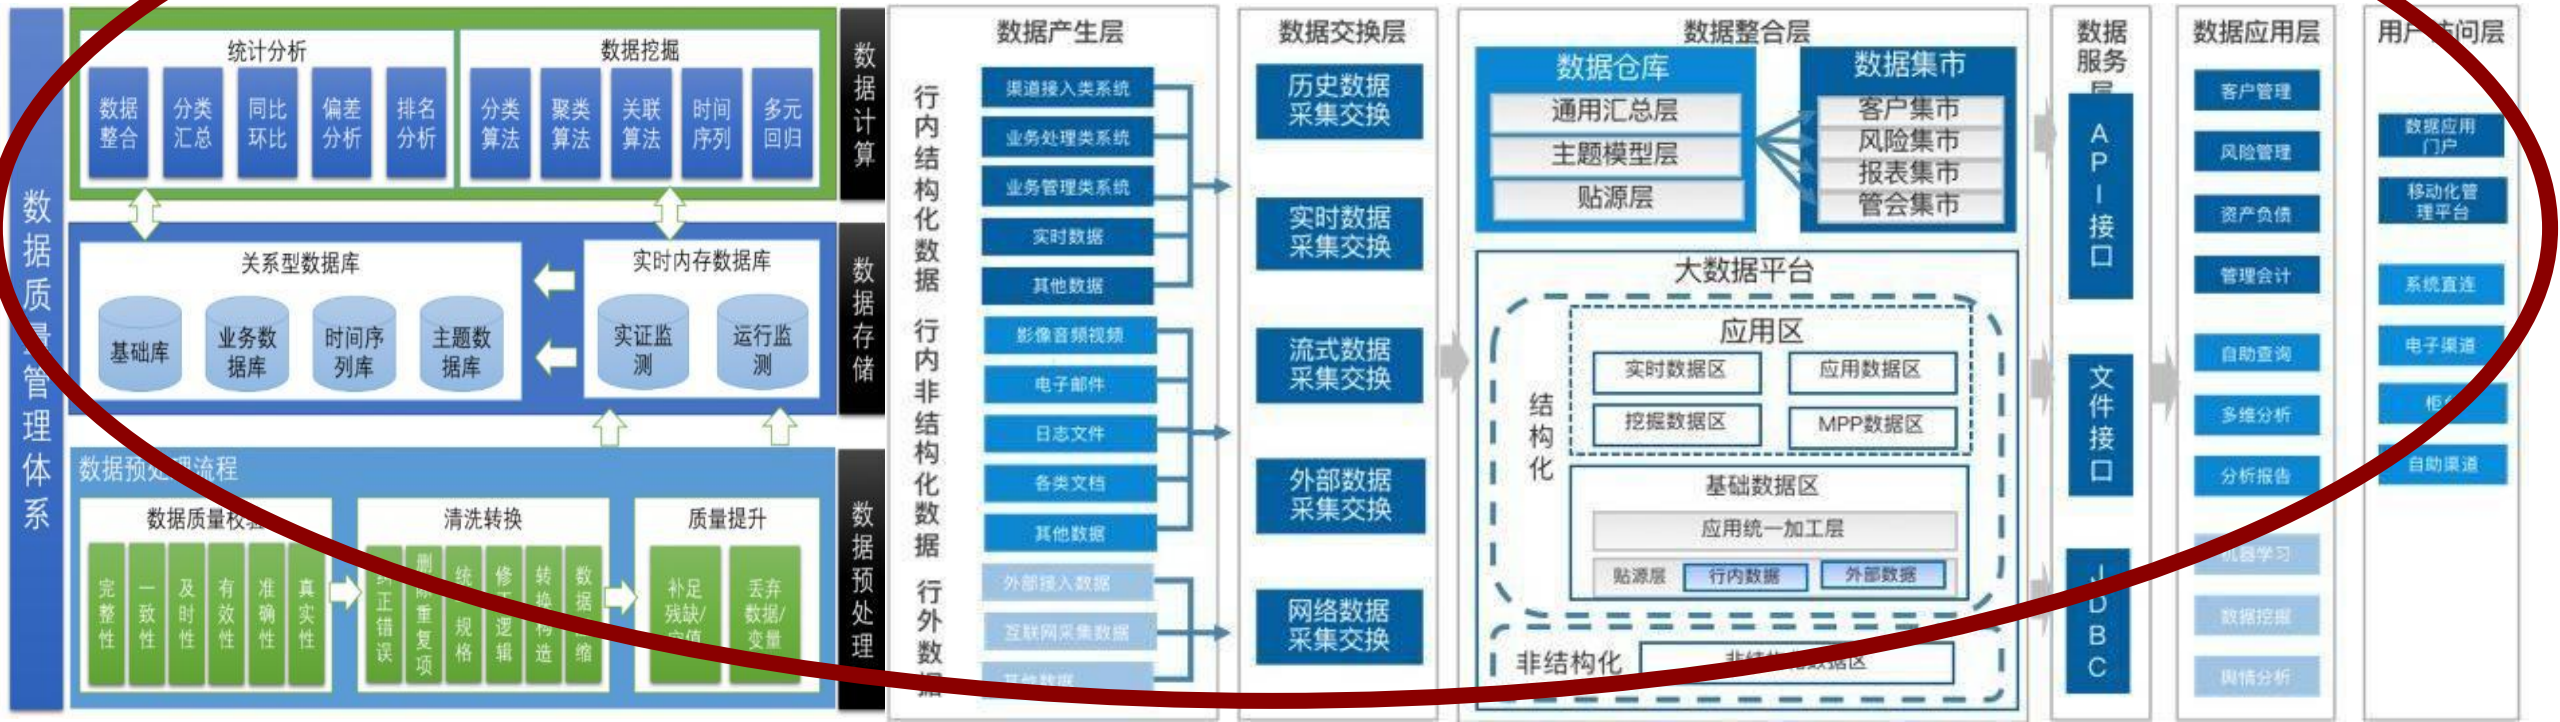
51.1 背景介绍 532
51.2 数据治理概况 534
51.3 组织保障 539
51.4 项目成果 540
51.5 工作价值 543
51.6 项目总结 543

附录 A 工业英文缩写术语表 545

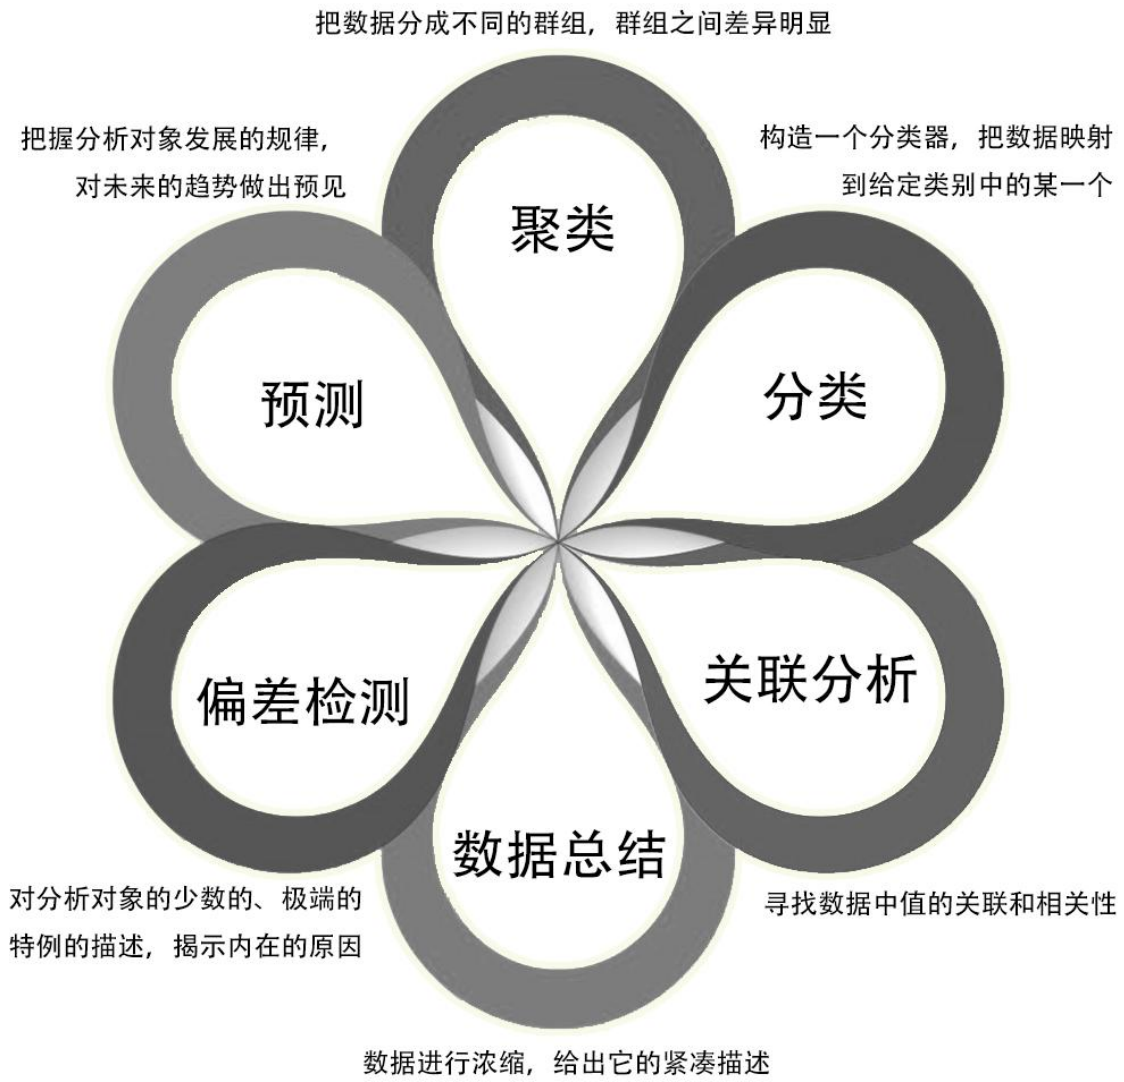
数据智能方向的数据视角：数据规划、数据治理、数据挖掘

- 信息系统规划设计方法（规划“主题数据库”）
- 行业数据模板（高质量的“主题数据库”）

- 数据治理（高可用的“主题数据”）
- 数据挖掘（挖掘数据价值，形成数据资产）



数据挖掘算法分类


把数据分成不同的群组，群组之间差异明显
把握分析对象发展的规律，
对未来的趋势做出预见
构造一个分类器，把数据映射
到给定类别中的某一个
聚类
预测
分类
偏差检测
关联分析
数据总结
对分析对象的少数的、极端的
特例的描述，揭示内在的原因
寻找数据中值的关联和相关性
数据进行浓缩，给出它的紧凑描述

大数据



最早提出“**大数据**”这一概念的是全球知名咨询公司**麦肯锡**，是这样定义大数据的：**一种规模大到在获取、存储、管理、分析方面大大超出了传统数据库软件工具能力范围的数据集合，具有海量的数据规模、快速的数据流转、多样的数据类型以及价值密度四大特征**

研究机构**Gartner**是这样定义大数据的：**“大数据”是需要新处理模式才能具有更强的决策力、洞察发现力和流转优化能力来适应海量、高增长率和多样化的信息资产**



大数据：利用常规技术不能有效处理的数据

大数据处理技术架构

操作框架（Operational Frameworks）
- 监测管理（Monitoring）：OpenTSDB Amdari
- 基准测试（Benchmarking）：YCSB Grid Mix Background

数据集成（Data Integration）
- 数据摄取（Ingest）：Flume, Sqoop, Kafka
- 序列化（Serialization）：Protocol Buffers, Avro
- ETL（萃取、转换、加载）：Crunch, Falcon, Cascading, Oozie
- 元数据（Metadata）：HCatalog

数据分析（Data Analysis）
- 分析工具（Tools）：Pig, Hive, Phoenix
- 分析类库（Libraires）：Mllib, SparkR, Mahout

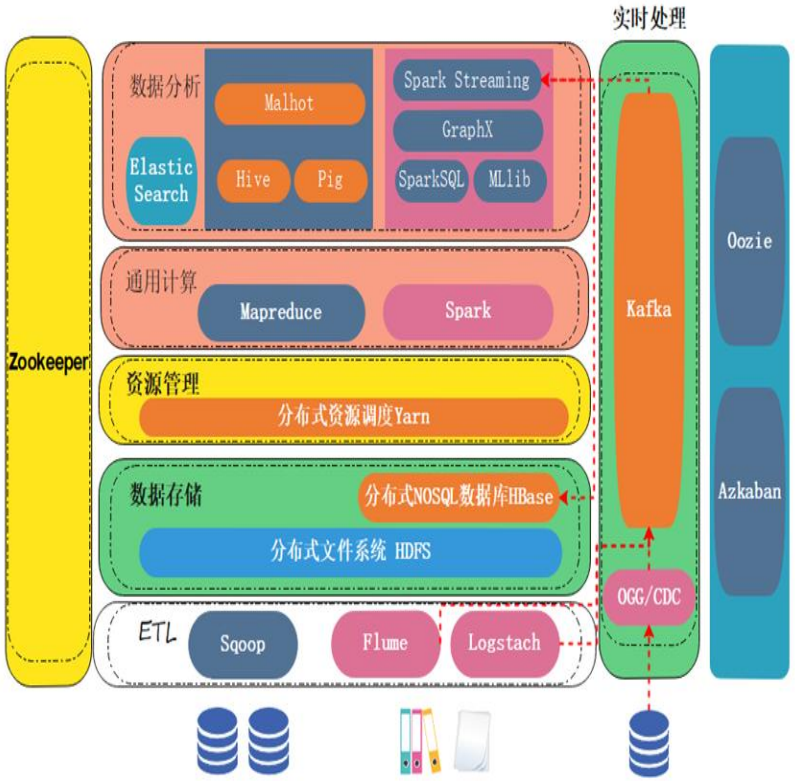
计算框架（Computational Integration）
- 交互式（Interactive）：Dremel, Drill, Tez, Impala, Shark, Presto, BlinkDB, Dryad
- 实时（RealTime）：Druid, Piot
- 流式（Streaming）：Storm, Samza, Spark Streaming
- 批处理（Batch）：MapReduce
- 迭代式（Iterative）：Pregel, Giraph, GraphX, Hama
- 引擎（Engines）：Spark, Flink

资源管理器（Resource Manager）
- Yarn, Mesos

资源协调器（Coordination）
- Paxos, Chubby, ZooKeeper

数据存储（Data Stores）
- 键值存储（KeyValue）：Dynamo, Cassandra, Voldemort
- 列存储（Column）：BigTable, Hbase, Hypertable
- 图存储（Graph）：Neo4j，Titan
- 文档存储（Graph）：CouchDB，MongoDB
- ACID：Megastore, MESA, Spanner, CockroachDB

文件系统（File Systems）
- Google File System, Hadoop HDFS, CEPH文件系统, Parquest, Tachyon, (O) RCFile



“数据”成为生产要素

- 生产要素，是经济学中的一个基本范畴，包括人的要素、物的要素及其结合因素。生产要素指进行社会生产经营活动时所需要的各种社会资源，是维系国民经济运行及市场主体生产经营过程中所必须具备的基本因素
- 2020年3月《中共中央、国务院关于构建更加完善的要素市场化配置体制机制的意见》，数据首次被正式纳入生产要素范围：生产要素包括土地、劳动力、资本、技术、数据五种

  ——数据记载信息，信息孕含知识，这些信息与知识过去是分散於生产经营的各个环节，不易量化，也不好积淀为显性数据与知识。伴随信息技术的飞速发展，识别数据的经济价值，充分发挥其影响全部生产力发展的作用日趋重要，也具备了识别、计量与管理海量数据的算法、算力等工具，于是将数据单列为生产要素就具备了现实条件


中华人民共和国中央人民政府
www.gov.cn

首页 | 简 | 繁 | EN | 登录 |

首页 > 政策 > 中央有关文件

中共中央 国务院关于构建更加完善的要素市场化配置体制机制的意见

2020-04-09 19:00 来源： 新华社

字号：默认 大 超大 | 打印 收藏 留言

新华社北京4月9日电

中共中央 国务院

关于构建更加完善的要素市场化配置体制机制的意见

（2020年3月30日）

完善要素市场化配置是建设统一开放、竞争有序市场体系的内在要求，是坚持和完善社会主义基本经济制度、加快完善社会主义市场经济体制的重要内容。为深化要素市场化配置改革，促进要素自主有序流动，提高要素配置效率，进一步激发全社会创造力和市场活

《意见》提出，要培育数字经济新产业、新业态和新模式，支持构建农业、工业、交通、教育、安防、城市管理、公共资源交易等领域规范化数据开发利用的场景。发挥行业协会商会作用，推动人工智能、可穿戴设备、车联网、物联网等领域数据采集标准化。

要加强数据资源整合和安全保护。制定数据隐私保护制度和安全审查制度。推动完善适用于大数据环境下的数据分类分级安全保护制度，加强对政务数据、企业商业秘密和个人数据的保护。

2022年12月19日发布“数据二十条”

构建数据基础制度体系

《中共中央、国务院关于构建数据基础制度更好发挥数据要素作用的意见》

(2022年12月2日)





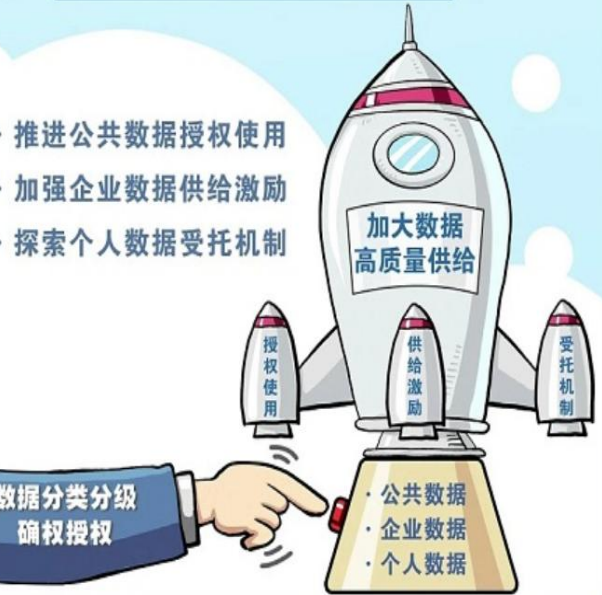
01 数据产权制度

探索数据产权结构性分置制度



推进数据分类分级确权授权机制

- 推进公共数据授权使用
- 加强企业数据供给激励
- 探索个人数据受托机制

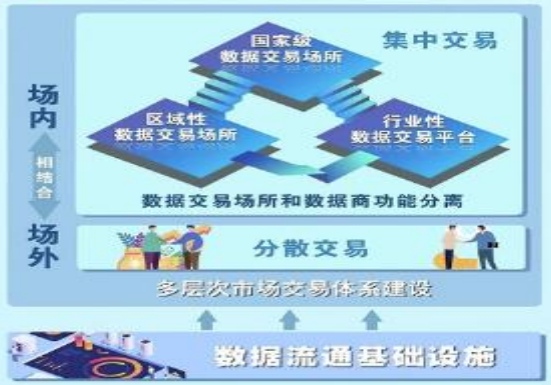


02 流通交易制度

完善数据全流程合规与监管规则体系



构建规范高效的数据交易场所



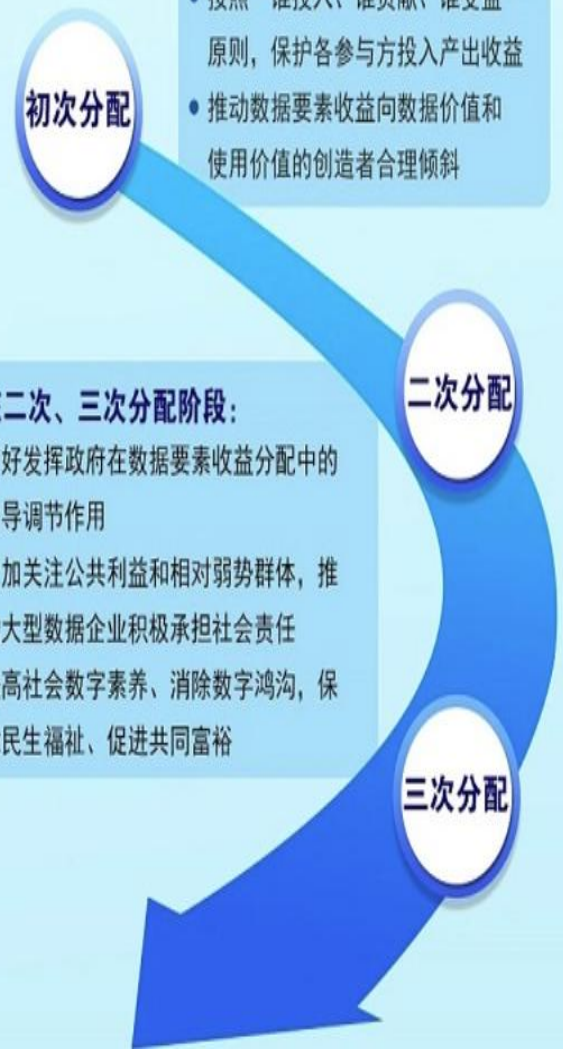
培育数据要素流通和交易服务生态



构建数据安全合规有序跨境流通机制



03 收益分配制度



04 安全治理制度



保障措施

切实加强组织领导

- 统一思想认识，加大改革力度，抓好推进落实
- 加强整体工作统筹，促进跨地区、跨部门、跨层级协同联动

加强政策支持力度

- 做大做强数据要素型企业
- 引导创业投资企业加大对数据要素型企业投入力度
- 支持实体经济企业数字化转型开展信用融资
- 探索数据资产入表新模式

积极鼓励试验探索

- 支持有条件的地区、行业、企业先行先试
- 推动数据要素相关技术和产业应用创新
- 建立创新容错机制，探索完善政策标准和体制机制

稳步推进制度建设

- 逐步完善数据产权界定、流通和交易、收益分配等主要领域关键环节政策及标准
- 加强数据产权保护、市场制度建设等理论研究和立法研究，推动完善相关法律制度

2024年：数据资产的元年

- **2023年8月，国家财政部印发《企业数据资源相关会计处理暂行规定》，明确了数据资源会计处理适用准则及列示和披露要求。该规定2024年1月1日起正式施行**

  ——“数据”正式纳入企业财务三张表之一的“资产负债表”项下，有望批量涌现



中华人民共和国中央人民政府
www.gov.cn

首页 | 简 | 繁 | EN | 登录 | 邮箱 | 无障碍

首页 > 国务院公报 > 2023年第28号

字号：默认 大 超大 | 打印

财政部关于印发《企业数据资源相关会计处理暂行规定》的通知

财会〔2023〕11号

国务院有关部委、有关直属机构，各省、自治区、直辖市、计划单列市财政厅（局），新疆生产建设兵团财政局，财政部各地监管局，有关单位：

为规范企业数据资源相关会计处理，强化相关会计信息披露，根据《中华人民共和国会计法》和相关企业会计准则，我们制定了《企业数据资源相关会计处理暂行规定》，现予印发，请遵照执行。

执行中如有问题，请及时反馈我部。

附件：企业数据资源相关会计处理暂行规定

财 政 部

2023年8月1日



开展数据资产管理需要解决的问题

- 目前关于数据是否能够完全资产化的现实问题和相关争议颇多,但数据资产未来必将成为企业具有关键地位和作用的资产这一观点得到普遍认同
- 数据资产作为新兴产物，如何识别和认定数据资产、如何判断其成本及价值、如何为数据资产进行合理定价，均处于早期研究及摸索阶段

—数据资产识别与认定

—数据资产确权

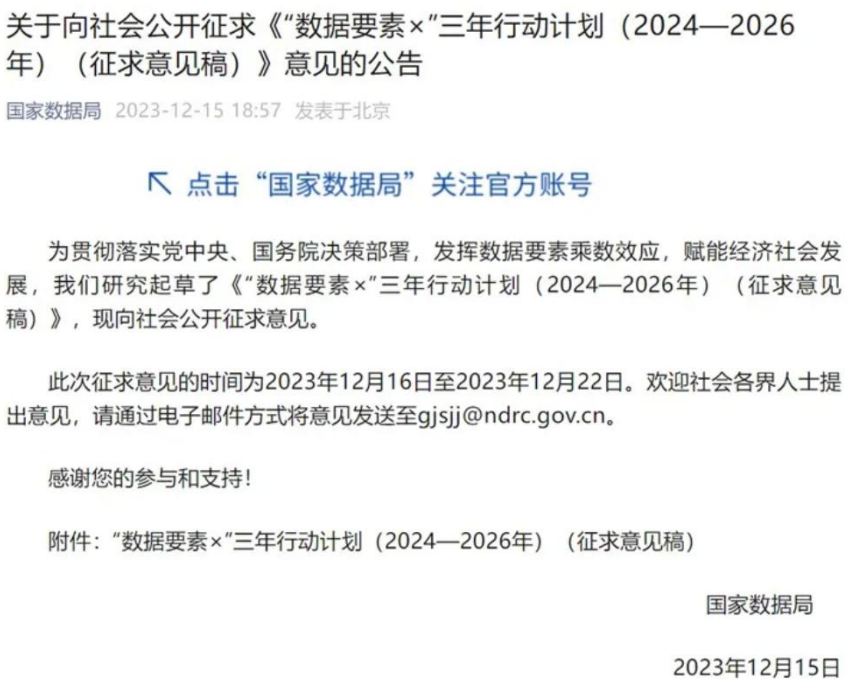
—数据资产评估与计量

—数据资产交易及变现

《“数据要素×”三年行动计划(2024—2026年)》
国数政策〔2023〕11号

- **《行动计划》是国家数据局正式挂牌后发布的第一份文件**
- **国家数据局等17部门联合印发**

—国家数据局、中央网信办、科技部、工业和信息化部、交通运输部、农业农村部、商务部、文化和旅游部、国家卫生健康委、应急管理部、中国人民银行、金融监管总局、国家医保局、中国科学院、中国气象局、国家文物局、国家中医药局



关于向社会公开征求《“数据要素×”三年行动计划（2024—2026年）（征求意见稿）》意见的公告

国家数据局 2023-12-15 18:57 发表于北京

↖ 点击“国家数据局”关注官方账号

为贯彻落实党中央、国务院决策部署，发挥数据要素乘数效应，赋能经济社会发展，我们研究起草了《“数据要素×”三年行动计划（2024—2026年）（征求意见稿）》，现向社会公开征求意见。

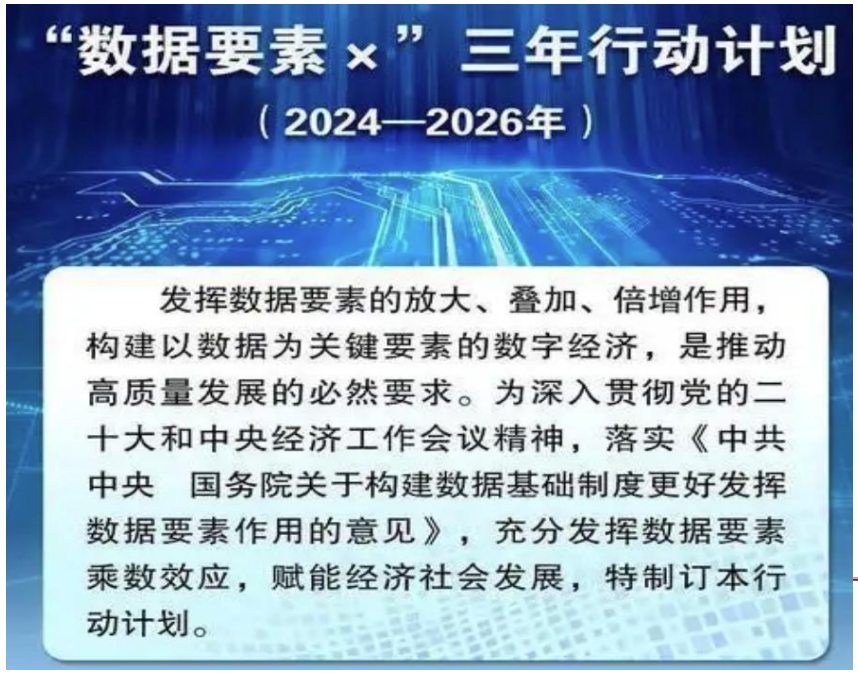
此次征求意见的时间为2023年12月16日至2023年12月22日。欢迎社会各界人士提出意见，请通过电子邮件方式将意见发送至gjsjj@ndrc.gov.cn。

感谢您的参与和支持！

附件：“数据要素×”三年行动计划（2024—2026年）（征求意见稿）

国家数据局

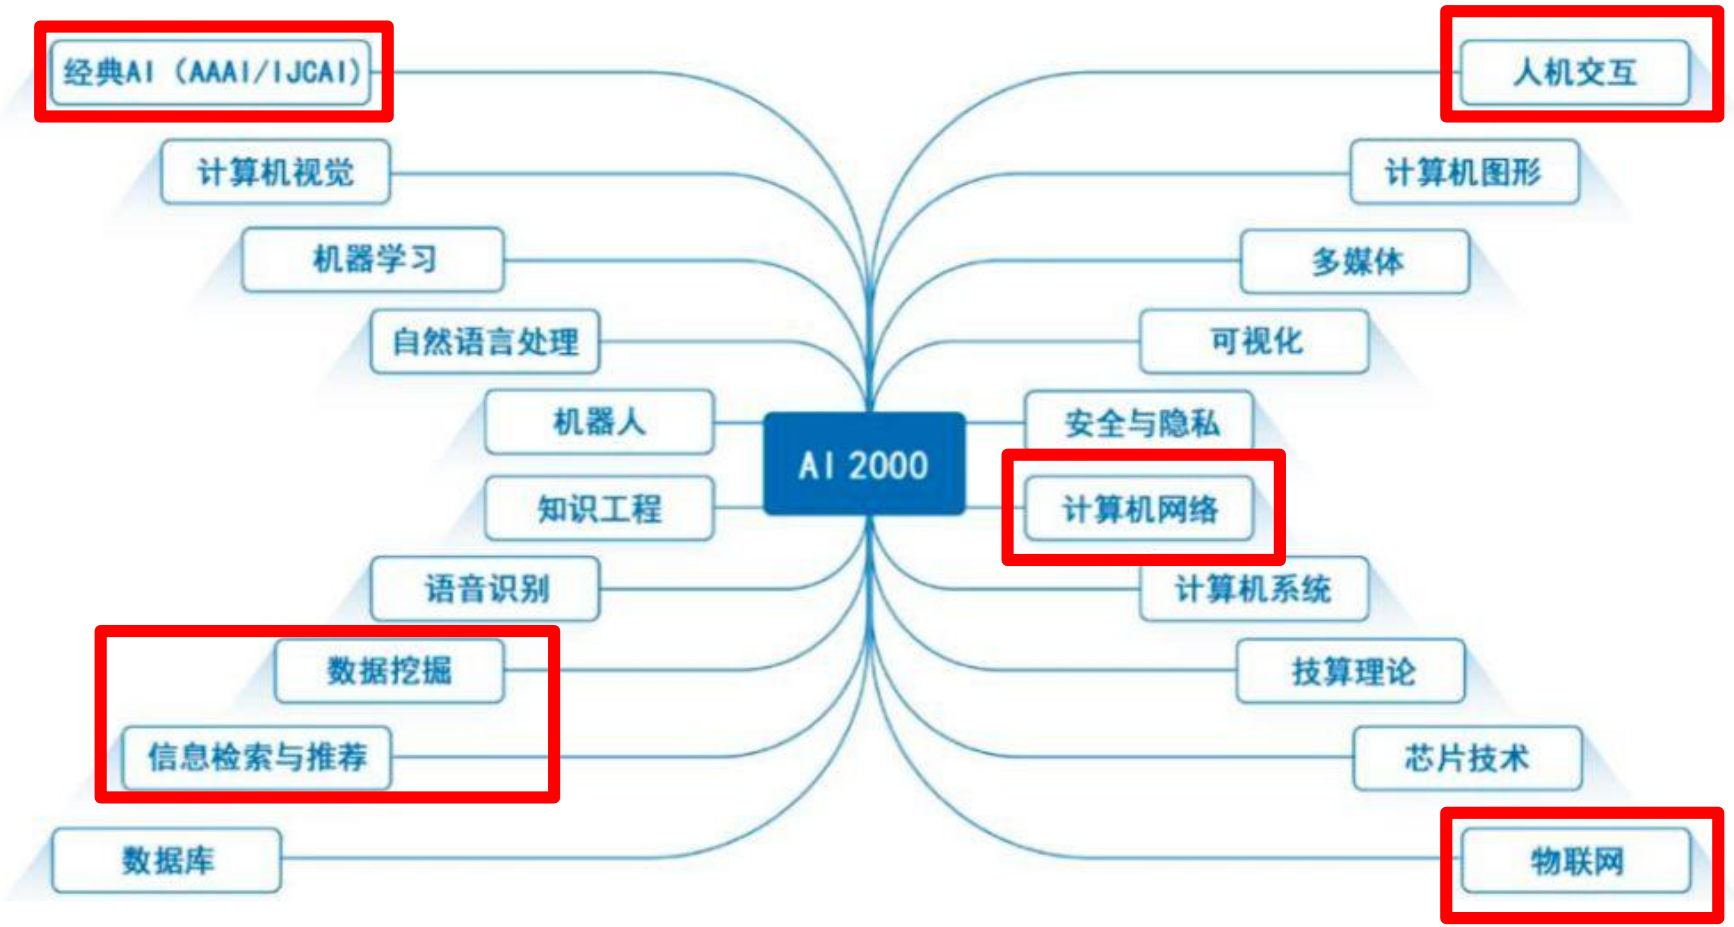
2023年12月15日



AI时代，数据挖掘过时了吗？

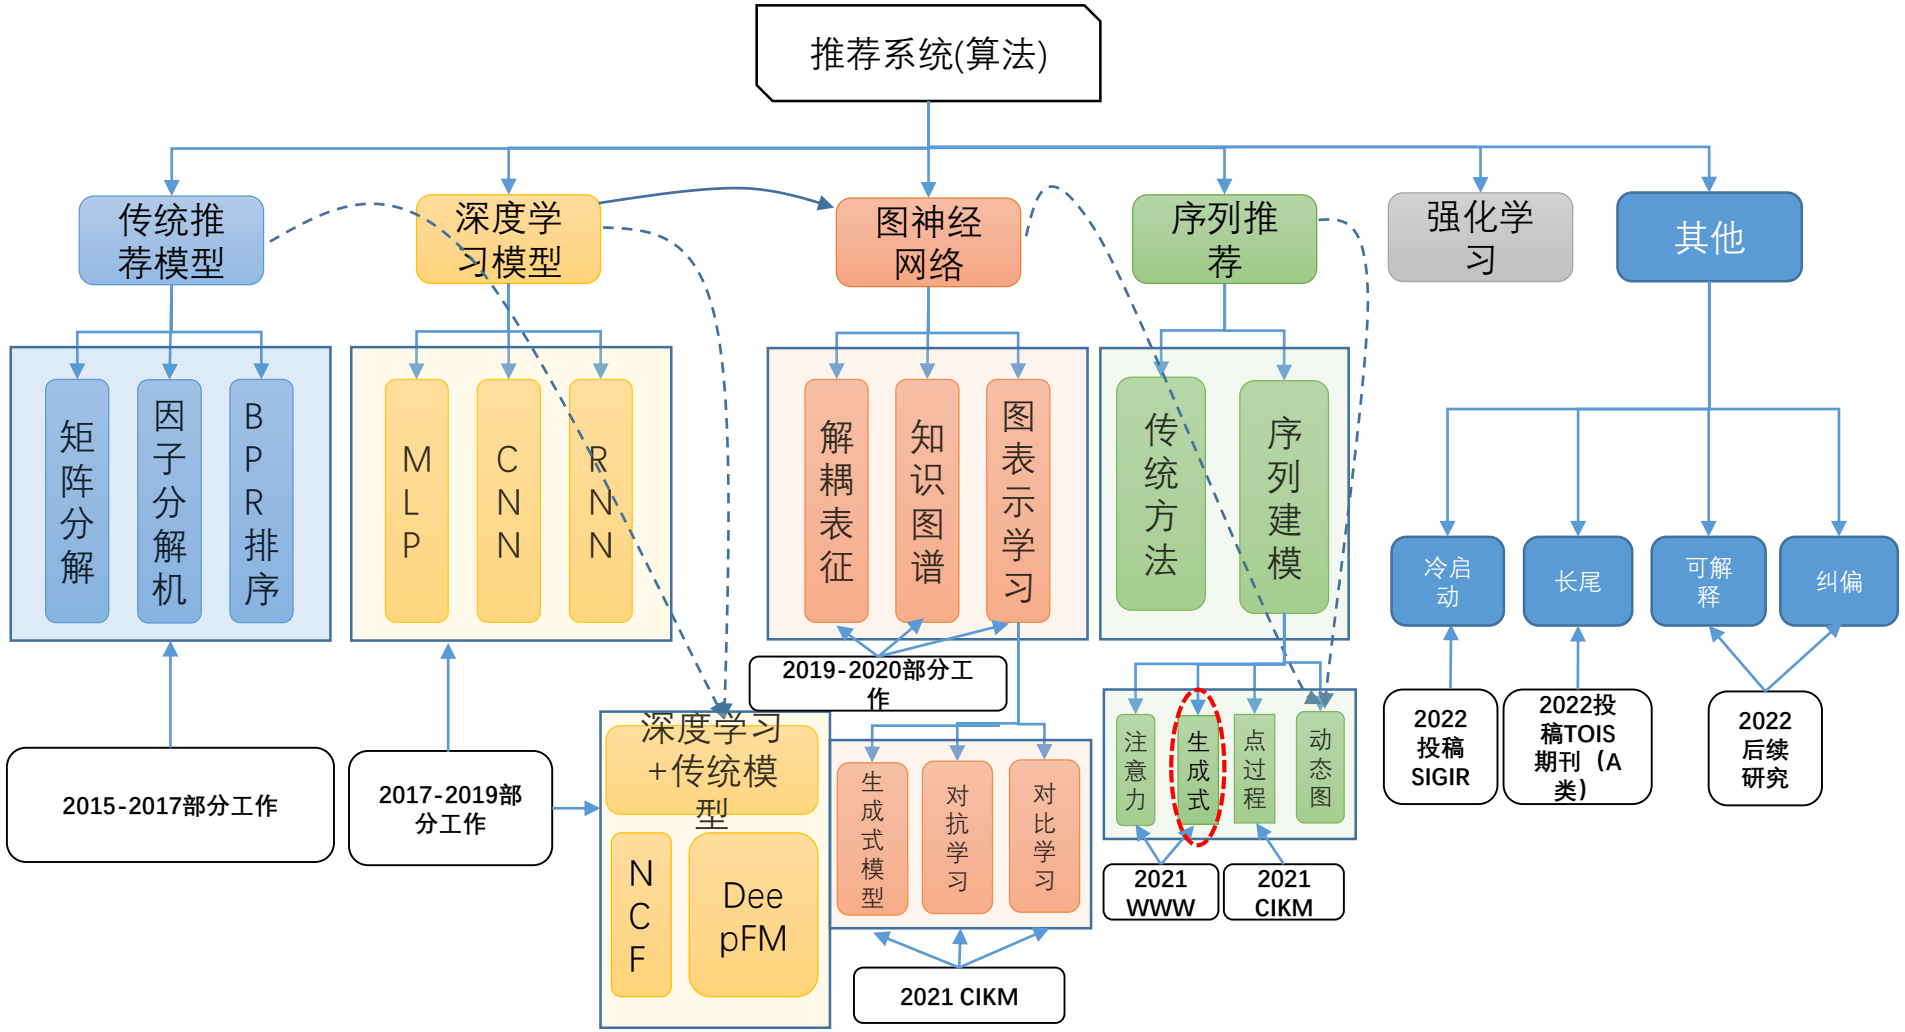


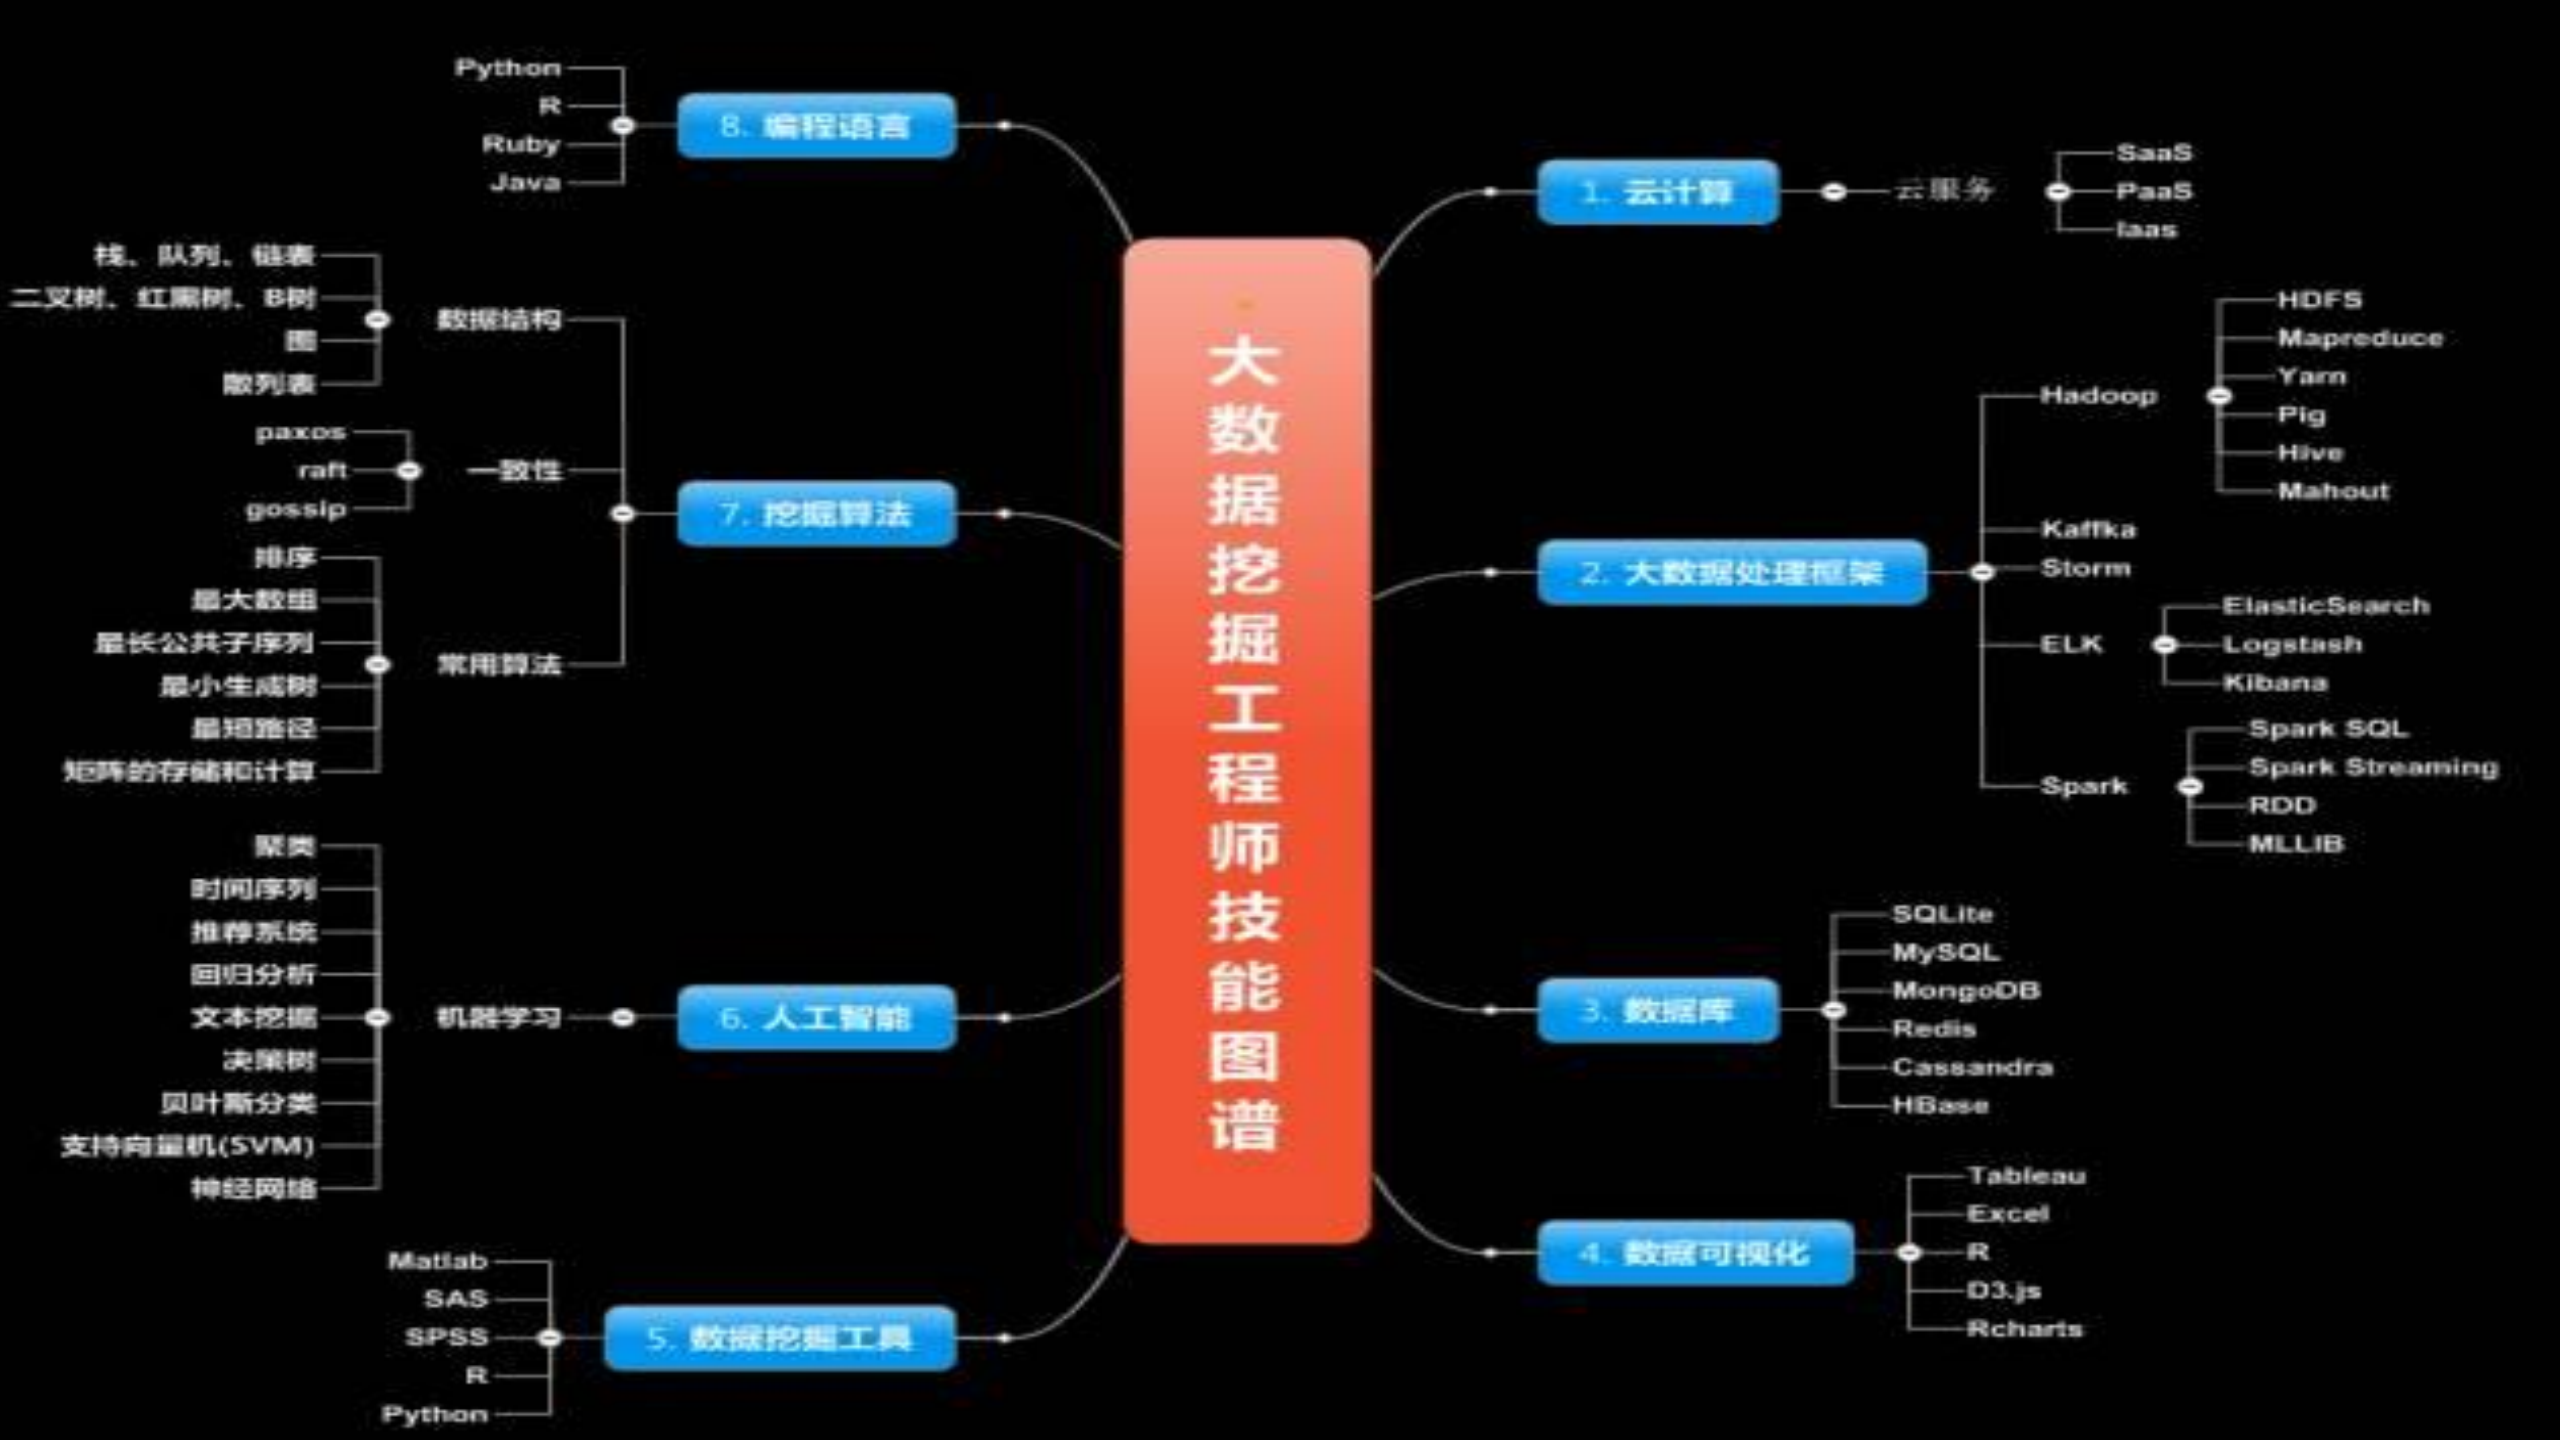
AI时代，数据挖掘过时了吗？



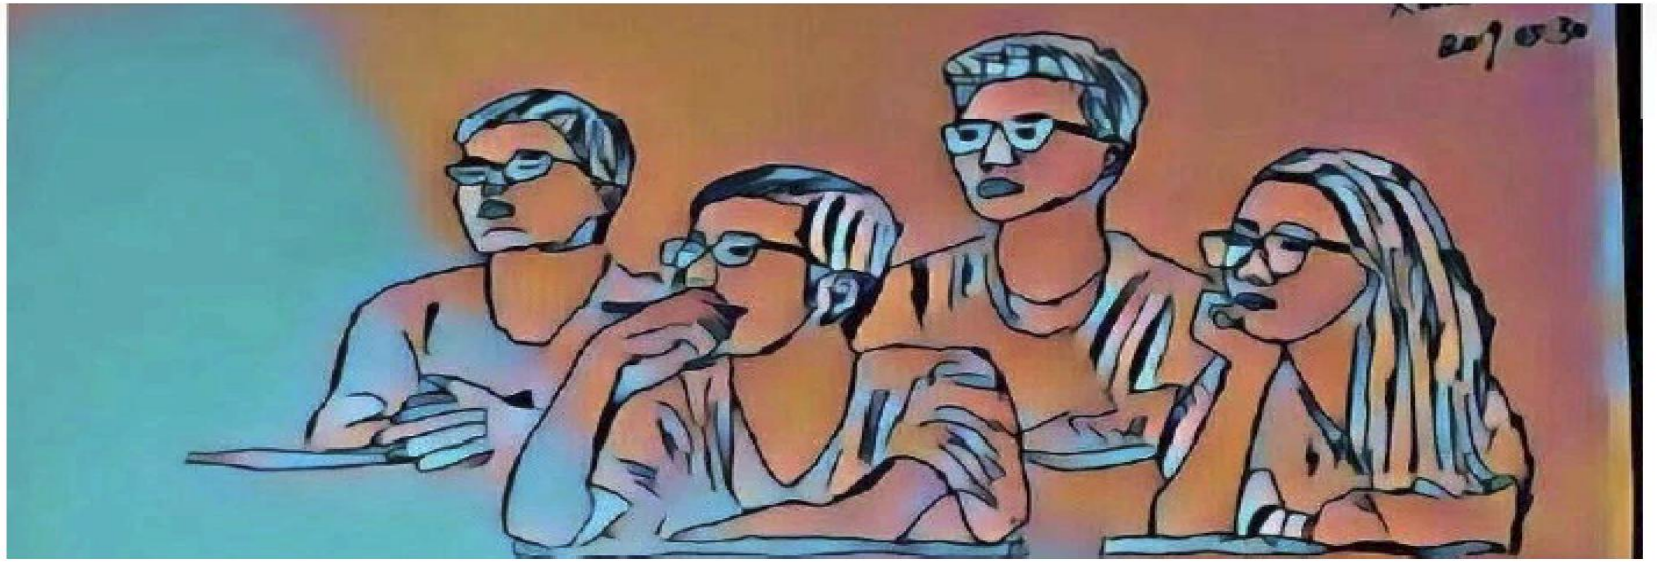
2020年1月，清华—中国工程院知识智能联合研究中心和清华大学人工智能研究院推出了
「 AI 2000人工智能全球 2000 位最具影响力学者榜单（AI 2000 Most Influential Scholar Award）」

物联网实验室在数据挖掘领域的研究工作




大数据挖掘工程师技能图谱
1. 云计算
云服务
SaaS
PaaS
Iaas
2. 大数据处理框架
Hadoop
HDFS
Mapreduce
Yarn
Pig
Hive
Mahout
Kaffka
Storm
ELK
ElasticSearch
Logstash
Kibana
Spark
Spark SQL
Spark Streaming
RDD
MLLIB
3. 数据库
SQLite
MySQL
MongoDB
Redis
Cassandra
HBase
4. 数据可视化
Tableau
Excel
R
D3.js
Rcharts
5. 数据挖掘工具
Matlab
SAS
SPSS
R
Python
6. 人工智能
机器学习
聚类
时间序列
推荐系统
回归分析
文本挖掘
决策树
贝叶斯分类
支持向量机(SVM)
神经网络
7. 挖掘算法
数据结构
栈、队列、链表
二叉树、红黑树、B树
图
散列表
一致性
paxos
raft
gossip
常用算法
排序
最大数组
最长公共子序列
最小生成树
最短路径
矩阵的存储和计算
8. 编程语言
Python
R
Ruby
Java

大模型对于“数据挖掘”“大数据分析”的影响



大模型时代的大数据分析师

用数说
高等教育行业 从业人员

4 人赞同了该文章

摘要:人工智能技术的飞速发展,尤其是大语言模型的崛起,正在深刻影响和重塑各行各业。作为处理和分析海量数据的专业人士,大数据分析师也面临着全新的机遇和挑战。本文将探讨大模型技术对大数据分析领域的影响,分析大模型如何赋能大数据分析师的工作,提出大数据分析师应对大模型时代的策略和方法。通过理论阐述和案例分析,展望大模型时代大数据分析师的发展前景和方向。

2.新一代信息技术与数据挖掘 提纲

- 新一轮科技和产业革命加速数字经济时代的到来
- 解析“健全促进实体经济和数字经济深度融合制度”国家战略
- 新一代信息技术是新质生产力的核心引擎
- 新型基础设施建设赋能经济和社会发展

本讲座从新一代信息技术全景视角分析：

- **数据从哪里来?**
- **数据为什么这么丰富多彩?**
- **数据的价值**
- **数据的采集、传输、处理、应用技术前沿趋势**

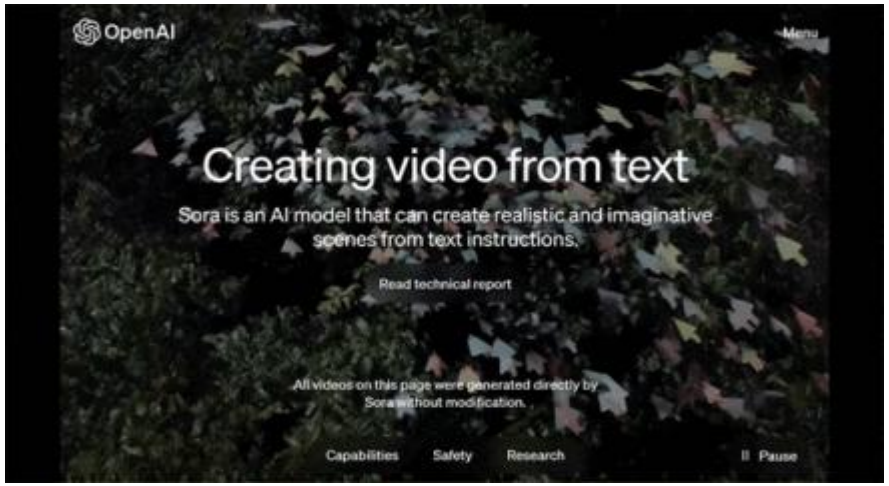
信息技术成为全球研发投入最集中、创新最活跃、应用最广泛、辐射带动作用最大的技术创新领域

2007移动互联网、2009物联网、2011云计算、2013大数据

2014智能硬件、2016人工智能、2017AR/VR、2018区块链

2019 5G、2020新基建、2021工业互联网、2022元宇宙

2023 ChatGPT、2024 SORA、2025 Deepseek…



美国OpenAI发布的人工智能文生视频大模型（但OpenAI并未单纯将其视为视频模型，而是作为“世界模拟器”），于2024年2月15日（美国当地时间）正式对外发布

“大智移云物”

—大数据

—人工智能

—移动互联网

—云计算

—物联网

“大智移云物”场景

—计算无处不在

—软件定义一切

—网络包容万物

—连接随手可及

—宽带永无止境

—智慧点亮未来

2017中国（上海）国际物联网大会（4月25日）
邬贺铨院士主题报告“物联网的产业机遇与安全挑战”

融合发展是新一代信息技术的“主旋律”
物联网、云计算、大数据、人工智能融合：高铁轨道检修案例

- 随着高铁繁忙运行，日客流量不断增长，高铁线路的几何形位也会产生变化，轨道结构也会产生损坏
- 采用40km/h的雷达检测车（物联网：图像传感器、超声波探伤、雷达测试、激光光电、其他各种轨道检测设备）对路基和轨道进行快速、无损地连续检测，还可以进行多通道载荷、位移测试
- 仅1公里线路上轨检车最高采样点可达到4100多个（云计算、大数据）
- 对轨道的轨距、方向、高低、水平以及曲线超高、曲率、车体的水平振动加速度、车体垂直振动加速度等历史数据进行清洗、归一化处理后，通过回归等数据挖掘手段建立轨道状态检测模型和轨道的动力学特性（人工智能）

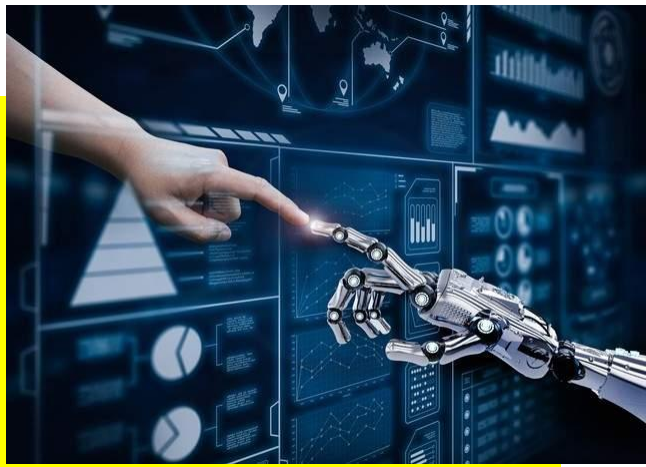


序号	轨道质量相关数据
1	轨道几何尺寸（轨距、水平、轨向、尖趾距离、查照间隔）
2	钢轨（接头轨面、内侧错牙、轨端飞边、轨缝）
3	轨枕（碎石道床轨接头岔枕、整体道床轨枕玻璃钢套管）
4	联接零件（尖轨、可动心轨与滑床板间缝，弹条中部前端下颚离缝）
5	轨道加强设备（转辙、辙叉部分轨撑离缝，爬行量）
…	……

轨道质量状态	对应质量状态描述
目标值（VO）	新线铺设、维修作业后应达到的质量标准
警告值（VA）	达到或超过此值的轨道不平顺，要实施重点观测，分析其发展变化情况并做出维修计划
干预值（VI）	达到或超过此值的地点或区段要实施必要的维修作业，一般在 15 天之内予以实施，并使其达到目标值
限速值（VR）	达到或超过该值的地点或区段列车必须降速行驶，并以任何可能的手段包括手工作业予以整治

人工智能将引爆新一轮的技术与产业革命

- 目前大多数技术由于其产业链的长度和体量，都无法引发社会总需求的爆发式增长，都不具备引发下一个技术和产业革命的潜力
- 随着人工智能机器自学习技术的不断发展，将引发诸多行业365x24小时的持续创新和优化。各行业需求的叠加必将引发社会总需求的爆发式增长



在2030年前后，一系列技术走向成熟

—感知：物联网成本大幅降低（离万物互联会更进一步）

—传输：6G无线传输提速

—计算：量子计算普及

—人机混合智能：人机互联（实现人脑与计算机的连接）实现……

将由人工智能引发新的技术与产业革命

新型基础设施

坚持系统完备、高效实用、智能绿色、安全可靠的导向，因业施策、因地制宜，加速建设信息基础设施，稳步发展融合基础设施，适度超前部署创新基础设施，为实现经济持续健康发展、高水平科技自立自强和不断增进民生福祉夯实先进基础。

面向世界科技前沿、面向经济主战场、面向国家重大需求、面向人民生命健康，建设协同、先进、开放、高效的创新基础设施体系。



- 超前布局科学研究设施
- 优化提升技术开发设施
- 加快完善试验验证设施
- 统筹发展科技资源支撑平台
- 推动建设创新创业服务设施

结合新型城镇化，推动交通、物流、能源、市政等基础设施智慧化改造，逐步形成网络化、智能化、服务化、协同化的融合基础设施。



- 打造具备较高水平的工业互联网
- 发展协同高效的智能交通物流设施
- 构建清洁高效的智慧能源系统
- 建设先进普惠的智慧民生基础设施



- 形成绿色智慧的环境资源设施
- 建设智能新型的城市基础设施
- 建设便捷高效的县城数字化设施
- 构筑系统完备的智慧农业农村设施体系

加速构建高速泛在、天地一体、集成互联、安全高效的信息基础设施。

- 发展泛在协同的物联网感知设施
- 推动5G网络全面深度覆盖
- 构建高速畅通的固定宽带网络
- 建设协同完善的空间信息基础设施
- 构建一体化大数据中心体系
- 布局高效的人工智能基础设施
- 培育面向未来的新技术基础设施



- ***新型基础设施赋能经济和社会发展***
  - ***—信息基础设施***
    - ***发展泛在协同的物联网感知设施***
    - ***推动5G网络全面深度覆盖***
    - ***构建一体化大数据中心体系***
    - ***布局高效的人工智能基础设施***
  - **—融合基础设施**
  - **—创新基础设施**



工信部联通信〔2024〕165号

- **持续建设低中高速协同发展的移动物联网体系**
- **集约部署城市感知终端，统一建设城市级物联网感知终端管理和数据分析平台**
- **强化物联网、人工智能等新技术风险评估，严格落实物联网卡安全管理要求**

- ***新型基础设施赋能经济和社会发展***
  - —信息基础设施
  - —***融合基础设施***
    - ***打造具备较高水平的工业互联网***
    - 发展协同高效的智能交通物流设施
    - ***建设智能新型的城市基础设施***
  - —创新基础设施



- ***新型基础设施赋能经济和社会发展***
  - —信息基础设施
  - —融合基础设施
    - 打造具备较高水平的工业互联网
    - 发展协同高效的智能交通物流设施
    - 建设智能新型的城市基础设施
  - ***—创新基础设施***

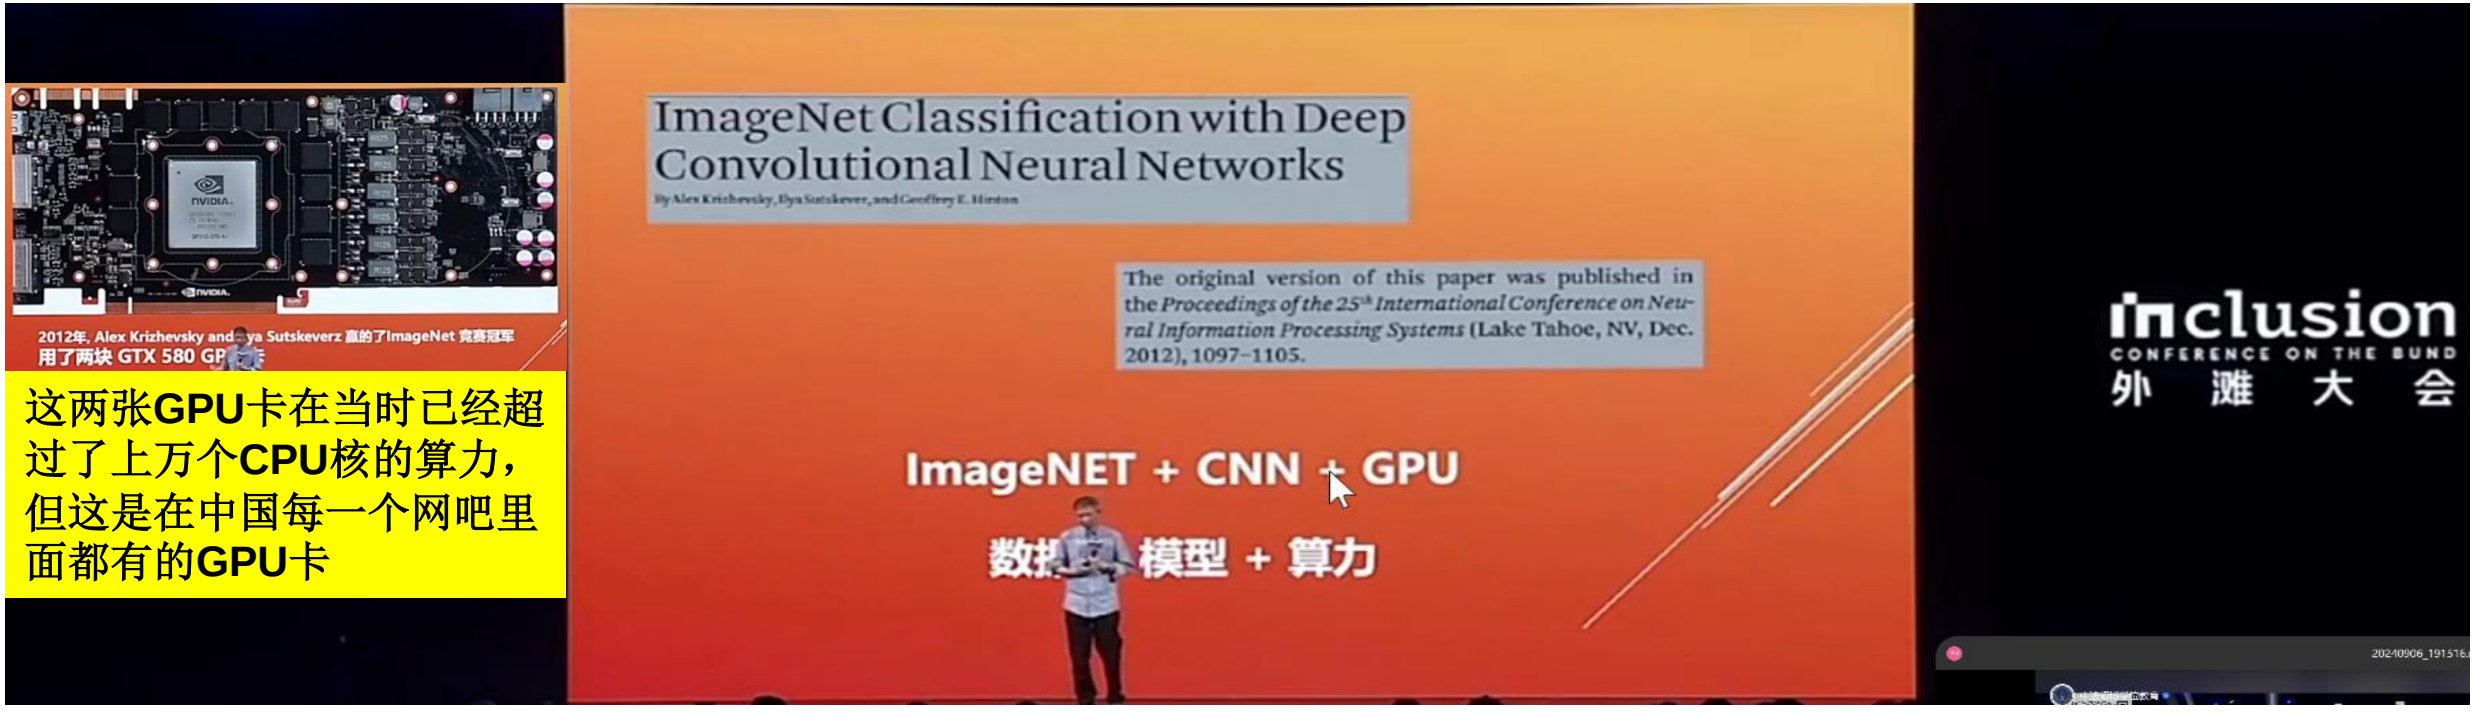


ImageNet Classification with Deep Convolutional Neural Networks

Alex Krizhevsky, Ilya Sutskever, Geoffrey E. Hinton

- 文章抽象出来三个东西：有组织的数据ImageNet；模型CNN；GPU。这三个东西都不是新的， ImageNet存在了很久，CNN也不是新算法，GPU在每个网吧里面都有
- 文章完美地把三个东西结合在一起，使GPU、模型和数据成为行业的最基本的标准
- GPU是在这篇文章之后，才成为学术界和工业界的标准（当时他们用了两块非常普通的GPU卡）
- 在创新阶段，没有比人的创造力再重要的事情

- 第一步：告诉我们干了什么事情：我们训练了一个大型的深度卷积神经网络，将LSVRC-2010竞赛中的ImageNet 120万张高分辨率图像分类到1000个不同的类别。
- 第二步：结果：在测试数据上，top-1的错误率是37.5%，top-5的错误率为17.0%，这大大优于之前的最先进水平。（2010年的竞赛给了测试集）
- 该神经网络有6000万个参数和65万个神经元，由5个卷积层组成，其中一些是最大池化层，还有三个全连接层，最后是1000路的softmax。
- 为了使训练更快，采用GPU。
- 为了减少全连接层的过拟合，采用名为“dropout”的正则化方法。
- 参加了LSVRC-2012比赛，2012年没有给测试集，我们的模型top-5错误率为15.3%，第二名的错误率为26.2%。



这两张GPU卡在当时已经超过了上万个CPU核的算力，但这是在中国每一个网吧里面都有的GPU卡



做影响和改变世界的交大人

——在2024年本科生毕业典礼上的讲话

上海交通大学校长、中国科学院院士　丁奎岭

2024年6月26日

3. 数据治理(1)认识数据 提纲

- Data Objects and Attribute Types
  数据对象与属性类型
- Basic Statistical Descriptions of Data
  数据的基本统计描述
- Data Visualization
  数据可视化
- Measuring Data Similarity and Dissimilarity
  度量数据的相似性和相异性
- Summary 小结

Types of Data Sets 数据类型

- Record
  - Relational records
  - Data matrix, e.g., numerical matrix crosstabs
  - Document data: text documents: term-frequency vector
  - Transaction data
- Graph and network
  - World Wide Web
  - Social or information networks
  - Molecular Structures
- Ordered
  - Video data: sequence of images
  - Temporal data: time-series
  - Sequential Data: transaction sequences
  - Genetic sequence data
- Spatial, image and multimedia:
  - Spatial data: maps
  - Image data:
  - Video data:

- 数据类型决定了应使用何种工具和技术来分析数据
- 数据挖掘研究常常是为了适应新的应用领域和新的数据类型的需要而展开的

Attributes 属性

数据挖掘 数据库

- **属性(Attribute)：** 数据仓库 机器学习 统计学
  也被成为维(Dimensions)、特征(Features)、变量(Variables)
- **通常是一个 数据字段， 表示数据对象的一个特征**
  - E.g., 顾客_ID, 姓名，地址
- **描述对象的一组属性称为属性向量（或特征向量）**

- **属性类型：由属性可能具有的值的集合决定**
  - **标称属性(Nominal)**
  - **二元属性(Binary)** → **定性的**
  - **序数属性(Ordinal)**
  - **数值属性(Numeric)： 量化的** → **定量的**
    - **区间标度(Interval-scaled)**
    - **比率标度(Ratio-scaled)**

Basic Statistical Descriptions of Data

数据的基本统计描述

- **为什么要描述？**

  —— 为了更好地理解数据的 **中心趋势度量、散布情况**

- **中心趋势度量**
  - 最大值、最小值、均值、中位数、众数、中列数……

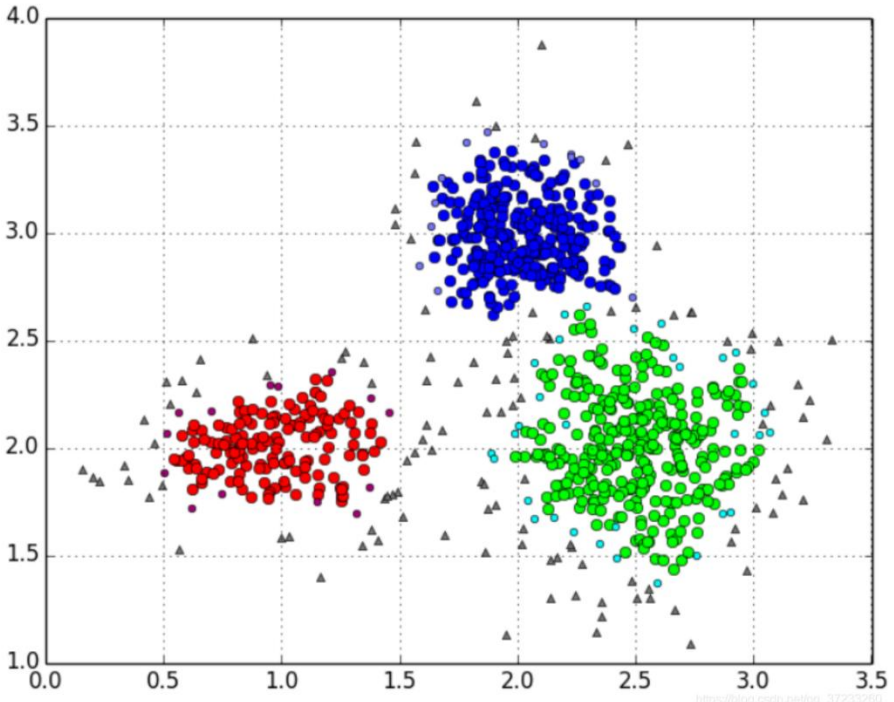
- **数据散布**
  - 评估数值数据散布或发散的度量
  - 包括极差、分位数、四分位数、百分位数和四分位数极差等

- **可视化地审视数据——描述的图形显示**
  - 一元分布：分位数图、直方图等
  - 二元分布：散点图

Data Visualization
数据可视化

- 为什么要 **数据可视化**？
  - — 通过图形表示清晰有效的数据
  - — 发现原始数据中不易观察到的数据联系
  - — **制造乐趣和有趣的图案**









可视化的方法

- **可视化多种多样……**
  - —基于像素的可视化技术
    - Pixel-oriented visualization techniques
  - —几何投影可视化技术
    - Geometric projection visualization techniques
  - —基于图符的可视化技术
    - Icon-based visualization techniques
  - —层次可视化技术
    - Hierarchical visualization techniques
  - —可视化复杂对象和关系
    - Visualizing complex data and relations

混合类型属性的相异性(Cont.)

$$\begin{pmatrix} 0 & & & \\ 1.0 & 0 & & \\ 0.5 & 0.5 & 0 & \\ 0 & 1.0 & 0.5 & 0 \end{pmatrix}$$

对象标识符	test-1	test-2	test-3
1	A	优秀	45
2	B	一般	22
3	C	好	64
4	A	优秀	28

$$\begin{bmatrix} 0 & & & \\ 1 & 0 & & \\ 1 & 1 & 0 & \\ 0 & 1 & 1 & 0 \end{bmatrix}$$

处理test-1和test-2的过程在此略过

首先计算test-3的相异性矩阵

令 $\min_h x_h = 22$ ， $\max_h x_h = 64$ 用两者之差来规格化相异性矩阵的值

$$\begin{pmatrix} 0 & & & \\ 0.55 & 0 & & \\ 0.45 & 1.00 & 0 & \\ 0.40 & 0.14 & 0.86 & 0 \end{pmatrix}$$

然后将三个矩阵合并，例如 $d(3,1) = \frac{1(1) + 1(0.5) + 1(0.45)}{3} = 0.65$

依此类推，得到最终结果

$$\begin{pmatrix} 0 & & & \\ 0.85 & 0 & & \\ 0.65 & 0.83 & 0 & \\ 0.13 & 0.71 & 0.79 & 0 \end{pmatrix}$$

3. 数据治理(2)数据预处理 提纲

- 概述
- 数据清洗（见数据预处理—数据清洗）
- 数据集成（见数据预处理—数据集成）
- 数据规约（见数据预处理—数据规约）
- 数据变换与数据离散化
- 小结

Pandas: 强大的 Python 数据分析支持库

版本：0.25.3 **日期**：2019 年 10 月 31 日

下载文档（英文）：PDF Version | Zipped HTML

实用链接: 二进制安装包 | 源码仓库 | 问题和想法 | 常见问题 | 邮件列表

Pandas 是基于 BSD 许可的开源支持库，为 Python 提供了高性能、易使用的数据结构与数据分析工具。

更多内容，请参阅 Pandas 概览。

- v0.25.3 版新特性（发布于：2019 年 10 月 31 日）
- 安装
- 快速入门
- Pandas 概览
- 十分钟入门 Pandas
- 基础用法
- 数据结构简介
- 与其它工具比较
- 教程
- 用户指南
- IO 工具（文本、CSV、HDF5 ...）
- 索引与选择数据
- 多层索引与高级索引
- 合并、连接、结合
- 重塑与数据透视表
- 重塑与数据透视表
- 处理文本数据
- 处理缺失数据
- 分类数据
- 可空整型数据
- 可视化
- 计算工具
- 分组操作：拆分-应用-组合
- 时间序列 / 日期
- 时间差
- 样式
- 选项与设置
- 性能优化
- 稀疏数据结构
- 常见问题（FAQ）
- 烹饪指南
- Pandas 生态系统
- API 参考手册
- [输入 / 输出](https://pandas.pydata.org/pandas-docs/stable/reference/io/.html
- 通用函数
- Series
- DataFrame
- Pandas 数组
- Panel
- 索引
- 日期偏移
- 窗口函数
- 分组
- 重采样

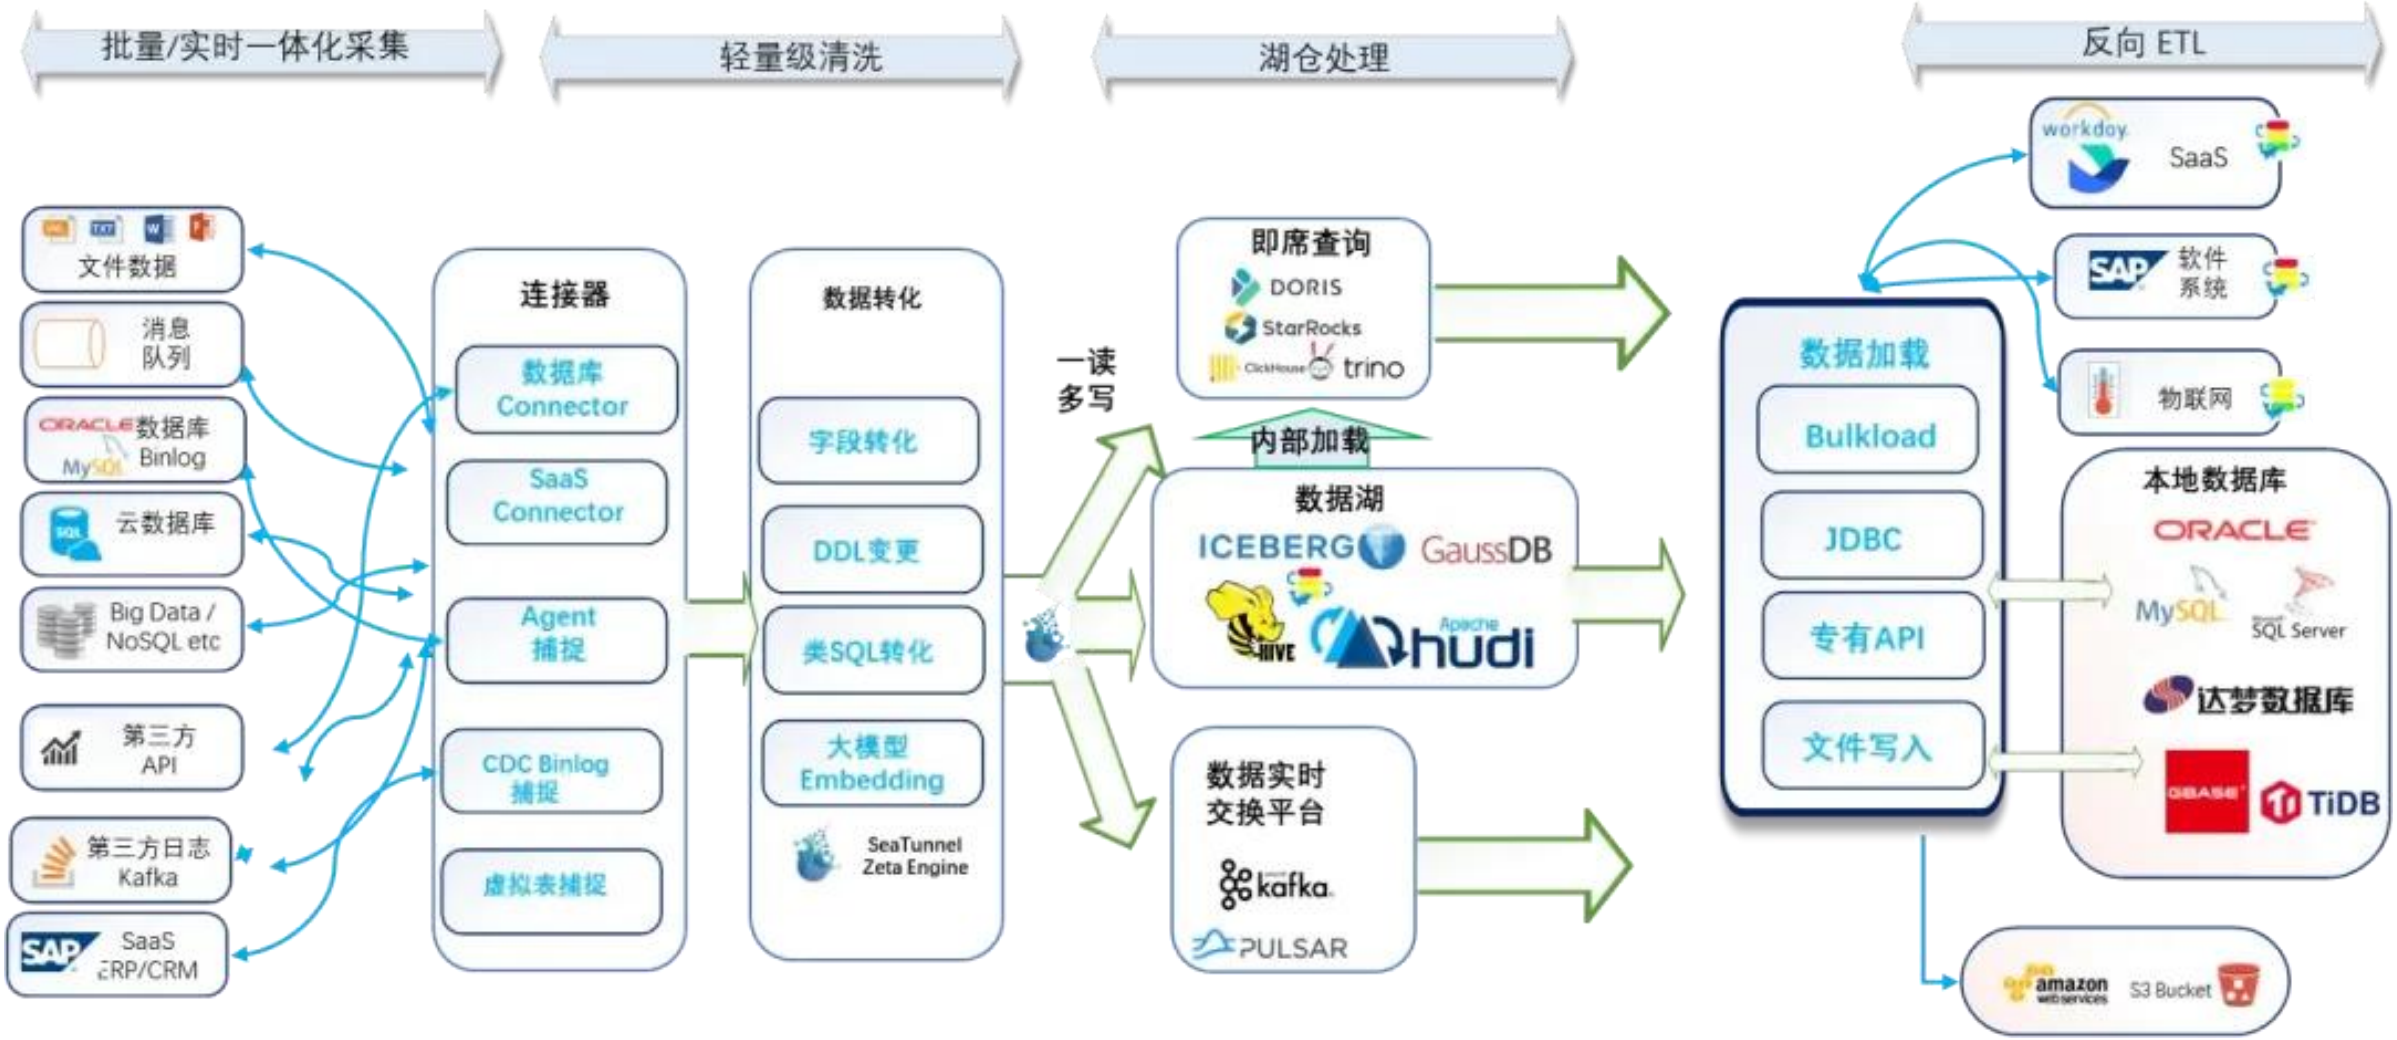
3. 数据治理(2)数据预处理 提纲

- 概述
- 数据清洗（见数据预处理—数据清洗）
- 数据集成（见数据预处理—数据集成）
- 数据规约（见数据预处理—数据规约）
- 数据变换与数据离散化
- 小结

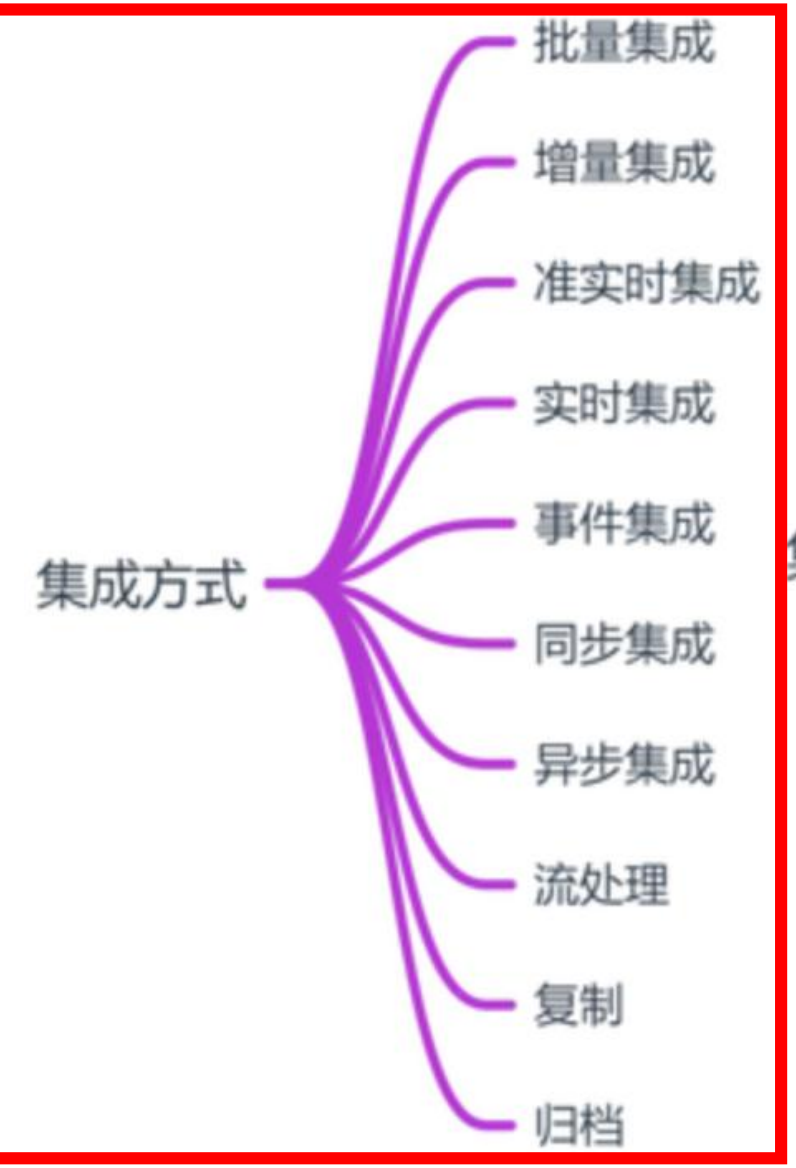
数据集成

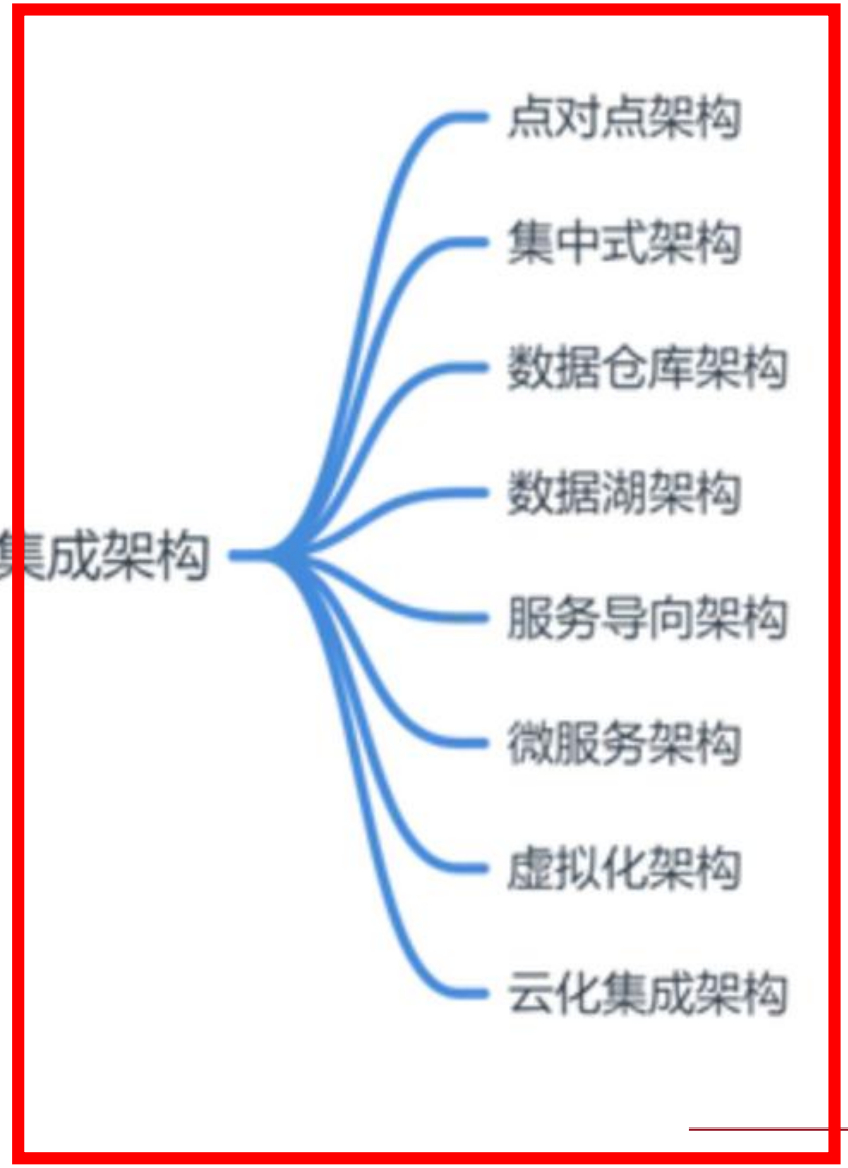
- 基本概念
- 数据集成的方式
- 数据集成的架构
- 数据集成的工具
- 数据集成技术发展趋势

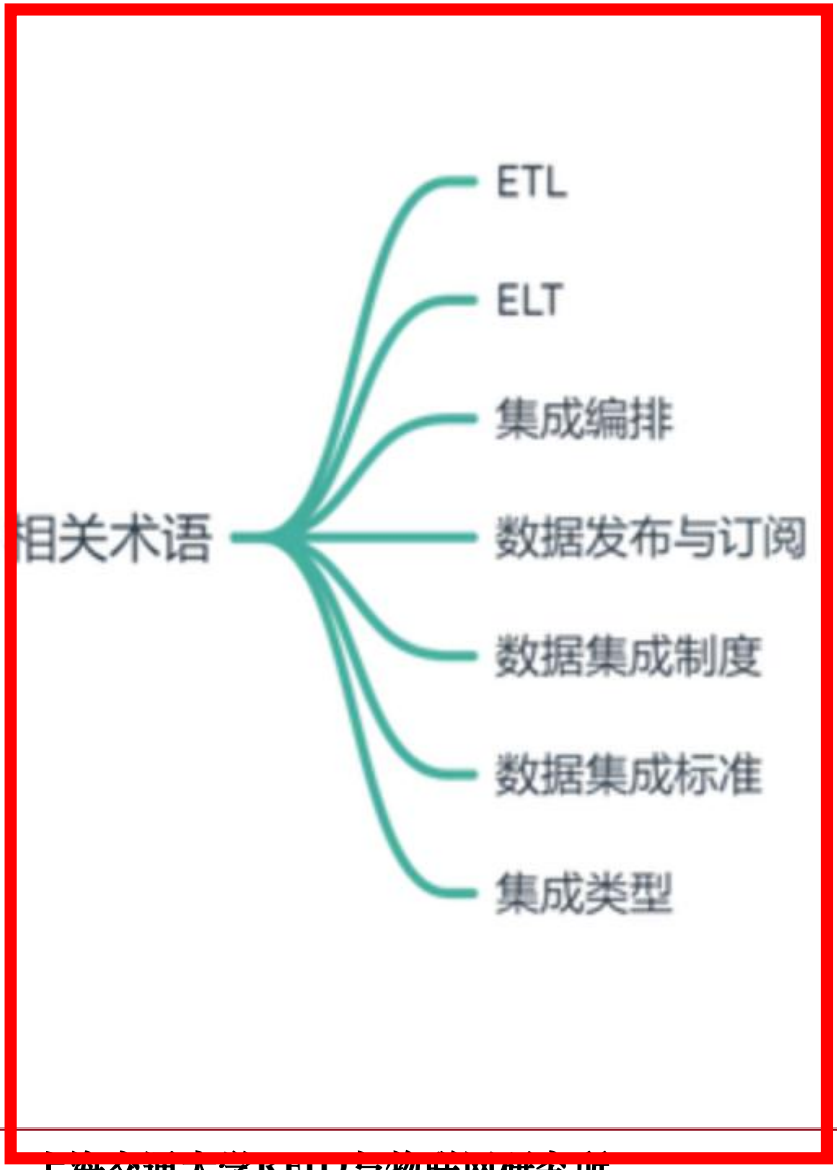
数据集成业界领先实践2024年



数据集成的知识体系


集成方式
批量集成
增量集成
准实时集成
实时集成
事件集成
同步集成
异步集成
流处理
复制
归档


集成架构
点对点架构
集中式架构
数据仓库架构
数据湖架构
服务导向架构
微服务架构
虚拟化架构
云化集成架构


相关术语
ETL
ELT
集成编排
数据发布与订阅
数据集成制度
数据集成标准
集成类型

3. 数据治理(2)数据预处理 提纲

- 概述
- 数据清洗（见数据预处理—数据清洗）
- 数据集成（见数据预处理—数据集成）
- 数据规约（见数据预处理—数据规约）
- 数据变换与数据离散化
- 小结

数据规约1: 维规约Dimensionality Reduction

- 维数灾难Curse of dimensionality
  - 当维数增长时,数据变得越来越稀疏
  - 在聚类和离群点分析中至关重要的点之间的密度和距离，变得不太有意义
  - 子空间的可能的组合将成倍增长
- 维规约Dimensionality reduction
  - 防止维数灾难
  - 有助于消除不相关的功能irrelevant features和降低噪音reduce noise
  - 减少数据挖掘过程中需要的时间和空间成本
  - 更容易可视化Allow easier visualization
- 维规约技术
  - 小波变换 Wavelet transforms
  - 主成分分析 Principal Component Analysis
  - 监督和非线性技术Supervised and nonlinear techniques (如属性选择 feature selection)

3. 数据治理(3)数据仓库与联机分析处理 提纲

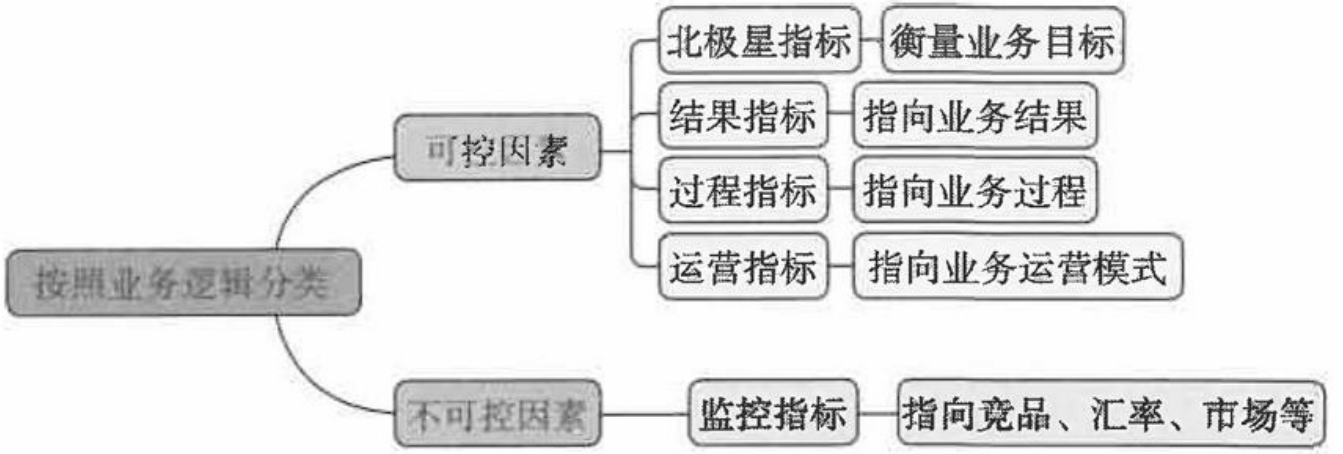
- 01-数据指标体系设计与应用实践
- 02-数据仓库
- 03-企业实践案例

数据指标体系设计与应用实践　提纲

- 数据指标
- 数据指标体系
- 数据指标体系构建的方法论
- 数据指标体系构建案例
- 数据埋点

按照业务逻辑分类

- 北极星指标
  - 北极星指标是在不同发展阶段指引业务发展的重要指标， 是业务目标的指向灯
- 结果指标
  - 对北极星指标进行业务目标的拆分， 可以得到各个指向业务结果的子目标， 称为结果指标
- 过程指标
  - 达成业务结果的过程中涉及的数据指标称为过程指标
- 运营指标
  - 不同业务运营模式下的业务指标也有所差异，有些指标并不能划归到结果指标或者过程指标中， 例如，商品库存是电商行业的重要指标， 它并不属于结果指标或过程指标， 但依然不可或缺， 可以将其归入运营指标
- 监控指标
  - 监控指标是业务外部不可控的因素， 涉及但不限于竞品、汇率、市场等方面



数据指标体系的 3个要素

- 数据指标体系拥有3个要素
  - —极星指标
  - —核心指标
  - —分析维度



- 北极星指标也称为唯一关键指标（One Metric That Matters, OMTM）， 是评价某一块业务现状最 重要的数据指标
  - —交易类产品的北极星指标是GMV
  - —社交类产品的北极星指标是活跃用户数量
- 通常情况下， 北极星指标是一个结果指标， 这个结果受到一系列过程的影响， 然而如果只考虑结果指标， 业务过程是无法得到监督和改进的。 将北极星指标拆解到不同的业务过程， 从而得到核心指标， 核心指标也称为过程指标， 是达成北极星指标必经的过程
- 无论是北极星指标还是核心指标， 都容易陷入平均数陷阱。增加分析维度可以将数据指标切分成若干块， 从而在一定程度上减少平均数陷阱的问题， 能够将业务的整体和局部分析得更加清晰

数据指标体系的构建流程

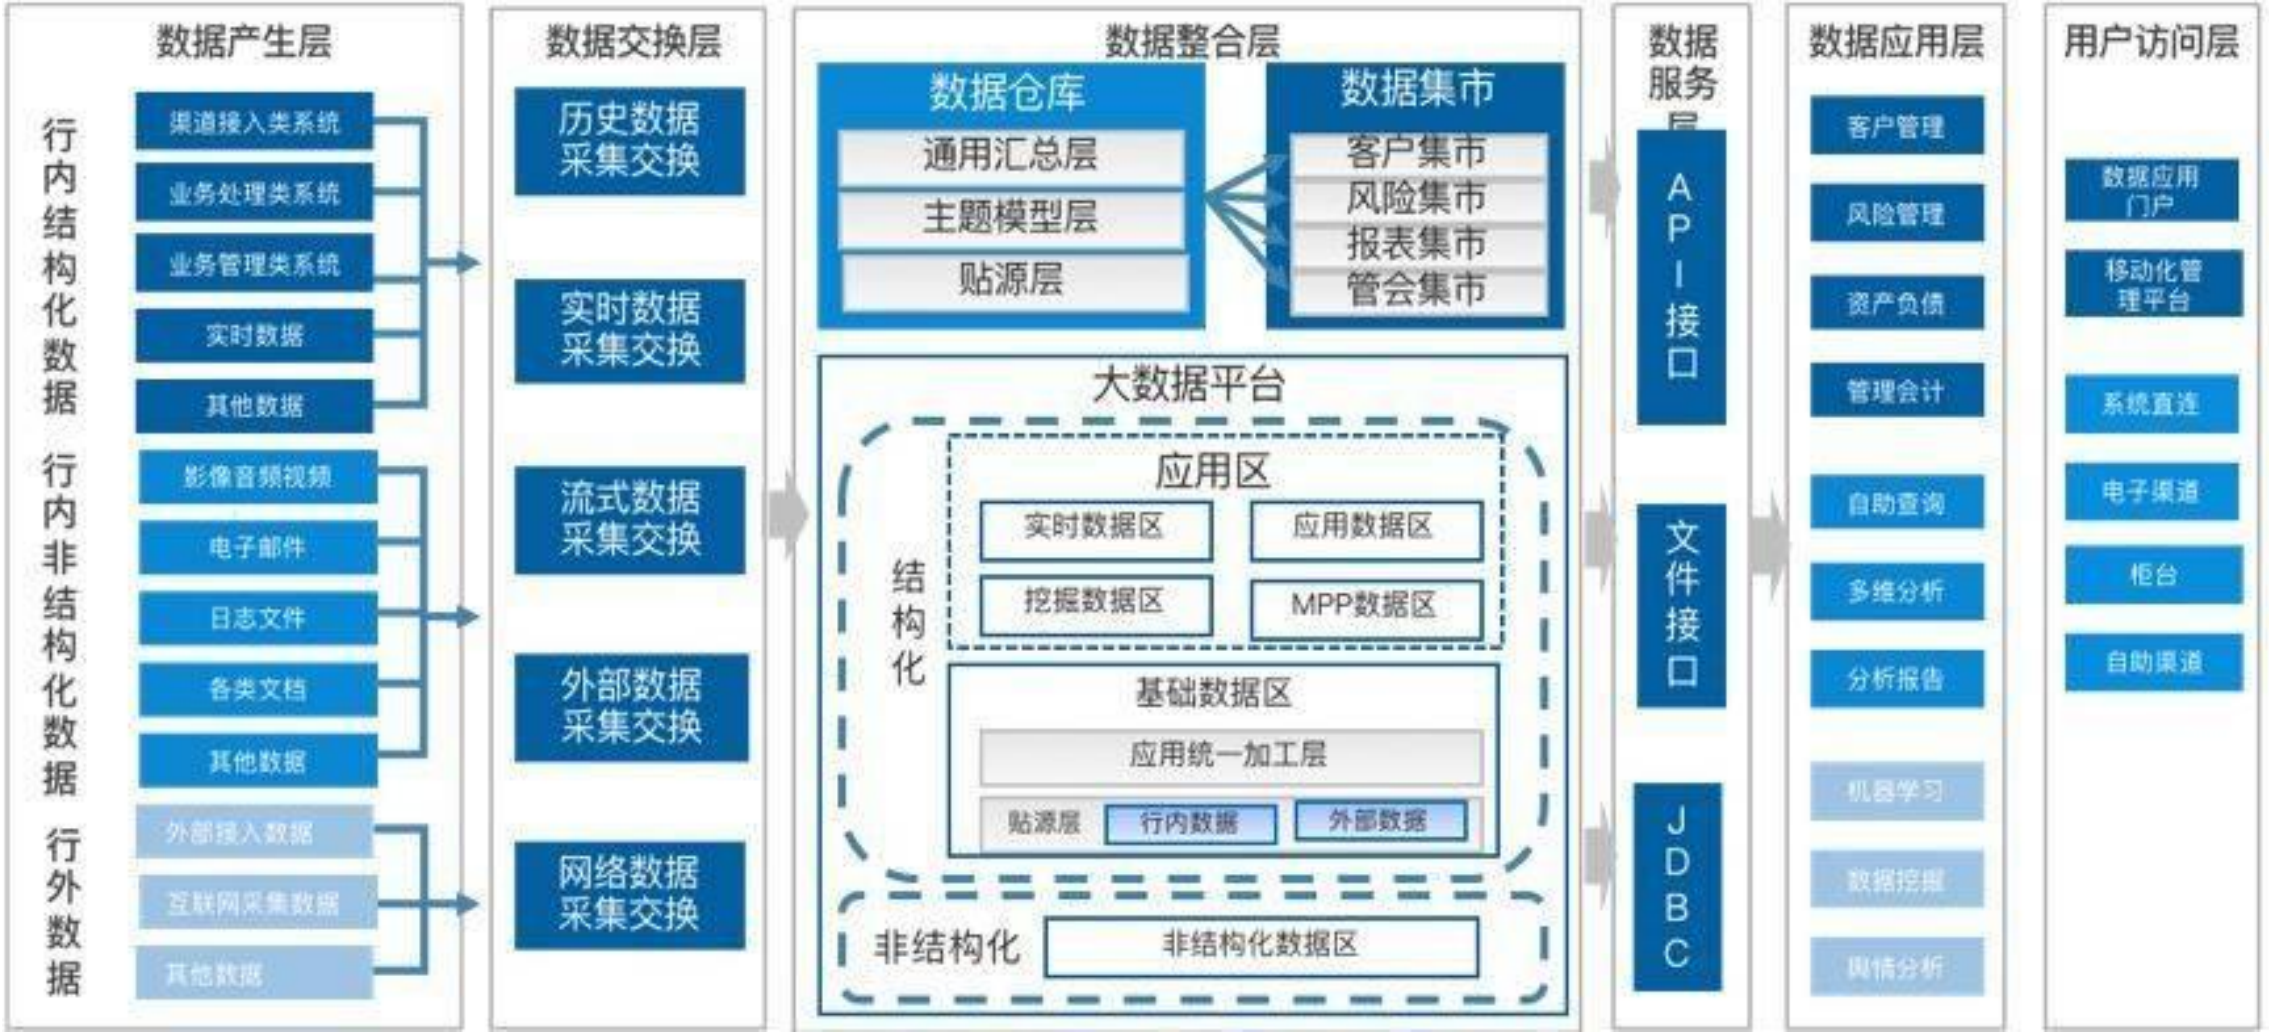
- 指标规划是构建数据指标体系的第一步， 相 当于构建整个数据指标体系构建流程的大纲， 该阶段的重要内容是构建业务目标和数据字典
- 有了规划好的指标后，要获取相关的数据就需要通过数据埋点进行采集， 在数据埋点过程中要明确字段类型、 上报时间、 上报方式
- 通过埋点采集到数据之后， 就可以选取多个合适的指标以及相应的维度在BI工具上对数据进行呈现， 以形成可以监控业务的数据指 标体系
- 有了基础的报表体系之后， 就能通过数据报表来反映业务趋势了， 当业务数据出现波动时， 数据分析师可以通过指标的上卷和下钻等功能快速排查业务问题



3. 数据治理(3)数据仓库与联机分析处理 提纲

- 01-数据指标体系设计与应用实践
- 02-数据仓库
- 03-企业实践案例

数据应用服务架构


数据产生层
行内结构化数据
渠道接入类系统
业务处理类系统
业务管理类系统
实时数据
其他数据
行内非结构化数据
影像音频视频
电子邮件
日志文件
各类文档
其他数据
行外数据
外部接入数据
互联网采集数据
其他数据
数据交换层
历史数据采集交换
实时数据采集交换
流式数据采集交换
外部数据采集交换
网络数据采集交换
数据整合层
数据仓库
通用汇总层
主题模型层
贴源层
数据集市
客户集市
风险集市
报表集市
管会集市
大数据平台
结构化
应用区
实时数据区
应用数据区
挖掘数据区
MPP数据区
基础数据区
应用统一加工层
贴源层
行内数据
外部数据
非结构化
非结构化数据区
数据服务层
API接口
文件接口
JDBC
数据应用层
客户管理
风险管理
资产负债
管理会计
自助查询
多维分析
分析报告
机器学习
数据挖掘
舆情分析
用户访问层
数据应用门户
移动化管理平台
系统直连
电子渠道
柜台
自助渠道

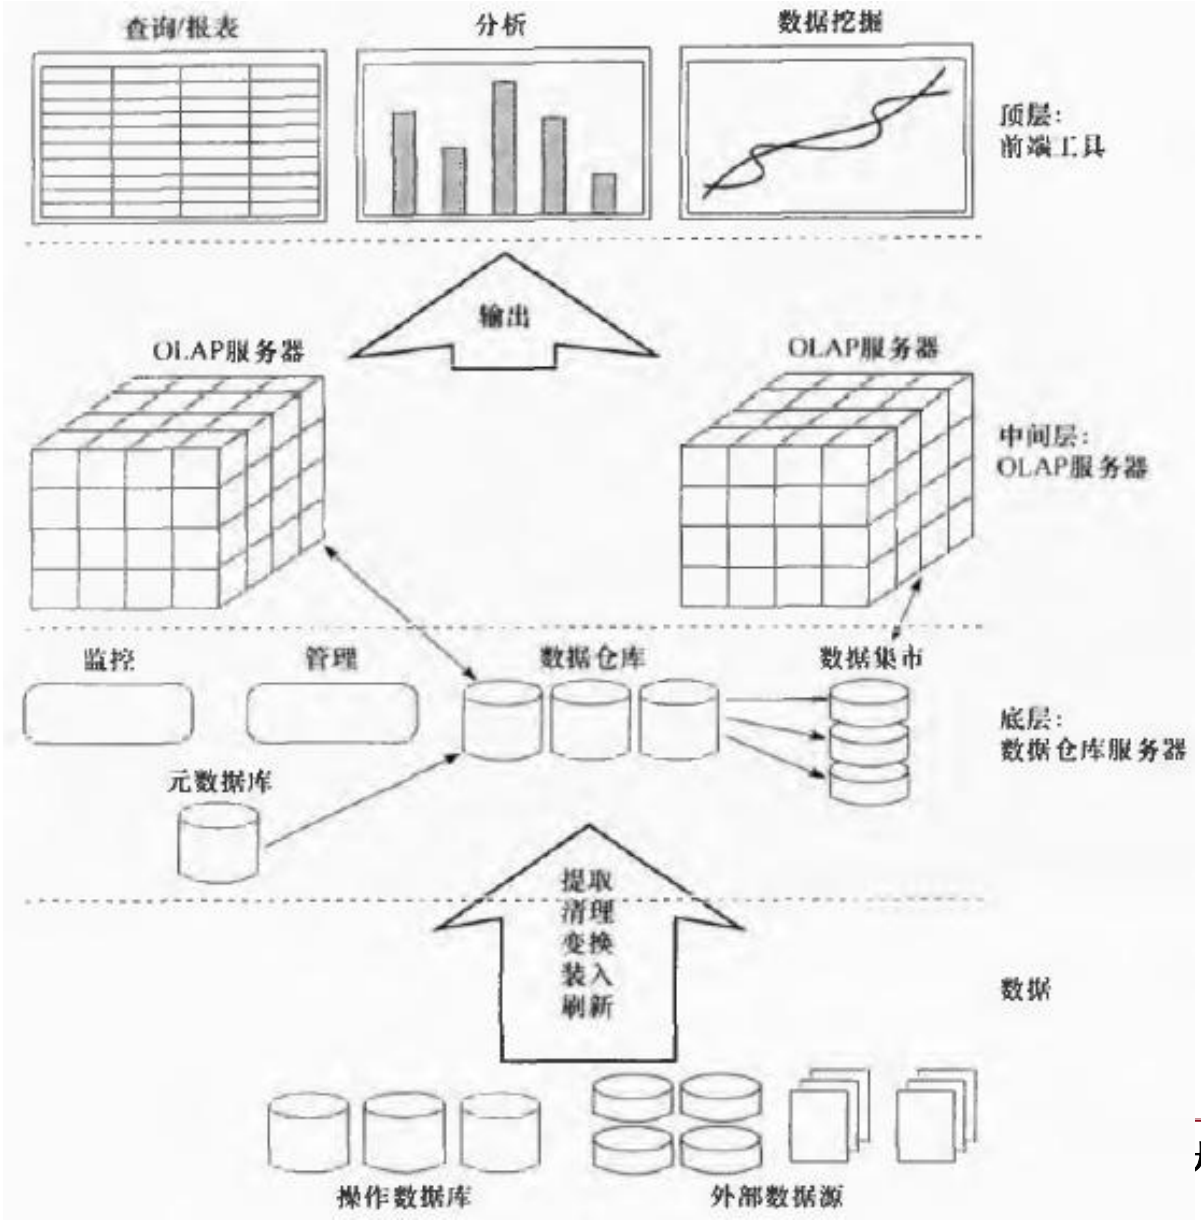
Chapter 5-02: Data Warehousing and On-line Analytical Processing

- Data Warehouse: Basic Concepts
  数据仓库：基本概念
- Data Cube and OLAP
  数据仓库建模：数据立方体与 OLAP
- Data Warehouse Design and Usage
  数据仓库的设计与使用
- Data Warehouse Implementation
  数据仓库的实现
- Summary

What is a Data Warehouse?

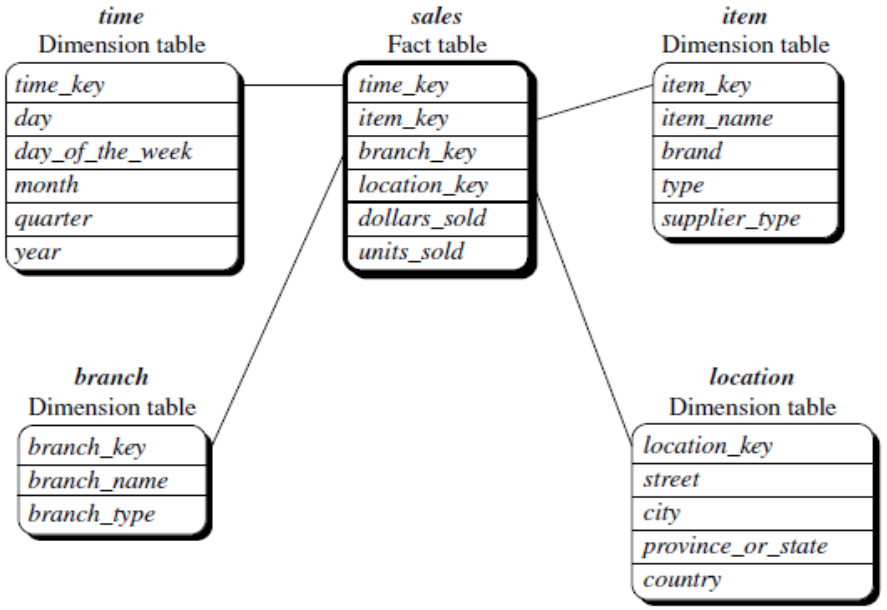
- Defined in many different ways, but not rigorously.
  - A decision support database that is maintained separately from the organization's operational database
  - 它是一个提供决策支持功能的数据库，它与公司的操作数据库分开维护
  - Support information processing by providing a solid platform of consolidated, historical data for analysis.
  - 为统一的历史数据分析提供坚实的平台，对信息处理提供支持
- "A data warehouse is a subject-oriented, integrated, time-variant, and nonvolatile collection of data in support of management's decision-making process."—W. H. Inmon
- "数据仓库是一个 面向主题的、集成的、随时间而变化的、不容易丢失的数据集合，支持管理部门的决策过程."— W. H. Inmon
- Data warehousing
  - The process of constructing and using data warehouses

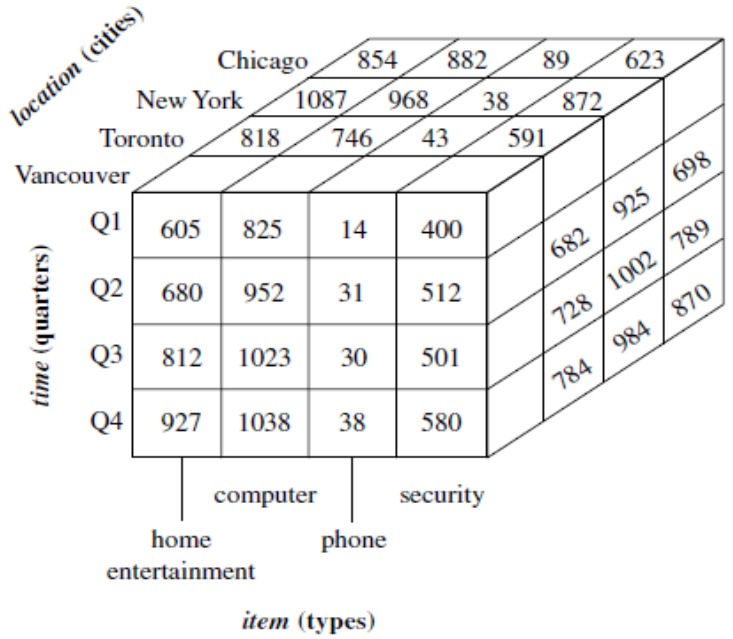
Data Warehouse: A Multi-Tiered Architecture
三层数据仓库架构



由表和电子数据表到数据立方体

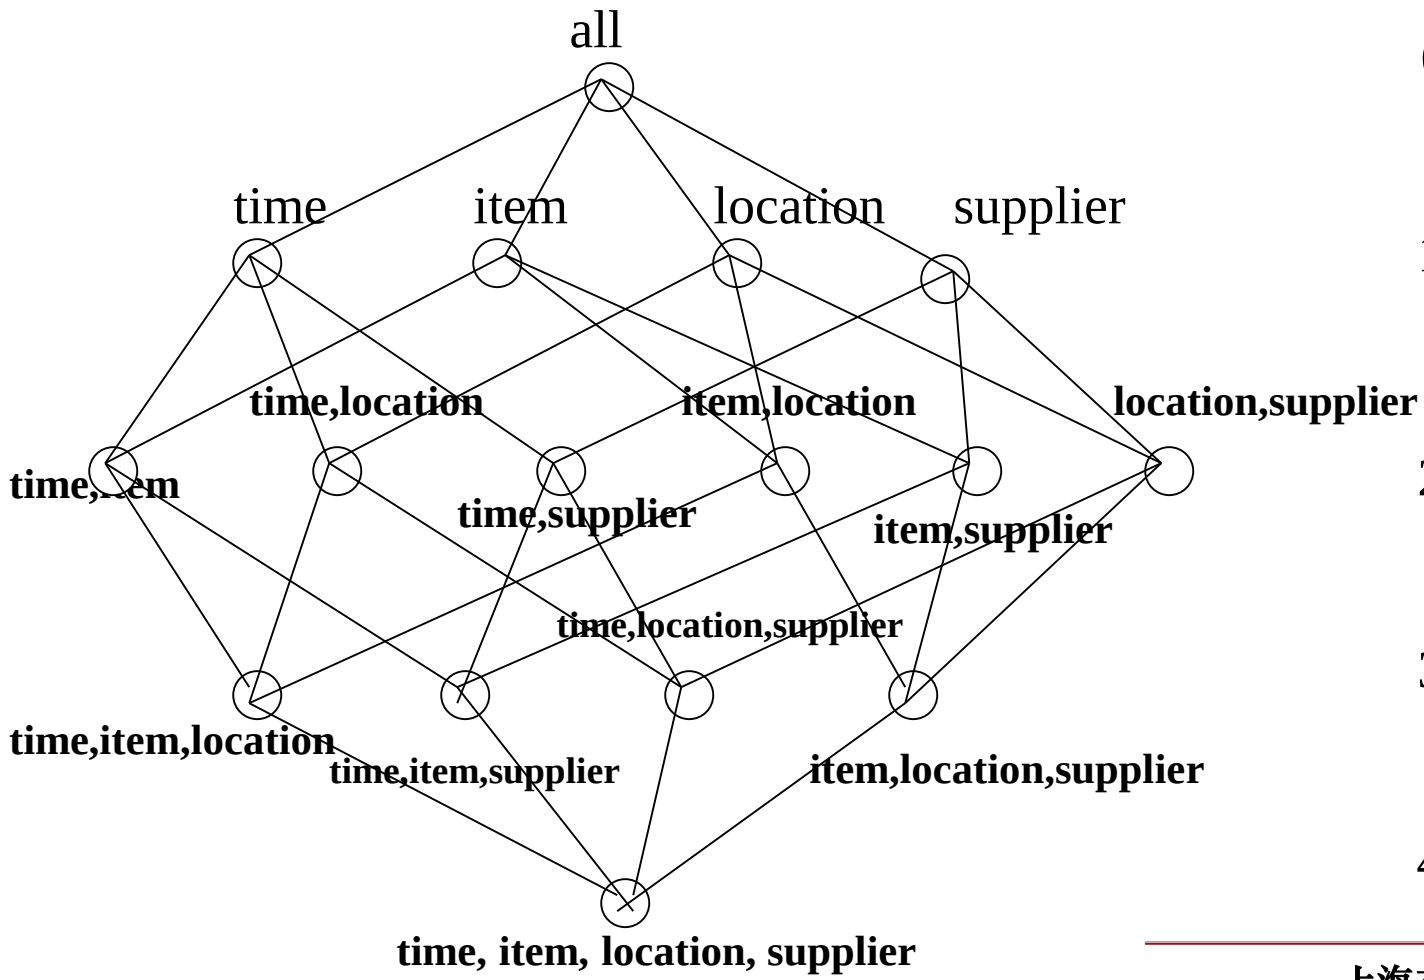
- 一个数据仓库建立在多维数据模型上，多维数据模型把数据看成数据立方体的形式
- 一个数据立方体，像sales，允许以多维对数据建模和观察
  - —维表，例如item的维表包含属性(item_name, brand, type)，time的维表包含属性(day, week, month, quarter, year)
  - —事实表包含度量(例如dollars_sold) 和每个相关维表的关键字





Cube: A Lattice of Cuboids
立方体：一个方体格

- 数据仓库语义中，一个n-D 底层方体称为**基本方体**；最高层的0-D方体，存放最高层的汇总，称为**顶点方体**；所有的方体格组成了**数据立方体**



0-D (*apex*) cuboid

1-D cuboids

2-D cuboids

3-D cuboids

4-D (*base*) cuboid

Star Schema

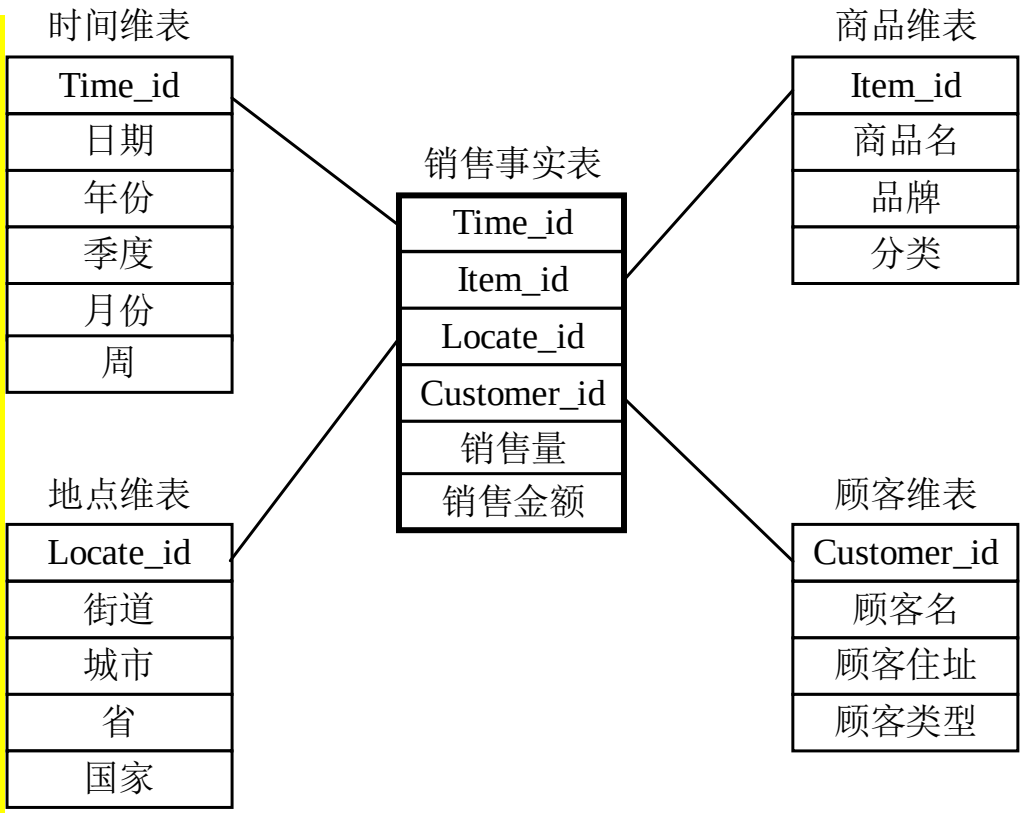
- 星形模式是由一个事实表和一组维表组成，每个维表都有一个维主键，所有维组合成事实表的主键，换言之，事实表主键的每个元素都是维表的外键。该模式的核心是事实表，通过事实表将各种不同的维表连接起来，各个维表都连接到中央事实表

一个“销售”数据仓库的星形模式

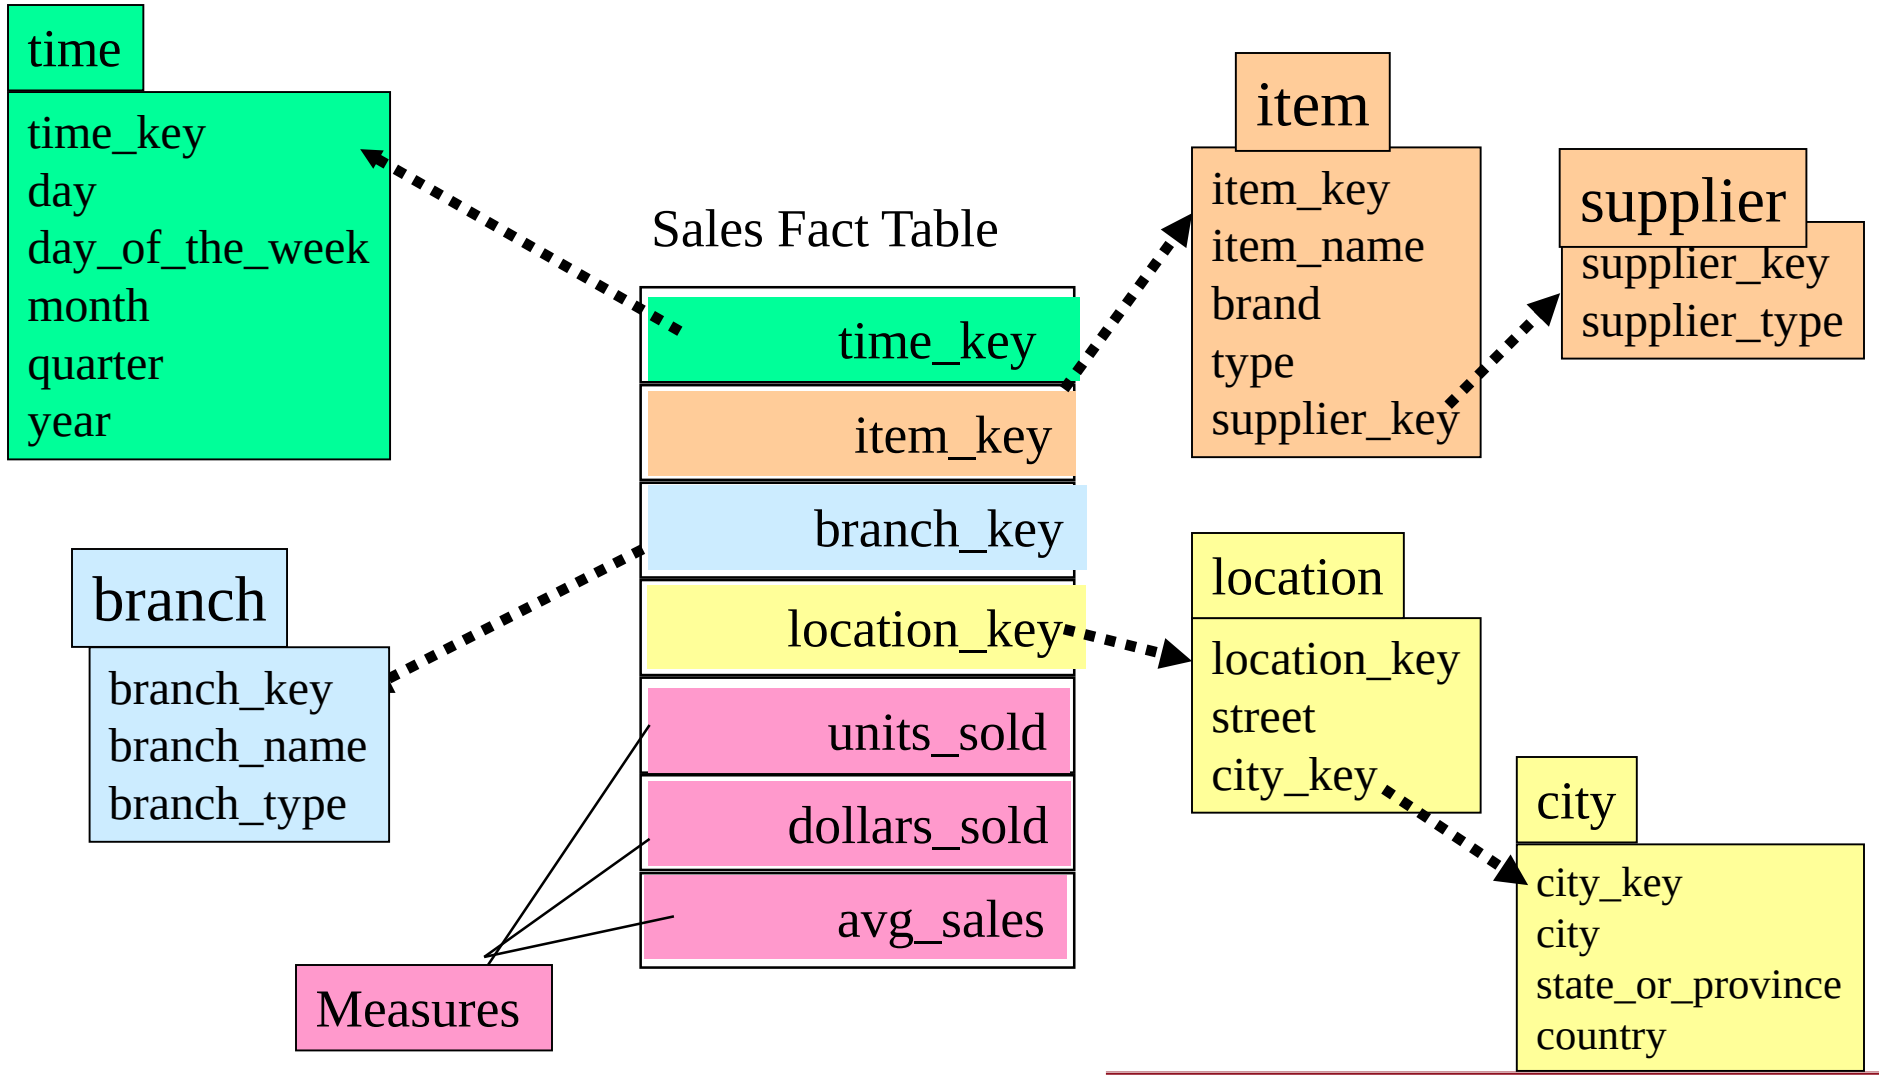
包含一个中心事实表“销售事实表”和4个维表：时间维表、销售商品维表、销售地点维表和顾客维表。在销售事实表中存储着四个维表的主键和两个度量“销售量”和“销售金额”

维表通常不使用业务数据库的关键字作为主键，而是对每个维表另外增加一个额外的字段作为主键来识别维表中的对象。在维表中新设定的键也称为代理键

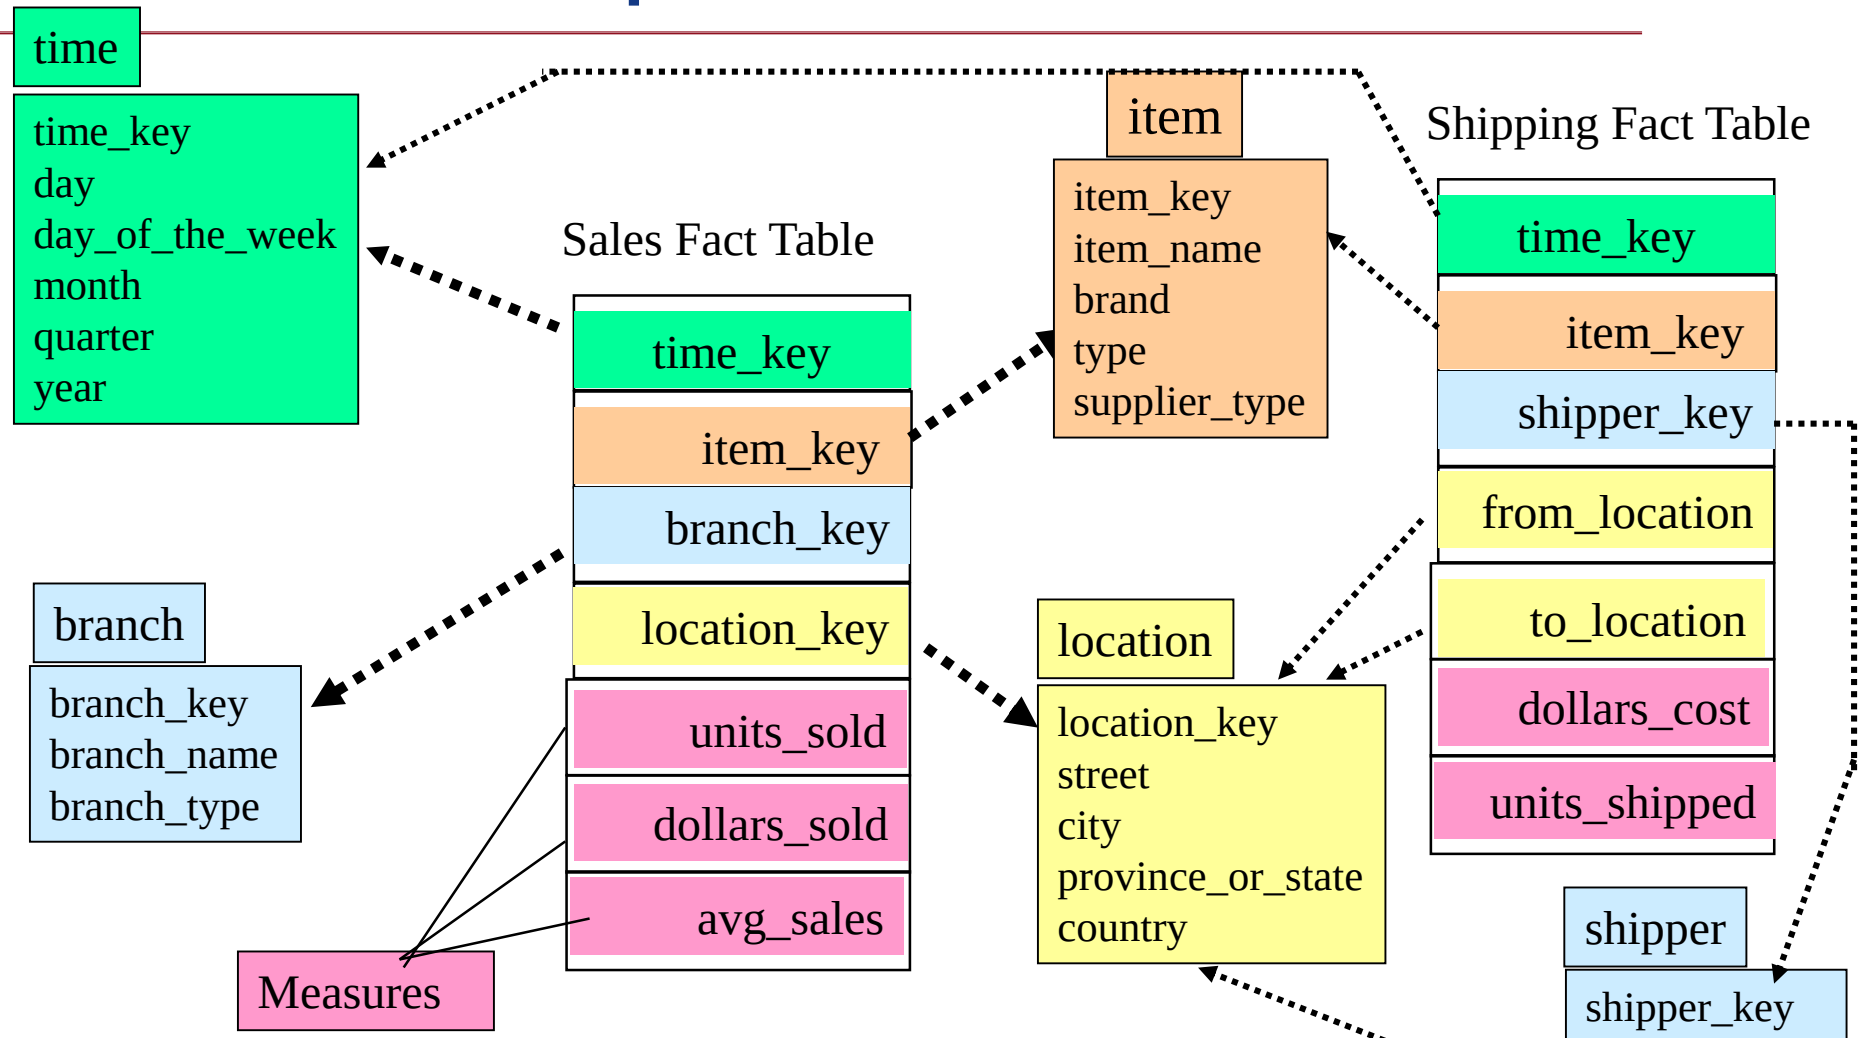
事实表中除度量外，其他字段都是维表或中间表（对于雪花模式）的关键字（外键）。如果事实相关的维很多，则事实表的字段个数也会比较多。事实表记录数量很多，应当尽量减小一条记录的长度，避免事实表过大而难于管理



Snowflake Schema



Example of Fact Constellation



多维数据模型上的OLAP操作

- **上卷(roll-up，也称上钻drill-up):汇总数据**
  - 通过一个维的概念分层向上攀升或者通过维规约在数据立方体上进行聚集
  - 当用维归约进行上卷时，一个或多个维由给定的数据立方体删除
- **下钻(drill-down)：上卷的逆操作**
  - 由不太详细的数据到更详细的数据，可以通过沿维的概念分层向下或引入新的维来实现 (为给定数据添加更多细节)
- **切片和切块(slice and dice)**
  - 切片操作在给定的数据立方体的一个维上进行选择，导致一个子立方体
  - 切块操作通过对两个或多个维进行选择，定义个子立方体

多维数据模型上的OLAP操作Cont.

- **转轴(pivot)**
  - —立方体的重定位，可视化，或将一个3维立方体转化为一个2维平面序列
  - —转轴是一种可视化操作，通过转动当前数据的视图来提供一个数据的替代表示
- **其他OLAP操作**
  - —钻过(drill_across)：执行涉及多个事实表的查询
  - —钻透(drill_through)：使用关系SQL机制，钻到数据立方体的底层，到后端关系表
  - —其他OLAP操作可能包括列出表中最高或最低的N项，以及计算移动平均值、增长率、利润、统计函数等等

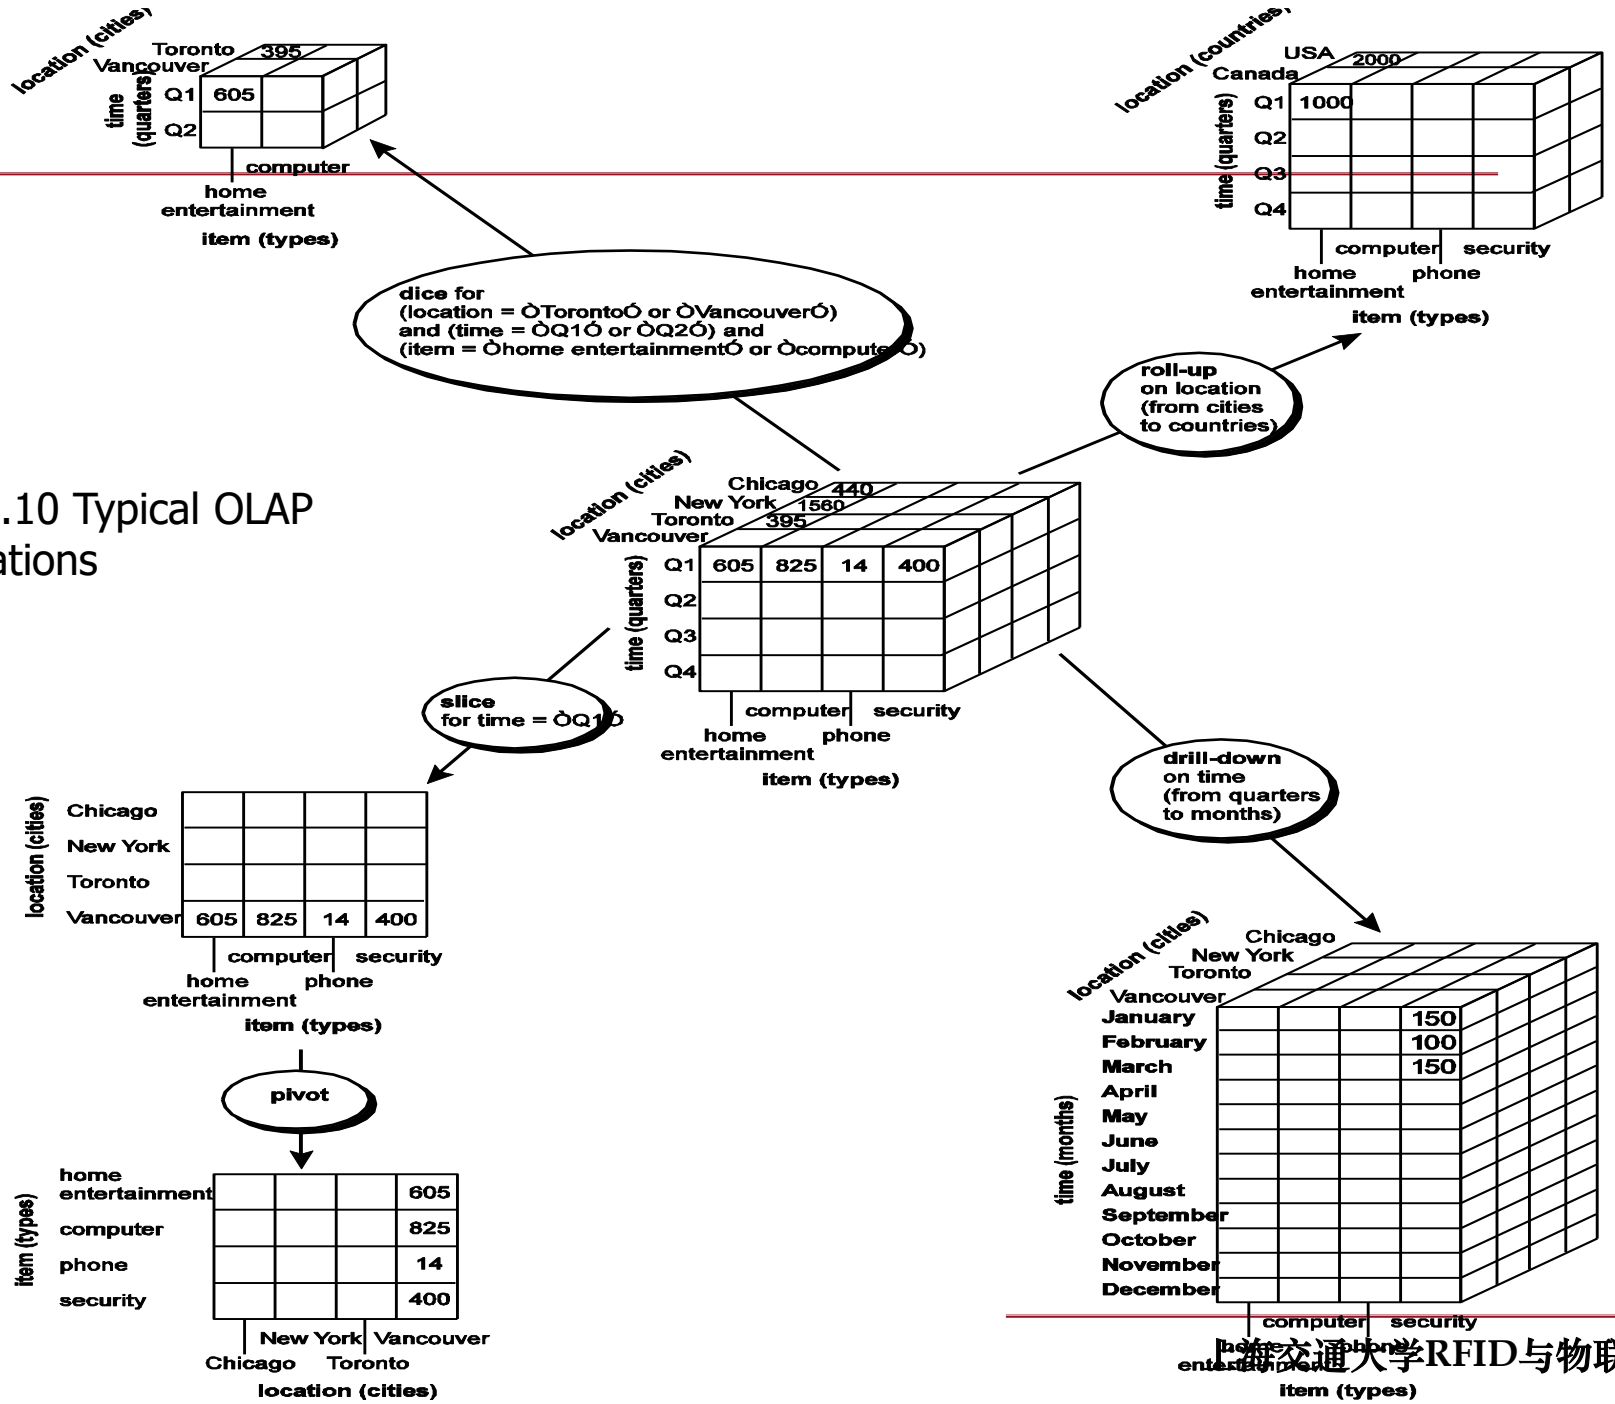
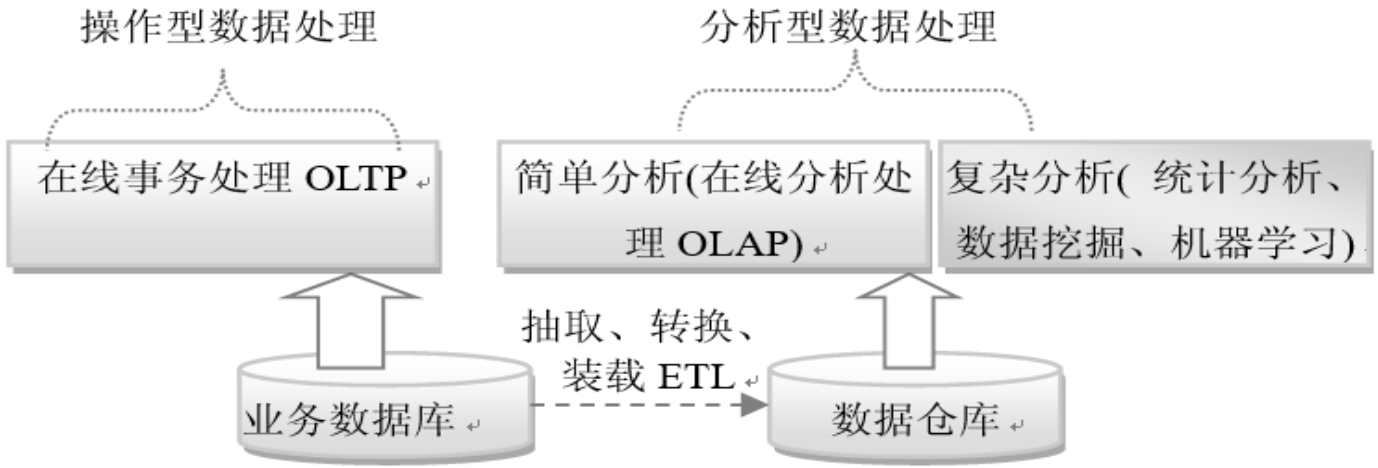
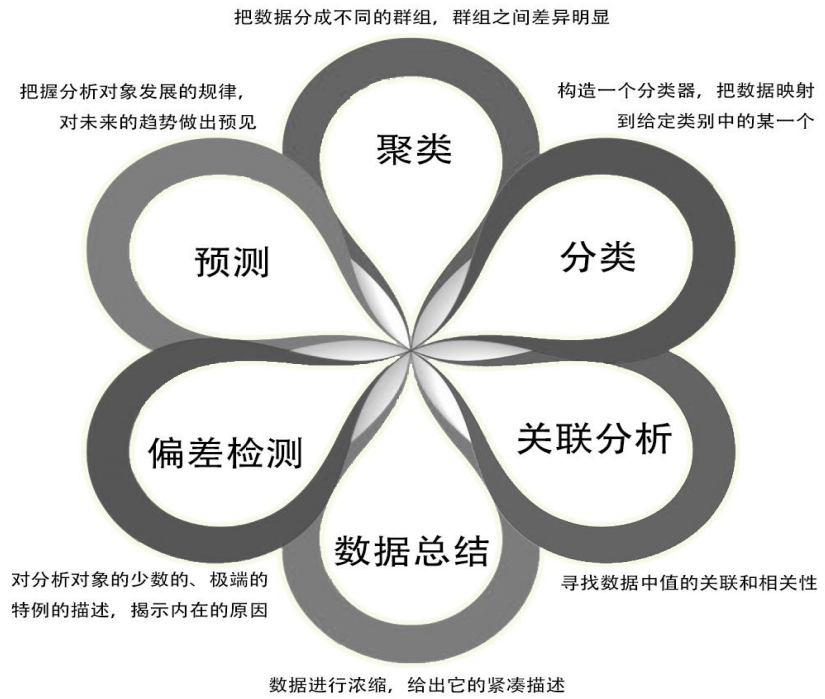


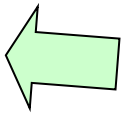
Fig. 3.10 Typical OLAP Operations

4.经典数据挖掘算法


操作型数据处理
分析型数据处理
在线事务处理 OLTP
简单分析(在线分析处理 OLAP)
复杂分析(统计分析、数据挖掘、机器学习)
抽取、转换、装载 ETL
业务数据库
数据仓库


把数据分成不同的群组，群组之间差异明显
聚类
把握分析对象发展的规律，对未来的趋势做出预见
预测
构造一个分类器，把数据映射到给定类别中的某一个
分类
偏差检测
对分析对象的少数的、极端的特例的描述，揭示内在的原因
关联分析
寻找数据中值的关联和相关性
数据总结
数据进行浓缩，给出它的紧凑描述

Chapter 6
挖掘频繁模式、关联和相关性基本概念和方法

- Apriori:候选生成和测试方法 
- 提升Apriori的效率
- FPGrowth:频繁模式增长的方法
- ECLAT:垂直数据格式下的频繁模式挖掘

Chapter 7 Classification 分类
7-1: Basic Concepts 基本概念

- Classification: Basic Concepts 基本概念
- Decision Tree Classifier *决策树分类器(ML课程)*
- Model Overfitting 模型的过拟合
- Model Selection 模型选择
- Model Evaluation 模型评估
- Presence of Hyper-parameters 超参数的使用
- Pitfalls of Model Selection and Evaluation 模型选择与评估中的陷阱
- Model Comparison 模型比较
- Techniques to Improve Classification Accuracy 提高分类准确率的技术

Chapter 7 Classification 分类
7-2：Adanced Methods 高级方法

- Rule-Based Classification 基于规则的分类
- Bayes Classification Methods *贝叶斯分类(ML课程)*
- Bayesian Belief Networks 贝叶斯信念网络
- Classification by Backpropagation *用后向传播分类(ML课程)*
- Support Vector Machines *支持向量机(ML课程)*
- Classification Using Frequent Patterns 使用频繁模式分类
- Lazy Learners 惰性学习法*(ML课程)*

  (or Learning from Your Neighbors) （或从近邻学习）
- Other Classification Methods 其他分类方法
- Ensemble Learning 集成分类法
- Additional Topics Regarding Classification 关于分类的其它问题

Chapter 7 Classification 分类
7-1: Basic Concepts 基本概念

- **Classification: Basic Concepts** **基本概念**
- Decision Tree Induction 决策树归纳
- Model Overfitting 模型的过拟合
- Model Selection 模型选择
- Model Evaluation 模型评估
- Presence of Hyper-parameters 超参数的使用
- Pitfalls of Model Selection and Evaluation 模型选择与评估中的陷阱
- Model Comparison 模型比较
- Techniques to Improve Classification Accuracy 提高分类准确率的技术

Decision Tree Classifier

— Overview

— Basic Algorithm to Build a Decision Tree

— Methods for Expressing Attribute Test Conditions

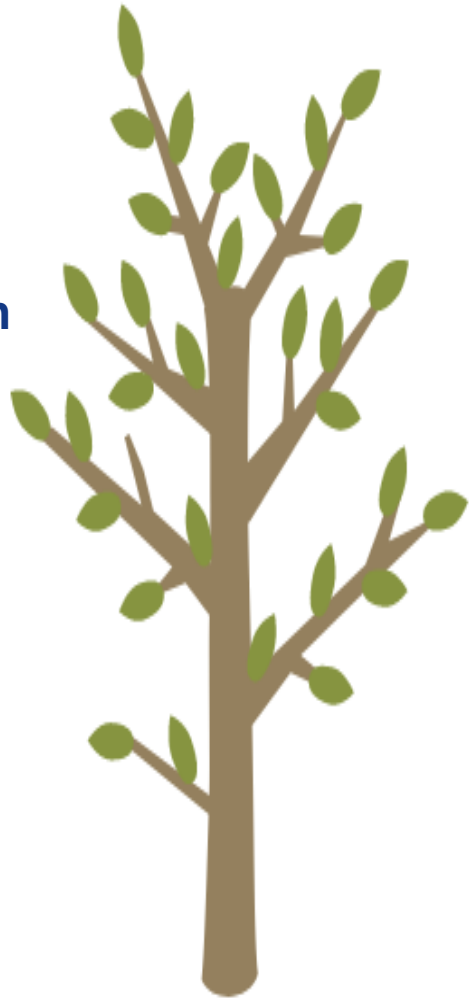
— Measures for Selecting an Attribute Test Condition

— Algorithm for Decision Tree Induction

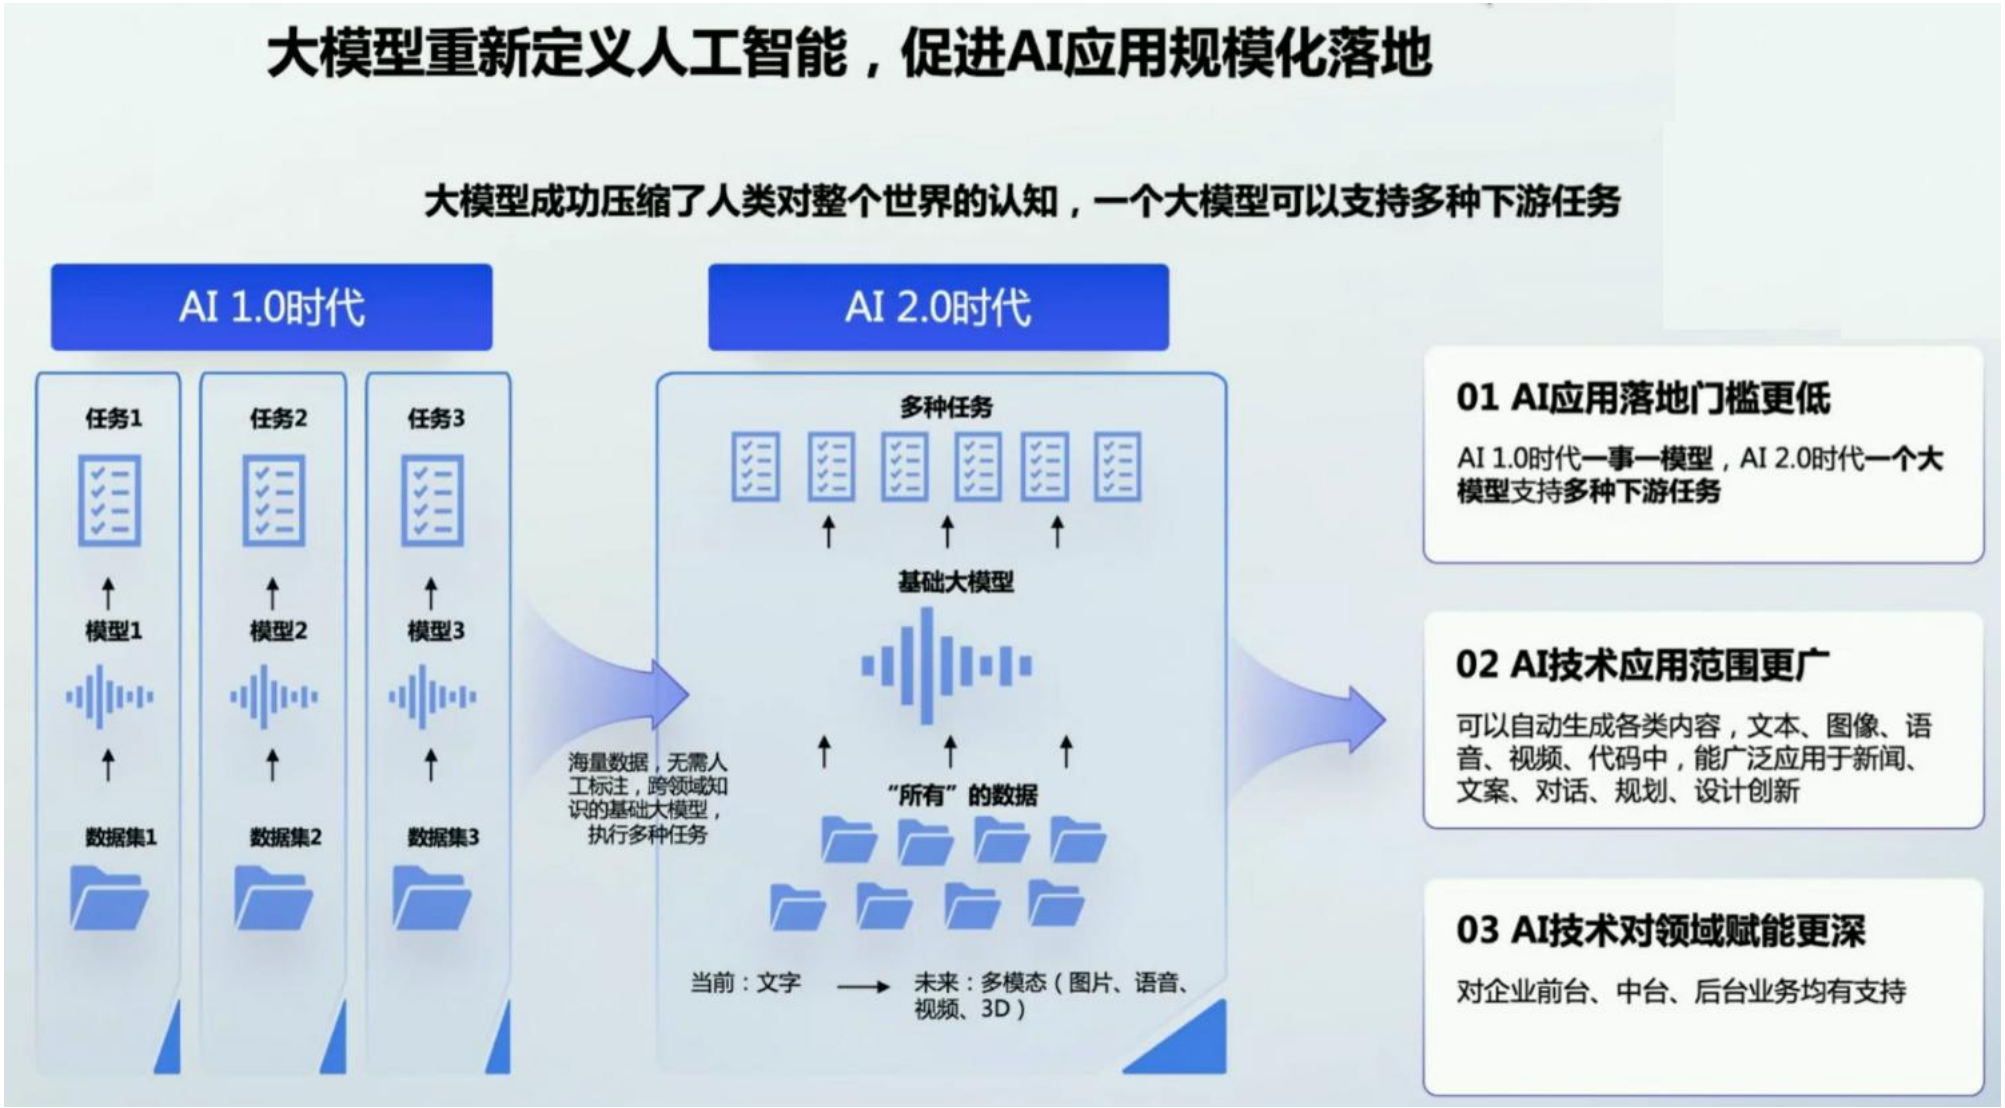
— Classic decision tree algorithm

— Example Application: Web Robot Detection

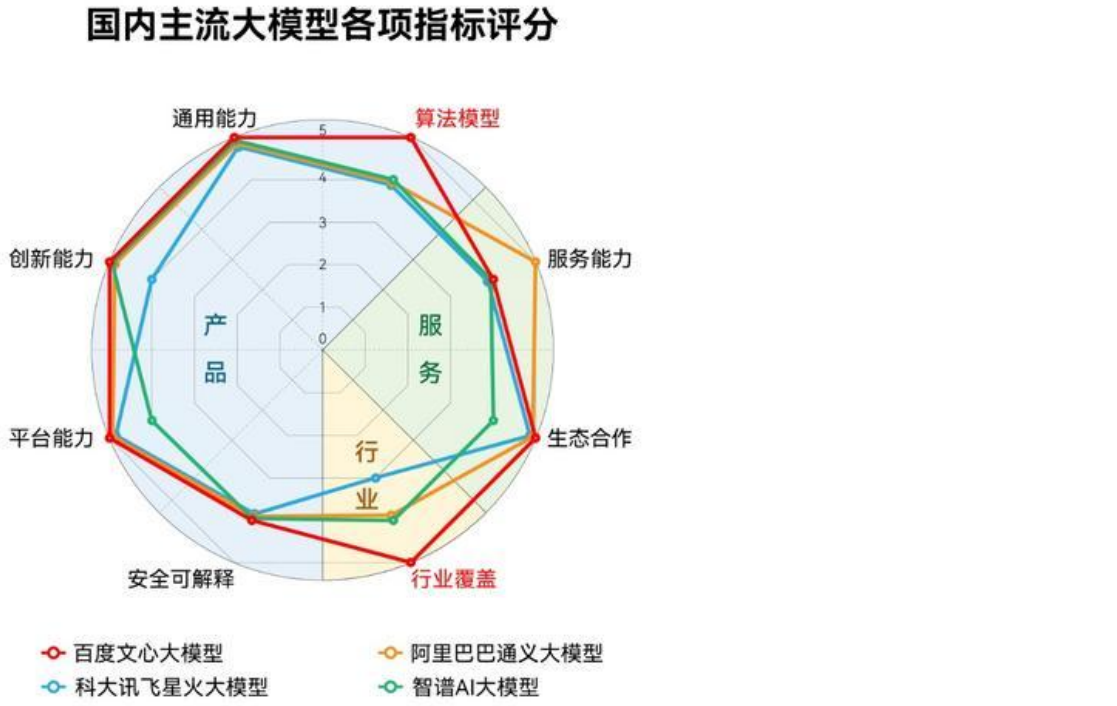
— Characteristics of Decision Tree Classifiers



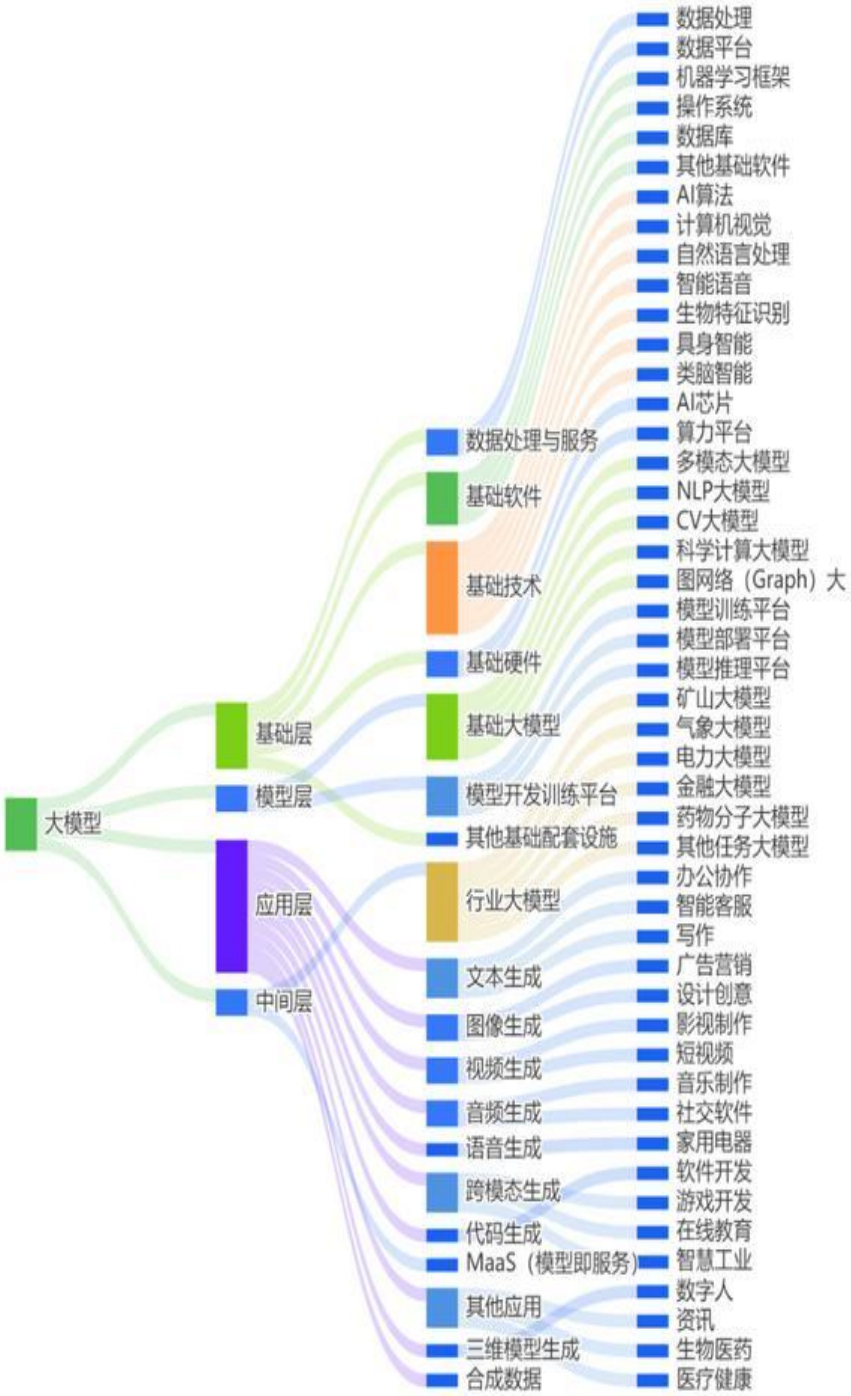
5.大模型与数据挖掘


大模型重新定义人工智能，促进AI应用规模化落地
大模型成功压缩了人类对整个世界的认知，一个大模型可以支持多种下游任务
AI 1.0时代
任务1
任务2
任务3
模型1
模型2
模型3
数据集1
数据集2
数据集3
海量数据，无需人工标注，跨领域知识的基础大模型，执行多种任务
AI 2.0时代
多种任务
基础大模型
“所有”的数据
当前：文字
未来：多模态（图片、语音、视频、3D）
01 AI应用落地门槛更低
AI 1.0时代一事一模型，AI 2.0时代一个大模型支持多种下游任务
02 AI技术应用范围更广
可以自动生成各类内容，文本、图像、语音、视频、代码中，能广泛应用于新闻、文案、对话、规划、设计创新
03 AI技术对领域赋能更深
对企业前台、中台、后台业务均有支持

“百模大战”



360智脑大模型 · 商汤 sensetime · 百川智能 BAICHUAN AI · 火山引擎 · 阿里云
智谱·AI · 百度智能云 · 腾讯混元 · 讯飞星火 · HUAWEI · MINIMAX
零一万物 01.AI · 面壁智能 MODELBEST · deepseek · 学而思 · 九章大模型 · Kimi



企业应用大模型主要有三种方式

- **第一种是构建基础大模型**
  - —只有少数企业会自建大模型，因为训练大模型的成本和技术壁垒都非常高
- **第二种是建立行业大模型**
  - —通常是了解行业know-how的企业，结合自身掌握的行业数据，用基础大模型精调出更贴合实际场景的行业大模型
- **第三种是在基础大模型和行业大模型之上，开发AI应用**
  - —这类企业其实是大多数，他们要思考的是：如何在这个大模型之上做好提示词工程，解决特定应用场景的问题。如何从模型效果、迭代速度、工具链这三大方面去选择一个好的大模型
  - —如果一个大模型不能解决行业问题，参数再多也没有意义

大模型微调

- 大模型微调的流程大致如下：
  1. 准备好你想要让大模型学习的数据集
  2. 选一个你觉得你的服务器显卡能跑得了的别人的大模型
  3. 通过LLaMA-Factory进行微调
  4. 导出微调后的模型，通过LLaMA-Factory或经典的ollama加载这个模型
  5. 开始聊天！

大模型概述

- 对于我们这类非专注于大模型训练开发领域的人而言，对大模型的认知只需要用一句话就能总结：用提示词让大模型帮我们解决问题
- 也就是说，经过了这么几个月有关大模型的研究，我至今依然认为一般人使用大模型不存在任何技术门槛，因为我们的目的是用大模型，而不是去设计、开发、训练大模型，这对我们而言不现实，也没必要，而用大模型只需要设计提示词
- 设计提示词？说白了就是问问题，这项技能别说我们了，连幼儿园的小朋友都会
- 而稍微有点技术门槛的，应该就是怎么去调API了，不过只需要有一丁点的编程经验，甚至零经验者跟随官方文档或视频教程也能轻松实现

大模型概述

- 再有点技术门槛的，那就是大模型微调了，只不过正如我之前所说，大模型微调只对参数量较高的大模型有意义，真正要用的时候还不如直接调用市面上已有的满血大模型的API比如DeepSeek-R1-671B，因此大模型微调对我们而言几乎不存在任何实际的应用方面的意义（也就是说，我不认为目前我们有能力微调某个模型使其性能能够超过满血DeepSeek-R1），不过要作为研究和学习大模型原理和应用或课程教学的一项内容我觉得是可以的
- 与大模型微调比较接近的还有一项技术，就是大模型RAG，不过RAG本质上是提示词工程，但是RAG最大的问题就是费用消耗比较高，比如你希望喂几本物联网相关的书籍给大模型，让大模型根据其中的知识进行回答，这样做是可行的，但是这意味着与你本次提问相关的知识都会被作为提示词输入给大模型，从而导致输入的Token数比较高，因此大部分时候直接采用官网的文件传输功能就行了

大模型概述

- 总而言之，最现实的、与我们最贴近的利用大模型帮助我们做项目、做研究的方式，就是**设计提示词、调用API**，而要实现这一点几乎不包含任何技术门槛，也并不是一件很高深、很复杂的事情

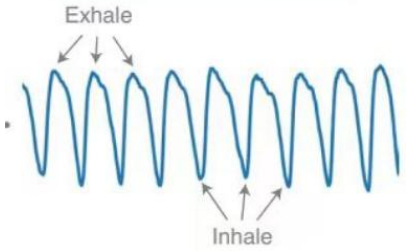
6.完整数据挖掘案例 超声波睡眠监测

Data source

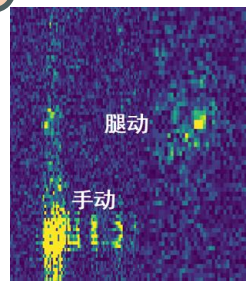


Acoustic Sensing

Inputs

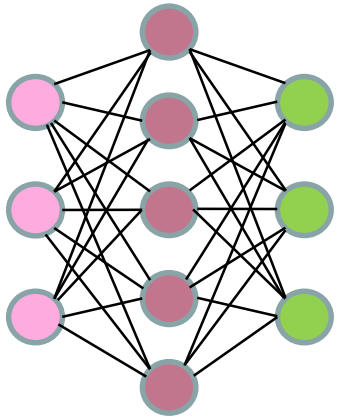


Breathing waves



Sleep movements

AI-based model



Outputs



Sleep Hypnogram Generation



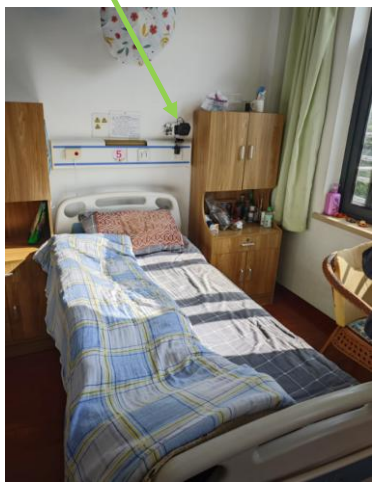
Sleep Apnea Detection

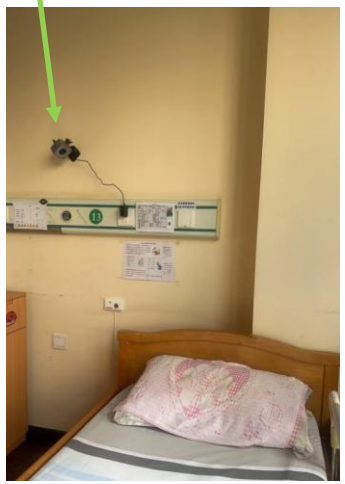
基于超声感知的无感睡眠监测系统

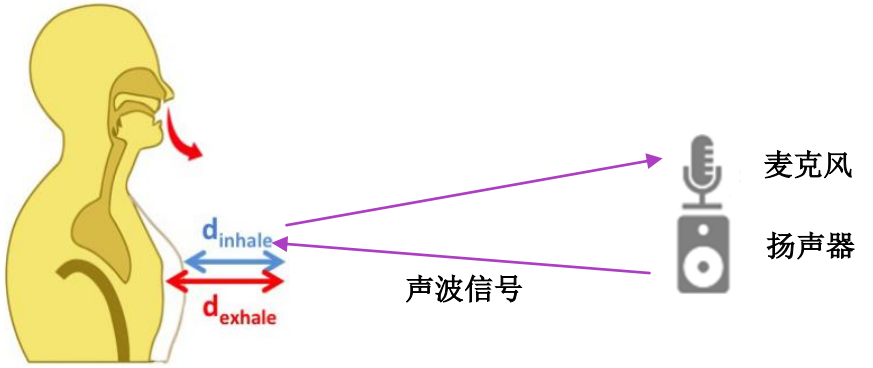
可部署于床头柜或墙上等靠近床的位置









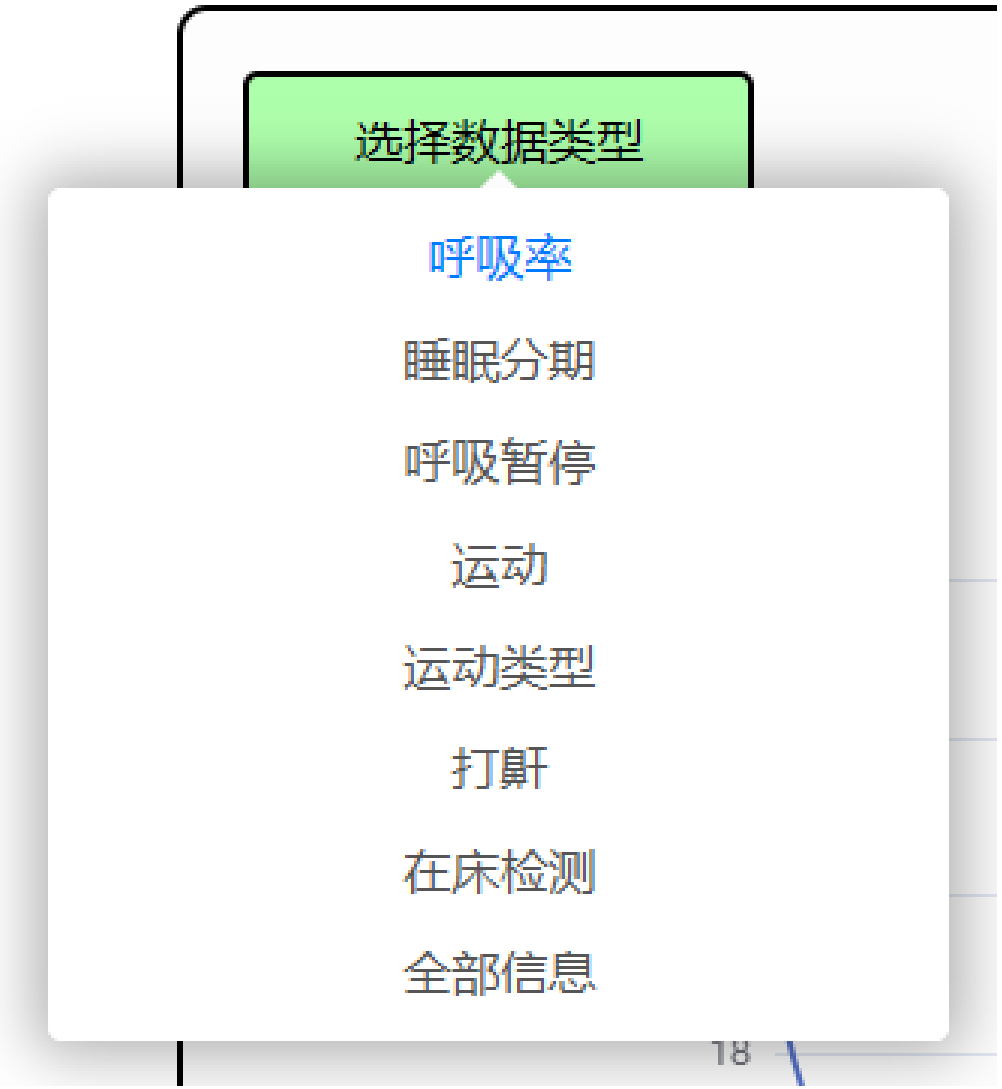




设备端收发超声信号（人耳不可听、无辐射、功率接近环境噪声）

端云协同实时智能感知（有效降低数据带宽和云端计算资源）

睡眠监测指标

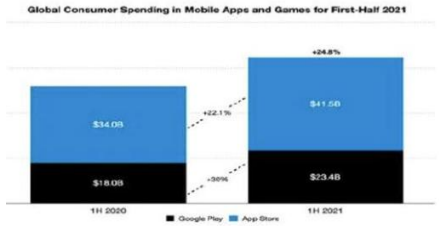


- 系统共监测7个睡眠指标。
  1. 呼吸率
  2. 睡眠分期
  3. 呼吸暂停
  4. 运动幅度
  5. 运动类型
  6. 打鼾
  7. 在床检测
- 每项指标都对应一至两张不同类型的图表，并且图表下方提供了由大模型生成的健康建议供用户参考。

7. 大数据数据挖掘

推荐系统

- 推荐系统是商业化最成功的AI技术



2021H1, App Store收入415亿美元, Google Play 234亿美元；

来源网上公开数据



阿里广告收入超1745亿人民币（2019年）





Google广告收入2297亿美元（2018年）

字节跳动：~1800亿人民币 (2020)

推荐系统

- 推荐系统的类型
  - —Content-based RS （基于内容）
  - —Collaborative filtering （协同过滤）

社会网络和社区发现

- **社会网络**（Social Network）
  - —是由许多节点以及节点间关系构成的一个网络结构
  - —节点通常是指个人或组织（又称社团）
  - —社会网络代表各种社会关系，产生的网络结构往往是非常复杂的



上海交通大学RFID与物联网研究所
上海东川路800号交通大学软件大楼5313室

王东
18621365573
wangdong@sjtu.edu.cn

张谦
13816047437
qwert3472@sjtu.edu.cn