

Data Mining and Big data anlysis

数据挖掘及大数据分析

Chapter3：Getting to Know Your Data

认识数据

王东、张谦、丁玥

上海交通大学软件学院RFID与物联网实验室

2025年春季

Types of Data Sets 数据类型

- **Record**
  - Relational records
  - Data matrix, e.g., numerical matrix crosstabs
  - Document data: text documents: term-frequency vector
  - Transaction data
- **Graph and network**
  - World Wide Web
  - Social or information networks
  - Molecular Structures
- **Ordered**
  - Video data: sequence of images
  - Temporal data: time-series
  - Sequential Data: transaction sequences
  - Genetic sequence data
- **Spatial, image and multimedia**
  - Spatial data: maps
  - Image data
  - Video data

Chapter 3. 认识数据

- Data Objects and Attribute Types
  数据对象与属性类型
- Basic Statistical Descriptions of Data
  数据的基本统计描述
- Data Visualization
  数据可视化
- Measuring Data Similarity and Dissimilarity
  度量数据的相似性和相异性
- Summary 小结

Data Objects 数据对象

- 数据集由数据对象组成
- 一个 **数据对象** 代表一个实体
  - 销售数据库：顾客、商品、销售……
  - 医疗数据库：患者、治疗方法……
  - 大学的数据库：学生、教授、课程……
- 有些人把它称之为……
  - 样本(Samples)、实例(instances)、数据点(data points)、对象(objects)……
- 数据对象通常用 **属性** 描述
- 数据对象通常放在数据库中——
  - 数据库的行 -> 数据对象
  - 数据库的列 -> 属性

Attributes

Objects

Tid	Refund	Marital Status	Taxable Income	Cheat
1	Yes	Single	125K	No
2	No	Married	100K	No
3	No	Single	70K	No
4	Yes	Married	120K	No
5	No	Divorced	95K	Yes
6	No	Married	60K	No
7	Yes	Divorced	220K	No
8	No	Single	85K	Yes
9	No	Married	75K	No
10	No	Single	90K	Yes

Attributes 属性

数据挖掘
数据库

数据仓库

机器学习

统计学

- **属性(Attribute)：**
  也被成为维(Dimensions)、特征(Features)、变量(Variables)
- **通常是一个 数据字段， 表示数据对象的一个特征**
  - E.g., 顾客_ID, 姓名，地址
- **描述对象的一组属性称为属性向量（或特征向量）**

- **属性类型：由属性可能具有的值的集合决定**
  - **标称属性(Nominal)**
  - **二元属性(Binary)** → **定性的**
  - **序数属性(Ordinal)**
  - **数值属性(Numeric)： 量化的** → **定量的**
    - **区间标度(Interval-scaled)**
    - **比率标度(Ratio-scaled)**

Attributes 属性 1 —— 标称属性(Nominal)

- 标称属性(Nominal)：定性的
  - —“分类的”，代表某种类别、编码或状态
  - —不必具有有意义的序
  - —“枚举的”
    - 头发颜色 = {黑色、棕色、淡黄色、红色、赤褐色、灰色…}
    - 婚姻状况 = {单身、已婚、离异、丧偶}
- 可以用 数 表示这些符号或名称
  - —对于Hair_color，指定代码0表示黑色，1表示棕色…
  - —Customer_ID，它的可能值可以都是数值
- 但它不是定量的，并不打算定量地使用这些数，数学运算没有意义
  - —与从一个年龄值（年龄是数值属性）减去另一个不同，从一个顾客号减去另一个顾客号毫无意义
  - —均值、中位数等都没有意义

Attributes 属性 2 —— 二元属性(Binary)

- 二元属性(Binary)：定性的
  - —它是一种标称属性，只有两个类别或状态（0或1）
  - —又称为布尔属性，如果两种状态对应于True和False

- 分类
  - —对称二元属性（两种状态具有同等价值且携有 相同权重 ）
    - 性别 = {男、女}
  - —非对称二元属性（两种状态具有不同权重）
    - 医疗化验结果 = {阴性(常见)、阳性}
    - 通常对重要的结果用1编码

Attributes 属性 3 —— 序数属性(Ordinal)

- 序数属性(Ordinal)：定性的
  - —可能的值之间具有有意义的序或秩评定（先后次序）
    - 可乐杯大小 = {大、中、小}
    - 成绩 = {A+、A、A-、B+、B、B-、……}
  - —对于记录不能客观度量的主观质量评估，序数属性是有用的。因此，序数属性通常用于等级评定调查
  - —序数属性也可以通过把数值量的值域划分成有限个有序类别，把数值属性离散化而得到
  - —相继值之间的差是未知的

- 可以用 众数（集合中最频繁出现的值） 和 中位数（有序数据值的中间值）来表示中心趋势，但不能定义均值

Attributes 属性 4 —— 数值属性(Numeric)

- 数值属性(Numeric)：**定量**的

  用整数或数值表示

- 分类

  — 区间标度属性(Interval)

  - E.g., 温度、日期等
  - 用 **相等的**单位尺度度量
    - 摄氏温度是水在标准大气压下沸点温度与冰点温度之差的1/100
  - 值有序，允许比较和定量评估值之间的 **差**
    - 温度：假设有许多天的室外温度值，其中每天是一个对象。把这些值排序，则得到这些对象关于温度的秩评定。可以量化不同值之间的差，例如，温度20度比5度高出15度。
    - 日历日期：2002年与2010年相差8年。
  - 由于没有真正的“零”，不允许 **比率**
    - 可以计算温度差，但是不能说一个温度值是另一个的倍数
  - 可以计算 中位数、众数、均值

Attributes 属性 4 —— 数值属性(Numeric) Cont.

—比率标度属性(Interval)

- 具有固有的零点的数值属性
- 可以计算比率
  - E.g., 开氏温度(绝对零点)、货币量
- 可以计算中位数、众数、均值

Attributes 属性 5 —— 离散 v.s. 连续

- **离散属性(Discrete Attributes)**
  - 具有有限或无限个可数个值
  - E.g., 可乐杯大小、顾客_ID、邮政编码
  - 有时，可以用 **整数值** 表示

  - 注意！ 二元属性 是离散属性的一个特殊情况

- **连续属性(Continuous Attributes)**
  - 通常用实数表示

    E.g., 温度、高度、重量……
  - 连续属性一般用 **浮点** 表示

Chapter 2. 认识数据

- Data Objects and Attribute Types
  数据对象与属性类型
- Basic Statistical Descriptions of Data
  数据的基本统计描述
- Data Visualization
  数据可视化
- Measuring Data Similarity and Dissimilarity
  度量数据的相似性和相异性
- Summary 小结

Basic Statistical Descriptions of Data

数据的基本统计描述

- **为什么要描述？**

  —— 为了更好地理解数据的 **中心趋势度量、散布情况**

- **中心趋势度量**
  - 最大值、最小值、均值、中位数、众数、中列数……

- **数据散布**
  - 评估数值数据散布或发散的度量
  - 包括极差、分位数、四分位数、百分位数和四分位数极差等

- **可视化地审视数据——描述的图形显示**
  - 一元分布：分位数图、直方图等
  - 二元分布：散点图

Basic Statistical Descriptions of Data

数据的基本统计描述 之 **中心趋势度量**

- 我们有某个属性X（例如：salary 工资），共分析N个对象

  令 X1, X2, X3, X4, …, Xn 为 “属性X的N个 **观测值**”

  又称 观测 或 (X的)数据集

- 如果标出Salary的这些观测值**(以千美元为单位按递增次序)**

  30，31，47，50，52， 52，56，60，63，70，70，110

- 那么大部分值将落在何处？

  —这反应数据的中心趋势

  —包括：均值(Mean)、中位数(Median)、众数(Mode)

Basic Statistical Descriptions of Data

数据的基本统计描述 之 中心趋势度量 Cont.

- 中心趋势的思想

  包括：**均值(Mean)**、中位数(Median)、众数(Mode)

- **(算数)均值（Mean）：**

$$\bar{x} = \frac{1}{n}\sum_{i=1}^{n} x_i$$

— **加权平均**

$$\bar{x} = \frac{\sum_{i=1}^{n} w_i x_i}{\sum_{i=1}^{n} w_i}$$

— **截尾均值(trimmed mean)**

- 为了抵消少数极端值的影响，丢弃高低极端值后的均值

Basic Statistical Descriptions of Data

数据的基本统计描述 之 **中位数**

- 中心趋势的思想

  包括：均值(Mean)、**中位数(Median)**、众数(Mode)

- **中位数（ Median ）：**
  - 对于倾斜（非对称）数据，数据中心的更好度量
  - 有序数据值的 **中间值**
  - 假设给定某属性X的N个有序观测值

    如果N是奇数，

    中位数即该有序集的中间值

    如果N是偶数，

    中位数不唯一

age	*frequency*
1–5	200
6–15	450
16–20	300
21–50	1500
51–80	700
81–110	44

Median interval → 21–50

- **中位数近似值计算：**

  (根据中位数区间)

$$median = L_1 + (\frac{n/2 - (\sum freq)_l}{freq_{median}})width$$

教材更正

Basic Statistical Descriptions of Data

数据的基本统计描述 之 **众数**

- 中心趋势的思想

  包括：均值(Mean)、中位数(Median)、**众数(Mode)**

- **众数（ Mode ）：**
  - 集合中出现 **最频繁** 的值
  - 可以对定性和定量属性确定众数
  - 可能最高频率对应多个不同值，具有 **多个众数（单峰、多峰）**

- **对于适度倾斜(非对称)的单峰数值数据，众数近似值计算：**

$$mean - mode = 3 \times (mean - median)$$

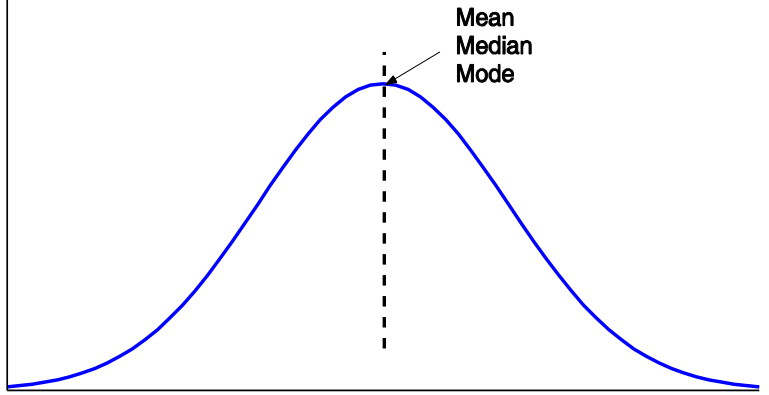
- **中列数**
  - **数据集的最大和最小值的平均值**

Basic Statistical Descriptions of Data

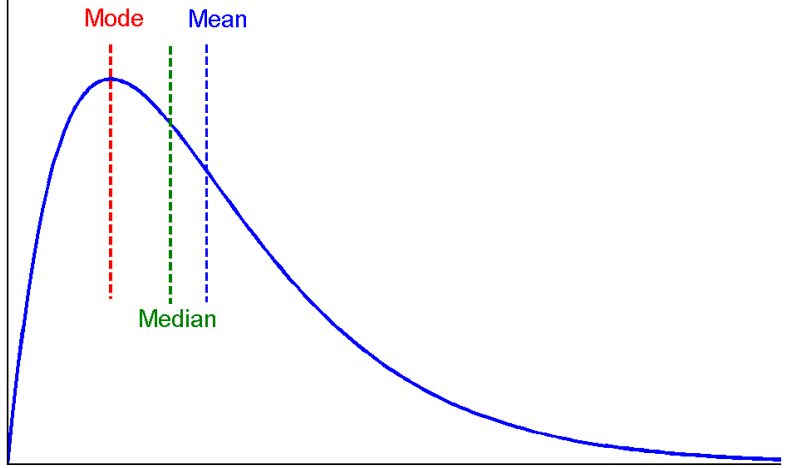
数据的基本统计描述 之 众数 Cont.

- 均值、中位数、众数：

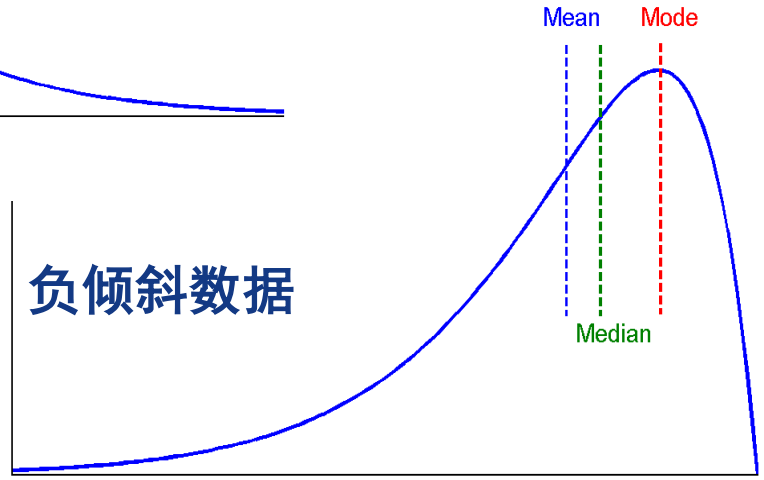
对称数据：均值、中位数、众数一致



正倾斜数据



负倾斜数据



Basic Statistical Descriptions of Data

数据的基本统计描述

- 为什么要描述？

  —— 为了更好地理解数据的 **中心趋势度量、散布情况**

- 中心趋势度量

  — 最大值、最小值、均值、中位数、众数、中列数……

- **数据散布**

  — 评估数值数据散布或发散的度量

  — 包括极差、分位数、四分位数、百分位数和四分位数极差等

- 可视化地审视数据——描述的图形显示

  — 一元分布：分位数图、直方图等

  — 二元分布：散点图

数据散布

— 评估数值数据散布或发散的度量

- 极差
- 分位数
- 四分位数
- 百分位数
- 四分位数极差

— 方差和标准差

Basic Statistical Descriptions of Data

数据的基本统计描述 之 **数据散布**

- 极差、五数概括（基于四分位数）、中间四分位数极差

—极差（range）

- 数据集的最大值和最小值之差

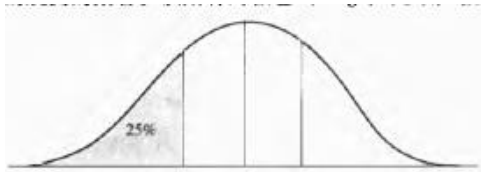
—分位数（quantile）是取自数据分布的每隔一定间隔上的点，把数据划分成基本上大小相等的连贯集合

- 2-分位数是一个数据点，它把数据分布划分成高低两半，分位数对应于中位数。
- 4-分位数是3 个数据点，它们把数据分布划分成4 个相等的部分，使得每部分表示数据分布的四分之一。
- 100-分位数把数据分布划分成100个大小相等的连贯集

—中间四分位数极差*(IQR)*： $IQR = Q_3 - Q_1$

- 四分位数：Q1 (25th percentile), Q3 (75th percentile)

—孤立点：挑出落在至少高于第三个四分位数或低于第一个四分位数 *1.5*×*IQR*处的值

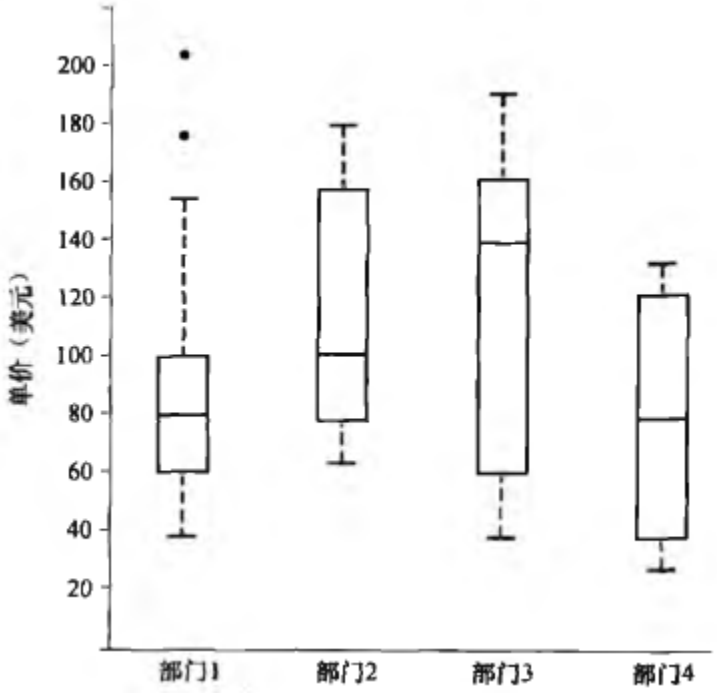


Basic Statistical Descriptions of Data

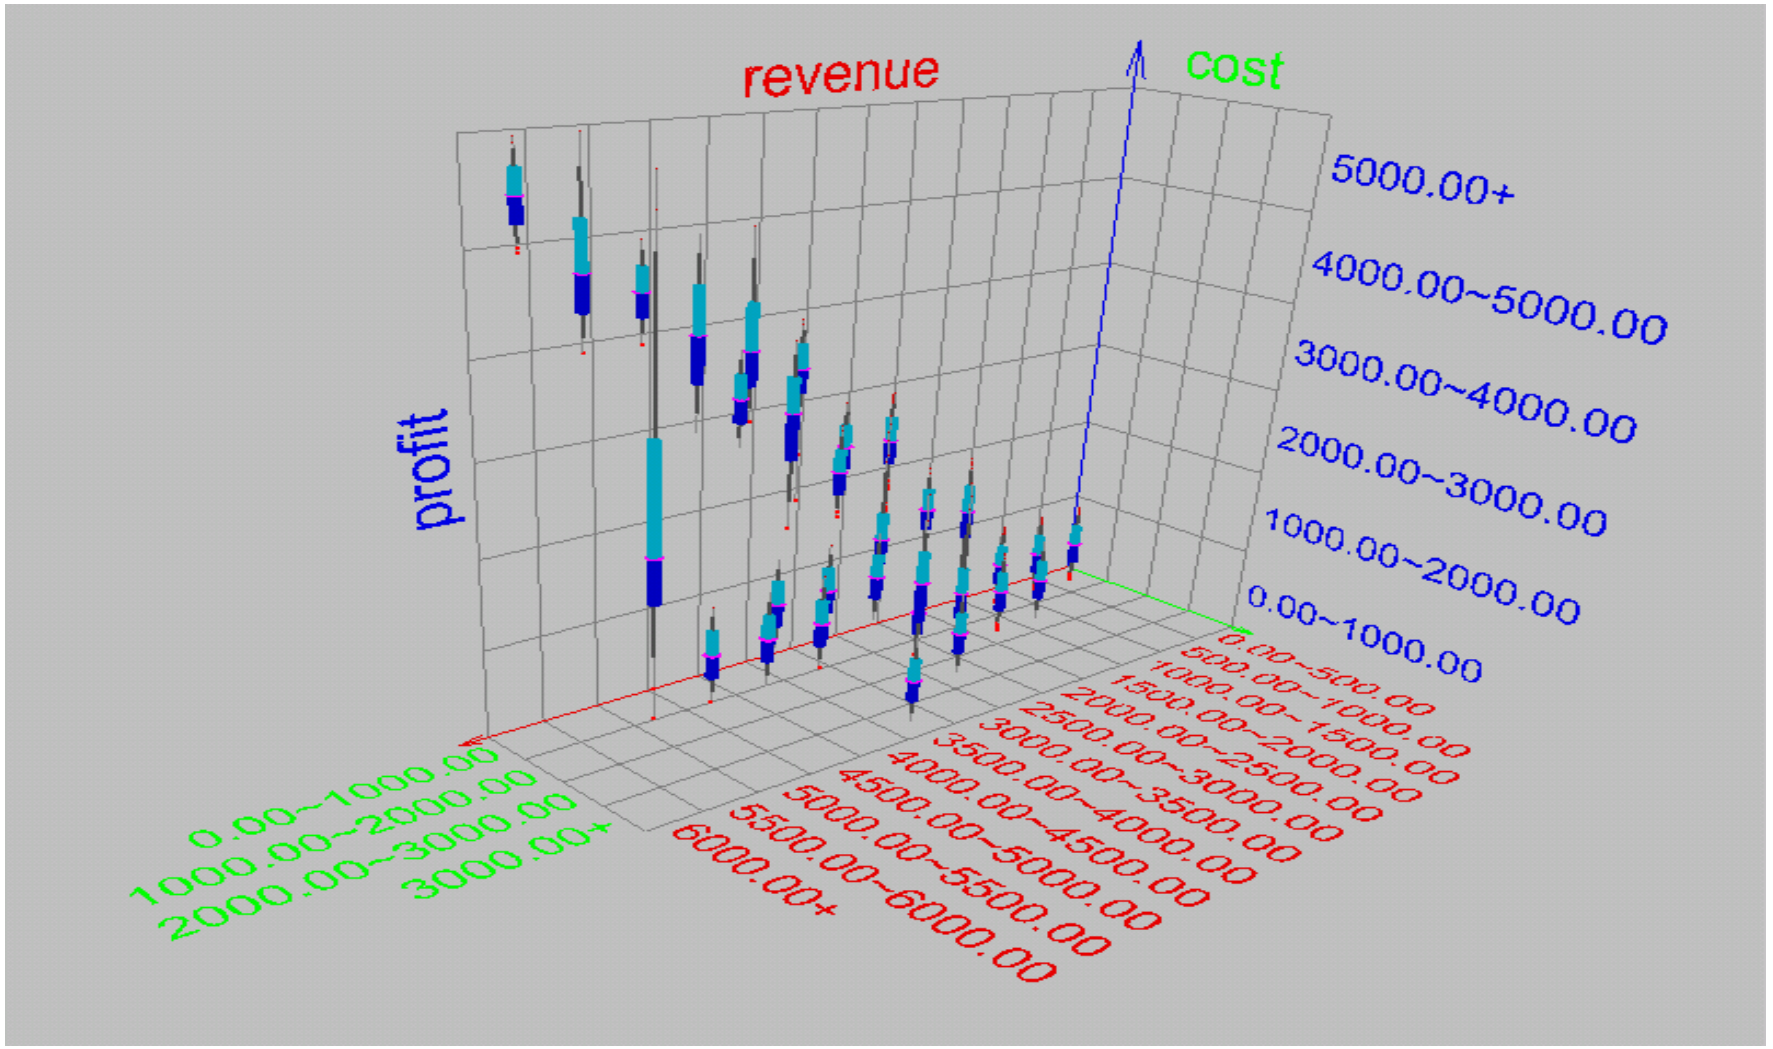
数据的基本统计描述 之 **数据散布**

- 五数概括（five-number summary）
  - —*min, Q_1, Median, Q_3, max*
  - — 用来比较若干个可比较的数据集

- 盒图
  - —数据分布的一种直观表示
  - —端点在四分位数上，使得盒图的长度是*IQR*
  - —中位数*M*用盒内的线标记
  - —胡须延伸到最大最小观测值
    - **胡须在出现在四分位数的1.5xIOQ 之内的最极编的观测值处终止**
    - **剩下的情况个别地绘出（175和202均大于IOQ的1.5倍，这里IOQ-40）**
  - —该盒图为在给定时间段在AllElectronics的4个分店销售的商品单价的盒图
    - 分店1
      - 中位数$80
      - Q1: $60
      - Q3: $100



使用盒图的数据离散的可视化描述



Basic Statistical Descriptions of Data

数据的基本统计描述 之 **数据散布 Cont.**

- **数据散布**
  - 评估数值数据散布或发散的度量
  - 包括：极差、分位数、**方差和标准差**

- **包括：**
  - **方差：**

$$\sigma^2 = \frac{1}{N}\sum_{i=1}^{n}(x_i - \mu)^2 = \frac{1}{N}\sum_{i=1}^{n} x_i^{\ 2} - \mu^2$$

  - **标准差：**方差 σ^2 的平方根

Basic Statistical Descriptions of Data

数据的基本统计描述

- **为什么要描述？**

  —— 为了更好地理解数据的 **中心趋势度量、散布情况**

- **中心趋势度量**
  - 最大值、最小值、均值、中位数、众数、中列数……

- **数据散布**
  - 评估数值数据散布或发散的度量
  - 包括极差、分位数、四分位数、百分位数和四分位数极差等

- **可视化地审视数据——描述的图形显示**
  - 一元分布：分位数图、直方图等
  - 二元分布：散点图

Basic Statistical Descriptions of Data

数据的基本统计描述 之 **图形显示**

- **图形显示包括：**

一元分布

— **分位数图：**

每个观测值 x_i 与一个百分数 f_i 配对，之处大约 f_i*100% 的数据小于值 x_i

— **分位数-分位数图(q-q图)：**

观测取自两个部门的观测集分布

判断从一个分布到另一个分布是否有漂移

— **直方图(频率直方图)：**

对于标称属性X，对于X的每个已知值，画一个柱或竖直条

高度表示该X值出现的频率

二元分布

— **散点图：**

观察双变量数据（点簇和离群点）及其相关联系的可能性

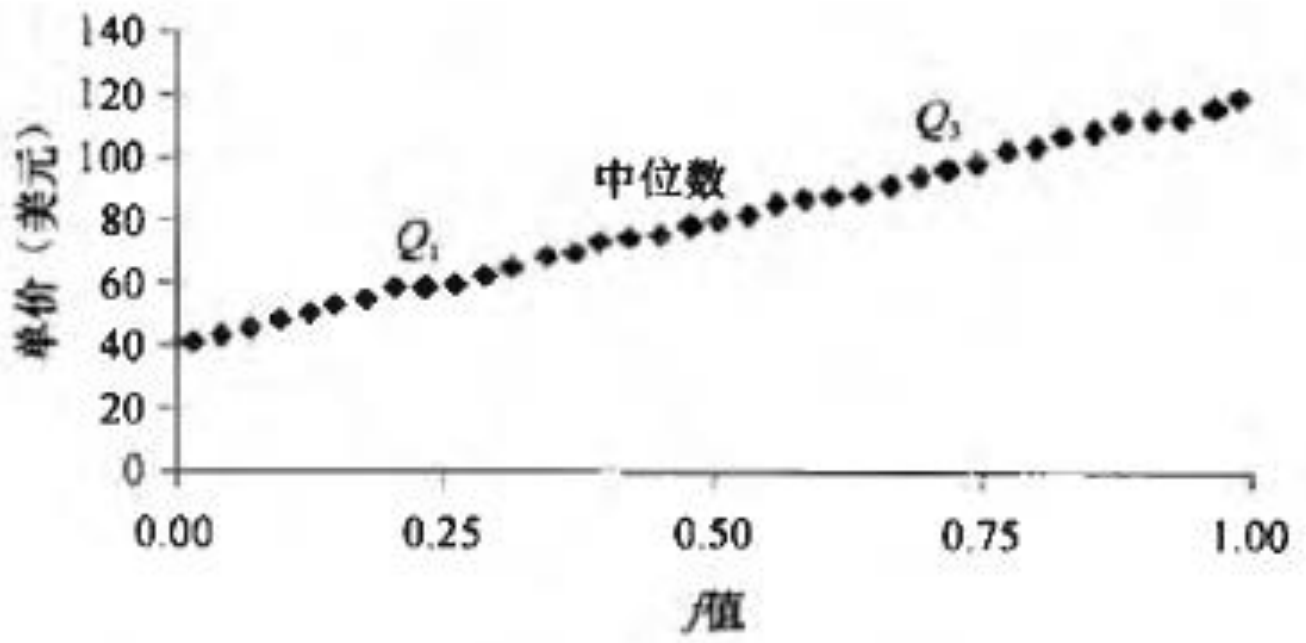
Quantile Plot

图形表示 之 **分位数图**

- **图形显示 之 分位数图：**
  - —观察单变量数据分布的简单有效方法
  - —每个观测值 xi 与一个百分数 fi 配对，使大约 fi*100% 的数据小于值 xi

表 2.1 AllElectronics 的一个部门销售的商品单价数据集

单价（美元）	商品销售量
40	275
43	300
47	250
…	…
74	360
75	515
78	540
…	…
115	320
117	270
120	350



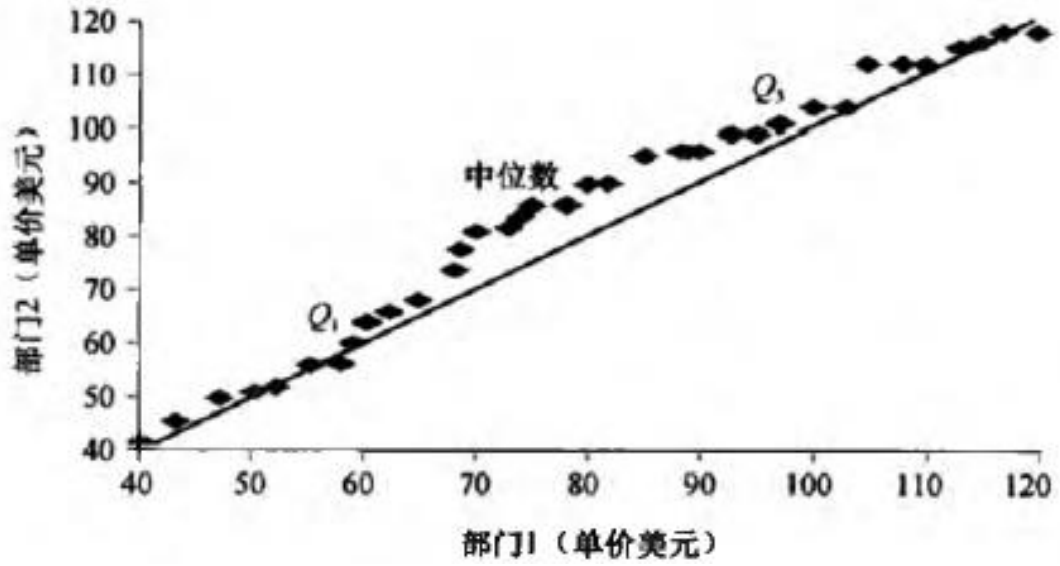
Quantile - Quantile Plot

图形表示 之 分位数-分位数图

- **图形显示 之 分位数-分位数图：**

  观测取自两个部门的观测集分布，判断从一个分布到另一个分布是否有漂移

- **图形**



✓部门1销售的商品单价比部门2 稍低。
✓换言之，部门1销售的商品25%低于或等于60美元，而在部门2 销售的商品25%低于或等于64美元。在第50个分位数（标记为中位数，即Q2），看到部门1销售的商品50%低于或等于78美元，而在部门2 销售的商品50%低于或等于85美元。
✓一般地，我们注意到部门1的分布相对于部门2 有一个漂移，因为部门1销售的商品单价趋向于比部门2 低。

Histogram

图形表示 之 直方图

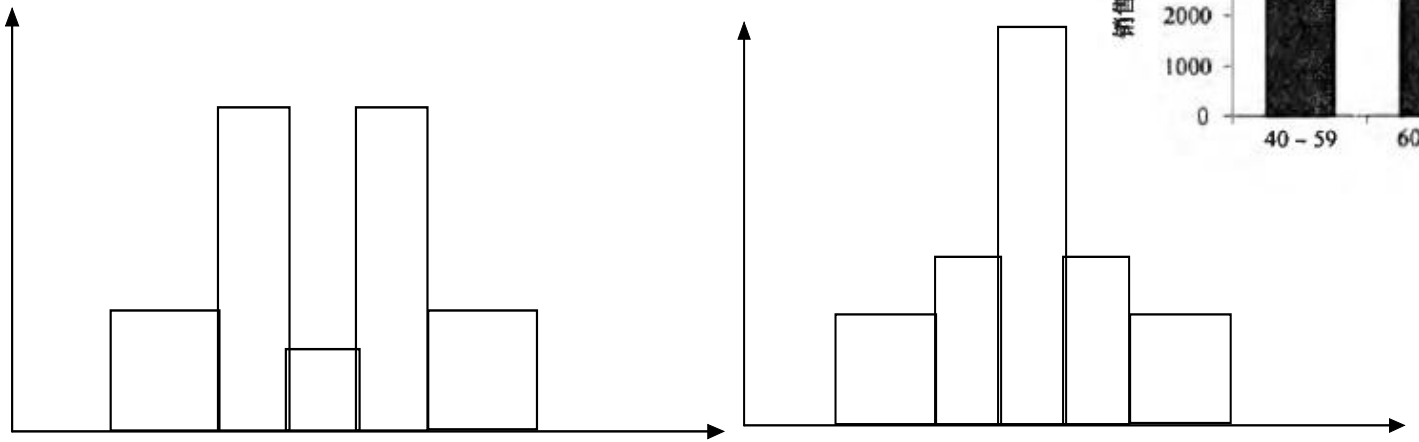
- **图形显示 之 直方图：**

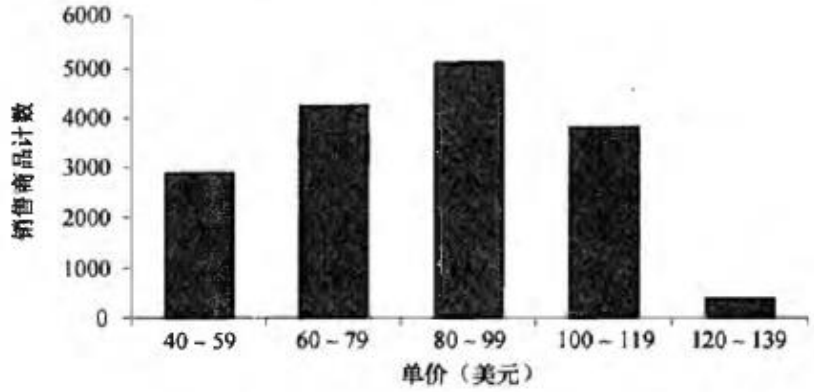
  对于标称属性X，对于X的每个已知值，画一个柱或竖直条

  高度表示该X值出现的频率

- **图形：以下两个直方图具有相同的五值**

  但他们的数据分布完全不同





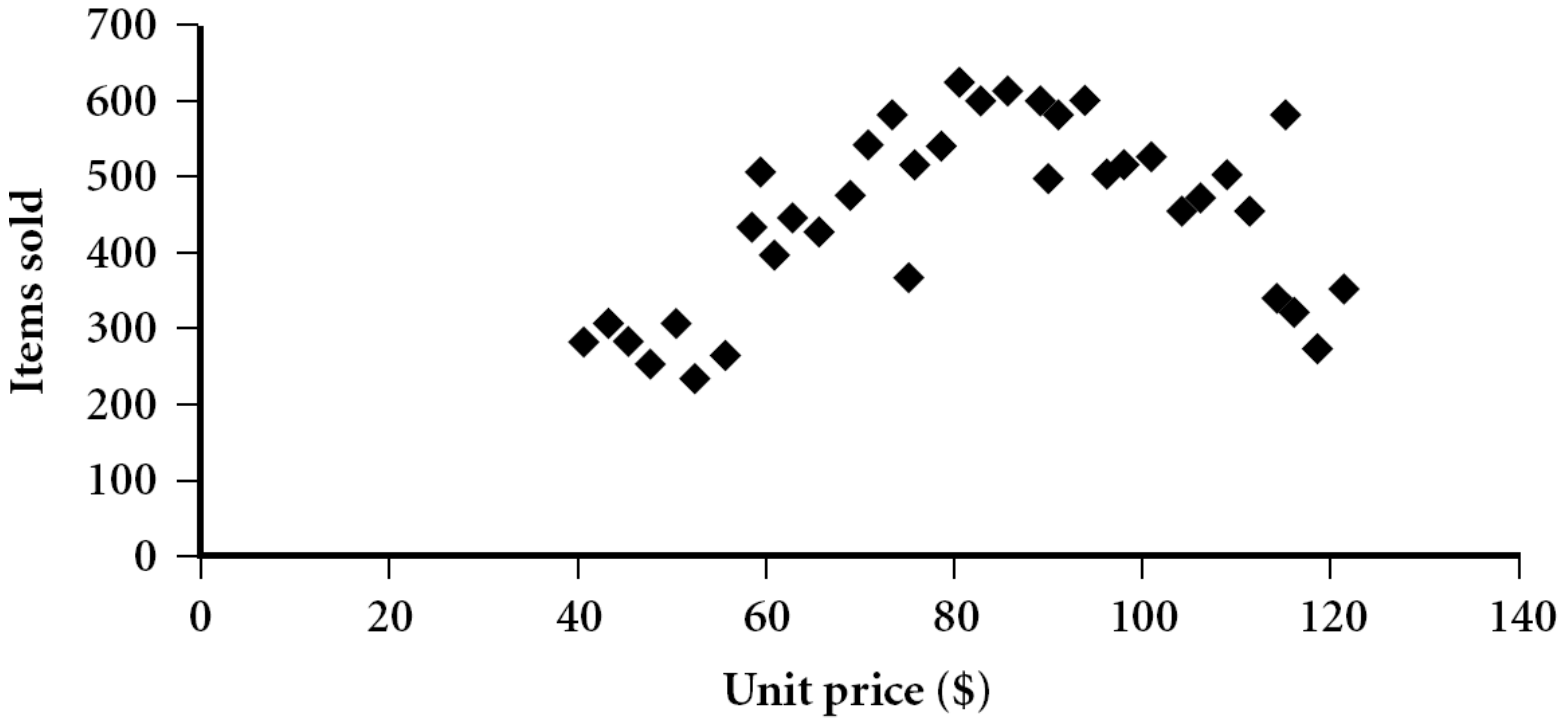
Scatter Plot

图形表示 之 **散点图**

- **图形显示 之 散点图：**

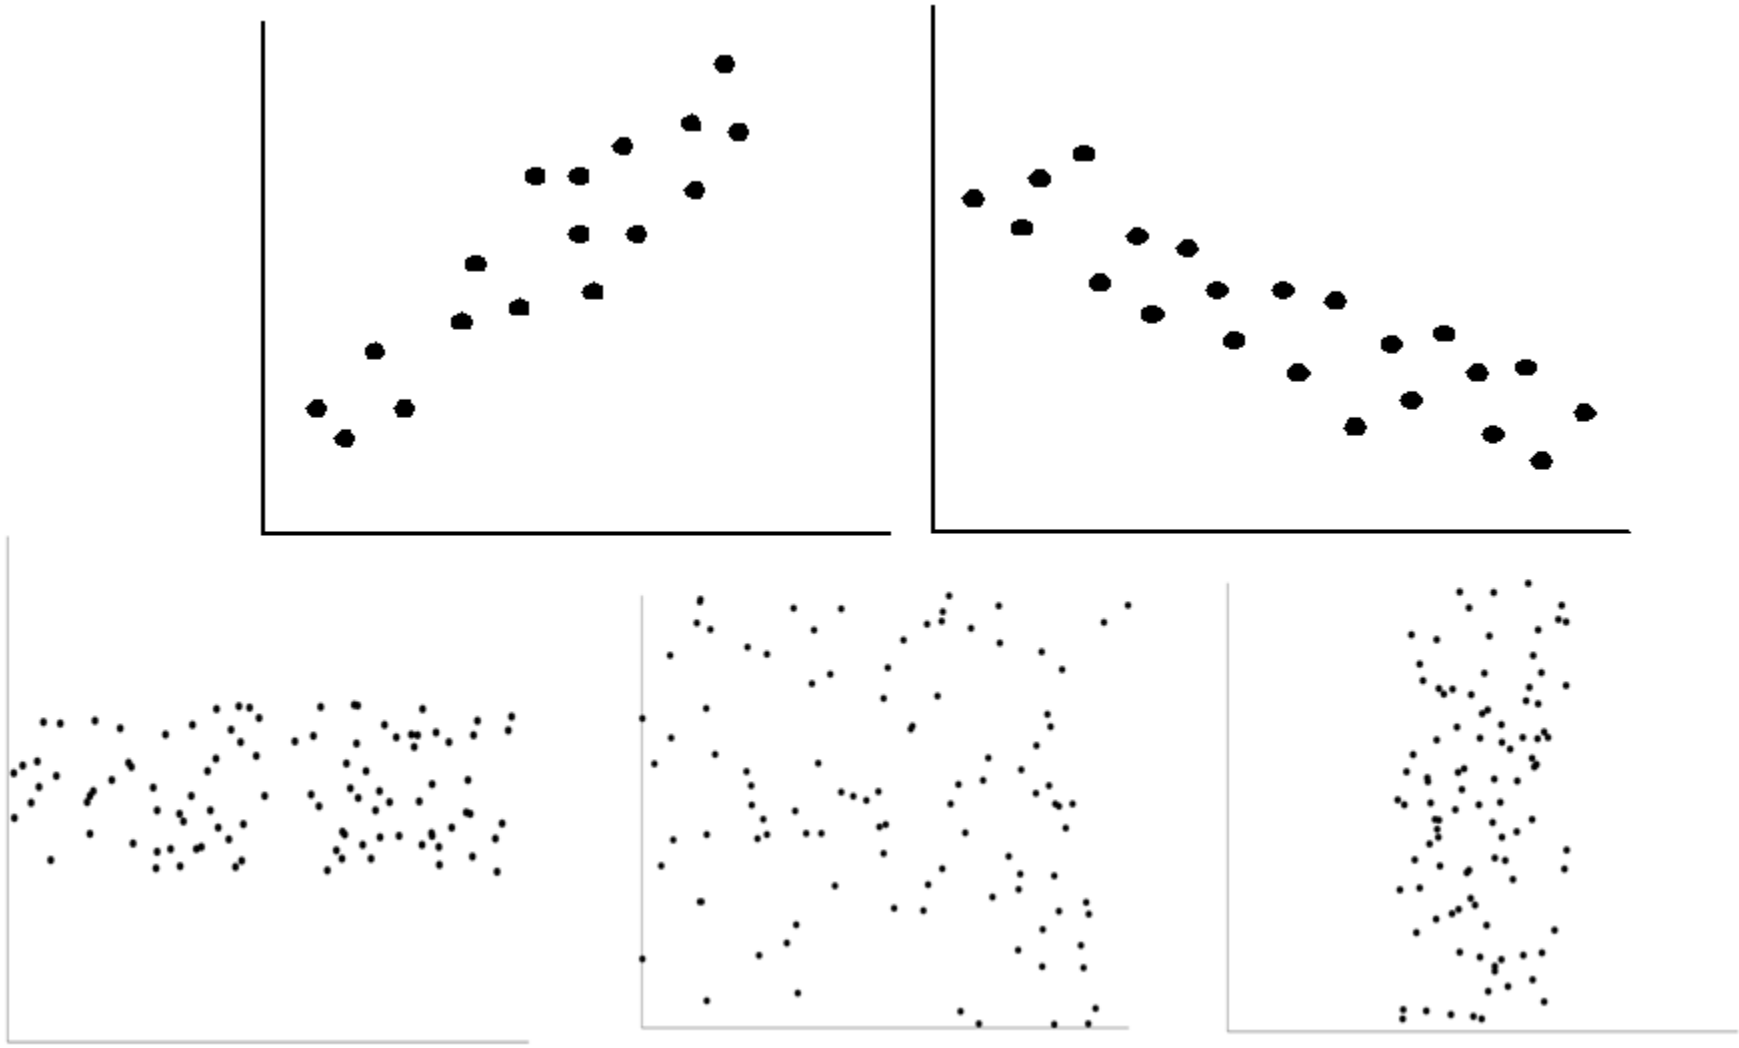
  观察两个数值变量（点簇和离群点）及其相关联系的可能性

- **图形**



Scatter Plot

图形表示 之 散点图 Cont.



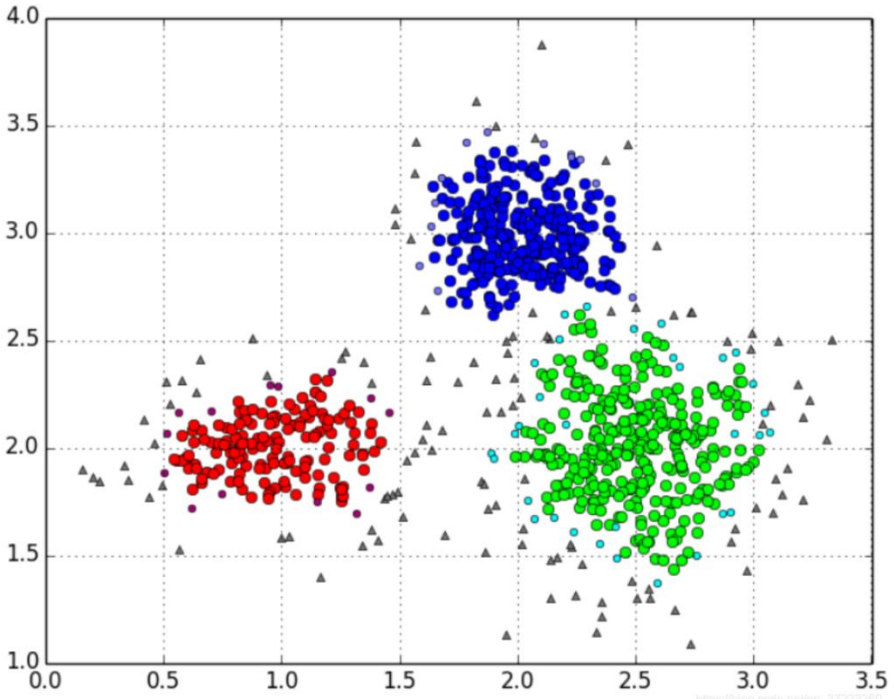
Chapter 2. 认识数据

- Data Objects and Attribute Types
  数据对象与属性类型
- Basic Statistical Descriptions of Data
  数据的基本统计描述
- Data Visualization
  数据可视化
- Measuring Data Similarity and Dissimilarity
  度量数据的相似性和相异性
- Summary 小结

Data Visualization
数据可视化

- 为什么要 **数据可视化**？
  - — 通过图形表示清晰有效的数据
  - — 发现原始数据中不易观察到的数据联系
  - — **制造乐趣和有趣的图案**









可视化的方法

- **可视化多种多样……**
  - —基于像素的可视化技术
    - Pixel-oriented visualization techniques
  - —几何投影可视化技术
    - Geometric projection visualization techniques
  - —基于图符的可视化技术
    - Icon-based visualization techniques
  - —层次可视化技术
    - Hierarchical visualization techniques
  - —可视化复杂对象和关系
    - Visualizing complex data and relations

Pixel-Oriented Visualization Techniques
基于像素的可视化技术

- 对于一个m维的数据集，在屏幕上创建m个窗口(每维一个)
- 一条记录的m个维值映射到这些窗口中对应位置的m个像素

- **像素的 颜色 反应对应的值**

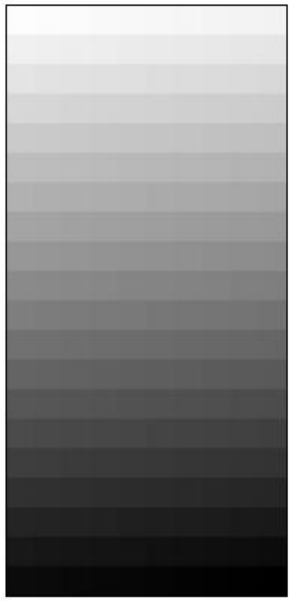
- **E.g.,** AllElectronics 维护了一张顾客信息表，包含四维：
  - Income（收入），credit_limit（信贷额度），transaction_volume（成交量）和 age（年龄）

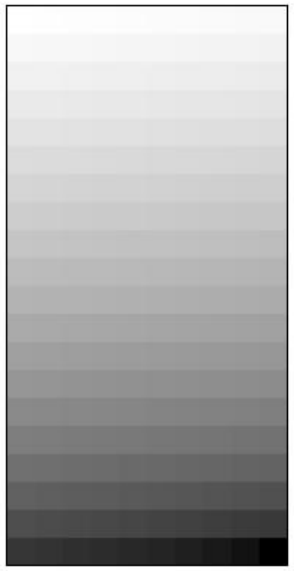
分析income与其他属性的相关性

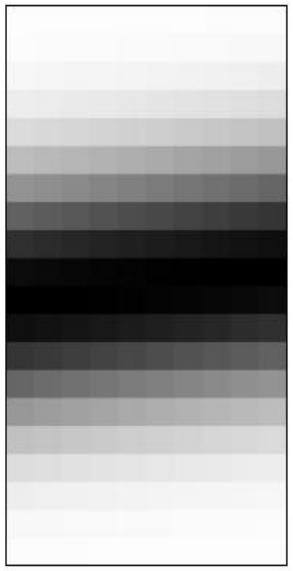
Pixel-Oriented Visualization Techniques
基于像素的可视化技术 Cont.

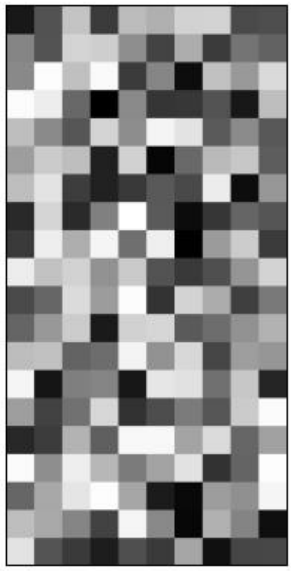
- 对所有顾客按收入的递增序排序
- 在4个可视化窗口中按以上排序安排顾客数据
- 像素颜色越淡，值越小
- 得到四张图

✓Credit Limit随Income增加而增加
✓收入处于中部区间的顾客更可能从AllElectronics购物；
✓Income与age之间没有明显的相关性


(a) Income

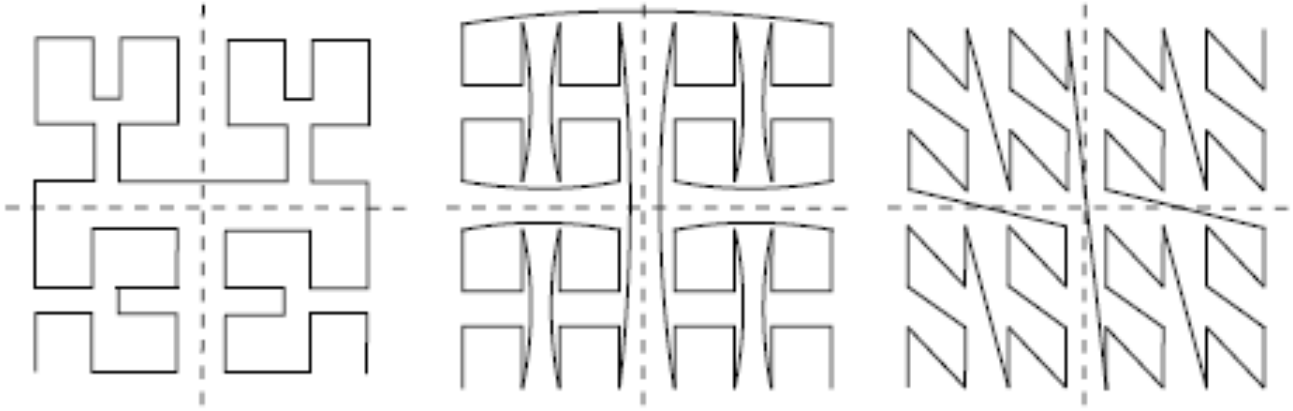

(b) Credit Limit


(c) transaction volume


(d) age

Pixel-Oriented Visualization Techniques
基于像素的可视化技术 Cont.

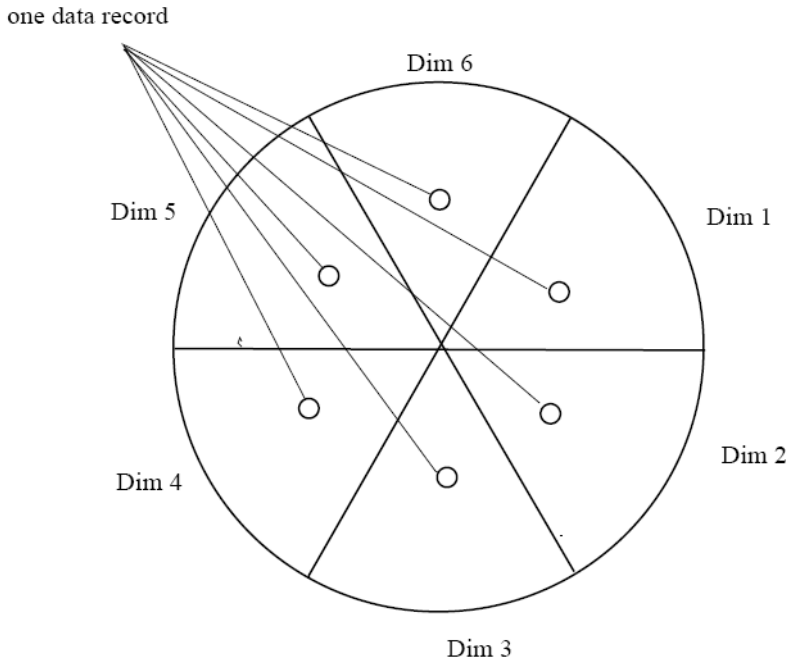
- 缺点1：线性安排填充窗口效果可能不好
  - —每一行的第一个像素与前一行的最后一个像素离得太远，本应是全局序下彼此贴近的
  - —使用空间填充曲线
    - 是这样一种曲线，它的范围覆盖整个n维单位超立方体



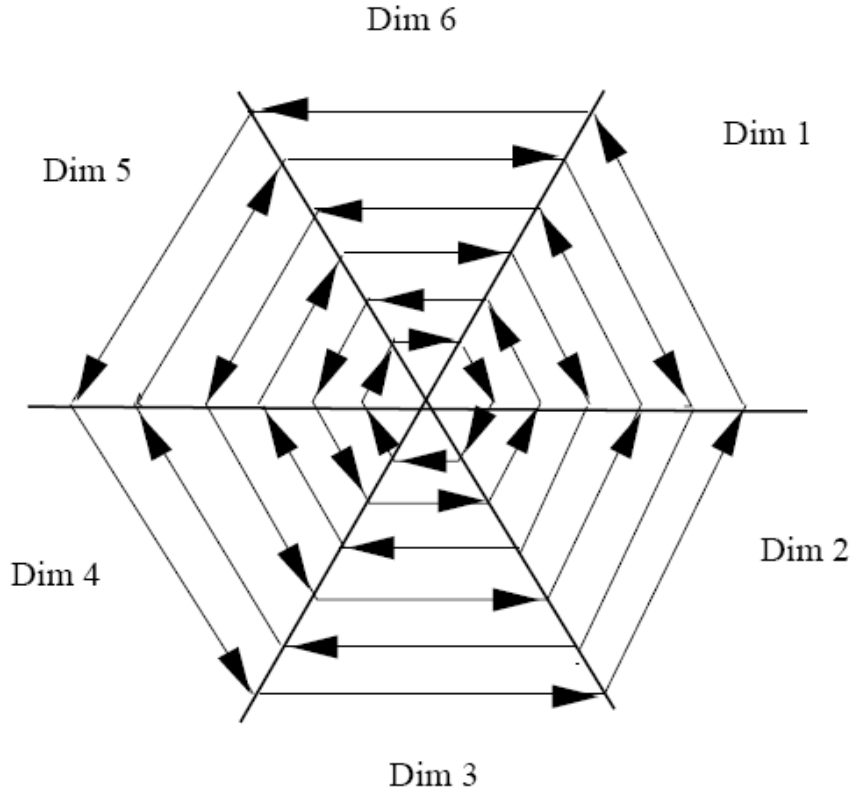
(a) Hilbert curve (b) Gray code (c) Z-curve

Pixel-Oriented Visualization Techniques
基于像素的可视化技术 Cont.

- 缺点2：空间浪费比较多，比较不是很明显
  - —使用圆弓分割技术，显示多维间的联系，改善维比较



(a) Representing a data record in circle segment



(b) Laying out pixels in circle segment

可视化的方法

- **可视化多种多样……**
  - —基于像素的可视化技术
    - Pixel-oriented visualization techniques
  - —几何投影可视化技术
    - Geometric projection visualization techniques
  - —基于图符的可视化技术
    - Icon-based visualization techniques
  - —层次可视化技术
    - Hierarchical visualization techniques
  - —可视化复杂对象和关系
    - Visualizing complex data and relations

Geometric projection visualization techniques
几何投影可视化技术

- **基于像素的可视化技术还有一个缺点：**
  - —对于理解多维空间的数据分布帮助不大
    - 并不显示在多维子空间是否存在稠密区域

- **几何投影可视化技术**

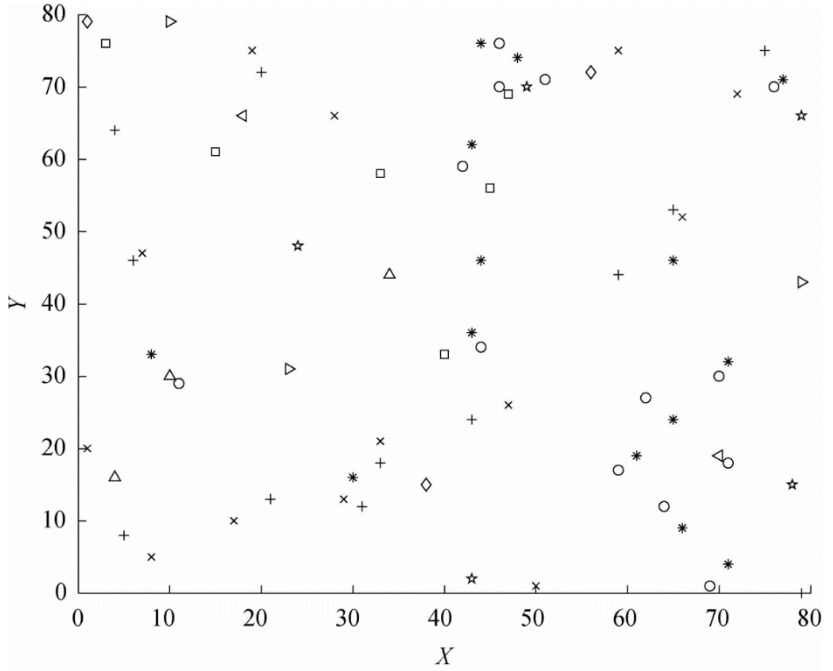
  解决：如何在二维显示上可视化高维空间

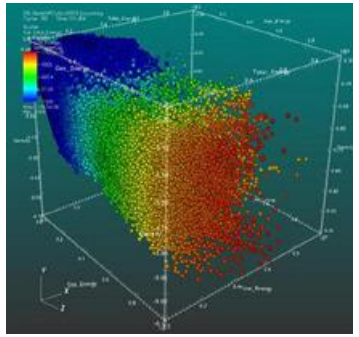
- **具体方式：**
  - —**散点图**
  - —**散点图矩阵**
  - —**平行坐标**

Geometric projection visualization techniques
几何投影可视化技术 之 散点图

- 几何投影可视化技术： 散点图
- 笛卡尔坐标显示 **二维** 数据点
- E.g.,
  X轴和Y轴表示两个属性
  第三维 用形状表示
- 如果再添加 **颜色**可以表示 **第四维**

“+” 和 “x”类型的点趋向于一起出现

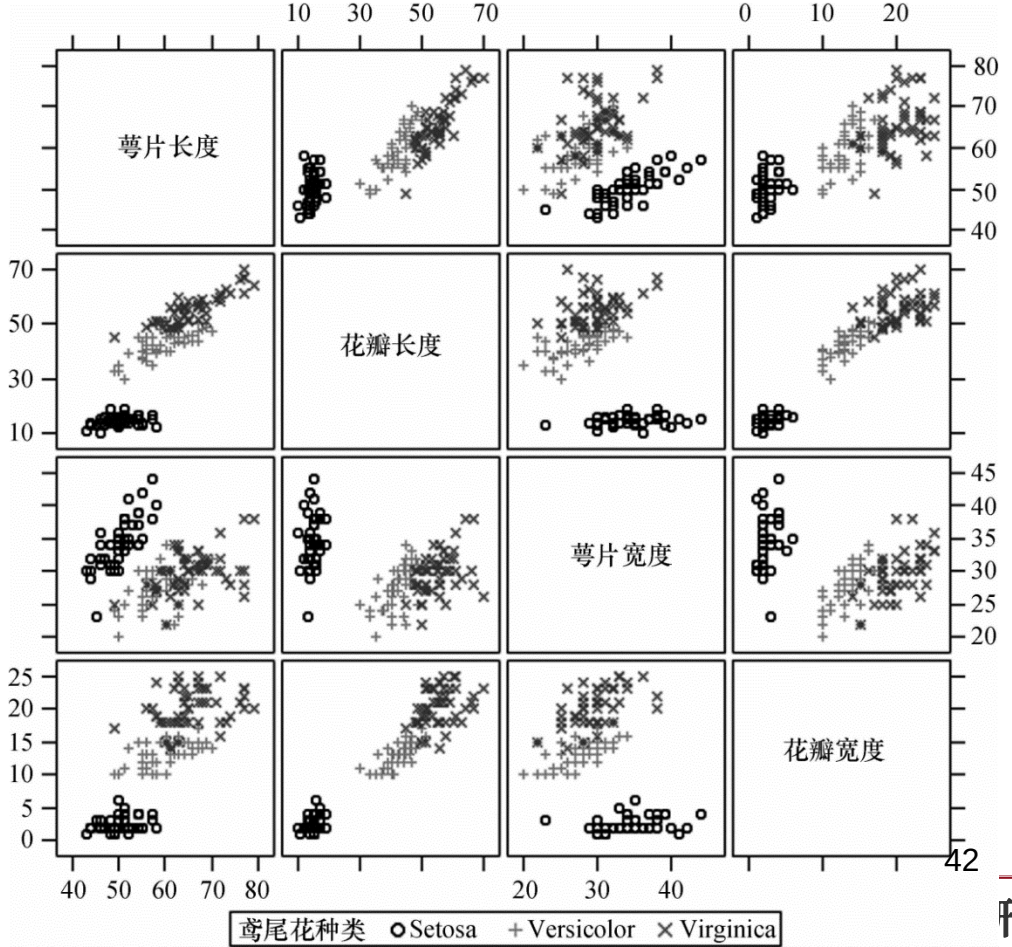




Geometric projection visualization techniques

几何投影可视化技术 之 散点图 Cont.

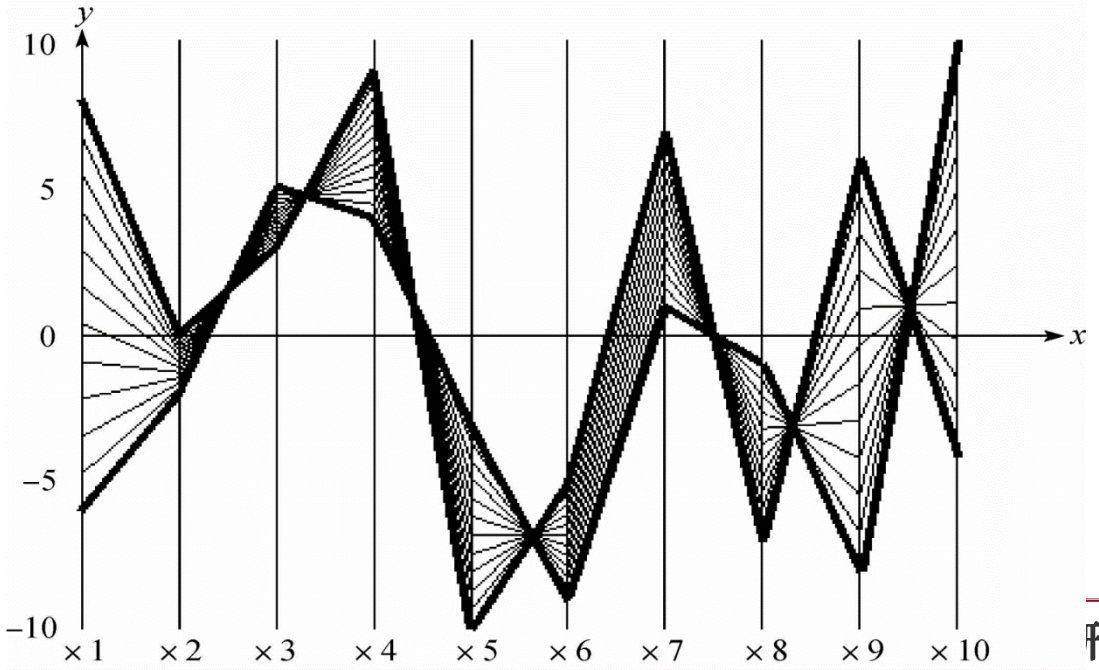
- 几何投影可视化技术： **散点图矩阵**
  - — 散点图的一种扩充, 解决 四维 以上的可视化
  - —对于n维数据集，散点图矩阵是二维散点图的nxn网格，提供每个维与所有其他维的可视化
- **鸢(yuan)尾花数据集**
  - —法国国花，别名蓝蝴蝶……
  - —450个样本，取自3 种鸢尾花。
  - —数据集有5 个维
    - 萼片长度
    - 萼片宽度
    - 花瓣长度
    - 花瓣宽度
    - 种属



Geometric projection visualization techniques

几何投影可视化技术 之 散点图 Cont.

- 几何投影可视化技术： **平行坐标**
  - —当维数继续增加时，散点图矩阵变得不太有效
  - —另一种流行的技术是平行坐标
    - 绘制n个等距离、相互平行的轴，每维一个
    - 数据记录用折线表示，与每个轴在对应于相关维值的点上相交
    - 不能显示具有很多记录的数据集



可视化的方法

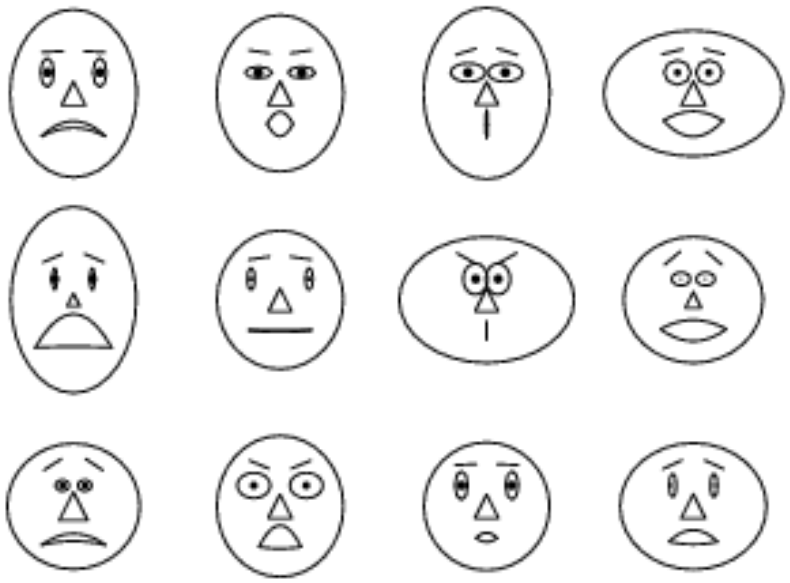
- **可视化多种多样……**
  - —基于像素的可视化技术
    - Pixel-oriented visualization techniques
  - —几何投影可视化技术
    - Geometric projection visualization techniques
  - —基于图符的可视化技术
    - Icon-based visualization techniques
  - —层次可视化技术
    - Hierarchical visualization techniques
  - —可视化复杂对象和关系
    - Visualizing complex data and relations

基于图符的可视化技术

- 用图符来将数据值可视化
- 典型可视化方法：
  - —切尔诺夫脸
  - —人物线条画
- 通用技术：
  - —形状编码：用形状来代表特定的信息编码
  - —彩色图符：用彩色图符来编码更多信息
  - —Tile bars：用小图符来表示检索到的文档的相关特征向量

Icon-based visualization techniques
基于图符的可视化技术 Cont.

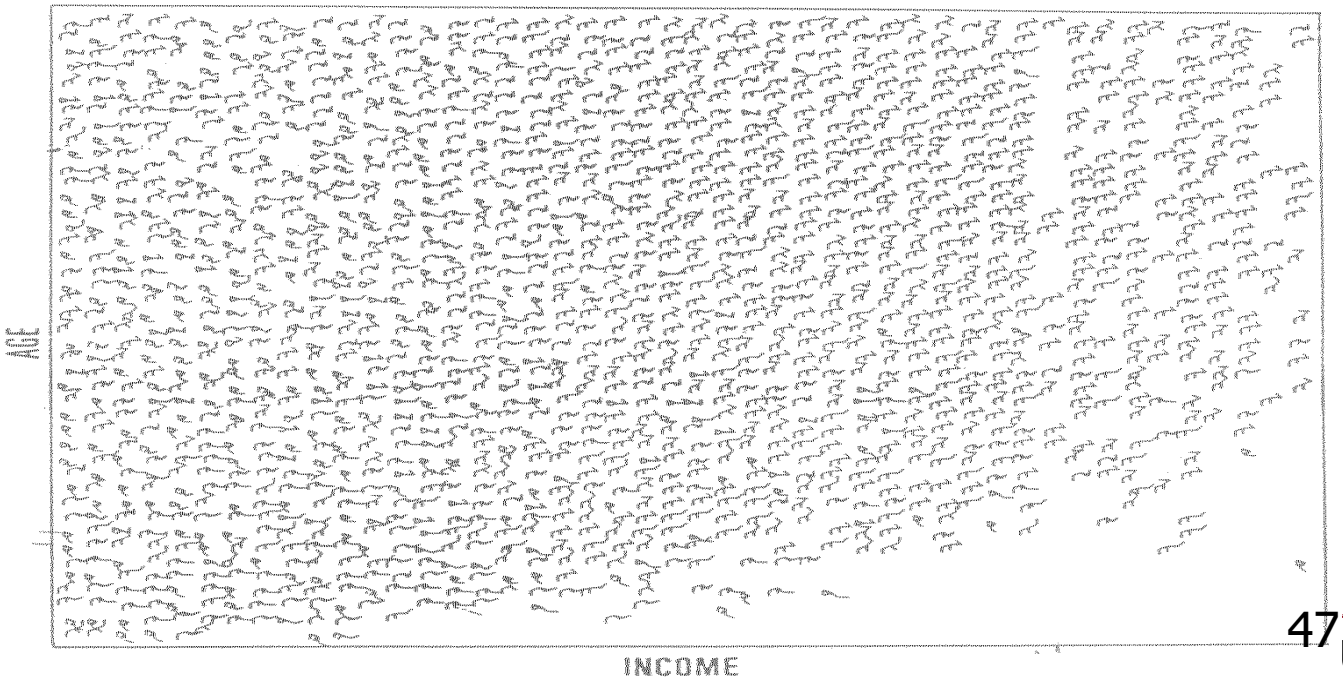
- **切尔诺夫脸（统计学家1973年）**
  - 一种可将变量显示在二维平面上的方法
  - 多维（最多18维）->卡通人脸
    - 脸的要素，如眼、耳、口、鼻等用其形状，大小、位置和方向表示维的值：眼的大小、两眼的距离、鼻子长度、鼻子宽度、嘴巴曲度、嘴巴宽度、嘴巴阔度、眼球大小、眉毛倾斜、眼睛偏离程度和头部偏离程度
- 每张脸表示一个数据点。
- 切尔诺夫脸利用人的思维能力，识别面部特征微小差异并立即消化理解许多面部特征。
- 观察大型数据表可能是令人乏味的，通过浓缩数据，更容易被用户消化理解，有助于数据的规律和不规律性的可视化。
- 缺点
  - 在多重联系的能力方面存在局限性
  - 没有显示具体数值
  - 面部特征因感知的重要性而异，这意味两张脸〔代表两个多维数据点〉的相似性可能因指派到面部特征的维的次序而异



- 扩展：**非对称切尔诺夫脸**
- 脸具有垂直（关于Y轴）对称性，因此脸的左右两边是相同的，对称的切尔诺夫脸是浪费空间。非对称的切尔诺夫脸使面部特征加倍，这样允许显示多达36维

Icon-based visualization techniques
基于图符的可视化技术 Cont.

- 人物线条画
  - 多维数据->5-段人物线条画（四肢和一个躯干）
  - 两维被映射到显示轴，其余的维映射到四肢的角度和（或）长度
  - 相对稠密->纹理模式，反映数据趋势
- 展示人口调查数据的图，显示了年龄，收入，性别、教育等



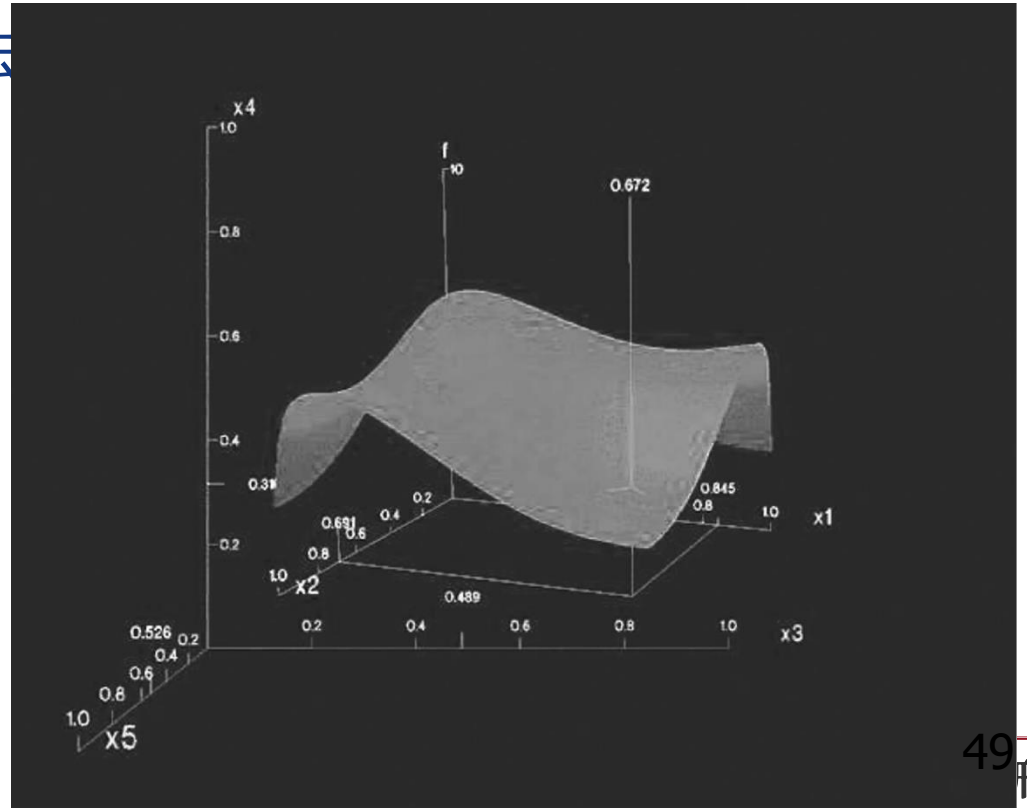
可视化的方法

- **可视化多种多样……**
  - —基于像素的可视化技术
    - Pixel-oriented visualization techniques
  - —几何投影可视化技术
    - Geometric projection visualization techniques
  - —基于图符的可视化技术
    - Icon-based visualization techniques
  - —层次可视化技术
    - Hierarchical visualization techniques
  - —可视化复杂对象和关系
    - Visualizing complex data and relations

Hierarchical visualization techniques
层次可视化技术

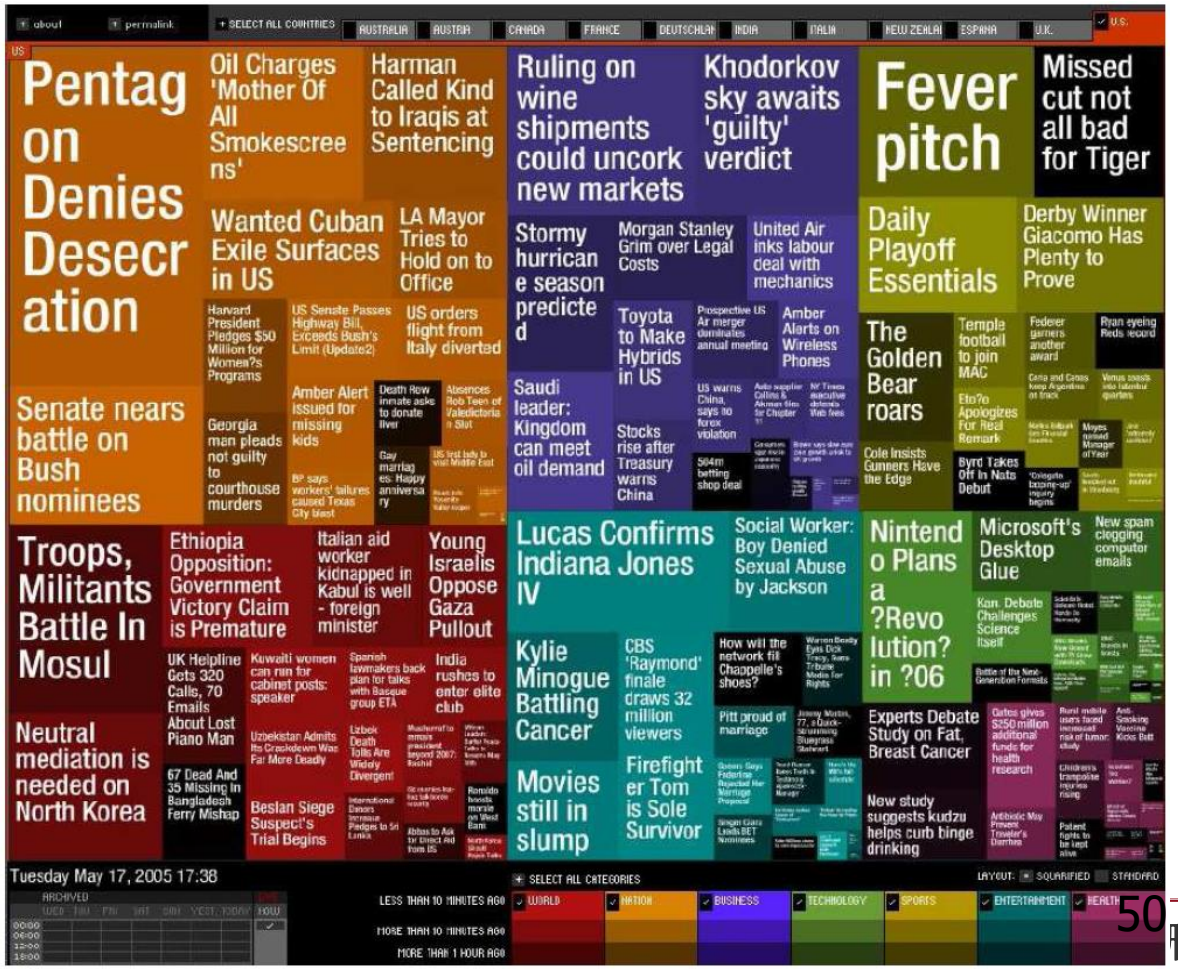
- 上述方法都是对所有维度同时显示，但对于大型高维数据集，很难同时对所有维可视化
- **把所有维划分成子集（即子空间），按层次可视化**

- **“世界中的世界”（worlds-within-worlds），是一种**具有代表性的可视化方法
- 六维数据：F、X1…X5



Hierarchical visualization techniques
层次可视化技术 Cont.

- 层次可视化的另一个例子：
- **树图**
  - 把层次数据显示成嵌套矩阵的集合
- Google新闻报导可视化的树图
  - 所有新闻报道组织成7 个类，每个显示在一个唯一颜色的矩形中
  - 在每个类别内（即在最顶层每个矩形内〉，新闻报道进一划分成较小的子类别。



可视化的方法

- **可视化多种多样……**
  - —基于像素的可视化技术
    - Pixel-oriented visualization techniques
  - —几何投影可视化技术
    - Geometric projection visualization techniques
  - —基于图符的可视化技术
    - Icon-based visualization techniques
  - —层次可视化技术
    - Hierarchical visualization techniques
  - —可视化复杂对象和关系
    - Visualizing complex data and relations

Visualizing complex data and relations
可视化复杂对象和关系

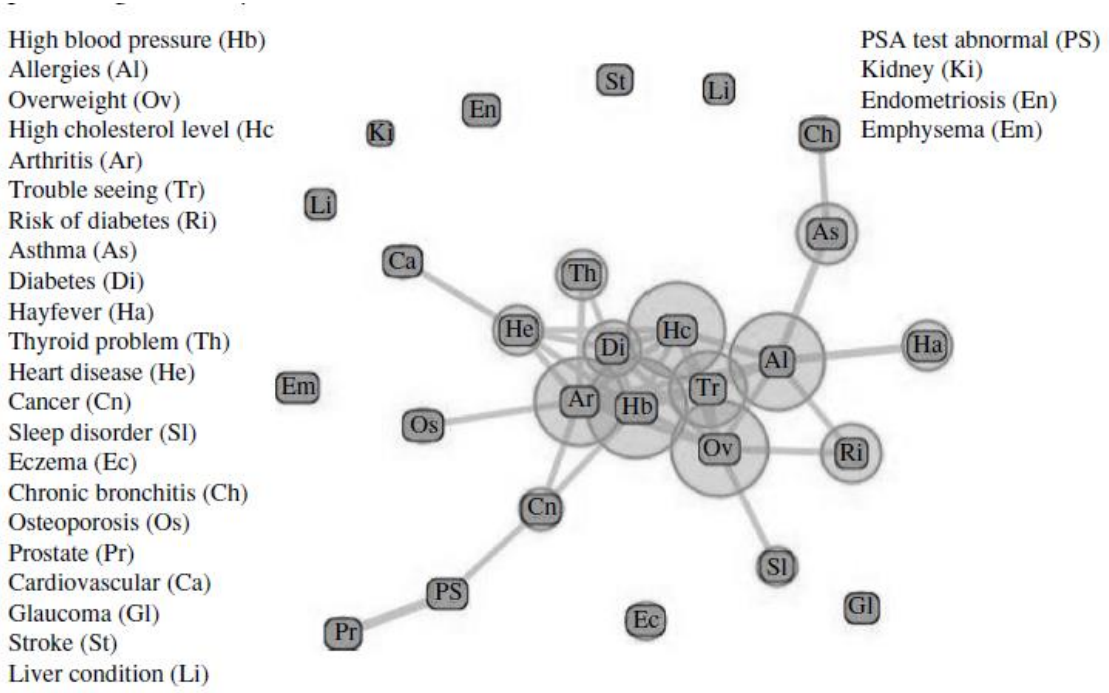
- 可视化非数值数据：文本和社会网络
- 标签云
  - —WEB 上许多人对诸如图片、博客和产品评论加标签
  - —可视化用户产生的标签的统计量
- 标签的重要性由字体大小或者颜色来表示
- 主要用法有两种：
  - —单个术语：大小——标签被不同的用户用于该术语的次数（一个术语对应多个标签）
  - —多个术语：大小——标签用于的术语数（一个标签对应多个术语）
    - 标签的人气

Visualizing complex data and relations
可视化复杂对象和关系 Cont.



Visualizing complex data and relations
可视化复杂对象和关系 Cont.

- 除了复杂数据，数据项之间的复杂关系也对可视化提出了挑战



使用疾病影响图来可视化疾病之间的相关性。图中的结点是疾病，每个结点的大小与对应疾病的流行程度成正比。如果对应的疾病具有强相关性，两个结点用一条边连接。边的宽度与两个对应的疾病的相关强度成正比。

更多关于数据可视化的信息

大数据丛书

- 数据可视化
  - —陈为等编著
  - —电子工业出版社
  - —2013年12月第一版

可视化与数据挖掘

- 可视化为探索数据提供了有效的工具，有许多现成的工具和方法

- 可视化可以用于数据挖掘的若干方面
  - —对数据可视化
  - —也可以用于表现挖掘过程、从挖掘方法得到的模式，以及用户与数据交互
  - —可视数据挖掘是一个重要的研究开发方向

Chapter 2. 认识数据

- Data Objects and Attribute Types
  数据对象与属性类型
- Basic Statistical Descriptions of Data
  数据的基本统计描述
- Data Visualization
  数据可视化
- Measuring Data Similarity and Dissimilarity
  度量数据的相似性和相异性
- Summary 小结

相似性和相异性

- **为什么需要度量相似性和相异性？**
  - —在诸如聚类、离群点分析和最近邻分类等数据挖掘应用中，我们需要评估对象之间相互比较的相似或不相似程度
    - 商店希望搜索顾客对象簇，得出具有类似特征〈例如，类似的收入、居住区域和年龄等）的顾客组聚类，这些信息用于销售。簇是数据对象的集合，使得同一个簇中的对象互相相似，而与其他族中的对象相异
    - 离群点分析也使用基于聚类的技术，把可能的离群点看做与其他对象高度相异的对象
    - 对象的相似性可以用于最近邻分类，对给定的对象（例如，患者），基于它与模型中其他对象的相似性赋予一个类标号（比如，诊断结论）

相似性和相异性

- **相似性**
  - 描述两个数据对象相似程度的数值
  - 越相似值越大
  - 值通常在[0,1]中
- **相异性(e.g. 距离)**
  - 描述两个数据对象不同程度的数值
  - 越不相似值越大
  - 最小相异性的值通常为0
- **邻近性**
  - 相似性或相异性

相似性和相异性

如何计算被下述属性或属性组合刻画的对象的相异性

- 标称属性
- 二元属性
- 数值属性
- 序数属性
- 这些属性类型组合

关于如何计算相异性的知识对于研究属性是有用的，并且被关于聚类、离群点分析、最近邻分类所引用。

如何计算相似性度量

- 对非常长、稀疏的数据向量（如表示信息检索的文档的词频向量）的相似性度量

用于度量的两种数据结构
数据矩阵与相异性矩阵

- **数据矩阵**
  - —用于存放数据对象
  - —或称对象——属性结构
  - —关系表形式或nxp矩阵存放n个数据对象
  - —二模（行代表对象和列代表属性）

N个数据对象
P个属性

$$\begin{bmatrix} x_{11} & \cdots & x_{1f} & \cdots & x_{1p} \\ \cdots & \cdots & \cdots & \cdots & \cdots \\ x_{i1} & \cdots & x_{if} & \cdots & x_{ip} \\ \cdots & \cdots & \cdots & \cdots & \cdots \\ x_{n1} & \cdots & x_{nf} & \cdots & x_{np} \end{bmatrix}$$

- **相异性矩阵**
  - —用于存放数据对象对的相异性值
    - d(i,j)=0,一个对象自身差别为0
  - —或称对象——对象结构
  - —存放n个对象两两间的邻近度
  - —通常用nxn的矩阵表示
  - —单模（只包括一类实体或事物）
  - —许多聚类和最近邻算法都在相异性矩阵上运行

$$\begin{bmatrix} 0 & & & & \\ d(2,1) & 0 & & & \\ d(3,1) & d(3,2) & 0 & & \\ \vdots & \vdots & \vdots & & \\ d(n,1) & d(n,2) & \cdots & \cdots & 0 \end{bmatrix}$$

- **相似性度量和相异性度量的关系**

$$sim(i,j) = 1 - d(i,j)$$

相似性和相异性

如何计算被下述属性或属性组合刻画的对象的相异性

- 标称属性
- 二元属性
- 数值属性
- 序数属性
- 这些属性类型组合

关于如何计算相异性的知识对于研究属性是有用的，并且被关于聚类、离群点分析、最近邻分类所引用。

如何计算相似性度量

- 对非常长、稀疏的数据向量（如表示信息检索的文档的词频向量）的相似性度量

标称属性的邻近性度量

- **标称属性的邻近性度量**
- 标称属性可以取两个或者多个状态：
  - e.g. map_color是一个标称属性：红，黄，绿，粉红和蓝

- **如何计算标称属性所刻画的对象之间的相异性？**
- **不匹配率：**

$$d(i,j)=\frac{p-m}{p}$$

  - **其中m是匹配（i和j取值相同状态的属性）的数目，p是刻画对象的属性总数**

标称属性的邻近性度量(Cont.)

对象标识符	test-1
1	A
2	B
3	C
4	A

对象1和对象2有d(1,2)=(1-0)/1=1
对象1和对象4有d(1,4)=(1-1)/1=0

$$\begin{bmatrix} 0 & & & \\ 1 & 0 & & \\ 1 & 1 & 0 & \\ 0 & 1 & 1 & 0 \end{bmatrix}$$

相似性可以用下式计算：

$$sim(i,j) = 1 - d(i,j) = \frac{m}{p}$$

相似性和相异性

如何计算被下述属性或属性组合刻画的对象的相异性

- 标称属性
- 二元属性
- 数值属性
- 序数属性
- 这些属性类型组合

关于如何计算相异性的知识对于研究属性是有用的，并且被关于聚类、离群点分析、最近邻分类所引用。

如何计算相似性度量

- 对非常长、稀疏的数据向量（如表示信息检索的文档的词频向量）的相似性度量

二元属性的相异性

- **二元属性只有两种状态：0或1**

  0表示该属性不出现，1表示该属性出现

  注意：不能像对待数值一样来处理二元属性！

- **那么，如何计算两个二元属性之间的相异性？**

  — 针对 **对称二元属性**

  E.g., 对于对象 I 和对象 J，

  q 是对象 I 和 J都取1的属性数

  r 是对象 I 取1，对象 J 取0的属性数

  s 是对象 I 取0，对象 J 取1的属性数

  t 是对象 I 和 J都取0的属性数

表 2.3　二元属性的列联表

		对象 j		
		1	0	sum
对象 i	1	q	r	$q+r$
	0	s	t	$s+t$
	sum	$q+s$	$r+t$	p

- **此时，相异性**

$$d(i,j)=\frac{r+s}{q+r+s+t}$$

二元属性的相异性(Cont.)

- 针对 **非对称二元属性（E.g., 病理化验的阳性(1)和阴性(0)结果）**

- **负匹配（t）被认为是不重要的可以被忽略**

表 2.3　二元属性的列联表

		对象 j		
		1	0	sum
对象 i	1	q	r	$q+r$
	0	s	t	$s+t$
	sum	$q+s$	$r+t$	p

- **此时，相异性** $d(i,j)=\dfrac{r+s}{q+r+s}$

- **相对应的** $sim_{Jaccard}(i,j)=\dfrac{q}{q+r+s}$

  也被称为Jaccard系数

相似性和相异性

如何计算被下述属性或属性组合刻画的对象的相异性

- 标称属性
- 二元属性
- 数值属性
- 序数属性
- 这些属性类型组合

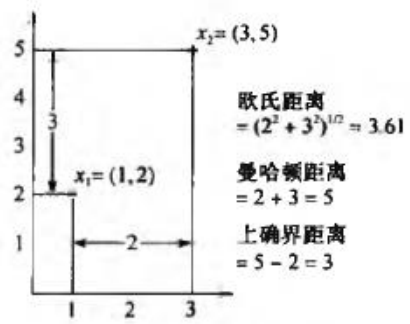
关于如何计算相异性的知识对于研究属性是有用的，并且被关于聚类、离群点分析、最近邻分类所引用。

如何计算相似性度量

- 对非常长、稀疏的数据向量（如表示信息检索的文档的词频向量）的相似性度量

数值属性的相异性

- 计算数值属性刻画的对象之间相异性的距离度量
  - —欧几里得距离
  - —曼哈顿距离
  - —闵可夫斯基距离



- （加权）欧几里得距离（直线或“乌鸦飞行”距离）

$$d(i,j) = \sqrt{(x_{i1} - x_{j1})^2 + (x_{i2} - x_{j2})^2 + (x_{i3} - x_{j3})^2 + \cdots + (x_{ip} - x_{jp})^2}$$

$$d(i,j) = \sqrt{w_1 |x_{i1} - x_{j1}|^2 + w_2 |x_{i2} - x_{j2}|^2 + \cdots + w_p |x_{ip} - x_{jp}|^2}$$

  - —其中 $i = (x_{i1}, x_{i2}, x_{i3}, \ldots, x_{ip})$, $j = (x_{j1}, x_{j2}, x_{j3}, \ldots, x_{jp})$ 是被p个数值属性描述的两个对象

- 曼哈顿距离（城市两点之间的街区距离）
  - —如，向南2 个街区，横过3 个街区，共计5 个街区

$$d(i,j) = |x_{i1} - x_{j1}| + |x_{i2} - x_{j2}| + \cdots + |x_{ip} - x_{jp}|$$

数值属性的相异性(Cont.)

- 欧几里得距离和曼哈顿距离都满足以下数学性质：
  - —非负性 $d(i,j) \geq 0$
  - —同一性 $d(i,i) = 0$
  - —对称性 $d(i,j) = d(j,i)$
  - —三角不等式 $d(i,j) \leq d(i,k) + d(k,j)$

- 满足以上几个条件的测度称为 **度量**

数值属性的相异性(Cont.)

- 闵可夫斯基距离：欧几里得距离和曼哈顿距离的推广

$$d(i,j) = \sqrt[h]{|x_{i1} - x_{j1}|^h + |x_{i2} - x_{j2}|^h + \cdots + |x_{ip} - x_{jp}|^h}$$

- 这种距离又称Lp范数

—h=1时为曼哈顿距离，h=2时为欧几里得距离

- 当h趋向于正无穷时，我们得到上确界距离（切比雪夫距离）

$$d(i,j) = \lim_{h\to\infty}\left(\sum_{f=1}^{p}|x_{if} - x_{jf}|^h\right)^{\frac{1}{h}} = \max_{f}^{p}|x_{if} - x_{jf}|$$

—各座标数值差的最大值

- 也就是找出属性f，它产生两个对象的最大值差

相似性和相异性

如何计算被下述属性或属性组合刻画的对象的相异性

- 标称属性
- 二元属性
- 数值属性
- 序数属性
- 这些属性类型组合

关于如何计算相异性的知识对于研究属性是有用的，并且被关于聚类、离群点分析、最近邻分类所引用。

如何计算相似性度量

- 对非常长、稀疏的数据向量（如表示信息检索的文档的词频向量）的相似性度量

序数属性的邻近性度量

- 序数属性的值之间具有有意义的序或排位，但相继值之间的量值未知
  - —e.g. 可乐杯大小
- 数值属性的值域可以映射到具有M_f个状态的序数属性f
  - —e.g. 摄氏温度可以组织成以下状态
  - —-30~-10，-10~10,10~30 代表 cold, moderate, warm
- 顺序很重要 e.g. rank

序数属性的邻近性度量(Cont.)

- 如何处理序数属性？ 和数值属性的处理十分类似
- 假设f是用于描述n个对象的一组序数属性之一
  - 属性f有 M_f 个有序的状态，表示排位1,…., M_f
  - 用对应的排位 $r_{if} \in \{1,\ldots,M_f\}$ 取代 x_{if}
  - 将第i个对象的第f个属性的值映射到[0.0,1.0]上

$$z_{if} = \frac{r_{if} - 1}{M_f - 1}$$

  - 相异性可以用之前的任一距离度量计算
- 同样,可以得到相似性值

$$sim(i,j) = 1 - d(i,j)$$

序数属性的邻近性度量(Cont.)

对象标识符	test-2
1	优秀
2	一般
3	好
4	优秀

test-2有三个状态，即 $M_f=3$
将每个值替换成它的排位 3,1,2,3
将排位映射成1->0, 2->0.5, 3->1.0实现规格化
利用欧几里得距离实现以下排位

$$\begin{pmatrix} 0 & & & \\ 1.0 & 0 & & \\ 0.5 & 0.5 & 0 & \\ 0 & 1.0 & 0.5 & 0 \end{pmatrix}$$

相似性和相异性

如何计算被下述属性或属性组合刻画的对象的相异性

- 标称属性
- 二元属性
- 数值属性
- 序数属性
- 这些属性类型组合

关于如何计算相异性的知识对于研究属性是有用的，并且被关于聚类、离群点分析、最近邻分类所引用。

如何计算相似性度量

- 对非常长、稀疏的数据向量（如表示信息检索的文档的词频向量）的相似性度量

混合类型属性的相异性

- 之前讨论的是如何计算相同类型的属性描述的对象间的相异性
- 一个数据库可能包含所有的属性类型
  - 标称的，对称二元的，非对称二元的，数值的，序数的
- 如何计算混合属性类型的对象间的相异性？
- 第一种方法：每种类型的属性分为一组，对每种类型分别进行数据挖掘分析
  - 大部分情况不能产生兼容的结果
- 第二种方法:一起处理，只做一次分析
  - 将不同的属性组合在一个相异性矩阵中，所有有意义属性转换到共同的区间[0.0, 1.0]上

混合类型属性的相异性(Cont.)

- 假设数据集包含p个混合类型的属性，对象I和j之间的相异性d(I,j)定义为：

$$d(i,j)=\frac{\sum_{f=1}^{p}\delta_{ij}^{(f)}d_{ij}^{(f)}}{\sum_{f=1}^{p}\delta_{ij}^{(f)}}$$

- 针对每一个属性f，对于其对I和j之间的相异性的贡献 $d_{ij}^{(f)}$
  - f是二元或者标称的：$d_{ij}^{(f)} = 0$ if $x_{if} = x_{jf}$，否则$d_{ij}^{(f)} = 1$
  - f是序数的：计算排位，映射，并将作为数值属性对待 $z_{if}=\frac{r_{if}-1}{M_f-1}$
  - f是数值的： $d_{ij}^{(f)}=\frac{|x_{if}-x_{jf}|}{\max_h x_{hf}-\min_h x_{hf}}$

  其中h遍取属性f的所有非缺失对象
- 对于指示符:
  - 如果x_{jf}或x_{if}缺失，或者$x_{if}=x_{jf}=0$并且f是非对称二元属性 $\delta_{ij}^{(f)}=0$
  - 否则，$\delta_{ij}^{(f)}=1$

混合类型属性的相异性(Cont.)

$$\begin{pmatrix} 0 & & & \\ 1.0 & 0 & & \\ 0.5 & 0.5 & 0 & \\ 0 & 1.0 & 0.5 & 0 \end{pmatrix}$$

对象标识符	test-1	test-2	test-3
1	A	优秀	45
2	B	一般	22
3	C	好	64
4	A	优秀	28

$$\begin{bmatrix} 0 & & & \\ 1 & 0 & & \\ 1 & 1 & 0 & \\ 0 & 1 & 1 & 0 \end{bmatrix}$$

处理test-1和test-2的过程在此略过

首先计算test-3的相异性矩阵

令 $\min_h x_h = 22$ ， $\max_h x_h = 64$ 用两者之差来规格化相异性矩阵的值

$$\begin{pmatrix} 0 & & & \\ 0.55 & 0 & & \\ 0.45 & 1.00 & 0 & \\ 0.40 & 0.14 & 0.86 & 0 \end{pmatrix}$$

然后将三个矩阵合并，例如 $d(3,1) = \frac{1(1) + 1(0.5) + 1(0.45)}{3} = 0.65$

依此类推，得到最终结果

$$\begin{pmatrix} 0 & & & \\ 0.85 & 0 & & \\ 0.65 & 0.83 & 0 & \\ 0.13 & 0.71 & 0.79 & 0 \end{pmatrix}$$

相似性和相异性

如何计算被下述属性或属性组合刻画的对象的相异性

- 标称属性
- 二元属性
- 数值属性
- 序数属性
- 这些属性类型组合

关于如何计算相异性的知识对于研究属性是有用的，并且被关于聚类、离群点分析、最近邻分类所引用。

如何计算相似性度量

- 对非常长、稀疏的数据向量（如表示信息检索的文档的词频向量）的相似性度量

对非常长、稀疏的数据向量的相似性度量

- 一个文档可以用数以千计的属性表示，每个记录文档中的一个关键词或短语的频度
  - 即，每个文档都被一个词频向量所表示

Document	*team*	*coach*	*hockey*	*baseball*	*soccer*	*penalty*	*score*	*win*	*loss*	*season*
Document1	5	0	3	0	2	0	0	2	0	0
Document2	3	0	2	0	1	1	0	1	0	1
Document3	0	7	0	2	1	0	0	3	0	0
Document4	0	1	0	0	1	2	2	0	3	0

- 可以看到，文档1中，hockey出现了3次，但coach却在此文档中未出现
- 其他向量对象：微阵列中的基因特征等
- 应用：信息检索，生物学分类，基因特征映射等
- 稀疏的，传统的距离度量并不好
  - 两个词频向量可能有很多公共0值，意味对应的文档许多词是不共有的，而这使得它们不相似
  - 需要一种度量，关注两个文档确实共有的词，以及这种词出现的频率
- 需要一种度量，忽略0匹配的数值数据

余弦相似性(Cont.)

- 余弦相似性：令x和y是两个待比较的向量，用余弦度量作为相似性函数

$$\mathrm{sim}(x,y) = \frac{x \cdot y}{\|x\| \|y\|}$$

- 其中•为向量点乘，对向量 $x = (x_1, x_2, \ldots, x_p)$来说

$$\|x\| = \sqrt{x_1^2 + x_2^2 + \cdots + x_p^2}$$

- 余弦值0意味着两个向量正交，没有匹配
- 越接近1，夹角越小，向量之间的匹配越大

余弦相似性(Cont.)

- Ex. 找到文档1和2的相似性.

d_1 = (5, 0, 3, 0, 2, 0, 0, 2, 0, 0)
d_2 = (3, 0, 2, 0, 1, 1, 0, 1, 0, 1)

$d_1 \bullet d_2$ = 5*3+0*0+3*2+0*0+2*1+0*1+0*1+2*1+0*0+0*1 = 25
$\|d_1\|$= (5*5+0*0+3*3+0*0+2*2+0*0+0*0+2*2+0*0+0*0)$^{0.5}$=(42)$^{0.5}$ = 6.481
$\|d_2\|$= (3*3+0*0+2*2+0*0+1*1+1*1+0*0+1*1+0*0+1*1)$^{0.5}$=(17)$^{0.5}$ = 4.12
cos(d_1, d_2) = 0.94
结果分析：两个文档高度相似

余弦相似性(Cont.)

- 当属性是二元属性时，余弦相似性函数可以用共享特征或属性来解释
- 如果 $x_i = 1$ 则意味着对象x有第i个属性
- 那么，$x \cdot y$ 是x和y共同具有的属性数，可以将余弦公式进行简单变种

$$\mathrm{sim}(x,y) = \frac{x \cdot y}{x \cdot x + y \cdot y - x \cdot y}$$

- x和y所共有属性与x和y所有具有的属性个数之间的比率
- 被称为Tanimoto系数或Tanimoto距离

Chapter 3. 认识数据

- Data Objects and Attribute Types
  数据对象与属性类型
- Basic Statistical Descriptions of Data
  数据的基本统计描述
- Data Visualization
  数据可视化
- Measuring Data Similarity and Dissimilarity
  度量数据的相似性和相异性
- Summary 小结

Summary

- Data attribute types: nominal, binary, ordinal, interval-scaled, ratio-scaled
- Many types of data sets, e.g., numerical, text, graph, Web, image.
- Gain insight into the data by:
  - Basic statistical data description: central tendency, dispersion, graphical displays
  - Data visualization: map data onto graphical primitives
  - Measure data similarity
- Above steps are the beginning of data preprocessing
- Many methods have been developed but still an active area of research