上海交通大学
SHANGHAI JIAO TONG UNIVERSITY



Data Mining and Big Data Anlysis

数据挖掘及大数据分析

Chapter4：Data Preprocessing

数据预处理：01-数据清洗

王东、张谦、丁玥

上海交通大学软件学院RFID与物联网实验室

2025年春季

Chapter 4: 数据预处理

- 概述
- 数据清洗（见数据预处理—数据清洗）
- 数据集成（见数据预处理—数据集成）
- 数据规约（见数据预处理—数据规约）
- 数据变换与数据离散化
- 小结

数据清洗 Data Cleaning

- 现实世界的数据一般都是脏的：许多潜在的不正确的数据，例如，由设备故障、人或电脑出错、传输错误引起的
  - —数据有缺失incomplete: 缺少属性值或者某些感兴趣的属性，或仅包含聚集数据
    - e.g., *Occupation* = “ ” (missing data)
  - —噪声数据noisy: 包含错误或存在偏离期望的值
    - e.g., *Salary* = “−10” (an error)
  - —不一致inconsistent: 在编码或名称上存在差异, e.g.,
    - *Age* = “42”, *Birthday* = “03/07/2010”
    - Was rating “1, 2, 3”, now rating “A, B, C”
    - 重复的记录有出入
  - —人为因素Intentional (e.g., *disguised missing* data)
    - Jan. 1 as everyone’s birthday?

缺失值Incomplete (Missing) Data

- 并不是在所有情况下都能获取数据
  - —E.g., 许多数据缺乏某些属性，比如销售数据中，顾客的收入数据
- 缺失值可能是因为
  - —设备故障
  - —不符合其他记录的数据，从而删除
  - —由于无解，数据未被输入
  - —在输入数据的时候某些数据被认为是不重要的
  - —数据变化而缺乏历史记录
- 丢失的数据可能需要被推断

如何处理缺失值?

- 忽略元组 Ignore the tuple: 当缺少类标号时通常这样做（假定挖掘任务涉及分类）—当每个属性缺失值的百分比变化很大时，它的性能很差
- 人工填写缺失值: 费事 + 不可行?
- 使用一定的内容填充
  - —全局常量: e.g., “unknown”, a new class?!
  - —使用属性的中心度量（如均值或中位数）
  - —使用与给定元组属同一类的所有样本的属性均值或总位数：更科学
    - 如果将顾客按风险等级分类，则用具有相同信用风险的顾客的平均收入替换缺失值
  - —使用最可能的值: 使用回归、贝叶斯形式化的方法或者决策树等基于推理的工具

噪声数据Noisy Data

- 噪声Noise: 被检测的变量的随机误差或方差
- 不正确的属性值 可能是因为
  - —错误的数据收集工具
  - —数据输入的问题
  - —数据传输问题
  - —技术限制
  - —不一致的命名惯例
- 这些数据问题 也需要数据清洗
  - —重复记录
  - —数据不完整
  - —数据不一致

如何处理噪声数据?

- 分箱Binning
  - —通过考察数据的“近邻”（即周围的值）来光滑有序数据值
    - 首先这些有序的值被分布到一些“箱”中
    - 接着可以 用箱均值光滑，用箱中位数光滑，用箱边界光滑

price 的排序后数据（元）：4, 8, 15, 21, 21, 24, 25, 28, 34

划分为（等深的）箱：

箱 1：4, 8, 15

箱 2：21, 21, 24

箱 3：25, 28, 34

用平均值平滑：

箱 1：9, 9, 9

箱 2：22, 22, 22

箱 3：29, 29, 29

用边界平滑：

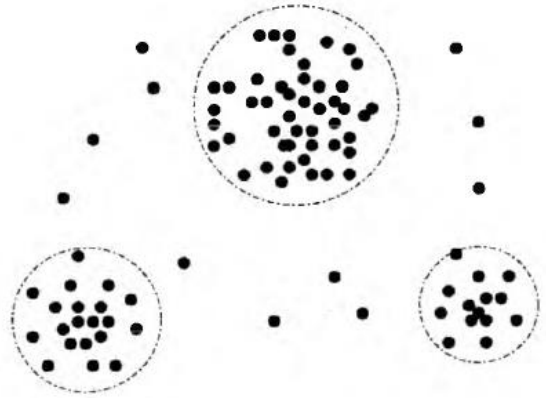
箱 1：4, 4, 15

箱 2：21, 21, 24

箱 3：25, 25, 34

如何处理噪声数据?

- 回归Regression
  - —用一个函数拟合数据来光滑数据
    - 线性回归涉及找出拟合两个属性（或变量）的“ 最佳” 直线，使得一个属性可以用来预测另一个
- 聚类Clustering
  - —删除离群点



- 计算机和人工检查结合
  - —检查可疑的值，结合人工手段 (e.g., 删除可能的离群点)

数据清洗往往花费整个数据挖掘项目工作量的大部分
强调实践！

数据清洗—ETL

1 基于ETL的数据清洗

2 ETL关键技术

3 ETL常见工具介绍

基于ETL的数据清洗



ETL的概念

ETL是英文Extract-Transform-Load的缩写，分别表示用来描述将数据从源端经过抽取（extract）、转换（transform）、加载（load）至目的端的过程，它能够对各种分布的、异构的源数据（如关系数据）进行抽取，按照预先设计的规则将不完整数据、重复数据以及错误数据等脏数据内容进行清洗，得到符合要求的“干净”数据，并加载到数据仓库中进行存储，这些“干净”数据就成为了数据分析、数据挖掘的基石

基于ETL的数据清洗



ETL的概念

常用ETL实现方式

借助ETL工具（如Pentaho Kettle）

该方式可以快速建立ETL工程，屏蔽复杂的编码任务、加快速度和降低难度，但是缺少灵活性。

编写SQL语句

该方式的优点是灵活，可以提高ETL的运行效率，但是编码复杂，对技术要求比较高。

将ETL工具和SQL语句结合使用

该方式综合了前面两种方式的优点，可以极大地提高ETL的开发速度和效率。

基于ETL的数据清洗



ETL的体系结构



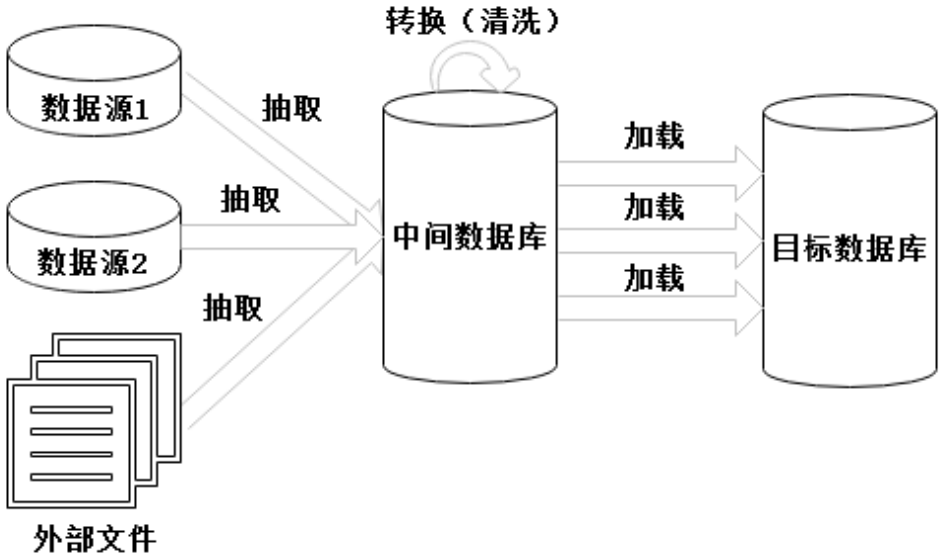
ETL主要是用来实现异构数据源数据集成的。多种数据源的所有原始数据大部分未作修改就被载入到ETL，因而，无论数据源在关系型数据库、非关系型数据库还是外部文件，集成后的数据都将被置于数据库的数据表或数据仓库的维度表中，以便在数据库内或数据仓库中作进一步地转换。

基于ETL的数据清洗



ETL的体系结构

若数据源1和数据源2均为功能较强大的DBMS，可使用SQL语句完成一部分数据清洗工作。但是，如果数据源为外部文件，无法使用SQL语句进行数据清洗工作，只能直接从数据源中抽取出来，然后在数据转换时进行数据清洗工作。因此，数据仓库中的数据清洗工作主要是在数据转换时进行。清洗好的数据将保存到目标数据库中，用于后续数据分析、数据挖掘以及商业智能。



数据清洗—ETL

1 基于ETL的数据清洗

2 ETL关键技术

3 ETL常见工具介绍

ETL的关键技术



数据的抽取



数据抽取就是从异构数据源抽取数据，但是并不是所有的数据源中的数据都有实际的价值。数据的抽取分为数据的全量抽取和数据的增量抽取。其中，全量抽取类似于数据迁移或数据复制，它将原数据表中的数据全部抽取出来；经过上次抽取后，源数据表中的数据出现变化时，就会进行增量抽取，增量抽取是抽取数据源表中新增或被修改的数据。

ETL的关键技术



数据的抽取

- 根据抽取要求，在要被抽取的数据源表上建立插入、修改、删除三个触发器，每当数据源表中数据发生变化，就被相应触发器将变化数据写入一个增量日志表中，ETL增量抽取是从增量日志中抽取，而不是直接在源表中抽取数据，同时增量日志表中抽取过的数据要及时被标记或者删除。

触发器方式

时间戳方式

在增量抽取时，抽取进程通过比较指定抽取时间与抽取源表的时间戳字段的值来决定抽取哪些数据。这种方式需要在源表中增加一个时间戳字段，系统中更新或修改源表数据的时候，也会同时修改时间戳字段的值。插入数据的时间戳是由系统时间指定。

ETL的关键技术



数据的抽取

- 全表比对方式是指在增量抽取时，ETL进行逐条比较源表和目标表的每次从源表中读取所有记录，然后逐条比较源表和目标表的记录，将变化的记录过滤读取出来。

全表比对方式

日志表方式

对于建立了业务系统的生产数据库的企业来说，可以在数据库中创建业务日志表，当特定需要监控的业务数据发生变化时，由相应的业务系统程序模块更新维护日志表的内容。增量抽取时，通过读日志表数据决定加载哪些数据及如何加载。日志表的维护需要由业务系统程序编写代码来完成。

ETL的关键技术



数据的清洗转换



数据的清洗转换是指将抽取到数据源表中的数据，根据数据仓库系统模型的要求来进行数据的清洗、转换等操作，保证来自不同系统、不同格式数据的一致性和完整性，并且要按照业务要求加载到目标表。数据的清洗转换是ETL中最为复杂的部分，主要任务是过滤掉不符合要求的数据，不符合要求的数据主要有不完整的数据、错误的数据、重复的数据三大类。

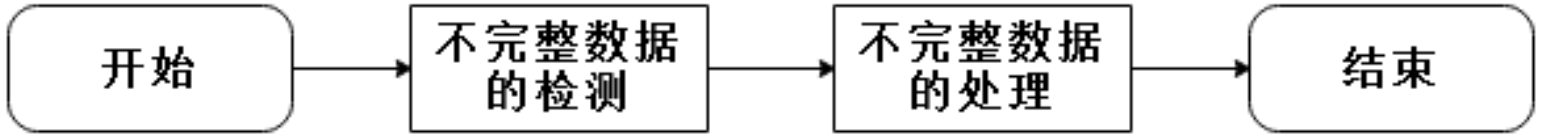
ETL的关键技术



数据的清洗转换

1．不完整的数据

当数据上报、接口调用时都会产生大量的不完整数据，不完整数据的产生是不可避免的现象，而不完整的数据对大数据环境下的决策具有一定的影响。不完整数据的清洗流程如下所示：



- 对获得的数据源进行不完整数据的检测，为后续的数据处理提供所需的数据；
- 对检测出来的不完整数据进行处理，例如修复缺失部分或全部内容的数据；
- 输出处理后的符合要求的完整数据。

ETL的关键技术



数据的清洗转换

2. 错误的数据

大数据环境下数据量的剧增使得获取到的数据源会由于各种原因存在大量的错误数据。

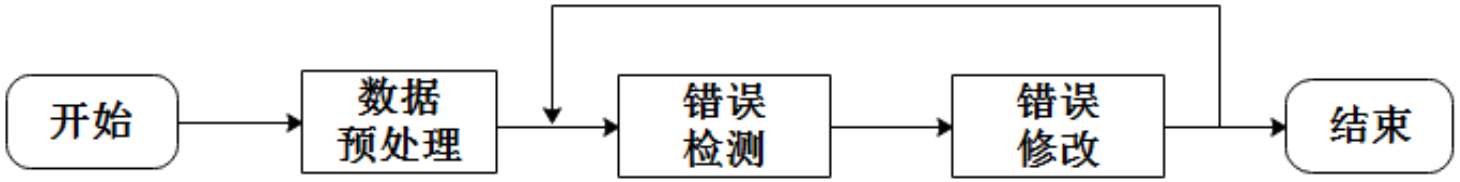
错误数据产生的原因是业务系统不够健全，在接收输入数据后没有进行过滤判断，而是直接将数据写入到后台数据库而造成的，如数值数据输成全角数字字符、字符串数据后面出现一个回车操作、日期格式不正确、日期越界等错误。错误数据清洗的过程如下图所示（见下页）。

ETL的关键技术



数据的清洗转换

2. 错误的数据



- 将数据源按照规定的数据格式进行检测，并执行数据预处理，为后续处理步骤做准备；
- 对预处理后的数据进行一致性检测，如果预处理后的数据与原始数据存在完整性不一致的问题，则通过数据修改过程使数据统一。为避免再次出现该问题，应重复进行检测与修改过程，直到符合要求为止；
- 输出修改后的数据。

ETL的关键技术



数据的清洗转换

3. 重复的数据

重复数据产生的原因较多。例如数据集成、系统重复录入等，通常表现为多条记录所表达的含义相同，或同一目标实体的记录虽然在形式上有所不同，但其描述的目标却相同。这些重复记录的数据特征并不明显，但是对数据识别和数据清洗造成很大的难度。因此，对重复记录数据进行清洗，可提高数据库使用率，降低系统消耗，并提高数据质量。

重复数据检测主要分为基于字段和基于记录的重复检测。基于字段的重复检测算法主要为编辑距离算法；基于记录的重复检测算法主要包括排序邻居算法、优先队列算法、 N-Gram 聚类算法。

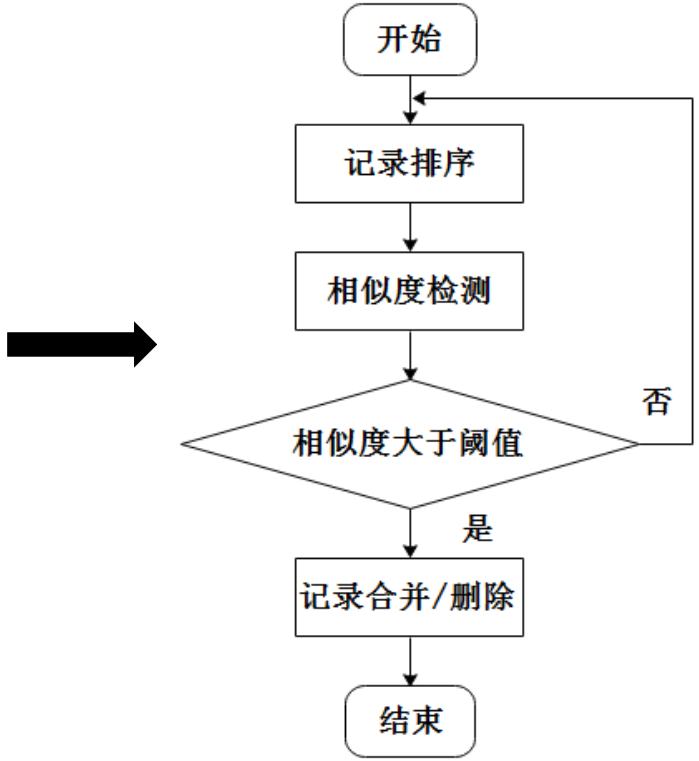
ETL的关键技术



数据的清洗转换

3. 重复的数据

采用排序合并算法清洗重复数据的流程





ETL的关键技术



数据的清洗转换

3. 重复的数据

重复数据的清洗流程主要分为四个步骤，具体如下：

- 通过对源数据库属性字段的分析，找到属性的唯一值，并根据唯一值对源数据库中的数据记录进行排序，可以选择自上而下或者自下而上顺序来排序；
- 按顺序扫描数据库中的每一条记录，并将它与相邻的记录进行比较，进行记录的相似度匹配计算输出修改后的数据；
- 如果计算出的相似度数值大于系统设定的阈值，说明该记录或连续的几条记录为相似重复记录，则进行数据记录的合并或删除操作；否则，扫描下一条数据记录，重复以上第（2）、（3）步骤；
- 当所有数据记录检测完毕后，输出清洗后的数据结果。

ETL的关键技术



数据的加载



数据加载是ETL的最后一个阶段，它的主要任务是将数据从临时数据表或文件中，加载到指定数据仓库中。一般来说，可以通过编写SQL语句和利用加载工具将数据加载到数据仓库中。ETL的数据加载和数据抽取类似，将数据加载到目标数据表或者数据仓库的过程中可分为全量加载、增量加载以及批量加载。

ETL的关键技术



数据的加载

1．全量加载

全量加载是指全表删除后再进行全部（全量）数据加载。从技术角度来说，全量加载和增量加载相比较，全量加载更为的简单。一般只需要在数据加载之前将目标表清空，再将源数据表中的数据进行导入。但是，由于数据量、系统资源和数据实时性的要求，很多情况下都需要使用增量加载机制。



ETL的关键技术



数据的加载

2. 增量加载

增量加载是指目标表仅更新源数据表中变化的数据。增量加载的关键在于如何正确的设计相应的方法，用于从源数据表中抽取增量的数据，以及变化“牵连”数据（虽没有变化，但受到变化数据影响的数据）。同时，将这些变化的和未变化但受到影响的数据，在完成相应的逻辑转换后更新到数据仓库中。

数据加载的性能和作业失败后可进行恢复重启的易维护性，需要一个有效的增量抽取机制的支持。因为在一个有效的增量抽取机制，ETL能够将业务系统中变化的数据按一定的频率准确的进行捕获，并且不会对业务系统造成太大的压力，也不会影响现有的业务。

ETL的关键技术



数据的加载

2. 增量加载

01 **时间戳方式**

即在业务表中统一添加一个字段作为时间戳，当OLAP系统更新修改业务数据时，同时也会修改时间戳字段值，这时就将更新修改的数据加载到目标表中。

02 **日志表方式**

即在OLAP系统中添加日志表，业务数据发生变化时，更新维护日志表内容。

ETL的关键技术



数据的加载

2. 增量加载

03 **全表对比方式**

即抽取所有源数据，在加载目标表之前先根据主键和字段进行数据比对，有更新的数据就进行更新或插入。

04 **全表删除插入方式**

即删除目标表中的数据，将源数据表中的数据全部加载到目标表中。

ETL的关键技术



数据的加载

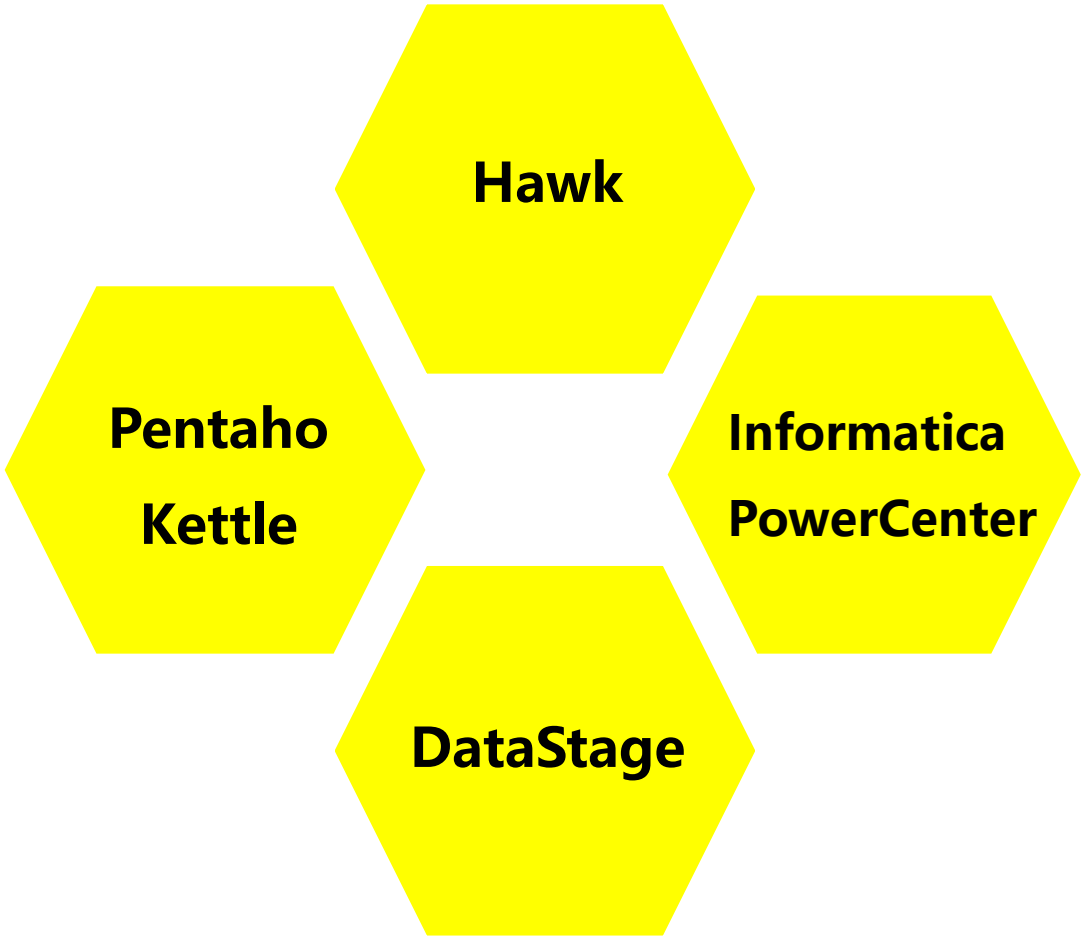
3. 批量加载

通常情况下，对于几十万条记录的数据迁移而言，采取DML（即数据操纵语言）的insert、update、delete等语句能够较好地将数据迁移到目标数据库中，然而，当数据迁移量过大时，DML语句执行时所生成的事物日志（事务日志是一个与数据库文件分开的文件，用于存储对数据库进行的所有更改，并全部记录插入、更新、删除、提交、回退和数据库模式变化）和约束条件将大大影响加载性能，故需要针对数据采取批量加载处理。

数据清洗—ETL

1. 基于ETL的数据清洗
2. ETL关键技术
3. ETL常见工具介绍

ETL常见工具介绍



ETL常见工具介绍

1. Pentaho Kettle

Kettle是一款国外免费开源的ETL工具，纯java语言编写，可以在Windows、Linux、Unix系统上运行，并且是绿色无需安装的。

Kettle中文名称叫水壶，该工具的设计理念是希望把来自不同数据库中的数据放到一个“壶”里，然后以一种指定的格式流出。Kettle拥有两种脚本文件，分别是Transformation（转换）和Job（作业），其中Transformation是用于完成数据的基础转换；而Job是完成整个工作流的控制。



ETL常见工具介绍

2. Hawk

Hawk是一种数据采集和清洗工具，依据GPL协议开源，基于C#语言编写的，并且其前端界面是使用WPF开发，支持插件扩展。

Hawk的含义为“鹰”，能够高效、准确地捕杀猎物。也就是说，Hawk能够灵活、有效地采集来自网页、数据库和文件等来源的数据，并通过可视化地拖拽操作，快速地进行生成、过滤及转换等操作。Hawk主要应用于爬虫和数据清洗等领域。



ETL常见工具介绍

3. Informatica PowerCenter

Informatica PowerCenter是Informatica公司开发的世界级的企业数据集成平台，也是业界领先的ETL工具。Informatica PowerCenter用于访问和集成几乎任何业务系统、任何格式的数据，它可按任意速度在企业内交付数据，具有高性能、高可扩展性、高可用性的特点。Informatica PowerCenter提供了多个可选的组件，以扩展Informatica PowerCenter的核心数据集成功能，这些组件包括：数据清洗和匹配、数据屏蔽、数据验证、元数据交换等。



ETL常见工具介绍

4. DataStage

IBM的InfoSphere DataStage，简称DataStage，它是一个领先的ETL平台，可跨多个企业系统集成数据。DataStage利用高性能并行框架，可根据项目需求，在云中或者本地部署ETL环境，它支持HBase、Hive、Amazon以及MongoDB等数据库的连接，可以灵活、有效的更新和管理数据继承的基础架构。



Pandas 概览

Pandas 是 Python 的核心数据分析支持库，提供了快速、灵活、明确的数据结构，旨在简单、直观地处理关系型、标记型数据。Pandas 的目标是成为 Python 数据分析实践与实战的必备高级工具，其长远目标是成为**最强大、最灵活、可以支持任何语言的开源数据分析工具**。经过多年不懈的努力，Pandas 离这个目标已经越来越近了。

Pandas 适用于处理以下类型的数据：

- 与 SQL 或 Excel 表类似的，含异构列的表格数据;
- 有序和无序（非固定频率）的时间序列数据;
- 带行列标签的矩阵数据，包括同构或异构型数据;
- 任意其它形式的观测、统计数据集, 数据转入 Pandas 数据结构时不必事先标记。

Pandas 的主要数据结构是 Series（一维数据）与 DataFrame（二维数据），这两种数据结构足以处理金融、统计、社会科学、工程等领域里的大多数典型用例。对于 R 用户，DataFrame 提供了比 R 语言 data.frame 更丰富的功能。Pandas 基于 NumPy 开发，可以与其它第三方科学计算支持库完美集成。

Pandas 就像一把万能瑞士军刀，下面仅列出了它的部分优势：

- 处理浮点与非浮点数据里的**缺失数据**，表示为 `NaN`；
- 大小可变：**插入或删除** DataFrame 等多维对象的列；
- 自动、显式**数据对齐**：显式地将对象与一组标签对齐，也可以忽略标签，在 Series、DataFrame 计算时自动与数据对齐；
- 强大、灵活的**分组**（group by）功能：**拆分-应用-组合**数据集，聚合、转换数据；
- 把 Python 和 NumPy 数据结构里不规则、不同索引的数据**轻松**地转换为 DataFrame 对象；
- 基于智能标签，对大型数据集进行**切片**、**花式索引**、**子集分解**等操作；
- 直观地**合并**（merge）、**连接**（join）数据集；
- 灵活地**重塑**（reshape）、**透视**（pivot）数据集；
- **轴**支持结构化标签：一个刻度支持多个标签；
- 成熟的 IO 工具：读取**文本文件**（CSV 等支持分隔符的文件）、Excel 文件、数据库等来源的数据，利用超快的 **HDF5** 格式保存 / 加载数据；
- **时间序列**：支持日期范围生成、频率转换、移动窗口统计、移动窗口线性回归、日期位移等时间序列功能。

这些功能主要是为了解决其它编程语言、科研环境的痛点。处理数据一般分为几个阶段：数据整理与清洗、数据分析与建模、数据可视化与制表，Pandas 是处理数据的理想工具。

其它说明：

- Pandas 速度**很快**。Pandas 的很多底层算法都用 Cython 优化过。然而，为了保持通用性，必然要牺牲一些性能，如果专注某一功能，完全可以开发出比 Pandas 更快的专用工具。
- Pandas 是 statsmodels 的依赖项，因此，Pandas 也是 Python 中统计计算生态系统的重要组成部分。
- Pandas 已广泛应用于金融领域。

Pandas: 强大的 Python 数据分析支持库

版本：0.25.3 **日期**：2019 年 10 月 31 日

下载文档（英文）：PDF Version | Zipped HTML

实用链接: 二进制安装包 | 源码仓库 | 问题和想法 | 常见问题 | 邮件列表

Pandas 是基于 BSD 许可的开源支持库，为 Python 提供了高性能、易使用的数据结构与数据分析工具。

更多内容，请参阅 Pandas 概览。

- v0.25.3 版新特性（发布于：2019 年 10 月 31 日）
- 安装
- 快速入门
- Pandas 概览
- 十分钟入门 Pandas
- 基础用法
- 数据结构简介
- 与其它工具比较
- 教程
- 用户指南
- IO 工具（文本、CSV、HDF5 ...）
- 索引与选择数据
- 多层索引与高级索引
- 合并、连接、结合
- 重塑与数据透视表
- 重塑与数据透视表
- 处理文本数据
- 处理缺失数据
- 分类数据
- 可空整型数据
- 可视化
- 计算工具
- 分组操作：拆分-应用-组合
- 时间序列 / 日期
- 时间差
- 样式
- 选项与设置
- 性能优化
- 稀疏数据结构
- 常见问题（FAQ）
- 烹饪指南
- Pandas 生态系统
- API 参考手册
- [输入 / 输出](https://pandas.pydata.org/pandas-docs/stable/reference/io/.html
- 通用函数
- Series
- DataFrame
- Pandas 数组
- Panel
- 索引
- 日期偏移
- 窗口函数
- 分组
- 重采样