

Data Mining and Big Data Anlysis

数据挖掘及大数据分析

Chpter4：Data Preprocessing

数据预处理：数据规约

王东、张谦、丁玥

上海交通大学软件学院RFID与物联网实验室

2025年春季

Chapter 4: 数据预处理

- 概述
  - —数据质量
  - —数据预处理的主要任务
- 数据清洗
- 数据集成
- 数据规约
- 数据变换与数据离散化
- 小结


中文版累计热销超过5万册，众多世界名校数据挖掘参考书
本书源自斯坦福大学“CS246：海量数据挖掘”“CS224W：图机器学习”和“CS341：项目实战课”三门课程的内容。书中以海量数据挖掘和机器学习为重点，全面分析并实现了各种常用的数据挖掘算法，同时介绍了目前Web应用的许多重要话题。
这一版不仅新增一章，专门探讨神经网络和深度学习这一主题，还在上一版基础上扩充了社会网络分析和决策树的相关内容，同时更新了其他一些内容。
分布式文件系统以及MapReduce
相似性搜索
数据流处理以及特殊情况专用处理算法
搜索引擎技术，如谷歌的PageRank
频繁项集挖掘
大规模高维数据集的聚类算法
广告管理系统和推荐系统
社会网络图挖掘
降维处理，如SVD和CUR分解
大规模机器学习
深度神经网络
Mining of Massive Datasets
斯坦福
数据挖掘教程
（第3版）
CAMBRIDGE UNIVERSITY PRESS
www.cambridge.org
图灵社区：iTuring.cn
分类建议：计算机 / 数据挖掘
人民邮电出版社网址：www.ptpress.com.cn
扫码加入人工智能交流群
定价：129.00元
斯坦福
数据挖掘教程
（第3版）
[美] 尤雷·莱斯科夫（Jure Leskovec） 阿南德·拉贾拉曼（Anand Rajaraman） 杰弗里·大卫·厄尔曼（Jeffrey David Ullman） 著
王斌 王达侃 译
人民邮电出版社
TURING 图灵程序设计丛书
CAMBRIDGE
CS246 海量数据挖掘
CS224W 图机器学习
CS341 项目实战课
Mining of Massive Datasets
Third Edition
斯坦福
数据挖掘教程
（第3版）
中国工信出版集团
人民邮电出版社 POSTS & TELECOM PRESS

7.6.3 桶的初始化 …… 219
7.6.4 桶合并 …… 219
7.6.5 查询应答 …… 221
7.6.6 并行环境下的聚类 …… 221
7.6.7 习题 …… 222
7.7 小结 …… 222
7.8 参考文献 …… 224

第 8 章 Web 广告 …… 226

8.1 在线广告相关问题 …… 226
8.1.1 广告机会 …… 226
8.1.2 直投广告 …… 227
8.1.3 展示广告的相关问题 …… 227
8.2 在线算法 …… 228
8.2.1 在线和离线算法 …… 228
8.2.2 贪心算法 …… 229
8.2.3 竞争率 …… 230
8.2.4 习题 …… 230
8.3 广告匹配问题 …… 231
8.3.1 匹配及完美匹配 …… 231
8.3.2 极大匹配贪心算法 …… 232
8.3.3 贪心匹配算法的竞争率 …… 232
8.3.4 习题 …… 233
8.4 adwords 问题 …… 233
8.4.1 搜索广告的历史 …… 234
8.4.2 adwords 问题的定义 …… 234
8.4.3 adwords 问题的贪心方法 …… 235
8.4.4 Balance 算法 …… 236
8.4.5 Balance 算法竞争率的一个下界 …… 236
8.4.6 多投标者的 Balance 算法 …… 238
8.4.7 一般性的 Balance 算法 …… 239
8.4.8 adwords 问题的最后论述 …… 240
8.4.9 习题 …… 240
8.5 adwords 的实现 …… 240
8.5.1 投标和搜索查询的匹配 …… 241
8.5.2 更复杂的匹配问题 …… 241
8.5.3 文档和投标之间的匹配算法 …… 242
8.6 小结 …… 243
8.7 参考文献 …… 245

第 9 章 推荐系统 …… 246

9.1 推荐系统的模型 …… 246
9.1.1 效用矩阵 …… 246
9.1.2 长尾现象 …… 247
9.1.3 推荐系统的应用 …… 249
9.1.4 效用矩阵的填充 …… 249
9.2 基于内容的推荐 …… 249
9.2.1 项模型 …… 250
9.2.2 文档的特征发现 …… 250
9.2.3 基于 Tag 的项特征获取 …… 251
9.2.4 项模型的表示 …… 252
9.2.5 用户模型 …… 253
9.2.6 基于内容的项推荐 …… 254
9.2.7 分类算法 …… 254
9.2.8 习题 …… 256
9.3 协同过滤 …… 257
9.3.1 相似度计算 …… 257
9.3.2 相似度对偶性 …… 259
9.3.3 用户聚类和项聚类 …… 261
9.3.4 习题 …… 262
9.4 降维处理 …… 262
9.4.1 UV 分解 …… 262
9.4.2 RMSE …… 263
9.4.3 UV 分解的增量式计算 …… 264
9.4.4 对任一元素的优化 …… 267
9.4.5 一个完整 UV 分解算法的构建 …… 267
9.4.6 习题 …… 269
9.5 Netflix 竞赛 …… 270
9.6 小结 …… 271
9.7 参考文献 …… 272

第 10 章 社会网络图挖掘 …… 273

10.1 将社会网络看成图 …… 273
10.1.1 社会网络的概念 …… 273
10.1.2 将社会网络看成图 …… 274
10.1.3 各种社会网络的例子 …… 275
10.1.4 多类型节点构成的图 …… 276
10.1.5 习题 …… 277
10.2 社会网络图的聚类 …… 277
10.2.1 社会网络图的距离计算 …… 277

10.2.2 应用标准的聚类算法 …… 278
10.2.3 中介度 …… 279
10.2.4 Girvan-Newman 算法 …… 279
10.2.5 利用中介度来发现社区 …… 282
10.2.6 习题 …… 283
10.3 社区的直接发现 …… 283
10.3.1 团的发现 …… 284
10.3.2 完全二部图 …… 284
10.3.3 发现完全二部子图 …… 285
10.3.4 完全二部子图一定存在的原因 …… 285
10.3.5 习题 …… 287
10.4 图划分 …… 287
10.4.1 图划分的好坏标准 …… 288
10.4.2 归一化割 …… 288
10.4.3 描述图的一些矩阵 …… 289
10.4.4 拉普拉斯矩阵的特征值 …… 290
10.4.5 其他图划分方法 …… 292
10.4.6 习题 …… 292
10.5 重叠社区的发现 …… 293
10.5.1 社区的本质 …… 293
10.5.2 极大似然估计 …… 294
10.5.3 关系图模型 …… 295
10.5.4 社区分配的离散优化 …… 296
10.5.5 避免成员隶属关系的离散式变化 …… 297
10.5.6 习题 …… 298
10.6 Simrank …… 299
10.6.1 社会网络上的随机游走者 …… 299
10.6.2 带重启的随机游走 …… 300
10.6.3 近似 Simrank …… 302
10.6.4 近似 Simrank 有效的原因 …… 303
10.6.5 Simrank 在社区发现中的应用 …… 304
10.6.6 习题 …… 305
10.7 三角形计数问题 …… 306
10.7.1 为什么要对三角形计数 …… 306
10.7.2 一个寻找三角形的算法 …… 307
10.7.3 三角形寻找算法的最优性 …… 308
10.7.4 基于 MapReduce 寻找三角形 …… 308
10.7.5 使用更少的 Reduce 任务 …… 310
10.7.6 习题 …… 310
10.8 图的邻居性质 …… 311
10.8.1 有向图和邻居 …… 311
10.8.2 图的直径 …… 312
10.8.3 传递闭包和可达性 …… 313
10.8.4 基于 MapReduce 的可达性计算 …… 314
10.8.5 半朴素求值 …… 315
10.8.6 线性传递闭包 …… 315
10.8.7 基于双重递归的传递闭包 …… 316
10.8.8 智能传递闭包 …… 317
10.8.9 多种方法的比较 …… 319
10.8.10 基于图归约的传递闭包 …… 320
10.8.11 邻居规模的近似计算 …… 321
10.8.12 习题 …… 323
10.9 小结 …… 324
10.10 参考文献 …… 326

第 11 章 降维处理 …… 328

11.1 特征值和特征向量 …… 328
11.1.1 定义 …… 328
11.1.2 特征值与特征向量计算 …… 329
11.1.3 基于幂迭代方法的特征对求解 …… 331
11.1.4 特征向量矩阵 …… 333
11.1.5 习题 …… 333
11.2 主成分分析 …… 334
11.2.1 一个示例 …… 334
11.2.2 利用特征向量进行降维 …… 337
11.2.3 距离矩阵 …… 338
11.2.4 习题 …… 339
11.3 奇异值分解 …… 339
11.3.1 SVD 的定义 …… 339
11.3.2 SVD 解析 …… 341
11.3.3 基于 SVD 的降维 …… 342
11.3.4 将较低奇异值置为 0 后有效的原因 …… 343
11.3.5 使用概念进行查询处理 …… 344

上海交通大学RFID与物联网研究所

数据规约策略 Strategies

- 数据规约Data reduction: 获取数据集减少后的表示，它小得多，但仍接近于保持原始数据的分析结果
- 为何进行数据规约? — 数据库database/数据仓库data warehouse 可能存储了数兆兆字节terabytes. 复杂的数据分析可能花费非常长的时间在该完整的数据集上运行
- 数据规约策略
  - —维规约Dimensionality reduction, e.g., 删除不重要的属性
    - 小波变换 Wavelet transforms
    - 主成分分析 Principal Components Analysis (PCA)
    - 属性子集选择 Feature subset selection, feature creation
  - —数量规约Numerosity reduction (也称: 数据规约Data Reduction)
    - 回归Regression 和 对数-线性模型Log-Linear Models
    - 直方图Histograms, 聚类clustering, 抽样sampling
    - 数据立方体聚集Data cube aggregation
  - —数据压缩Data compression

数据规约策略 Strategies

—维规约Dimensionality reduction, e.g., 删除不重要的属性
- 小波变换 Wavelet transforms
- 主成分分析 Principal Components Analysis (PCA)
- 属性子集选择 Feature subset selection, feature creation

—数量规约Numerosity reduction (也称: 数据规约Data Reduction)
- 回归Regression 和 对数-线性模型Log-Linear Models
- 直方图Histograms, 聚类clustering, 抽样sampling
- 数据立方体聚集Data cube aggregation

—数据压缩Data compression

数据规约1: 维规约Dimensionality Reduction

- 维数灾难Curse of dimensionality
  - 当维数增长时，数据变得越来越稀疏
  - 在聚类和离群点分析中至关重要的点之间的密度和距离，变得不太有意义
  - 子空间的可能的组合将成倍增长
- 维规约Dimensionality reduction
  - 防止维数灾难
  - 有助于消除不相关的功能irrelevant features和降低噪音reduce noise
  - 减少数据挖掘过程中需要的时间和空间成本
  - 更容易可视化Allow easier visualization
- 维规约技术
  - 小波变换 Wavelet transforms
  - 主成分分析 Principal Component Analysis
  - 监督和非线性技术Supervised and nonlinear techniques (如属性选择 feature selection)

教材中P67内容如何理解？

- 离散小波变换的过程使用一种层次金字塔算法，它在每次迭代时将数据减半，导致计算速度很快。该方法如下：
  - —输入数据向量的长度L必须是2 的整数幂。必要时，通过在数据向量后添加0，这一条件可以满足L>=n。
  - —每个变换涉及应用两个函数。第一个使用某种数据光滑，如求和或加权平均。第二个进行加权差分，提取数据的细节特征。
  - —两个函数作用于X中的数据点对，即作用于所有的测量对（X_{2i}，X_{2i+1}).这导致两个长度为L/2 的数据集。一般而言，它们分别代表输入数据的光滑后的版本或低频版本和它的高频内容。
  - —两个函数递归地作用于前面循环得到的数据集，直到得到的结果数据集的长度为2。
  - —由以上迭代得到的数据集中选择的值被指定为数据变换的小波系数。

附录2

小波变换

数据规约1: 维规约Dimensionality Reduction

- 维数灾难Curse of dimensionality
  - 当维数增长时, 数据变得越来越稀疏
  - 在聚类和离群点分析中至关重要的点之间的密度和距离，变得不太有意义
  - 子空间的可能的组合将成倍增长
- 维规约Dimensionality reduction
  - 防止维数灾难
  - 有助于消除不相关的功能irrelevant features和降低噪音reduce noise
  - 减少数据挖掘过程中需要的时间和空间成本
  - 更容易可视化Allow easier visualization
- 维规约技术
  - 小波变换 Wavelet transforms
  - 主成分分析 Principal Component Analysis
  - 监督和非线性技术Supervised and nonlinear techniques (如属性选择 feature selection)

如何理解教材P68主成分分析步骤?

- 给定一个n维的N个数据向量，找到$k \leq n$ 个正交向量（主成分）去表示原有的数据
  - —对输入数据规范化，使得每个属性都落入相同的空间
  - —计算k个标准正交向量，作为规范化输入数据的基（主成分）
  - —每个输入的向量都是这k个向量的线性组合
  - —对主成分按“重要性”或强度降序排列。
  - —既然主成分根据已降序排列，因此可以通过去掉较弱的成分（即方差较小的那些）来规约数据
- 只适用于数值数据

附录1

主成份分析

数据规约1: 维规约Dimensionality Reduction

- 维数灾难Curse of dimensionality
  - 当维数增长时, 数据变得越来越稀疏
  - 在聚类和离群点分析中至关重要的点之间的密度和距离，变得不太有意义
  - 子空间的可能的组合将成倍增长
- 维规约Dimensionality reduction
  - 防止维数灾难
  - 有助于消除不相关的功能irrelevant features和降低噪音reduce noise
  - 减少数据挖掘过程中需要的时间和空间成本
  - 更容易可视化Allow easier visualization
- 维规约技术
  - 小波变换 Wavelet transforms
  - 主成分分析 Principal Component Analysis
  - 监督和非线性技术Supervised and nonlinear techniques (如属性选择 feature selection)

属性子集选择Attribute Subset Selection

- 另一种减少数据维度的方法
- 冗余属性
  - —在一个或多个属性中重复包含信息
  - —**E.g., purchase price of a product and the amount of sales tax paid**
- 无关属性
  - —包含与数据挖掘任务无关的信息
  - —**E.g., students' ID is often irrelevant to the task of predicting students' GPA**

在属性选择中采用启发式搜索

- 对于d个属性， 有2^d 个可能的子集
- 典型的启发式属性选择方法:
  - —通过统计显著性检验来确定最好的属性，这里假定属性是相互独立的
  - —逐步向前选择 **Best step-wise feature selection:**
    - **The best single-attribute is picked first**
    - **Then next best attribute condition to the first, ...**
  - —逐步向后删除 **Step-wise attribute elimination:**
    - **Repeatedly eliminate the worst attribute**
  - —逐步向前选择和逐步向后删除的组合 **Best combined attribute selection and elimination**
  - —决策树归纳 **Optimal branch and bound:**
    - **Use attribute elimination and backtracking**

属性构造 (Feature Generation)

- 通过创建新的属性，以便比原始属性更有效地获取数据集中的重要信息
- 三个通用方法
  - —属性提取Attribute extraction
    - 特定领域Domain-specific
  - —将数据映射到新的空间Mapping data to new space (see: data reduction)
    - E.g., 傅里叶变换，小波变换
  - —属性建设Attribute construction
    - 属性合并 Combining features
    - 数据离散化 Data discretization

数据规约策略 Strategies

—维规约Dimensionality reduction, e.g., 删除不重要的属性
- 小波变换 Wavelet transforms
- 主成分分析 Principal Components Analysis (PCA)
- 属性子集选择 Feature subset selection, feature creation

—数量规约Numerosity reduction (也称: 数据规约Data Reduction)
- 回归Regression 和 对数-线性模型Log-Linear Models
- 直方图Histograms, 聚类clustering, 抽样sampling
- 数据立方体聚集Data cube aggregation

—数据压缩Data compression

数据规约2: 数量规约Numerosity Reduction

- 通过选择替代的，更小的数据形式表示来减少数据量
- 参数化方法 **Parametric methods (e.g., 回归)**
  - —使用模型估计数据，使得一般只需要存放模型参数，而不是实际数据（离群点可能也要存放）
  - —**Ex.: 对数-线性模型 Log-linear models**
- 非参数方法 **Non-parametric methods**
  - —不用模型估计
  - —包括: 直方图 **histograms, 聚类 clustering, 抽样sampling, …**

数据规约策略

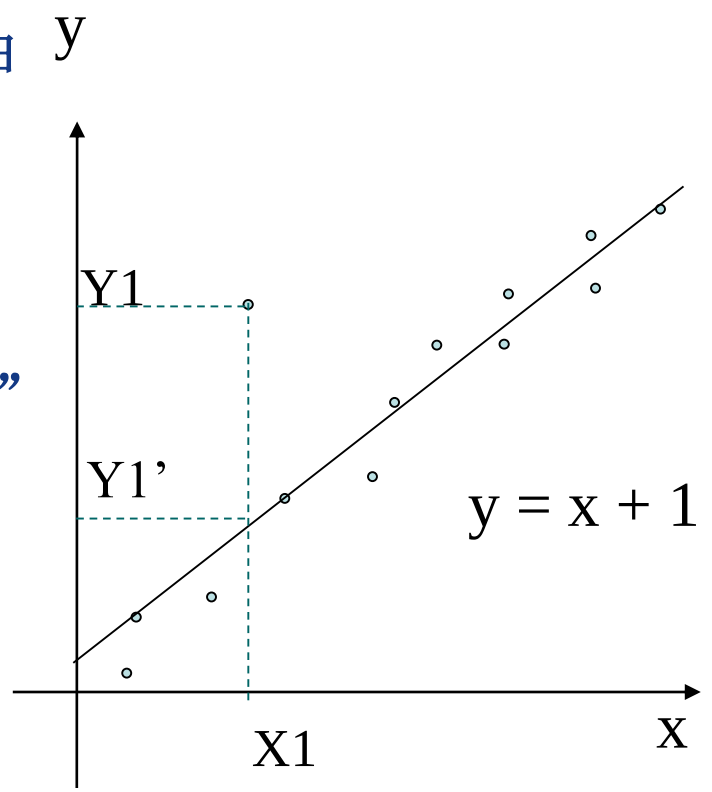
- 维规约Dimensionality reduction, e.g., 删除不重要的属性
  - 小波变换 Wavelet transforms
  - 主成分分析 Principal Components Analysis (PCA)
  - 属性子集选择 Feature subset selection, feature creation
- 数量规约Numerosity reduction (也称: 数据规约Data Reduction)
  - 回归Regression 和 对数-线性模型Log-Linear Models
  - 直方图Histograms, 聚类clustering, 抽样sampling
  - 数据立方体聚集Data cube aggregation
- 数据压缩Data compression

回归和对数线性模型：参数化数据规约

- 线性回归
  - —对数据建模，使之拟合到一条直线
  - —通常使用最小二乘法 **least-square method**
- 多元回归 **Multiple regression**
  - —允许用两个或多个自变量的线性函数对因变量Y建模
- 对数线性模型 **Log-linear model**
  - —近似离散的多维概率分布

回归分析Regression Analysis

- 回归分析Regression analysis: 建模和分析由一个或多个自变量（亦称解释变量或预测变量）和一个因变量（也称为响应变量或测量）组成的数值数据的技术的总称
- 估计参数，以便提供对数据的“最佳配合”
- 最常见、最合适的是通过使用最小二乘法估计的，但其它标准也被用于预测（包括时间序列数据的预测）、推理、假设测试和因果关系的建模



回归分析和对数线性模型

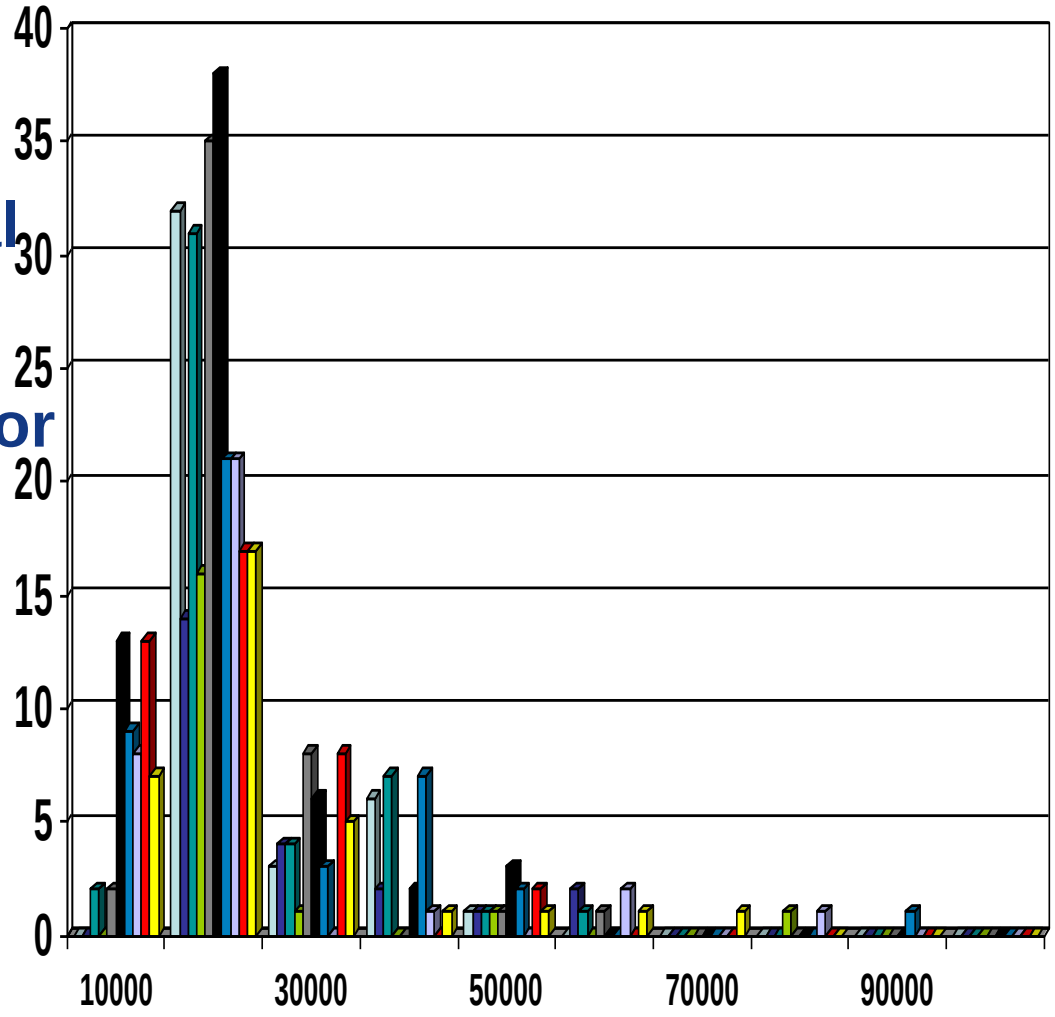
- 线性回归Linear regression: $Y = w X + b$
  - 回归系数w and b根据现有的数据进行估计
  - 根据已知$Y_1, Y_2, \ldots, X_1, X_2, \ldots$使用最小二乘法
- 多元回归Multiple regression: $Y = b_0 + b_1 X_1 + b_2 X_2$
  - 许多非线性函数可转化为上述公式
- 对数线性模型Log-linear models:
  - 近似离散的多维概率分布
  - 给定n维元组的集合，可以把每个元组看作n维空间的点。使用对数线性模型，基于维组合的一个较小子集，估计多维空间中每个点的概率，使得高维空间可以由低维空间来构造
  - 可用于维规约和数据光滑

数据规约策略

- 维规约Dimensionality reduction, e.g., 删除不重要的属性
  - 小波变换 Wavelet transforms
  - 主成分分析 Principal Components Analysis (PCA)
  - 属性子集选择 Feature subset selection, feature creation
- 数量规约Numerosity reduction (也称: 数据规约Data Reduction)
  - 回归Regression 和 对数-线性模型Log-Linear Models
  - 直方图Histograms, 聚类clustering, 抽样sampling
  - 数据立方体聚集Data cube aggregation
- 数据压缩Data compression

直方图分析Histogram Analysis

- 将数据划分成子集
- 分区规则:
  - —等宽Equal-width: equal bucket range
  - —等频Equal-frequency (or equal-depth)



聚类 Clustering

- 根据相似度，将数据集划分成簇，只记录簇的质心和直径
- 如果数据能够被聚类，则非常高效
- 可以层次聚类和被存储在多维索引树结构
- 有许多聚类定义以及算法的选择
- 在Chapter 10将详细深入学习聚类算法

抽样Sampling

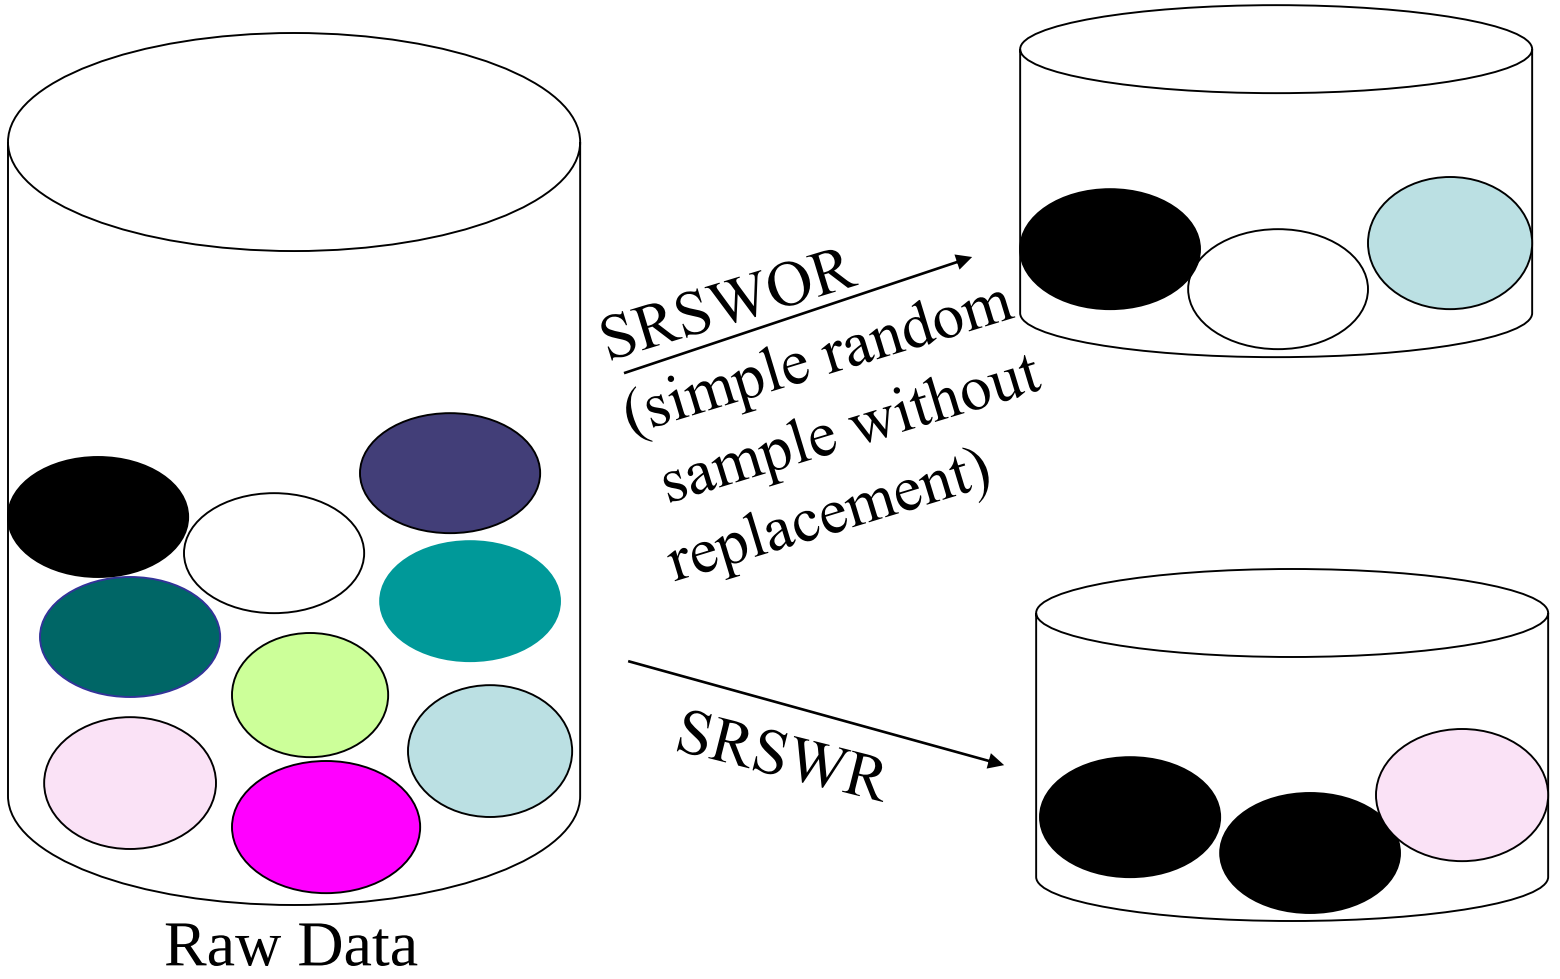
- 抽样Sampling: 获得小样本 **s** 表达大数据集 ***N***
- 挖掘算法的复杂度可能亚线性（**sub-linear**）于数据大小
- 主要准则: 选出数据集中有代表性的子集
  - —简单随机抽样可能有偏差的存在，表现很差
  - —开发自适应采样方法, **e.g.**, 分层抽样

- 注意: 抽样方法可能不会减少数据库的读写

抽样种类

- 简单随机抽样 Simple random sampling
  - —There is an equal probability of selecting any particular item
- 无放回简单随机抽样 Sampling without replacement
  - —Once an object is selected, it is removed from the population
- 有放回简单随机抽样 Sampling with replacement
  - —A selected object is not removed from the population
- 簇抽样
- 分层抽样Stratified sampling:
  - —Partition the data set, and draw samples from each partition (proportionally, i.e., approximately the same percentage of the data)
  - —Used in conjunction with skewed data

Sampling: With or without Replacement



数据规约策略

- 维规约Dimensionality reduction, e.g., 删除不重要的属性
  - 小波变换 Wavelet transforms
  - 主成分分析 Principal Components Analysis (PCA)
  - 属性子集选择 Feature subset selection, feature creation
- 数量规约Numerosity reduction (也称: 数据规约Data Reduction)
  - 回归Regression 和 对数-线性模型Log-Linear Models
  - 直方图Histograms, 聚类clustering, 抽样sampling
  - 数据立方体聚集Data cube aggregation
- 数据压缩Data compression

数据立方体聚集Data Cube Aggregation

- 数据立方体的最低抽象层（基本方体）
  - —对感兴趣个体的数据汇总
  - —E.g., sales and customer
- 在多维数据集的多个层面聚集
  - —进一步减少需要处理的数据的大小
- 参考适当的水平
  - —使用足以满足任务的最小表示
- 如果可能的话，关于汇总信息的查询应该使用数据立方体来回答

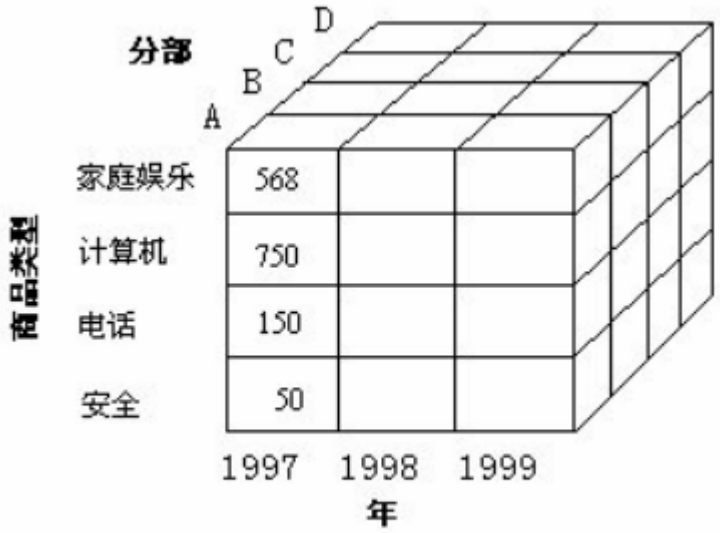


图 3.5　AllElectronics 销售数据方

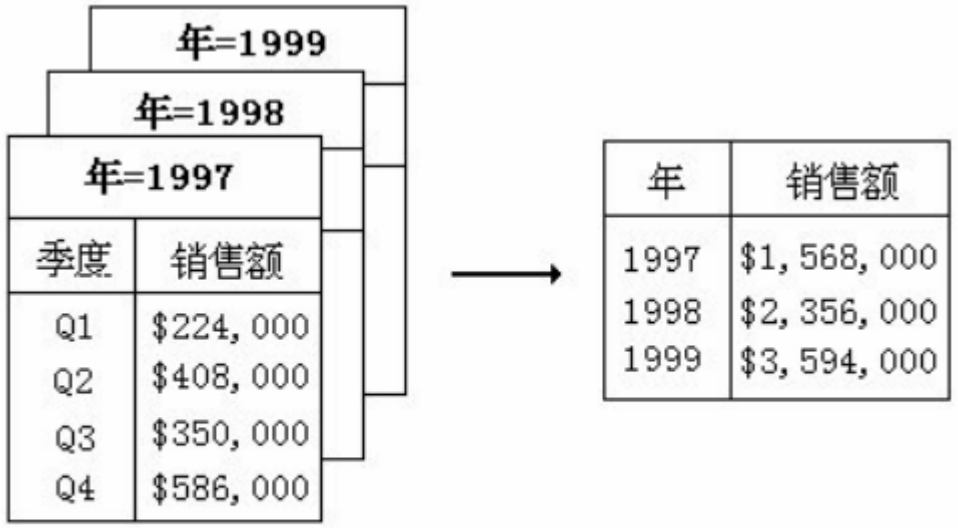


图 3.4　AllElectronics 1997 年到 1999 年的销售数据。左部销售数据按季度显示，右部数据聚集以提供年销售额

数据规约策略 Strategies

—维规约Dimensionality reduction, e.g., 删除不重要的属性

- 小波变换 Wavelet transforms
- 主成分分析 Principal Components Analysis (PCA)
- 属性子集选择 Feature subset selection, feature creation

—数量规约Numerosity reduction (也称: 数据规约Data Reduction)

- 回归Regression 和 对数-线性模型Log-Linear Models
- 直方图Histograms, 聚类clustering, 抽样sampling
- 数据立方体聚集Data cube aggregation

—数据压缩Data compression

数据规约3: 数据压缩

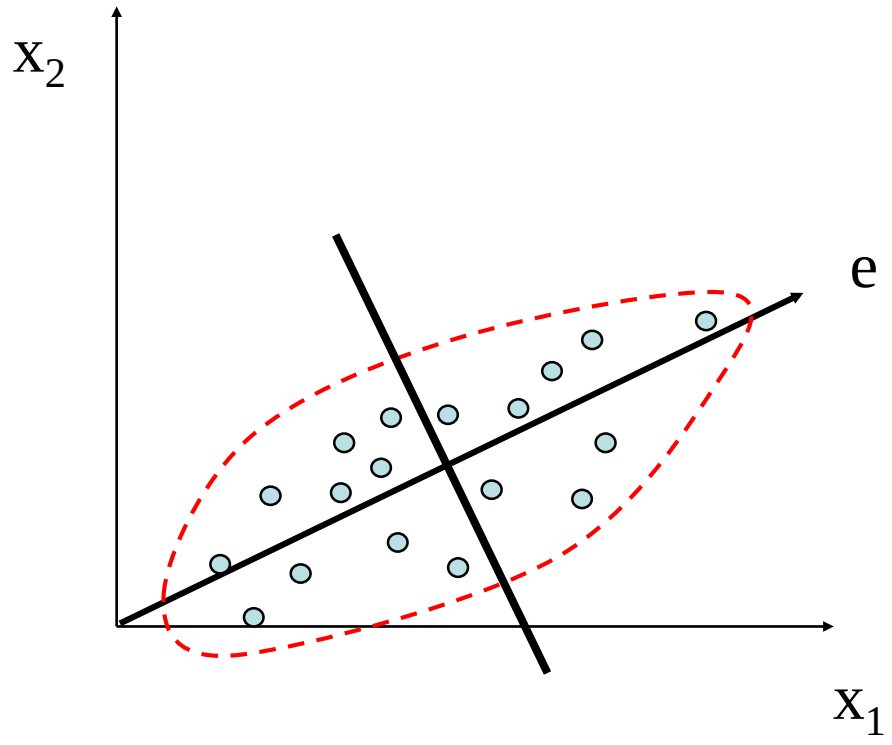
- 字符串压缩String compression
  - —There are extensive theories and well-tuned algorithms
  - —Typically lossless, but only limited manipulation is possible without expansion
- 视频/音频压缩 Audio/video compression
  - —Typically lossy compression, with progressive refinement
  - —Sometimes small fragments of signal can be reconstructed without reconstructing the whole
- Time sequence is not audio
  - —Typically short and vary slowly with time
- 维规约和数量规约也可以视为某种形式的数据压缩

附录1c

主成份分析

主成分分析 （ Principal Components Analysis ,PCA）

- 寻找一个最能捕捉到数据中数值变化的维
- 原数据投影到一个小得多的空间上，导致维规约



主成分分析法
（Principal Components Analysis,PCA）

- 主成分分析法概述
- 主成分分析的基本原理
- 主成分分析的计算步骤

什么是主成分分析法？

- 主成分分析法（ Principal Components Analysis ）和因子分析法（Factor Analysis）就是把变量维数降低以便于描述、理解和分析的方法
- 主成分分析也称为主分量分析，是一种通过降维来简化数据结构的方法：如何把多个变量化为少数几个综合变量（综合指标），而这几个综合变量可以反映原来多个变量的大部分信息，所含的信息又互不重叠，即它们之间要相互独立，互不相关
- 这些综合变量就叫因子或主成分，它是不可观测的，即它不是具体的变量,只是几个指标的综合

一个例子

- 53个学生的数学、物理、化学、语文、历史、英语的成绩如下表（部分）

学生代码	数学	物理	化学	语文	历史	英语
1	65	61	72	84	81	79
2	77	77	76	64	70	55
3	67	63	49	65	67	57
4	80	69	75	74	74	63
5	74	70	80	84	81	74
6	78	84	75	62	71	64
7	66	71	67	52	65	57
8	77	71	57	72	86	71
9	83	100	79	41	67	50
…	…	…	…	…	…	…

- **能不能把这个数据表中的6个变量用一两个综合变量来表示呢？**
- **这一两个综合变量包含有多少原来的信息呢？**

一个例子

- 事实上，以上问题在平时的研究中，也经常遇到。它所涉及的问题可以推广到对企业、对学校、对区域进行**分析、评价、排序和分类等**
- 比如对n个样本进行综合评价，可选的描述样本特征的指标很多，而这些指标往往存在**一定的相关性**（既不完全独立，又不完全相关），这就给研究带来很大不便

—若选指标太多，会增加分析问题的难度与复杂性

—选指标太少，有可能会漏掉对样本影响较大的指标，影响结果的可靠性

解决方案：

在相关分析的基础上，采用主成分分析法找到几个新的相互独立的综合指标，达到既减少指标数量、又能区分样本间差异的目的

主成分分析法起源

- 主成分概念首先由 Karl Pearson在1901年引进，当时只对非随机变量来讨论。1933年Hotelling将这个概念推广到随机变量
- 一项十分著名的工作是美国的统计学家斯通(Stone)在1947年关于国民经济的研究
  - —他曾利用美国1929—1938年各年的数据，得到了17个反映国民收入与支出的变量要素，例如雇主补贴、消费资料和生产资料、纯公共支出、净增库存、股息、利息外贸平衡等等
  - —进行主成分分析后，竟以97.4%的精度，用三新变量就取代了原17个变量。根据经济学知识，斯通给这三个新变量分别命名为总收入F1、总收入变化率F2和经济发展或衰退的趋势F3

主成分分析法
（Principal Components Analysis,PCA）

- 主成分分析法概述
- 主成分分析的基本原理
- 主成分分析的计算步骤

主成分分析的基本原理

- （一）主成分分析的几何解释
- （二）主成分分析的数学模型

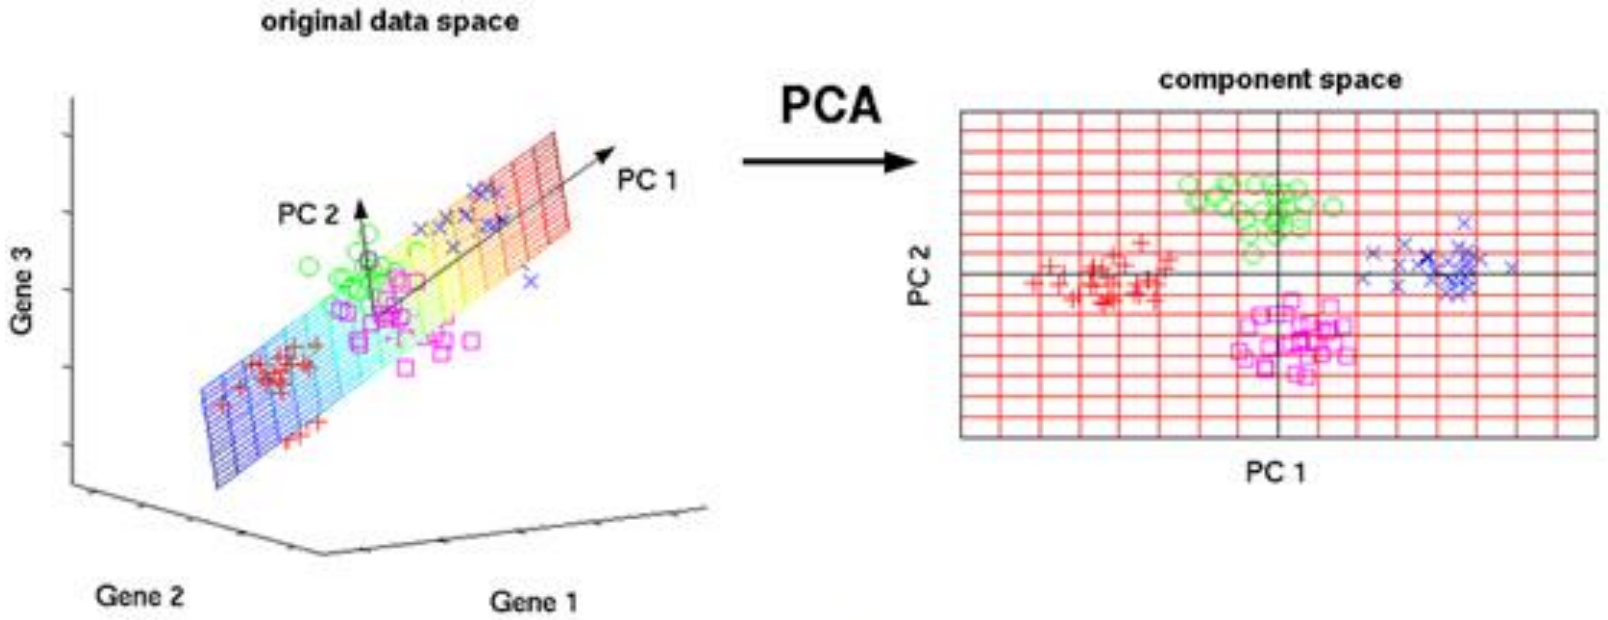


图 1

样本均值

$$\overline{Y_i} = \frac{1}{n}\sum_{k=1}^{n} Y_{ki}$$

样本标准差

$$S_i = \sqrt{\frac{1}{n-1}\sum_{k=1}^{n}\left(Y_{ki} - \overline{Y_i}\right)^2}$$

$$X_{ij} = \frac{Y_{ij} - \overline{Y_j}}{S_j}\begin{pmatrix} i = 1,2,\cdots n \\ j = 1,2,\cdots p \end{pmatrix}$$

- **均值**描述的是样本集合的中间点，**标准差**描述的则是样本集合的各个样本点到均值的距离之平均
  - 以两个集合为例：
    - [0，8，12，20]
    - [8，9，11，12]
  - 两个集合的均值都是10，但显然两个集合差别是很大的，计算两者的标准差，前者是8.3，后者是1.8，显然后者较为集中，故其标准差小一些，**标准差描述的就是这种“散布度”**
  - 之所以除以n-1而不是除以n，是因为这样能使我们以较小的样本集更好的逼近总体的标准差，即统计上所谓的“无偏估计”
  - **方差**则是标准差的平方

- **标准差和方差**一般是用来描述一维数据的
- 对于两维数据的数据集，可以按照每一维独立计算其方差，计算每个维度；偏离均值的程度

$$var(X) = \frac{\sum_{i=1}^{n}(X_i - \bar{X})(X_i - \bar{X})}{n-1}$$

- **协方差是一种用来度量两个随机变量关系的统计量**，可以仿照方差的定义

$$cov(X,Y) = \frac{\sum_{i=1}^{n}(X_i - \bar{X})(Y_i - \bar{Y})}{n-1}$$

- ✓ 如果结果为正值，则说明两者是正相关的(从协方差可以引出“相关系数”的定义)
- ✓ 结果为负值就说明负相关的
- ✓ 如果为0，也是就是统计上说的相互独立

$$1.cov(X,X) = var(X)$$
$$2.cov(X,Y) = cov(Y,X)$$

- 协方差也只能处理二维问题，那维数多了自然就需要计算多个协方差，比如n维的数据集就需要计算多个协方差，使用矩阵来组织这些数据，这就是**协方差矩阵**

$$C_{n\times n} = (c_{i,j}, c_{i,j} = cov(Dim_i, Dim_j))$$

- 以三维数据集为例，有三个维度（x，y，z），则协方差矩阵为

$$C = \begin{pmatrix} cov(x,x) & cov(x,y) & cov(x,z) \\ cov(y,x) & cov(y,y) & cov(y,z) \\ cov(z,x) & cov(z,y) & cov(z,z) \end{pmatrix}$$

（一）主成分分析的几何解释

- 例中数据点是六维的，即每个观测值是6维空间中一个点。希望把6维空间用低维空间表示
- 先假定只有二维，即只有两个变量，语文成绩（x_1）和数学成绩（x_2），分别由横坐标和纵坐标所代表，每个学生都是二维坐标系中的一个点

学生代码	数学	物理	化学	语文	历史	英语
1	65	61	72	84	81	79
2	77	77	76	64	70	55
3	67	63	49	65	67	57
4	80	69	75	74	74	63
5	74	70	80	84	81	74
6	78	84	75	62	71	64
7	66	71	67	52	65	57
8	77	71	57	72	86	71
9	83	100	79	41	67	50
…	…	…	…	…	…	…

原始数据标准化

- 因为在实际应用中，往往存在指标的量纲不同，所以在计算之前须先消除量纲的影响，而将原始数据标准化
- 为了实现样本数据的标准化，应求样本数据的平均和方差。对数据矩阵Y作标准化处理，即对每一个指标分量作标准化变换，变换公式为：

  —原始变量Y经规格化后变为新变量X，其均值为零，方差为1

$$\begin{bmatrix} y_{11} & y_{12} & \cdots & y_{1p} \\ y_{21} & y_{22} & \cdots & y_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ y_{n1} & y_{n2} & \cdots & y_{np} \end{bmatrix}$$

样本均值

$$\overline{Y_i} = \frac{1}{n}\sum_{k=1}^{n} Y_{ki}$$

样本标准差

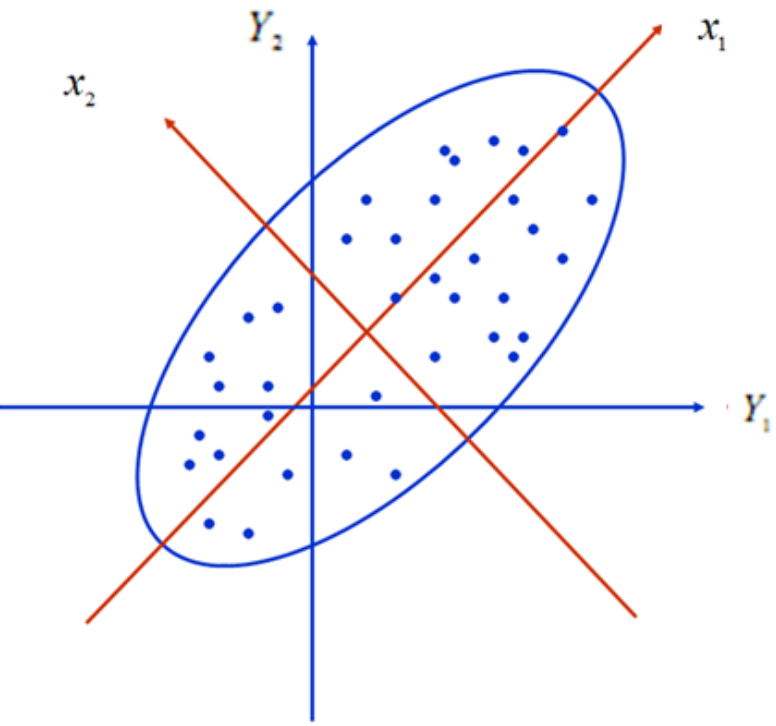
$$S_i = \sqrt{\frac{1}{n-1}\sum_{k=1}^{n}\left(Y_{ki} - \overline{Y_i}\right)^2}$$

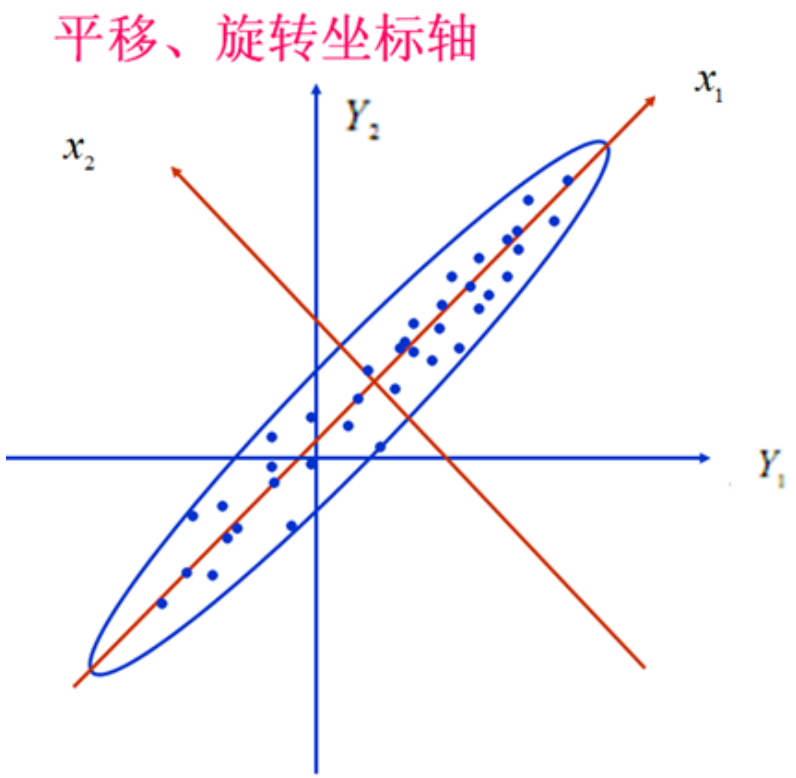
$$X_{ij} = \frac{Y_{ij} - \overline{Y_j}}{S_j} \begin{pmatrix} i = 1,2,\cdots n \\ j = 1,2,\cdots p \end{pmatrix}$$

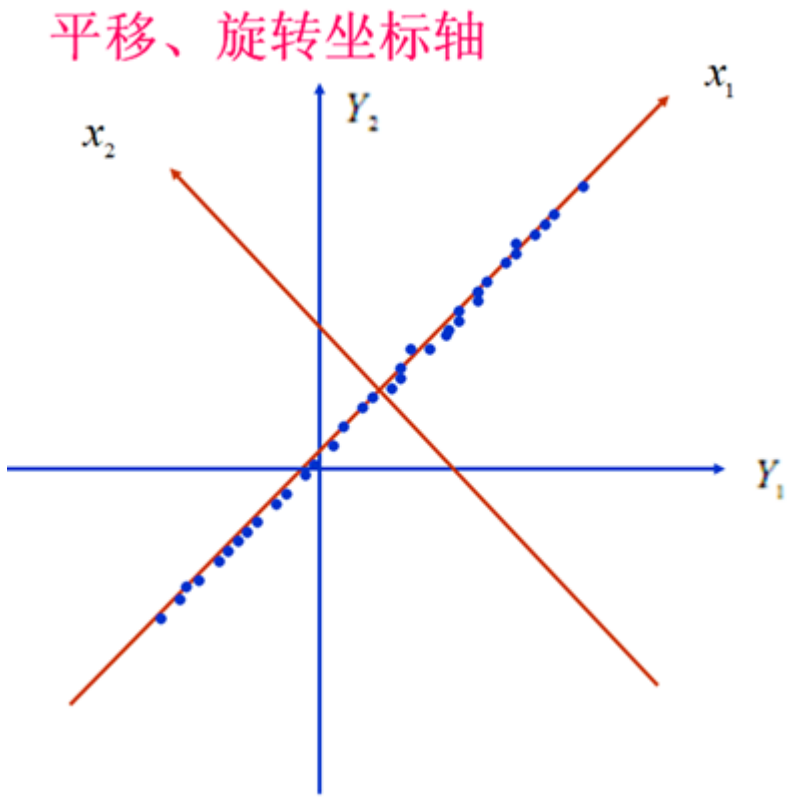
$$X = \begin{bmatrix} X_{11} & X_{12} & \cdots & X_{1p} \\ X_{21} & X_{22} & \cdots & X_{2p} \\ \vdots & \vdots & \vdots & \vdots \\ X_{n1} & X_{n2} & \cdots & X_{np} \end{bmatrix}$$

原始数据标准化

- 原始变量Y_{ij}经规格化后变为新变量X_{ij}，其均值为零，方差为1
- 对二维空间来讲n个标准化后的样本在二维空间的分布大体为一椭圆形，该椭圆有一个长轴和一个短轴。在短轴方向上数据变化很少，极端的情况下，短轴如退化成一点，长轴的方向可以完全解释这些点的变化







主成分分析的基本原理

- （一）主成分分析的几何解释
- （二）主成分分析的数学模型

主成分分析的数学模型

假设讨论的实际问题中，有p个指标，把这p个指标看作p个随机变量，记为X_1，X_2，…，X_p，主成分分析就是要把这p个指标的问题，转变为讨论 m 个新的指标F_1，F_2，…，F_m(m<p），按照保留主要信息量的原则充分反映原指标的信息，并且相互独立

$$X=\begin{bmatrix} X_{11} & X_{12} & \cdots & X_{1p} \\ X_{21} & X_{22} & \cdots & X_{2p} \\ \vdots & \vdots & \vdots & \vdots \\ X_{n1} & X_{n2} & \cdots & X_{np} \end{bmatrix}=\begin{pmatrix} X_1 & X_2 & \cdots & X_p \end{pmatrix} \qquad \text{其中} \quad X_i=\begin{pmatrix} X_{1i} \\ X_{2i} \\ \vdots \\ X_{ni} \end{pmatrix}$$

主成分分析要做的就是设法将原来众多具有一定相关性的变量，重新组合为一组新的相互无关的综合变量来代替原来变量。通常，数学上的处理方法就是将原来的变量做线性组合，作为新的综合变量

$$F_1 = a_{11}X_1 + a_{21}X_2 + \cdots + a_{p1}X_p$$
$$F_2 = a_{12}X_1 + a_{22}X_2 + \cdots + a_{p2}X_p$$
$$\cdots\cdots$$
$$F_p = a_{1p}X_1 + a_{2p}X_2 + \cdots + a_{pp}X_p$$

这种组合如果不加以限制，则可以有很多，应该如何选择呢？

满足如下的条件：

- 每个主成分的系数平方和为1。即

$$a_{1i}^2 + a_{2i}^2 + \cdots + a_{pi}^2 = 1$$

- 主成分之间相互独立，即无重叠的信息。即

$$Cov(F_i, F_j) = 0, \quad i \neq j, \quad i, j = 1, 2, \cdots, p$$

$$Cov(A,B) = E((A-\bar{A})(B-\bar{B})) = \frac{\sum_{i=1}^{n}(a_i-\bar{A})(b_i-\bar{B})}{n}$$

- 主成分的方差依次递减，重要性依次递减，即

$$Var(F_1) \geq Var(F_2) \geq \cdots \geq Var(F_p)$$

主成分分析法

- 主成分分析法概述
- 主成分分析的基本原理
- 主成分分析的计算步骤

多指标 求解主成分的步骤

在一般情况下，设有n个样品，每个样品观测p个指 标，将原始数据排成如下矩阵：

$$\begin{pmatrix} x_{11} & x_{12} & \cdots & x_{1p} \\ x_{21} & x_{22} & \cdots & x_{2p} \\ \cdots & \cdots & \cdots & \cdots \\ x_{n1} & x_{n2} & \cdots & x_{np} \end{pmatrix}$$

1.求样本均值 $\overline{X} = (\overline{x_1}, \overline{x_2}, \ldots, \overline{x_p})'$ 和样本协方差矩阵S;

2.求解特征方程 $|S - \lambda I| = 0$, 其中I是单位矩阵

解得p个特征根 $\lambda_1, \lambda_2, \ldots, \lambda_p \quad (\lambda_1 \geq \lambda_2 \geq \ldots \geq \lambda_p)$

3. 求 λ_k 所对应的单位特征向量 $\alpha_k \ (k = 1, 2, \ldots, p)$

解得 $\alpha_k = (a_{1k}, a_{2k}, \ldots, a_{pk})'$

4. 写出主成分的表达式

$$F_k = a_{1k}(x_1 - \overline{x_1}) + a_{2k}(x_2 - \overline{x_2}) + \ldots + a_{pk}(x_p - \overline{x_p})$$

或 $F_k = a_{1k}x_1 + a_{2k}x_2 + \ldots + a_{pk}x_p$

例1 下表是10位学生的身高X_1、胸围X_2、体重X_3的数据。

身高x_1(cm)	胸围x_2(cm)	体重x_3(kg)
149.5	69.5	38.5
162.5	77.0	55.5
162.7	78.5	50.8
162.2	87.5	65.5
156.5	74.5	49.0
156.1	74.5	45.5
172.0	76.5	51.0
173.2	81.5	59.5
159.5	74.5	43.5
157.7	79.0	53.5

对此进行主成分分析。

1. 求样本均值和样本协方差矩阵

$$\begin{pmatrix}\overline{x_1}\\ \overline{x_2}\\ \overline{x_3}\end{pmatrix}=\begin{pmatrix}161.2\\ 77.3\\ 51.2\end{pmatrix}\qquad S=\begin{pmatrix}46.67 & & \\ 17.12 & 21.11 & \\ 30.00 & 32.58 & 55.53\end{pmatrix}$$

$$Cov(A,B)=E((A-\bar{A})(B-\bar{B}))=\frac{\sum_{i=1}^{n}(a_i-\bar{A})(b_i-\bar{B})}{n}$$

2. 求解协方差矩阵的特征方程 $|S-\lambda I|=0$

$$\begin{vmatrix}46.67-\lambda & 17.12 & 30.00\\ 17.12 & 21.11-\lambda & 32.58\\ 30.00 & 32.58 & 55.53-\lambda\end{vmatrix}=0$$

3.解得三个特征值和对应的单位特征向量：

$\lambda_1=98.15$ $\quad(a_{11},a_{21},a_{31})=(0.56,0.42,0.71)$

$\lambda_2=23.60$ $\quad(a_{12},a_{22},a_{32})=(0.81,-0.33,-0.48)$

$\lambda_3=1.56$ $\quad(a_{13},a_{23},a_{33})=(0.03,0.85,-0.53)$

4. 由此我们可以写出三个主成分的表达式：

$$F_1 = 0.56(x_1 - 161.2) + 0.42(x_2 - 77.3) + 0.71(x_3 - 51.2)$$

$$F_2 = 0.81(x_1 - 161.2) - 0.33(x_2 - 77.3) - 0.48(x_3 - 51.2)$$

$$F_3 = 0.03(x_1 - 161.2) + 0.85(x_2 - 77.3) - 0.53(x_3 - 51.2)$$

5. 主成分的含义

F_1表示学生身材大小。

F_2反映学生的体形特征

三个主成分的方差贡献率分别为：

$$\frac{\lambda_1}{\sum_{i=1}^{3}\lambda_i}=\frac{98.15}{98.15+23.60+1.56}=\frac{98.15}{123.31}=79.6\%$$

$$\frac{\lambda_2}{\sum_{i=1}^{3}\lambda_i}=\frac{23.60}{123.31}=19.1\%$$

$$\frac{\lambda_3}{\sum_{i=1}^{3}\lambda_i}=\frac{1.56}{123.31}=1.3\%$$

前两个主成分的累积方差贡献率为：

$$\frac{\lambda_1+\lambda_2}{\sum_{i=1}^{3}\lambda_i}=\frac{121.75}{123.31}=98.7\%$$

主成分实际含义解释

- **主成分分析中一个很关键的问题是如何给主成分赋予新的意义，给出合理的解释**
- 一般而言，这个解释是根据主成分表达式的系数结合定性分析来进行的。主成分是原来变量的线性组合，在这个线性组合中各变量的系数有大有小，有正有负，有的大小相当，因而不能简单地认为这个主成分是某个原变量的属性的作用，线性组合中各变量系数的绝对值大者表明该主成分主要综合了绝对值大的变量，有几个变量系数大小相当时，应认为这一主成分是这几个变量的总和，这几个变量综合在一起应赋予怎样的实际意义，这要结合具体实际问题和专业，给出恰当的解释，进而才能达到深刻分析的目的

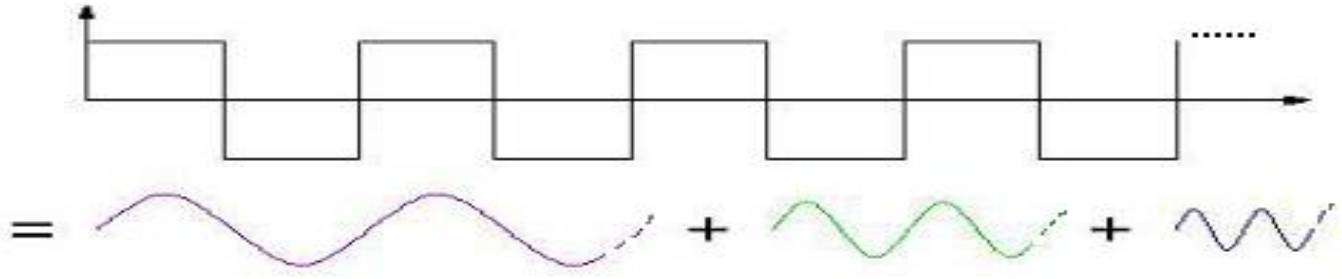
小波变换

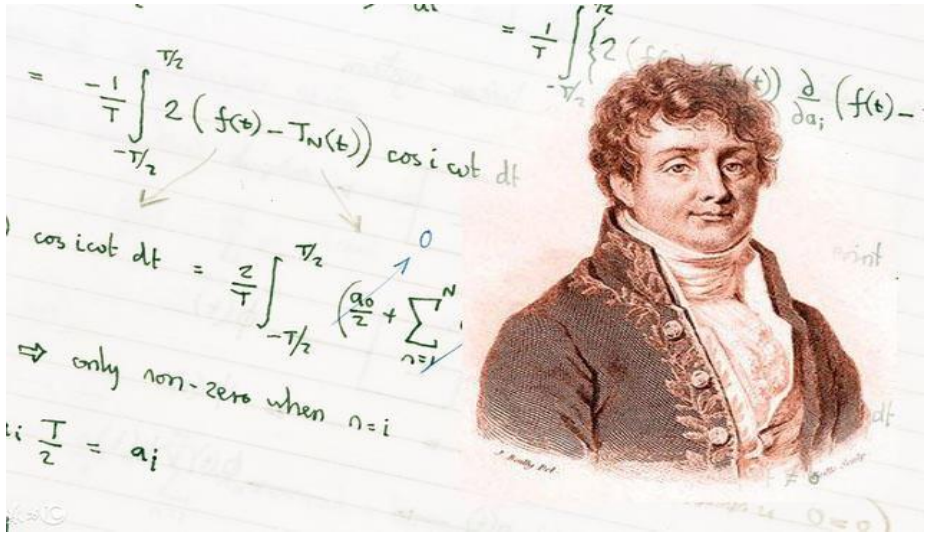
将数据映射到一个新空间

傅里叶变换 Fourier transform

—1807: Joseph Fourier

- 傅立叶理论指出，一个信号可表示成一系列正弦和余弦函数之和，叫做傅立叶展开式

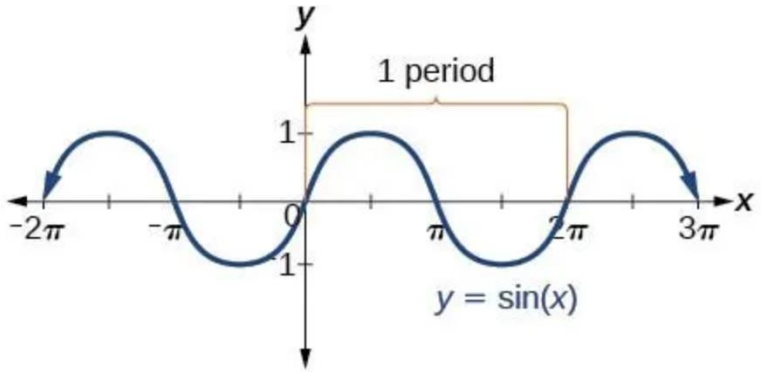


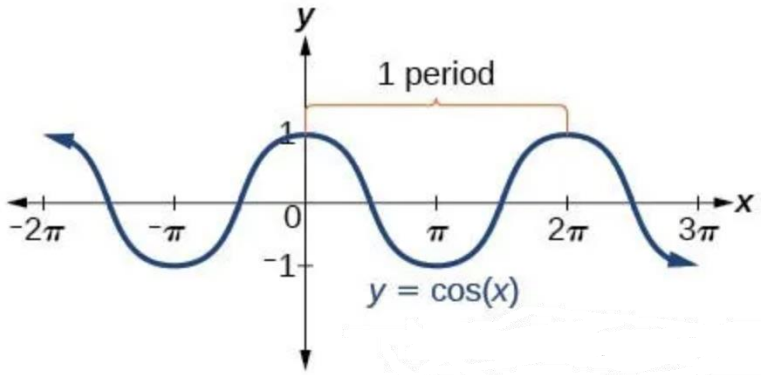


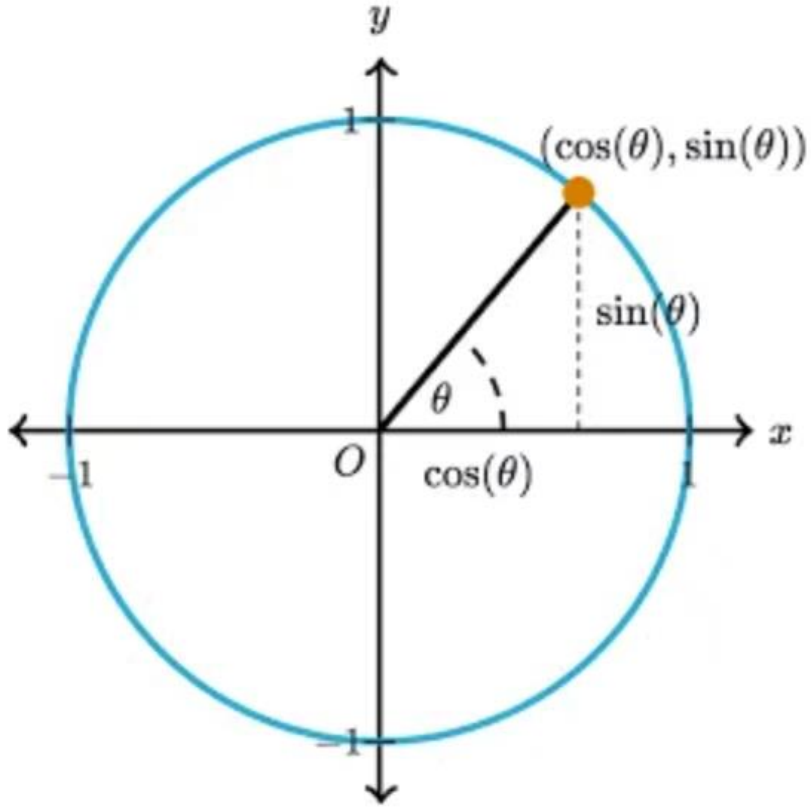
数学意义上的傅里叶变换（Fourier transform），用通俗易懂的话来讲，就是“将一切的函数用正弦函数拟合”。因其基本思想首先由法国学者约瑟夫•傅里叶系统地提出，所以以其名字来命名以示纪念

傅里叶变换和傅里叶级数是有史以来最深奥的数学发现

- **将函数分解为其基本成分，揭示了任何数学函数的基本模块**
  - —余弦和正弦作为绕单位圆运动的点的坐标
  - —由这两个函数组成的和可以表示任何数学函数





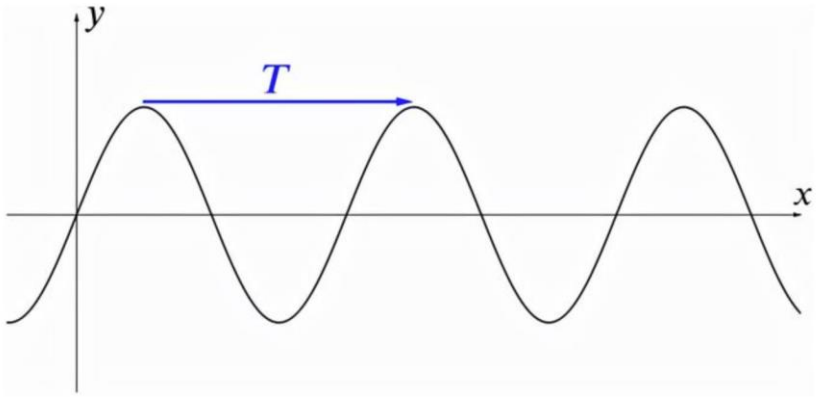


傅立叶级数和傅立叶变换

- **傅立叶级数和傅立叶变换的区别在于，前者用于将周期函数分解为正弦和余弦之和，而后者则用于非周期函数**

- **傅里叶级数用于周期性函数**
- 如果以下等式成立，一个函数f(t)被称为是周期性的，其最小周期为T，该函数以长度为T的时间间隔重复其数值

$$f(t - T) = f(t) = f(t + T) \text{ for all } t$$



傅立叶级数和傅立叶变换

- 傅里叶级数是正弦函数的无限加权和，每个正弦函数的频率都是原始周期函数的基频(1/T)的整数倍

$$g(t) = a_0 + \sum_{m=1}^{\infty} a_m \cos\left(\frac{2\pi mt}{T}\right) + \sum_{n=1}^{\infty} b_n \sin\left(\frac{2\pi nt}{T}\right)$$

$$= \sum_{m=0}^{\infty} a_m \cos\left(\frac{2\pi mt}{T}\right) + \sum_{n=1}^{\infty} b_n \sin\left(\frac{2\pi nt}{T}\right)$$

$$a_m = \frac{2}{T}\int_0^T f(t)\cos\left(\frac{2\pi mt}{T}\right)dt$$

$$b_n = \frac{2}{T}\int_0^T f(t)\sin\left(\frac{2\pi nt}{T}\right)dt$$

傅里叶级数的指数形式

Euler's Formula

$$e^{i\phi} = \cos\phi + i\sin\phi$$

Euler's identity

$$e^{i\pi} + 1 = 0$$

- **傅里叶变换：关注的是非周期性函数**

$$F(j\omega) = \int_{-\infty}^{\infty} f(t)e^{-j\omega t}dt$$

Fourier Transform

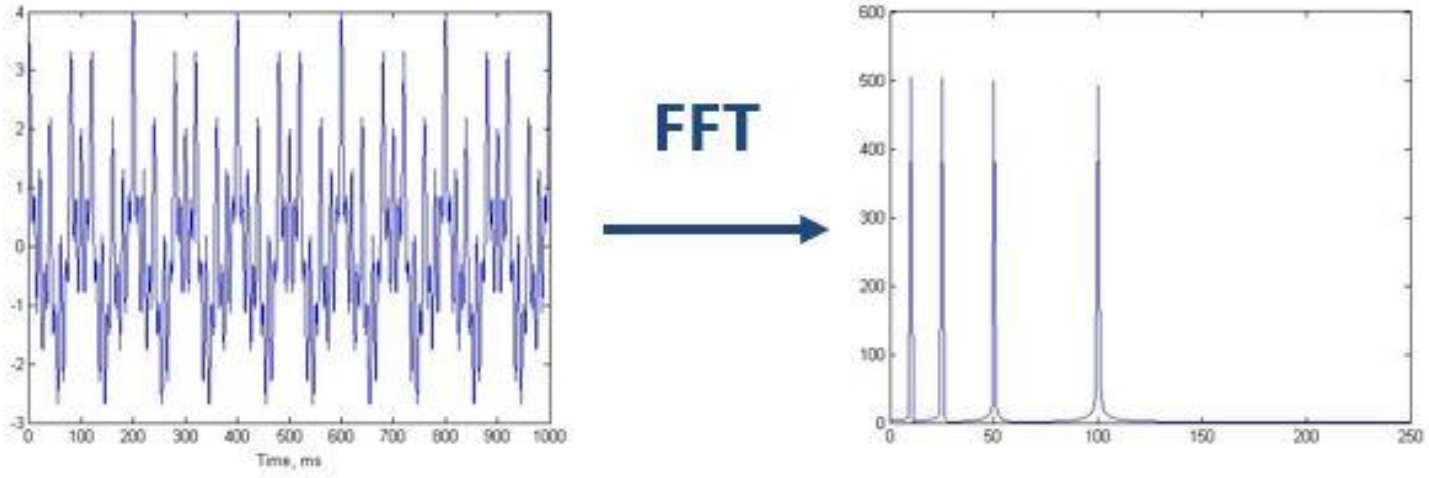
$$F(\omega) = \int_{-\infty}^{+\infty} f(t)e^{-j\omega t}dt$$

$$f(t) = \frac{1}{2\pi}\int_{-\infty}^{+\infty} F(\omega)\mathrm{e}^{j\omega t}$$

- 傅里叶变换的结果是一个频率的函数。“ω”是用来表示角频率的，它是乘积2πf的名字。当初始函数f(t)是一个时间函数时，傅里叶变换给了该函数的频率内容
- 一个时间函数的傅里叶变换是一个频率的复值函数，其大小（绝对值）代表了原始函数中存在的该频率的数量，其参数是该频率的基本正弦波的相位偏移。傅里叶变换不限于时间函数，但原始函数的域通常被称为时域
- 用逆傅里叶变换把初始函数找回来

傅里叶变换适合处理平稳信号

- 做完FFT（快速傅里叶变换）后，可以在频谱上看到清晰的四条线，信号包含四个频率成分
- 但是，如果是**频率随着时间变化的非平稳信号**呢？

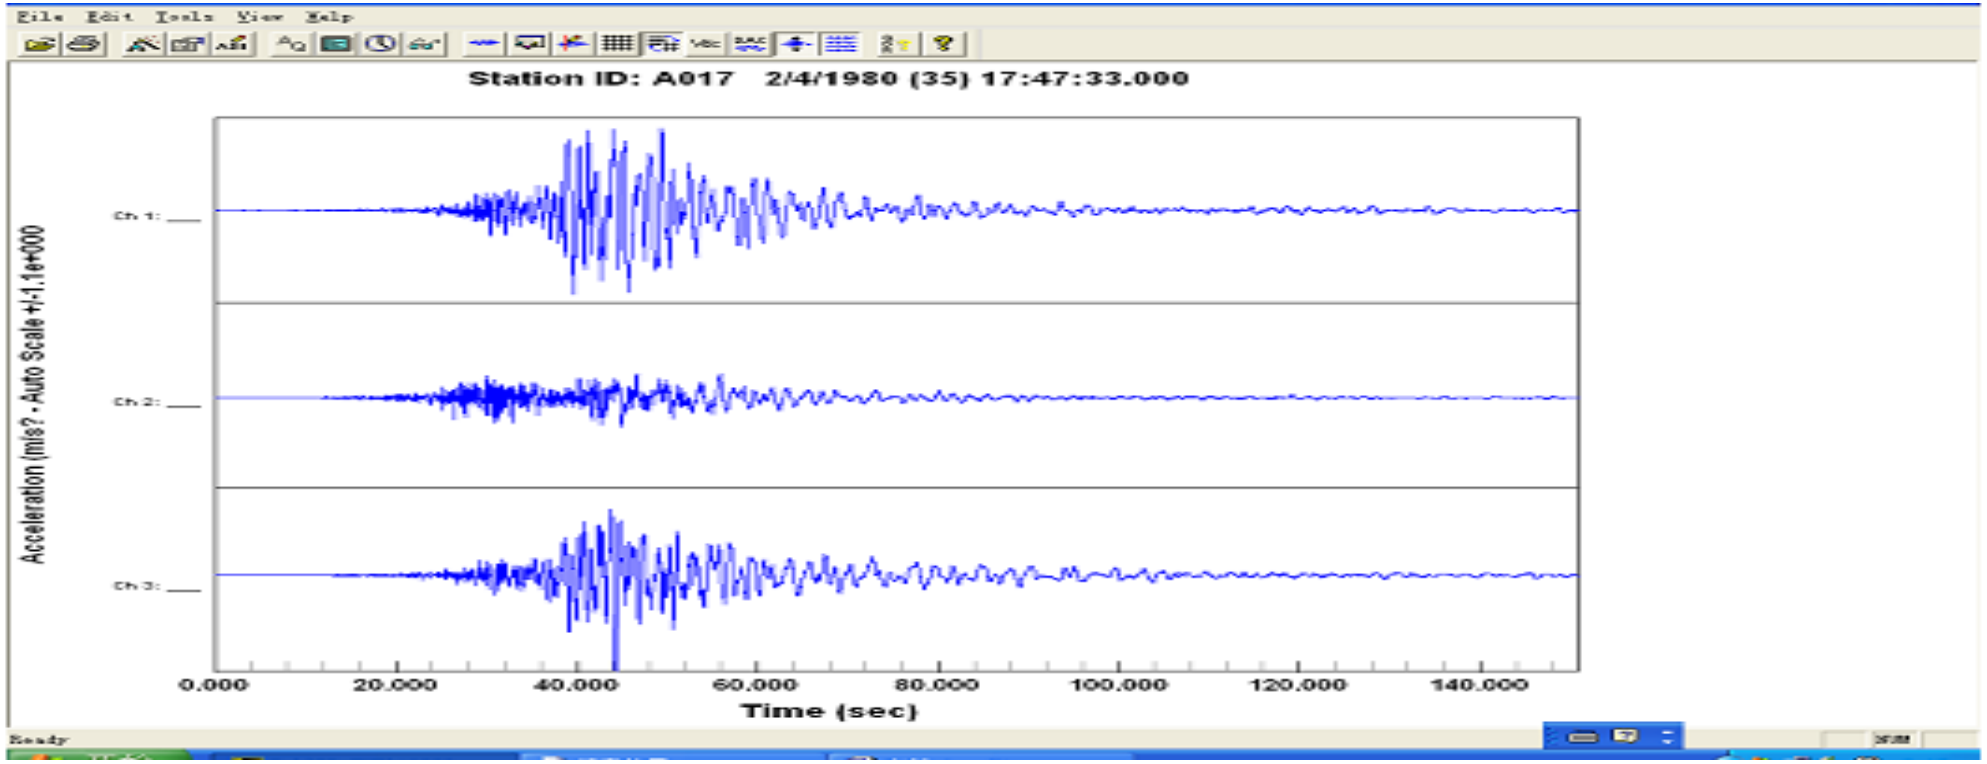


$$x(t)=\cos(2\pi*10t)+\cos(2\pi*25t)+\cos(2\pi*50t)+\cos(2\pi*100t)$$

10, 25, 50, 100Hz

傅里叶变换处理非平稳信号有天生缺陷

- FT变换适于分析平稳信号。实际中大多数信号含有大量的非平稳信号，例如：突变，奇异，事件的起始与终止等情况。这些情况反映了信号的重要特征，是分析的对象

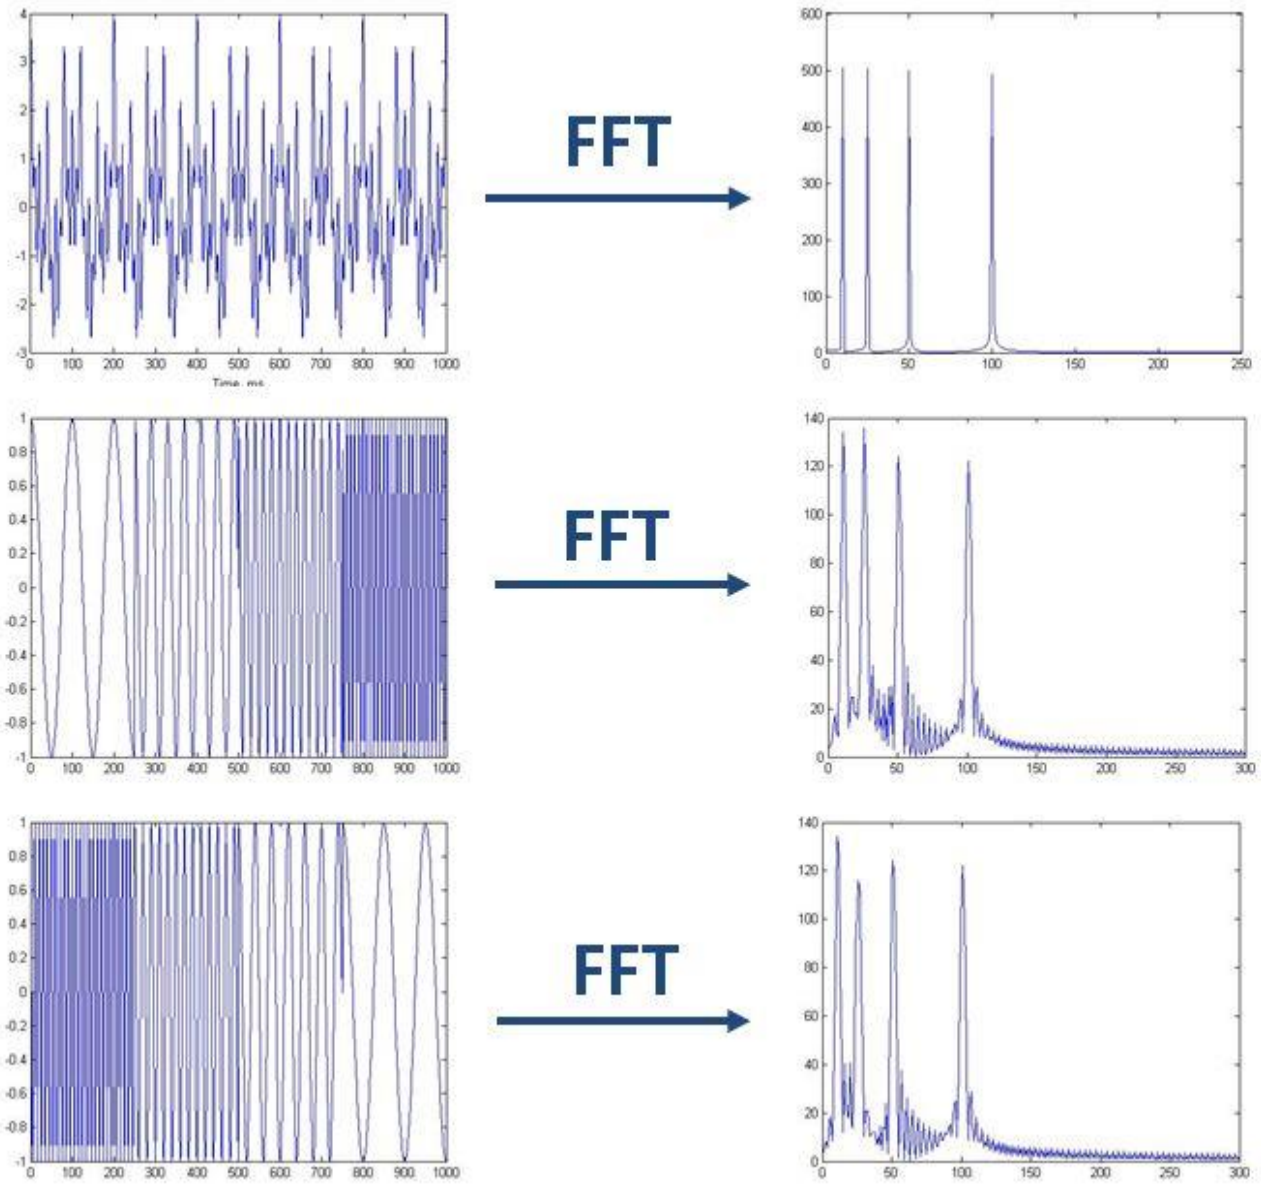


典型的地震记录

傅里叶变换处理非平稳信号有天生缺陷

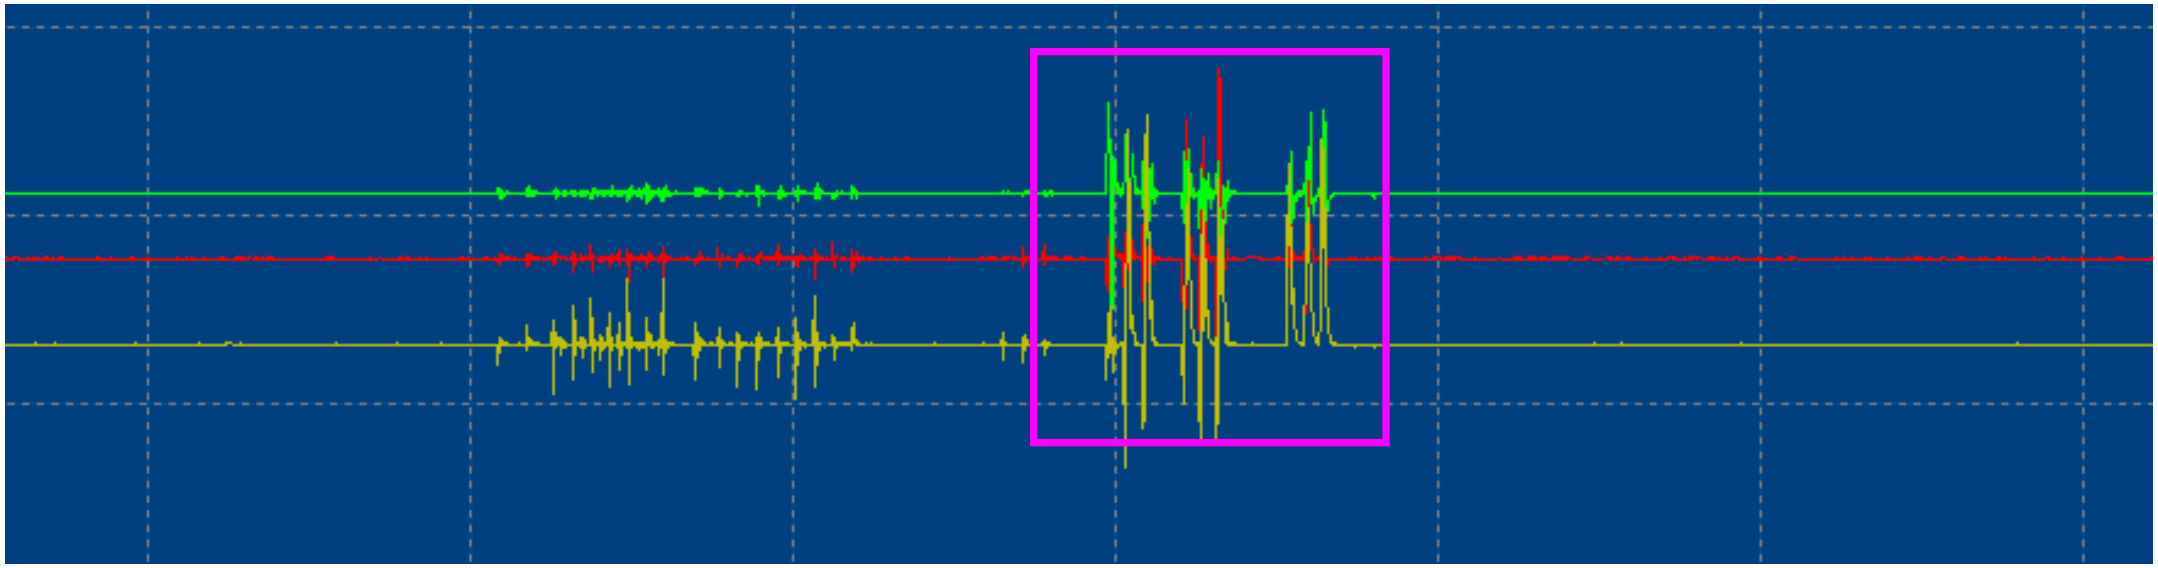
- 最上边的是频率始终不变的平稳信号，下边两个则是频率随着时间改变的非平稳信号，它们同样包含和最上信号相同频率的四个成分
- 做FFT后，发现这三个时域上有巨大差异的信号，频谱（幅值谱）却非常一致。尤其是下边两个非平稳信号，从频谱上无法区分它们，因为它们包含的四个频率的信号的成分确实是一样的，只是出现的先后顺序不同
- **傅里叶变换处理非平稳信号有天生缺陷。它只能获取一段信号总体上包含哪些频率的成分，但是对各成分出现的时刻并无所知**。因此时域相差很大的两个信号，可能频谱图一样

对于非平稳信号，只知道包含哪些频率成分是不够的，还想知道各个成分出现的时间。知道信号频率随时间变化的情况，各个时刻的瞬时频率及其幅值——这也就是时频分析



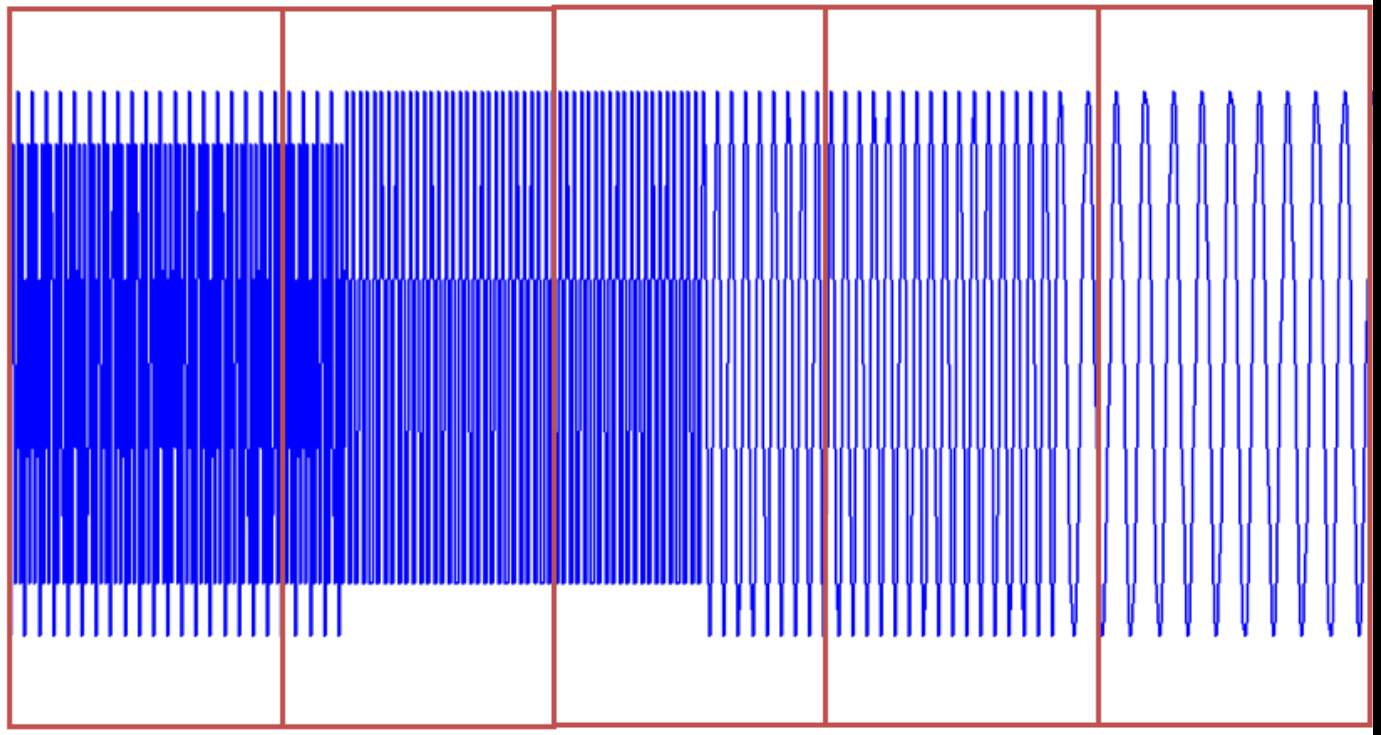
短时傅立叶变换（STFT）

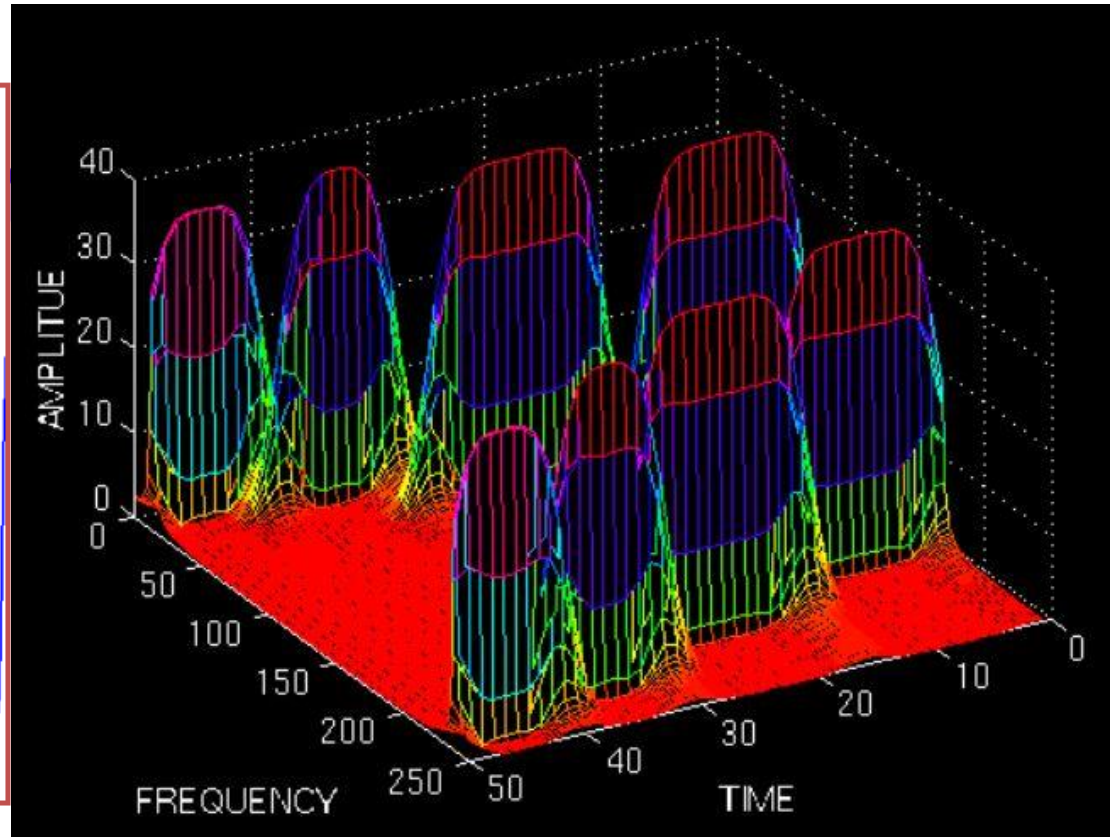
- **短时傅里叶变换（Short-time Fourier Transform, STFT）**
- 基本思想
  - 把整个时域过程分解成无数个等长的小过程，每个小过程近似平稳，再傅里叶变换，就知道在哪个时间点上出现了什么频率了。这就是短时傅里叶变换给信号加一个小窗，主要集中在对小窗内的信号进行变换，因此反映了信号的局部特征



短时傅立叶变换（STFT）

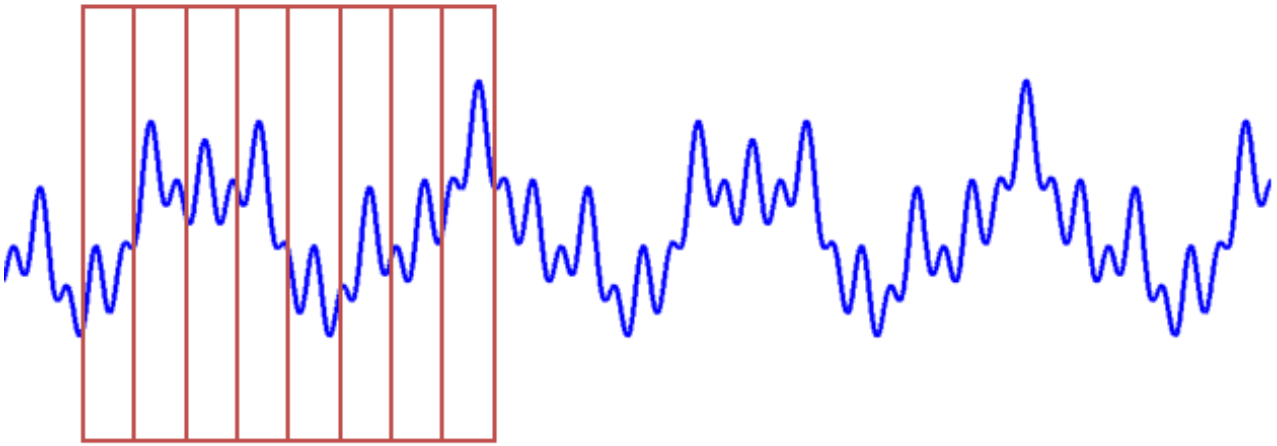
- 时域上分成一段一段做FFT，就知道了频率成分随着时间的变化情况。用这样的方法，可以得到一个信号的时频图
  - **图上既能看到10Hz, 25 Hz, 50 Hz, 100 Hz四个频域成分，还能看到出现的时间**。两排峰是对称的，所以只用看一排就行了



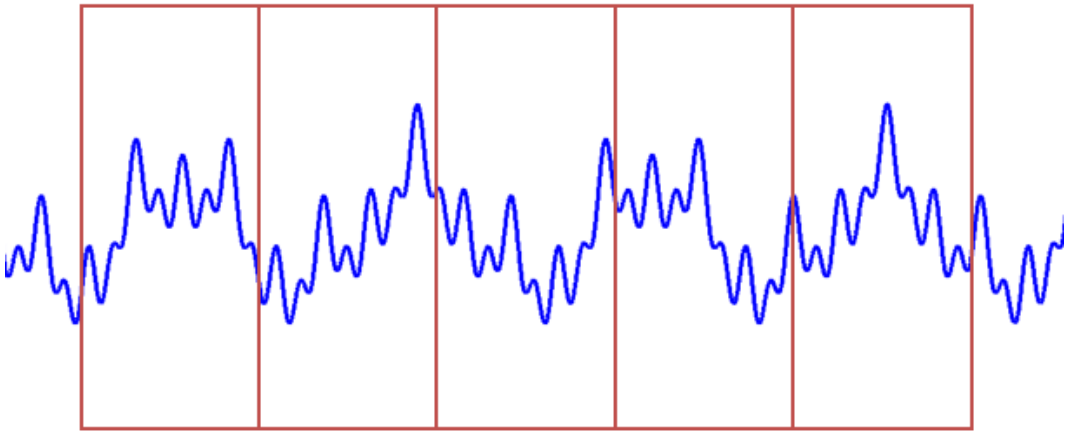


短时傅立叶变换（STFT）的缺陷

- 其窗函数的大小和形状均与**时间和频率无关**，保持固定不变，对于分析时变信号**不利！**（高频信号持续时间短，低频长。希望对于**高频采用小的时间窗，低频使用大时间窗**进行分析，STFT无能为力了！）



框太窄 → 频率分辨率差



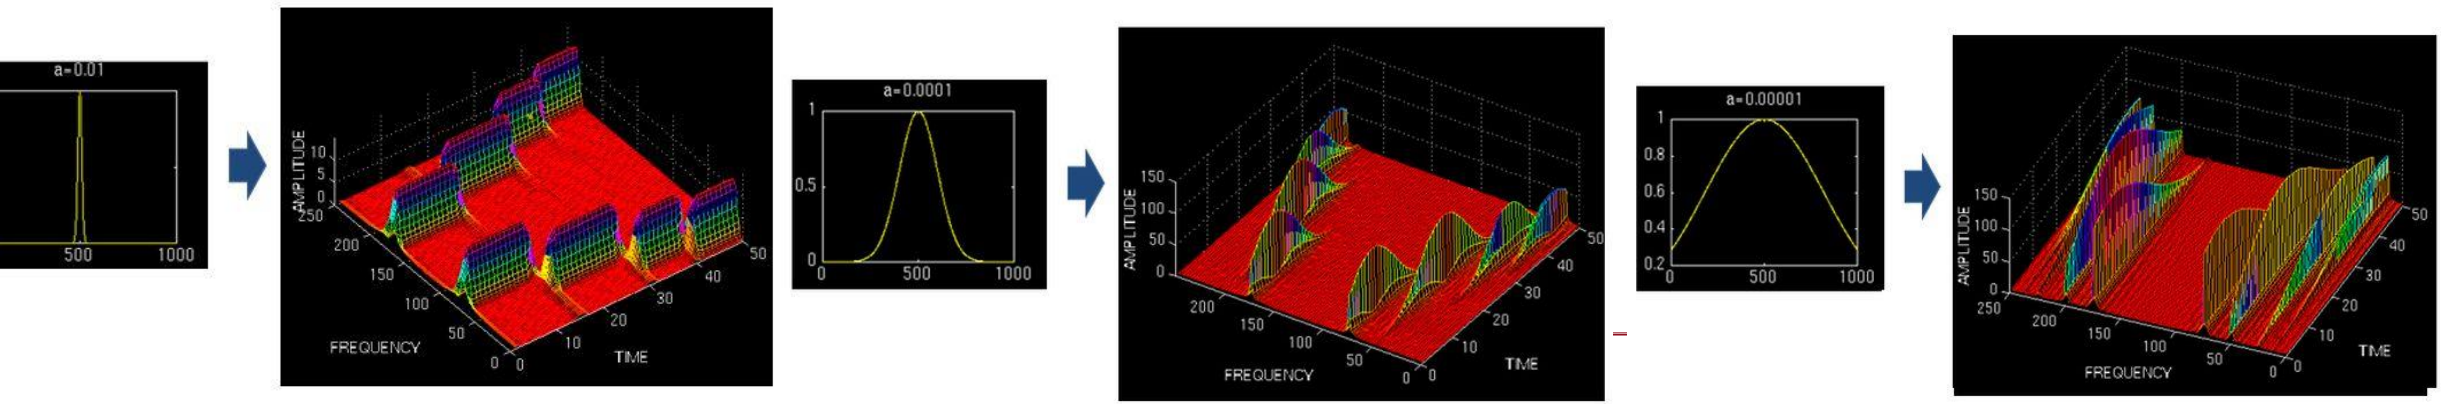
框太宽 → 时间分辨率差

短时傅立叶变换（STFT）的缺陷

- 窗太窄，窗内的信号太短，会导致频率分析不够精准，频率分辨率差。窗太宽，时域上又不够精细，时间分辨率低

—同一个信号（4个频率成分）采用不同宽度的窗做STFT，结果如图。用窄窗，时频图在时间轴上分辨率很高，几个峰基本成矩形，而用宽窗则变成了绵延的矮山。但是频率轴上，窄窗明显不如下边两个宽窗精确

—**窄窗口时间分辨率高、频率分辨率低，宽窗口时间分辨率低、频率分辨率高。**对于时变的非稳态信号，**高频适合小窗口，低频适合大窗口**。然而**STFT的窗口是固定的**，在一次STFT中宽度不会变化，所以STFT还是无法满足非稳态信号变化的频率的需求



短时傅立叶变换（STFT）

- **缺陷**

  —不能构成正交基，给数值计算带来不便

正交基的解释

- 若一物体可用颜色和大小表示，我们称颜色和大小为特征基，构成此物体特征描述空间
- 大小和颜色是互不相干的2种描述，我们称其为正交
- 同时若这些基能够完全表示所有物体，我们称其为完备特征基
- 因为特征基表现了物体特征，因而可以用更简洁的描述表示物体

小波信号隆重登场

- **登场原因：**

  （1）继承和发展了STFT的局部化思想

  （2）克服了窗口大小不随频率变化、缺乏离散正交基的缺点

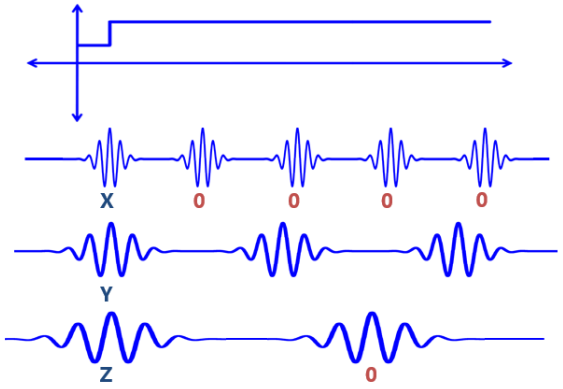
STFT是给信号加窗，分段做FFT

小波直接把傅里叶变换的基给换了——将无限长的三角函数基换成了有限长的会衰减的小波基。这样不仅能够获取频率，还可以定位到时间了

$$WT(a,\tau)=\frac{1}{\sqrt{a}}\int_{-\infty}^{\infty}f(t)*\psi(\frac{t-\tau}{a})dt$$

不同于傅里叶变换，变量只有频率ω，小波变换有两个变量：尺度a（scale）和平移量τ（translation）。**尺度a**控制小波函数的**伸缩**，**平移量τ**控制小波函数的**平移**。**尺度**就对应于**频率**（反比），**平移量τ**就对应于**时间**

对于突变信号



只有小波函数和信号突变处重叠时，系数不为0

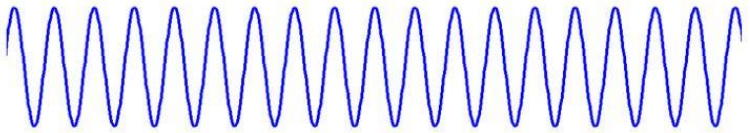
傅里叶变换

$$F(w)=\int_{-\infty}^{\infty}f(t)*e^{-iwt}dt$$

原信号



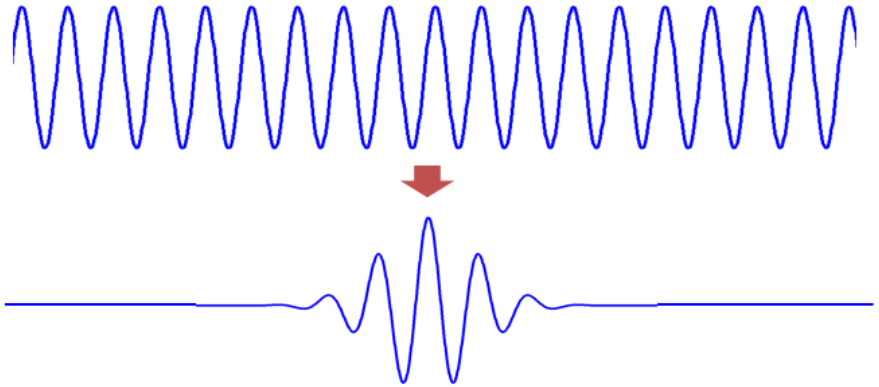
基函数



铺满了整个时域

小波变换

$$F(w)=\int_{-\infty}^{\infty}f(t)*e^{-iwt}dt \Rightarrow WT(a,\tau)=\frac{1}{\sqrt{a}}\int_{-\infty}^{\infty}f(t)*\psi(\frac{t-\tau}{a})dt$$



小波变换 Wavelet transform（续）

- 小波分析/小波变换

  变换目的是获得时间和频率域之间的相互关系

  —小波变换

  - 对一个函数在空间和时间上进行局部化的一种数学变换
    - 通过平移母小波(mother wavelet)获得信号的时间信息
      通过缩放母小波的宽度(或称尺度)获得信号的频率特性
    - 对母小波的平移和缩放操作是为计算小波的系数，这些系数代表局部信号和小波之间的相互关系
  - 对比傅立叶变换
    - 提供了频率域的信息，但丢失了时间域的局部化信息

  —小波分析中常用的三个基本概念

  - 连续小波变换
  - 离散小波变换
  - 小波重构

小波变换 Wavelet transform（续）

- 连续小波变换(continuous wavelet transform，CWT)
  - —傅立叶分析
    - 用一系列不同频率的正弦波表示一个信号
    - 一系列不同频率的正弦波是傅立叶变换的基函数
  - —小波分析
    - 用母小波通过移位和缩放后得到的一系列小波表示一个信号
    - 一系列小波可用作表示一些函数的基函数
  - —凡能用傅立叶分析的函数都可用小波分析
    - 小波变换可理解为用经过缩放和平移的一系列函数代替傅立叶变换用的正弦波
  - —用不规则的小波分析变化激烈的信号比用平滑的正弦波更有效，或者说对信号的基本特性描述得更好

小波变换 Wavelet transform（续）

— CWT的变换过程示例见图，分5步

1. 小波$\psi(t)$和原始信号$f(t)$的开始部分进行比较
2. 计算系数C——该部分信号与小波的近似程度；C值越高表示信号与小波相似程度越高
3. 小波右移k得到的小波函数为$\psi(t-k)$，然后重复步骤1和2，……直到信号结束
4. 扩展小波，如扩展一倍，得到的小波函数为$\psi(t/2)$
5. 重复步骤1~4

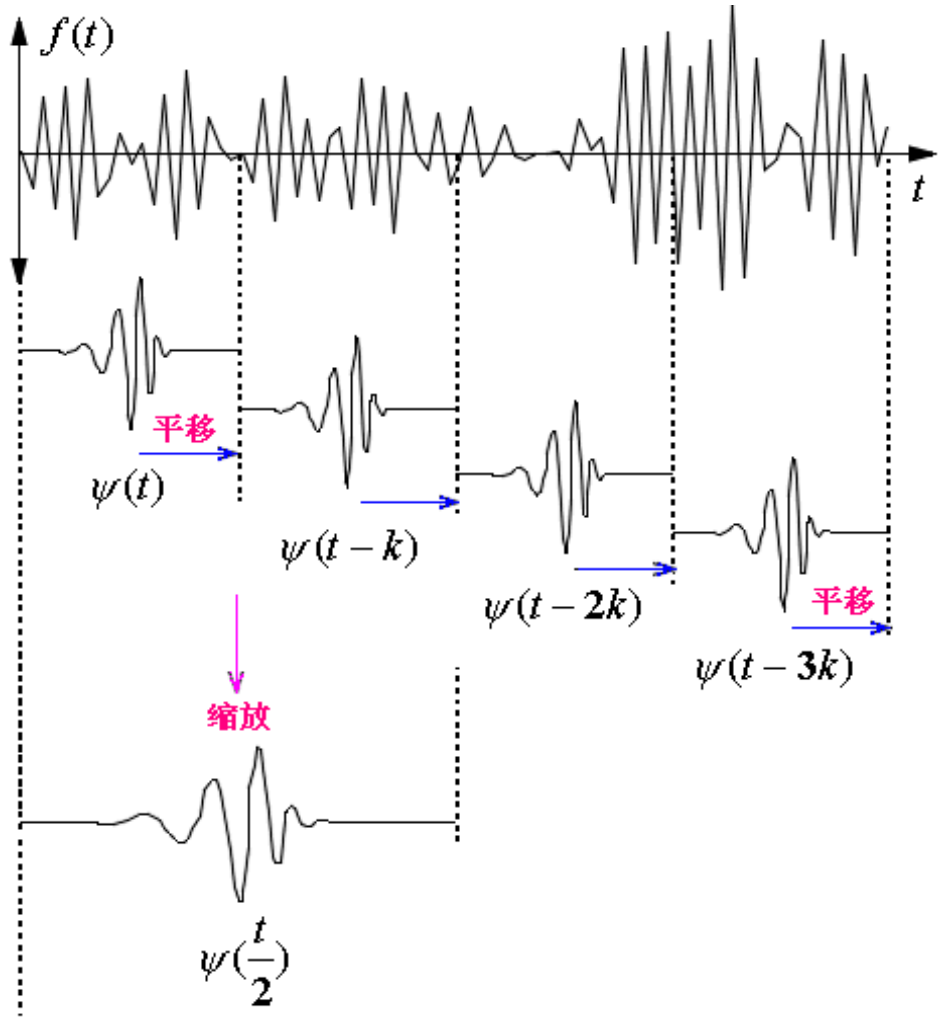


图 连续小波变换的过程

小波变换 Wavelet transform（续）

— 连续小波变换用下式表示

$$C(scale, position) = \int_{-\infty}^{+\infty} f(t)\psi(scale, position, t)dt$$

- 该式含义：小波变换是信号*f(t)*与被缩放和平移的小波函数*Ψ*之积在信号存在的整个期间里求和
- CWT变换的结果是许多小波系数*C*，这些系数是缩放因子(scale)和位置(position)的函数

- 离散小波变换(discrete wavelet transform，DWT)

— 用小波的基函数(basis functions)表示一个函数的方法

- 小波的基函数序列或称子小波(baby wavelets)函数是由单个小波或称为母小波函数通过缩放和平移得到的
- 缩放因子和平移参数都选择2^j (*j* >0的整数)的倍数，这种变换称为双尺度小波变换(dyadic wavelet transform)

小波变换 Wavelet transform（续）

—DWT得到的小波系数、缩放因子和时间关系，见图

- 图(a)是20世纪40年代使用Gabor开发的短时傅立叶变换(short time Fourier transform，STFT)得到的
- 图(b)是20世纪80年代使用Morlet开发的小波变换得到的

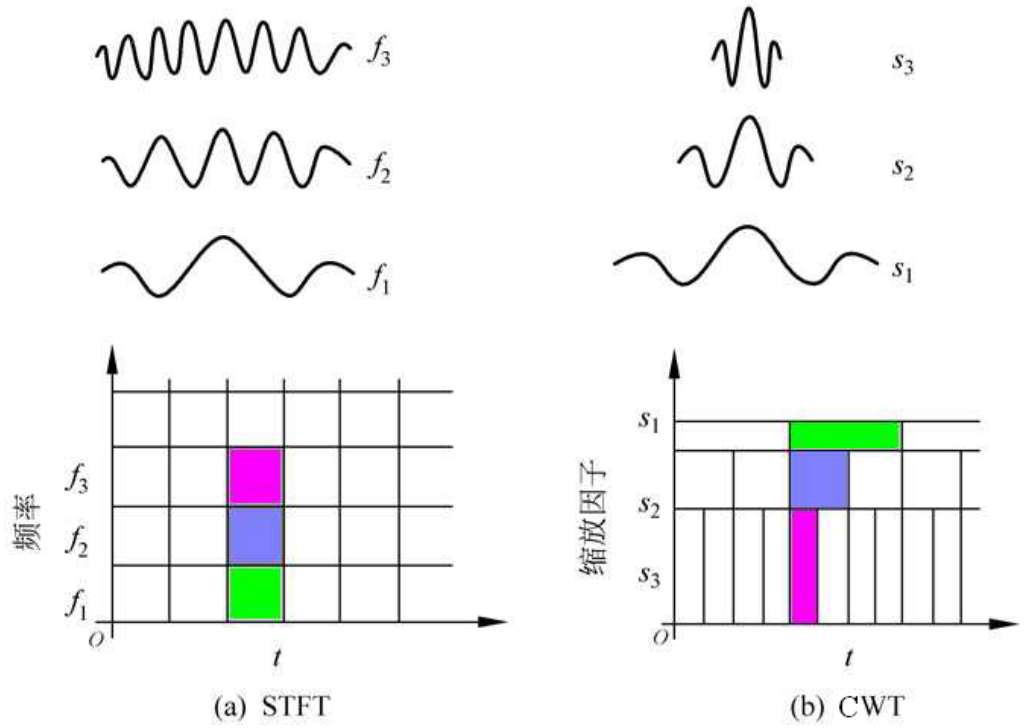


图 离散小波变换分析图

小波变换 Wavelet transform（续）

—执行DWT的有效方法

- 用Mallat在1988年开发的滤波器，称为Mallat算法
- DWT的概念见图。S表示原始的输入信号；通过两个互补的滤波器产生A和D两个信号

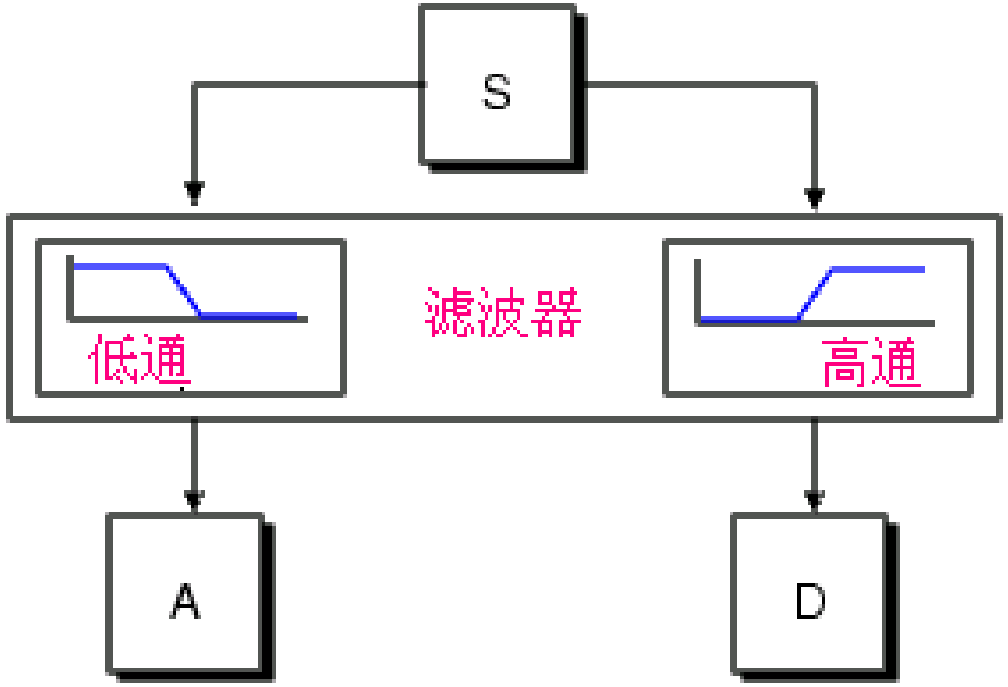


图 双通道滤波过程

– A表示信号的近似值(approximations)，大的缩放因子产生的系数，表示信号的低频分量
– D表示信号的细节值(detail)，小的缩放因子产生的系数，表示信号的高频分量

小波变换 Wavelet transform（续）

- 小波分解树与小波包分解树

—由低通滤波器和高通滤波器组成的树

- 原始信号通过一对滤波器进行的分解叫做一级分解。信号的分解过程可以迭代，即可进行多级分解。

—小波分解树(wavelet decomposition tree)

- 用下述方法分解形成的树：对信号的高频分量不再继续分解，而对低频分量连续进行分解，得到许多分辨率较低的低频分量

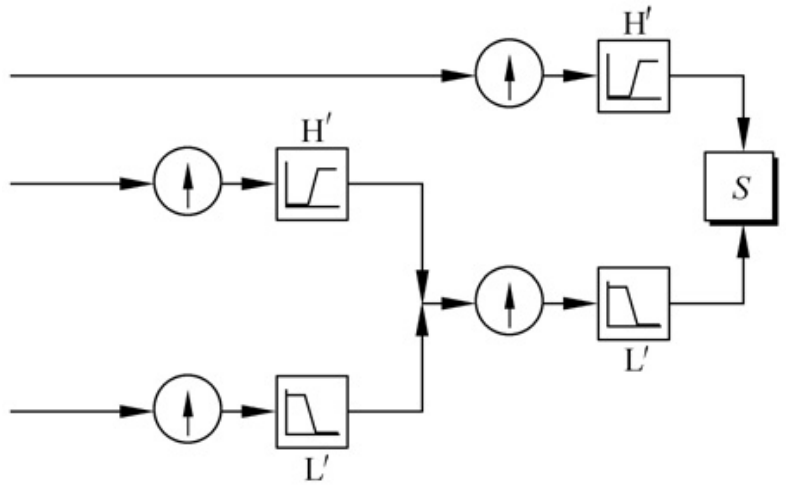
—小波包分解树(wavelet packet decomposition tree)

- 用下述方法分解形成的树：不仅对信号的低频分量连续进行分解，而且对高频分量也进行连续分解，这样不仅可得到许多分辨率较低的低频分量，而且也可得到许多分辨率较低的高频分量

小波变换 Wavelet transform（续）

- 小波重构
  - —重构概念
    - 把分解的系数还原成原始信号的过程叫做小波重构(wavelet reconstruction)或合成(synthesis)，数学上叫做逆离散小波变换(inverse discrete wavelet transform，IDWT)
  - —两个过程
    - 在使用滤波器做小波变换时包含滤波和降采样(downsampling)两个过程，在小波重构时也包含升采样(upsampling)和滤波两个过程，见图7-10
    - 升采样是在两个样本数据之间插入“0”，目的是把信号的分量加长，其过程见图7-11

小波变换 Wavelet transform（续）



H′: 高通滤波器　L′: 低通滤波器

图7-10 小波重构方法

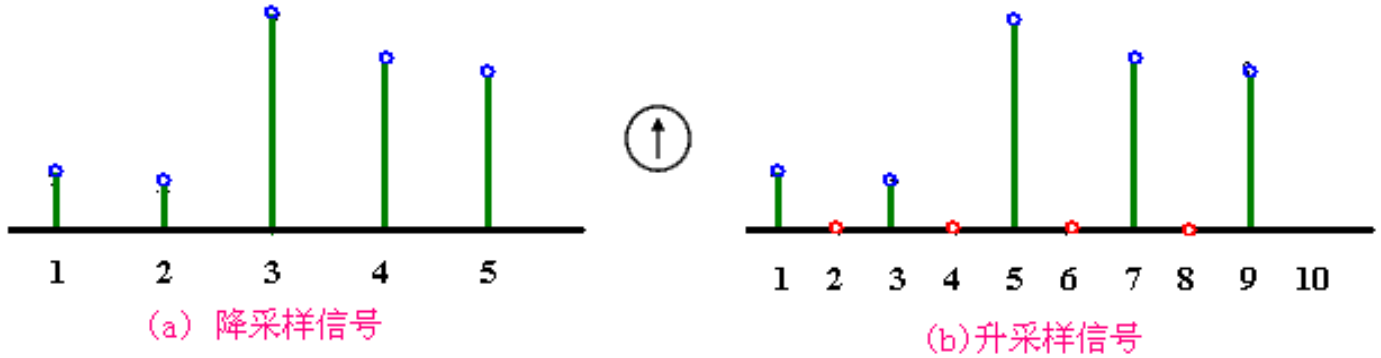


图7-11 升采样的方法

小波变换 Wavelet transform（续）

- 重构滤波器
  - —滤波器关系到能否重构出满意的原始信号。在信号的分解期间，降采样会引进畸变，这种畸变叫做混叠(aliasing)。这就需要在分解和重构阶段精心选择关系紧密但不一定一致的滤波器才有可能取消这种混叠
  - —低通分解滤波器(L)和高通分解滤波器(H)以及重构滤波器(L'和H')构成一个系统，这个系统叫做正交镜像滤波器(quadrature mirror filters，QMF)系统，如图7-12所示

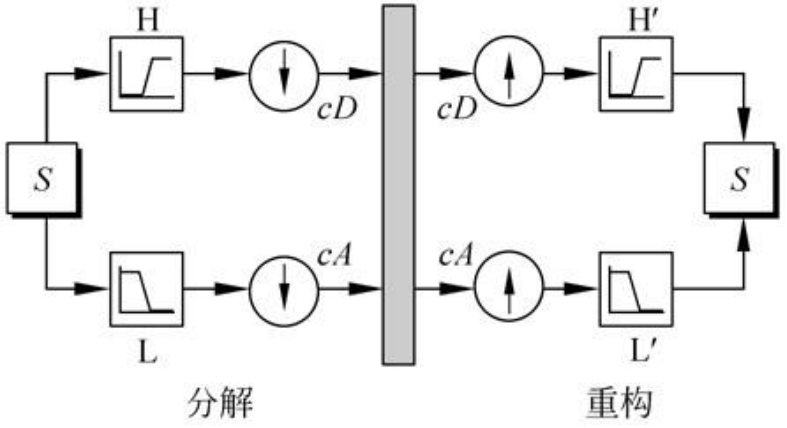


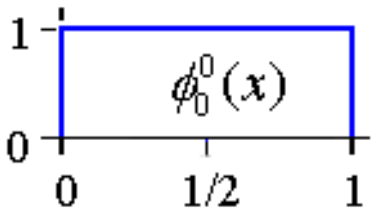
图7-12 正交镜像滤波器系统

小波变换 Wavelet transform（续）
哈尔基函数

- 哈尔基函数
  - —基函数是一组线性无关的函数，可以用来构造任意给定信号，如用基函数的加权和表示
  - —哈尔基函数(Haar basis function)
    - 定义在半开区间[0，1)上的一组分段常值函数(piecewise-constant function)集
    - 生成矢量空间V^0的常值函数

$$V^0:\ \phi_0^0(x)=\begin{cases}1 & 0\le x<1\\ 0 & \text{其他}\end{cases}$$

波形：



小波变换 Wavelet transform（续）

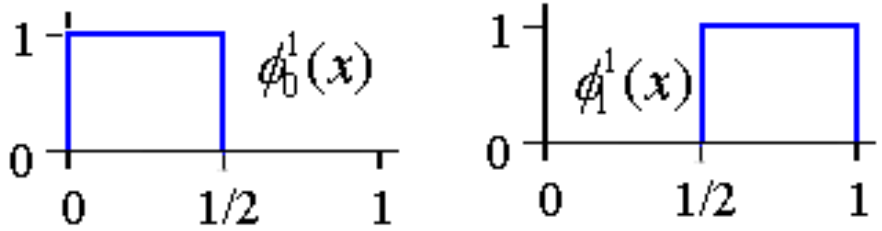
哈尔基函数

- 生成矢量空间V^1的常值函数

$$V^1:\ \phi_0^1(x)=\begin{cases}1 & 0\le x<0.5\\ 0 & \text{其他}\end{cases},$$

$$\phi_1^1(x)=\begin{cases}1 & 0.5\le x<1\\ 0 & \text{其他}\end{cases}$$

波形：



小波变换 Wavelet transform（续）

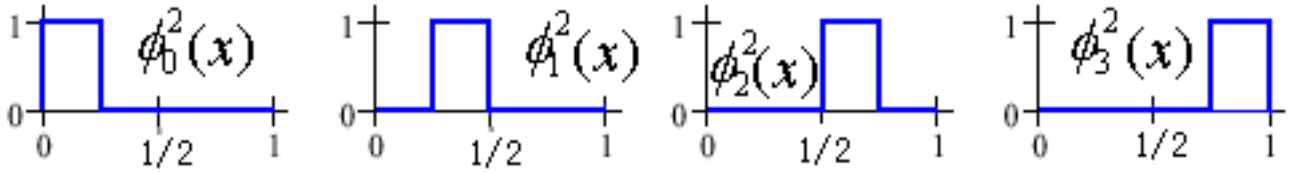
哈尔基函数

- 生成矢量空间V^2的常值函数

$$\phi_0^2(x)=\begin{cases}1, & 0\le x<1/4\\ 0, & \text{其他}\end{cases} \qquad \phi_1^2(x)=\begin{cases}1, & 1/4\le x<1/2\\ 0, & \text{其他}\end{cases}$$

$$\phi_2^2(x)=\begin{cases}1, & 1/2\le x<3/4\\ 0, & \text{其他}\end{cases} \qquad \phi_3^2(x)=\begin{cases}1, & 3/4\le x<1\\ 0, & \text{其他}\end{cases}$$

波形：



- 可按照以上方法继续定义哈尔基函数和由它生成的矢量空间V^j，……

小波变换 Wavelet transform（续）

哈尔基函数

- 为了表示矢量空间中的矢量，每一个矢量空间都需要定义一个基(basis)，哈尔基定义为

$$\phi(x)=\begin{cases}1 & 0\le x<1\\ 0 & \text{其他}\end{cases}$$

- 为生成矢量空间而定义的基函数也叫做尺度函数(scaling function)。哈尔基尺度函数定义为

$$\phi_i^j(x)=\phi(2^j x-i),\quad i=0,1,\cdots,(2^j-1)$$

  - 其中，*j*为尺度因子，使函数图形缩小或放大
    *i*为平移参数，使函数沿*x*轴方向平移

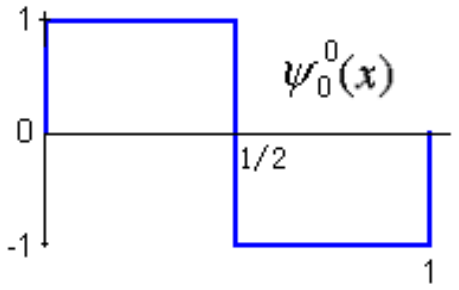
小波变换 Wavelet transform（续）
哈尔函数（Haar小波）

- **哈尔小波(函数)**
  - —最古老和最简单的小波，定义为

$$\psi(x)=\begin{cases}1 & \text{当 } 0\le x<1/2\\ -1 & \text{当 } 1/2\le x<1\\ 0 & \text{其他}\end{cases}$$

  - —生成矢量空间W^0的哈尔小波

$$\psi_0^0(x)=\begin{cases}1 & 0\le x<1/2\\ -1 & 1/2\le x<1\\ 0 & \text{其他}\end{cases}$$

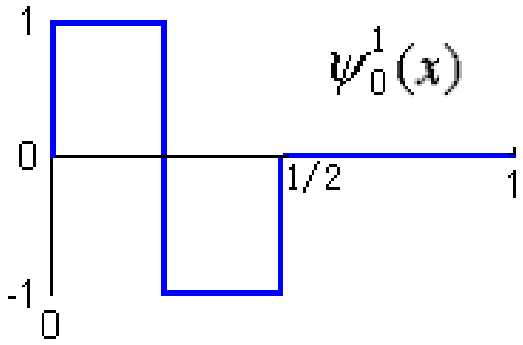


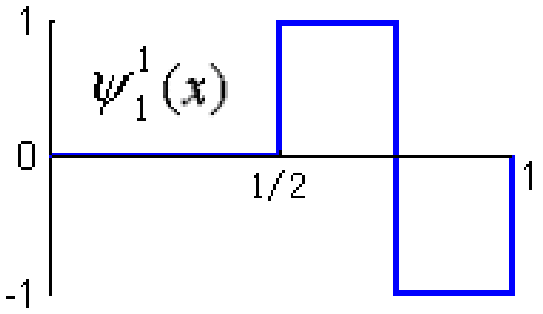
小波变换 Wavelet transform（续）

哈尔函数（Haar小波）

—生成矢量空间W^1的哈尔小波

$$\psi_0^1(x)=\begin{cases}1 & 0\le x<1/4\\ -1 & 1/4\le x<1/2\\ 0 & \text{其他}\end{cases}\qquad \psi_1^1(x)=\begin{cases}1 & 1/2\le x<3/4\\ -1 & 3/4\le x<1/2\\ 0 & \text{其他}\end{cases}$$





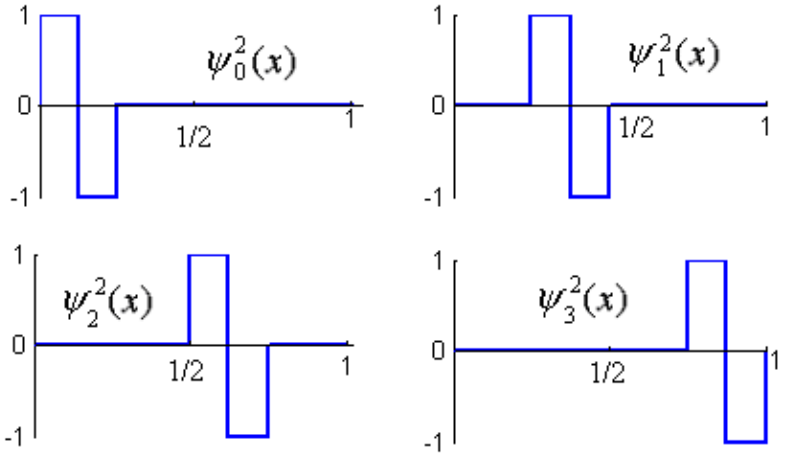
小波变换 Wavelet transform（续）

哈尔函数（Haar小波）

—生成矢量空间W^2的哈尔小波

$$\psi_0^2(x)=\begin{cases}1 & 0\le x<1/8\\ -1 & 1/8\le x<2/8\\ 0 & \text{其他}\end{cases}\qquad \psi_1^2(x)=\begin{cases}1 & 2/8\le x<3/8\\ -1 & 3/8\le x<4/8\\ 0 & \text{其他}\end{cases}$$

$$\psi_2^2(x)=\begin{cases}1 & 4/8\le x<5/8\\ -1 & 5/8\le x<6/8\\ 0 & \text{其他}\end{cases}\qquad \psi_3^2(x)=\begin{cases}1 & 6/8\le x<7/8\\ -1 & 7/8\le x<1\\ 0 & \text{其他}\end{cases}$$



小波变换 Wavelet transform（续）
哈尔函数（Haar小波）

- 哈尔小波变换系数计算

—[例] 假设有一幅分辨率有4个像素P_0、P_1、P_2、P_3的一维图像，对应的像素值或称图像位置的系数分别为

[9 7 3 5]

计算该图像的哈尔小波变换系数

- 步骤1：求均值(averaging)。计算相邻像素对的平均值，得到一幅分辨率比较低的新图像，它的像素数目变成了2个，即新的图像的分辨率是原来的1/2，相应的像素值为

[8 4]

小波变换 Wavelet transform（续）
哈尔函数（Haar小波）

- **步骤2**：求差值(differencing)。为能从2个像素组成的图像重构由4个像素组成的原始图像，就需要存储一些图像的细节系数(detail coefficient)
  - 方法是把像素对的第一个像素值减去这个像素对的平均值，或者使用这个像素对的差值除以2

原始图像用两个均值和两个细节系数表示为

[8 4 1 -1]

- **步骤3**：重复步骤1和2，把由第一步分解得到的图像进一步分解成分辨率更低的图像和细节系数。其结果，整幅图像表示为

[6 2 1 -1]

小波变换 Wavelet transform（续）
哈尔函数（Haar小波）

表 哈尔变换过程

分辨率	平均值	细节系数
4	[9 7 3 5]	
2	[8 4]	[1 -1]
1	[6]	[2]

—把由4个像素组成的一幅图像用一个平均像素值和三个细节系数表示，这个过程称为哈尔小波变换(Haar wavelet transform)，也称哈尔小波分解(Haar wavelet decomposition)。这个概念可以推广到使用其他小波基的变换

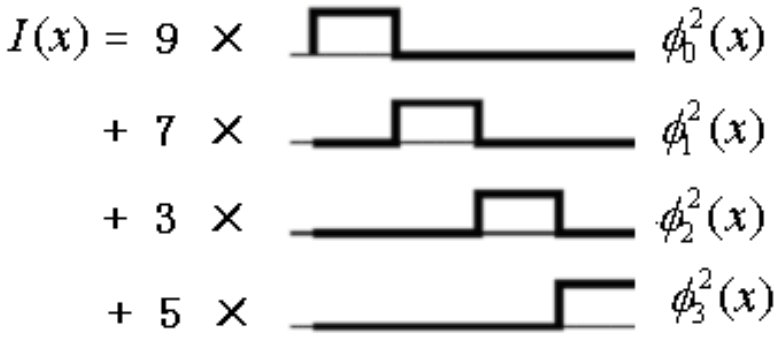
—特点：

- (1) 变换过程中没有丢失信息，因为能够从所记录的数据中重构出原始图像。
- (2) 对这个给定的变换，可从所记录的数据中重构出各种分辨率的图像。
- (3) 通过变换之后产生的细节系数的幅度值比较小，为图像压缩提供了一种途径，如去掉微不足道的系数

小波变换 Wavelet transform（续）
哈尔函数（Haar小波）

- 哈尔小波变换
  - —在上例中的求均值和差值的过程实际上就是一维小波变换的过程，现在用数学方法重新描述哈尔小波变换
    - *I*(*x*)图像用V^2中的哈尔基表示

$$I(x)=9\phi_0^2(x)+7\phi_1^2(x)+3\phi_2^2(x)+5\phi_3^2(x)$$

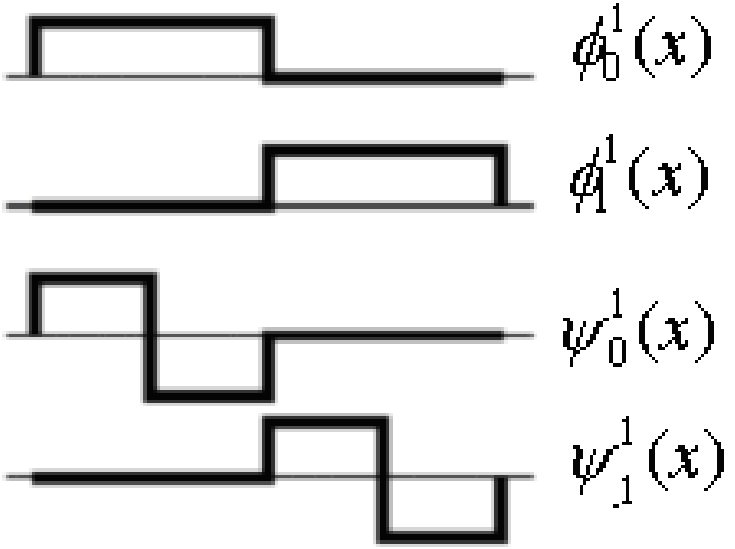


小波变换 Wavelet transform（续）
哈尔函数（Haar小波）

- **I(x)图像用V^1和W^1中的函数表示**
  生成V^1矢量空间的基函数为$\phi_0^1(x)$ 和 $\phi_1^1(x)$，生成矢量空间W^1的小波函数为$\psi_1^1(x)$ 和 $\psi_0^1(x)$，I(x)可表示为

$$I(x) = c_0^1\phi_0^1(x) + c_1^1\phi_1^1(x) + d_0^1\psi_0^1(x) + d_1^1\psi_1^1(x)$$

$$I(x) = 8 \times \phi_0^1(x) + 4 \times \phi_1^1(x) + 1 \times \psi_0^1(x) + (-1) \times \psi_1^1(x)$$



小波变换 Wavelet transform（续）
哈尔函数（Haar小波）

- **$I(x)$图像用V^0、W^0和W^1中的函数表示**
  生成矢量空间V^0的基函数为 $\phi_0^0(x)$，生成矢量空间W^0的小波函数为 $\psi_0^0(x)$，生成矢量空间W^1的小波函数为
  $\psi_0^1(x)$和 $\psi_1^1(x)$ ， $I(x)$可表示为

$$I(x) = c_0^0\phi_0^0(x) + d_0^0\psi_0^0(x) + d_0^1\psi_0^1(x) + d_1^1\psi_1^1(x)$$

$$I(x) = \quad 6 \times \phi_0^0(x)$$

$$+ \quad 2 \times \psi_0^0(x)$$

$$+ \quad 1 \times \psi_0^1(x)$$

$$+ \quad -1 \times \psi_1^1(x)$$

小波变换 Wavelet transform（续）
哈尔函数（Haar小波）

- 用小波对图像进行变换的两种方法
  - — 标准分解(standard decomposition)
    - 首先使用一维小波对图像每一行的像素值进行变换，产生每一行像素的平均值和细节系数，然后使用一维小波对这个经过行变换的图像的列进行变换，产生这个图像的平均值和细节系数
    - 分解的过程如下：

```
procedure StandardDecomposition(C: array [1. . . h, 1. . . w] of reals)
    for row 1 to h do
        Decomposition(C [row, 1 . . . w])
    end for
    for col 1 to w do
        Decomposition(C [1 . . . h, col])
    end for
end procedure
```

小波变换 Wavelet transform（续）

哈尔函数（Haar小波）

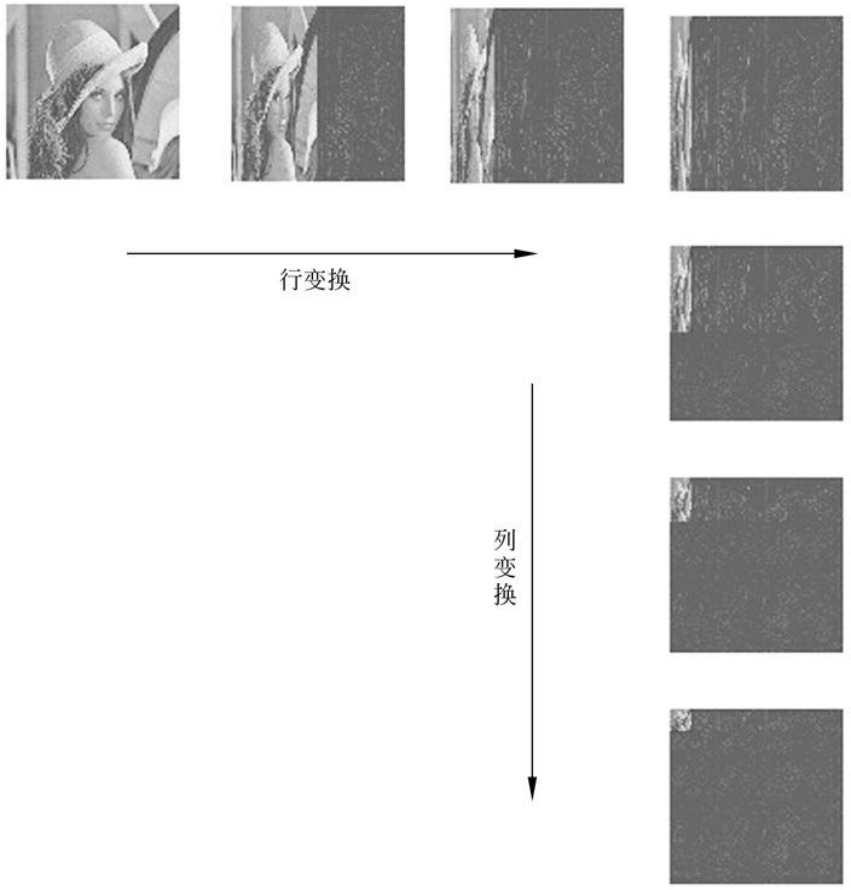


图 图像的标准分解方法

小波变换 Wavelet transform（续）
哈尔函数（Haar小波）

—非标准分解(nonstandard decomposition)

- **用一维小波交替地对每一行和每一列像素值进行变换。**
  - 对每一行计算像素对的均值和差值，然后对每一列计算像素对的均值和差值
  - 对包含均值的1/4像素计算行和列的均值和差值，依此类推

```
procedure NonstandardDecomposition(C: array[1...h, 1...h] of reals)
    C ← C/h    (normalize input coefficients)
    while h > 1 do
        for row 1 to h do
            DecompositionStep(C [row, 1 . . . h])
        end for
        for col 1 to h do
            DecompositionStep(C [1 . . . h, col])
        end for
        h ← h/2
    end while
end procedure
```

小波变换 Wavelet transform（续）

哈尔函数（Haar小波）

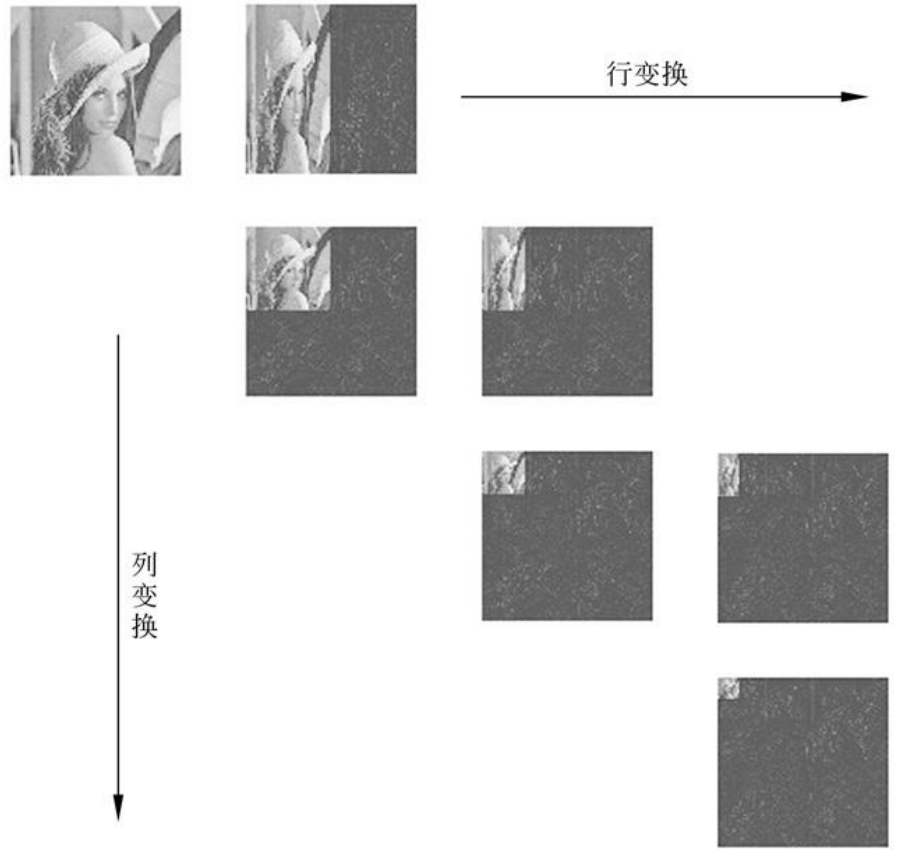


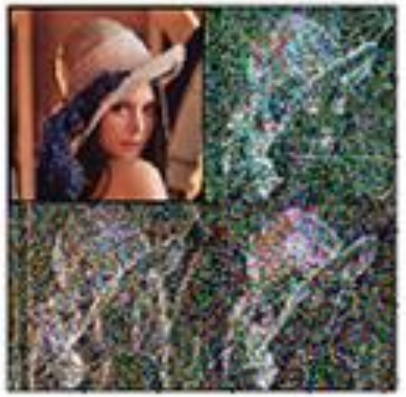
图 图像的非标准分解方法

小波变换 Wavelet transform（续）

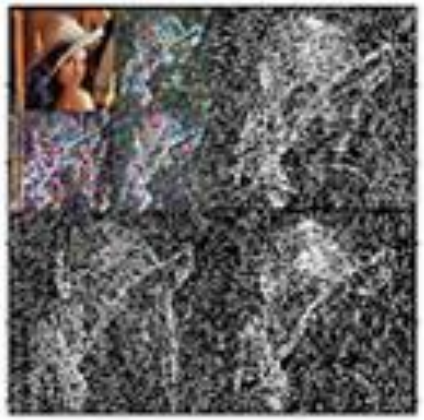
哈尔函数（Haar小波）



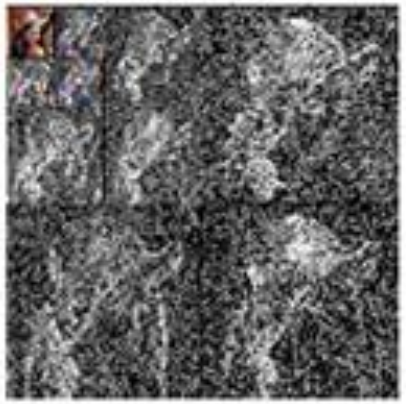
（a）原始图像



（b）1/4分辨率图像



（c）1/16分辨率图像

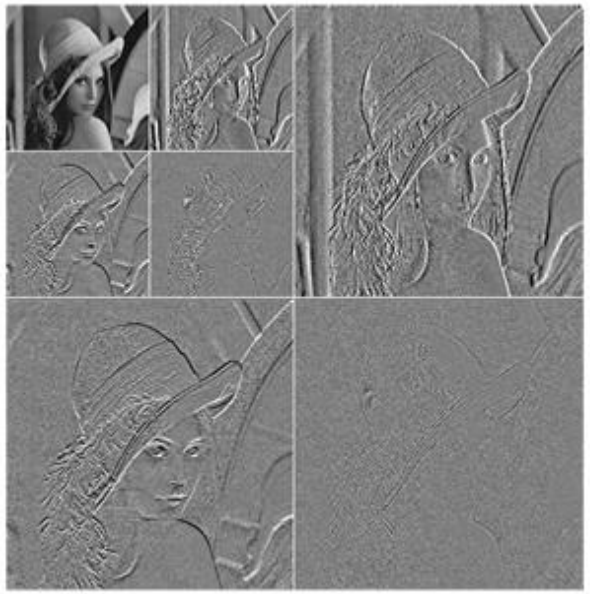


（d）1/64分辨率图像

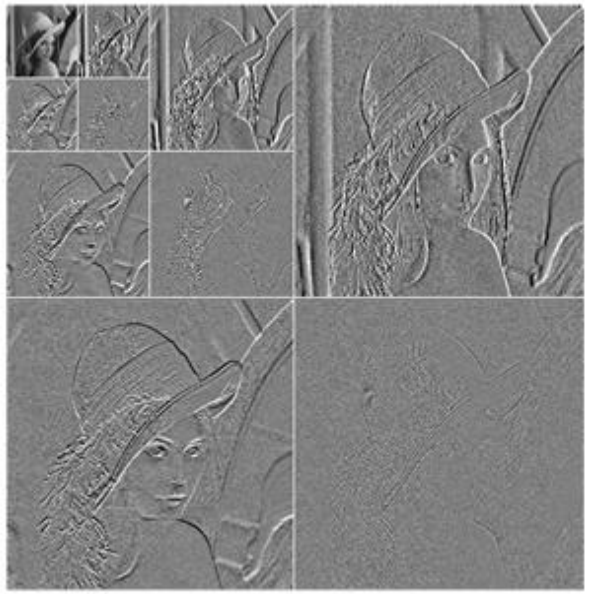
图 使用小波分解产生多种分辨率图像

小波变换 Wavelet transform（续）
哈尔函数（Haar小波）

灰度图



(c) 1/16分辨率图像



(d) 1/64分辨率图像

降维

- 高维数据因为其计算代价昂贵（纬度高计算必然昂贵）和建立索引结构的困难（空间索引结构往往面临着“维度灾”），因此有对其进行数据压缩的需求，即对高维数据进行降维
- 傅里叶变换和小波变换都可以用来对高维数据进行降维
- 傅里叶变换用不同频率的三角函数的和去拟合原始信号，对于每个单独的三角函数，只需要记录其相位和幅度即可。信息论可以证明，对于一个长度为n的离散信号（计算机中所有的信号都肯定是离散的），可以分解为n个三角函数的线性组合，这n个三角函数的频率是按2的指数倍递增的，这两种表示方法是等价的，也就是从后者（三角函数的信息：相位、幅度）可以完美地重构出前者。而原始信号中的主要信息都集中在低频分量上，高频分量往往是噪音，因此可以对变换后的三角函数系数只保留其前k个系数，而忽略剩余的高频部分，这样就将数据降为了k维，由于高频大多是噪音，因此丢失信息并不多
- 小波变换也是一样的，只不过它使用的基底函数不是三角函数，而是所谓的小波函数，小波分析或者说小波变换要做的就是将原始信号表示为一组小波基的线性组合，然后通过忽略其中不重要的部分达到数据压缩或者说降维的目的