

Data Mining and Big data anlysis

数据挖掘及大数据分析

Chpter 5：数据仓库与联机分析处理

03-企业实践案例

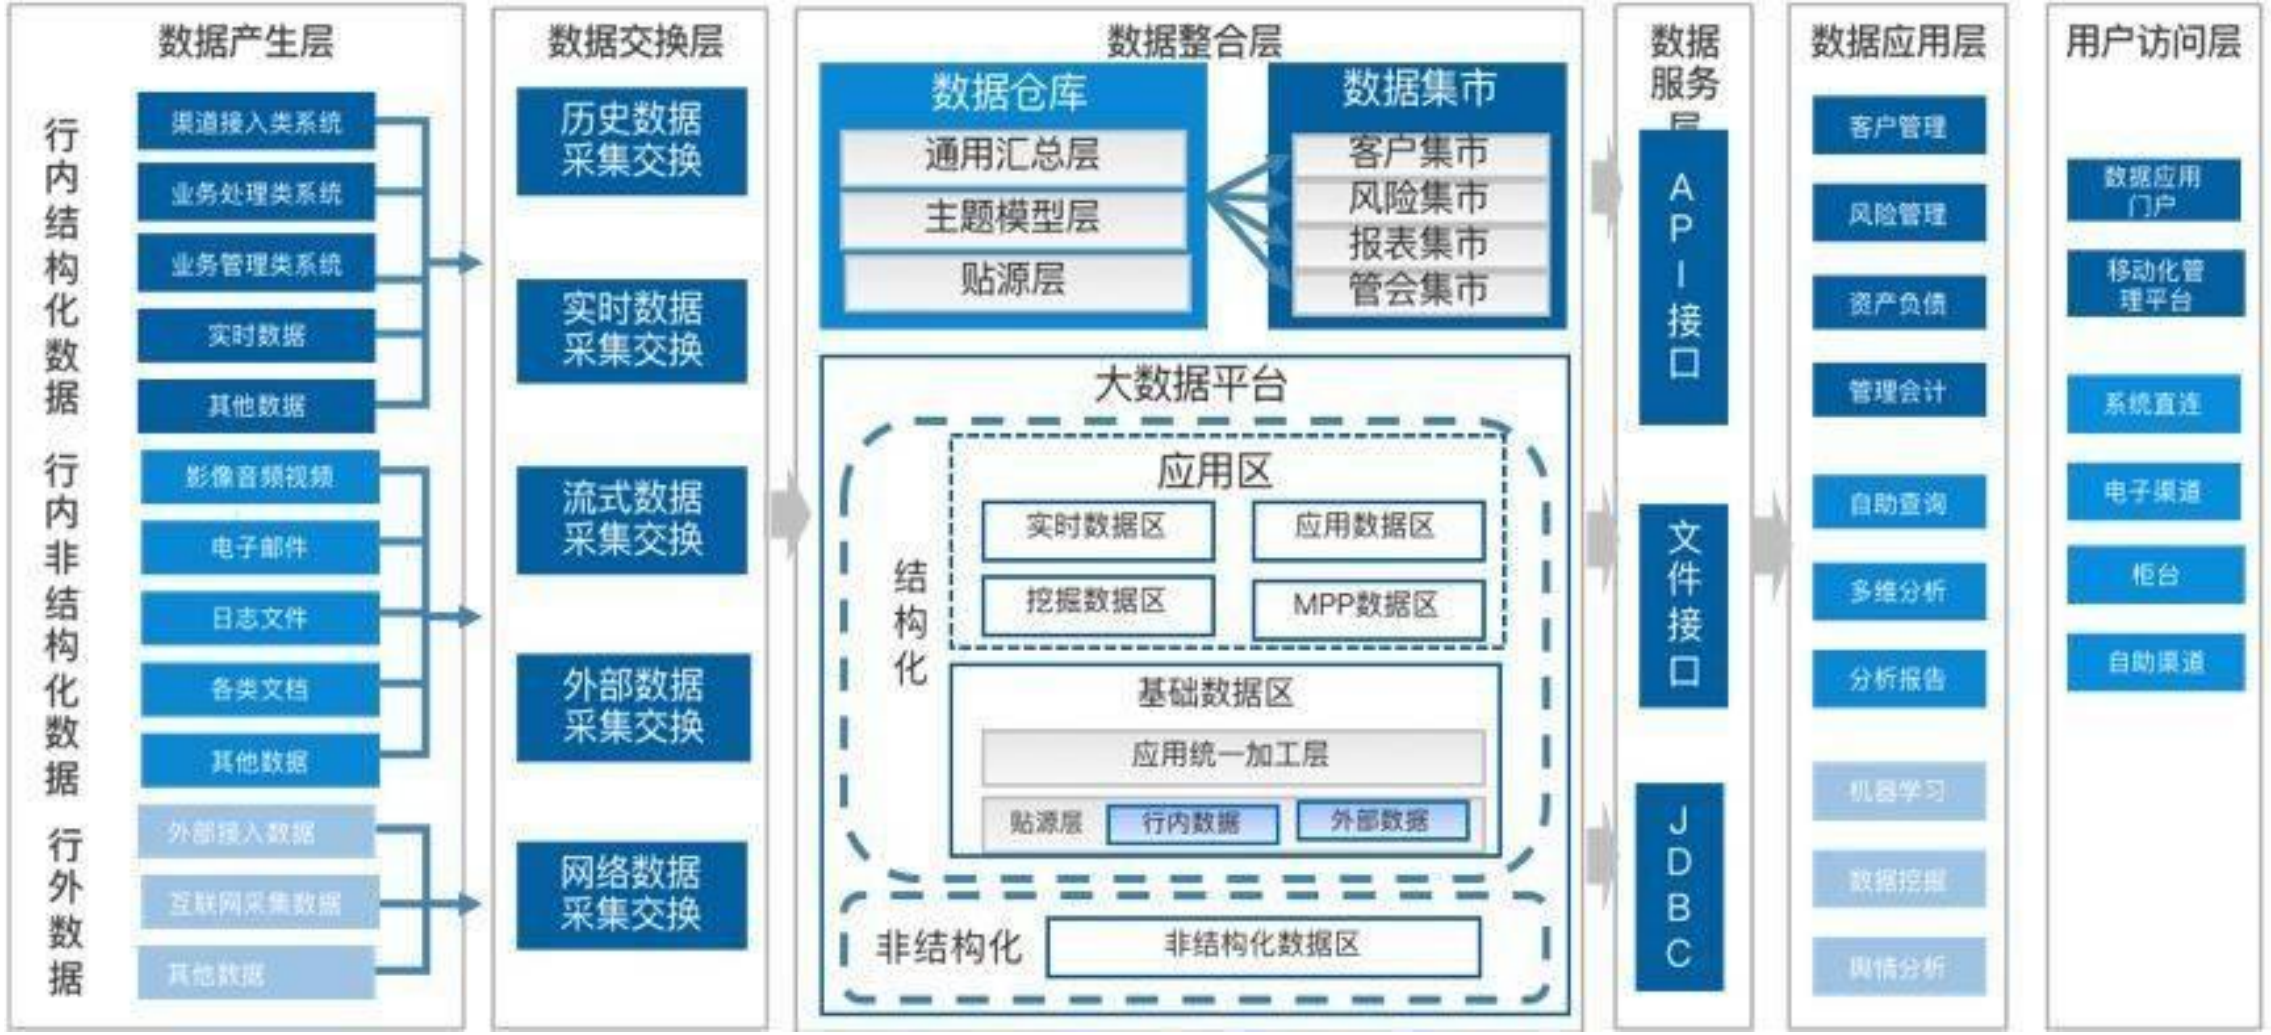
王东、张谦、丁玥

上海交通大学软件学院RFID与物联网实验室

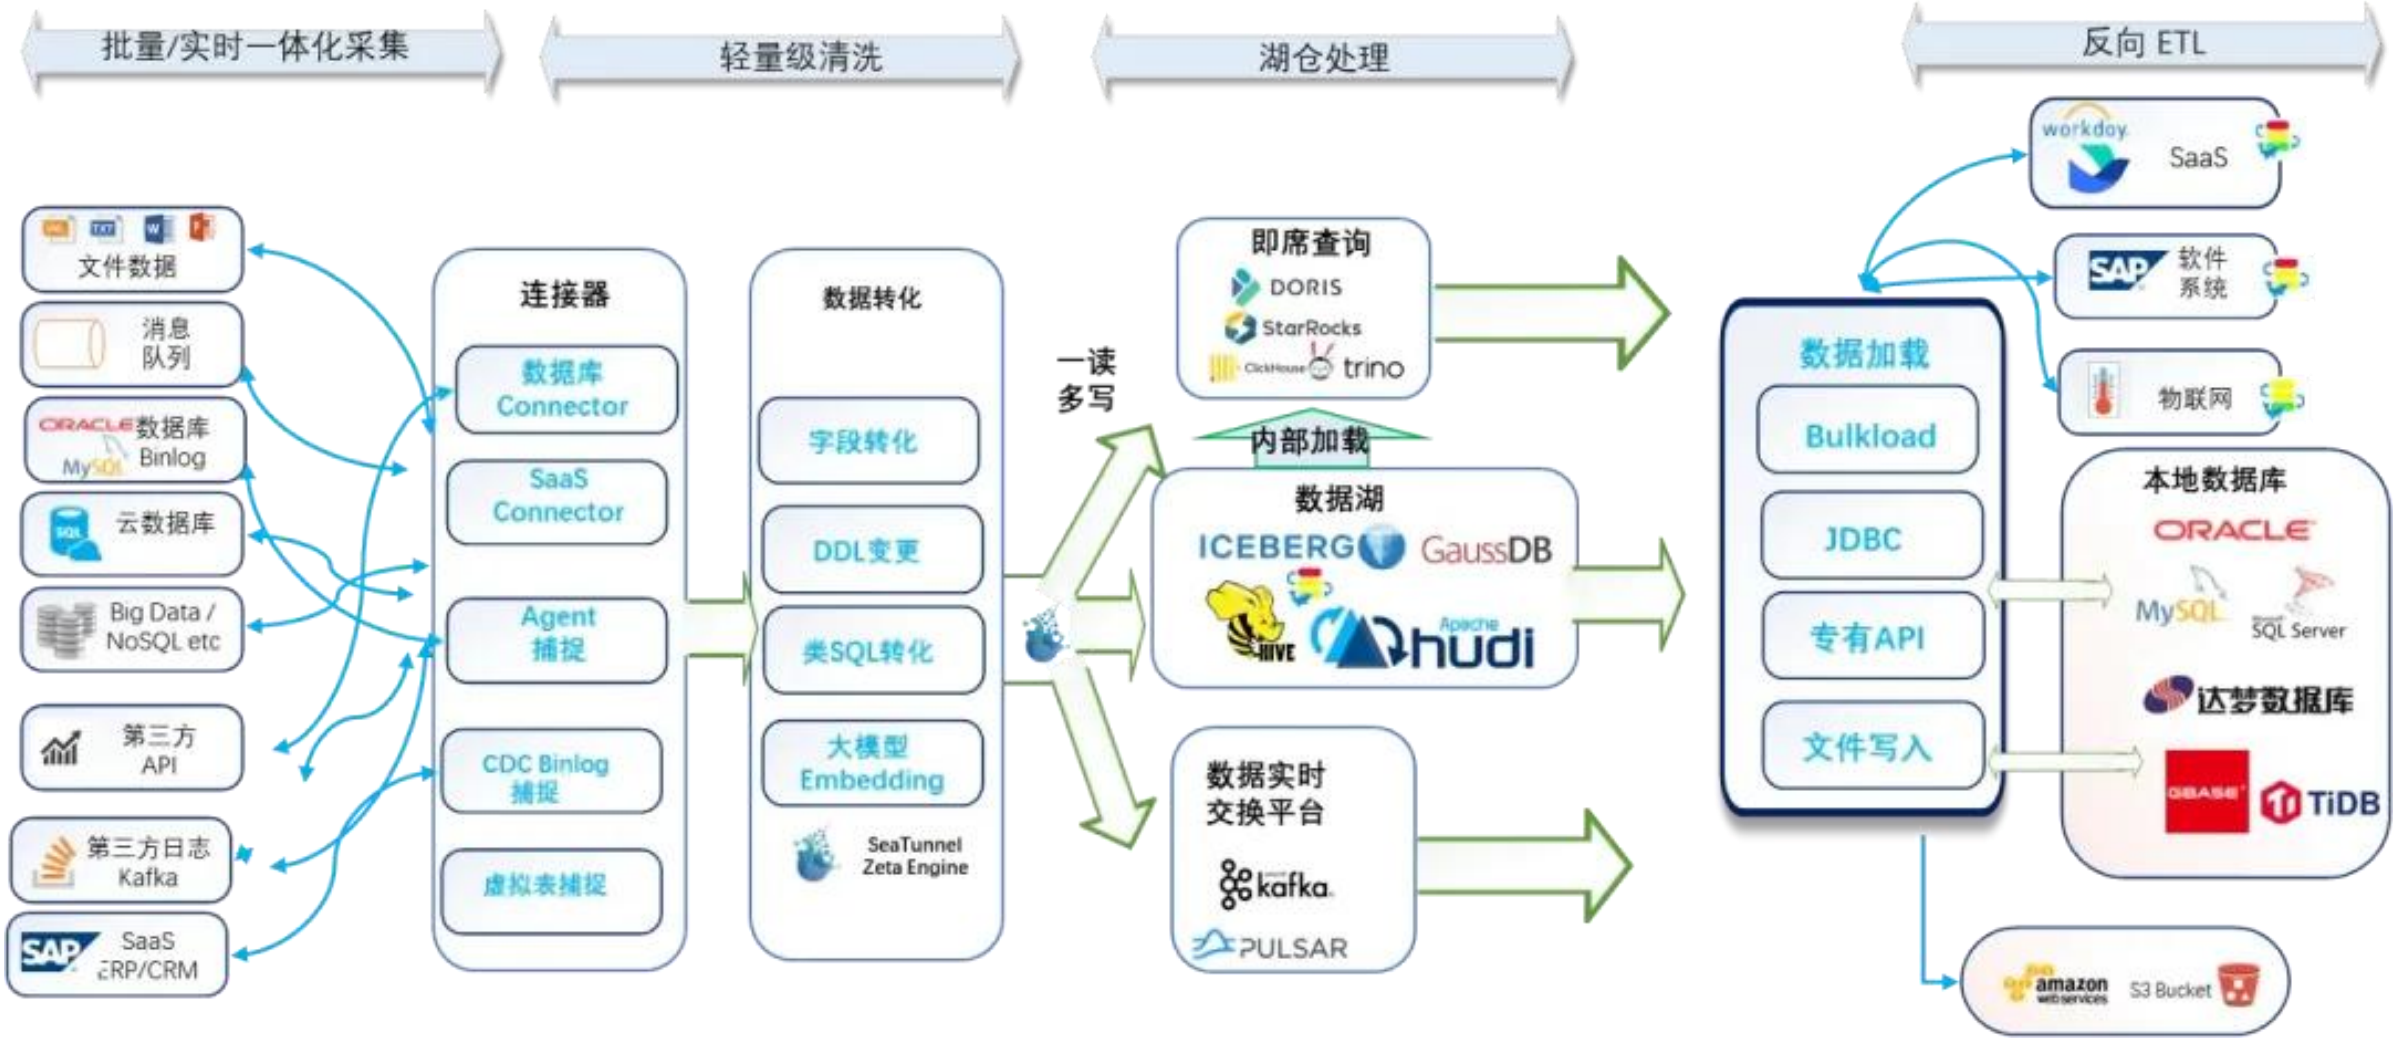
2025年春季

课程内容设计思路梳理

数据应用服务架构


数据产生层
行内结构化数据
渠道接入类系统
业务处理类系统
业务管理类系统
实时数据
其他数据
行内非结构化数据
影像音频视频
电子邮件
日志文件
各类文档
其他数据
行外数据
外部接入数据
互联网采集数据
其他数据
数据交换层
历史数据采集交换
实时数据采集交换
流式数据采集交换
外部数据采集交换
网络数据采集交换
数据整合层
数据仓库
通用汇总层
主题模型层
贴源层
数据集市
客户集市
风险集市
报表集市
管会集市
大数据平台
结构化
应用区
实时数据区
应用数据区
挖掘数据区
MPP数据区
基础数据区
应用统一加工层
贴源层
行内数据
外部数据
非结构化
非结构化数据区
数据服务层
API接口
文件接口
JDBC
数据应用层
客户管理
风险管理
资产负债
管理会计
自助查询
多维分析
分析报告
机器学习
数据挖掘
舆情分析
用户访问层
数据应用门户
移动化管理平台
系统直连
电子渠道
柜台
自助渠道

数据集成业界领先实践2024年



数据集成的知识体系


集成方式
批量集成
增量集成
准实时集成
实时集成
事件集成
同步集成
异步集成
流处理
复制
归档
集成架构
点对点架构
集中式架构
数据仓库架构
数据湖架构
服务导向架构
微服务架构
虚拟化架构
云化集成架构
相关术语
ETL
ELT
集成编排
数据发布与订阅
数据集成制度
数据集成标准
集成类型

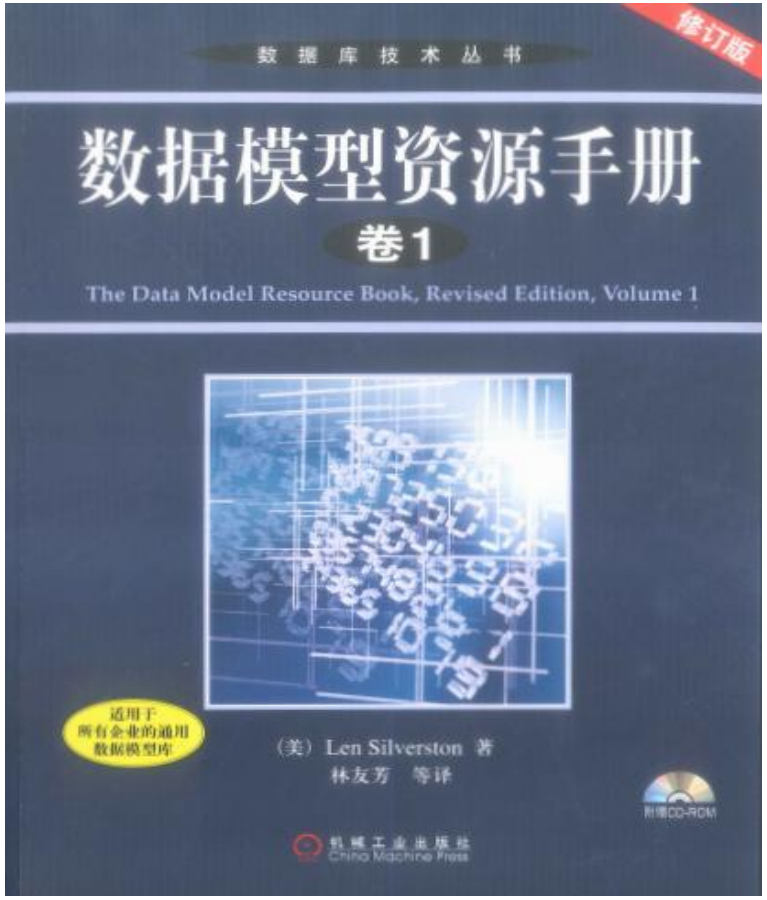
物联网数据采集

- 通过物联网实现人、机、物、系统等产业链供应链要素的全面连接、实时化、在线化
- 通过工业互联网为新一代信息通信技术与产业链深度融合提供新型基础设施、应用模式和生态



数据智能方向的数据视角：数据规划、数据治理、数据挖掘

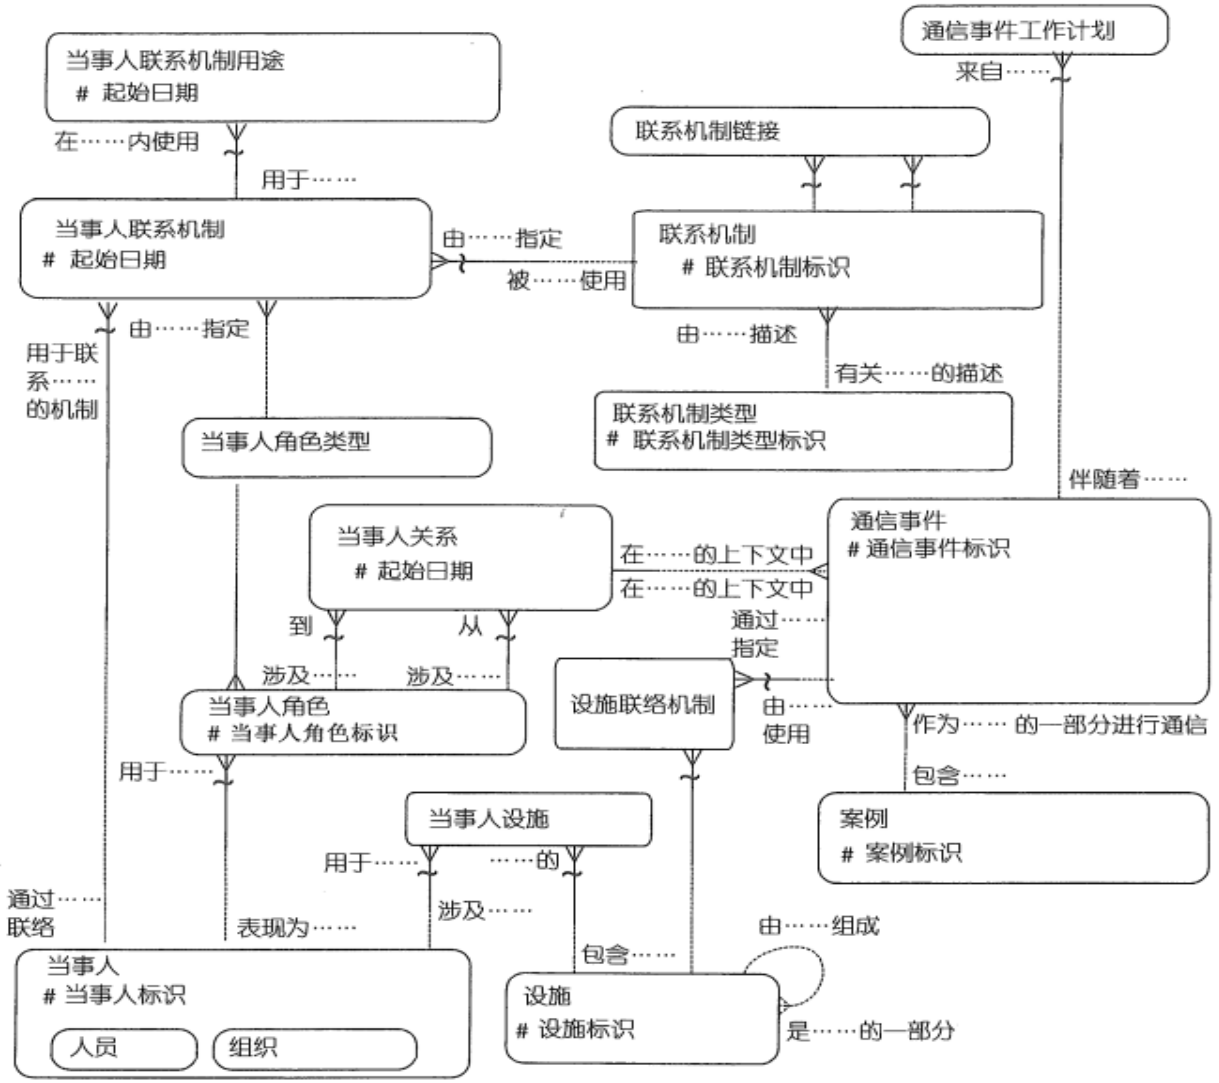
方法论2：行业数据模板



第1章 绪论
第2章 人与组织
第3章 产品模型
第4章 产品订购模型
第5章 装运模型
第6章 工作计划模型
第7章 发票模型
第8章 会计和预算模型
第9章 人力资源模型
第10章 根据企业数据模型建立数据
第11章 一个数据仓库数据模型范例
第12章 销售分析星型模式设计
第13章 人力资源的星型模式设计
第14章 附加的星型模式设计
第15章 实施通用数据模型

- 卷1为一系列的行业提供了企业业务生命周期中每一个阶段所需的通用数据模型
  - 人和组织间交互并形成各种关系
  - 产品（服务或物理上的货物）的定义、供应、定价、成本，可能还有库存
  - 人和／或组织间因购买产品而建立起来的承诺（在不同场合或许会称为订单、协议、合同、金融事务，等等）
  - 装运，将物理货品运输到它们的目的地
  - 工作计划，需要对工作进行计划和跟踪，如维修、制造、项目和服务工作的计划
  - 开发票确定应付款
  - 预算和会计用于管理财务问题
  - 对人力资源进行管理和跟踪
- 卷1 中的数据模型适合于大多数企业，因为上述步骤基本反映了多数行业的运作模式。卷1 所描述的这些数据模型标识出了适合于各种行业的基本的信息需求

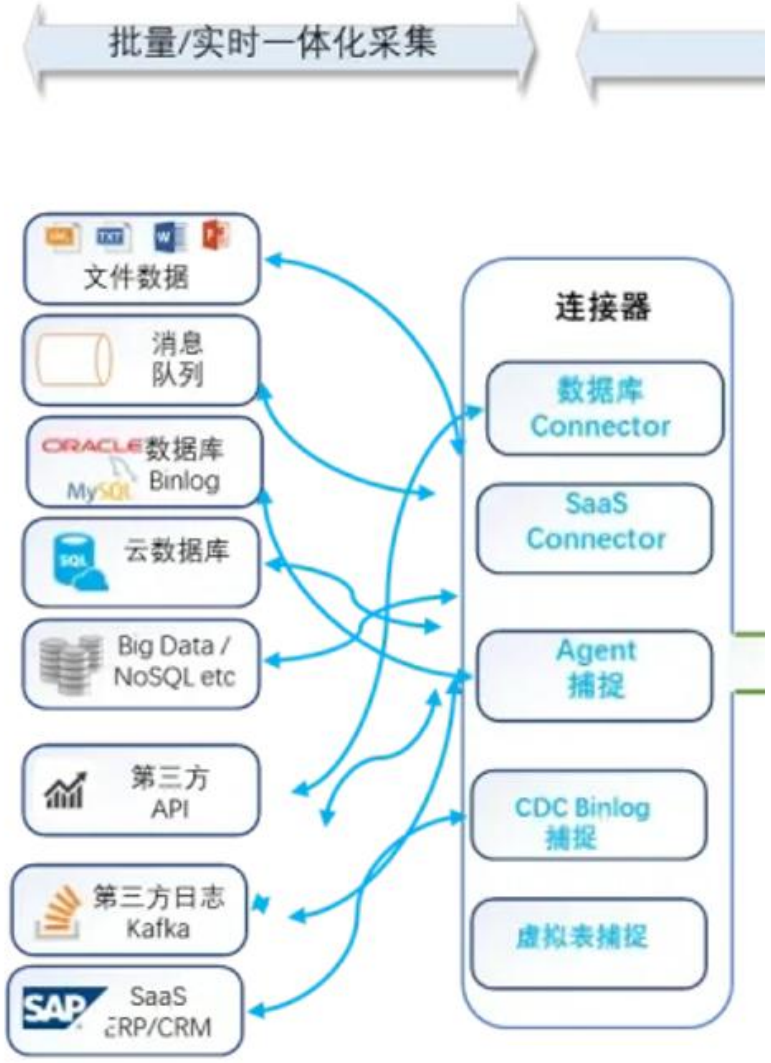
当事人整体数据模型



- 最常见的业务信息需求是针对人和组织提出一些问题，并且能针对这些问题给出准确的、可信赖的回答
  - 在办理业务的过程中涉及到的人和组织的属性或特点是什么？
  - 在不同的人之间、在不同的组织之间以及在人和组织之间存在哪些关系？
  - 人以及组织的地址、电话号码和其他联系方式是什么？怎样才能同他们取得联系？
  - 在各种当事人之间发生了哪些类型的通信或联系？为了有效地加强这些通信的后续工作，需要做哪些工作？
- 几乎所有业务应用都要求记录有关人和组织的信息，如客户、供应商、子公司、雇员和承包商等，这些信息在许多不同的系统中是冗余的。因此，确保客户联系方式等关键信息的一致和准确是非常困难的
  - 有关人和组织信息可能应用于销售、市场、采购、订单处理、发票、项目管理和财务中

数据集成：数据源统一化采集

- 数据集成的起点在于多源异构数据的采集
  - —传统数据库（如Oracle、MySQL、信创数据库等）
  - —文件（Excel、CSV、OSS、S3、FTP）
  - —SaaS服务（如SAP、Salesforce）
  - —API等非结构化接口
- 设计多样化的连接器，实现对多种类型数据源广泛覆盖
  - —数据库连接器
  - —SaaS连接器
- Agent模式 和 CDC（Change Data Capture）增量采集技术的引入，保证了数据采集的实时性与完整性，为后续数据处理提供高质量的输入



数据集成：轻量级数据转换

- 此阶段旨在消除数据孤岛问题，将原始数据转化为易于分析的标准化形式。对数据进行轻量化的转换处理，以满足不同业务系统的需求
  - —数据结构的规范化
  - —DDL自动生成
  - —SQL逻辑优化
  - —基于 Embedding 的数据嵌入技术，可以通过大数据计算引擎（如SeaTunnel Zeta Engine）实现对复杂数据结构的深度处理



数据智能方向的数据视角：数据规划、数据治理、数据挖掘

内 容 简 介

本书是一本全面关注企业数据标准化方面的工具书，主要分为5篇。第1篇介绍了数据标准化是数据治理的基础，包括数据标准化与数据治理的关系，以及数据标准化主要内容、本书阅读导引。第2篇介绍了数据标准化框架体系，包括架构类数据标准、对象类数据标准、基础类数据标准。第3篇介绍了数据标准化实施流程与方法，包括建立数据标准化保障机制、现状分析及评估、技术平台和工具、数据标准化关键域实施。第4篇介绍了数据标准化评价，包括数据标准化评价方法、数据标准成熟度评价、数据标准化成熟度评价流程。第5篇介绍了数据标准化案例，包括油气行业、多元化集团、装备制造行业、核电行业、汽车行业、金融行业、政务行业、互联网行业等行业的数据治理案例，为读者提供了专业、丰富、可信的数据治理实施范例。

本书是工业大数据应用技术国家工程实验室多年潜心研究的重要科研成果的总结和凝聚，既具有理论高度，也具备面向中国各行业企业的可实操性。参与本书编写的作者均为国内相关领域的专家，所有案例均来自这些企业的实践。

未经许可，不得以任何方式复制或抄袭本书之部分或全部内容。
版权所有，侵权必究。

图书在版编目（CIP）数据

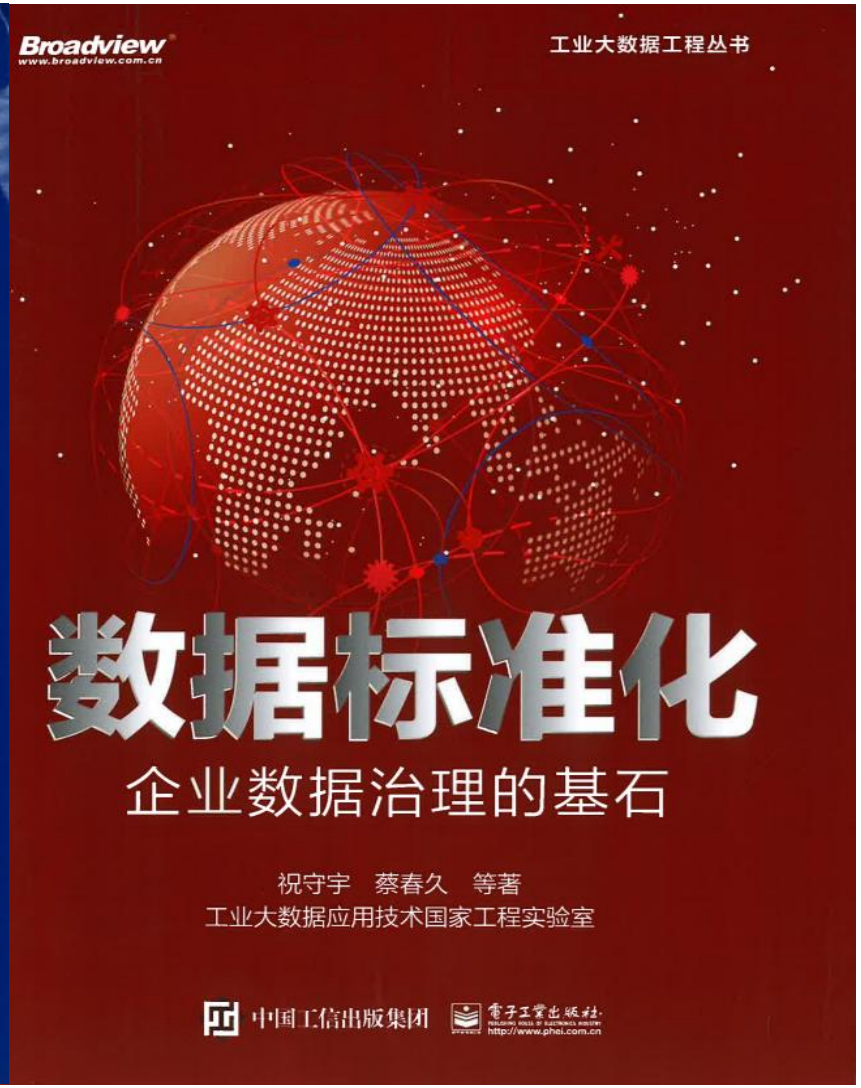
数据标准化：企业数据治理的基石 / 祝守宇等著. —北京：电子工业出版社，2023.1
（工业大数据工程丛书）
ISBN 978-7-121-44398-5

Ⅰ. ①数… Ⅱ. ①祝… Ⅲ. ①企业管理—数据管理—研究 Ⅳ. ①F272.7

中国版本图书馆 CIP 数据核字（2022）第 192190 号

责任编辑：王　静
印　刷：三河市华成印务有限公司
装　订：三河市华成印务有限公司
出版发行：电子工业出版社
北京市海淀区万寿路 173 信箱　邮编：100036
开　本：787×980　1/16　印张：34.5　字数：721.5 千字
版　次：2023 年 1 月第 1 版
印　次：2023 年 1 月第 1 次印刷
定　价：158.00 元





目录

第 1 篇　概述篇

第 1 章　工业企业需要数据治理 2

1.1　工业革命的演变与发展趋势 2
1.2　工业大数据是第四次工业革命的核心基础 4
1.3　各国的工业大数据战略 6
1.4　工业企业数据的核心价值 7
1.5　我国各行业数据治理现状 10
1.6　数据治理是工业大数据的基础 12
1.7　工业企业数据治理面临的挑战 12
本章精要 14

第 2 章　工业企业数据治理概述 15

2.1　数据治理的相关概念和定义 15
2.2　数据的分类 17
2.3　数据治理的顶层架构 20
2.4　数据治理的核心内容 21
本章精要 22

第 3 章　主流数据治理标准及框架介绍 23

3.1　国际标准 23
3.2　国内标准及模型 24
3.3　专业组织 26
3.4　国内外数据治理体系的对比分析 28
本章精要 30

第 4 章　数据治理的发展趋势 31

4.1　国内外数据治理的演变与发展 31
4.2　数据隐私保护政策 32
4.3　区块链与数据共享 33
4.4　5G 技术与数据安全 38
4.5　新技术与数据治理 39
4.6　数据文化与伦理道德 40
4.7　工业企业数据的运营 41
本章精要 43

第 5 章　本书阅读导引 44

5.1　数据治理是一个系统工程 44
5.2　工具是数据治理的保障 45
5.3　实施数据治理有路线可循 45
5.4　数据治理已在诸多行业成功实施 46
参考资料 47

第 2 篇　体系篇

第 6 章　数据管控 51

6.1　数据管控概述 51
6.2　组织架构 53
6.2.1　数据治理组织架构 53
6.2.2　数据治理组织模式 55
6.2.3　数据治理职责分工 58
6.3　制度规范 61
6.3.1　数据治理制度框架 61
6.3.2　数据治理制度修订 64
6.4　执行流程 65
6.4.1　数据治理总体流程框架 65
6.4.2　数据治理典型场景的流程 67
6.5　设计机制 70
6.6　绩效体系 72
6.7　标准体系 74
本章精要 76

第 7 章　数据战略 77

7.1　数据战略概述 77
7.2　数据战略规划 77
7.2.1　愿景和目标 78
7.2.2　基本原则 79
7.2.3　战略举措选择 80
7.2.4　模型工具 81
7.3　数据战略实施 82
7.3.1　实施策略 83
7.3.2　实施路径 83
7.3.3　实施步骤 83
本章精要 87

第 8 章　数据架构 88

8.1　数据架构概述 89
8.2　框架设计 90
8.2.1　数据分布 90
8.2.2　数据主题域 92
8.2.3　数据关联关系 93
8.3　数据建模 98
8.3.1　概念数据模型 99
8.3.2　逻辑数据模型 100
8.3.3　物理数据模型 101
8.3.4　数据模型开发方法 102
本章精要 105

第 9 章　主数据管理 106

9.1　主数据和主数据管理 106
9.1.1　主数据的特征 106
9.1.2　主数据管理的基本概念 107
9.2　主数据标准管理 108
9.3　主数据全生命周期管理 109

上海交通大学RFID与物联网研究所

9.4 主数据应用管理 110
9.5 企业常用的几类主数据 112
9.5.1 物料主数据 112
9.5.2 设备主数据 113
9.5.3 资产主数据 114
9.5.4 财务主数据 115
9.5.5 组织机构和员工主数据 116
本章精要 116

第 10 章 元数据管理 117

10.1 元数据的定义 117
10.2 元数据分类 117
10.2.1 业务元数据 118
10.2.2 技术元数据 119
10.2.3 操作元数据 120
10.3 元数据核心能力 120
10.4 元数据的价值 123
本章精要 124

第 11 章 数据指标管理 125

11.1 数据指标管理概述 125
11.1.1 数据指标应用和管理中的挑战 125
11.1.2 设计目的 126
11.1.3 设计思路 126
11.2 体系框架 128
11.2.1 典型的数据指标定义框架 128
11.2.2 指标选取原则及方法 129
11.2.3 指标体系层级设计 130
11.2.4 指标体系评价方法 131
11.3 找指标 132
11.4 理指标 134
11.5 管指标 136
11.6 用指标 137
本章精要 137

第 12 章 时序数据管理 138

12.1 时序数据管理概述 138
12.2 时序数据的特点 139
12.3 时序数据的应用 141
12.3.1 技术挑战 141
12.3.2 典型的技术架构及特点 142
12.3.3 系统核心功能 143
本章精要 143

第 13 章 数据质量管理 144

13.1 数据质量需求 144
13.2 数据质量检查 145
13.3 数据质量分析 146
13.4 数据质量提升 147
13.5 数据质量评估 149
13.5.1 数据质量问题的起因 150
13.5.2 数据质量管理技术指标 151
13.5.3 数据质量管理业务指标 152
本章精要 153

第 14 章 数据安全管理 155

14.1 数据安全管理概述 155
14.2 数据安全体系框架 156
14.3 数据安全防护策略 159
14.4 数据安全审计 161
14.5 数据安全风险评估 162
14.6 数据应急保障 164
本章精要 165

第 15 章 数据交换与服务 166

15.1 数据交换与服务的意义 167
15.2 数据交换与服务技术演进 168
15.2.1 文件共享技术 168
15.2.2 数据库中间表技术 168
15.2.3 点对点接口技术 168
15.2.4 消息队列技术 170
15.2.5 企业服务总线交换技术 171
15.2.6 ETL 数据交换技术 173
15.2.7 物联网数据采集交换技术 173
15.3 工业企业数据交换与服务标准体系架构 175
15.3.1 CPS 信息交换模型 176
15.3.2 设备互联总线 177
15.3.3 应用互联总线 178
15.3.4 数据总线 179
15.3.5 开放互联 API 网关 181
本章精要 182

第 16 章 数据共享与开放 183

16.1 共享与开放概述 183
16.2 数据资源目录 185
16.3 数据资源准备 186
16.3.1 数据采集 186
16.3.2 数据加工 187
16.3.3 数据保密 187
16.3.4 数据装载 189
16.3.5 数据发布 189
16.4 数据服务 190
16.5 共享与开放评价 190
本章精要 191

第 17 章 数据管理成熟度评估 192

17.1 数据管理成熟度评估模型 192
17.2 数据管理成熟度等级定义 195
17.3 开展数据管理成熟度评估 198
17.4 数据管理成熟度评估实施 199
本章精要 200
参考资料 200

第 3 篇 工具篇

第 18 章 数据治理工具概述 203

第 19 章 数据资产运营工具 207

19.1 数据资产目录 207
19.1.1 总体概述 208
19.1.2 数据资产目录系统构建 208
19.1.3 数据资产目录能力评估模型 210
19.2 数据资产价值评估 213
19.2.1 总体概述 213
19.2.2 数据资产价值评估模型 214
19.2.3 数据资产价值评估工具 223
本章精要 224

第 20 章 数据模型管理工具 225

20.1 数据模型管理工具概述 225

上海交通大学RFID与物联网研究所

20.2 企业级数据模型管控 226
20.3 数据标准管控 228
20.3.1 标准的发布和工具访问 228
20.3.2 模型设计中的应用数据标准 228
20.3.3 数据标准应用情况的自动检核 229
20.3.4 自定义标准的发布管理 229
20.4 数据字典的质量检核 230
本章精要 230

第 21 章 数据指标管理工具 231

21.1 指标库管理 231
21.2 指标体系管理 232
21.3 指标评价管理 233
21.4 指标应用管理 234
本章精要 235

第 22 章 主数据管理工具 236

22.1 主数据提取与整合 236
22.2 主数据模型管理 237
22.3 主数据清洗管理 238
22.3.1 主数据清洗的内容 239
22.3.2 主数据清洗的一般过程 239
22.4 主数据全周期管理 242
22.5 主数据质量管理 244
22.6 主数据发布与共享 246
本章精要 248

第 23 章 元数据管理工具 249

23.1 元数据管理工具概述 249
23.2 元数据在数据架构管理中的应用 250
23.3 元数据在数据资产目录中的应用 251
23.4 元数据在主数据管理中的应用 251
23.5 元数据在数据交换和共享中的应用 251
23.6 元数据在大数据平台中的应用 252
本章精要 253

第 24 章 时序数据处理工具 254

24.1 通用大数据处理工具的不足 254
24.2 时序数据处理工具应具备的功能和特点 255
24.3 时序数据的采集 257
24.4 时序数据处理工具 258
本章精要 260

第 25 章 数据质量管理工具 261

25.1 数据质量管理工具概述 261
25.2 数据质量稽核规则设置 262
25.3 数据质量任务管理 263
25.4 数据质量报告 264
本章精要 264

第 26 章 数据交换与服务工具 265

26.1 数据交换与服务工具概述 265
26.2 数据采集 266
26.3 数据交换 268
26.3.1 前置交换子系统 268
26.3.2 交换传输子系统 269
26.3.3 交换管理子系统 269
26.4 数据加工服务 269
26.5 数据共享服务 271
26.6 工业大数据技术平台 272
26.6.1 工业大数据的采集 272
26.6.2 工业大数据的交换 274
26.6.3 工业大数据的处理 275
本章精要 277

第 27 章 数据安全管理工具 278

27.1 数据安全管理工具概述 278
27.2 数据采集安全管理工具 279
27.2.1 数据分类与分级工具 279
27.2.2 采集内容及策略 279
27.2.3 数据采集人员管理工具 280
27.2.4 数据源鉴别及记录 280
27.3 数据传输安全管理工具 280
27.3.1 加密算法 281
27.3.2 对称加密 281
27.3.3 非对称加密 282
27.4 数据存储安全管理工具 282
27.4.1 数据存储介质管理 283
27.4.2 数据存储安全 283
27.4.3 数据备份和恢复 283
27.4.4 等级划分 284
27.5 数据处理安全管理工具 285
27.6 数据交换安全管理工具 286
27.6.1 数据导入/导出的安全保障 287
27.6.2 数据交换安全 287
27.6.3 数据销毁安全管理 288
27.7 统一的身份认证系统 289
本章精要 290

第 28 章 数据中台 291

28.1 数据中台的概念和定位 291
28.2 数据采集 293
28.2.1 数据采集方式 293
28.2.2 通用数据采集 293
28.2.3 流式数据采集 293
28.3 数据存储 294
28.3.1 分布式数据存储 294
28.3.2 NoSQL 数据存储 294
28.4 数据计算 294
28.4.1 分布式查询 295
28.4.2 分布式计算 295
28.4.3 数据建模 295
28.4.4 数据分析 296
28.5 数据服务 296
28.5.1 API 网关 297
28.5.2 API 生成 298
28.5.3 API 发布 298
28.5.4 API 调用申请 298
28.5.5 API 调用审核 298
28.5.6 API 信息支持 298
28.5.7 API 服务监控 299
28.6 从 ETL 向 ELT 转变 299
本章精要 300
参考资料 300

上海交通大学RFID与物联网研究所

第 4 篇　实施篇

第 29 章　数据治理实施策略和路径选择 303

29.1　实施内容 303
29.2　路径选择 304
本章精要 306

第 30 章　数据治理顶层架构规划与设计 307

30.1　实施内容 307
30.2　步骤和方法 309
30.2.1　顶层设计总体思路 309
30.2.2　数据治理顶层设计要点 311
30.3　成熟度评估 322
本章精要 324

第 31 章　数据资产运营实施 325

31.1　实施内容 325
31.2　步骤和方法 327
本章精要 328

第 32 章　主数据管理实施 329

32.1　实施内容 329
32.2　步骤和方法 329
32.2.1　实施步骤 329
32.2.2　实施方法 331
本章精要 336

第 33 章　元数据管理实施 337

33.1　实施内容 337
33.2　步骤和方法 337
本章精要 340

第 34 章　数据指标管理实施 341

34.1　实施内容 341
34.2　步骤和方法 342
34.3　模板 344
34.3.1　数据指标项定义 344
34.3.2　形成指标卡片及指标模板 345
34.3.3　数据需求规划 346
本章精要 347

第 35 章　数据质量管理实施 348

35.1　实施内容 348
35.2　步骤和方法 349
35.2.1　数据剖析 349
35.2.2　数据质量诊断 350
35.2.3　数据处理规则 351
35.2.4　数据质量优化 351
35.2.5　数据质量监管 352
35.2.6　实施数据质量管理时需注意的问题 353
本章精要 354

第 36 章　数据安全管理实施 355

36.1　实施内容 355
36.2　实施步骤 355
36.3　实践模式 358
36.3.1　数据安全管理的建设策略 358
36.3.2　数据安全管理的切入方式 359
36.3.3　工业互联网云平台的数据安全 359
本章精要 360

第 37 章　数据治理常见误区 361

本章精要 363
参考资料 363

第 5 篇　案例篇

第 38 章　电力行业：夯实数字化转型基础——南方电网数据资产管理行动实践 365

38.1　背景介绍 365
38.2　项目实施 367
38.3　项目成果 377
38.4　项目亮点和洞察 378
38.5　数据治理愿景 379

第 39 章　电力行业：支撑集团产业数字化转型——国家电投集团数据治理实践 380

39.1　背景介绍 380
39.2　数据治理工作实践 382
39.2.1　五凌电力数据治理实践——水电领域 386
39.2.2　黄河公司数据治理实践——光、风、水领域 390
39.2.3　云南国际数据治理实践——风电领域 392
39.3　经验总结 396
39.4　总结与展望 397

第 40 章　能源化工行业：数据治理助百年油企数字化转型 398

40.1　背景介绍 398
40.2　工作概况 400
40.3　组织保障 404
40.4　主要成果 405
40.5　炼化公司智能工厂数据治理实践案例 408
40.6　建设主要内容 409
40.7　总结与展望 411

第 41 章　钢铁行业：酒钢集团数据治理实践 413

41.1　背景介绍 413
41.2　项目目标 414
41.3　项目实施 414
41.4　项目总结 417
41.5　未来展望 419

第 42 章　汽车行业：数据驱动长安汽车数字化转型 420

42.1　背景介绍 420

上海交通大学RFID与物联网研究所

42.2 工作概况 422
42.3 组织保障 426
42.4 项目成果 427
42.5 工作价值 431
42.6 交流分享 432

第 43 章 核工业：物料主数据治理助力核电智慧运营 433

43.1 背景介绍 433
43.2 工作概况 435
43.3 组织保障 437
43.4 项目成果 439
43.5 项目总结 440

第 44 章 航天行业：军工企业的“三位一体”数据治理体系建设实践 441

44.1 背景介绍 441
44.2 工作历程 443
44.3 组织保障 447
44.4 实施效果 449
44.5 项目总结 450
44.6 未来展望 453

第 45 章 航空行业：面向航空装备研制生产的数据治理研究与实践 456

45.1 背景介绍 456
45.2 两级数据管控模式 459
45.3 信息分类与编码标准 460
45.4 数据应用场景 462
45.5 总结与展望 466

第 46 章 重型装备制造行业：数据标准，装备中国——中国一重的数据标准化管理项目 468

46.1 背景介绍 468
46.2 数据治理概况 472
46.3 数据治理成果 474
46.4 总结与成效 475

第 47 章 交通物流行业：主数据治理助力中国外运数字化转型 477

47.1 背景介绍 477
47.2 项目实施 479
47.3 主要成果 482
47.4 未来展望 489

第 48 章 建材行业：中国建材集团工业大数据应用实践 490

48.1 背景介绍 490
48.2 工作实施 491
48.3 应用框架与技术路线 493
48.4 工作成果 494

第 49 章 制造行业：威孚集团基于斯欧应用互联平台建设数据通道 501

49.1 背景介绍 501
49.2 项目建设技术方案 505
49.3 项目实施步骤 509
49.4 项目实施效果 511
49.5 项目价值及特点 512

第 50 章 战略投资行业：国投集团的数据标准化管理实践 514

50.1 背景介绍 514
50.2 工作概况 516
50.3 组织保障 519
50.4 项目成果 520
50.5 工作价值 528
50.6 经验分享 529

第 51 章 多元化集团：数据治理助力多元化企业集团管控 532

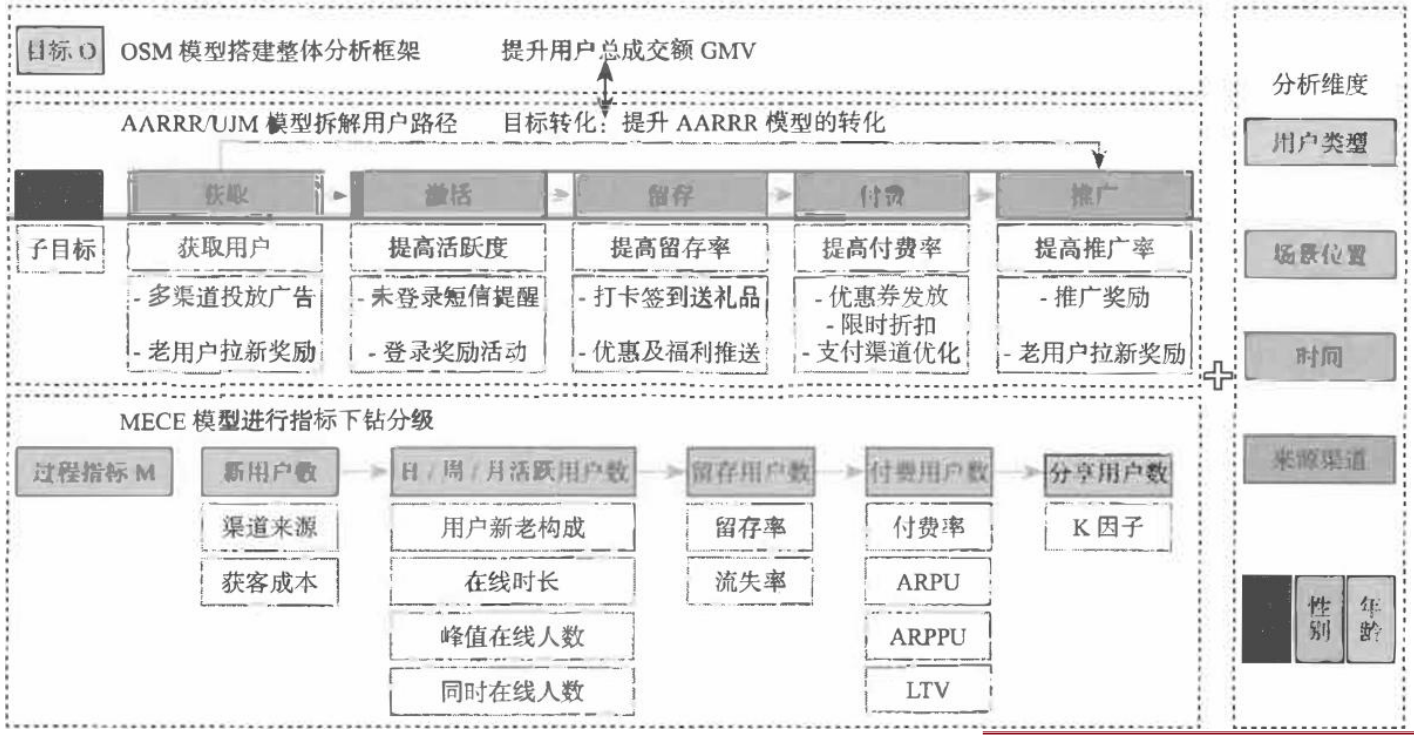
51.1 背景介绍 532
51.2 数据治理概况 534
51.3 组织保障 539
51.4 项目成果 540
51.5 工作价值 543
51.6 项目总结 543

附录 A 工业英文缩写术语表 545

构建数据指标体系的过程总结

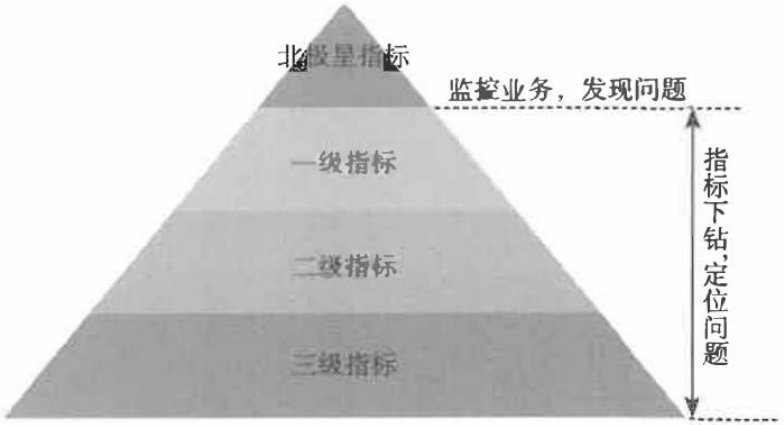
数据指标体系的构建要基于业务场景展开， 符合业务需要的数据指标体系才是好的数据指标体系

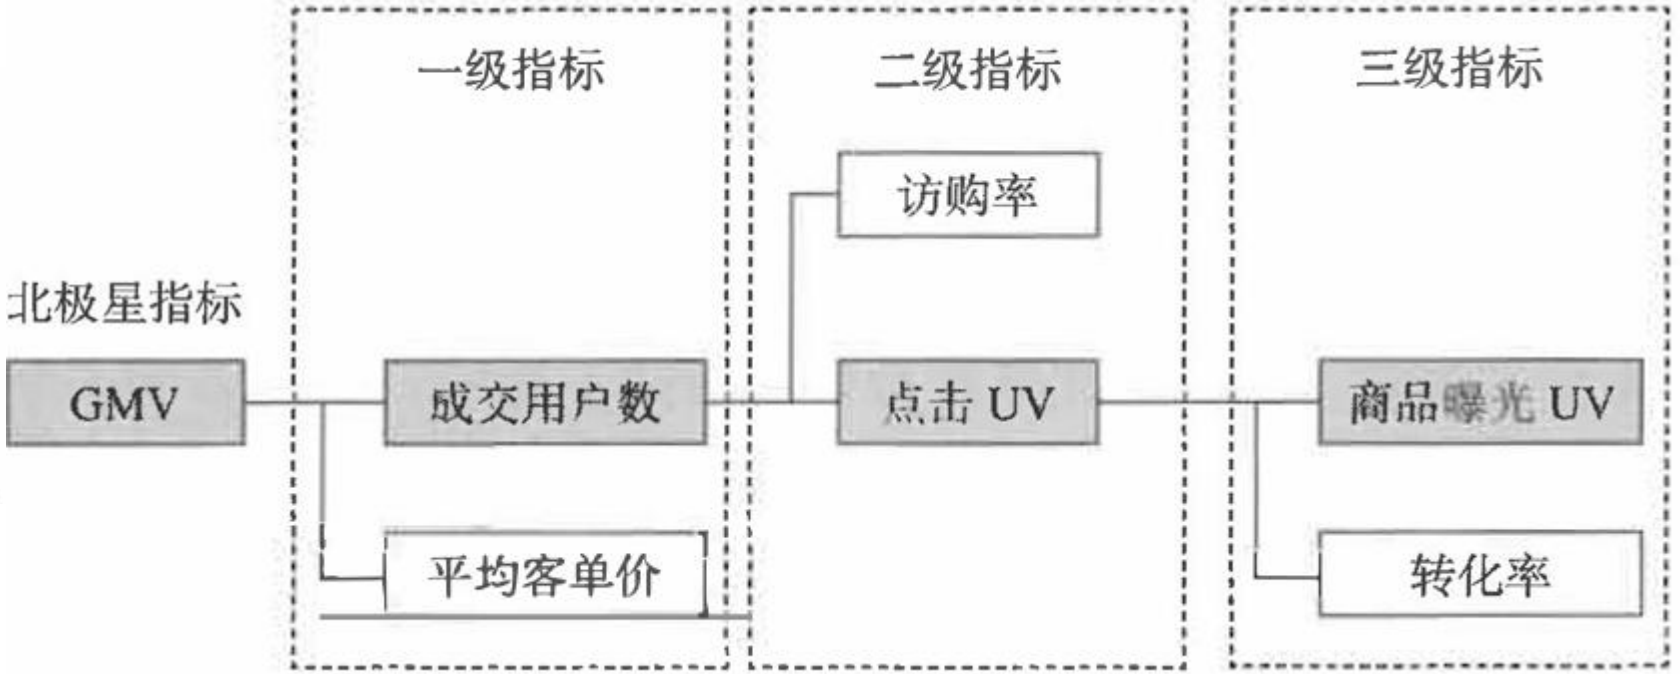
- 首先，根据业务场景提炼业务目标， 明确北极星指标
- 其次，通过AARRR模型拆解用户路径， 明确过程指标
- 之后，对过程指标进行下钻分级
- 最后，添加分析维度， 形成完整的数据指标体系



基于数据指标形成数据指标体

- **数据指标会分为不同的层级结构**， 北极星指标是整个业务模块的核心指标， 一级指标是北极星指标的下钻和拆解， 而三级指标又是二级指标的下 钻和拆解， 依此类推
  - — GMV是电商平台的北极星指标
  - — GMV可以拆解为成交用户数与平均客单价的乘积， 因此成交用户数和平均客单价是一级指标
  - — 成交用户数也可以继续拆解为点击UV （独立访客）与访购率， 二级指标也有了
  - — 点击UV又可拆解为商品曝光UV和转化率， 这是三级指标
  - — **如果GMV出现数据波动， 就可以根据数据指标体系找到影响GMV波动的因素，从而快速定位业务问题**



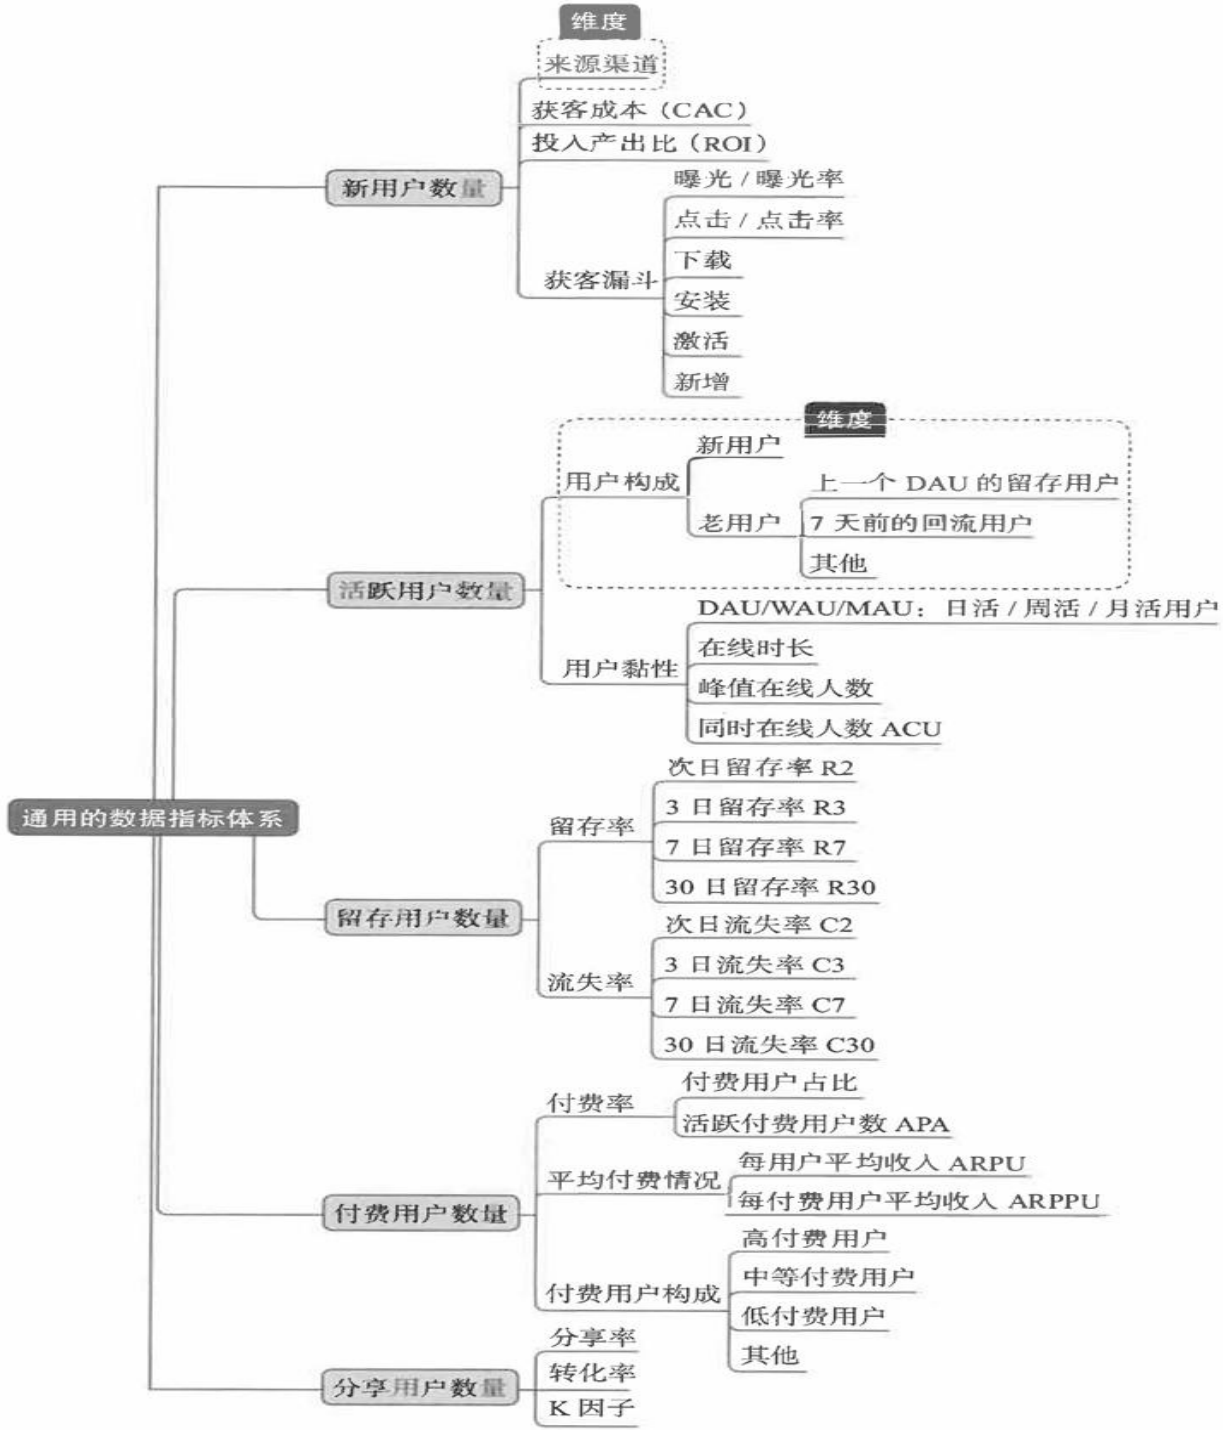


4个步骤实现数据指标体系构建

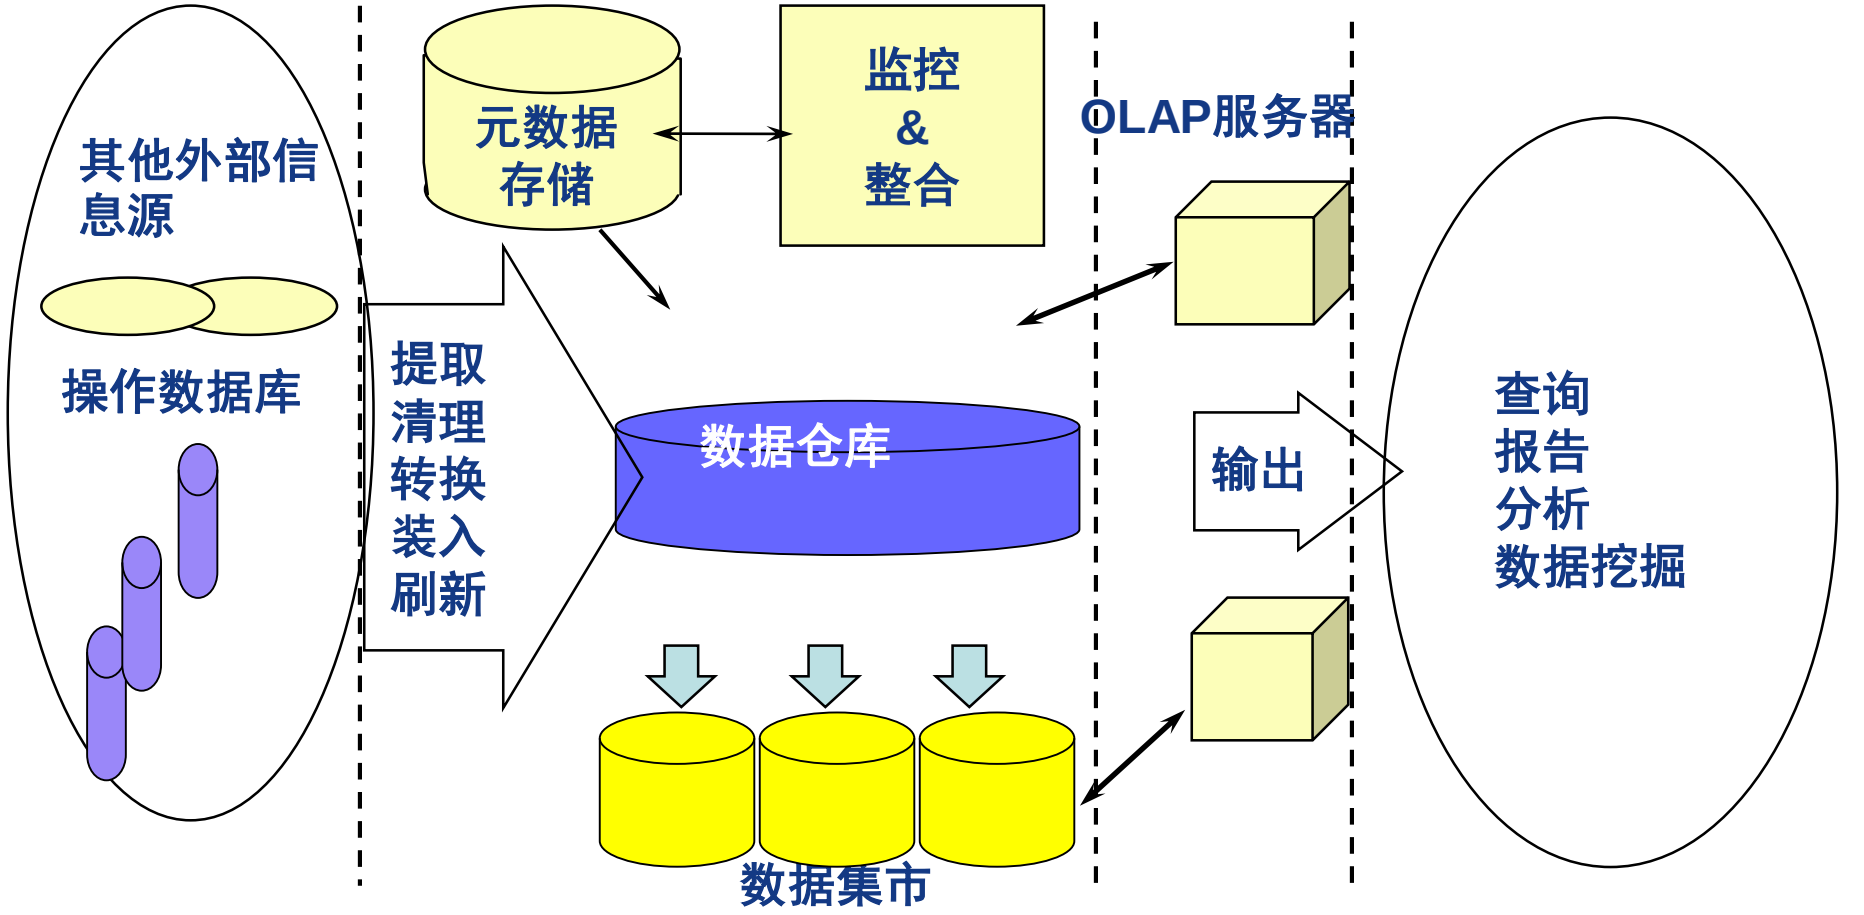
3.指标下钻分级，构建多层级数据指标体系

- 北极星指标能够指示业务发展方向，监控业务现状，如果该指标一直保持平稳上升的状态， 则说明业务一直向好。如果该指标出现下跌，就需要排查过程指标，或二级指标、三级指标。因此，明确过程指标之后，需要**对过程指标进行下钻分级，以建立更加完整的数据指标体系**

不同的业务场景， 数据指标体系也会有一定的变化， 这里提供一个较为通用的数据指标体系模板

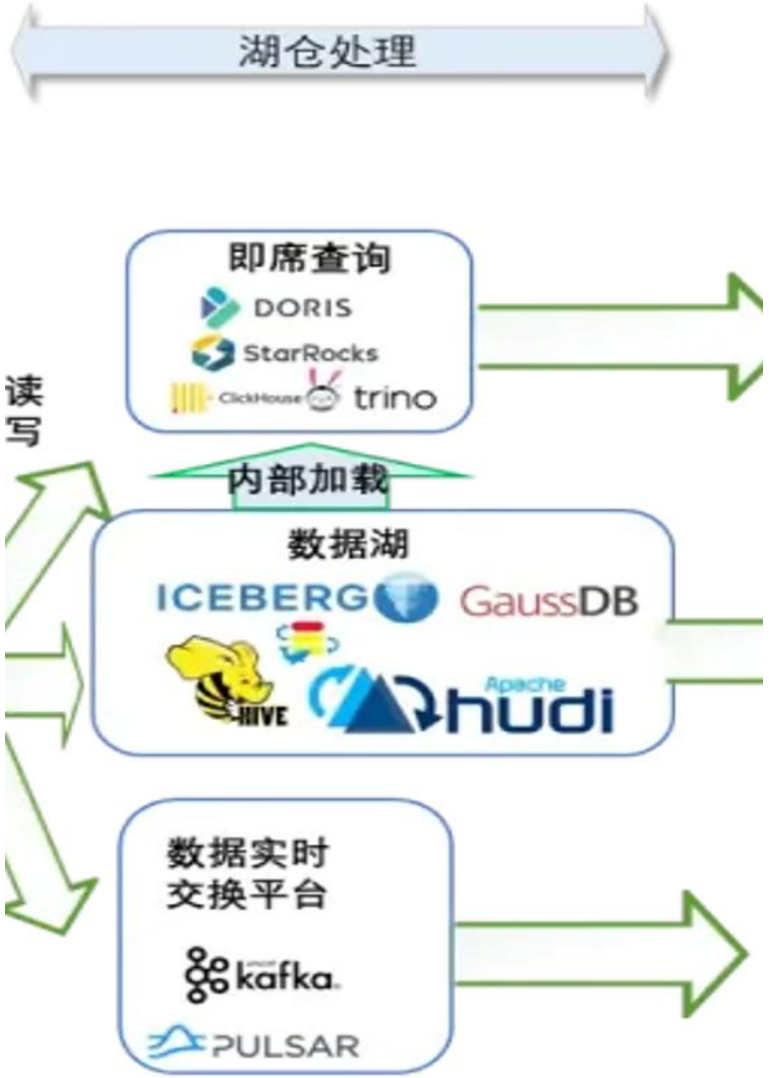


Data Warehouse: A Multi-Tiered Architecture
三层数据仓库架构



数据集成：湖仓架构处理

- 随着数据规模的扩大与分析需求的复杂化，湖仓一体化架构成为数据处理的主流选择
- 通过将数据写入 数据湖（如Iceberg、Hudi）或者 数据仓库（如Redshift、Greenplum、Snowflake、Doris、StarRocks、Trino、GaussDB等），实现数据的高效存储与管理
- 在这一阶段，数据湖与数据仓库之间的高效协同至关重要，既需要数据湖的弹性扩展性，也需要数据仓库的高性能分析能力。通过统一的数据格式与高效的查询接口，湖仓架构大幅提升了数据处理效率与灵活性

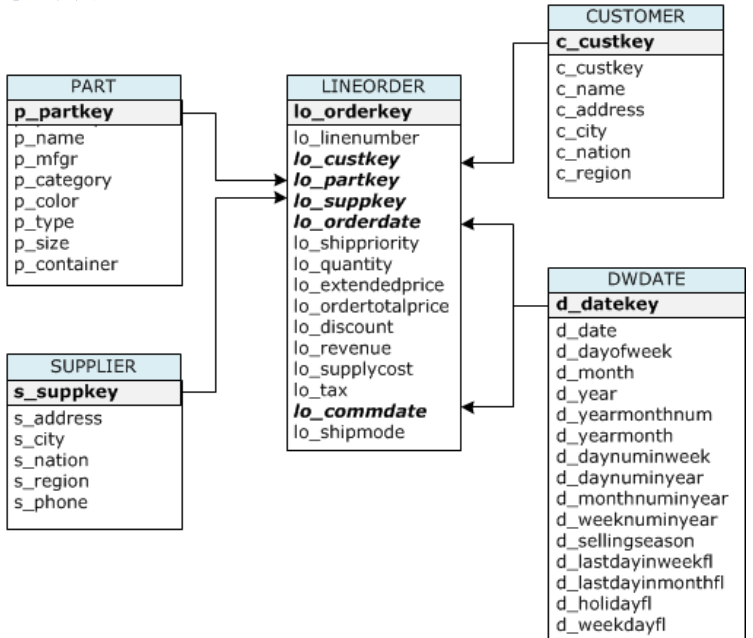


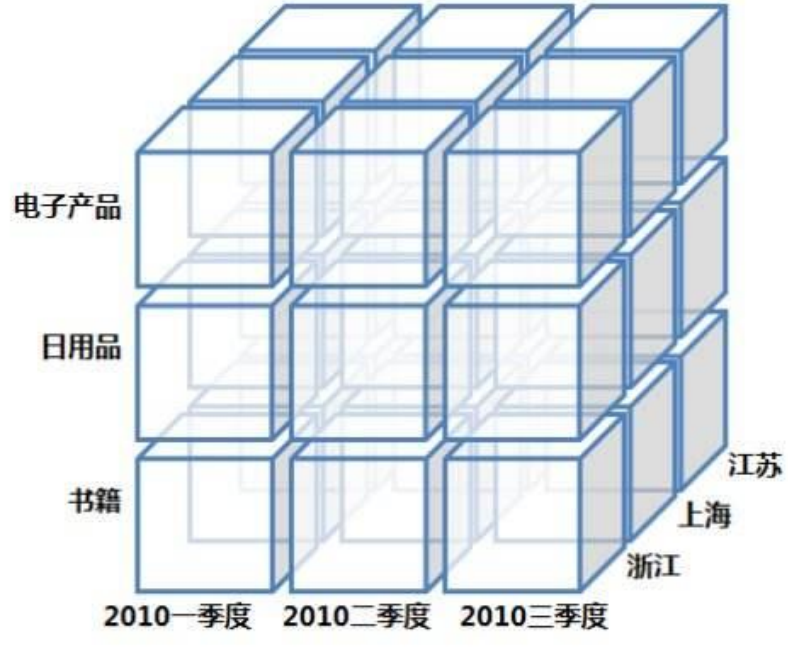
数据服务与数据分析

- **数据分析**、简单分析、复杂分析
  - 数据分析
    - ✓ 随着业务的不断发展，积攒了大量的业务数据
    - ✓ 数据分析任务是面向分析人员（或者管理层），通过对大量数据（甚至在整个数据库数据上）使用复杂的计算模型进行分析，从而发现数据中隐藏的模式或规律
    - ✓ 数据分析侧重对决策人员和高层管理人员的决策支持，可以根据分析人员的要求快速、灵活地进行大数据量的复杂查询处理，并且以一种直观而易懂的形式将查询结果提供给决策人员，以便准确掌握企业（公司）的经营状况并进行宏观决策
    - ✓ 数据分析任务的响应时间一般比较长，比如以分钟和小时计

数据服务与数据分析

- 数据分析、简单分析、复杂分析
  - 简单分析与OLAP（Online Analytic Processing，联机分析处理）
    - ✓ 简单分析是简单汇总和报表。OLAP采用星型模型或者数据立方体组织数据，保存在数据仓库中，然后进行多维度的聚集查询处理
    - ✓ 在OLAP应用中，在事实表中记录一系列的事件，在维表中记录事件的维度，然后从维表中选取一些维度对事实表进行汇总操作，这些汇总操作包括计数、求和、求平均值、求最大值、求最小值
    - ✓ 将OLAP分析所用到的多维数据，物理上存储为多维数组形式，形成“立方体”(Cube)的结构。星型模型的各个维的属性值，被映射成多维数组的下标值或下标的范围，而聚集数据作为多维数组的值存储在数组的单元中





Star Schema

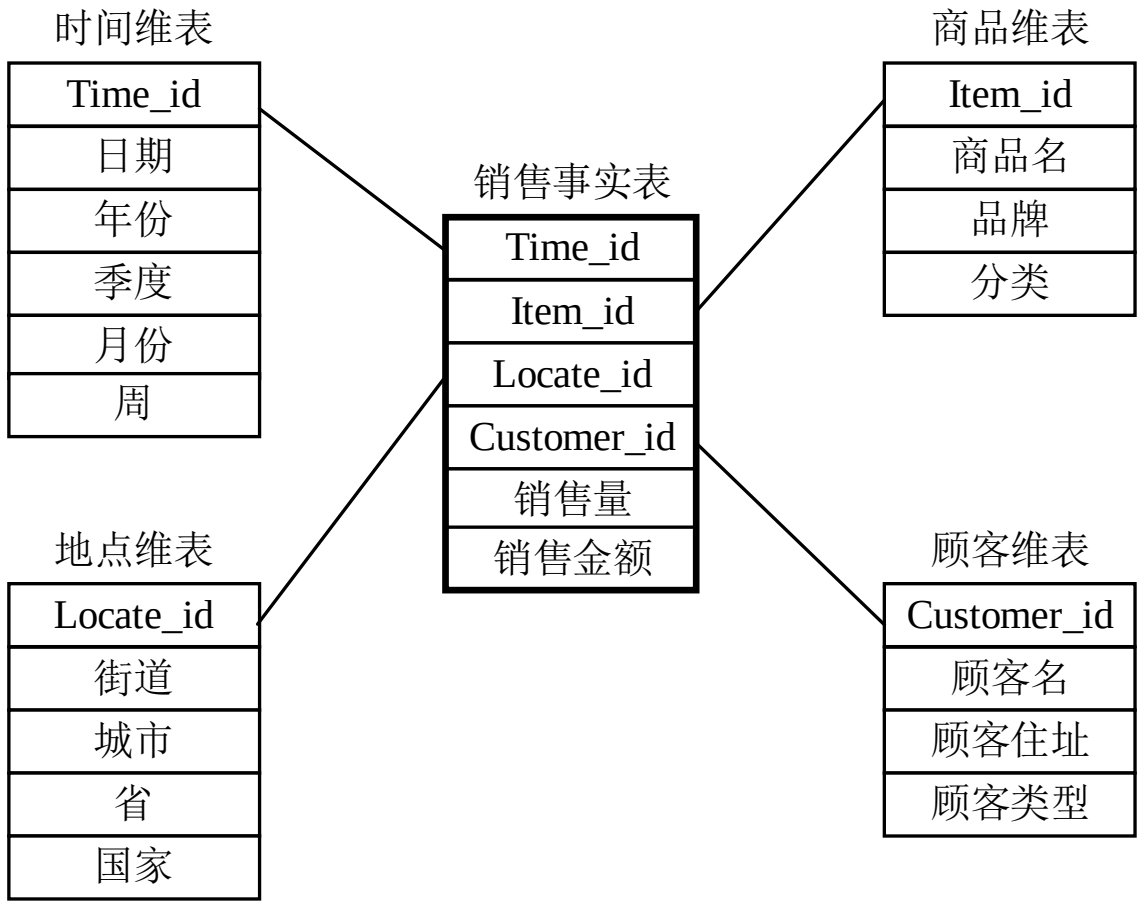
- 星形模式是由一个事实表和一组维表组成，每个维表都有一个维主键，所有维组合成事实表的主键，换言之，事实表主键的每个元素都是维表的外键。该模式的核心是事实表，通过事实表将各种不同的维表连接起来，各个维表都连接到中央事实表

一个“销售”数据仓库的星形模式

包含一个中心事实表“销售事实表”和4个维表：时间维表、销售商品维表、销售地点维表和顾客维表。在销售事实表中存储着四个维表的主键和两个度量“销售量”和“销售金额”

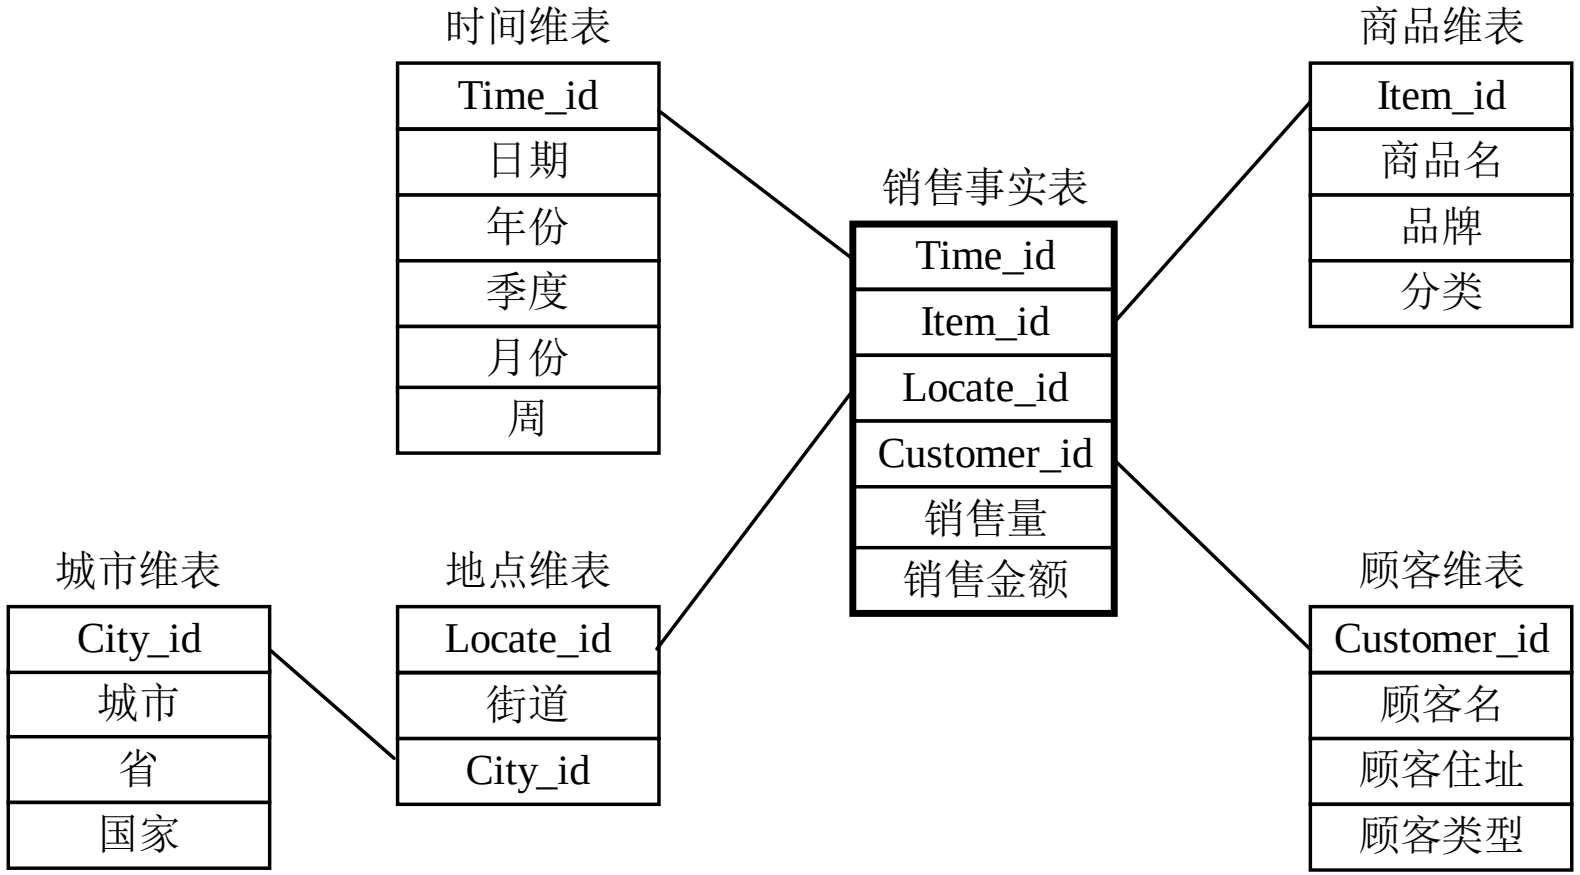
维表通常不使用业务数据库的关键字作为主键，对每个维表另外增加一个额外的字段作为主键来识别维表中的对象。在维表中新设定的键也称为**代理键**

事实表中除度量外，其他字段都是维表或中间表（对于雪花模式）的关键字（外键）。如果事实相关的维很多，则事实表的字段个数也会比较多。事实表记录数量很多，应当尽量减小一条记录的长度，避免事实表过大而难于管理



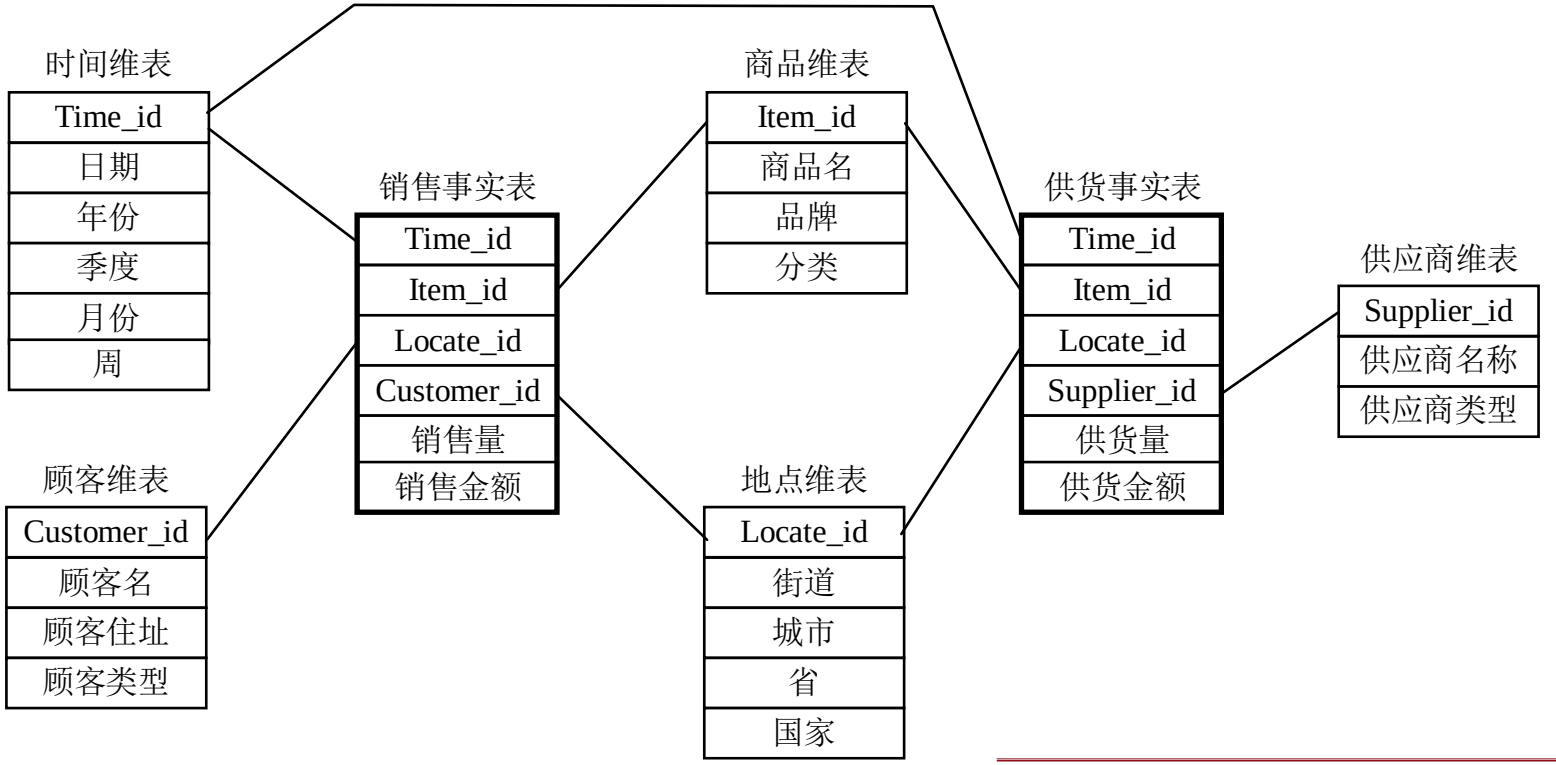
Snowflake Schema

- 雪花模式是对星形模式的扩展，每一个维表都可以向外连接多个详细类别表
- 在这种模式中，维表除了具有星形模式中维表的功能外，还连接对事实表进行详细描述的详细类别表，详细类别表通过对事实表在有关维上的详细描述达到了缩小事实表和提高查询效率的目的



事实星座模式（Fact Constellations schema）

- 通常一个星形模式或雪花模式对应一个问题的解决（一个主题），它们都有多个维表，但是只能存在一个事实表
- 在一个多主题的复杂数据仓库中可能存放多个事实表，此时就会出现多个事实表共享某一个或多个维表的情况，这就是事实星座模式



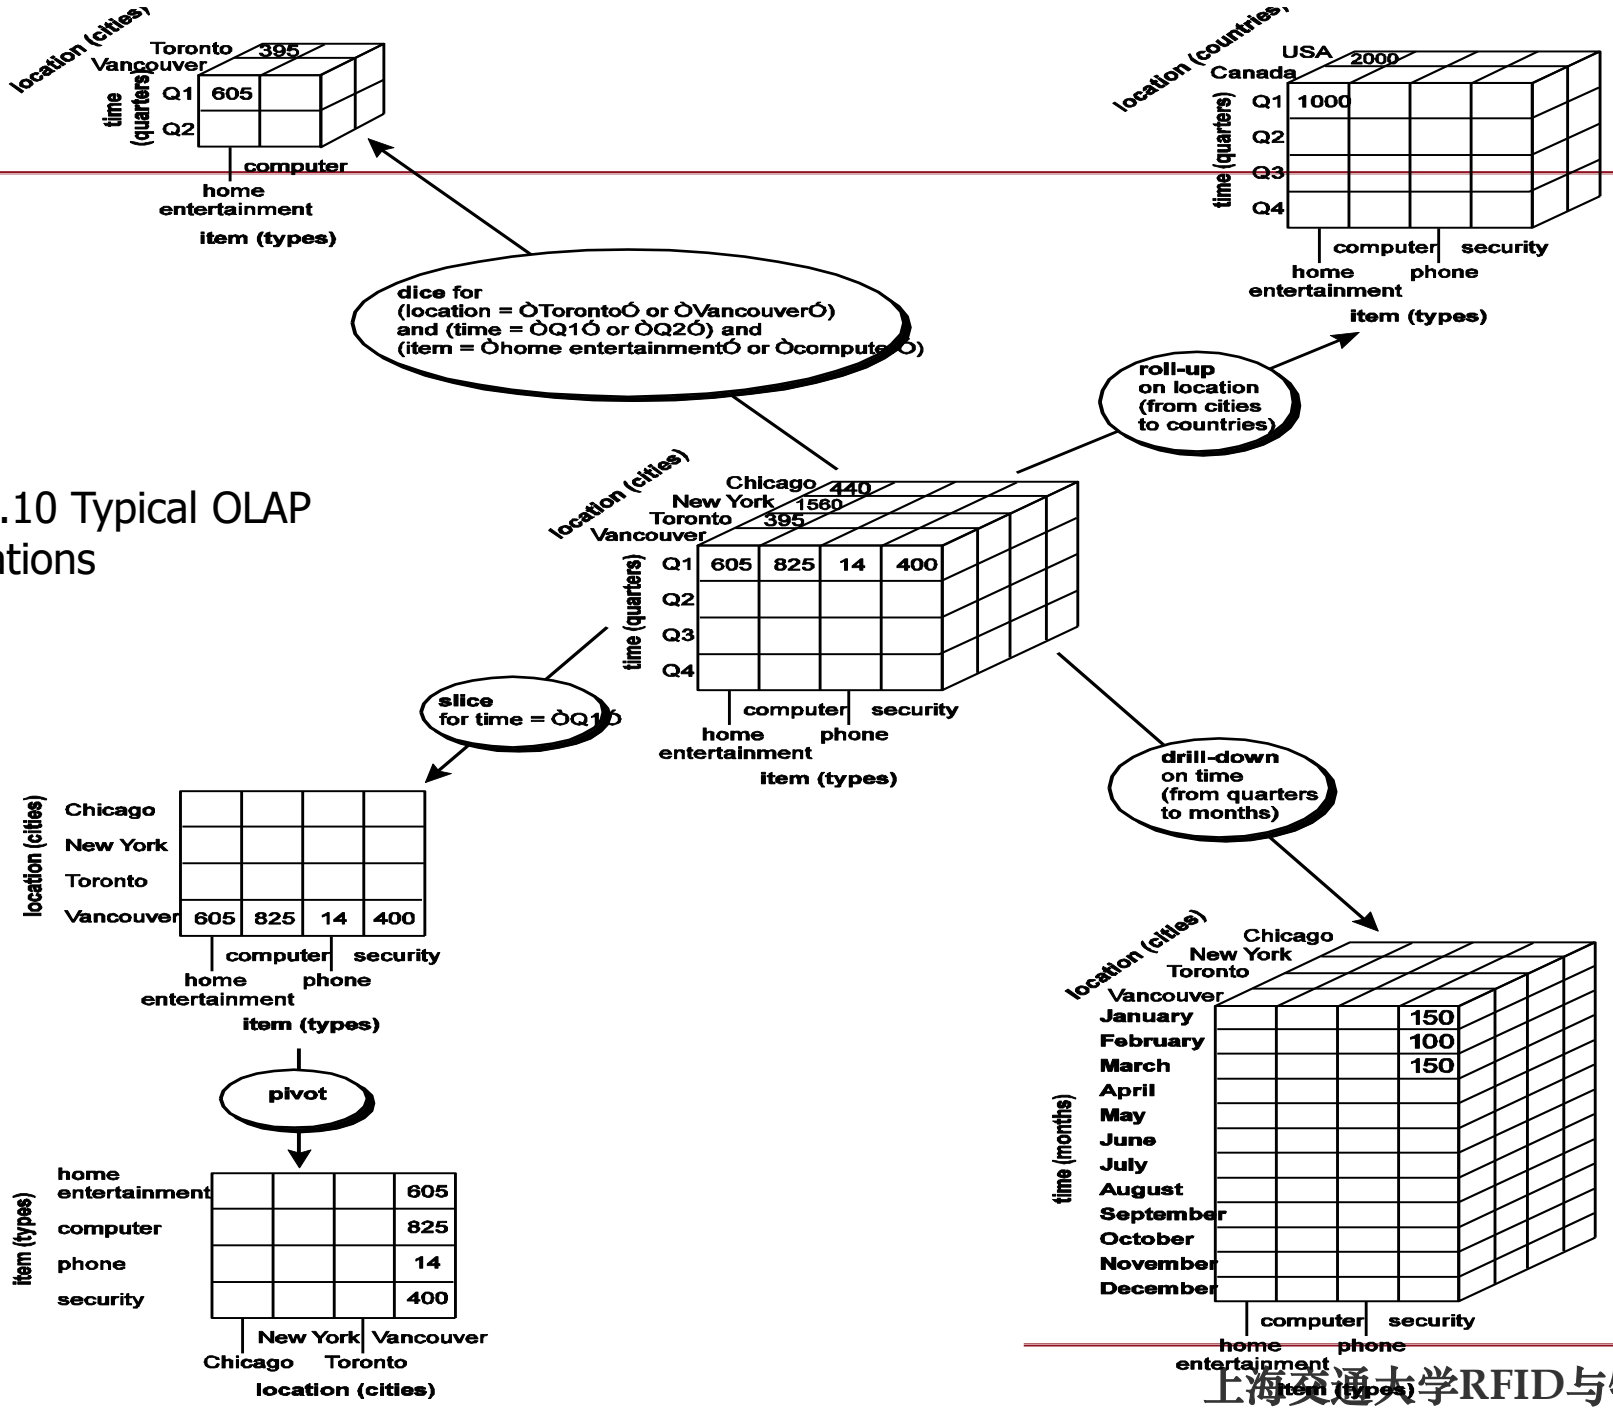
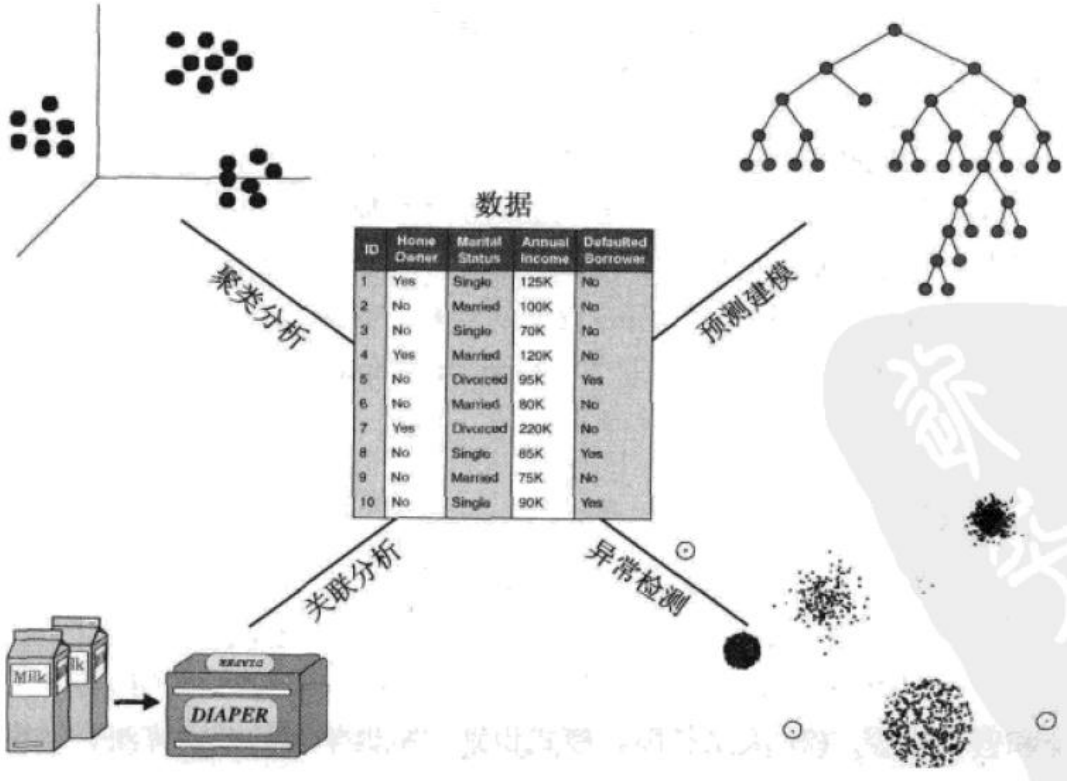


Fig. 3.10 Typical OLAP Operations

数据服务与数据分析

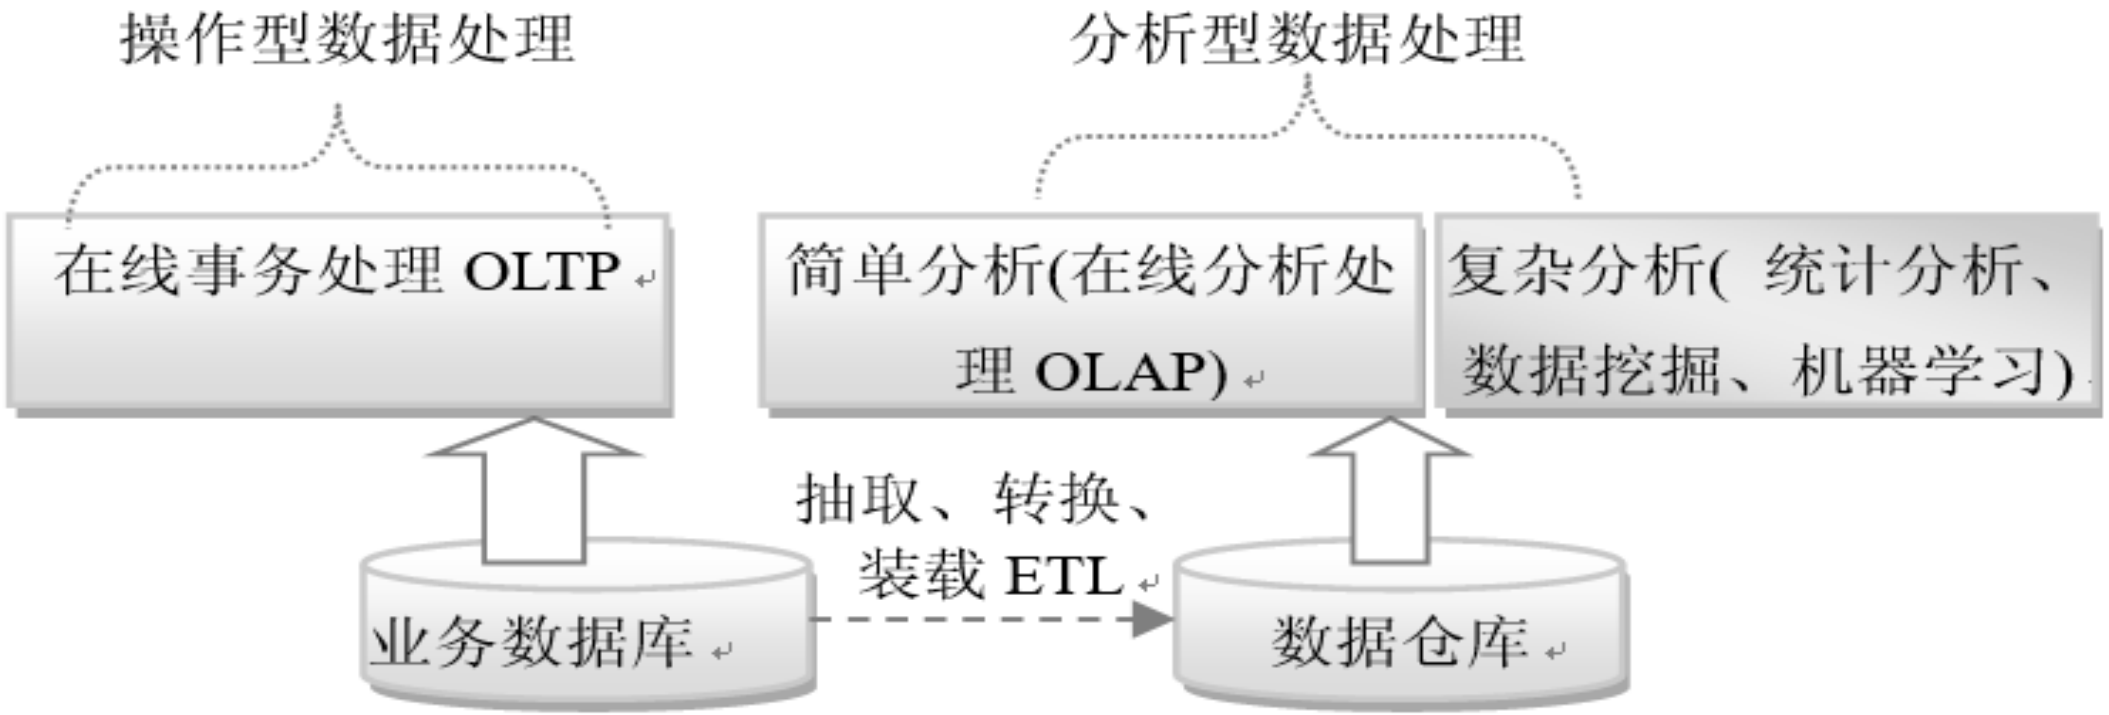
- 数据分析、简单分析、复杂分析
  - 复杂分析与数据挖掘、机器学习
    - ✓ 复杂分析一般需要利用统计分析方法、数据挖掘与机器学习方法，对数据进行深入分析，提取有用信息并形成结论，辅助决策



TID	Items
1	Bread, Milk
2	Bread, Diaper, Beer, Eggs
3	Milk, Diaper, Beer, Coke
4	Bread, Milk, Diaper, Beer
5	Bread, Milk, Diaper, Coke

数据服务与数据分析

- 在用户和数据处理系统进行一次交互的过程中，用户使用到的功能可能囊括数据服务、简单数据分析和复杂数据分析



数据仓库以及 OLAP 实验

- 数据仓库构建实验
  - 运用ETL工具对数据库sakila中的数据进行清洗操作，构建一个DVD租赁商店数据仓库系统，实现定期从源数据库sakila中抽取增量数据，转换成符合DVD租赁业务的数据，最后加载到目标数据仓库中
- OLAP 实验
  - 进行的 OLAP 操作（上卷、下钻、旋转、切块、切片等）

数据越来越“大”：大数据



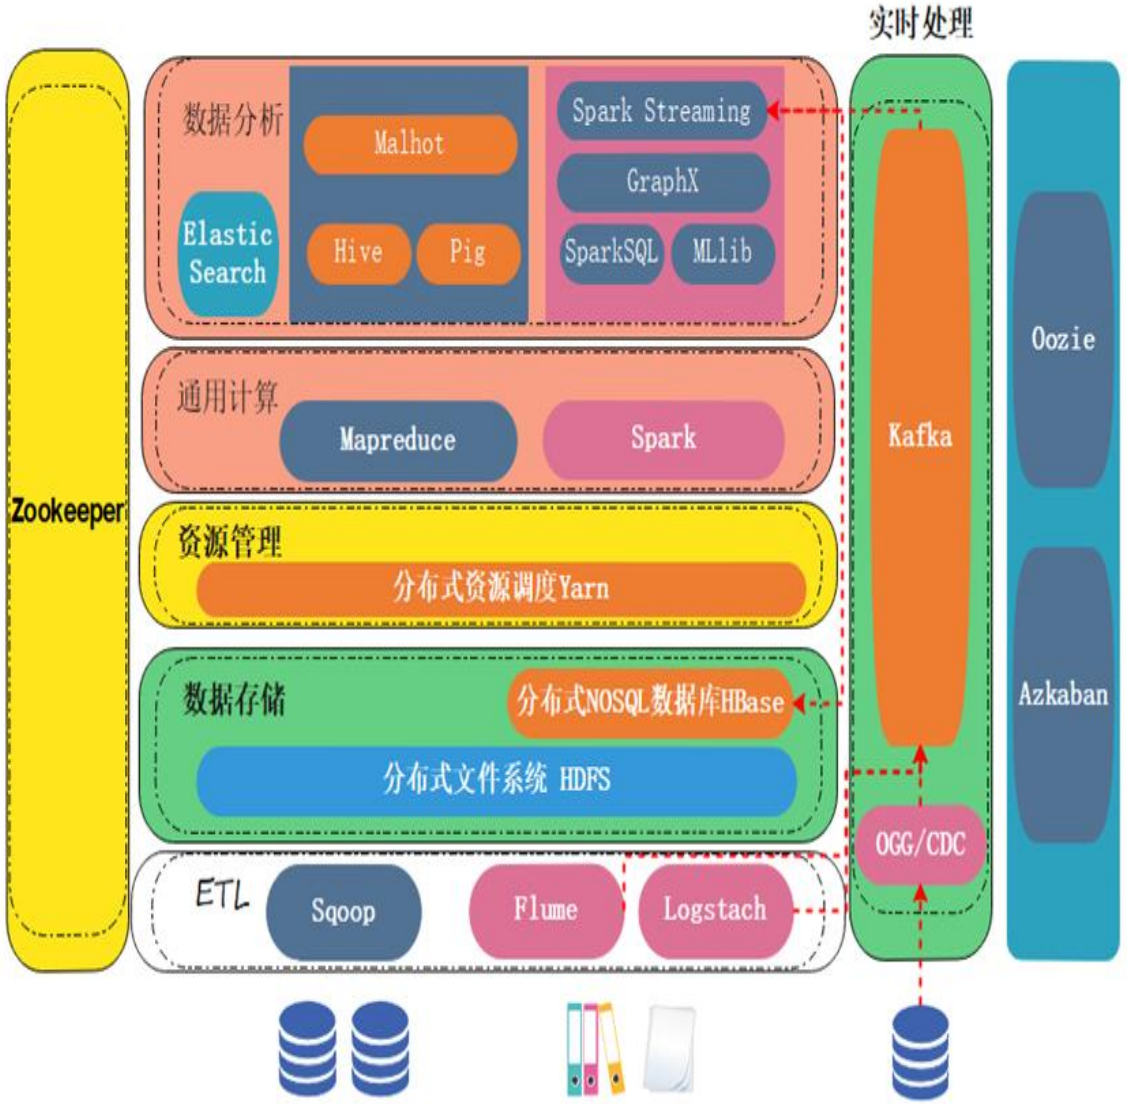
最早提出“**大数据**”这一概念的是全球知名咨询公司**麦肯锡**，是这样定义大数据的：**一种规模大到在获取、存储、管理、分析方面大大超出了传统数据库软件工具能力范围的数据集合，具有海量的数据规模、快速的数据流转、多样的数据类型以及价值密度四大特征**

研究机构**Gartner**是这样定义大数据的：**“大数据”是需要新处理模式才能具有更强的决策力、洞察发现力和流转优化能力来适应海量、高增长率和多样化的信息资产**



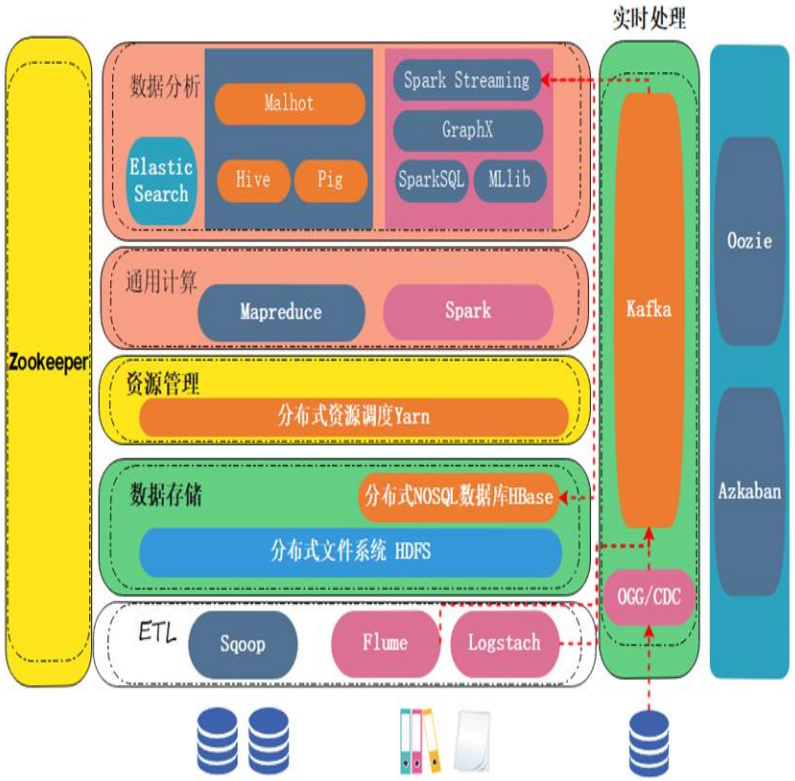
大数据：利用常规技术不能有效处理的数据

大数据处理技术架构


实时处理
数据分析
Malhot
Spark Streaming
GraphX
Elastic Search
Hive
Pig
SparkSQL
MLlib
通用计算
Mapreduce
Spark
Zookeeper
资源管理
分布式资源调度Yarn
数据存储
分布式NOSQL数据库HBase
分布式文件系统 HDFS
ETL
Sqoop
Flume
Logstach
Kafka
OGG/CDC
Oozie
Azkaban

大数据处理技术架构

监测管理（Monitoring） OpenTSDB Amdari	操作框架 （Operational Frameworks）	基准测试（Benchmarking） YCSB Grid Mix Background
数据摄取（Ingest） Flume, Sqoop, Kafka	数据集成 （Data Integration）	序列化（Serialization） Protocol Buffers, Avro
ETL（萃取、转换、加载） Crunch, Falcon, Cascading, Oozie		元数据（Metadata） HCatalog
分析工具（Tools） Pig, Hive, Phoenix	数据分析 （Data Analysis）	分析类库（Libraires） Mllib, SparkR, Mahout
交互式（Interactive） Dremel, Drill, Tez, Impala Shark, Presto, BlinkDB, Dryad	实时（RealTime） Druid, Piot	流式（Streaming） Storm, Samza, Spark Streaming
批处理（Batch） MapReduce	计算框架 （Computational Integration）	迭代式（Iterative） Pregel, Giraph, GraphX, Hama
Spark	引擎（Engines）	Flink
Yarn	资源管理器 （Resource Manager）	Mesos
Paxos Chubby	资源协调器 （Coordination）	ZooKeeper
键值存储（KeyValue） Dynamo, Cassandra, Voldemort	数据存储（Data Stores）	列存储（Column） BigTable, Hbase, Hypertable
图存储（Graph） Neo4j，Titan		文档存储（Graph） CouchDB，MongoDB
Megastore Spanner	ACID	MESA CockroachDB
Google File System Hadoop HDFS	文件系统 （File Systems）	CEPH文件系统 Parquest
		Tachyon （O）RCFile



阿里巴巴的大数据之路

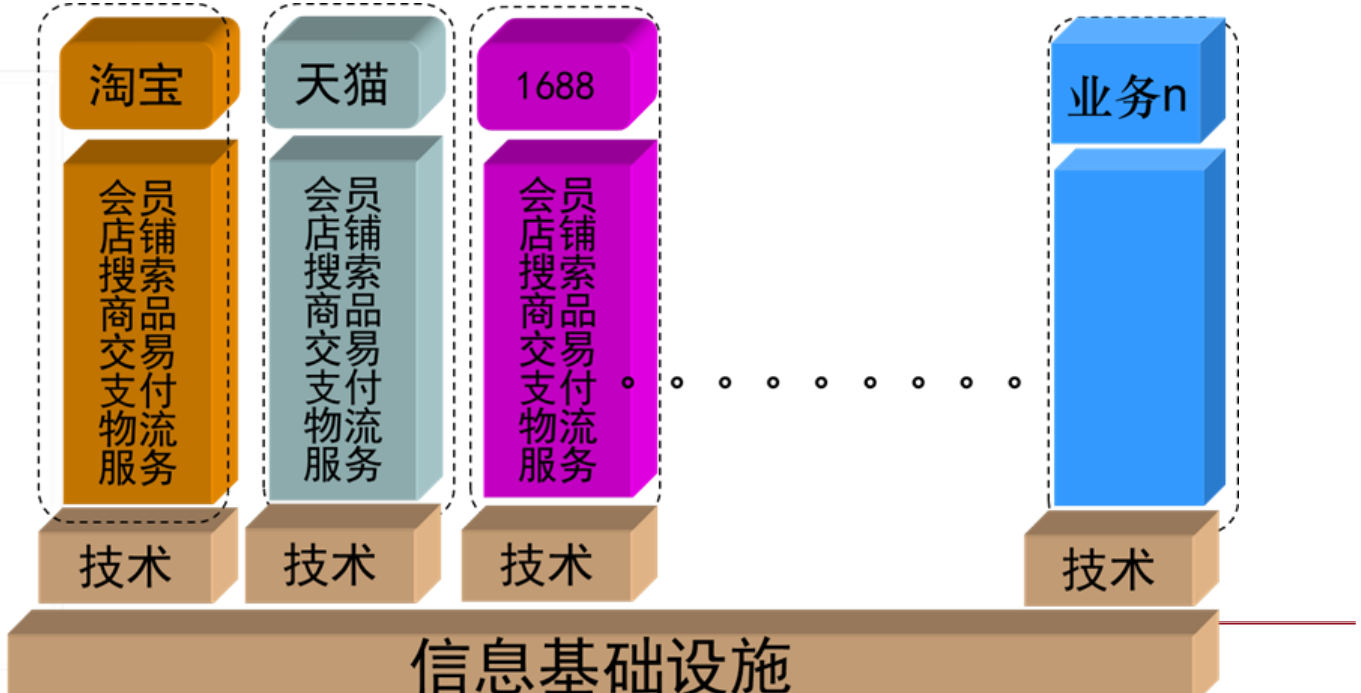
阿里巴巴的大数据之路艰难起步

- 2014年9月19日阿里巴巴在美国上市，阿里巴巴高速发展，业务也越来越多元化，这时面临着一个非常严峻的问题——迫切需要数据治理

  —如果不能有效地治理数据，那么仅仅服务器产生的成本就会吃掉公司未来的利润。当时，**1张数据库表，8个部门存8遍。1张表一年的成本是1200万元，8张表加起来将近1亿元**

- 这个任务摆在了DT（DataTechnology，数据技术）团队面前，虽然彼时互联网蓬勃发展，但放眼全行业，几乎没有专业的数据人。面对每天层出不穷的问题，既没有可以借鉴的解决方案，也没有可以照抄的答案





大数据的开端

萌芽期 概念的产生
预热期 概念的前身
过渡期 概念落地的开端
上升期I 技术核心议题
上升期II 战略级指导方向
黄金期 全球化、国家级战略

TB级数据处理量
PB级数据处理量

20世纪 | 21世纪 | 互联网时代 | IT时代 | DT时代 | NOW

1974年 1991年 2003年 2008年 2011年 2012年

数据仓库
BIII Inmon出版《建立数据仓库》

海量数据
Google公开其内部实践的"海量数据"处理技术

大数据
Nature 特设专栏《Big Data》

大数据
- EWC世界大会：大数据概念被正式提出
- 麦肯锡全球报告：大数据时代已来
- Gartner新兴技术成熟度曲线报告：大数据来新技术趋势

大数据
- 瑞士达沃斯论坛："数据成为一种新型的经济资产"
- 华尔街新闻："信息技术已经进入大数据时代"
- 美国政府：《大数据研究和发展倡议》

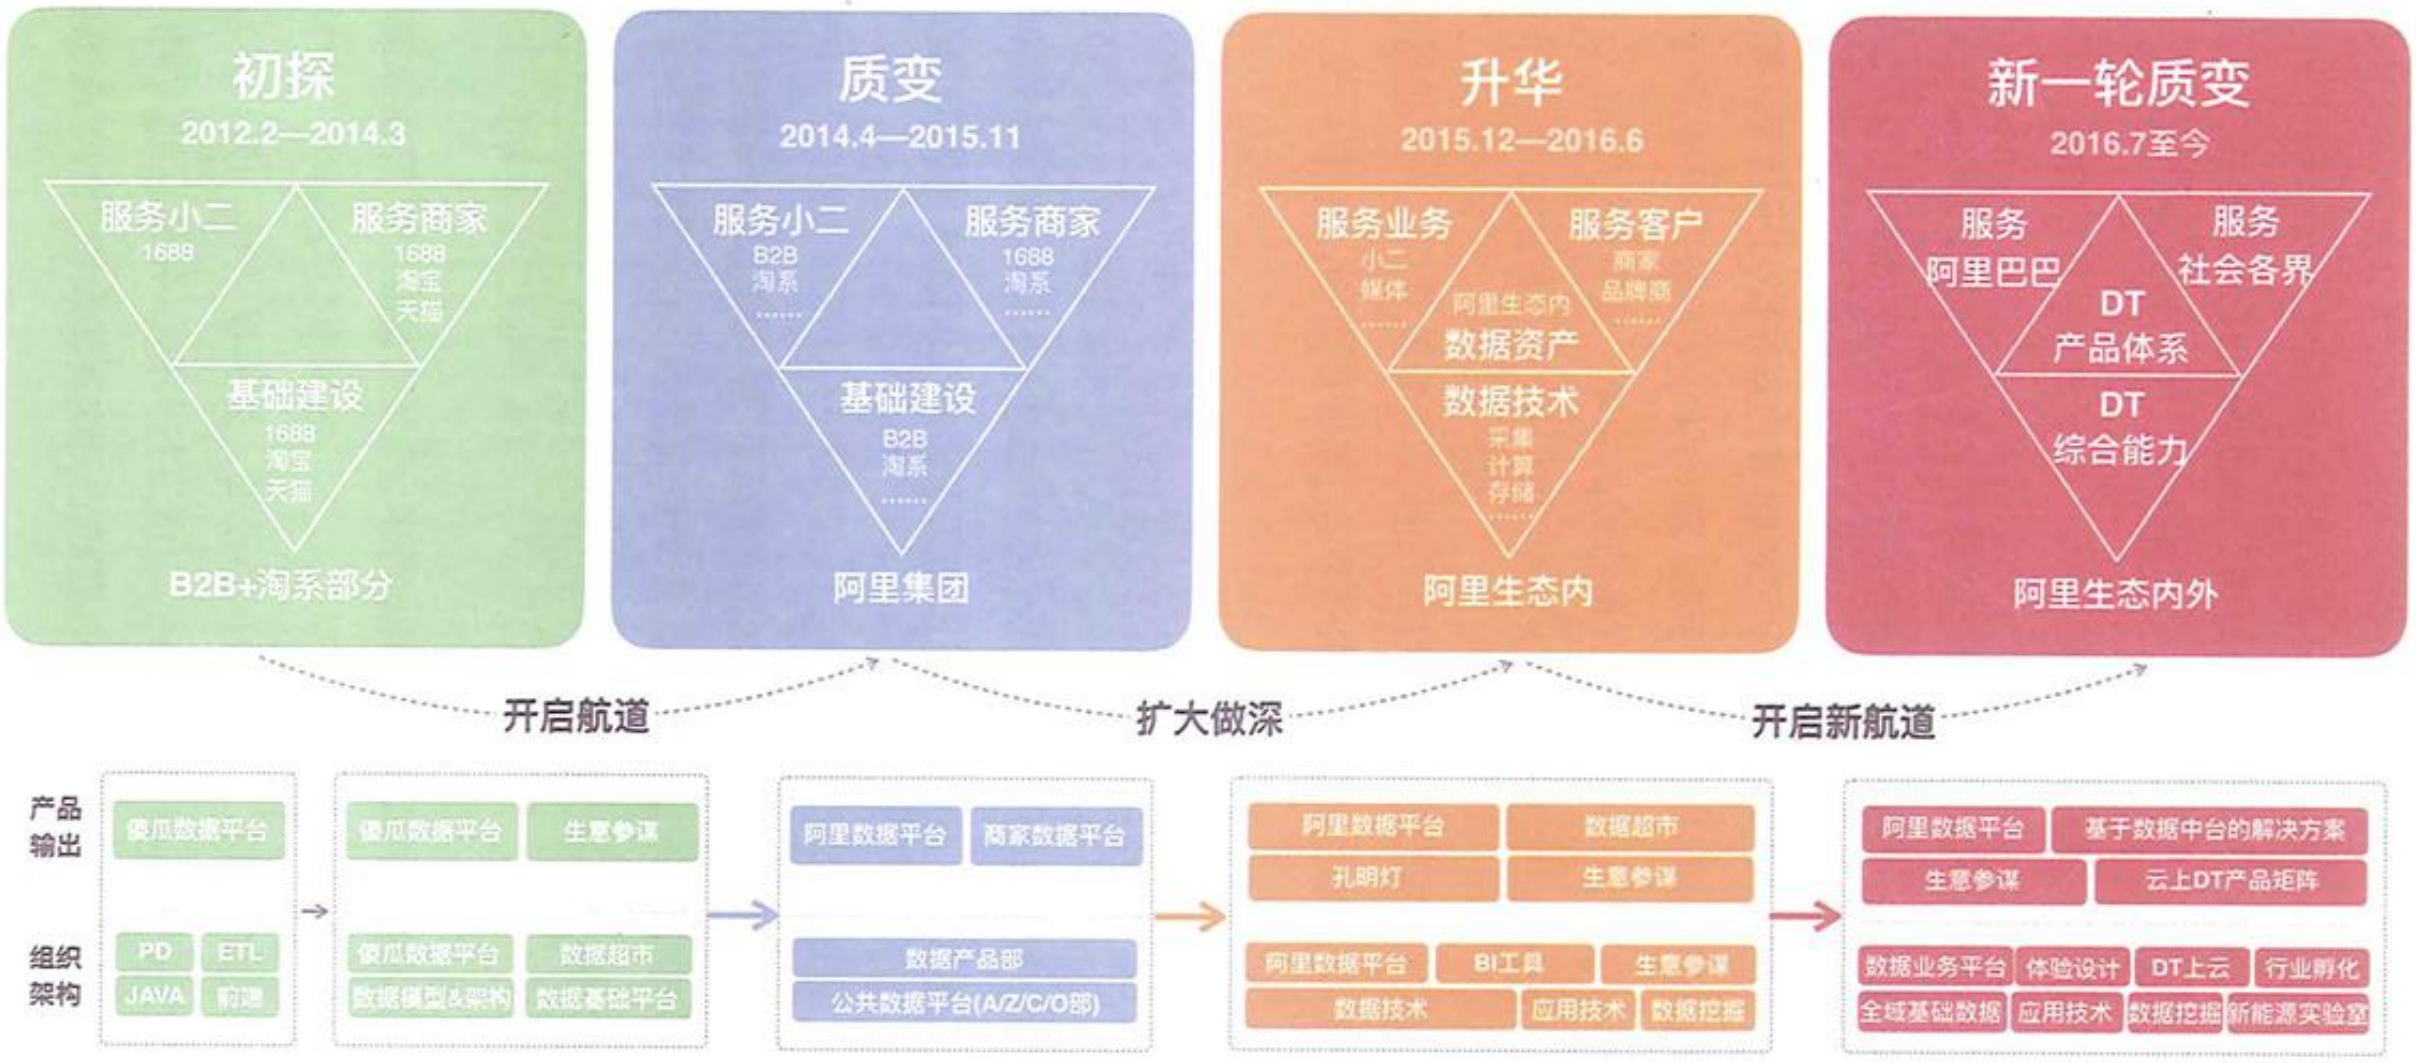
大数据
- 2011年
  欧盟：发布报告《开放数据：创新、增长和透明治理的引擎》
  澳大利亚：启动国家数字经济战略
- 2012年
  日本：发布《面向2020年的ICT综合战略》
  美国：发布《大数据研究和发展倡议》《数字政府战略》
- 2013年
  澳大利亚：发布《公共服务大数据战略》
- 2014年
  欧盟：再次发布《数据驱动经济战略》
  中国：贵阳大数据产业推介会
- 2016年
  美国：发布《联邦大数据研究与开发战略计划》

大数据战略全面升级

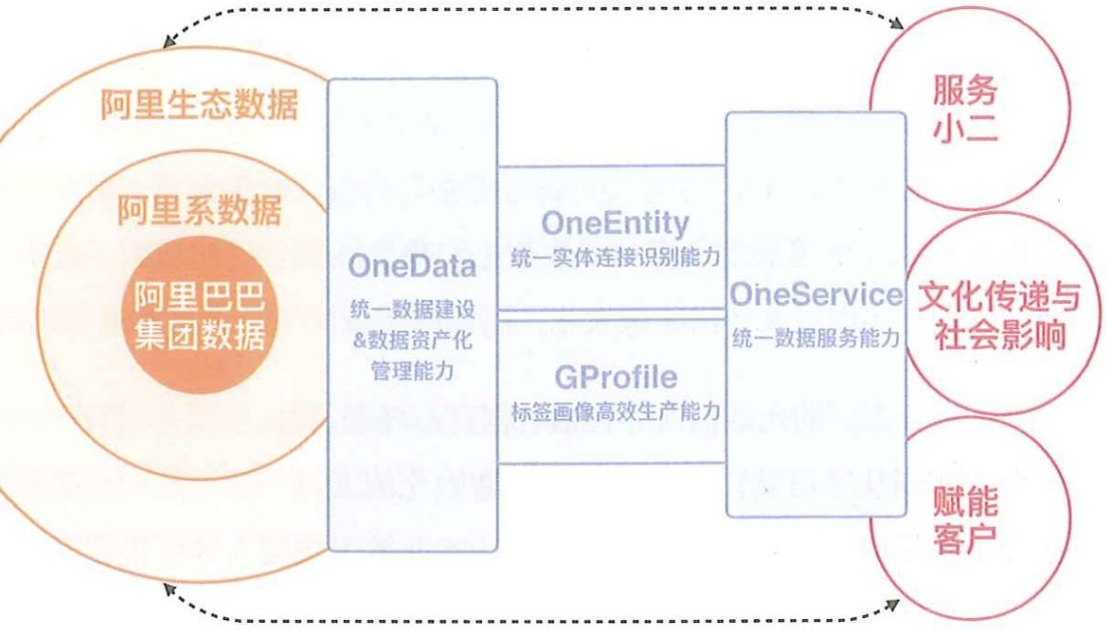
美国	2012年《大数据研究和发展倡议》和《数字政府战略》 2016年《联邦大数据研究与开发战略计划》
澳大利亚	2011年《国家数字经济战略报告》 2013年《公共服务大数据战略》
英国	2013年《英国数据能力发展战略规划》
日本	2012年《面向2020年的ICT综合战略》
欧盟	2011年《开放数据：创新、增长和透明治理的引擎》 2014年《数据驱动经济战略》

中国
2016年，《国民经济和社会发展第十三个五年规划纲要》，明确提出实施"大数据战略"

阿里巴巴数据中台顶层设计的四个阶段



阿里巴巴的数据中台





OneData 致力于实现数据的标准与统一，让数据成为资产而非成本；OneEntity 致力于实现实体统一，让数据融通而非以孤岛存在；OneService 致力于实现数据服务统一，让数据复用而非复制。

阿里巴巴的数据中台

全流程一体化
从数据采集到数据服务全链路通

向上多样化赋能场景
通用产品+行业产品+尊享产品

向下屏蔽多计算引擎
公共云+专有云+私有云

双向联动
业务与技术协同互助

OneData体系方法论
数据标准化
技术内核产品化
元数据驱动智能化

OneEntity体系方法论
技术驱动数据连接
技术内核产品化
业务驱动技术价值化

OneService体系方法论
主题式数据服务
统一但多样化数据服务
跨源数据服务

阿里巴巴数据中台赋能业务全景图



阿里“共享事业部”和“中台”的缘起

- 三套电商体系的架构完全独立，各个应用独立开发和运维
  - —2008年淘宝的技术团队同时支持着淘宝和天猫两大电商平台
  - —1999年成立的B2B电商平台1688一直拥有自己的技术支持团队
- 为什么不共享，要独立建设和维护？
  - —不管是B2B、C2C或者B2C电商平台都需要提供会员服务、商品的信息、交易支付，这些是电商都具有的通用业务功能



各业务都是由以交易为核心关联的领域组成

- 交易的对象是商品
- 商品通过店铺售卖给会员
- 交易的凭证是订单
- 在线交易需要支付
- 成单后需要货品出库和物流派送等
- 售前需要营销促销活动吸引流量并加强转化
- 售后用户会对店铺、商品进行评价等



2015年中马云团队的一次商务拜访

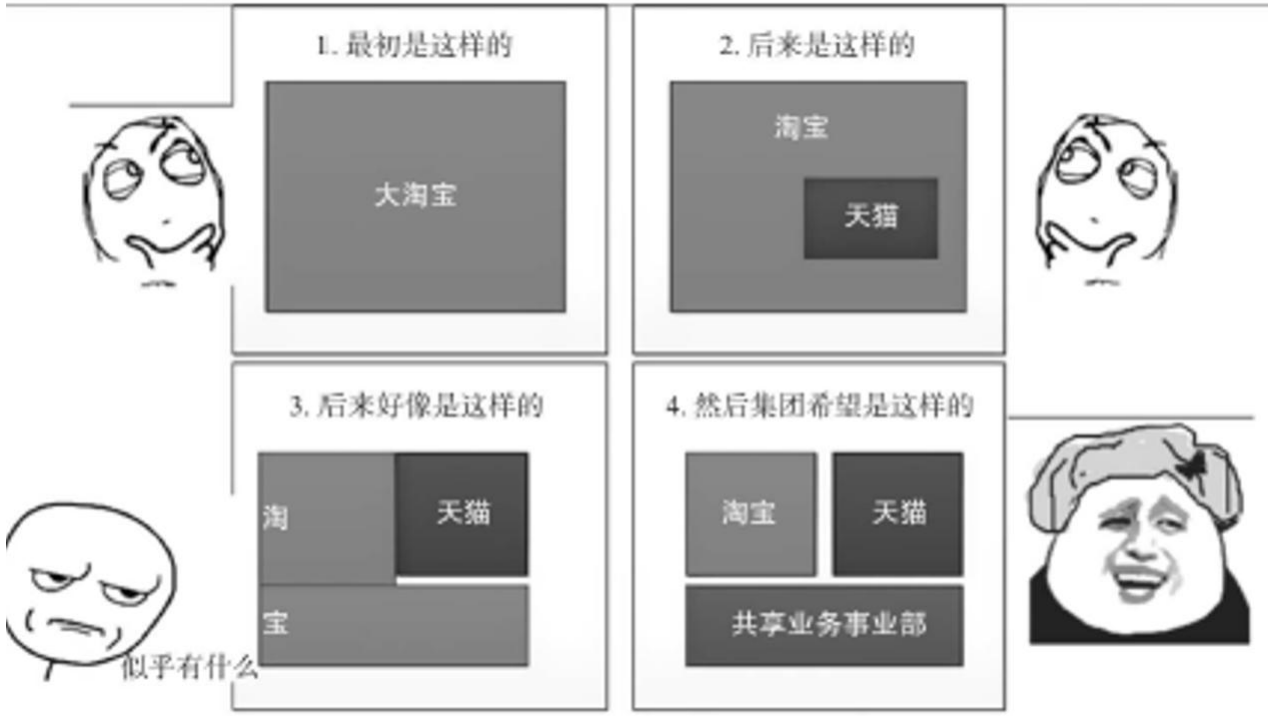
- 拜访了位于芬兰赫尔辛基的移动游戏公司Supercell，这家号称是世界上最成功的移动游戏公司，以《部落战争》《海岛奇兵》《卡通农场》等游戏知名
- Supercell是一家典型的以小团队模式进行游戏开发的公司，一般来说两个员工，或者5个员工，最多不超过7个员工组成独立的开发团队，称之为Cell（细胞），这也是公司名字Supercell（超级细胞）的由来。团队自己决定做什么样的产品，然后最快时间推出产品的公测版，看看游戏是否受用户欢迎。如果用户不欢迎，迅速放弃这个产品，再进行新的尝试，期间几乎没有管理角色的介入。团队研发的产品失败后，不但不会受到惩罚，甚至会举办庆祝仪式，以庆祝他们从失败中学到了东西
- 使用这样的模式使得Supercell公司成为了年税前利润15亿美元的游戏公司，2015年App畅销排行榜上Top10的游戏中，Supercell公司开发的游戏占据了榜单的大半江山。2016年6月，中国腾讯公司以86亿美元收购了员工数不超过200人的Supercell公司84.3%的股权，每一名员工人均贡献的估值超过3.54亿人民币

2015年中马云团队的一次商务拜访

- 强大“中台”的构建，强大的业务试错能力，是Supercell相比于其他游戏公司最大的核心竞争力
  - —这家游戏公司经过6年的时间将游戏开发过程中公共、通用的游戏开发素材、基础设施、游戏引擎、内部开发工具和平台做了很好的沉淀，科学的研发方法和体系，使得公司可以支持几个人的小团队在几周时间就能研发出一款新游戏，并进行公测
  - —企业的文化充分鼓励员工进行创新，甚至进行试错，才使得他们在开发的众多游戏中以最快时间找到那些用户真正喜爱的游戏
- 正是有了这次拜访才真正让阿里巴巴的领导层有了足够的决心要将组织架构进行调整，为下一轮的业务腾飞打下更为坚实的基础在。半年后，阿里正式启动中台战略

阿里巴巴做出中台战略转型的决定并非空中楼阁

- **阿里巴巴从2009年就开始建设共享业务事业部，已经为中台战略在转型过程中将会面临的组织间业务协作、业务核心能力的沉淀、组织KPI考核等方面都做了很好的实践和经验沉淀**



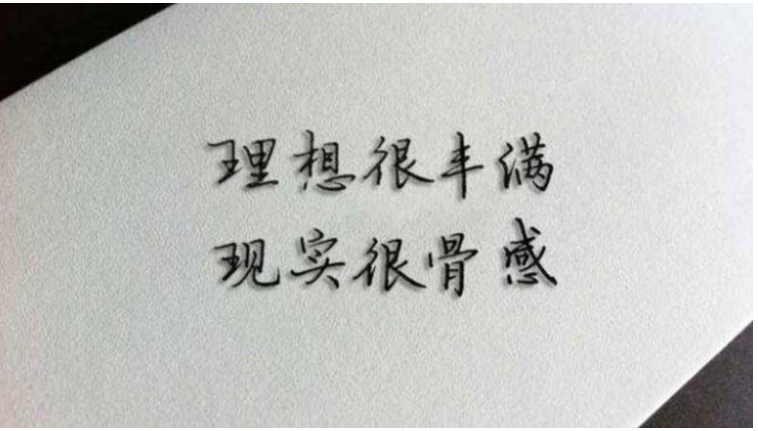
团购平台发展完美地诠释了共享业务事业部这种阵型的威力

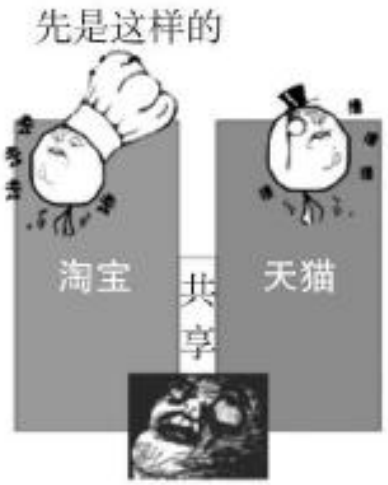
- **这种阵型对于业务快速创新和业务试错的一个代表性案例**
  - —2010年市场上团购业务蓬勃发展，美团、高朋等专业团购网站涌现，阿里也决定构建团购平台。当时阿里投入了包含产品经理、运营、开发的十几名员工进行基于淘宝和天猫商品的团购平台的建设，最终这个团购平台在1个半月后就成功上线！其他同类型的团购平台建设所投入的研发资源可能是阿里投入资源的几十倍，上线时间可能是阿里上线准备时间的好几倍
  - —最大功劳来自于已运转两年的阿里共享服务体系。精心沉淀和打造的用户中心、商品中心、交易中心、评价中心等服务能力在其中都扮演了非常重要的角色

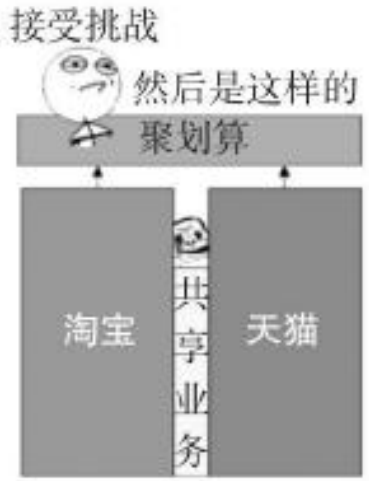


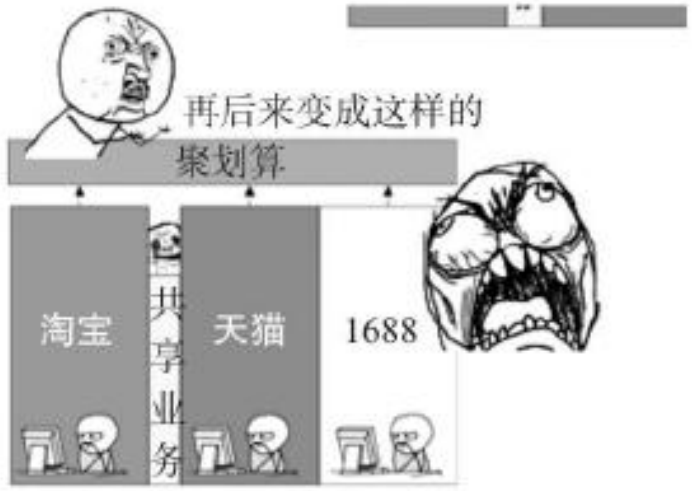
上线后的团购平台在短期内展现出了超出所有人想象的流量吸力之后，集团意识到这是一个非常重要的流量入口，大量资源投入到这一新兴业务，结果是在短短14个月后，这个原本十几人的小团队发展壮大成为接近600人的事业部，这一团购平台就是阿里巴巴的“聚划算”团购平台，目前是与淘宝、天猫并驾齐驱的三大电商事业部

故事就这么完美结束了？





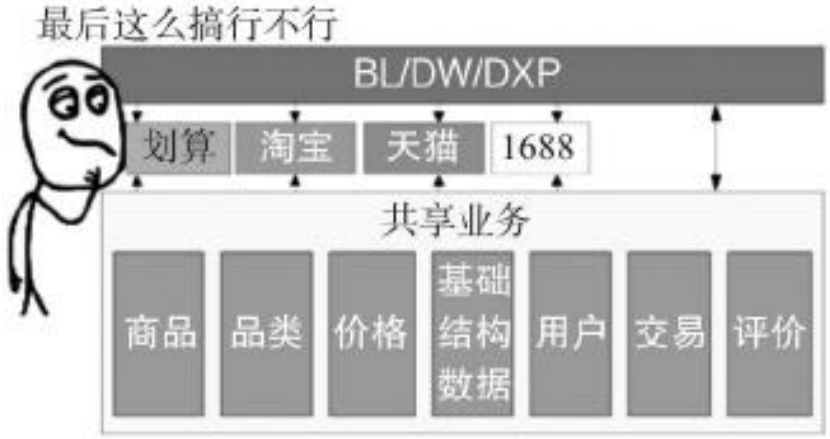




Z 转折点

2010年阿里电商业务的团购入口——聚划算出现





阿里的业务中台组成：（1）会员中心

- 会员中心服务于用户的消费全生命周期，为用户提供特定的权益和服务，企业可以通过会员中心与用户进行互动，培养用户忠诚度。主要能力包括：
  - —会员运营管理：包括会员注册、个人信息维护、会员注销、会员卡办理等相关能力
  - —会员体系管理：包括会员体系的创建、积分规则、成长值规则、等级、权益等相关能力
  - —客户服务管理：包括客户的新增、导入、查询等相关能力
  - —积分交易管理：包括积分获取、核销、清零、冻结、兑换等相关能力

阿里的业务中台组成：（2）商品中心

- 商品中心提供管理商品核心数据的能力，围绕商品构建商品关联数据，诸如商品版本信息、商品品牌、商品属性、商品类目等。其主要能力有：
  - —品牌、类目、属性管理：包括对商品品牌维护、查询，前后端类目的维护，属性及属性组管理等相关能力
  - —产品数据管理：包括对产品模板的创建、编辑、查询、禁用等相关能力
  - —商品数据管理：包括商品创建、修改、查询等相关能力
  - —商品发布管理：包括商品发布、上下架（即时+定时）等相关能力

阿里的业务中台组成：（3）交易中心

- 交易中心负责企业业务交易订单的整体生命周期管理，包括加入购物车→订单生成→合并分拆→流转→支付→发货→退换货→完成。所有电商业务的核心系统都是围绕交易订单进行构建的。其主要能力包括：
  - —购物车管理：包括购物车商品添加、编辑、查询、校验等相关能力
  - —正向交易管理：包括交易订单生成、发起支付交易订单、商品发货管理、上门自提及核销等相关能力
  - —逆向交易管理：包括换货、退货、退款等相关能力
  - —订单数据管理：包括交易订单、支付记录、发货记录、换货记录、退款记录等数据管理能力
  - —交易流程编排：支持交易流程节点的配置化，便于根据业务场景的不同设置与之匹配的流程

阿里的业务中台组成：（4）评价中心

- 评价中心提供对评价主体对象、评价规则/等级、评价内容、评价操作的管理能力，从而满足不同角色的评价用户对评价内容的发布、追加、平台审核、平台申诉等需求。主要能力包括：
  - —评价内容管理：包括管理评价的主体对象、评价规则配置、评价等级、评价标签配置等相关能力
  - —评价操作能力：包括评价的发布、修改、追加、回复、申诉等相关能力
  - —评价监管能力：包括评价发布审核、申诉审核、评价屏蔽等监管相关能力

阿里的业务中台组成：（5）店铺中心

- 店铺中心提供企业店铺主体管理、店铺管理、类型管理、经营对象管理等能力以支持企业为商户提供线上门店，同时支持商户管理、店铺会员、店铺会员等级管理、店铺装修等。其主要能力包括：
  - —商户管理：包括商户单个、批量开通，商户审核，商户基本信息维护等相关能力
  - —店铺管理：包括店铺开通、店铺基本信息维护、店铺审核、店铺会员等相关能力

阿里的业务中台组成：（6）支付中心

- 支付中心给下游商户输出标准的支付服务，提供代付代收、财务对账等服务。通过对接多个主流渠道，稳定输出微信、支付宝、银联等支付能力。其主要能力包括：
  - —支付能力：包括创建支付订单、接收渠道通知、查询渠道订单等基本支付能力
  - —支付路由：包括支付渠道管理、支付方式管理、支付商户和应用开通管理等相关能力
  - —资金账户：包括资金账户管理、充值维护、提现等相关能力

阿里的业务中台组成：（7）营销中心

- **营销中心提供商家的活动计划、申报、审批、执行、核销的全链路管理，也提供基本的促销能力，如优惠券活动、满减买赠等。**其主要能力包括：
  - —**活动模板管理**：包括提供营销活动的策略模板、规则配置、条件、动作模板等相关能力
  - —**活动管理**：包括提供具体活动的基本信息配置、人群圈选、商品管理、触发条件等相关能力
  - —**优惠券管理**：包括优惠券的发放、领取、查询、使用核销等相关能力
  - —**赠品管理**：对于满赠、买赠活动，提供赠品维护、查询、启用、禁用等相关能力

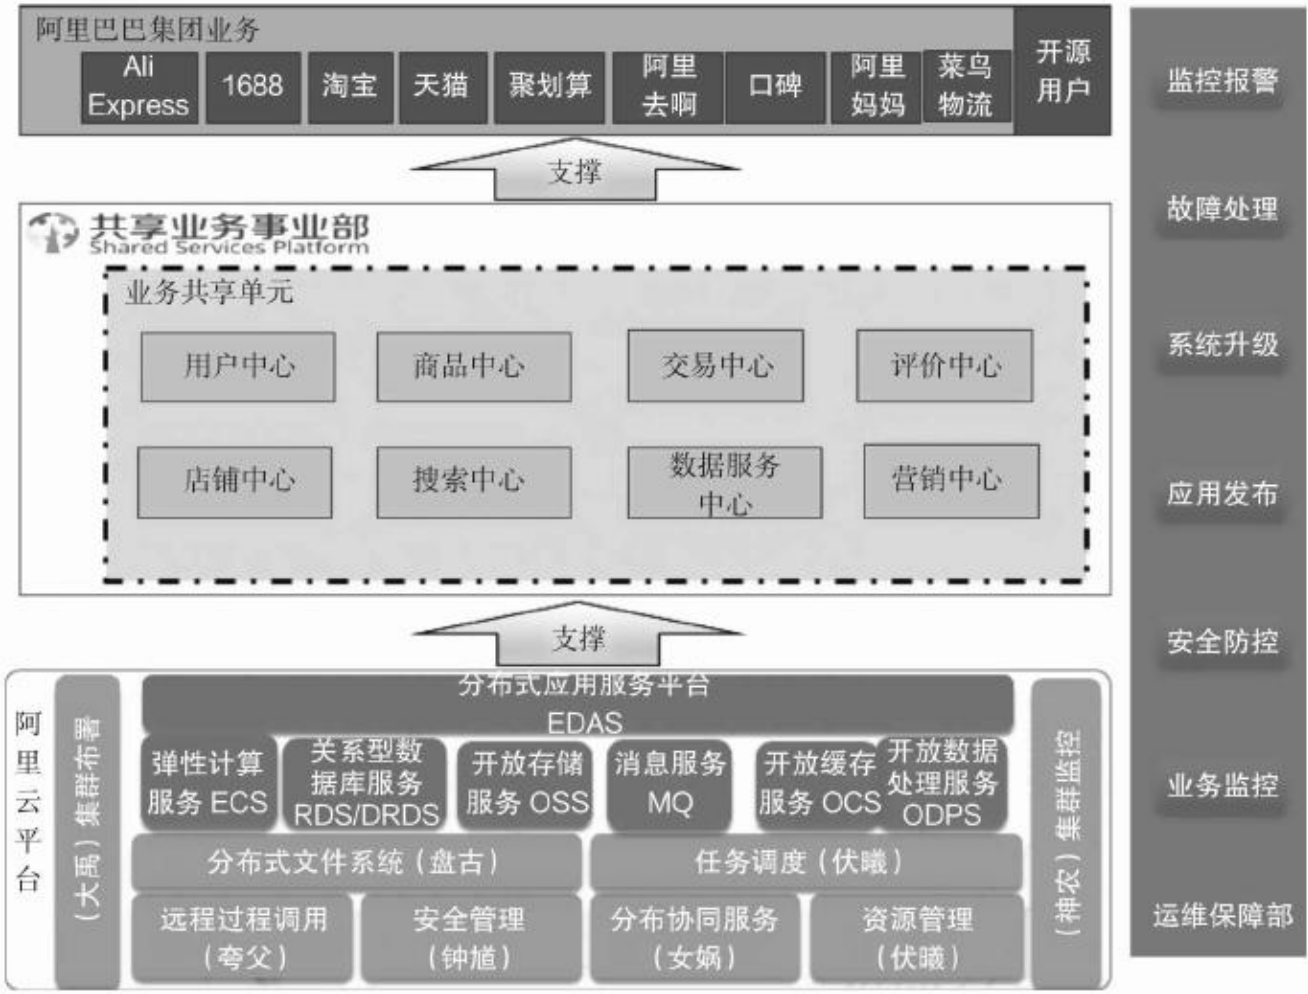
阿里的业务中台组成：（8）库存中心

- 库存中心提供仓库、库存、货品、单据（入库单/出库单/盘点单/盘点盈亏单）、审核（调拨/盘点）、包裹、货品运费、物流运输、接入第三方物流公司的服务能力。其主要能力包括：
  - —仓库管理：包括服务区、仓库、仓位及其关联管理等相关能力
  - —货品管理：包括货品进货入库、销售出库、调拨入库、调拨出库、调拨审核等相关能力
  - —货品盘点：包括盘点单生成、审核、查询等相关能力
  - —履约管理：包括库存检查、发货单创建及查询、包裹物流查询、运费管理、物流状态跟踪等相关能力

阿里共享业务事业部的发展史（图3）

- 阿里将前端业务中公共、通用的业务沉淀到了共享业务事业部，包含了用户中心、商品中心、交易中心、评价等十几个中心，共享业务事业部成了阿里的核心业务平台
- 目前阿里前端超过25个业务单元（如淘宝、天猫、聚划算、去啊等业务）均不是独立构建在阿里云平台之上，在后端阿里云技术平台和前端业务间有了一个“共享业务事业部”，为阿里各种前端业务提供相应服务中心领域内最为专业、稳定的业务服务

“厚平台、薄应用”架构形态

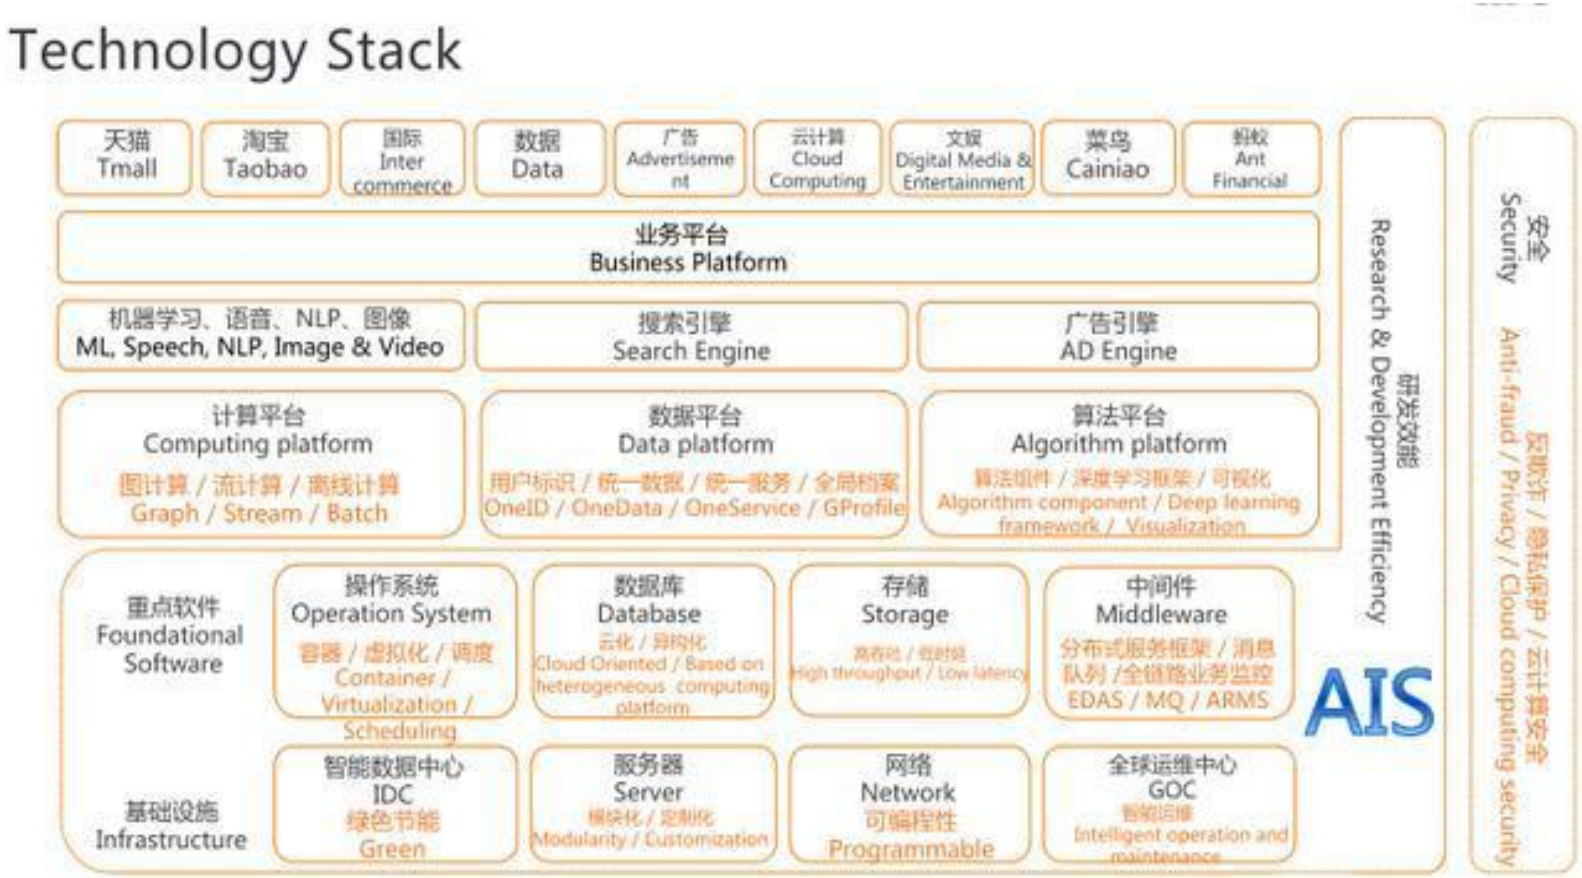


阿里巴巴的技术中台

三年投入1000亿

阿里巴巴达摩院

“比阿里还活得长”



阿里云 | 達摩院 ALIBABA DAMO ACADEMY

达摩院：以科技，创新世界

2017年10月11日，达摩院正式成立，定位于应用驱动的基础科学和创新技术研究

Research for solving the problem with profit and fun

愿景：要活得比阿里巴巴久；服务全世界至少20亿人口；要面向未用科技解决未来的问题

家国情怀
世界担当

新应用

新零售、新金融、新制造、新技术、新能源

算法

感知，理解，决策

数据

认知图谱

计算

芯片、量子

技术合作
商业合作
学术合作

应用驱动全面的技术布局和集成，实现系统层面的颠覆式创新

阿里巴巴的数据中台

- **数据中台是一个用技术连接大数据计算存储能力，用业务连接数据应用场景能力的平台，“连接能力”是数据中台的精髓**
  - 在业务层面需要尽可能**连接各种数据源**作为其生产资料。同时，由于生产数据的场景越来越多，覆盖了线上、线下等多渠道，各数据生产资料之间也需要进行连接，才能形成全域的数据
  - 数据在数据中台这个平台上按照标准的模型进行规范加工处理后需要服务于多种场景，同样需要**提供标准的数据服务接口将数据与应用场景连接**起来
  - **连接是数据中台的根本能力，也是数据中台的价值所在**

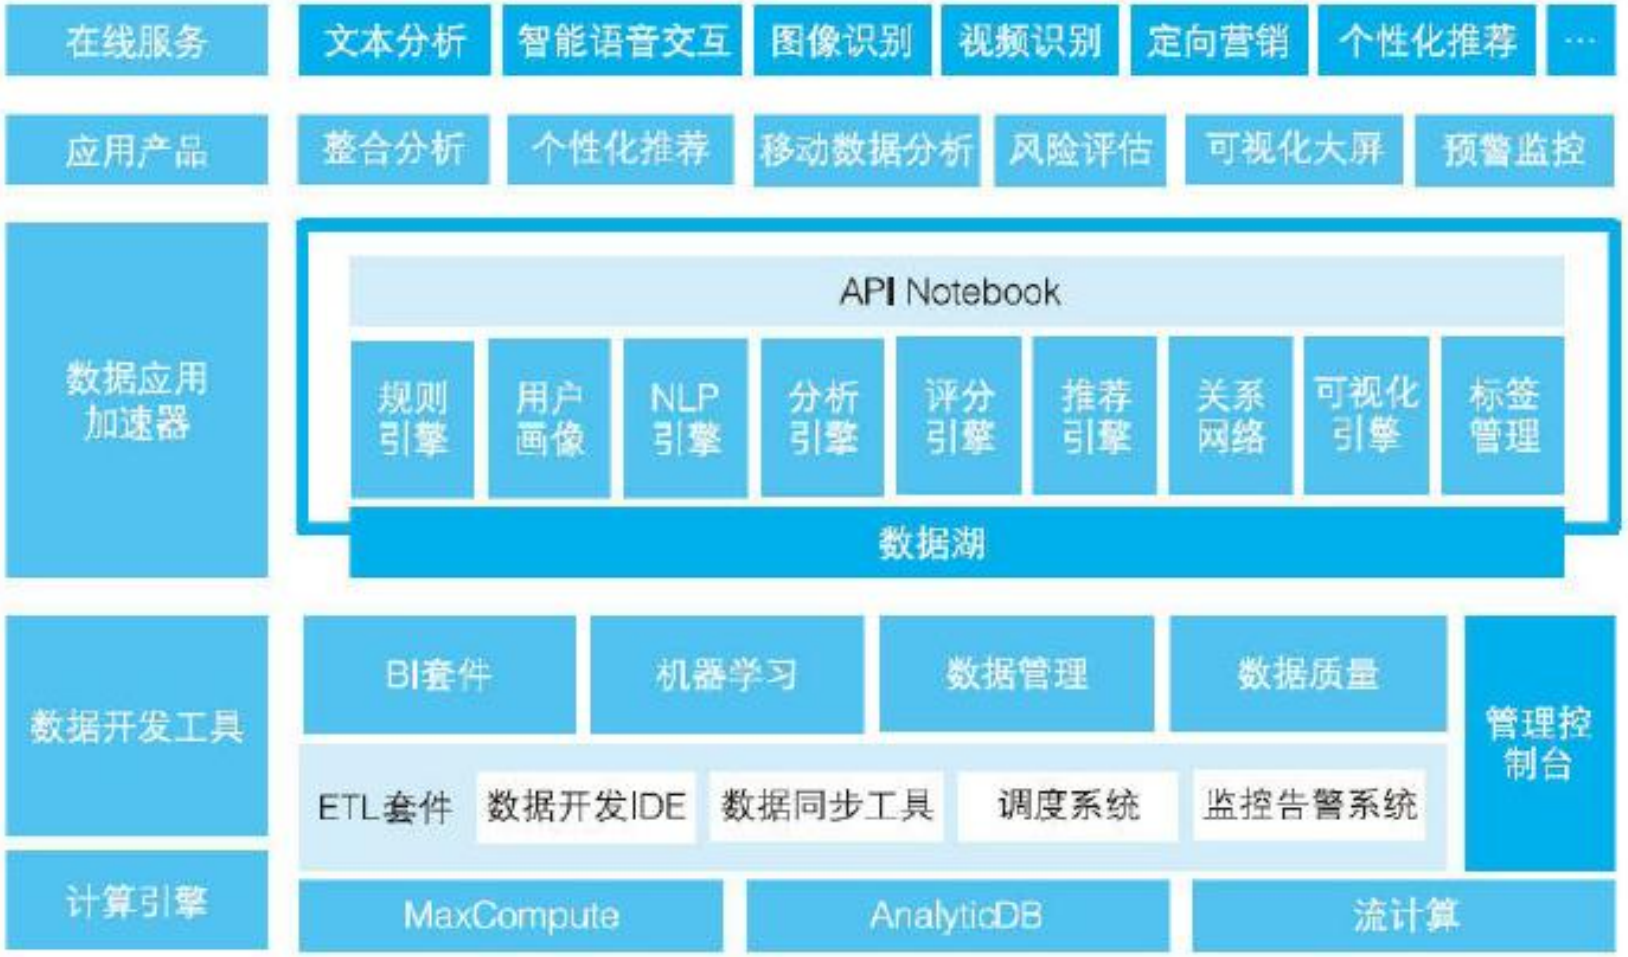


阿里巴巴的数据中台


应用场景
首页千人千面
购物车关联推荐
搜索页猜你喜欢
数据中台
商品推荐模型API（客户ID）
用户A：女性，评价好，常搜索连衣裙，多次加入购物车
用户标签
商品A：爆款，连衣裙，女士服装，被多人多次浏览
商品标签
全域数据打通
用户浏览数据
用户搜索数据
商品交易数据
商品评价数据
商品分享数据
数据源
埋点日志
业务数据

阿里巴巴的数据中台

- 除了通用的数据分析以外，还包含“个性化推荐”“风险评估”“预警监控”等与业务紧密结合的数据赋能业务的应用。而这些丰富的赋能业务的数据应用必须依赖数据中台提供的强大的数据服务来支撑



roadview® 博文视点·IT出版旗舰品牌
www.broadview.com.cn
技术凝聚实力·专业创新出版

大数据之路

阿里巴巴大数据实践

◆十余年大数据实践总结◆
◆多位阿里数据人经验汇总◆

数据技术篇
日志采集　数据同步
离线数据开发　实时技术
数据服务　数据挖掘

数据模型篇
大数据领域建模综述　阿里巴巴数据整合及管理体系
维度设计　事实表设计

数据管理篇
元数据　计算管理
存储和成本管理　数据质量

数据应用篇
生意参谋　对内数据产品平台

易读易查 知识点目录+插图索引
加深理解 精心绘制139张流程与架构示意插图

博文视点Broadview
新浪微博 weibo.com
@博文视点Broadview

策划编辑：张彦红
责任编辑：葛　娜
封面设计：李　玲

上架建议：大数据

ISBN 978-7-121-31438-4
9 787121 314384 >
定价：79.00元

大数据之路 阿里巴巴大数据实践

電子工業出版社

Broadview®
www.broadview.com.cn

Alibaba Group 阿里巴巴集团 | 技术丛书

大数据之路

阿里巴巴大数据实践

阿里巴巴数据技术及产品部 著



中国工信出版集团
電子工業出版社 PUBLISHING HOUSE OF ELECTRONICS INDUSTRY http://www.phei.com.cn

目 录

第 1 章　总述……1

第 1 篇　数据技术篇

第 2 章　日志采集……8

2.1　浏览器的页面日志采集……8

2.1.1　页面浏览日志采集流程……9

2.1.2　页面交互日志采集……14

2.1.3　页面日志的服务器端清洗和预处理……15

2.2　无线客户端的日志采集……16

2.2.1　页面事件……17

2.2.2　控件点击及其他事件……18

2.2.3　特殊场景……19

2.2.4　H5 & Native 日志统一……20

2.2.5　设备标识……22

2.2.6　日志传输……23

2.3　日志采集的挑战……24

2.3.1　典型场景……24

2.3.2　大促保障……26

第 3 章　数据同步……29

3.1　数据同步基础……29

3.1.1　直连同步……30

3.1.2　数据文件同步……30

3.1.3　数据库日志解析同步……31

3.2　阿里数据仓库的同步方式……35

3.2.1　批量数据同步……35

3.2.2　实时数据同步……37

3.3　数据同步遇到的问题与解决方案……39

3.3.1　分库分表的处理……39

3.3.2　高效同步和批量同步……41

3.3.3　增量与全量同步的合并……42

3.3.4　同步性能的处理……43

3.3.5　数据漂移的处理……45

第 4 章　离线数据开发……48

4.1　数据开发平台……48

4.1.1　统一计算平台……49

4.1.2　统一开发平台……53

4.2　任务调度系统……58

4.2.1　背景……58

4.2.2　介绍……59

4.2.3　特点及应用……64

第 5 章　实时技术……68

5.1　简介……69

5.2　流式技术架构……71

5.2.1　数据采集……72

5.2.2　数据处理……74

5.2.3　数据存储……78

5.2.4　数据服务……80

5.3　流式数据模型……80

5.3.1　数据分层……80

5.3.2　多流关联……83

5.3.3　维表使用……84

5.4　大促挑战&保障……86

5.4.1 大促特征……86
5.4.2 大促保障……87
第 6 章 数据服务……91
6.1 服务架构演进……91
6.1.1 DWSOA……92
6.1.2 OpenAPI……93
6.1.3 SmartDQ……94
6.1.4 统一的数据服务层……96
6.2 技术架构……97
6.2.1 SmartDQ……97
6.2.2 iPush……100
6.2.3 Lego……101
6.2.4 uTiming……102
6.3 最佳实践……103
6.3.1 性能……103
6.3.2 稳定性……111
第 7 章 数据挖掘……116
7.1 数据挖掘概述……116
7.2 数据挖掘算法平台……117
7.3 数据挖掘中台体系……119
7.3.1 挖掘数据中台……120
7.3.2 挖掘算法中台……122
7.4 数据挖掘案例……123
7.4.1 用户画像……123
7.4.2 互联网反作弊……125

第 2 篇 数据模型篇

第 8 章 大数据领域建模综述……130
8.1 为什么需要数据建模……130
8.2 关系数据库系统和数据仓库……131

8.3 从 OLTP 和 OLAP 系统的区别看模型方法论的选择……132
8.4 典型的数据仓库建模方法论……132
8.4.1 ER 模型……132
8.4.2 维度模型……133
8.4.3 Data Vault 模型……134
8.4.4 Anchor 模型……135
8.5 阿里巴巴数据模型实践综述……136
第 9 章 阿里巴巴数据整合及管理体系……138
9.1 概述……138
9.1.1 定位及价值……139
9.1.2 体系架构……139
9.2 规范定义……140
9.2.1 名词术语……141
9.2.2 指标体系……141
9.3 模型设计……148
9.3.1 指导理论……148
9.3.2 模型层次……148
9.3.3 基本原则……150
9.4 模型实施……152
9.4.1 业界常用的模型实施过程……152
9.4.2 OneData 实施过程……154
第 10 章 维度设计……159
10.1 维度设计基础……159
10.1.1 维度的基本概念……159
10.1.2 维度的基本设计方法……160
10.1.3 维度的层次结构……162
10.1.4 规范化和反规范化……163
10.1.5 一致性维度和交叉探查……165
10.2 维度设计高级主题……166
10.2.1 维度整合……166
10.2.2 水平拆分……169

10.2.3 垂直拆分……170
10.2.4 历史归档……171
10.3 维度变化……172
10.3.1 缓慢变化维……172
10.3.2 快照维表……174
10.3.3 极限存储……175
10.3.4 微型维度……178
10.4 特殊维度……180
10.4.1 递归层次……180
10.4.2 行为维度……184
10.4.3 多值维度……185
10.4.4 多值属性……187
10.4.5 杂项维度……188
第 11 章 事实表设计……190
11.1 事实表基础……190
11.1.1 事实表特性……190
11.1.2 事实表设计原则……191
11.1.3 事实表设计方法……193
11.2 事务事实表……196
11.2.1 设计过程……196
11.2.2 单事务事实表……200
11.2.3 多事务事实表……202
11.2.4 两种事实表对比……206
11.2.5 父子事实的处理方式……208
11.2.6 事实的设计准则……209
11.3 周期快照事实表……210
11.3.1 特性……210
11.3.2 实例……212
11.3.3 注意事项……217
11.4 累积快照事实表……218
11.4.1 设计过程……218
11.4.2 特点……221

11.4.3 特殊处理……223
11.4.4 物理实现……225
11.5 三种事实表的比较……227
11.6 无事实的事实表……228
11.7 聚集型事实表……228
11.7.1 聚集的基本原则……229
11.7.2 聚集的基本步骤……229
11.7.3 阿里公共汇总层……230
11.7.4 聚集补充说明……234
第 3 篇 数据管理篇
第 12 章 元数据……236
12.1 元数据概述……236
12.1.1 元数据定义……236
12.1.2 元数据价值……237
12.1.3 统一元数据体系建设……238
12.2 元数据应用……239
12.2.1 Data Profile……239
12.2.2 元数据门户……241
12.2.3 应用链路分析……241
12.2.4 数据建模……242
12.2.5 驱动 ETL 开发……243
第 13 章 计算管理……245
13.1 系统优化……245
13.1.1 HBO……246
13.1.2 CBO……249
13.2 任务优化……256
13.2.1 Map 倾斜……257
13.2.2 Join 倾斜……261
13.2.3 Reduce 倾斜……269

第 14 章　存储和成本管理……275
14.1　数据压缩……275
14.2　数据重分布……276
14.3　存储治理项优化……277
14.4　生命周期管理……278
14.4.1　生命周期管理策略……278
14.4.2　通用的生命周期管理矩阵……280
14.5　数据成本计量……283
14.6　数据使用计费……284
第 15 章　数据质量……285
15.1　数据质量保障原则……285
15.2　数据质量方法概述……287
15.2.1　消费场景知晓……289
15.2.2　数据加工过程卡点校验……292
15.2.3　风险点监控……295
15.2.4　质量衡量……299

第 4 篇　数据应用篇

第 16 章　数据应用……304
16.1　生意参谋……305
16.1.1　背景概述……305
16.1.2　功能架构与技术能力……307
16.1.3　商家应用实践……310
16.2　对内数据产品平台……311
16.2.1　定位……311
16.2.2　产品建设历程……312
16.2.3　整体架构介绍……316
附录 A　本书插图索引……319

上海交通大学RFID与物联网研究所

内 容 简 介

本书是《大数据之路：阿里巴巴大数据实践》的升级版，内容不再仅仅聚焦于阿里巴巴，而是延伸到对千行百业的实践与探索。本书从追溯数据中台的起源与发展脉络，到从多视角、绘蓝图、资源化和资产化等多方面设计满足业务需求的数据中台框架，再到全方位探讨数据的交易与流通、智能算法的应用，以及“1NN”决策分析框架的应用，汇聚了作者在大数据实践过程中的经验、教训和方法。

本书理论与实践相结合，包含大量真实的案例，从金融服务的风险控制，到制造业的供应链优化，再到零售业的个性化营销，通过大量鲜活的实例为读者提供极具价值的参考与启示。不论是企业经营者、数据管理者，还是技术实践者、数据爱好者，都能从中受益。

未经许可，不得以任何方式复制或抄袭本书之部分或全部内容。
版权所有，侵权必究。

图书在版编目（CIP）数据

大数据之路. 2，数据更普惠，商业更智能 / 瓴羊智能科技著. — 北京 : 电子工业出版社，2025. 2.
ISBN 978-7-121-49210-5

Ⅰ. F272.7

中国国家版本馆 CIP 数据核字第 2024MX6751 号

责任编辑：张彦红　　文字编辑：孙奇俏
印　　刷：涿州市京南印刷厂
装　　订：涿州市京南印刷厂
出版发行：电子工业出版社
　　北京市海淀区万寿路 173 信箱　　邮编：100036
开　　本：720×1000　1/16　　印张：28.5　　字数：595.3 千字
版　　次：2025 年 2 月第 1 版
印　　次：2025 年 2 月第 2 次印刷
定　　价：98.00 元

凡所购买电子工业出版社图书有缺损问题，请向购买书店调换。若书店售缺，请与本社发行部联系，联系及邮购电话：（010）88254888，88258888。

质量投诉请发邮件至 zlts@phei.com.cn，盗版侵权举报请发邮件至 dbqq@phei.com.cn。

本书咨询联系方式：faq@phei.com.cn。

Broadview 博文视点

大数据之路 2 数据更普惠，商业更智能

電子工業出版社

Broadview
www.broadview.com.cn

阿里巴巴 | 瓴羊

大数据之路 2



数据更普惠，商业更智能

瓴羊智能科技 著

中国工信出版集团　電子工業出版社 PUBLISHING HOUSE OF ELECTRONICS INDUSTRY

走好选择的路，不选好走的路

距离《大数据之路：阿里巴巴大数据实践》一书出版已经过去 7 年。这些年里，我们收到了很多关于这本书再版的咨询，其中有学生，也有企业高管，以及不少出版社对第二本书的出版邀请。我们难免有些诚惶诚恐，这些摸着石头过河的经验没想到成为行业里的先行者和定义者，于是我们对出版新书更加审慎。

这 7 年来，数据浪潮引领着互联网时代来到了 AI 时代，各种变化也纷至沓来。数据体量的变化、竞争格局的变化、经济形势的变化和世界环境的变化，都给企业和企业里的数据人带来了巨大的挑战，也带来了巨大的机遇。数据，作为第五生产要素，正在发挥着前所未有的重要价值。

于我们自身而言，最大的变化是从阿里巴巴内部的数据团队转变为独立的数字化品牌——瓴羊智能科技，也是现在阿里巴巴云智能集团的核心数字化软件服务业务。从过去服务阿里巴巴，到现在服务千行百业，深入各个行业，我们发现数字化的发展程度各不相同，各家企业的需求也不尽相同，甚至一家企业内部对同一个数据的认识也不同。

我于 2004 年加入阿里巴巴，从加入的第一天起，我就在数据相关的岗位工作，可以说是中国最早的一批数据人。在阿里巴巴这艘“大船”上服务了 20 年，我们亲眼见证过数据从少到多、从繁到简、从局部优化变成核心引擎。

我印象最深的是 10 年前，当时阿里巴巴正在高速发展，生意增长非常快，业务也越来越多元化，这就面临着一个非常严峻的问题——如果不能有效地治理数据，那么仅仅服务器产生的成本就会吃掉公司未来的利润。当时，1 张数据库表，8 个部门存 8 遍。1 张表一年的成本是 1200 万元，8 张表加起来将近 1 亿元。

这个任务摆在了 DT（Data Technology，数据技术）团队面前，虽然彼时互联网蓬勃发展，但放眼全行业，几乎没有专业的数据人。面对每天层出不穷的问题，我们既没有可以借鉴的解决方案，也没有可以照抄的答案。更何况，庞大的数据治理工作需要各个业务部门的配合，但当时每个业务部门都在高速发展，都有非常充分的拒绝配合的理由和困难。有好心人提醒我：“做得好，不一定是你们的功劳；做得不好，你们可要负全部责任！”顶着这个压力，我带着团队进驻项目室，在干中学、在学中干，一边建设，一边优化。

最终，我们成功构建了集团数据公共层，这正是后来广为人知的阿里巴巴“数据中台”。在那个时期，我们确立了诸如 One Data、One ID、One Service 等概念，这些概念早已超越了阿里巴巴内部的专用范畴，不再仅仅是数据行业的专业术语，而是成为跨越多个领域的通用词汇。

如果说上一本书从我们在阿里巴巴的经验出发，在“术”的层面讲讲数据，那么在《大数据之路 2：数据更普惠，商业更智能》一书中，希望分享的更多是从瓴羊这个组织走出去，我们看到的千百家企业如何基于数据形成一套组织生长、企业管理、业务洞察的“方法论”，聊聊“道”的层面。

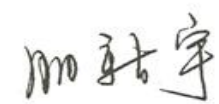
尤其 2024 年以来，AI 成为全行业共同的关注点，我们也感觉到企业对未来的期待和不安。期待，是因为新的变革和机会已经近在眼前；不安，则是因为不知道如何抓住先机。2024 年，在跟我们服务的一些企业 CEO 交流时，他们普遍表示：“我们对 AI 持非常开放的态度，并且非常愿意尝试，但问题在于，我们不知道如何与 AI 结合。”

这些 CEO 的困惑也是大部分企业正在面临的挑战，我们希望本书能给读者解惑，这也正是本书的价值所在。我们在服务每一家企业时，都是将企业视为一个“生命体”，深入研究其生长周期。数据作为这个“生命体”最基本的单元，如何生长更替，帮助企业完成“新陈代谢”，顺利穿越不同的经济周期，实现基业长青，是每家企业都渴望的目标。

最后，我也想向撰写本书的瓴羊团队致谢。他们在保证产品上线、升级、客户交付等工作的情况下，将瓴羊在行业中积累的经验和实践整理成文字，相信其中的价值已体现在字里行间，待各位读者细细翻阅。也特别感谢一路上信任和给我们提出宝贵意见与建议的客户、同行、专家和老师们。深知不足，唯有携手前行。

朋新宇

阿里巴巴集团副总裁、瓴羊 CEO



第 1 章　再出发：数据中台的萌芽与蜕变　001

1.1　理念起源：中台思维的初步形成　002
1.2　标准确立：OneData 体系的升级　004
1.3　平台构建：OneData 与数据中台的融合　006
1.4　转型深化：数据中台的新变革　011
1.5　持续进化：数据中台的未来发展　012

第 2 章　多视角：从千行百业中的问题出发　013

2.1　CXO 视角：数据中台的战略考量　014
2.1.1　数据中台的实质分析　014
2.1.2　数据中台的目标与价值体现　014
2.1.3　组织与人才在数据中台建设中的作用　017
2.2　数据管理者视角：数据中台的运维与治理　019
2.2.1　数据中台业务价值评估与团队认同　020
2.2.2　数据资源的高效利用与成本控制　021
2.2.3　数据治理实践与数据质量提升　023
2.3　数据消费者视角：数据中台的使用体验　025
2.3.1　优化数据搜索效率与用户体验　025
2.3.2　提高数据质量与数据可信度　026

第 3 章　绘蓝图：数据中台的思维与框架　027

3.1　跨越十年：数据中台的演进与本质思考　027
3.1.1　应变之道：面对变革的策略选择　027
3.1.2　双轨并进：数据构建与应用的协同演进　029
3.2　数据中台思维：战略 · 价值 · 运营　032
3.2.1　战略为先：顶层设计与渐进迭代　032
3.2.2　价值导向：业务共振与价值生成　034
3.2.3　运营为核：数据中台的建设策略　037
3.3　数据中台框架：从顶层设计到价值实现　038
3.3.1　顶层设计：塑造战略导向，组织敏捷与文化创新　039
3.3.2　资源化：构建稳健数据架构与高效建设机制　041
3.3.3　资产化：深化数据管理与治理，实现数据资产增值　043
3.3.4　要素化：促进数据交易与流通，激活数据市场活力　044
3.3.5　价值化：智能决策赋能，驱动业务创新与增长　046

第 4 章　资源化：数据架构与建设　049

4.1　数据架构的时光机：阿里巴巴视角下的演变　049
4.1.1　开启旅程：孵化期的业务数据启蒙　050
4.1.2　蓄势待发：萌芽期的独立引擎与离线仓库　050
4.1.3　迈向未来：迭代期的实时计算革命　052
4.1.4　筑梦成真：成熟期的 OneData 与数据中台　054
4.1.5　引领变革：变革期的湖仓一体架构　055
4.1.6　迎接挑战：大模型驱动的数据进化　057
4.2　数据架构模式的前沿探索　057
4.2.1　分布式之美：Data Mesh 的领域驱动　057
4.2.2　织就数据网：Data Fabric 的统一数据体验　058
4.2.3　敏捷运维之道：DataOps 的持续改进　059
4.2.4　数据中台：企业级数据治理的典范　060
4.3　数据架构的理论基石与设计原则　061
4.3.1　数据架构的本质与价值　061
4.3.2　数据模型架构设计的原则与方法　063
4.3.3　解析数据平台架构设计的关键要素与实践　068
4.4　数据架构案例：达米公司的数据架构建设实践　071
4.4.1　业务布局与数字化转型需求　072
4.4.2　如何规划企业级数据仓库　073

4.4.3 如何克服数据“孤岛”，实现数据集成 082
4.4.4 如何构建和管理多模态数据资产 089
4.5 行业数据架构推荐与案例分析 131
4.5.1 金融行业：数据治理与合规挑战 131
4.5.2 汽车行业：大规模数据处理与分析 136
4.5.3 服饰行业：个性化数据服务与营销 140

第 5 章 资产化：数据治理与管理 145

5.1 数据治理概述 145
5.1.1 区分数据治理与数据管理 145
5.1.2 解析数据治理的核心问题 146
5.1.3 制定数据治理的目标 150
5.1.4 构建数据治理的框架 150
5.2 数据标准管理 152
5.2.1 数据标准的核心问题 153
5.2.2 “三流合一”的数据标准解决方案 154
5.2.3 数据标准的治理工具与平台 161
5.3 数据质量管理 169
5.3.1 数据质量管理的核心挑战 169
5.3.2 “三流合一”的数据质量管理模式 176
5.3.3 数据质量评价与优化机制 184
5.4 数据安全与流通管理 188
5.4.1 数据安全合规面临的核心挑战 189
5.4.2 数据安全治理的方法和框架 192
5.4.3 数据安全实践 202
5.5 数据成本管理 203
5.5.1 数据资源利用的核心挑战 203
5.5.2 资源治理闭环体系的构建 204
5.5.3 数据成本计量与模型设计 207
5.6 数据治理运营体系建设 210
5.6.1 阿里巴巴数据治理模式：“0-1-N”模式 210
5.6.2 数据治理的人才体系及培训机制 211
5.6.3 数据治理的管理机制优化 213
5.6.4 数据治理的文化建设与宣导 216

第 6 章 要素化：数据的交易与流通 219

6.1 构建企业内部数据消费生态体系 220
6.1.1 数据资源化：激活数据价值的引擎 220
6.1.2 场景价值导向：驱动数据消费的深化与拓展 222
6.1.3 数据运营：企业数字化转型的基石与引擎 228
6.1.4 阿里巴巴大促：数据驱动下的精细化运营实践 237
6.2 布局企业外部数据流通生态体系 239
6.2.1 如何高效整合外部数据资源 239
6.2.2 数据资产商业化的策略与挑战 241
6.2.3 瓴羊港：企业数据流通的服务枢纽 243
6.3 数据流通的深化合规与技术融合 253
6.3.1 多维合规视角下的数据流通治理 253
6.3.2 合规与技术驱动的协同机制 258
6.4 数据资产入表 266
6.4.1 数据资产入表的定义与会计处理依据 267
6.4.2 数据资产入表的重要性 267
6.4.3 数据资产入表的条件 269
6.4.4 数据资产入表的步骤 270
6.4.5 数据资产入表的准备工作 274

第 7 章 大模型：数据与智能算法 277

7.1 从符号到大模型的 AI 跃迁 277
7.2 深度学习与数据驱动 279
7.2.1 深度学习模型的迭代与创新 279
7.2.2 数据到模型全流程优化路径 284
7.3 智能引擎在推荐系统、广告系统与搜索引擎中的应用 292
7.3.1 推荐系统的架构、链路与算法 292

7.3.2 计算广告体系的架构、链路与算法 298
7.3.3 搜索系统的架构、链路与算法 301
7.4 大模型时代的革新与发展 305
7.4.1 语言模型：从 Word2Vec 到通义千问 306
7.4.2 多模态大模型：从学习到生成模型 312
7.4.3 AI Agent：革新、架构与行业应用探索 322
7.5 大数据赋能大模型创新与突破 326
7.5.1 数据规模，大模型演化的关键 327
7.5.2 检索增强，大模型可信化的基石 328
7.5.3 数据资产，大模型效能的催化剂 330
7.6 大模型赋能 Quick BI 332
7.6.1 Quick BI，数据洞察的智慧平台 332
7.6.2 Quick BI 与智能小 Q 333
7.6.3 Quick BI 的底层核心能力 336

第 8 章 价值化：数据驱动下的智能决策 339

8.1 “1NN”决策体系框架：构建企业数智管理内核 339
8.1.1 一套数据语言体系：打造企业内部的“神经中枢”（“1”） 340
8.1.2 N 层决策分析核心架构：从战略到执行的准确映射（“N”） 342
8.1.3 N 个决策分析关键要素：确保数据语言准确高效（“N”） 343
8.2 “1NN”决策体系建设思路：推动数智管理的设计与实施 344
8.2.1 “1NN”决策体系建设的三大关键支柱 344
8.2.2 “1NN”决策体系建设的实施路径及步骤 346
8.3 数智管理案例：“1NN”决策体系在业务场景中的应用 348
8.3.1 业务痛点及核心需求分析 348
8.3.2 “1NN”决策体系解决方案：定制化应对策略 349
8.4 业财一体化案例：“1NN”决策体系数智化重塑业财融合 352
8.4.1 业务痛点及核心需求 352
8.4.2 “1NN”决策体系的业财解决方案 354
8.4.3 案例总结：业财融合的成功实践 357
8.5 人力资源数智化案例：“1NN”决策体系重塑人力资源管理体系 358
8.5.1 背景与需求 359
8.5.2 关键要素分析 359
8.5.3 人力资源管理的转型 360
8.5.4 人效金字塔方法论 361

第 9 章 价值化：数据驱动产销协同 365

9.1 数智产销的发展进阶 366
9.1.1 初始期：业务流程驱动管理 367
9.1.2 发展期：决策分析驱动管理 369
9.1.3 变革期：数据智能驱动管理 370
9.2 数智产销协同化 372
9.2.1 产销的“1NN”决策体系设计 372
9.2.2 产销的 PLM 智能决策设计 376
9.3 数智化产销决策实战案例 379
9.3.1 新品企划：宠物用品从洞察到爆品的实战路径 379
9.3.2 商品铺货：小家电的精细化管理实践 384
9.3.3 需求预测：供应链优化的实战案例 386
9.3.4 精准补调：瓴羊赋能快消品供应链优化 388

第 10 章 价值化：多源数据融合的智能营销探索 391

10.1 多源数据融合的价值场景案例 392
10.1.1 营销服务的痛点透视与核心需求解析 393
10.1.2 RTA 构建高效广告投放优化实战 394
10.1.3 LBS 数据赋能品牌跨渠道协同效应 396
10.2 多源数据融合的关键技术 400
10.2.1 通过 OneID 建立标签画像 400
10.2.2 Embedding 的两种形式 407
10.2.3 隐私计算与联邦学习 409
10.2.4 DataTrust：如何实现数据可用不可见 410

第 11 章　先行者：数据文化与组织建设　415
11.1　不同企业数据战略下的组织设计　416
11.1.1　以“数据能力建设”为导向的组织设计　417
11.1.2　以成为“客户运营商”为战略的组织设计　420
11.1.3　面向“数据商业”的组织设计　423
11.2　阿里巴巴的数据组织与文化运营　428
11.2.1　阿里巴巴数据组织的发展历程　428
11.2.2　数据岗位的设定与标准　430
11.2.3　数据文化的酝酿与繁荣　433
11.3　数据组织与文化保障企业数据战略落地　435
11.3.1　数据组织及文化建设的关键点　435
11.3.2　企业数据组织建设与数据文化运营的建议　437