

Data Mining and Big Data Anlysis
数据挖掘及大数据分析

— Chapter 7： Classification分类
7-2：高级方法

王东、张谦、丁玥
上海交通大学软件学院RFID与物联网实验室

2025年春季

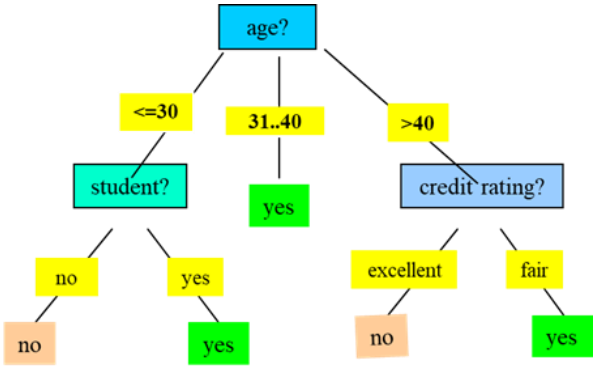
Chapter 7 Classification 分类
7-2：Adanced Methods 高级方法

Rule-Based Classification	**基于规则的分类**
Bayes Classification Methods	贝叶斯分类(ML课程)
Bayesian Belief Networks	贝叶斯信念网络
Classification by Backpropagation	用后向传播分类(ML课程)
Support Vector Machines	支持向量机(ML课程)
Classification Using Frequent Patterns	使用频繁模式分类
Lazy Learners	惰性学习法(ML课程)
(or Learning from Your Neighbors)	（或从近邻学习）
Other Classification Methods	其他分类方法
Ensemble Learning	集成分类法
Additional Topics Regarding Classification	关于分类的其它问题

Using IF-THEN Rules for Classification
使用 IF-THEN 规则分类

- **IF 条件 THEN 结论**
  - E.g., IF (age=youth) AND (student=yes) THEN buys_computer=yes

规则前件 或 前提　　结论



$$R1: (age = youth) \wedge (student = yes) \Rightarrow (buys_computer = yes)$$

- **Assessment: Coverage and Accuracy 覆盖率&准确度**
  - n_{covers} = 规则 R 覆盖的元组数（满足前提的元组数）
  - $n_{correct}$ = 规则 R 正确分类的元组数
  - coverage(R) = n_{covers} /|D| /* D: training data set */
  - accuracy(R) = $n_{correct}$ / n_{covers}

Using IF-THEN Rules for Classification

使用 IF-THEN 规则分类（Cont）

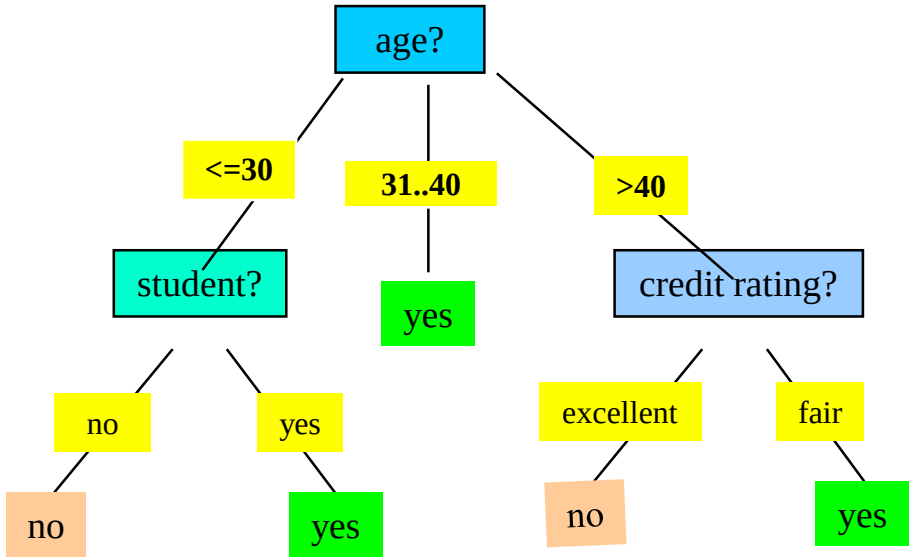
- 如果规则被 ***X*** 满足，则称该规则被 **触发**
- 如果规则 R1 是 **唯一** 满足的规则，则该规则被 **激活**，返回 ***X*** 的类预测

- 如果有 **多个规则** 被触发，则需要解决冲突
  - 如果指向了不同的类怎么办？
    - 规模序：把最高优先权赋予具有最多属性测试（最苛刻）的规则
    - 基于类的规则序：优先级按照普遍性**降序排序**，最普遍（或最频繁）类的所有规则首先出现，次普遍类的规则随后，如此等作为选择。也可以根据每个类的误分类代价排序。每个类中规则是无序的，不存在类冲突
    - 基于规则的规则序：根据准确度、覆盖率等等把规则组织成一个优先权列表（**决策表**）
  - 如果不存在 ***X*** 满足规则的情况？
    - 根据训练集指定一个默认类（默认类的选择视算法而定），可以建立一个省缺或默认规则，根据训练集指定一个默认类。这个类可以是多数类，或者不被任何规则覆盖的元组的多数类。当且仅当没有其他规则覆盖X 时，最后才使用默认规则。默认规则的条件为空。这样，当没有其他规则时该规则被激活

Rule Extraction from a Decision Tree

由决策树提取规则

- IF-THEN规则更容易理解
- 对每条从根到树叶节点的路径创建一个规则
- **E.g., *buys_computer* 决策树**



IF *age* = young AND *student* = *no*
THEN *buys_computer* = *no*

IF *age* = young AND *student* = *yes*
THEN *buys_computer* = *yes*

IF *age* = mid-age
THEN *buys_computer* = *yes*

IF *age* = old AND *credit_rating* = *excellent* THEN *buys_computer* = *no*

IF *age* = old AND *credit_rating* = *fair*
THEN *buys_computer* = *yes*

提取的每个规则之间蕴涵着析取（逻辑OR关系）。这些规则是互斥的和穷举的：互斥意味不可能存在规则冲突，因为没有两个规则被相同的元组触发（每个树叶有一个规则， 并且任何元组都只能映射到一个树叶）；穷举意味对于每种可能的属性- 值组合都存在一个规则，使得该规则集不需要默认规则。规则的序不重要，是无序的

Rule Induction: Sequential Covering Method
使用顺序覆盖算法的规则归纳

- 顺序覆盖算法：直接从训练数据提取IF-THEN规则
  - 不必产生决策树
  - 规则被顺序地学习，一次一个
- 典型的顺序覆盖算法：FOIL,AQ,CN2,RIPPER
- 为C类学习规则时，希望它能够覆盖C类所有（或许多）的训练元组，并且没有（或很少）覆盖其他类的元组
- 步骤：
  - 一次学习一条规则
  - 每学习一个规则，就把该规则覆盖的元组删除
  - 在剩下的元组上重复该过程直到满足终止条件 e.g. 没有更多的训练元组或者返回的规则质量低于用户指定的阈值
- 与决策树归纳做比较：同时学习一组规则

顺序覆盖算法

- **Input:**
  - *D, a data set of class-labeled tuples;*
  - *Att vals, the set of all attributes and their possible values.*
- **Output: A set of IF-THEN rules.**
- **Method:**
  - (1) *Rule set D fg; // initial set of rules learned is empty*
  - (2) for each class *c do*
  - (3) repeat
  - (4) Rule D Learn One Rule(*D, Att vals, c);*
  - (5) remove tuples covered by *Rule from D;*
  - (6) *Rule set D Rule set CRule; // add new rule to rule set*
  - (7) until terminating condition;
  - (8) endfor
  - (9) return *Rule Set ;*

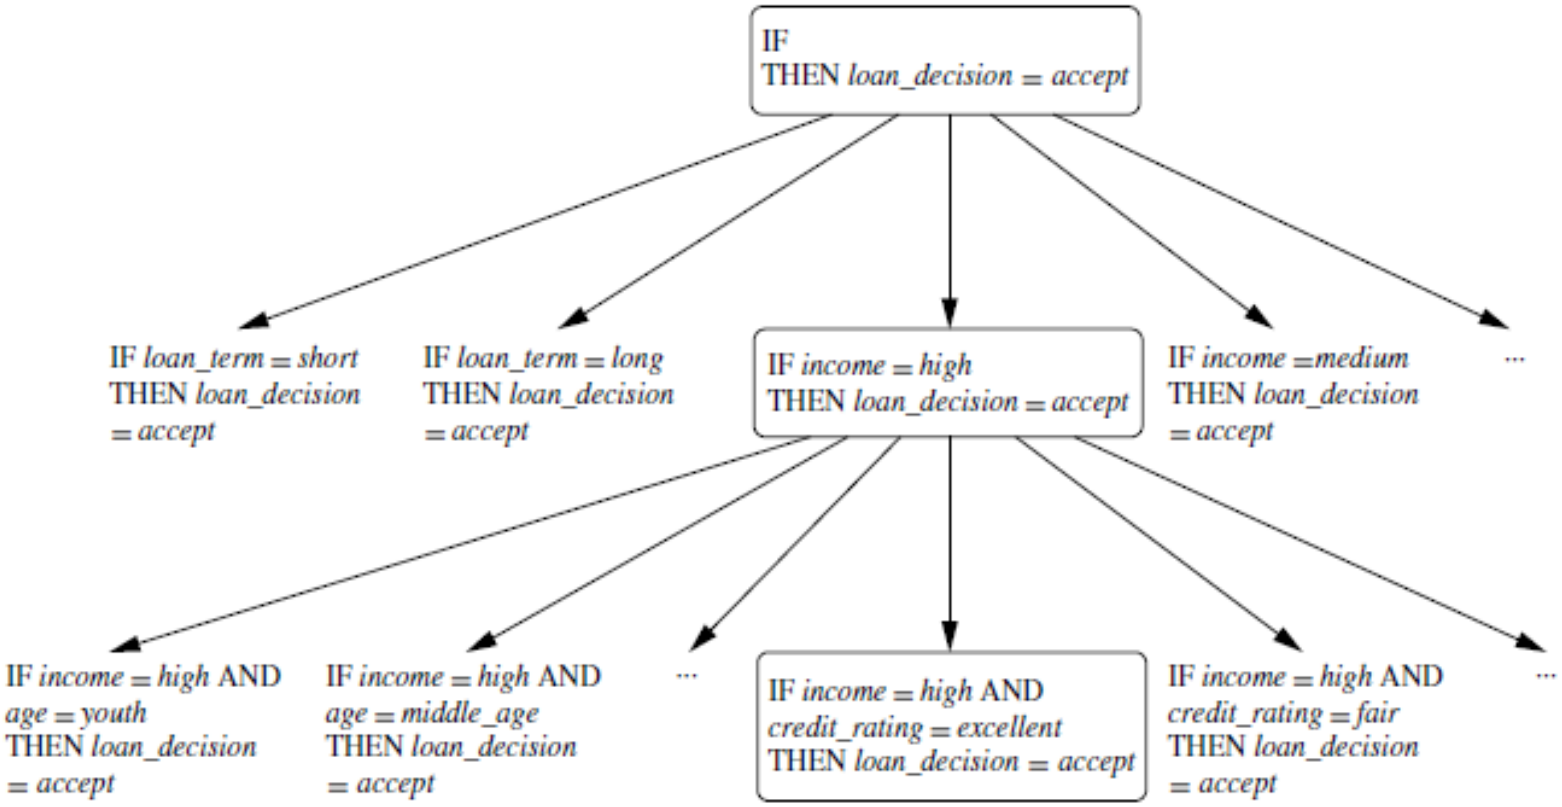
如何学习规则：规则生成

- 从空规则开始，然后逐渐向它添加属性测试
  - 添加的属性测试作为规则前件条件的逻辑合取
- 一个例子：训练集D由贷款申请数据组成：
  - 属性：年龄，收入，文化程度，住处，信誉等级和贷款期限
  - 分类属性：loan_decision（是否接受贷款申请）
- 刚开始的规则为：IF THEN load_decision=accept
- 考虑每个可能的属性测试
  - 对属性-值对(attr, val)考虑attr=val,attr<=val,attr>val
- 缺点：计算昂贵

如何学习规则：规则生成

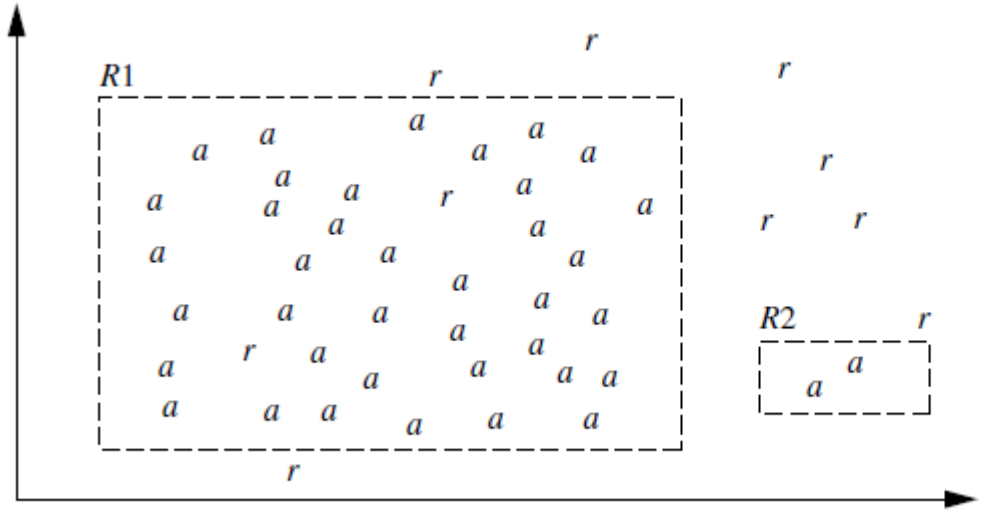
- 可以采用一种贪心的深度优先策略
  - 选择最能提高规则质量属性的测试
  - 质量度量方法：准确率，熵，FOIL中信息增益的度量
  - 每一步继续贪心地增长规则，直到结果规则达到可接受的质量水平

如何学习规则：规则生成


IF
THEN loan_decision = accept
IF loan_term = short
THEN loan_decision
= accept
IF loan_term = long
THEN loan_decision
= accept
IF income = high
THEN loan_decision = accept
IF income =medium
THEN loan_decision
= accept
...
IF income = high AND
age = youth
THEN loan_decision
= accept
IF income = high AND
age = middle_age
THEN loan_decision
= accept
...
IF income = high AND
credit_rating = excellent
THEN loan_decision = accept
IF income = high AND
credit_rating = fair
THEN loan_decision
= accept
...

规则质量度量

- 准确率
  - —该规则正确分类的元组所占的百分比
- 有例外情况
- 如下图所示，两个规则都是loan_decision=accept类的规则



规则 *R*1 正确地对它覆盖的 40 个元组中的 38 个进行了分类。规则 *R*2 只覆盖了 2 个元组，它正确地进行了分类。它们的准确率分别为 95% 和 100%。这样，*R*2 比 *R*1 具有更高的准确率。然而由于小覆盖率，*R*2 不是更好的规则。

规则质量度量

- 当前的规则是R:IF condition THEN class = c
- 新的条件为condition’，R’:IF condition’ THEN class = c
- 想知道R’是否比R更好
- 熵
  - —数据集D的元组分类所需要的期望信息

$$Info(D) = -\sum_{i=1}^{m} p_i \log_2(p_i),$$

- D是condition’覆盖元组的集合，p_i 是D中类 Ci 的概率，熵越小，condition’越好
- 偏向于覆盖单个类大量元组和少量其他元组的条件

规则质量度量 Cont.

- FOIL的基于信息增益的度量
- 在机器学习中，用于学习规则的类的元组称为正元组，其余元组为负元组
- 设pos(neg)为R覆盖的正（负）元组数，pos’(neg’)为R’覆盖的正（负）元组数
- 用下式估计扩展condition’而获得的信息

$$FOIL_Gain = pos' \times \left(\log_2 \frac{pos'}{pos' + neg'} - log_2 \frac{pos}{pos + neg} \right).$$

- 偏向于具有高准确率并且覆盖许多正元组的规则

规则剪枝

- 上面介绍的规则评估规则使用原训练数据集：
  - —乐观的，过分拟合
  - —训练数据上性能好，以后的数据上就不那么好
- 为了补偿，通过删除一个属性测试对规则剪枝
- 如果在独立的元组集上评估，R剪枝后的版本有着更高的质量，那么选择对规则R剪枝
  - —悲观剪枝
- FOIL中使用的方法

$$FOIL_Prune(R) = \frac{pos - neg}{pos + neg},$$

- 剪枝后FOIL_Prune值较高，就对R剪枝
- RIPPER从最近添加的合取项开始

Chapter 7 Classification 分类
7-2：Adanced Methods 高级方法

Rule-Based Classification	基于规则的分类
Bayes Classification Methods	**贝叶斯分类(ML课程)**
Bayesian Belief Networks	贝叶斯信念网络
Classification by Backpropagation	用后向传播分类(ML课程)
Support Vector Machines	支持向量机(ML课程)
Classification Using Frequent Patterns	使用频繁模式分类
Lazy Learners	惰性学习法(ML课程)
(or Learning from Your Neighbors)	（或从近邻学习）
Other Classification Methods	其他分类方法
Ensemble Learning	集成分类法
Additional Topics Regarding Classification	关于分类的其它问题

贝叶斯分类方法：为什么？

- **一个统计学的分类方法**
  - 预测类隶属关系的概率
  - 一个给定的元组属于一个特定类的概率

- 基础：**贝叶斯定理**

- **有效性：**与决策树和神经网络等多种分类法的对比实验表明，在某些领域，贝叶斯分类法足以与它们相媲美

- **标准：**贝叶斯分类可以用来为不直接使用贝叶斯定理的其他分类方法提供理论判定

贝叶斯定理：基础

- 朴素贝叶斯分类算法和贝叶斯信念网络分类算法都是建立在贝叶斯定理基础上
- 基本概念
  - 设X是类标签未知的数据样本
    - X: 一位35岁、收入4万美元的顾客
  - 设H为某种假设，如数据元组X属于某个特定类C
    - H: 顾客将购买计算机
  - P(H)（先验概率）：假设H的先验概率
    - 任意给定顾客将购买计算机的概率，不管年龄、收入或其他任何信息
  - P(H|X)（假设H的后验概率）：给定一个观察数据样本X，假设成立的概率
    - 反映知道顾客的年龄和收入时，顾客 X 将买计算机的概率
  - P(X)（先验概率）:样本数据X的先验概率
    - 顾客集合中35岁、收入4万美元的概率
  - P(X|H)（样本X的后验概率）:在给定假设H的前提条件下，样本X的后验概率
    - 已知顾客购买计算机，那么该顾客35岁且收入4万美元的概率

贝叶斯定理：基础

- 贝叶斯定理
  - —假设X和Y是一对随机变量
  - —联合概率P(X=x,Y=y)是指X取x且Y取值y的概率
  - —条件概率是指一随机变量在另一随机变量取值已知的情况下取某一特定值得概率
    - P(Y=y|X=x)是指在变量X取值x的情况下，变量Y取值y的概率
  - —X和Y的联合概率和条件概率满足

$$P(X,Y)=P(Y\mid X)P(X)=P(X\mid Y)P(Y)\Rightarrow P(Y\mid X)=\frac{P(X\mid Y)}{P(X)}P(Y)$$

- 对应样本X和假设H，根据贝叶斯定理，满足如下关系

$$P(H\mid \mathbf{X})=\frac{P(\mathbf{X}\mid H)P(H)}{P(\mathbf{X})}=P(\mathbf{X}\mid H)\times P(H)/P(\mathbf{X})$$

- 贝叶斯定理是在H和X的先验概率、X的后验概率已知的情况下，计算H后验概率的方法，分类取决于 P(H|X)（H的后验概率）

朴素贝叶斯分类的概念

- 设D是训练元组和他们相关联的类标号的集合，每个元组用一个n维属性向量X= (x1, x2, …, xn)，假设有m个类C1, C2, …, Cm

- 分类法将预测X属于具有 **最高后验概率** 的类，即 P(Ci|X)的最大值

  P(Ci|X)> P(Cj|X)(j!=i , 1<=j<=m)

- 根据贝叶斯定理，由于P(X)对于所有类为常数，所以只要P(X|Ci)P(Ci) 最大即可

$$P(Ci|\mathbf{X}) = \frac{P(X|Ci)P(Ci)}{P(\mathbf{X})} = P(X|Ci) \times P(Ci) / P(\mathbf{X})$$

- 类的先验概率可以用P(Ci)=|Ci,D|/|D|估计，|Ci,D|是D中Ci类的训练元组数

- 如果P(Ci)未知，那么假设这些类等概率，只要 P(X|Ci) 最大即可

朴素贝叶斯分类的概念Cont.

- 计算 P(X|Ci) 开销可能非常大
- 为降低计算P(X|Ci) 开销，做简单假设 —— 属性有条件的相互独立（属性之间不存在依赖关系），则：

$$P(\mathbf{X}|C_i) = \prod_{k=1}^{n} P(x_k|C_i) = P(x_1|C_i) \times P(x_2|C_i) \times ... \times P(x_n|C_i)$$

- 其中x_k表示元组X在属性A_k的值
- 如果A_k是分类属性， $P(x_k|Ci)$ 是D中属性A_k的值为X_k的Ci类的元组数除以Ci类的元组数$|C_{i,D}|$

朴素贝叶斯分类：一个例子

Class:

C1:buys_computer = ‘yes’

C2:buys_computer = ‘no’

Data to be classified:

X = (

age <=30,

Income = medium,

Student = yes

Credit_rating = Fair

)

age	income	student	credit_rating	_com
<=30	high	no	fair	no
<=30	high	no	excellent	no
31…40	high	no	fair	yes
>40	medium	no	fair	yes
>40	low	yes	fair	yes
>40	low	yes	excellent	no
31…40	low	yes	excellent	yes
<=30	medium	no	fair	no
<=30	low	yes	fair	yes
>40	medium	yes	fair	yes
<=30	medium	yes	excellent	yes
31…40	medium	no	excellent	yes
31…40	high	yes	fair	yes
>40	medium	no	excellent	no

朴素贝叶斯分类：一个例子

- $P(C_i)$: P(buys_computer = “yes”) = 9/14 = 0.643
  P(buys_computer = “no”) = 5/14= 0.357
- Compute $P(X|C_i)$ for each class
  P(age = “<=30” | buys_computer = “yes”) = 2/9 = 0.222
  P(age = “<= 30” | buys_computer = “no”) = 3/5 = 0.6
  P(income = “medium” | buys_computer = “yes”) = 4/9 = 0.444
  P(income = “medium” | buys_computer = “no”) = 2/5 = 0.4
  P(student = “yes” | buys_computer = “yes) = 6/9 = 0.667
  P(student = “yes” | buys_computer = “no”) = 1/5 = 0.2
  P(credit_rating = “fair” | buys_computer = “yes”) = 6/9 = 0.667
  P(credit_rating = “fair” | buys_computer = “no”) = 2/5 = 0.4

- X = (age <= 30 , income = medium, student = yes, credit_rating = fair)

$P(X|C_i)$: P(X|buys_computer = “yes”) = 0.222 x 0.444 x 0.667 x 0.667 = 0.044
P(X|buys_computer = “no”) = 0.6 x 0.4 x 0.2 x 0.4 = 0.019

$P(X|C_i)*P(C_i)$: P(X|buys_computer = “yes”) * P(buys_computer = “yes”) = 0.028
P(X|buys_computer = “no”) * P(buys_computer = “no”) = 0.007

Therefore, X belongs to class (“buys_computer = yes”)

朴素贝叶斯分类：小作业

outlook	temperature	humidity	wind	play ball
sunny	hot	high	weak	no
sunny	hot	high	strong	no
overcast	hot	high	weak	yes
rain	mild	high	weak	yes
rain	cool	normal	weak	yes
rain	cool	normal	strong	no
overcast	cool	normal	strong	yes
sunny	mild	high	weak	no
sunny	cool	normal	weak	yes
rain	mild	normal	weak	yes
sunny	mild	normal	strong	yes
overcast	mild	high	strong	yes
overcast	hot	normal	weak	yes
rain	mild	high	strong	no

{outlook,temperature,humidity,wind}

X={rain，hot，normal，weak，？}

朴素贝叶斯分类的概念Cont.

- 如果A_k是连续值属性，可以用两种方法估计连续属性的类条件概率
- 方法一
  - 可以将每个连续的属性离散化，然后用相应的离散区间替换连续属性值。把连续属性转换为序数属性，通过计算类Ci的训练样本中落入x_k对应区间的比例来估计条件概率$P(x_k|Ci)$
  - 估计误差由离散策略和离散区间的数目决定：如果离散区间的数目太大，则会因为每个区间中训练样本太少而不能对$P(x_k|Ci)$ 做出可靠的估计；如果区间数目太小，有些区间可能会包含来自不同类的样本，因此会失去正确的决策边界
- 方法二
  - 可以假设连续变量服从某种概率分布，然后使用训练样本估计分布的参数
  - 正态分布通常被用来表示连续属性的类条件概率分布，分布有均值和方差（数据集中属于Ci类的样本属性Ak的平均值和方差），类别Ci下属性x_k的类条件概率近似为

$$P(\mathbf{X}|C_i) \approx g(x_k, \mu_{C_i}, \sigma_{C_i}) \qquad g(x, \mu_{Ci}, \sigma_{Ci}) = \frac{1}{\sqrt{2\pi}\sigma_{Ci}} e^{-\frac{(x-\mu_{Ci})^2}{2\sigma_{Ci}^2}}$$

朴素贝叶斯分类的算法基本描述

- 函数名：NaïveBayes
- 输入：类标号未知的样本X={x1,x2,…,xn}
- 输出：未知样本X所属的类标号
- (1)for j=1 to m
- (2)　计算X属于每个类别Cj的概率

$$P(\mathbf{X}|C_j)=\prod_{k=1}^{n}P(x_k|C_j)=P(x_1|C_j)\times P(x_2|C_j)\times\ldots\times P(x_n|C_j)$$

- (3)　计算训练集中每个类别的概率P(Cj)
- (4)　计算概率值 μ = P(X|Cj) * P(Cj)
- End for
- 选择计算概率值 μ 最大的Ci（1<=i<=m）做为类别的输出

$$P(Ci|\mathbf{X})=\frac{P(X|Ci)P(Ci)}{P(\mathbf{X})}=P(X|Ci)\times P(Ci)/P(\mathbf{X})$$

朴素贝叶斯分类：避免零概率值问题

- **如果某个$P(x_k|Ci)$为零概率值，那么P(X|Ci)的值将返回零**
  - 一个零概率将消除乘积中涉及的（Ci上）所有其他（后验）概率的影响
- 解决方法
  - 有一个简单的技巧来避免该问题。可以假定训练数据库D很大，以至于对每个计数加1造成的估计概率的变化可以忽略不计，但可以方便地避免概率值为零。这种概率估计技术称为拉普拉斯校准或拉普拉斯估计法，以法国数学家皮埃尔·拉普拉斯（Pierre Laplace,1749—1827年）的名字命名
  - 如果对q个计数加上1，则必须记住在用于计算概率的对应分母上加上q
- **例：假设一个数据集有1000个元组**
  - **income=low(0),income=medium(990),income=high(10)**
  - **使用拉布拉斯校准**
    - **假定训练数据库D很大，以至于对每个计数加1造成的估计概率的变化可以忽略不计**
    - **Prob(income = low) = 1/1003**
    - **Prob(income = medium) = 991/1003**
    - **Prob(income = high) = 11/1003**
  - **校准的概率估计对应未校准的估计很接近**

贝叶斯分类的优缺点

优点：

- 计算速度最快的演算法
- 规则清楚易懂
- 独立事件的假设，大多数问题上不至于发生太大偏误；

缺点：

- 仅适用于类别变量
- 仅能应用于分类问题
- 假设变量间为独立互不影响，因此使用时需要谨慎分析变量间的相关性

基于贝叶斯定理的分类器模型

- **朴素贝叶斯（Naïve Bayes，NB）分类器**
  - 贝叶斯分类器中最简单有效的，并且在在实际使用中较为成功的一种分类器。其性能可以与神经网络、决策树分类器相比，在某些场合优于其他分类器。朴素贝叶斯分类器的特征是假定每个属性的取值对给定类的影响独立于其他属性的取值，即给定类变量的条件下各属性变量之间条件独立
- **树扩展的朴素贝叶斯（Tree-Augmented Naïve Bayes, TANB）**
  - 在朴素贝叶斯分类器的基础上，在属性之间添加连接弧，在一定程度上消除朴素贝叶斯分类器的条件独立性假设，这样的弧称为扩展弧，说明树形约束
- ***BAN （Bayesian network-Augmented Naïve Bayes）***
  - 一种增强的朴素贝叶斯分类器，改进了朴素贝叶斯分类器的条件独立假设，并且取消了TANB分类器中属性变量之间必须符合树状结构的要求，假定属性之间存在贝叶斯网络关系而不是树状关系，从而能够表达属性变量的各种依赖关系
- **贝叶斯多网（Bayesian Muti-Net，BMN）分类器**
  - TANB和BAN的一个扩展， TANB和BAN分类器认为对不同的类别，各属性变量之间的关系是不变的，即对于不同的类别具有相同的网络结构。而BMN认为对类变量的不同取值，各属性变量之间的关系可能是不一样的
- **GBN分类器（General Bayesian Network）**
  - 如果抛弃条件独立假设，就可以用一般贝叶斯网络作为分类器。GBN是一种无约束的贝叶斯网络分类器，与前面4类贝叶斯分类器不同的，前面4类分类器都将类变量作为一个特殊节点，类节点在网络结构中是各个属性的父节点，而GBN将类节点作为一个普通节点

Chapter 7 Classification 分类
7-2：Adanced Methods 高级方法

- Rule-Based Classification 基于规则的分类
- Bayes Classification Methods 贝叶斯分类(ML课程)
- Bayesian Belief Networks 贝叶斯信念网络
- **Classification by Backpropagation 用后向传播分类(ML课程)**
- Support Vector Machines 支持向量机(ML课程)
- Classification Using Frequent Patterns 使用频繁模式分类
- Lazy Learners 惰性学习法(ML课程)
- (or Learning from Your Neighbors) （或从近邻学习）
- Other Classification Methods 其他分类方法
- Ensemble Learning 集成分类法
- Additional Topics Regarding Classification 关于分类的其它问题



用后向传播分类

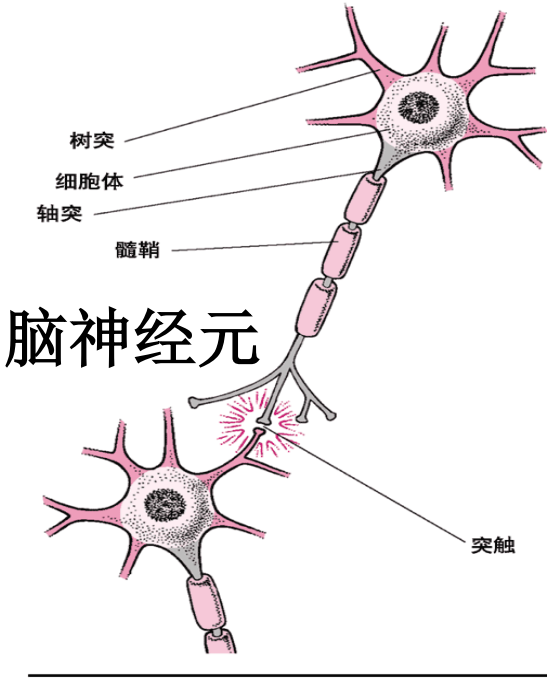
分类算法——神经网络　提纲

- 1、神经网络
- 2、BP网络学习算法
- 3、BP网络学习算例
- 4、后向传播和可解释性
- 5、BP神经网络算法的MATLAB实现

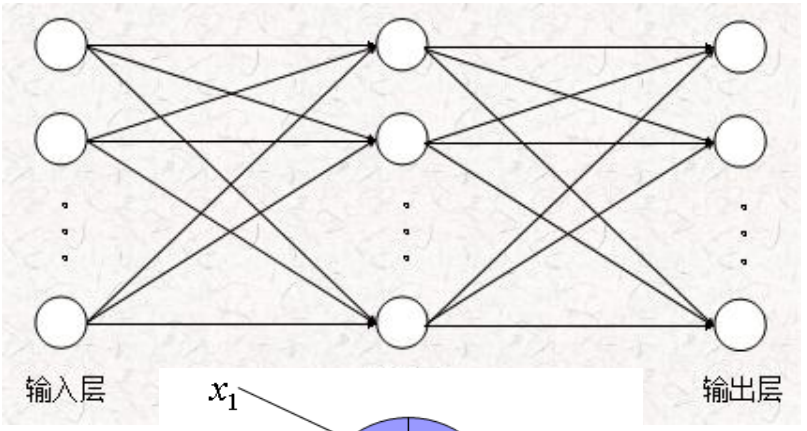
基本概念

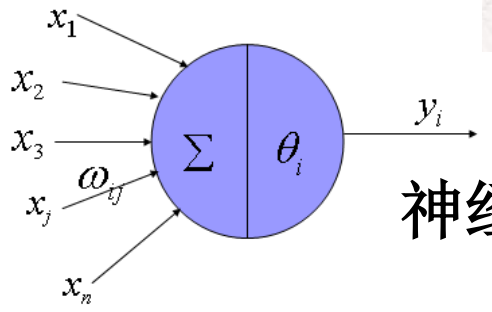
- 神经网络最早是由心理学家和神经学家提出的，旨在寻求开发和测试神经的计算模拟
- 神经网络是模拟人脑思维方式的数学模型，是在现代生物学研究人脑组织成果的基础上提出的，用来模拟人类大脑神经网络的结构和行为，反映了人脑功能的基本特征，如并行信息处理、学习、联想、模式分类、记忆等
- 简单地说，神经网络是一组连接的输入/ 输出单元，其中每个连接都与一个权重相关联。在学习阶段，通过调整这些权重，能够正确预测输入样本的类标号





脑神经元

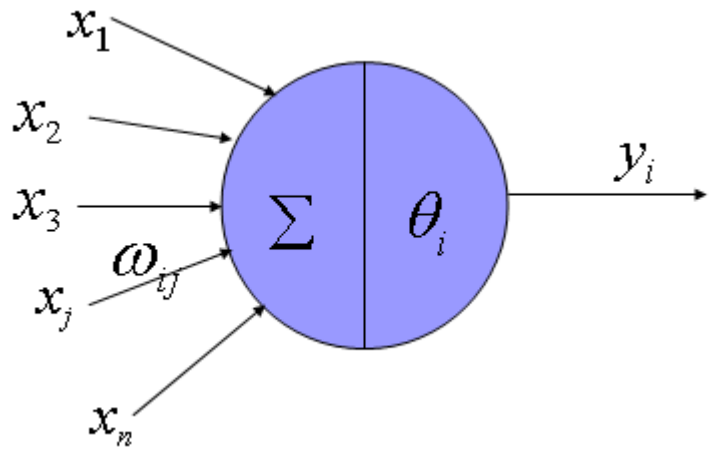




神经节点

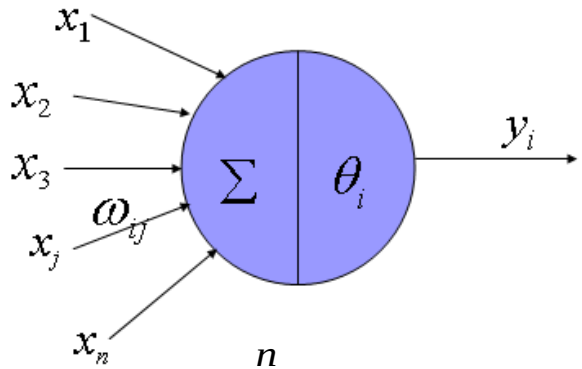
什么是阈值？

- 临界值
  - 比如有一头驴，往它身上压稻草，一根一根地压，当压到N根时，还没有被压倒，又压了一根，倒了，这时所有压在驴身上的稻草的多少，就是压倒这头驴的阈值
- 神经网络是模仿大脑的神经元，当外界刺激达到一定的阀值时，神经元才会受刺激，影响下一个神经元



什么是阈值？

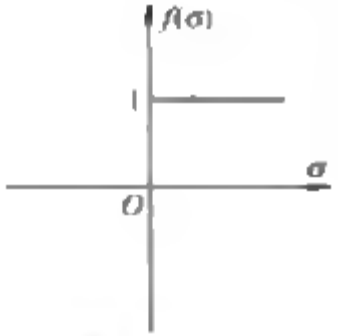
判断 $\sum_{j=1}^{n} x_j \omega_{ij}$ 是否大于阀值 θ_i



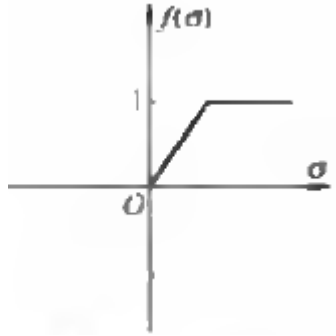
- 若 $\sum_{j=1}^{n} x_j \omega_{ij}$ 大于阀值 θ_i，则此神经元接受此信息，输出y=f($\sum_{j=1}^{n} x_j \omega_{ij}$)
- 若 $\sum_{j=1}^{n} x_j \omega_{ij}$ 小于阀值 θ_i，则此神经元不接受此信息的传递

传递函数

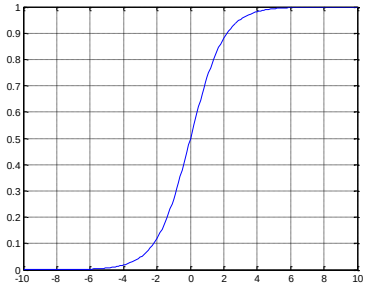
阈值型 $$f(x)=\begin{cases}1 & x_i \geq 0\\ 0 & x_i < 0\end{cases}$$



线性型 $$f(x_i)=\begin{cases}1 & x_i \geq x_2\\ ax_i+b & x_1 \leq x_i < x_2\\ 0 & x_i < x_1\end{cases}$$



S型 $$f(x_i)=\frac{1}{1+e^{(-\frac{x_i}{c})^2}}$$



人工神经网络的功能

历史数据

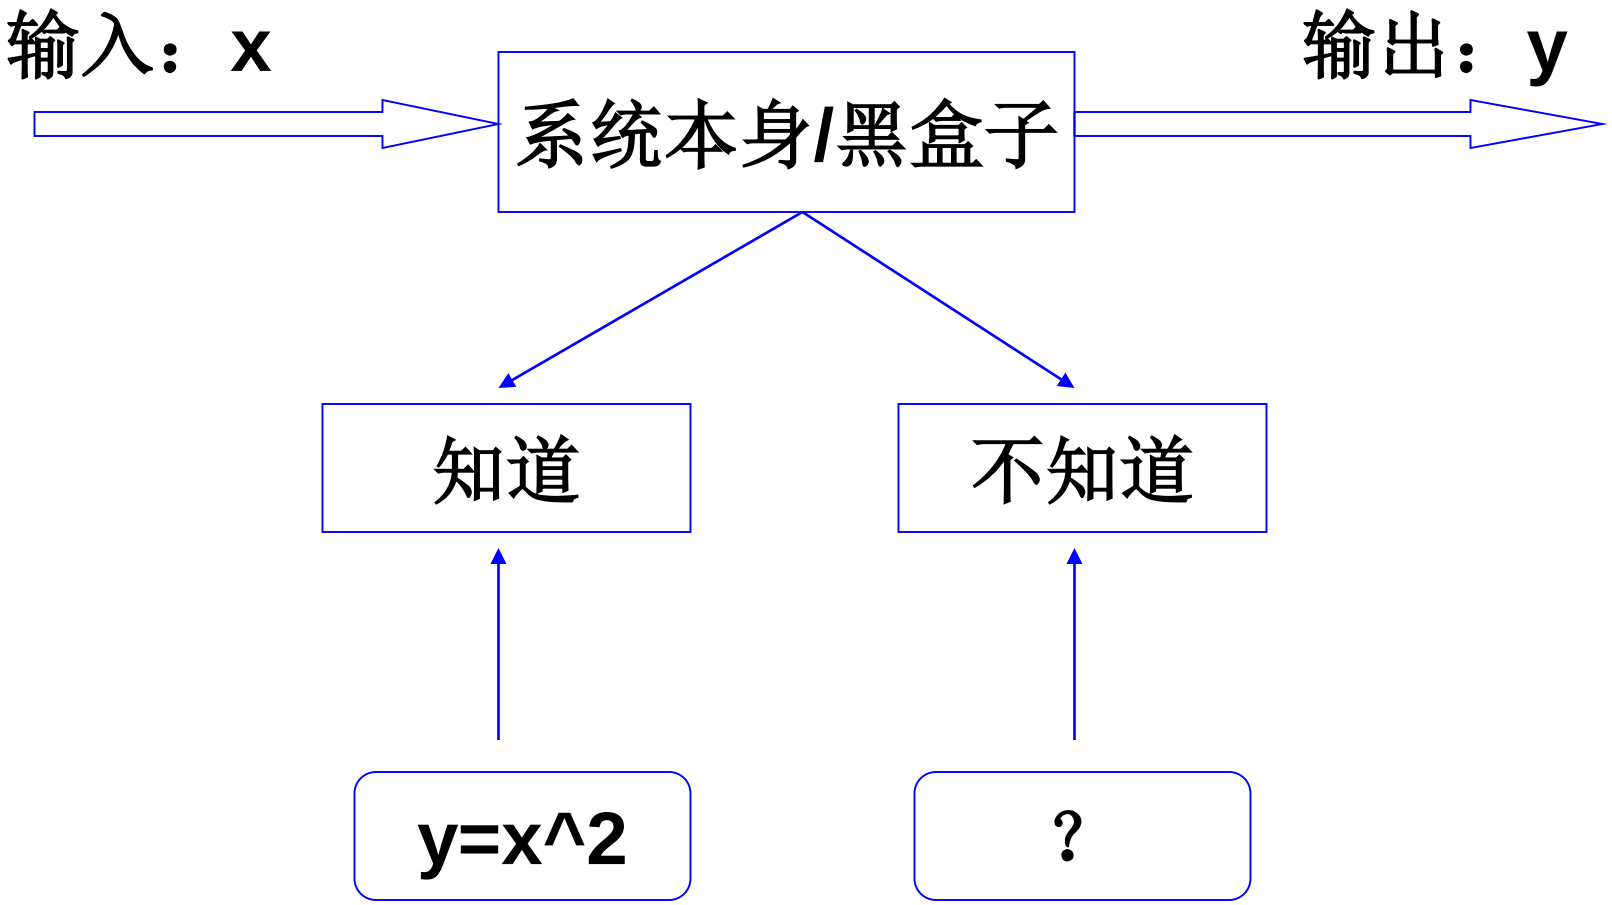
公称内径 d mm		2组		0组		3组		4组		5组	
超过	到	min	max	min	max	min	max	min	max	min	max
18	24	15	25	25	35	35	45	45	60	60	75
24	30	20	30	30	40	40	55	55	75	75	95
30	40	25	35	35	50	50	65	65	85	85	105
40	50	30	45	45	60	60	80	80	100	100	130
50	65	40	55	55	75	75	95	95	120	120	160
65	80	50	70	70	95	95	120	120	150	150	200
80	100	55	80	80	110	110	140	140	180	180	230
100	120	65	100	100	135	135	170	170	220	220	280
120	140	80	120	120	160	160	200	200	260	260	330
140	160	90	130	130	180	180	230	230	300	300	380
160	180	100	140	140	200	200	260	260	340	340	430
180	200	110	160	160	220	220	290	290	370	370	470
200	225	120	180	180	250	250	320	320	410	410	520
225	250	140	200	200	270	270	350	350	450	450	570
250	280	150	220	220	300	300	390	390	490	490	620
280	315	170	240	240	330	330	430	430	540	540	680
315	355	190	270	270	360	360	470	470	590	590	740
355	400	210	300	300	400	400	520	520	650	650	820
400	450	230	330	330	440	440	570	570	720	720	910
450	500	260	370	370	490	490	630	630	790	790	1000
500	560	290	410	410	540	540	680	680	870	870	1100
560	630	320	460	460	600	600	760	760	980	980	1230
630	710	350	510	510	670	670	850	850	1090	1090	1360
710	800	390	570	570	750	750	960	960	1220	1220	1500
800	900	440	640	640	840	840	1070	1070	1370	1370	1690
900	1000	490	710	710	930	930	1190	1190	1520	1520	1860



预测

分类




输入：x
输出：y
系统本身/黑盒子
知道
不知道
y=x^2
?

神经网络模型的类型

- 神经网络模型的性能主要取决于以下因素
  - —神经元（信息处理单元）的特性
  - —神经元之间相互连接的形式（拓扑结构）
  - —为适应环境而改善性能的学习规则
- 目前已经由40多种神经网络模型
  - —单层前向神经网络——线性网络
  - —阶跃网络
  - —多层前向神经网络（BP神经网络）
  - —Elman网络、Hopfield网络、双向联想记忆网络、自组织竞争网络……

神经网络能干什么？

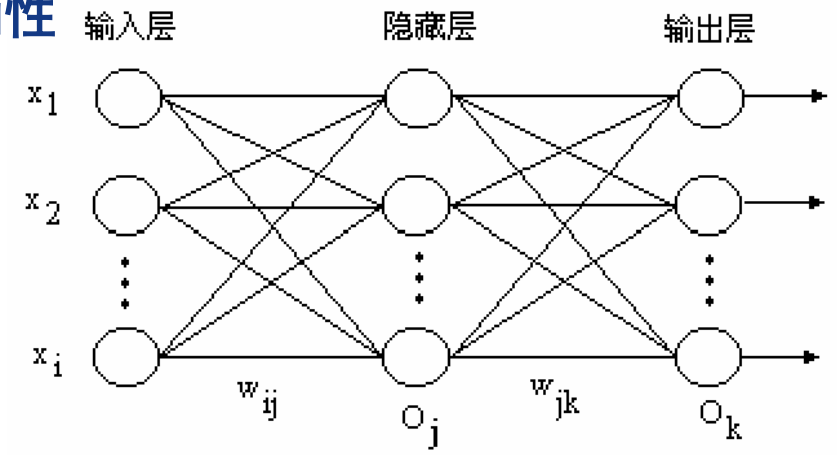
- 运用这些网络模型可实现
  - —函数逼近
  - —数据聚类
  - —模式分类
  - —优化计算……等功能
- 神经网络广泛应用于
  - —人工智能
  - —自动控制
  - —机器人
  - —统计学……等领域的信息处理中
- 虽然神经网络的应用很广,但是在具体的使用过程中到底应当选择哪种网络结构比较合适是值得考虑的。这就需要对各种神经网络结构有一个较全面的认识

分类算法——神经网络　提纲

- 1、神经网络
- 2、BP网络学习算法
- 3、BP网络学习算例
- 4、后向传播和可解释性
- 5、BP神经网络算法的MATLAB实现

多层前馈神经网络——定义网络拓扑

- 在开始训练之前，用户必须确定网络拓扑
  - —输入层的单元数
  - —隐藏层数（如果多于一层）
  - —每一隐藏层的单元数
  - —输出层的单元数
- 对训练样本中每个属性的值进行规格化，将有助于加快学习过程
  - —通常，对输入值规格化，使得它们落入 0.0 和1.0 之间
- 对于最好的隐藏层单元数，没有明确的规则
  - —网络设计是一个实验过程，并可能影响训练结果网络的准确性
  - —权的初值也可能影响结果的准确性

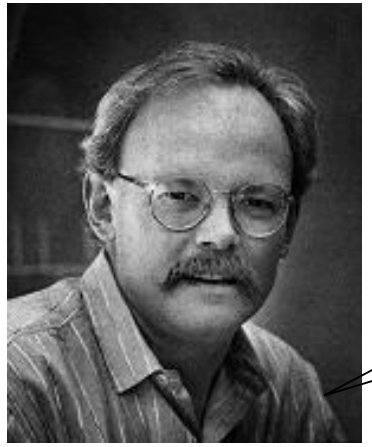


误差后向传播模型学习算法

1985年，Rumelhart和McClelland提出了误差后向传播模型学习算法(Back—Propagation Network，简称BP网络)，BP网络是目前应用最广泛的神经网络学习模型之一



David Rumelhart

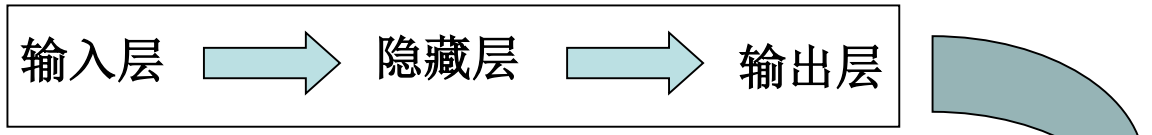


J. McClelland

BP学习算法

误差后向传播模型学习算法(Back—Propagation Network，简称BP网络)

正向传播：



误差的反向传播：



BP算法是一种有监督式的学习算法

其主要思想是：输入学习样本，使用反向传播算法对网络的权值和偏差进行反复的调整训练，使输出的向量与期望向量尽可能地接近，当网络输出层的误差平方和小于指定的误差时训练完成，保存网络的权值和偏差

BP网络学习算法

- 学习的过程
  - —神经网络在外界输入样本的刺激下不断改变网络的连接权值，以使网络的输出不断地接近期望的输出
  - —信号的正向传播 ⟹ 误差的反向传播
- 学习的本质
  - —对各连接权值的动态调整
- 学习的规则
  - —权值调整规则，即在学习过程中网络中各神经元的连接权变化所依据的一定的调整规则。

BP网络的学习算法——学习过程

- 正向传播：
  - —输入样本－－输入层－－各隐层－－输出层
- 判断是否转入反向传播阶段
  - —若输出层的实际输出与期望的输出不符
- 误差反传
  - —误差以某种形式在各层表示－修正各层单元的权值

- 网络输出的误差减少到可接受的程度
  进行到预先设定的学习次数为止

BP网络的学习算法——学习步骤

- 算法：后向传播。使用后向传播算法，分类或预测的神经网络学习。
- 输入：训练样本 D，学习率 l，多层前馈网络 network。
- 输出：训练后的神经网络。
- 方法：
- 1) 初始化 network 的权重和偏倚。
- 2) while 终止条件不满足 {
- 3) for D中的每个训练样本 X {
- 4) // 向前传播输入
- 5) for 每个输入层单元 j {
- 6) $O_j=I_j$； //输入单元的输出是它的实际输入值
- 7) for 隐藏或输出层每个单元 j {
- 8) // 关于前一层 i，计算单元 j 的净输入 $I_j=\sum w_{ij}O_i+\theta_j$
- 9) $O_j= 1/(1+e^{I_j})$ // 计算单元 j 的输出
- 10) // 后向传播误差
- 11) for 输出层每个单元 j
- 12) $Err_j=O_j(1-O_j)(T_j-O_j)$ // 计算误差
- 13) for 由最后一个到第一个隐藏层，对于隐藏层每个单元 j
- 14) $Err_j=O_j(1-O_j)$ //计算关于下一个较高层 k 的误差 $\sum_k Err_k w_{jk}$
- 15) for networ中每个权 w_{ij} {
- 16) $\Delta w_{ij}=(l)\ Err_j O_i$ // 权重增量
- 17) $w_{ij} = w_{ij}+ \Delta w_{ij}$ // 权重更新
- 18) for networ中每个偏倚θ_j {
- 19) $\Delta\theta_j=(l)Err_j$ // 偏倚增量
- 20) $\theta_j=\theta_j+\Delta\theta_j$ // 偏倚更新
- 21) }}

BP网络的学习算法——学习步骤

(1)初始化权重：网络的权被初始化为很小的随机数（例如，由-1.0 到 1.0，或由-0.5 到 0.5）

— 每个单元有一个偏置

每个样本 X按以下步骤处理

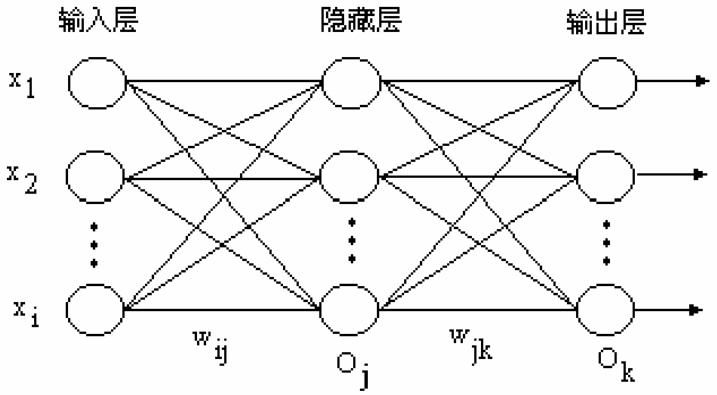
(2)向前传播输入：训练样本提供给网络的输入层，然后计算各层的输出：

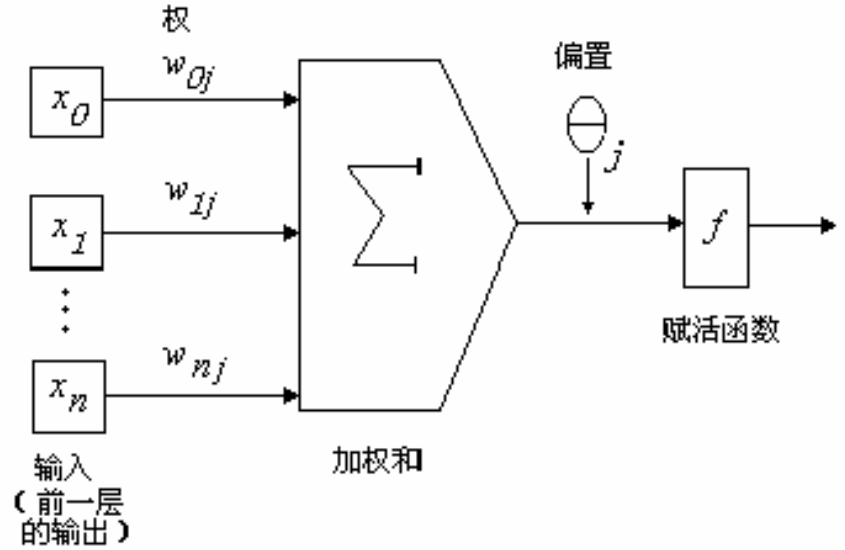
— 对于输入层的单元 ：它的输出等于它的输入

— 对于隐藏层和输出层的净输入：等于连接该单元的每个输入乘以其对应的权，然后加上偏倚

$$I_j = \sum_i w_{ij} O_i + \theta_j$$

— 输出：使用S型函数，$O_j = \dfrac{1}{1+e^{-I_j}}$

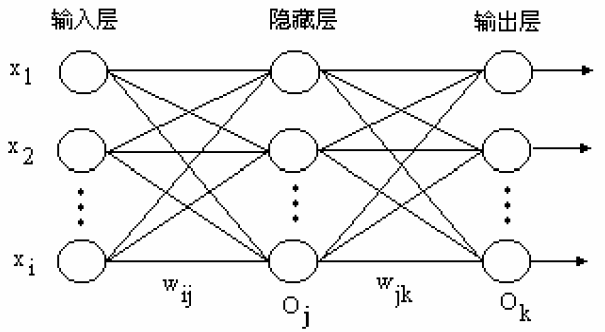




BP网络的学习算法——学习步骤

(3)后向传播误差：通过更新权重和反映网络预测误差的偏倚，向后传播误差。

- 对于**输出层单元** j的误差 Err_j用下式计算：
  - $Err_j=O_j(1-O_j)(T_j-O_j)$
  - 其中，O_j是单元 j 的实际输出，而 T_j是 j 基于给定训练元组的已知目标值
- 对于**隐藏层单元** j 的误差为：
  - $Err_j=O_j(1-O_j)\sum_k Err_k w_{jk}$



  - 其中，w_{kj}是由下一较高层中单元 k到单元 j 的连接权，而 Err_k是单元 k的误差。

BP网络的学习算法——学习步骤

- 更新权重和偏倚，反映传播的误差，权重由下式更新
  - $\Delta w_{ij}=(l)\ Err_j O_i \quad w_{ij} = w_{ij} + \Delta w_{ij}$
  - 其中：Δw_{ij}是权重w_{ij}的改变，变量 l 是学习率，通常取 0 和1 之间的值。这些权值可以对给定的分类问题建模，使得样本的网络类预测和实际的类标号距离平方的平均值最小
- 学习率帮助避免陷入判定空间的局部最小（即权值看上去收敛，但不是最优解），并有助于找到全局最小
  - 如果学习率太小，学习将进行得很慢。如果学习率太大，可能出现在不适当的解之间摆动。

BP网络的学习算法-学习步骤

- **偏倚**由下式更新
  - —$\Delta\theta_j=(l)Err_j$
  - —$\theta_j=\theta_j+\Delta\theta_j$
  - —其中，$\Delta\theta_j$是偏倚θ_j的改变
- **终止条件**
  - —(1)前一周期所有的Δw_{ij}都小于某个指定的阈值
  - —(2)前一周期未正确分类的样本百分比小于某个阈值
  - —(3)超过预先指定的周期数

分类算法——神经网络　提纲

- 1、多层前馈神经网络
- 2、BP网络学习算法
- 3、BP网络学习算例
- 4、后向传播和可解释性
- 5、BP神经网络算法的MATLAB实现

BP网络学习算例

- **例** 通过后向传播算法学习的样本计算

  —图给出了一个多层前馈神经网络

  - 设学习率为 0.9
  - 该网络的初始权值和偏倚值以及第一个训练样本 X = {1,0,1}（其类标号为 1）在表中给出

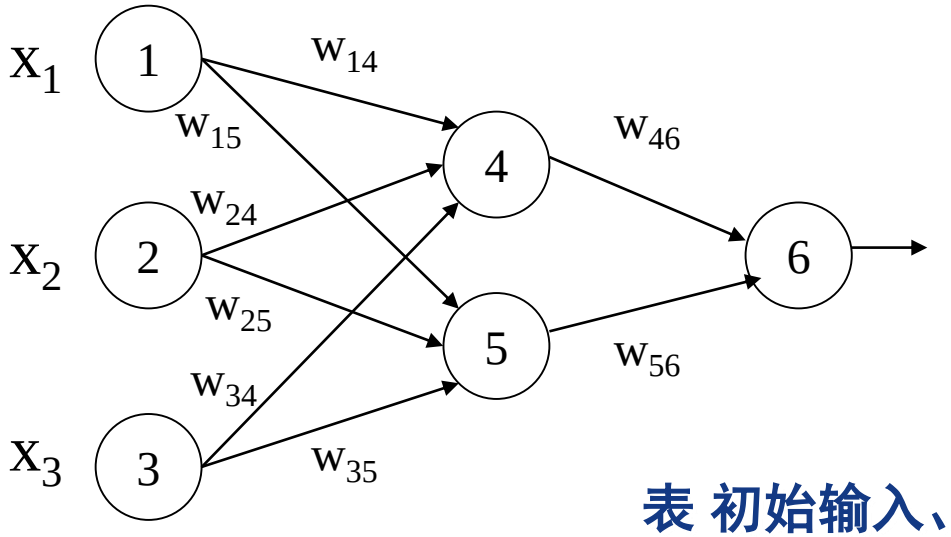


表 初始输入、权值和偏倚值

x_1	x_2	x_3	w_{14}	w_{15}	w_{24}	w_{25}	w_{34}	w_{35}	w_{46}	w_{56}	θ_4	θ_5	θ_6
1	0	1	0.2	-0.3	0.4	0.1	-0.5	0.2	-0.3	-0.2	-0.4	0.2	0.1

表1 初始输入、权值和偏倚值

x_1	x_2	x_3	w_{14}	w_{15}	w_{24}	w_{25}	w_{34}	w_{35}	w_{46}	w_{56}	θ_4	θ_5	θ_6
1	0	1	0.2	-0.3	0.4	0.1	-0.5	0.2	-0.3	-0.2	-0.4	0.2	0.1

表2 净输入和输出的计算表

单元j	净输入I_j	输出O_j
4	0.2+0-0.5-0.4=-0.7	$1/(1+e^{0.7})=0.332$
5	-0.3+0+0.2+0.2=0.1	$1/(1+e^{-0.1})=0.525$
6	(-0.3)(0.332)-(0.2)(0.525)+0.1=-0.105	$1/(1+e^{0.105})=0.474$

$$I_j = \sum_i w_{ij} O_i + \theta_j$$

$$\frac{1}{1+e^{-Ij}}$$

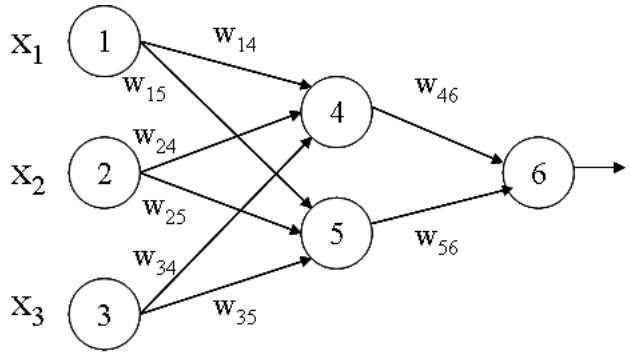


表3 计算每个节点的误差表

单元j	Err_j
6	(0.474)(1-0.474)(1-0.474)=0.1311
5	(0.525)(1-0.525)(0.1311)(-0.2)=-0.0065
4	(0.332)(1-0.332)(0.1311)(-0.3)=-0.0087

Errj=Oj(1-Oj)(Tj-Oj)

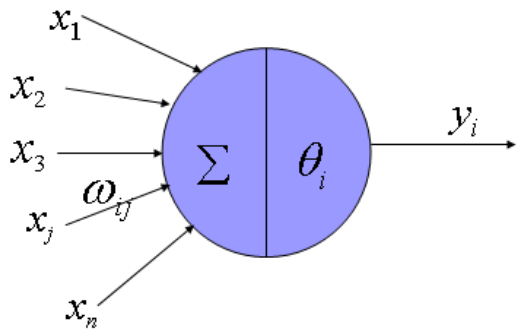
$Err_j=O_j(1-O_j)\sum_k Err_k w_{jk}$

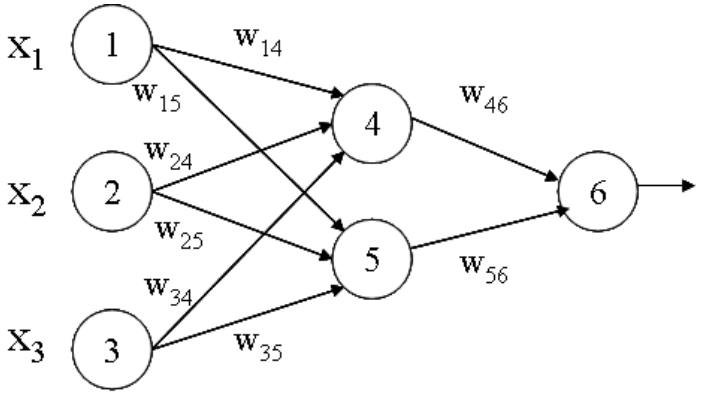
表4计算权重和偏倚的更新

权重或偏倚	新值
w_{46}	-0.3+ (0.9)(0.1311)(0.332)=-0.261
w_{56}	-0.2+(0.9)(0.1311)(0.525)=-0.138
w_{14}	0.2 + (0.9)(-0.0087)(1) = 0.192
W_{15}	-0.3+(0.9)(0.0065)(1)= -0.306
W_{24}	0.4+(0.9)(-0.0087)(0)=0.4
W_{25}	0.1+(0.9)(-0.0065)(0)= 0.1
W_{34}	-0.5+(0.9)(-0.0087)(1)=-0.508
W_{35}	0.2+(0.9)(-0.0065)(1)=0.194
θ_6	0.1+(0.9)(0.1311)=0.218
θ_5	0.2+(0.9)(-0.0065)=0.194
θ_4	-0.4+(0.9)(-0.0087)=-0.408

$\Delta wij=(l)\ ErrjOi \qquad wij = wij+\Delta wij$

$\Delta\theta j=(l)Errj \quad \theta j= \theta j+ \Delta\theta j$





分类算法——神经网络　提纲

- 1、多层前馈神经网络
- 2、BP网络学习算法
- 3、BP网络学习算例
- 4、后向传播和可解释性
- 5、BP神经网络算法的MATLAB实现

后向传播和可解释性

- 神经网络是一个黑盒
  - —神经网络的主要缺点是知识的表示
    - 用加权链连接单元网络表示的知识难以理解
- 如何提取隐藏在训练后的神经网络中的知识及象征性地表示这些知识
  - —解决方法

(1) 网络提取规则

1) 网络剪枝，神经元和连接的数目会大大地减少

2) 通过进行链、单元或活跃值的聚类在网络中提取规则，以得到表达明确的分类规则

(2) 灵敏度分析

用户评估一个给定输入变量对网络输出影响，改变该变量的输入而其它变量固定，监测网络输出的改变

识别每个隐藏结点 H_i的公共活跃值集合：

H_1: (-1,0,1)

H_2: (0,1)

H_3: (-1,0.24,1)

导出与输出结点 O_j的公共活跃值相关的规则：

IF ($H_2 = 0$ AND $H_3 = -1$) OR

($H_1 = -1$ AND $H_2 = 1$ AND $H_3 = -1$) OR

($H_1 = -1$ AND $H_2 = 0$ AND $H_3 = 0.24$)

THEN $O_1 = 1$, $O_2 = 0$

ELSE $O_1 = 0$, $O_2 = 1$

导出与输入节点 I_i到输出结点O_j相关的规则：

IF ($I_2 = 0$ AND $I_7 = 0$) THEN $H_2 = 0$

IF ($I_4 = 1$ AND $I_6 = 1$) THEN $H_3 = -1$

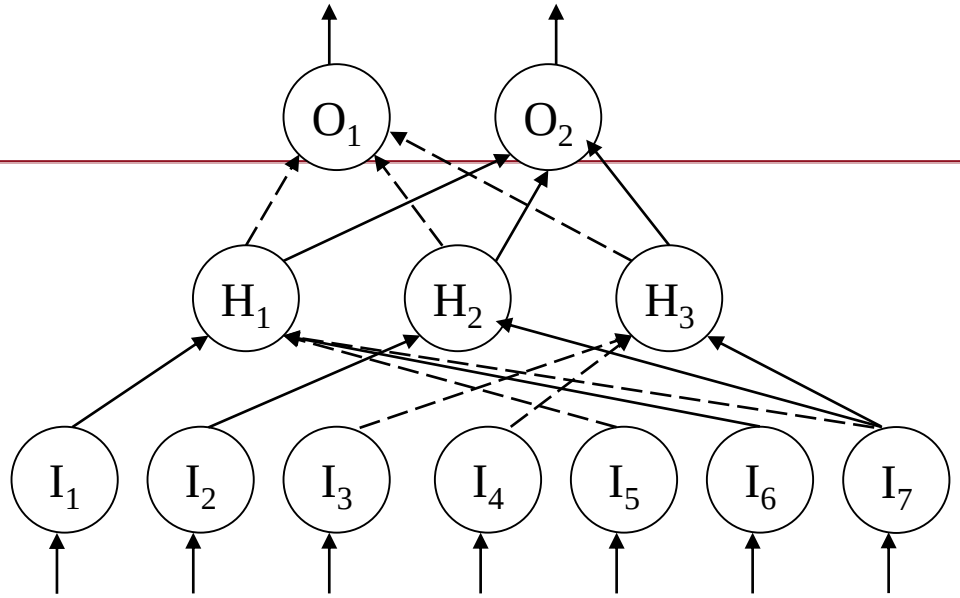
IF ($I_5 = 0$) THEN $H_3 = -1$

得到关于输入和输出类的规则：

IF ($I_2 = 0$ AND $I_7 = 0$ AND $I_4 = 1$ AND $I_6 = 1$)

THEN class=1 $O_1 = 1$, $O_2 = 0$

IF ($I_2 = 0$ AND $I_7 = 0$ AND $I_5 = 0$) THEN class = 1



H_1	H_2	H_3	O_1	O_2
-1	1	-1	0.92	0.08
-1	1	1	0.00	1.00
-1	1	0.24	0.01	0.99
-1	0	-1	1.00	0.00
-1	0	1	0.11	0.89
-1	0	0.24	0.93	0.07
1	1	-1	0.00	1.00
1	1	1	0.00	1.00
1	1	0.24	0.00	1.00
1	0	-1	0.89	0.11
1	0	1	0.00	1.00
1	0	0.24	0.00	1.00
0	1	-1	0.18	0.82
0	1	1	0.00	1.00
0	1	0.24	0.00	1.00
0	0	-1	1.00	0.00
0	0	1	0.00	1.00
0	0	0.24	0.18	0.82

小结

1、算法是由两部分组成

—信息的正向传递

—误差的反向传播

2、网络的输入输出关系是各层连接的权因子决定，权因子是通过学习信号调节的，这样学习越多，网络越聪明

3、隐含层越多，网络输出精度越高，且个别权因子的损坏不会对网络输出产生大的影响

4、反向传播网络的结构不完全受所要解决问题的限制

—网络的输入神经元数目及输出层神经元的数目是由问题的要求所决定

— 隐含层数以及每层的神经元数是由设计者来决定的

Chapter 7 Classification 分类
7-2：Adanced Methods 高级方法

Rule-Based Classification	基于规则的分类
Bayes Classification Methods	贝叶斯分类(ML课程)
Bayesian Belief Networks	贝叶斯信念网络
Classification by Backpropagation	用后向传播分类(ML课程)
Support Vector Machines	**支持向量机(ML课程)**
Classification Using Frequent Patterns	使用频繁模式分类
Lazy Learners	惰性学习法(ML课程)
(or Learning from Your Neighbors)	（或从近邻学习）
Other Classification Methods	其他分类方法
Ensemble Learning	集成分类法
Additional Topics Regarding Classification	关于分类的其它问题

支持向量机SVM简介

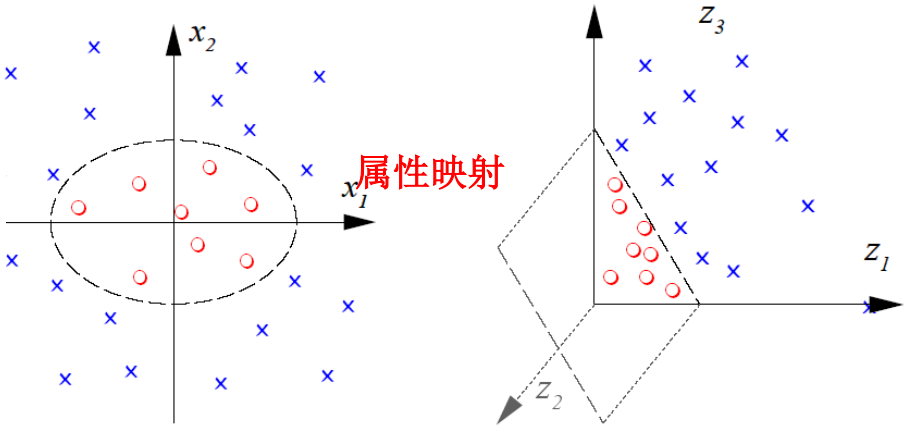
- 支持向量机(Support Vector Machine)是贝尔实验室研究者Vapnik等于1995年首先提出的，它在解决小样本、非线性及高维模式识别中表现出许多特有优势，并能够推广应用到其他机器学习问题中。
- SVM方法是建立在统计学习理论的VC 维理论和结构风险最小原理基础上的，根据有限的样本信息在模型的复杂性（即对特定训练样本的学习精度）和学习能力（即无错误地识别任意样本的能力）之间寻求最佳折衷，以期获得最好的推广能力。
- SVM发展史虽短，但其理论研究和算法实现方面却都取得突破性进展，这一切与SVM有较完备的统计学习理论基础的发展背景是密不可分的。



基于SVM的分类算法概念模型

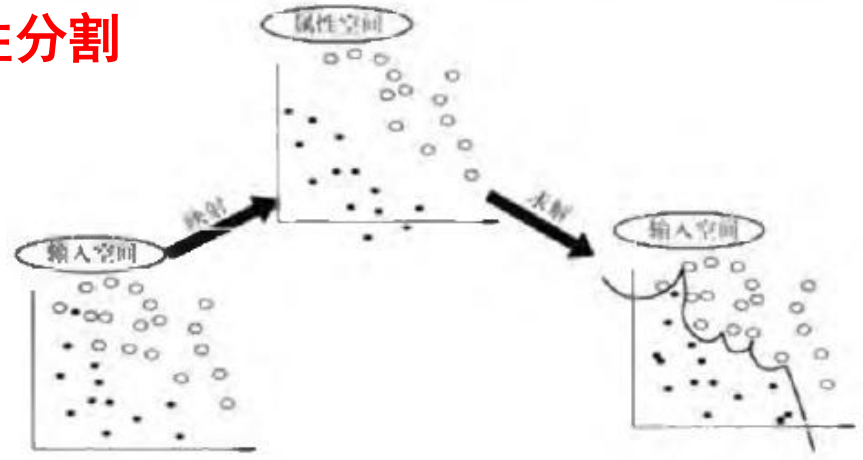
- 非线性映射（核函数）将输入空间映射到高维特征空间

$$\Phi : \mathbb{R}^2 \to \mathbb{R}^3$$
$$(x_1, x_2) \mapsto (z_1, z_2, z_3) := (x_1^2, \sqrt{2}\, x_1 x_2, x_2^2)$$



- 基于SVM的分类算法概念模型

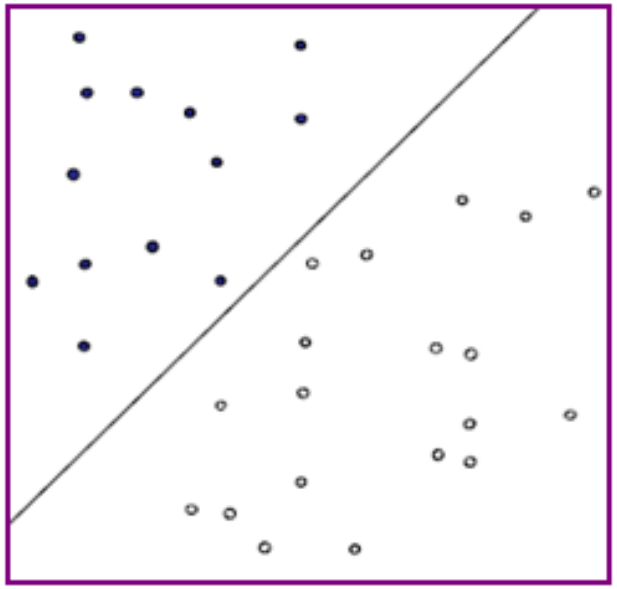
—通过预先选定的非线性映射将输入空间映射到高维特征空间，使得在高维属性空间中有可能对训练数据实现超平面分割，避免在原输入空间进行非线性分割



支持向量机的基本概念

- 如果一个线性函数能够将样本完全正确的分开，就称这些数据是线性可分的，否则称为非线性可分的。
- 如果不关注函数空间的维数，这种线性函数还有一个统一的名称，叫超平面（**Hyper Plane**）。
- 称由线性函数作为分类决策函数的分类器叫线性分类器。
- 称由非线性函数作为分类决策函数分类器叫非线性分类器。
- 由线性函数作为分类决策函数的支持向量机称为线性支持向量机。
- 由非线性函数作为分类决策函数的支持向量机称为非线性支持向量机。

支持向量机的基本原理



设两类问题训练样本集为(x_1,y_1), $(x_2,y_2),\ldots,(x_n,y_n)$,其中$x_i \in R^n$, $y_i=\{1,-1\}$, $i=1,\ldots,n$

线性可分是指存在着超平面（Hyper–plane）直线f(x) = *wx* + b，使得训练样本中的一类输入和另一类输入分别位于该超平面的两侧。

这种线性分类函数在一维空间里就是一个点，在二维空间里就是一条直线，三维空间里就是一个平面，可以如此想象下去，如果不关注空间的维数，这种线性函数还有一个统一的名称——超平面（Hyper Plane）！

分类算法——支持向量机　提纲

- 支持向量机基础
- 支持向量机的基本原理
- 算例
- 支持向量机的算法实现
- 算法总结

总结

- 最大间隔——VC维
- 软间隔——训练错误
- 点积——核函数
- 凸二次规划——全局最优解

主要应用领域

- 手写数字识别(银行票据系统，邮件分拣系统)
- 语音识别
- 人脸识别
- 文本分类

SVM与神经网络NN的对比

- SVM的理论基础比NN更坚实，更像一门严谨的“科学”（三要素：问题的表示、问题的解决、证明）

- SVM —— 严格的数学推理
- NN —— 强烈依赖于工程技巧

- 推广能力取决于“经验风险值”和“置信范围值”，NN不能控制两者中的任何一个。
- NN设计者用高超的工程技巧弥补了数学上的缺陷——设计特殊的结构，利用启发式算法，有时能得到出人意料的好结果。

SVM与神经网络NN的对比

“我们必须从一开始就澄清一个观点，就是如果某事不是科学，它并不一定不好。比如说，爱情就不是科学。因此，如果我们说某事不是科学，并不是说它有什么不对，而只是说它不是科学。”

—— *by R. Feynman*

from *The Feynman Lectures on Physics*, Addison-Wesley

同理，与SVM相比，NN不像一门科学，更像一门工程技巧，但并不意味它就一定不好！

Chapter 7 Classification 分类
7-2：Adanced Methods 高级方法

Rule-Based Classification	基于规则的分类
Bayes Classification Methods	贝叶斯分类(ML课程)
Bayesian Belief Networks	贝叶斯信念网络
Classification by Backpropagation	用后向传播分类(ML课程)
Support Vector Machines	支持向量机(ML课程)
Classification Using Frequent Patterns	**使用频繁模式分类**
Lazy Learners	惰性学习法(ML课程)
(or Learning from Your Neighbors)	（或从近邻学习）
Other Classification Methods	其他分类方法
Ensemble Learning	集成分类法
Additional Topics Regarding Classification	关于分类的其它问题

频繁模式挖掘或频繁项集挖掘

- 频繁模式（frequent pattern）
  - —显示频繁地出现在给定数据集中的属性—值对之间的有趣联系
  - —把每个属性—值对看做一个项，搜索这种频繁模式称做频繁模式挖掘或频繁项集挖掘
  - —见第6 章和第7 章，如何由频繁模式导出关联规则，那里关联通常用于分析顾客在商店的购买模式
  - —这种分析可以用于许多决策过程，如产品布局、分类设计和交叉购物

把频繁模式用于分类

- 可以把频繁模式用于分类

  —关联分类

  - 关联规则由频繁模式产生并用于分类
  - 基本思想是可以搜索频繁模式（属性—值对的合取）与类标号之间的强关联

  —基于有区别力的频繁模式分类

  - 在构建分类模型时，频繁模式充当组合特征，可以看做是对单个特征的补充
  - 由于频繁模式考察多个属性之间高置信度关联，因此基于频繁模式的分类可能克服决策树归纳一次只考虑一个属性的限制。研究表明，许多基于频繁模式的分类方法比诸如C4.5等传统的分类方法更准确、更可伸缩。

Chapter 7 Classification 分类
7-2：Adanced Methods 高级方法

Rule-Based Classification	基于规则的分类
Bayes Classification Methods	贝叶斯分类(ML课程)
Bayesian Belief Networks	贝叶斯信念网络
Classification by Backpropagation	用后向传播分类(ML课程)
Support Vector Machines	支持向量机(ML课程)
Classification Using Frequent Patterns	使用频繁模式分类
Lazy Learners	**惰性学习法(ML课程)**
(or Learning from Your Neighbors)	**（或从近邻学习）**
Other Classification Methods	其他分类方法
Ensemble Learning	集成分类法
Additional Topics Regarding Classification	关于分类的其它问题

惰性学习法（或从近邻学习）

- 决策树归纳、贝叶斯分类、基于规则的分类、后向传播分类、支持向量机和基于关联规则挖掘的分类等分类方法都是**急切学习法**的例子。
  - 当给定训练元组集，**急切学习法（eager learner）**在接收待分类新元组（如检验元组〕之前就构造泛化模型（即分类模型〉
  - 认为学习后的模型已经就绪，并急于对先前未见过的元组进行分类
- 相反，**惰性方法**
  - 学习程序直到对给定的检验元组分类之前的一刻才构造模型。也就是说，当给定一个训练元组时，**惰性学习法（lazy learner）**简单地存储它（或只是稍加处理），并且一直等待，直到给定一个检验元组。仅当看到检验元组时，它才进行泛化，以便根据与存储的训练元组的相似性对该元组进行分类。
  - 不像急切学习方法，惰性学习法在提供训练元组时只做少量工作，而在进行分类或数值预测时做更多的工作。
  - 由于惰性学习法存储训练元组或“ 实例” ，它们也称**基于实例的学习法（ininstance-based leaner）**，尽管所有的学习本质上都是基于实例的。

惰性学习法的特点

缺点

- 计算开销可能相当大。它们需要有效的存储技术，并且非常适合在并行硬件上实现。
- 它们不提供多少解释或对数据结构的洞察。

优点：

- 天生地支持增量学习
- 也能对具有超多边形形状的复杂决策空间建模，这些可能不太容易被其他学习算法描述（如被决策树建模的超矩形形状）

典型的惰性学习法介绍

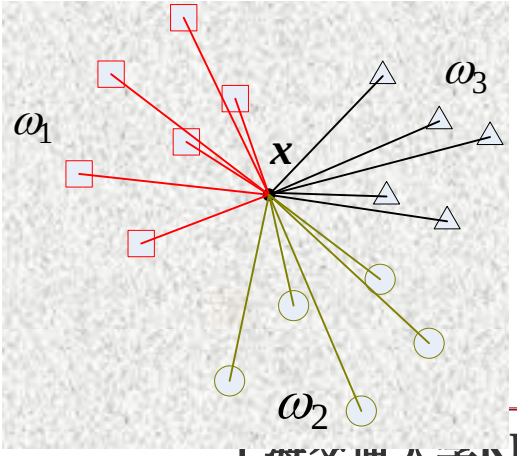
- K-最近邻分类（k-nearest-neighbor classifier，KNN）
- 基于案例的推理（Cased-Based Reasoning，CBR）

K-最近邻分类（k-nearest-neighbor classifier）

- K-最近邻方法是20世纪50年代早期首次引进的。当给定大量数据集时，该方法是计算密集的，直到20世纪60年代计算能力大大增强之后才流行起来。
- k-最近邻分类法是基于类比学习，即通过将给定的检验元组与和它相似的训练元组进行比较来学习
  - 训练元组用n个属件描述，每个元组代表n维空间的一个点。这样，所有的训练元组都存放在n维模式空间中
  - 当给定一个未知元组时，k-最近邻分类法搜索模式空间，找出最接近未知元组的k个训练元组，这k个训练元组是未知元组的k个“ 最近邻”
- 对于最近邻分类，未知元组被指派到它的k个最近邻中的多数类
  - 当k = 1 时，未知元组被指派到模式空间中最接近它的训练元组所在的类
- 最近邻分类也可以用于数值预测

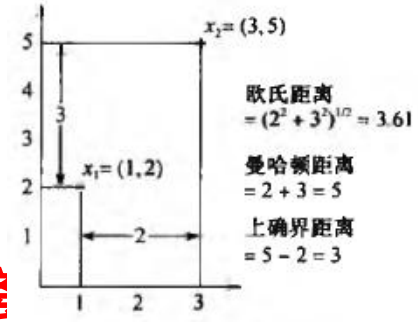
  即返回给定未知元组的实数值预测

  在这种情况下，分类器返回未知元组的k个最近邻的实数值标号的平均值



数值属性的相异性

- 计算数值属性刻画的对象之间相异性的距离度量：
  - —欧几里得距离
  - —曼哈顿距离
  - —闵可夫斯基距离



- （加权）欧几里得距离（直线或“乌鸦飞行”距离

$$d(i,j) = \sqrt{(x_{i1} - x_{j1})^2 + (x_{i2} - x_{j2})^2 + (x_{i3} - x_{j3})^2 + \cdots + (x_{ip} - x_{jp})^2}$$

$$d(i,j) = \sqrt{w_1 |x_{i1} - x_{j1}|^2 + w_2 |x_{i2} - x_{j2}|^2 + \cdots + w_p |x_{ip} - x_{jp}|^2}$$

  - —其中 $i = (x_{i1}, x_{i2}, x_{i3}, \ldots, x_{ip})$ $j = (x_{j1}, x_{j2}, x_{j3}, \ldots, x_{jp})$ 是被p个数值属性描述的两个对象

- 曼哈顿距离（城市两点之间的街区距离）
  - —如，向南2 个街区，横过3 个街区，共计5 个街区

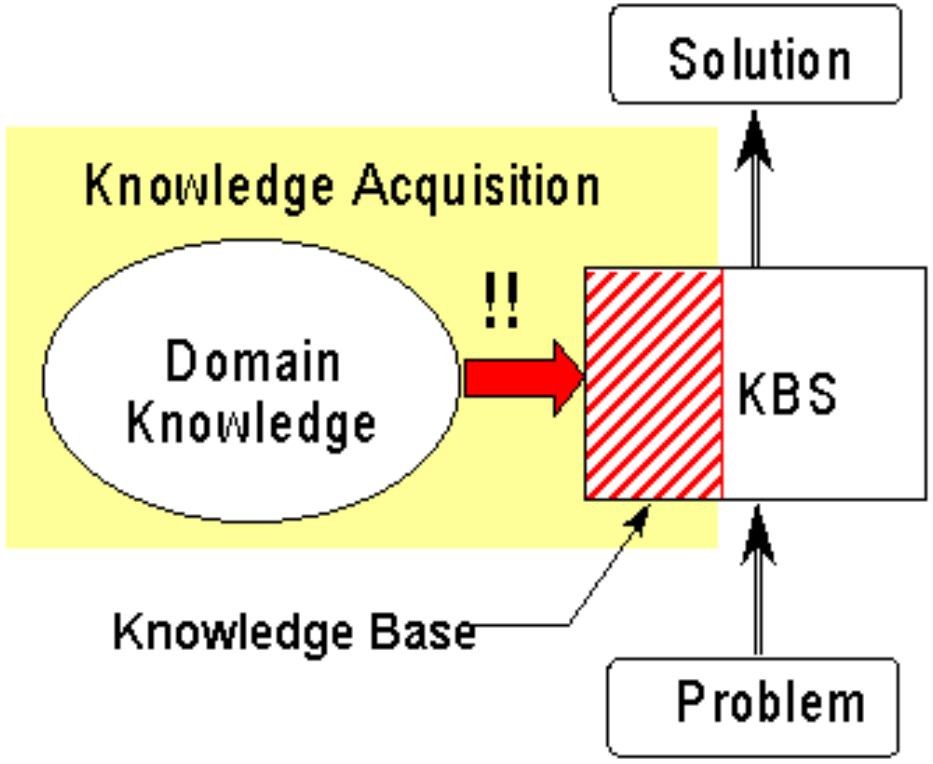
$$d(i,j) = |x_{i1} - x_{j1}| + |x_{i2} - x_{j2}| + \cdots + |x_{ip} - x_{jp}|$$

“邻近性”度量的关键问题

- 如何计算被下述属性或属性组合刻画的对象的相异性？
  - —数值属性
  - —标称属性
  - —二元属性
  - —序数属性
  - —这些属性类型组合
- 如何处理缺失值？
- 如何确定最近邻数k的值？
- 如何考虑不同属性的权重？
- 如何加快最近邻分类的速度？
- 如何比较评价KNN与其它分类方法？

典型的惰性学习法介绍

- K-最近邻分类（k-nearest-neighbor classifier，KNN）
- 基于案例的推理（Cased-Based Reasoning，CBR）



基于案例的推理（Cased-Based Reasoning）

- CBR使用一个存放问题解的数据库来求解新问题
  - 最近邻分类法把训练元组作为欧氏空间的点存储
  - CBR 把问题解决方案的元组或“ 案例” 作为复杂的符号描述存储
- CBR的商务应用包括
  - 顾客服务台问题求解，其中案例描述关于产品的问题诊断
  - 工程和法律领域，其中案例分别是技术设计和法律裁决
  - 医学教育领域，其中患者病史和治疗方案用来帮助诊断和治疗新患者
- CBR的求解原理
  - 当给定一个待分类的新案例时，基于案例的推理首先检查是否存在一个同样的训练案例。从概念上讲，这些训练案例可以视为新案例的近邻
    - 如果找到一个，则返回附在该案例上的解。
  - CBR试图组合近邻训练案例的解，为新案例提出一个解决方案
    - 如果找不到同样的案例，则CBR搜索具有类似于新案例成分的训练案例。如果案例用图表示，则这涉及搜索类似于新案例的子图。
    - 基于案例的推理可以使用背景知识和问题求解策略，以便提出可行的组合解。
  - 如果各解之间出现不相容，则可能需要回溯，搜索其他解

基于案例的推理（Cased-Based Reasoning）

- 基于案例的推理存在的挑战

—找到一个好的相似性度量（例如，为了匹配子图）和组合解的合适方法

—为索引训练案例选择显著的特征和开发有效的索引技术

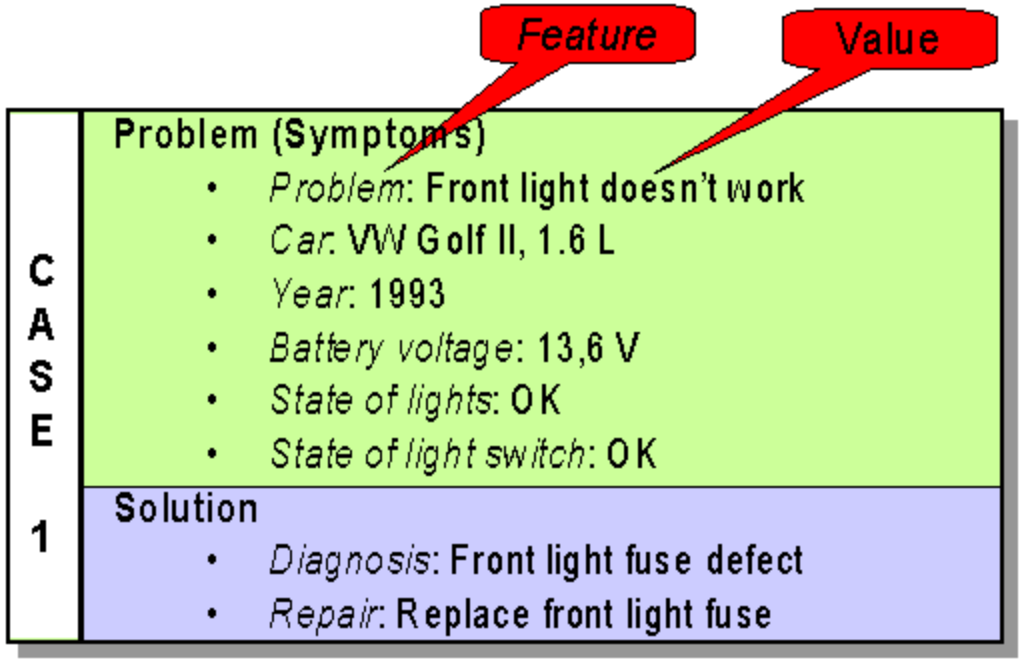
—准确性和有效性之间的折中

  - 随着案例数增加，CBR变得更智能。然而，到达某一点之后，系统的有效性将随着搜索和处理相关案例所需要时间增加而受损
  - 与最近邻分类一样，一种解决方案是编辑训练数据库。为了提高性能，可以丢弃冗余的或未被证明有用的案例。然而，这些决策并非轮廓鲜明的，它们的自动处理仍然是一个活跃的研究领域

CBR例

A Simple Example: What's a Case ?

- A case describes one particular diagnostic situation
- A case records several features and their specific values occurred in that situation
- A case is not a rule !!



Chapter 7 Classification 分类
7-2：Adanced Methods 高级方法

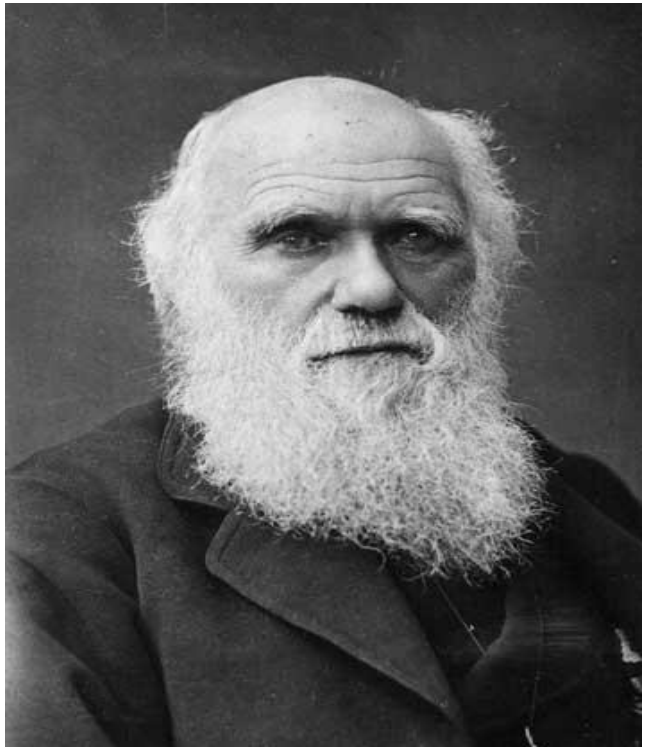
- Rule-Based Classification 基于规则的分类
- Bayes Classification Methods 贝叶斯分类(ML课程)
- Bayesian Belief Networks 贝叶斯信念网络
- Classification by Backpropagation 用后向传播分类(ML课程)
- Support Vector Machines 支持向量机(ML课程)
- Classification Using Frequent Patterns 使用频繁模式分类
- Lazy Learners 惰性学习法(ML课程)
- (or Learning from Your Neighbors) （或从近邻学习）
- **Other Classification Methods 其他分类方法**
- Ensemble Learning 集成分类法
- Additional Topics Regarding Classification 关于分类的其它问题

其它分类方法

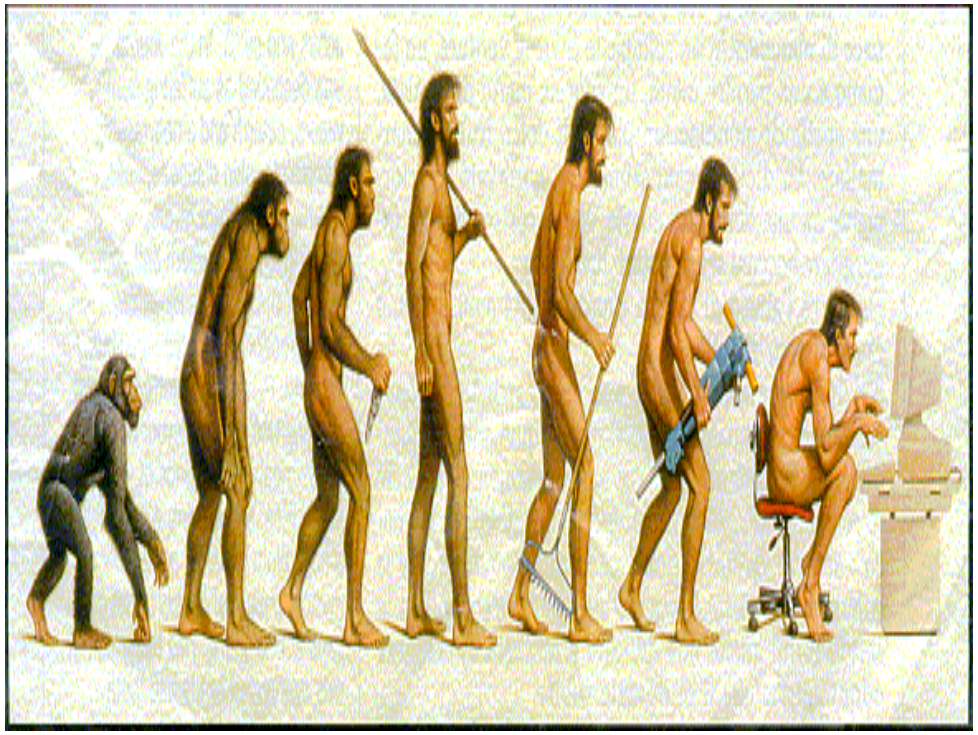
- 一般而言，与前面介绍的方法相比，还有些方法不常在商品化数据挖掘系统中使用。然而，这些方法在某些应用中确实表现出了它们的优点。
  - —遗传算法
  - —模糊集方法
  - —粗糙集方法

遗传算法

从生物进化到进化计算



（Darwin，1809 - 1882）



生物进化理论

——物竞天择、适者生存

生物进化理论和遗传学的基本知识

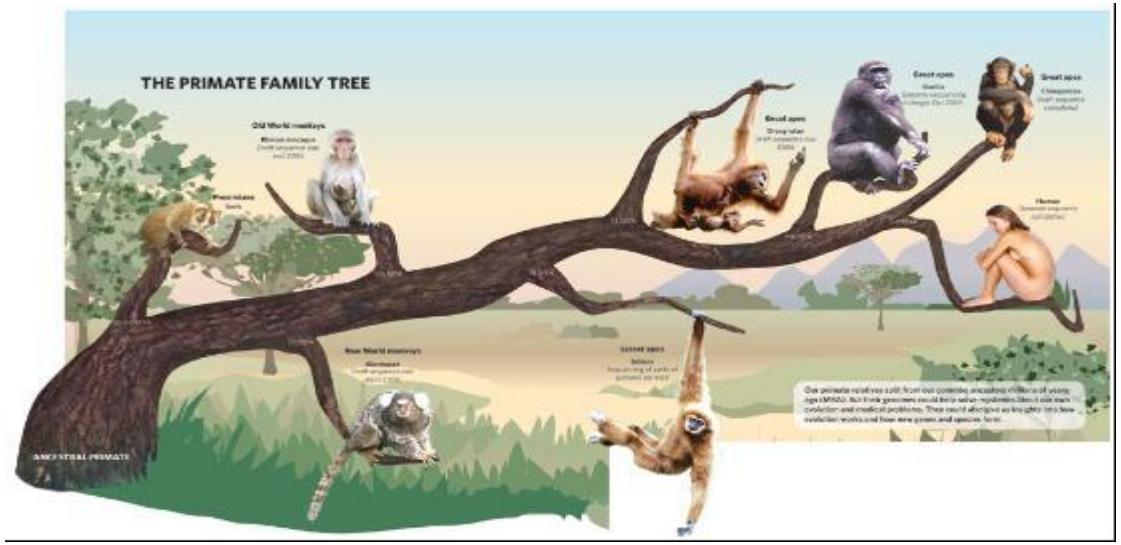
- 生命的基本特征包括
  - 生长
  - 繁殖
  - 新陈代谢
  - 遗传与变异
- 达尔文用自然选择(natural selection)来解释物种的起源和生物的进化，其自然选择学说包括以下三个方面
  - 遗传
  - 变异
  - 生存斗争和适者生存

生物进化理论和遗传学的基本知识

- 遗传
  - 生物的普遍特征，“种瓜得瓜，种豆得豆”，亲代把生物信息交给子代，子代按照所得信息发育、分化，因而子代总是和亲代具有相同或相似的形状。
  - 生物有了这个特征，物种才能稳定存在。
- 变异
  - 亲代和子代之间以及子代的不同个体之间总有些差异，这种现象称为变异。
  - 变异是随机发生的，变异的选择和积累是生命多样性的根源。

生物进化理论和遗传学的基本知识

- 生存斗争和适者生存
  - —自然选择来自繁殖过剩和生存斗争
  - —由于弱肉强食的生存斗争不断进行，其结果是适者生存，具有适应性变异的个体被保留下来，不具有适应性变异的个体被淘汰，通过一代代生存环境的选择作用，物种变异被定向着一个方向积累，演变成新的物种。



遗传算法



（John Holland，1929.2.2 - ）

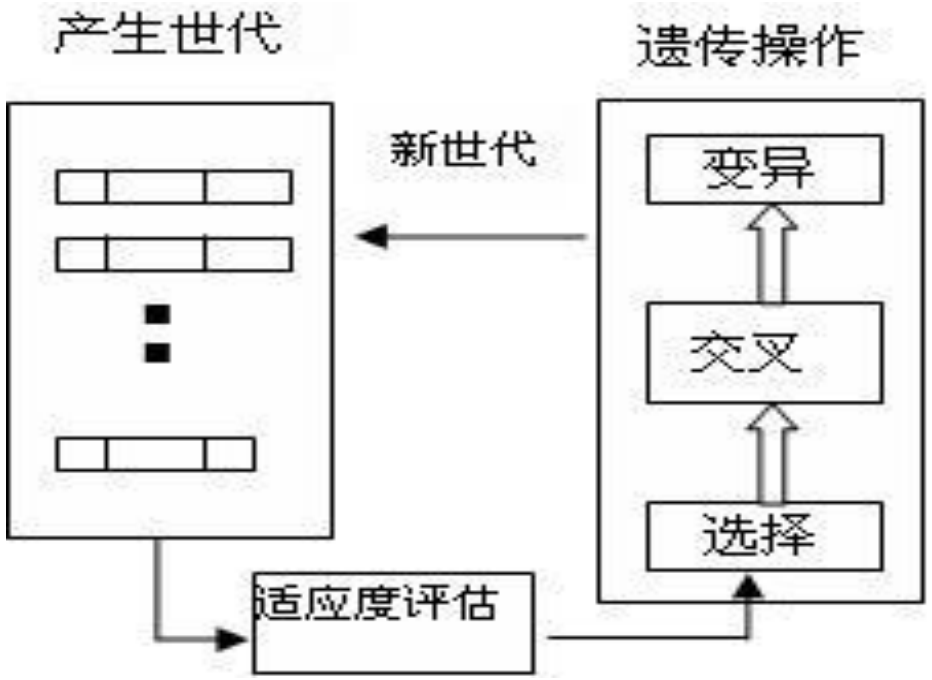
- 遗传算法（GA，Genetic Algorithms）是由霍兰德（ John Holland ）与其同事、学生于1975年在Michigan大学发展的
- GA是一种借鉴生物界自然选择和进化机制发展起来的高度并行、随机、自适应搜索算法。简单而言，它使用了搜索技术，将种群代表一组问题解，通过对当前种群施加选择、交叉和变异等一系列遗传操作，从而产生新一代的种群，并逐步使种群进化到包含近似最优解的状态。

遗传算法基本原理

- 遗传算法效法基于自然选择的生物进化，是一种摹仿生物进化过程的随机方法。
  - —遗传算法从代表问题可能潜在解集的一个种群开始，一个种群由经过基因编码的一定数目的个体组成。
  - —按照适者生存和优胜劣汰的原理，逐代演化产生出越来越好的近似解。
  - —在每一代，根据问题域中个体适应度大小挑选个体，借助于自然遗传学的遗传算子进行组合交叉和变异，产生出代表新的解集的种群。
  - —这个过程将导致种群像自然进化一样,后生代种群比前代更加适应于环境，末代种群中的最优个体经过解码可以作为问题近似最优解。

遗传算法基本原理

- 一定数目N个个体随机地初始化，并计算每个个体的适应度函数，初始代产生。
- 按照适应度选择个体，父代要求基因重组（交叉）而产生子代。所有子代按一定概率变异。
- 子代的适应度又被重新计算，子代被插入到种群中将父代取而代之，构成新的一代。直到满足优化准则为止。



遗传算法基本原理

遗传算法可定义为一个8元组：

$GA = (C, E, P_0, M, \Phi, \Gamma, \Psi, T)$

式中，

C—个体的编码方法；

E—个体适应值评价函数；

P_0—初始种群；

M—群体大小；

Φ—选择算子；

Γ—交叉算子；

Ψ—变异算子；

T—遗传算法终止条件。

遗传算法基本原理

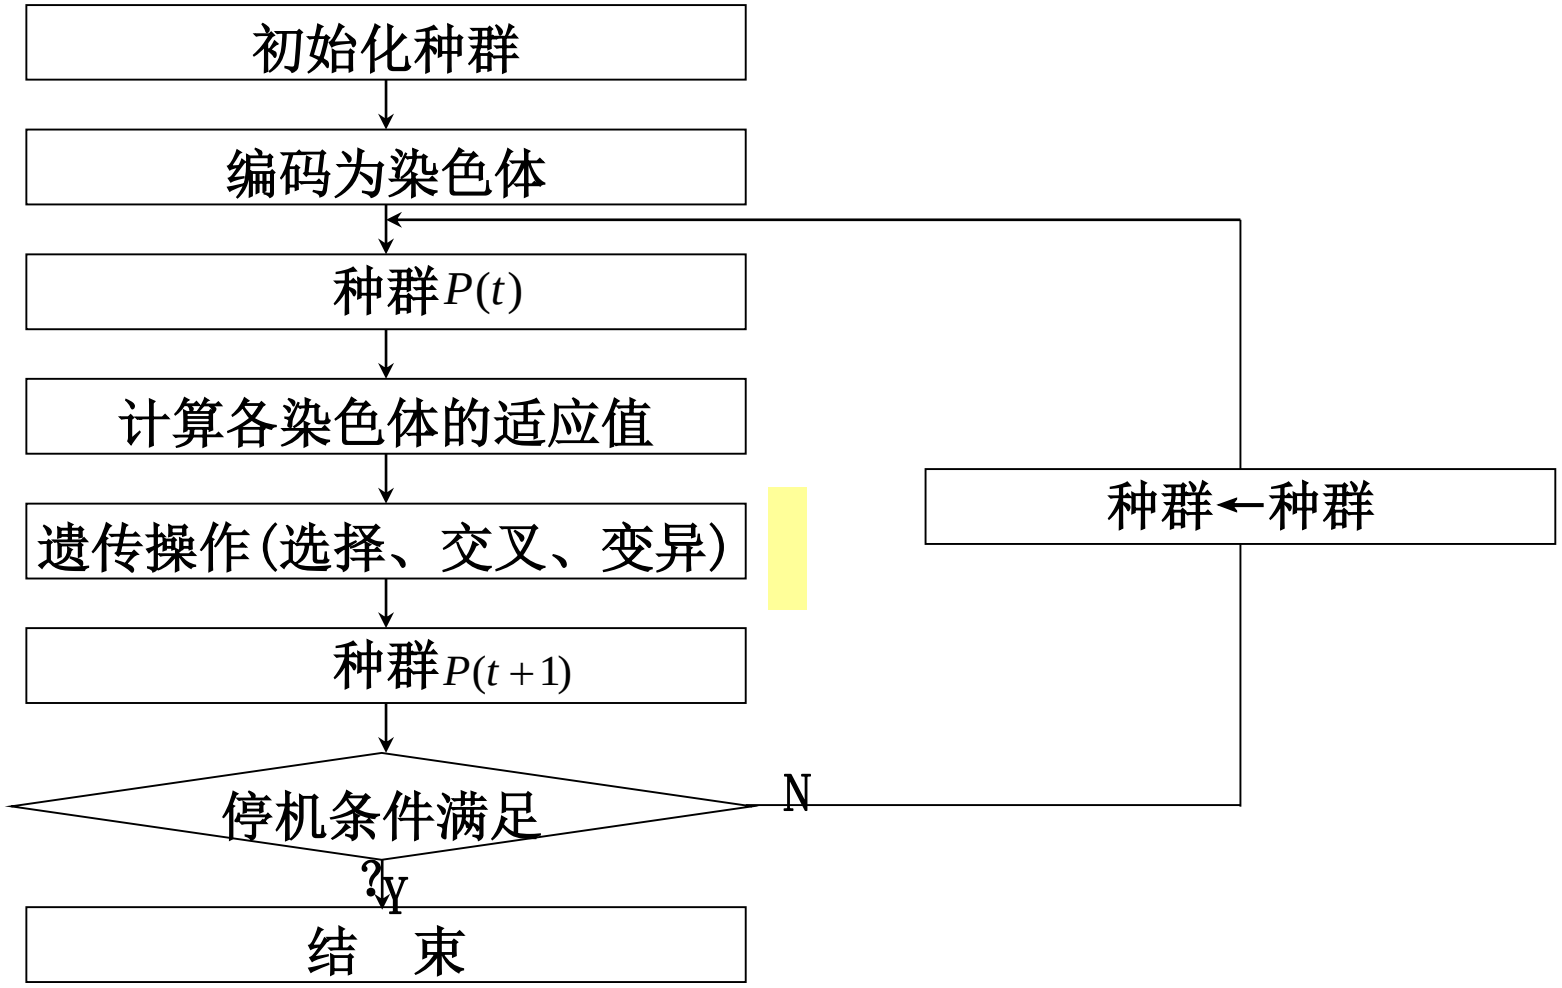


图　遗传算法的工作原理示意图

遗传算法基本原理

遗传算法的关键技术包括：

- 编码问题
- 初始种群的产生
- 确定适应值函数
- 选择遗传操作算子
- 停机条件

遗传算法关键技术：（1）编码问题

- 编码问题
  - 由于遗传算法不能直接处理解空间的解数据，因此必须通过编码将它们表示成遗传空间的基因型串结构数据。
  - 编码方法在很大程度上决定了如何进行群体的遗传进化运算以及遗传进化的效率。由于不同的编码方法具有不同的特点，为了提高遗传算法的效率，应根据不同的情况采用不同的编码方式。
  - 主要的编码方法有二进制编码、浮点数编码、符号编码、多参数编码、可变长染色体编码等。

遗传算法关键技术：（1）编码问题

- 编码问题
  - 在遗传算法中一般用二值（0，1）向量表示染色体，故先要对规则进行编码。
  - 编码采用二进制，将由特征和类别组成的训练例子集编码成二进制字符串的遗传样本。
  - 一个样本M^i是一个二元组，其形式如下：$M^i=[x^i, y^i]$，其中：i为样本号；x为条件部分，即训练例子的各特征编码；y为结论部分，即训练例子的类别。

遗传算法关键技术：（1）编码问题

具体的编码规则如下：

- ✓ 若属性为范畴型，定义属性段的宽度等于属性取值个数。对于每个属性段，若第一位为‘*’，表示该属性取值可以为任意；否则，各位若取值为1，表示取该属性值，0表示不取该属性值。例如，某条件属性C_i对应的编码二进制串为011001，表示该属性取第二个属性值或第三个属性值或第六个属性值，即 $C_i \in \{C_{i2}, C_{i3}, C_{i6}\}$
- ✓ 若属性为数值型，定义属性段的宽度 $w = [\log 2(n)] + 2$，其中n为该属性的取值个数。对于每个属性段，若第一位为‘*’，表示该属性取值可以为任意

遗传算法关键技术：（2）初始种群的产生

- 初始种群的产生
  - GA以初始种群作为初始点开始迭代。
  - 初始种群大小表示群体中所含个体的数量。
    - 当个体数量取值较小时，可提高遗传算法的运算速度，但搜索空间分布范围有限，降低了群体的多样性，有可能会引起遗传算法的早熟现象；
    - 当个体数量取值较大时，一方面计算复杂，会使遗传算法的运行效率降低，另一方面，部分高适应值的个体可能被淘汰，影响交叉。
    - 初始种群的一般取值范围是20~100。

遗传算法关键技术：（2）初始种群的产生

- 产生初始种群的方法通常有两种：

（1）对问题的解无任何先验知识的情况，采用随机产生样本的方法；

（2）对于具有某些先验知识的情况，可首先将这些先验知识转变为必须满足的一组要求，然后在满足这些要求的解中随机地选取样本。这样选择初始种群可使遗传算法更快地达到最优解。

遗传算法关键技术：（3）确定适应值函数

- 确定适应值函数
  - 遗传算法的设计要素之一是如何确定适应值函数，在遗传算法中，利用适应值来衡量个体的优劣，采用适者生存的原则决定哪些个体进行繁殖，哪些个体被淘汰。

遗传算法关键技术：（4）选择遗传操作算子

- 遗传算子包括三个基本算子
  - —选择算子(Selection Operator)
  - —交叉算子(Crossover Operator)
  - —变异算子(Mutation Operator)

遗传算法关键技术：（5）停机条件

- 停机条件
  - —遗传算法是一种反复迭代的搜索算法，它通过多次进化逐渐逼近最优解，因此需要确定停机条件。
  - —最常用的停机条件是规定遗传的代数，即迭代次数。

遗传算法关键技术

停机条件

— 当遗传算法是用来产生新的规则时，停机条件不能简单地用遗传代数确定。一次学习过程结束是当目前工作规则已收敛，停机条件应该定义为：子代种群的规则与其父代完全相同，并且各规则的适应值已连续M次保持不变。也就是说，当前工作种群已不再进化了。其中，M是根据不同的应用情况事先设置的一个参数。

遗传算法的步骤

- 代数计数器初始化：t←0；
- 产生初始种群；
- 评价群体P(t)的适应值；
- 根据当前群体的每个个体的适应值进行选择生成中间群体P1(t)；
- 个体交叉(重组)操作：P2(t) ←crossover[P1(t)]；
- 个体变异操作：P3(t) ←mutation[P2(t)]；
- 评价群体P3(t)的适应值；
- 终止条件判断，若不满足终止条件，则：t←t+1，
- 转向第3步，继续进行遗传操作过程；
- 若满足终止条件，则：输出当前最优个体，算法结束。

遗传算法应用于分类

- 创建一个由随机产生的规则组成的初始群体,每个规则可以用一个二进位串表示。
- 一个简单的例子
  - 假设给定的训练集样本用两个布尔属性A1和A2描述，并且有两个类C1和C2
  - 规则“IF A1 AND NOT A2 THEN C2”可以用二进位串“100”编码，其中最左边的两个二进位分别代表属性A1和A2，而最右边的二进位代表类。
  - 类似地，规则“IF NOT A1 AND NOT A2 THEN C1”可用“001”编码。
  - 如果一个属性具有k个值，则可以用k个二进位对该属性的值编码，类可以用类似的方式编码。

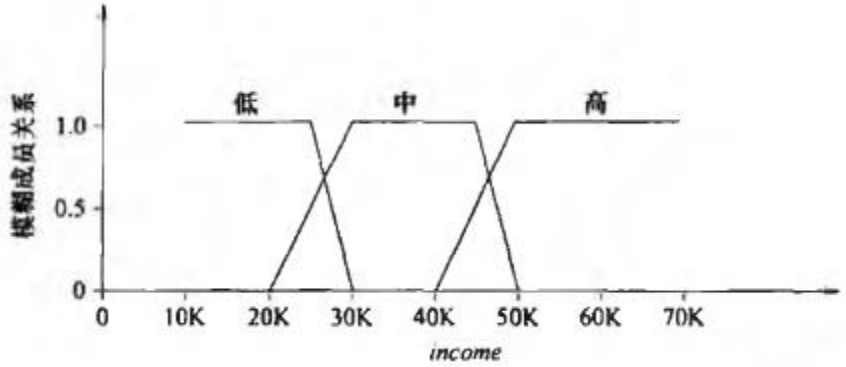
遗传算法应用于分类

- 根据适者生存的原则，形成新的群体，它由当前群体中最适合的规则以及这择规则的后代组成。通常，规则的拟合度（fitness）用它在训练样本集上的分类准确率评估。
- 后代通过使用诸如交叉和变异等遗传操作来创建。在交叉操作中，来自规则对的子串交换，形成新的规则对。在变异操作中, 规则串中随机选择的位被反转。
- 继续基于先前的规则群体产生新的规则群体的过程，直到群体P“进化”，P中的每个子规则都满足预先指定的拟合度阈值。
- 遗传算法易于并行，并且业已用于分类和其他优化问题。在数据挖掘中，它们可能用于评估其他算法的拟合度。

其它分类方法

- 一般而言，与前面介绍的方法相比，还有些方法不常在商品化数据挖掘系统中使用。然而，这些方法在某些应用中确实表现出了它们的优点。
  - —遗传算法
  - —模糊集方法
  - —粗糙集方法

模糊逻辑



- 基于规则的分类系统有一个缺点
  - 对于连续属性，它们有陡峭的截断
  - 例如，考虑顾客信用卡申请审批的规则
    - 该规则本质上是说：工作两年或多年，并且具有较高收入（即至少50000美元）的顾客申请将被批准
    - IF (year_employed>=2) AND (income>=50000) THEN credit=approved
    - 根据规则，一个至少工作两年的顾客将得到信用卡，如果他的收入是50000美元；但是，他的收入是49000美元，则得不到信用卡。
  - 这种苛刻的阈值看起来可能不公平
- 换一种方式，可以将收入离散化成类别，如{low_income，medium_income，high_oncome}，然后使用模糊逻辑，允许为每个类定义“模糊”阈值或边界。
  - 模糊逻辑使用0 和1之间的真值表示一个特定的值是一个给定类成员的隶属程度，而不是用类之间的精确截断。然后，每个类别表示一个模糊集。
  - 使用模糊逻辑，可以表达这样的概念：
    - 在某种程度上，49000美元的收入是高的，尽管没有50000美元的收入高。通常，模糊逻辑系统提供图形工具帮助用户把属性值转换成模糊真值。

模糊集理论

- 作为传统的二值逻辑和概率论的一种替代，它允许处理高层抽象，并且提供了一种处理数据的不精确测量的手段
- 最重要的是，模糊集理论允许处理模糊或不精确的事实
  - —例如，高收入集成员是不精确的（例如，如果收入50000美元是高收入，则收入49000美元或48000美元如何？ 不像传统的“明确的”集合，元素或者属于集合或者属于它的补，在模糊集合论中，元素可以属于多个模糊集
    - 例如，值49000美元属于模糊集medium和high，但具有不同的隶属度。使用模糊集的记号可以表示为：
      - $m_{medium_income}(\$49000)=0.15$， $m_{high_income}(\$49000)=0.96$
      - 其中，m为隶属度
- 在模糊集理论中，给定元素X（如$49000美元）的隶属值之和不必等于1，这与传统的概率论不同，传统的概率论受总和公理的约束。

模糊集理论的产生



1965年，美国加利福尼亚大学控制论专家扎德（*A.Zadeh*）教授在《信息与控制》杂志上发表一篇开创性论文《模糊集合》，这标志着模糊数学的诞生。扎德被誉为“模糊集之父”。

模糊数学概念

•产生

1965年，L.A. Zadeh（扎德） 发表了文章《模糊集 》

(Fuzzy Sets，Information and Control, 8, 338-353)

•基本思想

用属于程度代替属于或不属于。

某个人属于高个子的程度为0.8, 另一个人属于

高个子的程度为0.3等.

模糊数学概念

用数学的眼光看世界，可把我们身边的现象划分为：

1.确定性现象：如水加温到100°C就沸腾，这种现象的规律

性靠经典数学去刻画；

2.随机现象：如掷筛子，观看那一面向上，这种现象的规律

性靠概率统计去刻画；

3.模糊现象：如 “今天天气很热”，“小伙子很高”，…等等。

此话准确吗？有多大的水分？靠模糊数学去刻画。

模糊数学概念

年轻、重、热、美、厚、薄、快、慢、大、小、
高、低、长、短、贵、贱、强、弱、软、硬、
阴天、多云、暴雨、清晨、礼品。

共同特点：模糊概念的外延不清楚。

模糊概念导致模糊现象

模糊数学——研究和揭示模糊现象的定量处理方法。

模糊数学概念

- 涉及学科

模糊代数，模糊拓扑，模糊逻辑，模糊分析，
模糊概率，模糊图论，模糊优化等模糊数学分支

分类、识别、评判、预测、控制、排序、选择；

人工智能、控制、决策、专家系统、医学、土木、
农业、气象、信息、经济、文学、音乐

- 模糊产品

洗衣机、摄象机、照相机、电饭锅、空调、电梯

模糊集理论的应用领域

1976年英国学者Gains和Kohout搜集整理模糊数学及应用方面的论文统计表

表 1-1　模糊集合论文统计表

领　域	篇　数	领　域	篇　数	领　域	篇　数
自动机	65	形式逻辑	32	生 物 学	10
模式识别	55	拓扑学	29	格　论	10
社会科学	49	心理学	27	推　论	8
语言学	49	模糊度理论	24	对 策 论	7
自动控制	46	集合论	23	反论分析	7
概率论	45	学习机、人工智能	22	公差容限	4
判　定	45	信息检索	18	半　环	3
多值逻辑	38	分类理论	15	测　度	1
开关逻辑	36	医学科学	13	真　值	1
形式语言	32	系统理论	11	模态逻辑	1

基于模糊集理论的分类

- 对于进行基于规则的分类的数据挖掘系统来说，模糊集理论是有用的。它提供了结合模糊度量的操作。
- 假设除income的模糊集之外，还为属性year_employed定义模糊集junior_employee和senior_employee。
- 假设有一个规则，对给定的雇员X检测规则前件(IF部分) high_income和senior_employee 。如果这两个模糊度量用AND连接在一起，则取它们的最小度量为该规则的度量。换言之，
  - $m_{high_income\ AND\ senior_employee}(x)=min(m_{high_income}(x), m_{senior_employee}(x))$
    - 这类似于说：一条链与它的最弱的链接一样结实
  - $m_{high_income\ OR\ senior_employee}(x)=max(m_{high_income}(x), m_{senior_employee}(x))$
    - 这好像是说绳索与它的最结实的绳股一样结实
- 给定一个待分类的元组，可以使用多个模糊规则。每个可用的规则为类的隶属贡献一票。通常，对每个预测分类的真值进行求和，并组合这些和。有一些过程，将模糊输出结果转换成系统返回的非模糊或明确的值。
- 模糊逻辑系统已用于许多分类领域，包括市场调查、财经、卫生保健和环境工程。

其它分类方法

- 一般而言，与前面介绍的方法相比，还有些方法不常在商品化数据挖掘系统中使用。然而，这些方法在某些应用中确实表现出了它们的优点。
  - —遗传算法
  - —模糊集方法
  - —粗糙集方法

模糊集

- 1965年，Zadeh提出了模糊集，不少理论计算机科学家和逻辑学家试图通过这一理论解决G.Frege的含糊概念，但模糊集理论采用隶属度函数来处理模糊性，而基本的隶属度是凭经验或者由领域专家给出，所以具有相当的主观性。

粗糙集的提出

- 20世纪80年代初，波兰的Pawlak针对G.Frege的边界线区域思想提出了粗糙集（Rough Set），他把那些无法确认的个体都归属于边界线区域，而这种边界线区域被定义为上近似集和下近似集之差集。由于它有确定的数学公式描述，完全由数据决定，所以更有客观性 。

粗糙集与其他集合论

- 粗糙集理论与传统的集合理论有着相似之处，但是它们的出发点完全不同。
- 传统集合论认为，一个集合完全是由其元素所决定，一个元素要么属于这个集合，要么不属于这个集合，即它的隶属函数$\mu_X(x) \in \{0,1\}$。
- 模糊集合对此做了拓广，它给成员赋予一个隶属度，即$\mu_X(x) \in [0,1]$，使得模糊集合能够处理一定的模糊和不确定数据，但是其模糊隶属度的确定往往具有人为因素，这给其应用带来了一定的不便。而且，传统集合论和模糊集合论都是把隶属关系作为原始概念来处理，集合的并和交就建立在其元素的隶属度max和min操作上，因此其隶属度必须事先给定。
- 在粗糙集中，隶属关系不再是一个原始概念，因此无需人为给元素指定一个隶属度，从而避免了主观因素的影响。

粗糙集理论

- RS 理论是一种处理不精确、不确定与不完全数据的新的数学方法. 由于它在机器学习与知识发现、数据挖掘、决策支持与分析、专家系统、归纳推理、模式识别等方面的广泛应用，现已成为一个热门的研究领域

- RS 理论主要兴趣在于它恰好反映了人们用 RS 方法处理不可分辨问题的常规性，即以不完全信息或知识去处理一些不可分辨现象的能力，或依据观察，度量到的某些不确定的结果而进行分类数据的能力

粗糙集理论的应用

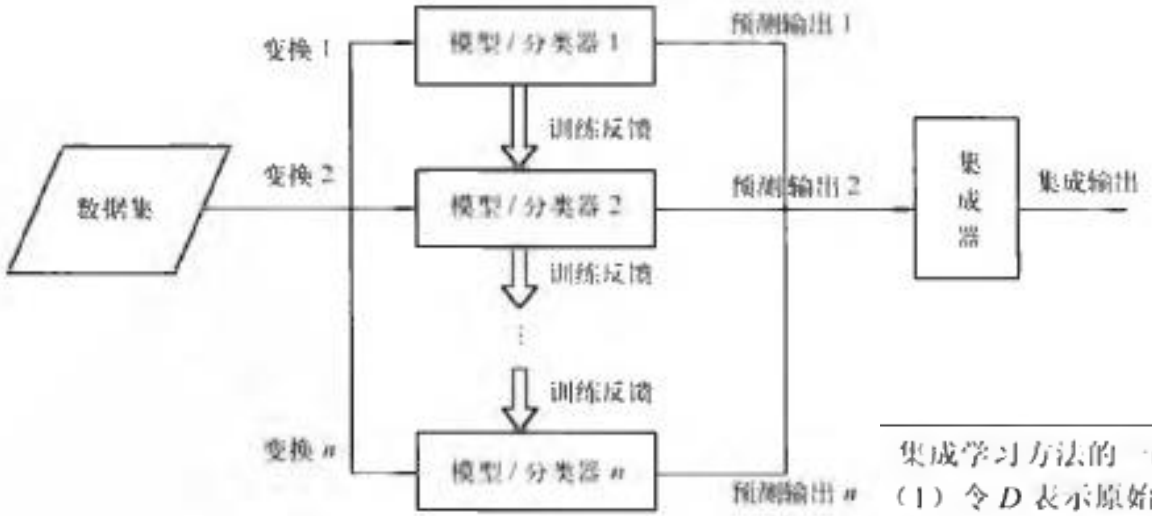
- RS 理论的生命力在于它具有较强的实用性，从诞生到现在虽然只有十几年的时间，但已经在许多领域取得了令人鼓舞的成果。
  - —模式识别
  - —数据挖掘
  - —粗糙控制 (rough control)
  - —在经济系统分析和预测、医疗诊断、图象处理 等

Chapter 7 Classification 分类
7-2：Adanced Methods 高级方法

Rule-Based Classification	基于规则的分类
Bayes Classification Methods	贝叶斯分类(ML课程)
Bayesian Belief Networks	贝叶斯信念网络
Classification by Backpropagation	用后向传播分类(ML课程)
Support Vector Machines	支持向量机(ML课程)
Classification Using Frequent Patterns	使用频繁模式分类
Lazy Learners	惰性学习法(ML课程)
(or Learning from Your Neighbors)	（或从近邻学习）
Other Classification Methods	其他分类方法
Ensemble Learning	**集成分类法**
Additional Topics Regarding Classification	关于分类的其它问题

集成学习法
Ensemble Learning

- 将多个分类方法聚集在一起形成组合分类器，基于每个个体分类器（基分类器）投票，返回最终的类标号预测。通常，一个集成分类器的分类性能会好于单个分类器。
  - — 使用训练集的不同子集训练得到不同的基分类器
  - — 用同一训练集的不同属性子集训练得到不同的基分类器



集成学习方法的一般过程

（1）令 D 表示原始训练数据集，k 表示基分类器的个数，Z 表示测试数据集

（2）for i=1 to k do

（3）　由 D 创建训练集 D_i

（4）　由 D_i 创建基分类器 C_i

（5）end for

（6）for 每个测试样本 $x \in Z$ do

（7）　$C^*(x)$=Vote($C_1(x)$,$C_2(x)$,…,$C_k(x)$)

（8）end for

集成学习法
Ensemble Learning

- 集成学习法不是简单第将数据集在不同分类器上重复训练，而是对数据集进行扰动，通过减少未知实例与训练集实例分布不同造成的预测误差，从而学习到更一般的模型，消除单个分类器所产生的偏差，得到更准确的模型。
- 常见的集成学习方法
  - Bagging 装袋
  - Boosting 提升
    - AdaBoost
  - Random Forest 随机森林

Bagging: Boostrap Aggregation

集成分类器 —— 1) 装袋

- 多个分类器，每个基分类器有着相同的投票权重
  - —多数表决

- 装袋算法
  - —d个元组的集合D
  - —对于迭代i(i=1,2…k),d个元组的训练集Di采用有放回抽样
    - 有些元组不出现
    - 有些元组重复多次
  - —每个训练集Di学习得到分类模型Mi
  - —未知元组X分类
    - 每个分类器Mi返回它的类预测
    - 得票最高的类赋予X
  - —可以用于连续值的预测

Bagging: Boostrap Aggregation

集成分类器 —— 1) 装袋

Algorithm: Bagging. The bagging algorithm—create an ensemble of classification models for a learning scheme where each model gives an equally weighted prediction.

Input:

- D, a set of d training tuples;
- k, the number of models in the ensemble;
- a classification learning scheme (decision tree algorithm, naïve Bayesian, etc.).

Output: The ensemble—a composite model, $M*$.

Method:

(1) **for** $i = 1$ to k **do** // create k models:
(2) create bootstrap sample, D_i, by sampling D with replacement;
(3) use D_i and the learning scheme to derive a model, M_i;
(4) **endfor**

To use the ensemble to classify a tuple, X:

let each of the k models classify X and return the majority vote;

Boosting

集成分类器 —— 2) 提升

- 算法基本思想
  - —提升是一个迭代的过程，用于自适应地改变训练样本的分布，使得使得基分类器聚焦在那些很难分的样本上。不像装袋，提升给每个训练样本赋予一个权值，而且可以在每轮提升过程结束自动地调整权值。
- 训练样本权值的应用
  - —①抽样分布，从原始数据集中提取出自主样本集
  - —②基分类器可以使用权值学习有利于高权值样本的模型
- 算法步骤
  - — 赋予每个训练元组以权重， 迭代地学习 k 个分类器 M_i
  - — 更新每个训练元组的权重，再次生成新的分类器
  - — 最终根据权重衡量各个子分类器的投票结果，得到最终的类

Boosting

集成分类器 —— 2) 提升

- **利用权值确定训练集的抽样分布**
  - —开始时，所有样本都赋予相同的权值，从而使得它们被选作训练样本的可能性都一样。
  - —根据训练样本的抽样分布来抽取样本，得到新的样本集。这里采用有放回的抽样，某些样本可能被选中多次（见第1轮）。然后由该训练集归纳一个分类器，并用它对原数据集中的所有样本进行分类。
  - —每轮提升结束时更新训练集样本的权值。增加被错误分类的样本的权值（第2轮中4被错误分类，第1轮中没有被选中的1和5），减小被正确分类样本的权值。
  - —这迫使分类器在随后迭代中关注那些很难分类的样本。

每轮提升选择的样本

提升第 1 轮	7	3	2	8	7	9	4	10	6	3
提升第 2 轮	5	4	9	4	2	5	1	7	4	2
提升第 3 轮	4	4	8	10	4	5	4	6	3	4

Random Forest

集成分类器 —— 3) 随机森林

- 想象组合分类器中的每个分类器都是一颗决策树
  因此分类器的集合就是一个“森林”

- 分类时，每棵树都投票并返回得票最多的类

- 随机森林可以使用 **装袋** 与 **随机属性选择** 结合来构建

- 与 Adaboost 相比：
  - 对错误和离群点鲁棒性更好

Chapter 7 Classification 分类
7-2：Adanced Methods 高级方法

- Rule-Based Classification 基于规则的分类
- Bayes Classification Methods 贝叶斯分类(ML课程)
- Bayesian Belief Networks 贝叶斯信念网络
- Classification by Backpropagation 用后向传播分类(ML课程)
- Support Vector Machines 支持向量机(ML课程)
- Classification Using Frequent Patterns 使用频繁模式分类
- Lazy Learners 惰性学习法(ML课程)
- (or Learning from Your Neighbors) （或从近邻学习）
- Other Classification Methods 其他分类方法
- Ensemble Learning 集成分类法
- **Additional Topics Regarding Classification 关于分类的其它问题**

关于分类的其它问题

- 多类分类
  - CART、SVM等算法仅仅支持二元分类，如何扩充这些算法，允许多类划分
- 半监督分类
  - 同时使用有类标号的数据和无类标号的数据构建分类器
- 主动学习
  - 迭代的监督学习
  - 适合数据丰富但类标号稀缺或获取昂贵的情况
  - 学习算法是主动的，可以有目的地向用户询问类标号，使需要的用于学习概念的元组数远小于典型的监督学习
- 迁移学习
  - 为训练一个分类模型需要进行大量的工作。如训练客户对照相机的评论，需要对大量的数据加标号，如果对每一类产品都如此训练一个评分分类模型，需要付出大量的努力。能否改编一个已有的分类模型（如为照相机建立的模型），帮助学习一个用于TV的分类模型？
  - 从一个或多个源任务提取知识，并将这些任务用于目标任务