

Data Mining and Big Data Anlysis
数据挖掘及大数据分析

— Chapter 8： Cluster Analysis聚类分析
8-1： Basic Concepts基本概念

王东、张谦、丁玥
上海交通大学软件学院RFID与物联网实验室

2025年春季

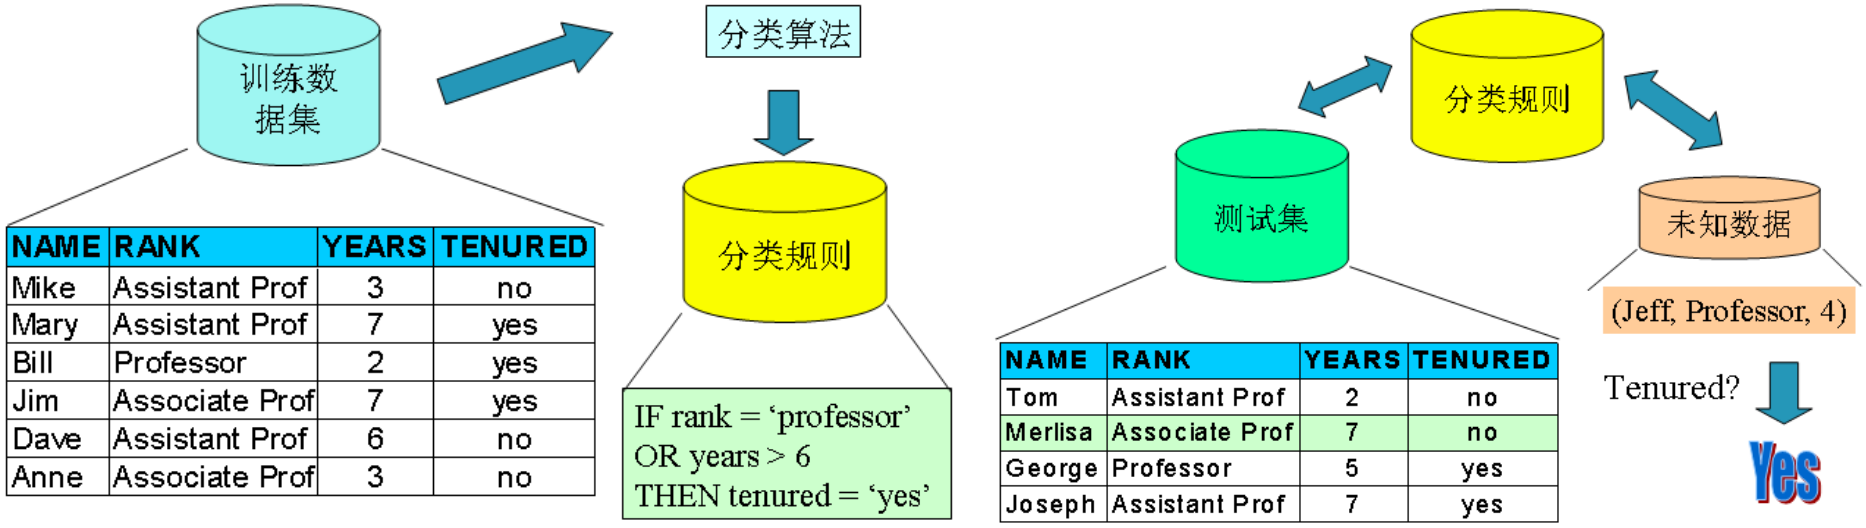
Chapter 8. Cluster Analysis 聚类
8-1: Basic Concepts 基本概念

- **Cluster Analysis: Basic Concepts** **基本概念**
- Partitioning Methods 划分方法
- Hierarchical Methods 分层方法
- Density-Based Methods 基于密度的方法
- Grid-Based Methods 基于网格的方法
- Evaluation of Clustering 聚类方法的评估

What is Cluster Analysis?
什么是聚类分析？

- **Cluster 聚类** 又称，自动分类/数据分割
  - 把数据对象(或观测)划分成子集的过程
  - 簇内对象彼此相似，簇外彼此相异
- **Unsupervised Learning** 非监督学习——用于聚类
  - 没有提供类标号信息
  - 通过 **观察学习**，而不是通过 示例学习。





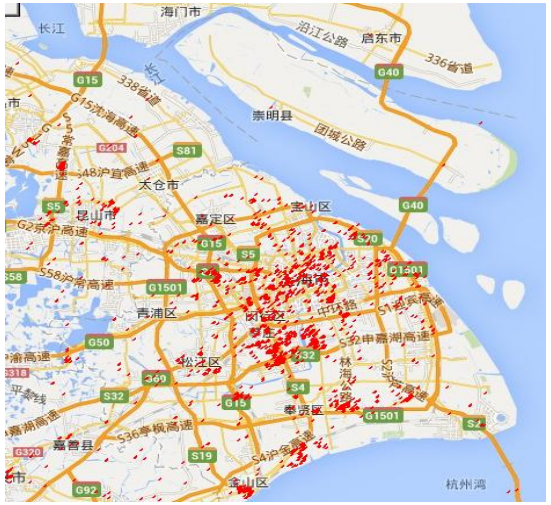
NAME	RANK	YEARS	TENURED
Mike	Assistant Prof	3	no
Mary	Assistant Prof	7	yes
Bill	Professor	2	yes
Jim	Associate Prof	7	yes
Dave	Assistant Prof	6	no
Anne	Associate Prof	3	no

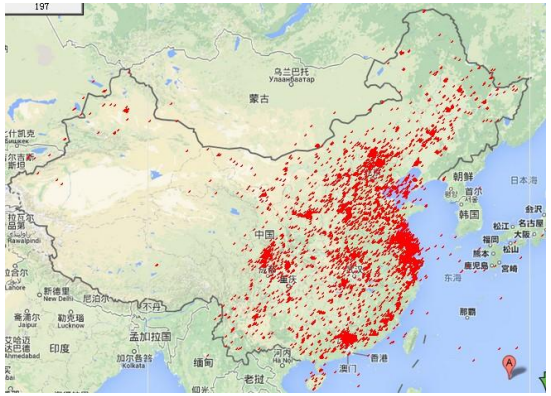
NAME	RANK	YEARS	TENURED
Tom	Assistant Prof	2	no
Merlisa	Associate Prof	7	no
George	Professor	5	yes
Joseph	Assistant Prof	7	yes

Applications of Cluster Analysis

聚类的常见应用

- 空间数据分析
  - — 通过聚类特征空间创建GIS中的主题映射
  - — 探测空间簇,用空间数据挖掘解释它们
- 图像模式识别
  - — 对手写数字数据集聚类，确定子类，每个子类代表手写可能出现“ 2” 的变体，使用基于子类的多个模型可以提高整体识别的准确率
- 经济学(特别指市场研究)
  - — 把客户分组，开发加强客户关系管理的商务策略
- Web关键词搜索
  - — Web页面数量巨大，关键词搜索会返回大量命中对象〈与搜索相关网页），用聚类将搜索结果分组，以简明的方式提交结果





Quality: What Is Good Clustering?

什么是一个好的聚类？

- **好的聚类方法**
  - —最大化类内的相似性
  - —最小化类间的相似性
- 聚类结果的质量依靠所使用度量的相似性和它的执行
- 聚类方法的质量也可以用它发现一些或所有隐含模式的能力来度量

Requirements and Challenges

对聚类分析的要求

- 可伸缩性
  - 可以针对不同大小的数据进行聚类
- 处理不同属性类型的能力
  - 数值属性、二元属性、标称属性、序数属性、混合的属性等
- 基于约束的聚类
  - 现实世界的应用需要在各种约束条件下进行聚类
- 可解释性和可用性
- 其他
  - 发现任何形状的簇
  - 处理噪声数据的能力
  - 增量聚类和对输入次序不敏感
  - 聚类高维数据的能力



Major Clustering Approaches
主要聚类方法的分类

- **Partitioning approach** 划分方法
  - 构造各种各样的划分,并用一些标准来评估它们
  - E.g., K-means, k-medoids, CLARANS
- **Hierarchical approach** 层次方法
  - 使用一些策略来进行数据(或对象)集的层次分解
  - E.g., Diana, Agnes, BIRCH, CAMELEON
- **Density-based approach** 基于密度的方法
  - 基于连续和密度函数 E.g., DBSACN, OPTICS, DenClue
- **Grid-based approach** 基于网格的方法
  - 基于多层粒度结构 E.g., STING, WaveCluster, CLIQUE
- **其他**
  - **基于模型的方法**
  - **基于频繁模式的方法 ……**

基于代表对象的技术，
中心点法（ **medoids**）

Major Clustering Approaches

主要聚类方法的分类——（1）划分方法

- 问题表述
  - —给定一个*n*个对象或元组的数据集，通过一个划分方法构建数据的*k*个划分，每个划分表示一个簇，并且*k*<=*n*
    - 每个组至少包含一个对象
    - 每个对象属于且仅属于一个组
- 划分准则
  - —同一个聚类中的对象尽可能的接近或相关，不同聚类中的对象尽可能的远离或不同
  - —基本划分方法采取互斥的簇划分，每个对象必须恰好属于一个组。这一要求，例如在模糊划分技术中，可以放宽
  - —大部分划分方法是基于距离的。给定要构建的分区数k，划分方法首先创建一个初始划分。然后，采用一种迭代的重定位技术，通过把对象从一个组移动到另一个组来改进划分。为了达到全局最优，基于划分的聚类可能需要穷举所有可能的划分，计算量极大。

Major Clustering Approaches

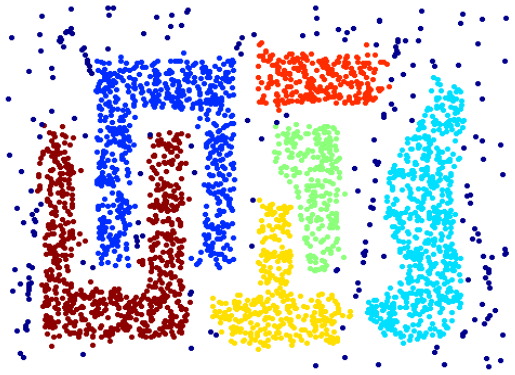
主要聚类方法的分类——（2）层次方法

- 层次方法创建给定数据对象集的层次分解
  - —将数据对象组成一棵树
- 根据层次分解如何形成，层次方法可以分为
  - —凝聚的方法，也称自底向上的方法，开始将每个对象作为单独的一个组，然后逐次合并相近的对象或组，直到所有的组合并为一个组（层次的最顶层）或者满足某个终止条件。
  - —分裂的方法，也称为自顶向下的方法，开始将所有的对象置于一个族中。在每次相继迭代中，一个簇被划分成更小的簇，直到最终每个对象在单独的一个簇中，或者满足某个终止条件。
- 划分准则
  - —基于距离的
  - —基于密度和连通性的
- 层次方法的缺陷
  - —一旦一个步骤（合并或分裂）完成，它就不能被撤销

Major Clustering Approaches

主要聚类方法的分类——（3）基于密度的方法

- 大部分划分方法基于对象之间的距离进行聚类，只能发现球状族，而在发现任意形状的簇时遇到了困难
- 基本思想
  - —只要“邻域” 中的密度（对象或数据点的数目 ）超过某个阈值，就继续增长给定的簇。也就是说，对给定簇中的每个数据点，在给定半径邻域中必须至少包含最少数目的点
  - —这样的方法可以用来过滤噪声或离群点，发现任意形状的族



Major Clustering Approaches

主要聚类方法的分类——（4）基于网格的方法

- 基本思想
  - —基于网格的方法把对象空间量化为有限个单元，形成一个网格结构，所有的聚类操作都在这个网格结构（即量化的空间）上进行
  - —这种方法的主要优点是处理速度很快，其处理时间通常独立于数据对象的个数，而仅依赖于量化空间中每一维的单元数

Major Clustering Approaches

主要聚类方法的特性分析

方　法	一般特点
划分方法	- 发现球形互斥的簇 - 基于距离 - 可以用均值或中心点等代表簇中心 - 对中小规模数据集有效
层次方法	- 聚类是一个层次分解（即多层） - 不能纠正错误的合并或划分 - 可以集成其他技术，如微聚类或考虑对象“连接”
基于密度的方法	- 可以发现任意形状的簇 - 簇是对象空间中被低密度区域分隔的稠密区域 - 簇密度：每个点的“邻域”内必须具有最少个数的点 - 可能过滤离群点
基于网格的方法	- 使用一种多分辨率网格数据结构 - 快速处理（典型地，独立于数据对象数，但依赖于网格大小）

Chapter 1. Cluster Analysis 聚类

- Cluster Analysis: Basic Concepts 基本概念
- **Partitioning Methods** **划分方法**
- Hierarchical Methods 分层方法
- Density-Based Methods 基于密度的方法
- Grid-Based Methods 基于网格的方法
- Evaluation of Clustering 聚类方法的评估

Partitioning Algorithms - Basic Concept

划分方法 – 基本概念

- **划分方法**
  - 把具有n个对象的数据库D构造成具有k个簇的集合的划分

$$E = \Sigma_{i=1}^{k} \Sigma_{p \in C_i} (d(p, c_i))^2$$

(其中 c_i 是簇群 C_i 的 **形心**)

对象 p与该簇的代表c_i的误差，用之间的欧氏距离表示

簇 C_i 的质量——**簇内变差**

  - 这个目标函数试图使生成的结果簇尽可能紧凑和独立

- 给定k，找出有k个簇的一个划分使得所选择的划分准则最优
  - 全局最优: 穷举所有可能的划分 （NP-困难）
    - 簇个数k、空间维度d、对象个数n：时间复杂度 $O(n^{dk+1} \log n)$
  - 启发式方法: k-平均算法 和 k-中心点算法
    - k-均值算法(MacQueen'67): 把簇的形心定义为簇内点的均值
    - k-中心点算法或PAM (Partition around medoids): 每一个簇用接近聚类中心的一个对象（代表对象）表示

The K-Means Clustering Method

K—均值算法

- 使用簇的均值代表该簇
- 簇Ci的均值可以用以下计算公式：

$$\overline{x_i} = \frac{1}{|C_i|}\sum_{x \in Ci} x$$

- 对象 $p \in C_i$ 与该簇的代表 c_i 之差用 $dist(p, c_i)$ 度量
- 其中dist(x,y)是两个点x和y之间的欧氏距离
- 簇Ci的质量可以用**簇内变差**度量

$$E = \sum_{i=1}^{k} \sum_{p \in Ci} dist(p, c_i)^2$$

- 其中E是数据集中所有对象的误差的平方和，p是空间中的点，表示给定的数据对象，c_i是簇Ci的代表

The K-Means Clustering Method

K-均值算法

- 给定k, k-均值算法 由以下四步来完成:
  - —随机的选择k个对象作为目前划分的簇的 初始簇中心
  - — 对剩下的每个对象，计算与各簇中心的欧氏距离，将它分配到最相似的簇
  - — 使用上次迭代分配到该簇的对象，计算新的均值
  - —使用新的均值作为新的簇中心，重新分配所有对象，直到分配稳定

The K-Means Clustering Method

K-均值算法

算法： *k*–均值。用于划分的*k*–均值算法，其中每个簇的中心都用簇中所有对象的均值来表示。

输入：

- *k*：簇的数目；
- *D*：包含*n*个对象的数据集。

输出： *k*个簇的集合。

方法：

（1）从*D*中任意选择*k*个对象作为初始簇中心；

（2）**repeat**

（3）　根据簇中对象的均值，将每个对象分配到最相似的簇；

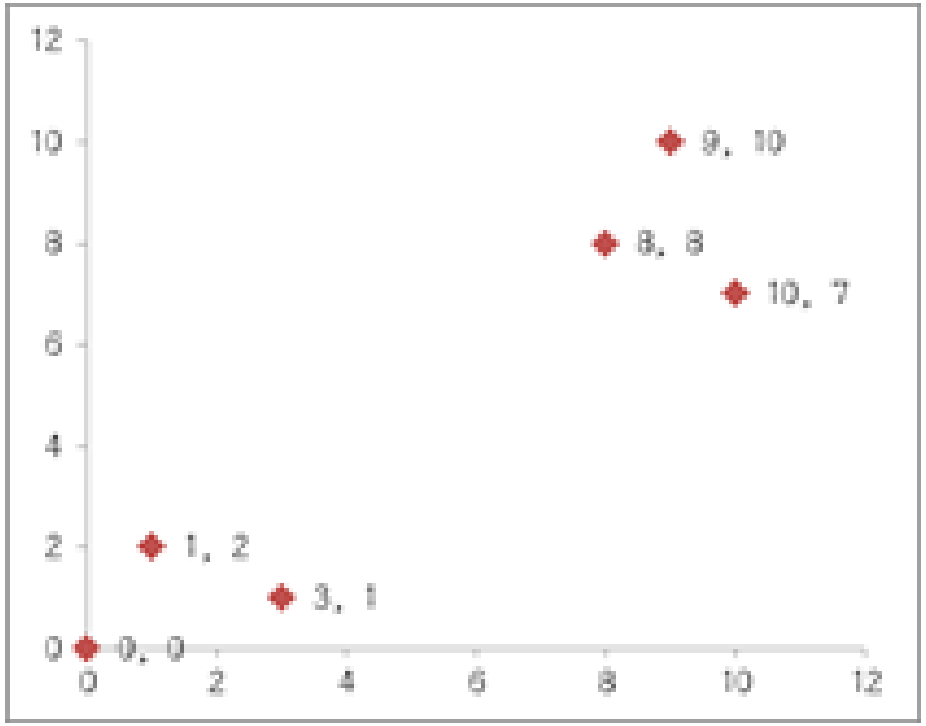
（4）　更新簇均值，即重新计算每个簇中对象的均值；

（5）**until**不再发生变化。

计算练习

- 初始簇中心：P1和P2

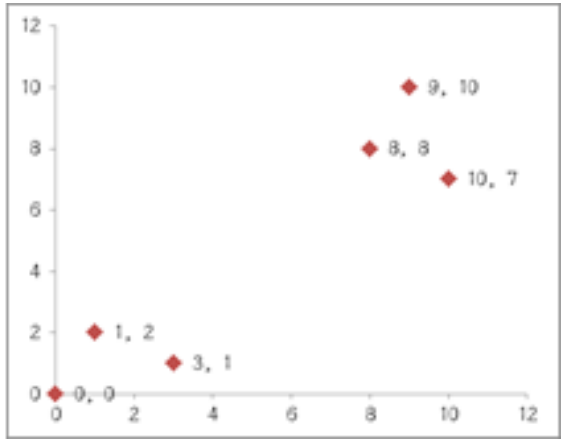
	X	Y
P1	0	0
P2	1	2
P3	3	1
P4	8	8
P5	9	10
P6	10	7



计算练习

初始簇中心：P1和P2

	X	Y
P1	0	0
P2	1	2
P3	3	1
P4	8	8
P5	9	10
P6	10	7



	P1	P2
P3	3.16	2.24
P4	11.3	9.22
P5	13.5	11.3
P6	12.2	10.3

	P1	P哥
P2	2.24	6.3246
P3	3.16	5.6036
P4	11.3	3
P5	13.5	5.2154
P6	12.2	4.0497

- 组A：P1
- 组B：P2、P3、P4、P5、P6
- P哥（（1+3+8+9+10）/5，（2+1+8+10+7）/5）=（6.2，5.6）

	P哥1	P哥2
P1	1.4	12
P2	0.6	10
P3	1.4	9.5
P4	47	1.1
P5	70	1.7
P6	56	1.7

- 组A：P1、P2、P3
- 组B：P4、P5、P6
- P哥1（1.33，1） P哥2（9，8.33）

问题讨论

1. K值怎么定？怎么知道应该几类？

- 没有确定的做法，分几类主要取决于个人的经验与感觉，通常的做法是多尝试几个K值，看分成几类的结果更好解释，更符合分析目的等

2. 初始的K个质心怎么选？

- 最常用的方法是随机选，初始质心的选取对最终聚类结果有影响，因此算法一定要多执行几次，哪个结果更reasonable，就用哪个结果
- 当然也有一些优化的方法，第一种是选择彼此距离最远的点，具体来说就是先选第一个点，然后选离第一个点最远的当第二个点，然后选第三个点，第三个点到第一、第二两点的距离之和最大，以此类推
- 第二种是先根据其他聚类算法（如层次聚类）得到聚类结果，从结果中每个分类选一个点

问题讨论

3. K-Means会不会陷入一直选质心的过程，永远停不下来？

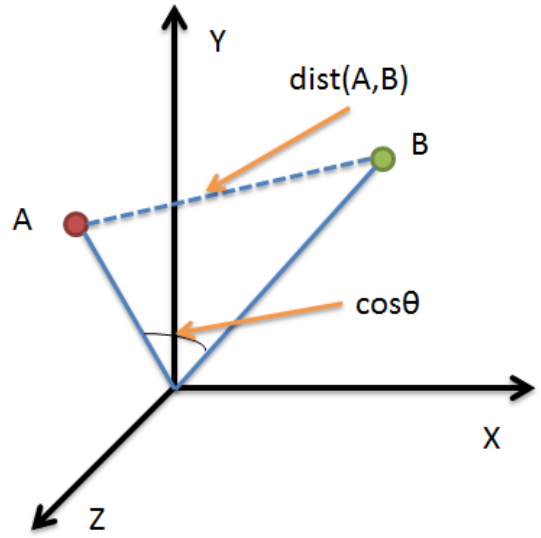
- 数学证明K-Means一定会收敛，大致思路是利用SSE的概念（也就是误差平方和），即每个点到自身所归属质心的距离的平方和，这个平方和是一个函数，然后能够证明这个函数是可以最终收敛的函数

4. 判断每个点归属哪个质心的距离怎么算？

- 欧几里德距离、明可夫斯基距离、切比雪夫距离、曼哈顿距离、马哈拉诺比斯距离、调整后的余弦相似度、Jaccard相似系数
- 欧几里德距离
- 余弦相似度，余弦相似度用向量空间中两个向量夹角的余弦值作为衡量两个个体间差异的大小。相比距离度量，余弦相似度更加注重两个向量在方向上的差异，而非距离或长度上

问题讨论

- 余弦相似度的余弦是哪个角的余弦，A，B是三维空间中的两个向量，这两个点与三维空间原点连线形成的角，如果角度越小，说明这两个向量在方向上越接近，在聚类时就归成一类：
  - 歌手大赛，三个评委给三个歌手打分，第一个评委打分（10，8，9） 第二个评委打分（4，3，2），第三个评委打分（8，9，10）
  - 如果采用欧氏距离， 第一和第三个评委的欧氏距离更近，就分成一类人了
    - 但其实不太合理，因为他们对于四位选手的排名都是完全颠倒的
  - 用余弦相似度来看，第一、第二个评委为一类人，第三个评委为另外一类
    - 如果采用余弦相似度来看每个评委的差异，虽然每个评委对同一个选手的评分不一样，但第一、第二两个评委对这四位歌手实力的排序是一样的，只是第二个评委对满分有更高的评判标准，说明第一、第二个评委对音乐的品味上是一致的



如果注重数值本身的差异，应该用欧氏距离，如果注重的是例中的这种的差异，就要用余弦相似度来计算

问题讨论

5. 度量问题

- 如果K-Means聚类中选择欧几里德距离计算距离，数据集出现了下述的情况
  - 比如X的单位是米，Y也是米，那么距离算出来的单位还是米，是有意义的。但是如果X是米，Y是吨，用距离公式计算就会出现“米的平方”加上“吨的平方”再开平方，最后算出的东西没有数学意义
    - 去除数据的单位限制，将其转化为无量纲的纯数值，便于不同单位或量级的指标能够进行计算和比较
  - 即使X和Y单位一致，但如果数据中X整体都比较小，比如都是1到10之间的数，Y很大，比如都是1000以上的数，那么，在计算距离的时候Y起到的作用就比X大很多，X对于距离的影响几乎可以忽略
    - 要进行数据标准化（normalization），即将数据按比例缩放，使之落入一个小的特定区间

问题讨论

标准化方法最常用的有两种：

- 1. min-max标准化（离差标准化）：对原始数据进行线性变换，使结果落到【0，1】区间，转换方法为 X'=（X-min）/（max-min），其中max为样本数据最大值，min为样本数据最小值
- 2. z-score标准化（标准差标准化）：处理后的数据符合标准正态分布（均值为0，方差为1），转换公式：X减去均值，再除以标准差

问题讨论

6. 每一轮迭代如何选出新的质心？

- 各个维度的算术平均
  - 比如（X1，Y1，Z1）、（X2，Y2，Z2）、（X3，Y3，Z3）那就新质心就是【（X1+X2+X3）/3，（Y1+Y2+Y3）/3，（Z1，Z2，Z3）/3】，这里要注意，新质心不一定是实际的一个数据点

7. 关于离群值？

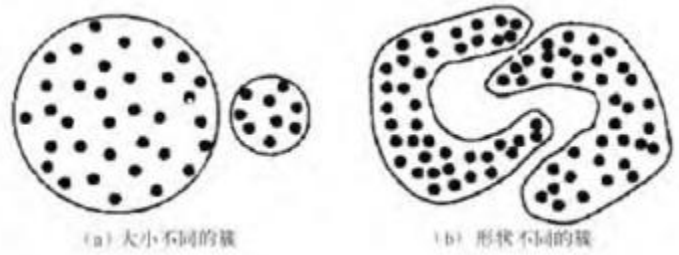
- 离群值就是远离整体的，非常异常、非常特殊的数据点，在聚类之前应该将这些“极大”“极小”之类的离群数据都去掉，否则会对于聚类的结果有影响。但是，离群值往往自身就很有分析的价值，可以把离群值单独作为一类来分析

The K-Means Clustering Method

K-均值算法 – 优劣

- **Strength** 优点
  - 复杂度: **O(tkn)**

    其中n 是对象的数目, k 是簇的数目, t 是迭代的次数. 通常k、t << n
- **Weakness** 缺点
  - 需要事先给出k，簇的数目
  - 对初始值选取敏感，常以 **局部最优** 结束



(a) 大小不同的簇　(b) 形状不同的簇

  - 不能处理噪声数据和孤立点，**对离群点敏感！**
  - 不适合发现非凸面形状的簇，或具有不同大小或密度的簇
    - 所采用的簇的表示及簇间相似性度量不能反映这些自然簇的特征
  - 只有在簇的平均值被定义的情况下才能使用，当涉及有分类属性的数据时该怎么办?

The K-Means Clustering Method

K-均值算法 – 优劣

- “不能处理噪声数据和孤立点，对离群点敏感！”
- 例
  - —一维空间7个点{1,2,3,8,9,10,25}
    - 直觉应该分为{1,2,3}、{8,9,10}，25是离群点
  - —使用k=2，进行k—均值
    - {1,2,3}、 {8,9,10,25}
      - 簇内变差计算$(1-2)^2 +(2-2)^2 +(3-2)^2 + +(8-13)^2 + (9-13)^2 + (10-13)^2 +(25-13)^2 =196$
    - {1,2,3,8}、 {9,10,25}
      - 簇内变差计算$(1-3.5)^2 +(2-3.5)^2 +(3-3.5)^2 +(8-3.5)^2 +(9-14.67)^2 + (10-14.67)^2 + +(25-14.67)^2 =189.67$
    - 由于离群点25的影响，使8被聚集到与8、10不同的簇
    - 簇中心偏离所有的簇成员

The K-Means Clustering Method

K-平均聚类算法 – 变种

- 一些变种k-平均方法在以下策略上有所不同
  - —通过簇的自动合并和分裂得到较为合理的簇数目K
  - — K个初始平均值的选择
  - — 相异度的计算
  - — 计算聚类平均值的策略

•标称属性数学运算没有意义

• 婚姻状况 = {单身、已婚、离异、丧偶}

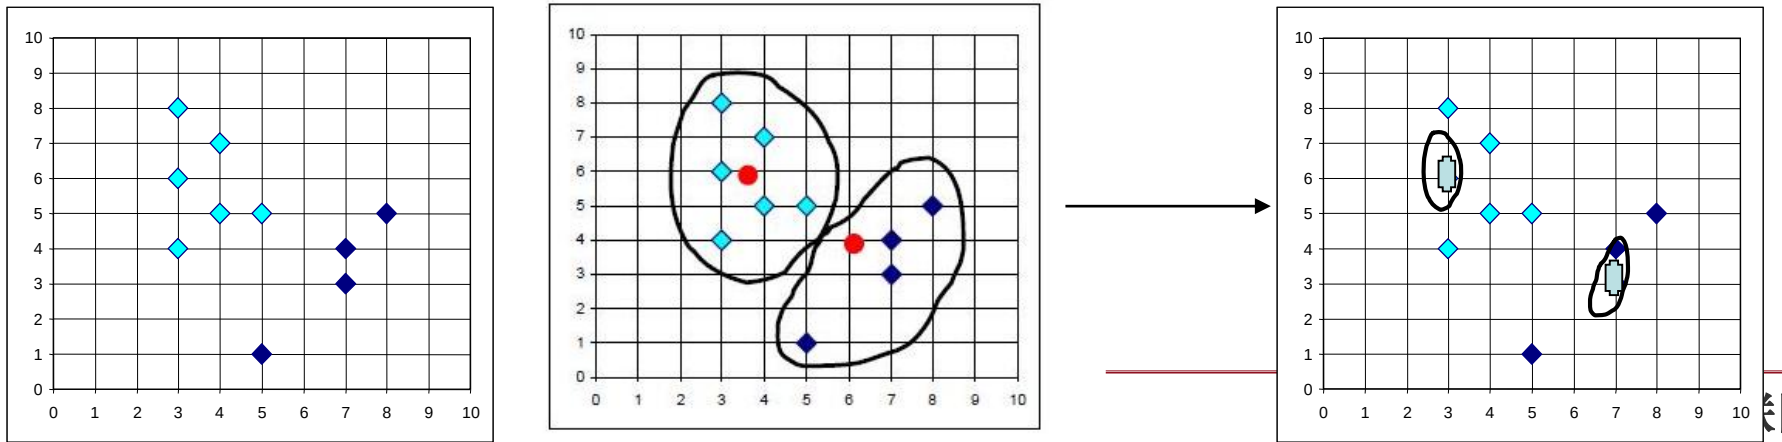
- 当簇的均值有定义时才能使用k—均值。在某些应用中，例如当涉及具有标称属性的数据时，均值可能无定义
  - —k-众数(k-modes)方法(Huang'98)
    - 用 众数 来代替聚类的平均值（集合中出现 最频繁 的值）
    - 使用新的相异性度量来处理分类对象
    - 采用基于 频率 的方法来修改聚类的众数
    - 分类数据和数值数据的综合：集成k-均值和k-众数方法

K-中心点：一种基于代表对象的技术
k-medoids

- **K-均值算法对离群点敏感！**
  - —一个有着很大值的对象能够大幅度地扭曲数据的分布
- **K-中心点：不采用簇中对象的均值作为参照点，而是挑选实际对象来代表簇，每个簇使用一个对象**
- **使用绝对误差标准**

$$E = \sum_{i=1}^{k} \sum_{p \in Ci} dist(p, o_i)$$

- **E是数据集中所有对象p与Ci的代表对象o_i的绝对误差之和**



K-中心点：一种基于代表对象的技术

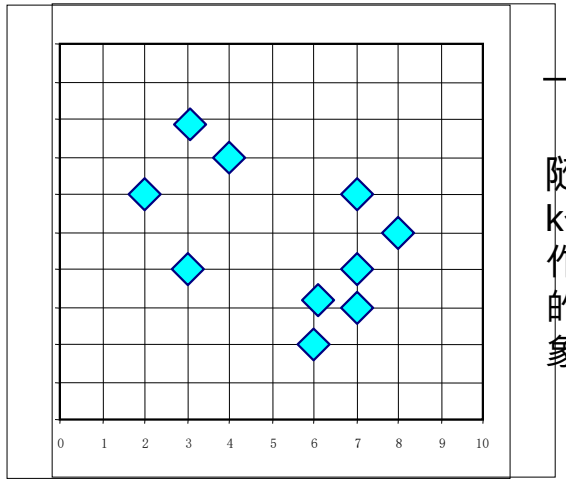
- K-中心点聚类方法，在时间O($k(k-n)^2$)内可找到准确中位数，K-中心点是NP-hard问题

— 对小数据集很有效，但对大数据集计算代价相当高

- PAM (Partitioning Around Medoids，围绕中心点的划分，1987)是K-中心点的一种流行的实现

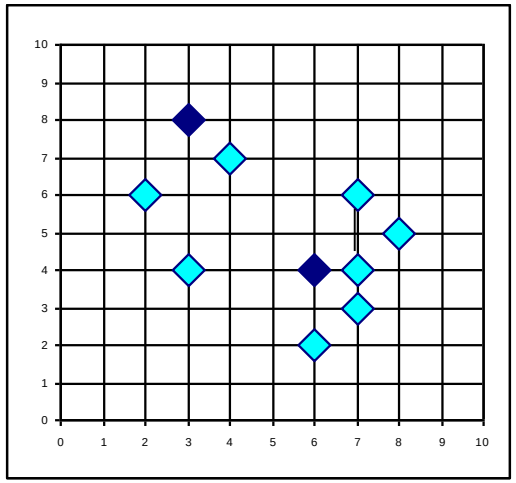
— 初始代表对象任意选取，接着重复地用一个非代表对象代替代表对象，如果它改善了结果聚类的整体距离则替换

PAM聚类



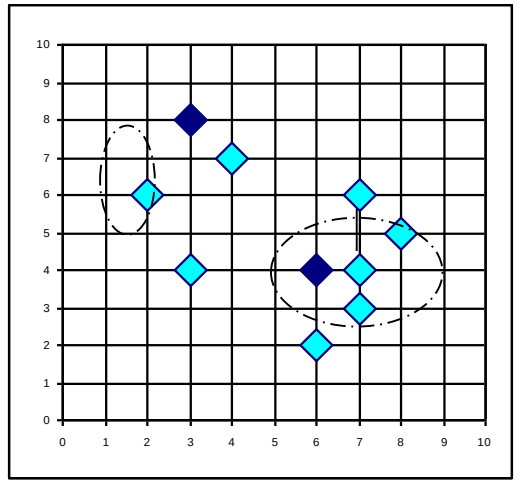
K=2

随机选取k个对象作为初始的代表对象

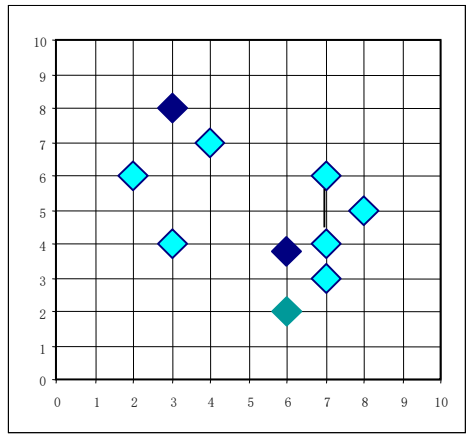


剩余对象分配到最近的代表对象所代表的簇

Total Cost = 20

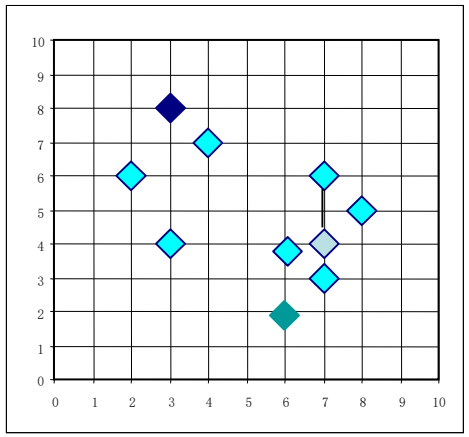


随机选择一个非代表对象，O_{ramdom}



计算交换的总代价

Total Cost = 26



如果质量提升交换O 和 O_{ramdom}

不断循环

直到没有变化

PAM聚类的算法流程

算法：*k*-中心点。PAM，一种基于中心点或中心对象进行划分的*k*-中心点算法。

输入：

- *k*：结果簇的个数。
- *D*：包含*n*个对象的数据集合。

输出：*k*个簇的集合。

方法：

（1）从*D*中随机选择*k*个对象作为初始的代表对象或种子；

（2）**repeat**

（3）　　将每个剩余的对象分配到最近的代表对象所代表的簇；

（4）　　随机地选择一个非代表对象o_{random}；

（5）　　计算用o_{random}代替代表对象o_j的总代价*S*；

（6）　　**if** *S*<0，**then** o_{random}替换o_j，形成新的*k*个代表对象的集合；

（7）**until**不发生变化；

PAM聚类的改进

- 基于 PAM 的改进

— CLARA (Kaufmann & Rousseeuw, 1990)

—Clustering Large Application，大型应用聚类

— CLARANS (Ng & Han, 1994): 随机的样本

—Clustering Large Application based upon RANdmised Search，基于随机搜索的聚类大型应用

PAM聚类的改进—CLARA

- CLARA并不考虑整个数据集合，而是使用数据集的一个随机样本，然后使用PAM方法由样本计算最佳中心点。
- 理论上，样本应该近似地代表原数据集。在许多情况下，大样本都很有效，如果每个对象都以相同的概率被选到样本中的话。被选中的代表对象（中心点）非常类似于从整个数据集选取的中心点。由多个随机样本建立聚类，并返同最佳的聚类作为输出。
- 在一个随机样本上计算中心点的复杂度为$O(ks^2+k(n-k))$，其中s是样本的大小，k是簇数，n是对象的总数。
- 能够处理的数据集比PAM更大
- CLARA的有效性依赖于样本的大小，如果一个对象是最佳中心点之一，但它在抽样时没有被选中，则CLARA将永远不能找到最佳聚类

PAM聚类的改进—CLARANS

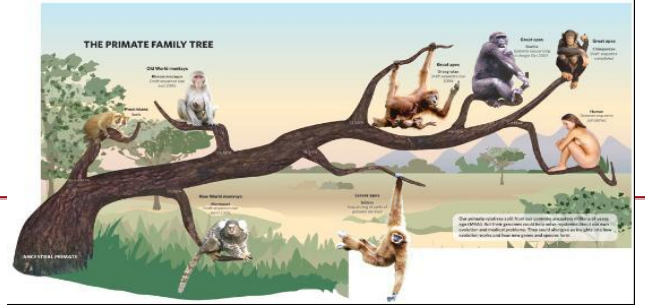
- PAM在搜索最佳中心点时，针对每个当前中心点考察数据集的每个对象
- **CLARA**把候选中心点仅局限在数据集的一个随机样本上

- **CLARANS**在数据集中随机选择k个对象作为当前中心点。然后，它随机地选择一个当前中心点X和一个不是当前中心点的对象y。用y替换X能够改善绝对误差吗？如果能，则进行替换。 **CLARANS**进行这种随机搜索L次，L步之后的中心点的集合被看做一个局部最优解。
- **CLARANS**重复以上随机过程m次，并返回最佳局部最优解作为最终的结果

Chapter 1. Cluster Analysis 聚类

- Cluster Analysis: Basic Concepts 基本概念
- Partitioning Methods 划分方法
- **Hierarchical Methods 层次方法**
- Density-Based Methods 基于密度的方法
- Grid-Based Methods 基于网格的方法
- Evaluation of Clustering 聚类方法的评估

Hierarchical Clustering

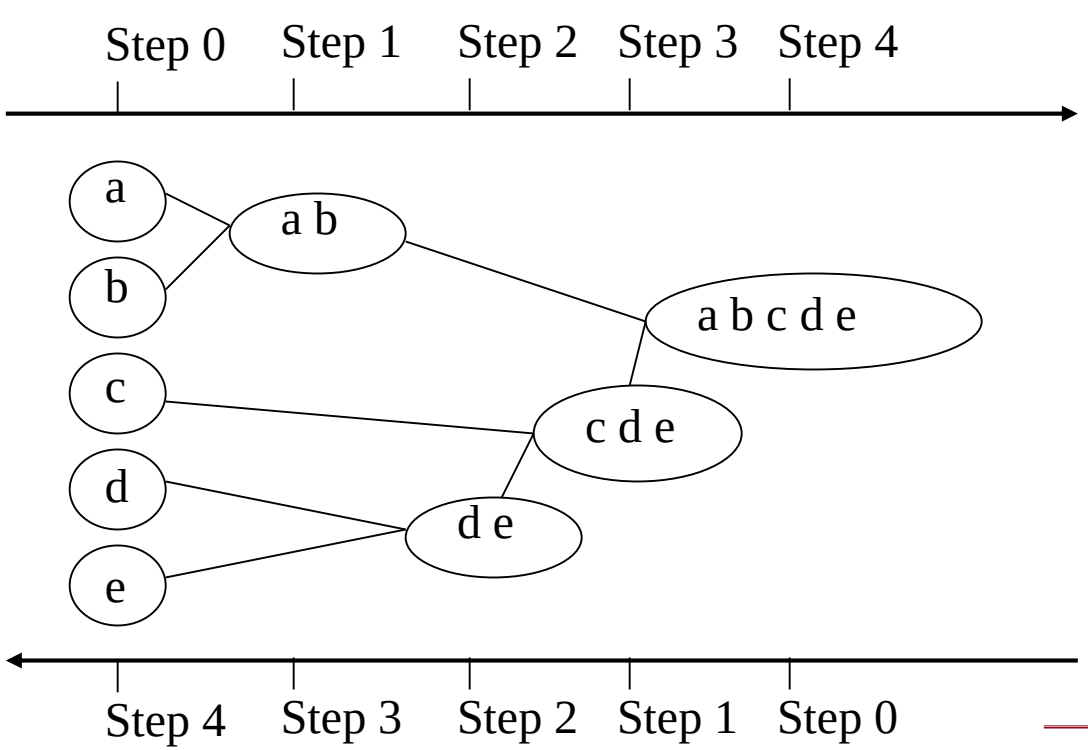


- 我们想把数据划分成不同层上的组群……

可以很容易地对组织在层次结构中的数据进行汇总或特征化

在某些应用中，可能数据具有我们想要发现的基本层次结构

- 使用距离矩阵作为聚类的标准，这种方法不需要簇的数目k作为输入，但需要一个中止条件



凝聚的
(AGNES)

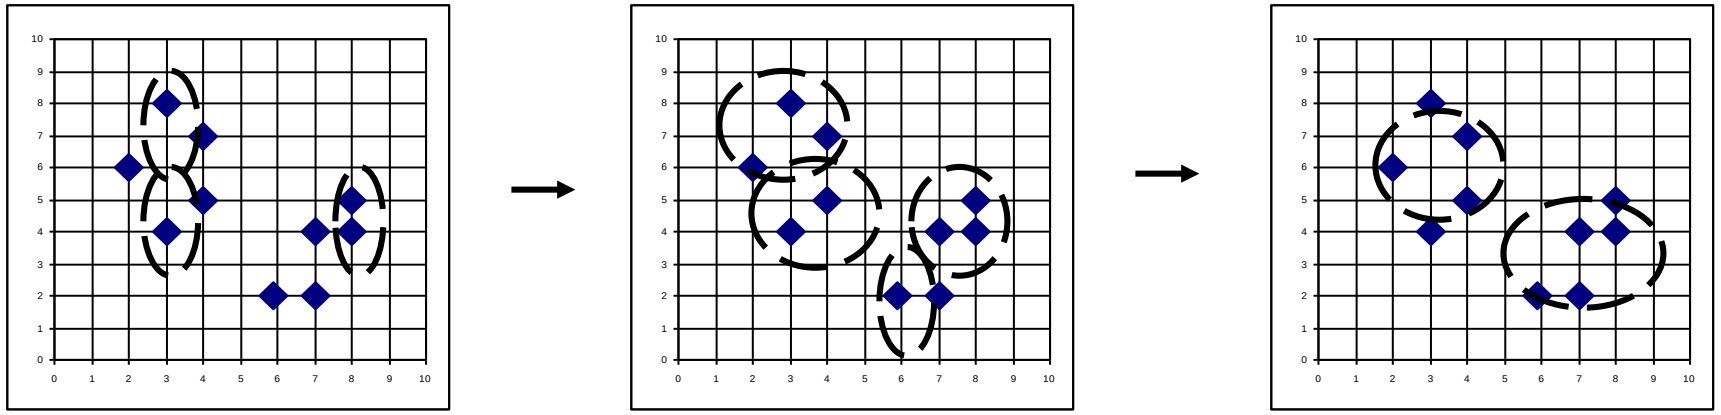
两种
层次
方法

分裂的
(DIANA)

AGNES (Agglomerative NESting)

凝聚的层次聚类方法

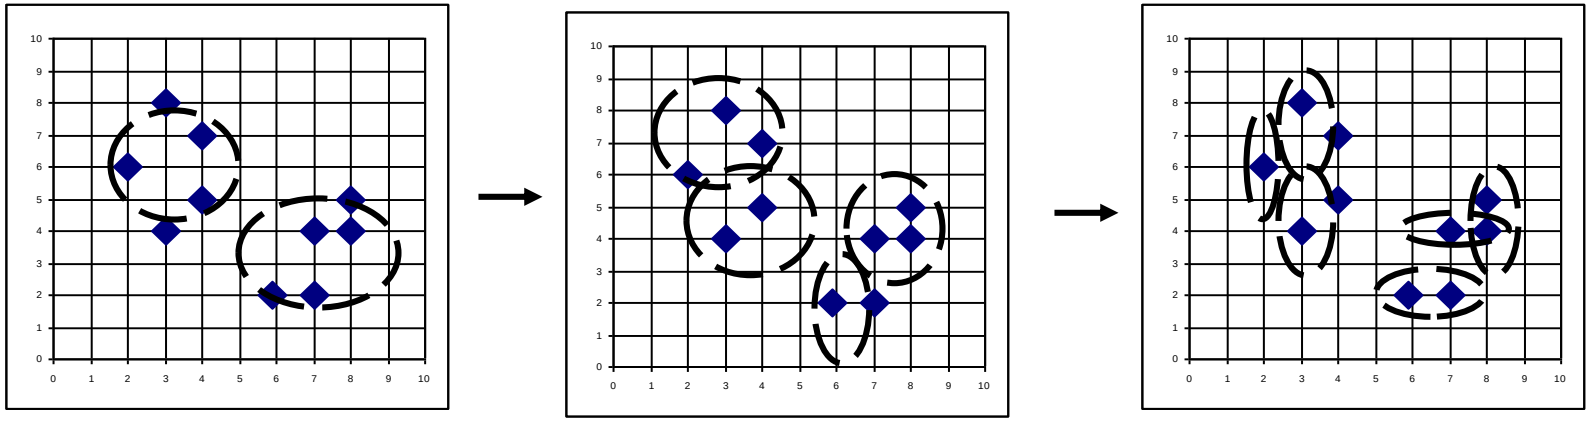
- 使用单连接方法和相异矩阵
- 合并最小相异的结点
- 以一个非下降的模式进行（自底向上）
- 最终所有的结点属于同一个簇



DIANA (Divisive Analysis)

分裂的层次聚类方法

- 与AGNES算法相反，自顶向下
- 最终每一个结点形成只包含它本身的簇



Hierarchical Clustering 层次聚类

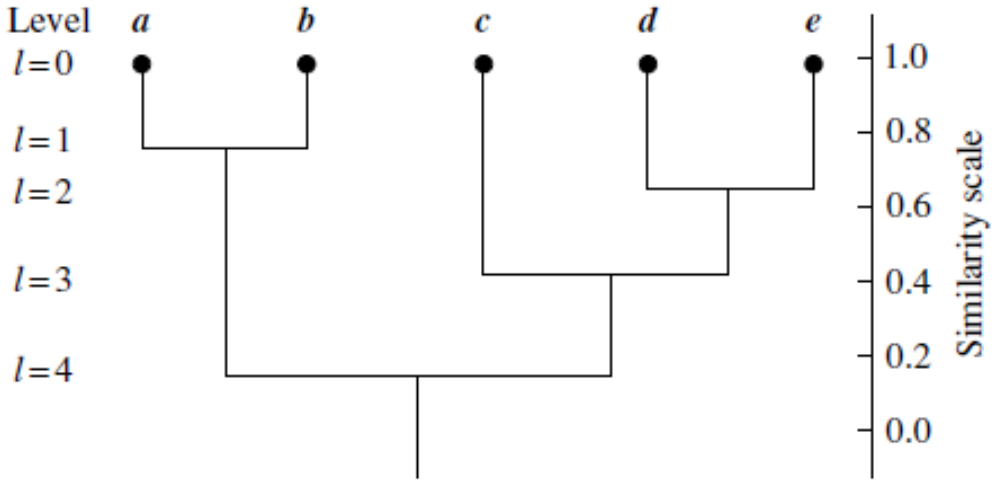
- 分裂方法的一个挑战是如何把一个大簇划分成几个较小的簇
  - —例如，把n个对象的集合划分成两个互斥的子集有$2^{n-1}-1$种可能的方法，其中n是对象数。当n很大时，考察所有的可能性的计算量是令人望而却步的。
  - —分裂方法通常使用启发式方法进行划分，但可能导致不精确的结果。
- 为了效率，分裂方法通常不对已经做出的划分决策回溯。一旦一个簇被划分，该簇的任何可供选择其他划分都不再考虑。由于分裂方法的这一特点，凝聚方法远比分裂方法多。

Dendrogram: Shows How Clusters are Merged

表示聚类是怎样被层次的合并 —— 树状图

树状图：把数据对象分解成几个嵌套的划分（树的簇）

数据对象聚类的获得是通过在期望的层次上进行分割，接着每一个相连的部分形成一个簇



算法方法的距离度量

- 4个广泛采用的簇间距离度量方法：
- 最小距离：$dist_{min}(C_i, C_j) = \min_{p \in C_i, p' \in C_j} \{|p - p'|\}$
- 最大距离：$dist_{max}(C_i, C_j) = \max_{p \in C_i, p' \in C_j} \{|p - p'|\}$
- 均值距离：$dist_{mean}(C_i, C_j) = |m_i - m_j|$
- 平均距离：$dist_{avg}(C_i, C_j) = \frac{1}{n_i n_j} \sum_{p \in C_i, p' \in C_j} |p - p'|$
- 其中|p – p’|是两个对象或点p和p’之间的距离，m_i是簇Ci的均值，n_i是簇Ci中对象的数目
- 这些度量又称为连接度量

算法方法的距离度量 Cont.

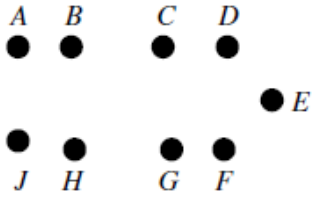
- 当使用最小距离$dist_{min}(Ci,Cj)$衡量簇间距离时：
  - —有时称它为最近邻聚类算法
  - —如果最近的两个簇间距离超过用户给定的阈值时聚类过程终止（单连接算法）
- 把数据点看做图的结点，边构成簇内结点间的路径，两个簇Ci和Cj的合并就对应于在Ci和Cj的最近的一对结点之间添加一条边。连接簇的边总是一个簇通往另一个簇，结果形成一棵树
  - —使用最小距离度量的凝聚层次聚类算法也被称为最小生成树算法
  - —其中图的生成树是一棵连接所有结点的树，而最小生成树是具有最小边权重和的生成树

算法方法的距离度量 Cont.

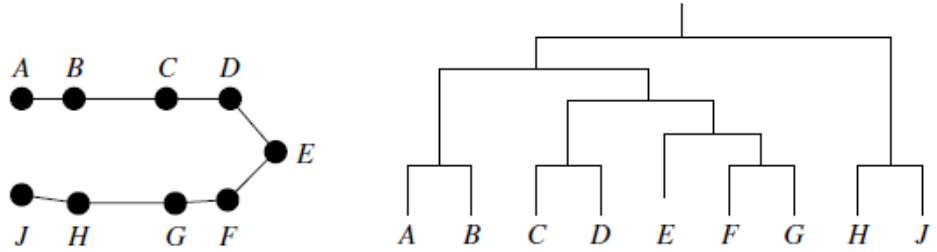
- 当使用最大距离$dist_{max}(Ci,Cj)$衡量簇间距离时：
  - —有时称它为最远邻聚类算法
  - —两个簇间的距离由两个簇中距离最远的结点间的距离确定。如果最近的两个簇间最大距离超过用户给定的阈值时聚类过程终止（全连接算法）
- 把数据点看做图的结点，边连接结点，每个簇为完全子图
- 最远邻算法试图在每次迭代中尽可能少地增加簇的直径。如果真实的簇较为紧凑并且大小近似相等，则这种方法将会产生高质量的簇，否则产生的簇可能毫无意义

算法方法的距离度量 Cont.

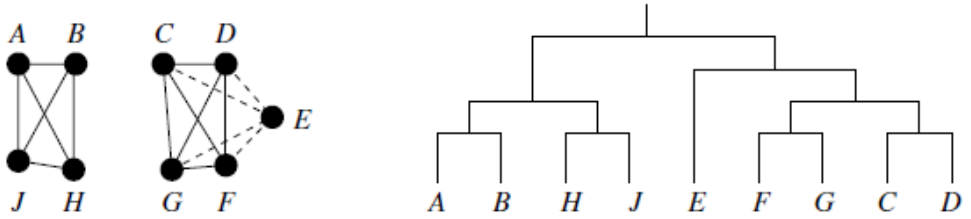
- 通过单连接，我们可以发现由局部邻近性定义的分层的簇，而全连接则趋向发现由全局邻近性选择的簇



(a) Data set



(b) Clustering using single linkage



(c) Clustering using complete linkage

Extensions to Hierarchical Clustering

更多关于层次聚类方法

- 凝聚的层次聚类方法的主要缺点
  - —伸缩性不够好: 时间复杂度最小为$O(n^2)$, n是全体对象的数目
  - —先前已做的处理不能被撤销

为了提高层次方法聚类质量——多阶段聚类……

- 层次聚类和基于距离聚类的集成
  - —BIRCH (1996): 使用CF树，增量的调整子聚类的质量
  - —CHAMELEON (1999): 采用动态模型的聚类方法

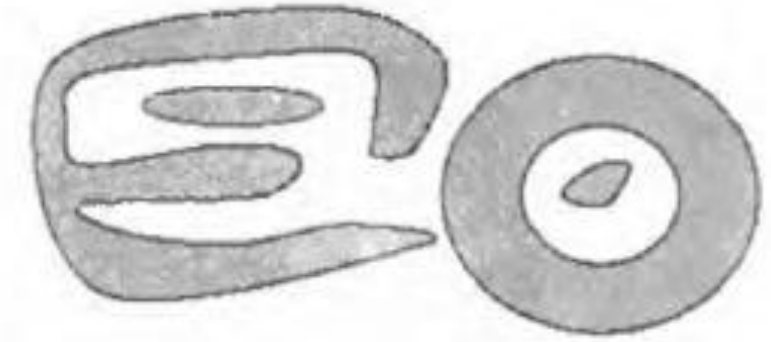
Chapter 1. Cluster Analysis 聚类

- Cluster Analysis: Basic Concepts 基本概念
- Partitioning Methods 划分方法
- Hierarchical Methods 分层方法
- **Density-Based Methods 基于密度的方法**
- Grid-Based Methods 基于网格的方法
- Evaluation of Clustering 聚类方法的评估

Density-Based Clustering Methods
基于密度的聚类方法

划分和层次方法很难发现球状簇以外的簇……

- 基于密度的簇
  - —密度相连的点的集合
  - —数据空间中被稀疏区域分开的稠密区域
- 主要特点：
  - — 发现任意形状的簇
  - — 能处理噪声
  - — 只需一次扫描
  - — 需要密度参数作为终结条件



- 几个有趣的研究：
  - — DBSCAN: Ester, et al. (KDD'96)
  - — OPTICS: Ankerst, et al (SIGMOD'99)
  - — DENCLUE: Hinneburg & D. Keim (KDD'98)

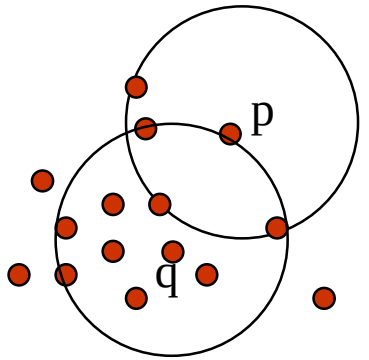
Density-Based Clustering: Basic Concepts

基于密度的聚类: 背景知识

- 两个参数：
  - Eps: 邻域的最大半径
  - MinPts: 一个对象的Eps-邻域至少包含的对象数
- $N_{Eps}(q)$: {p ∈D | dist(p,q) <= Eps}

- 直接密度可达: 一个对象p是从对象q关于Eps, MinPts直接密度可达的，如果
  - 1) p 属于$N_{Eps}(q)$
  - 2) 核心对象的条件:

    |NEps (q)| >= MinPts



MinPts = 5

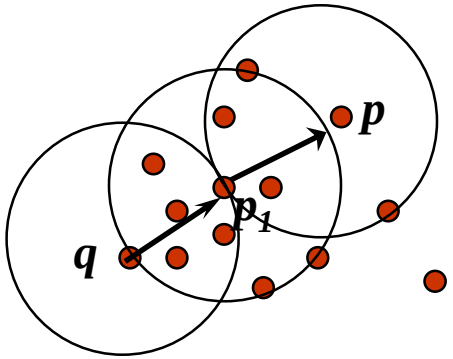
Eps = 1 cm

Density-Reachable and Density-Connected

基于密度的聚类: 背景(II)

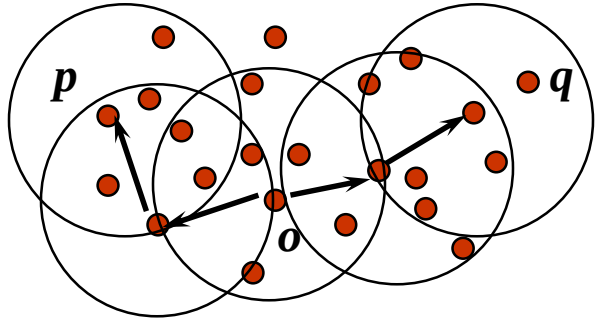
- **密度可达的:**

  一个对象p从对象q关于Eps,和MinPts是**密度可达**的， 如果存在一个对象链p1, …, pn, p1 = q, pn= p pi+1 是从pi关于Eps,和MinPts直接密度可达的



- **密度相连的:**

  如果存在一个对象o，使得对象p和q是从o关于Eps和MinPts 密度可达的，那么对象p和q是关于Eps和MinPts **密度相连**的

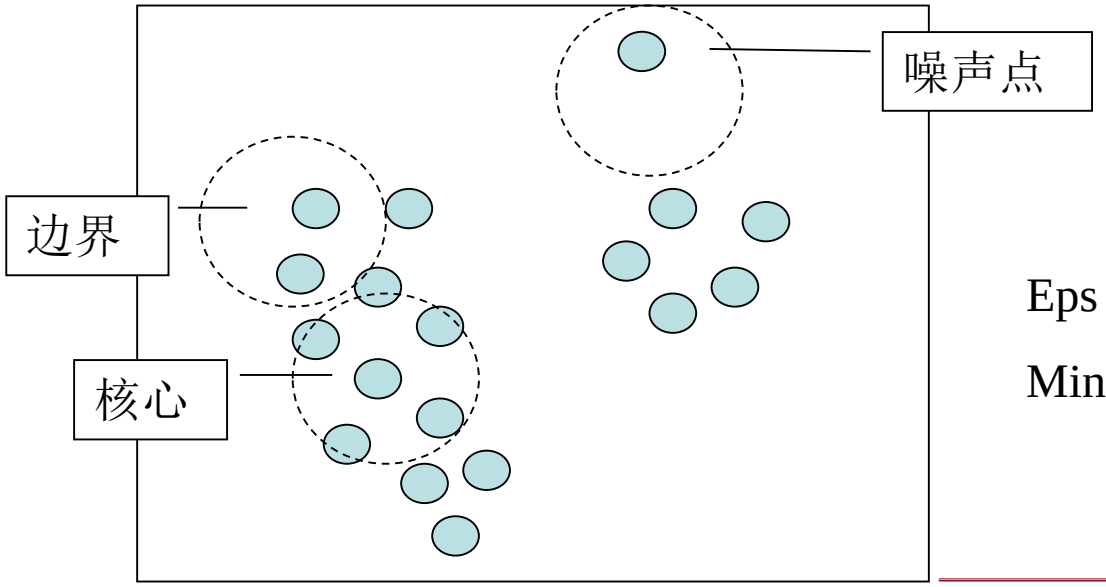


Density-Based Clustering Methods
基于密度的聚类方法

- DBSCAN: Ester, et al. (KDD'96)
- OPTICS: Ankerst, et al (SIGMOD'99)
- DENCLUE: Hinneburg & D. Keim (KDD'98)

DBSCAN

- 基于高密度连接区域的密度聚类方法
  - —Density-Based Clustering Based on Connected Regions with High Density
- 依赖簇的基于密度的思想：它定义簇为密度相连的点的最大集合
- 在带有“噪声”的空间数据库中发现任意形状的聚类



Eps = 1cm

MinPts = 5

DBSCAN: The Algorithm

DBSCAN: 算法

- 任意选择一个点p
- 找出从对象p 关于Eps 和MinPts.密度可达的所有点
- 如果是一个核心对象，则一个聚类就形成了
- 如果p 是一个边界点，没有从p密度可达的对象，DBSCAN则访问数据库中的其他点
- 继续这个过程，直到所有的点被处理

DBSCAN聚类实例

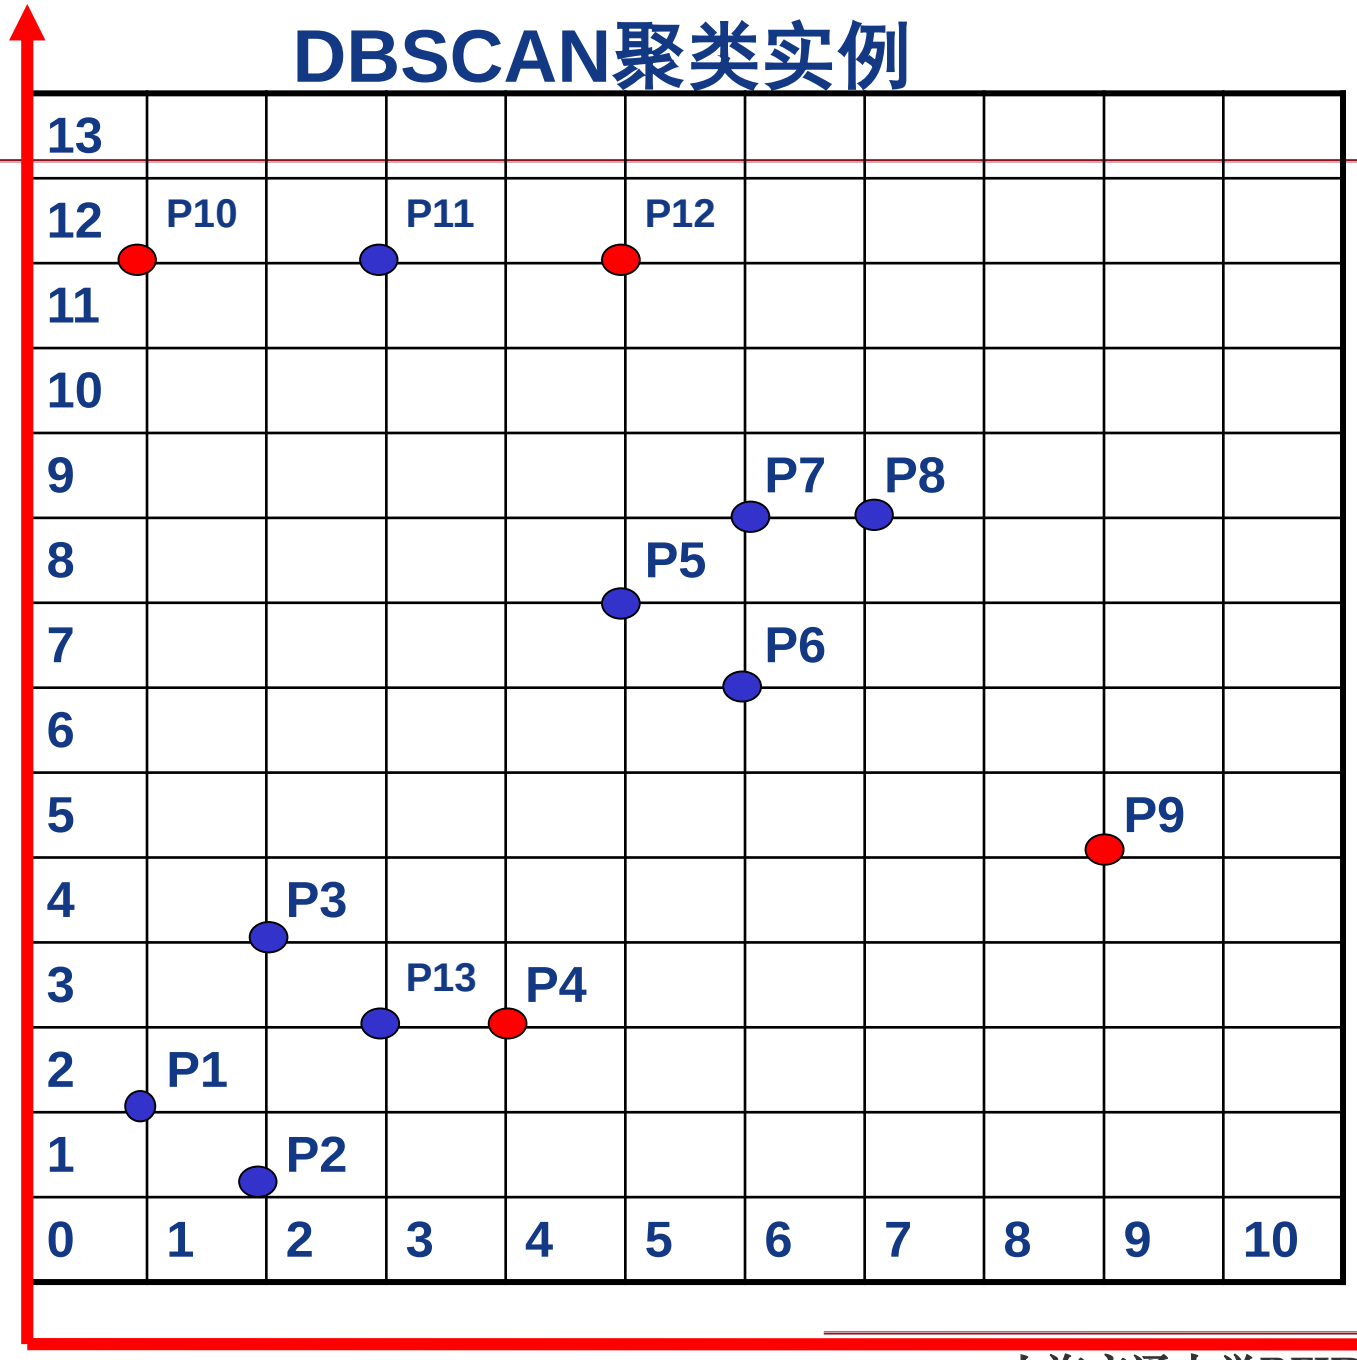
- 二维平面上的数据集，取Eps=3，MinPts=3，使用曼哈顿距离演示DBSCAN算法的聚类过程

P1	P2	P3	P4	P5	P6	P7	P8	P9	P10	P11	P12	P13
1	2	2	4	5	6	6	7	9	1	3	5	3
2	1	4	3	8	7	9	9	5	12	12	12	3

DBSCAN聚类实例

Eps=3

MinPts=3



DBSCAN聚类过程

- （1）随机选择一个点P1，其邻域中包含{P1,P2,P3,P13} ,P1是核心点，其邻域中的点构成簇1的一部分，依次检查P2、P3和P13的Eps邻域，进行扩展，将点P4并入，P4是边界点
- （2）检查P5，其Eps邻域中包含{P5,P6,P7,P8}，P5是核心点，其邻域中的点构成簇2，依次检查P6、P7和P8的Eps邻域，每个点都是核心点，但不能扩展簇
- （3）检查P9，其Eps邻域中包含{P9}，P9是噪声点
- （4）检查P10，其Eps邻域中包含{P10,P11}，P10是噪声点或边界点，检查P11，其Eps邻域中包含{P10,P11,P12} ，P11是核心点，其邻域中的点构成簇3；进一步检查， P10、P12为边界点

DBSCAN算法 Cont.

Algorithm: DBSCAN: a density-based clustering algorithm.

Input:

- D: a data set containing n objects,
- ϵ: the radius parameter, and
- *MinPts*: the neighborhood density threshold.

Output: A set of density-based clusters.

Method:

```
(1)  mark all objects as unvisited;
(2)  do
(3)      randomly select an unvisited object p;
(4)      mark p as visited;
(5)      if the ε-neighborhood of p has at least MinPts objects
(6)          create a new cluster C, and add p to C;
(7)          let N be the set of objects in the ε-neighborhood of p;
(8)          for each point p' in N
(9)              if p' is unvisited
(10)                 mark p' as visited;
(11)                 if the ε-neighborhood of p' has at least MinPts points,
                         add those points to N;
(12)             if p' is not yet a member of any cluster, add p' to C;
(13)         end for
(14)         output C;
(15)     else mark p as noise;
(16) until no object is unvisited;
```

DBSCAN: Sensitive to Parameters

Figure 8. DBScan results for DS1 with MinPts at 4 and Eps at (a) 0.5 and (b) 0.4.

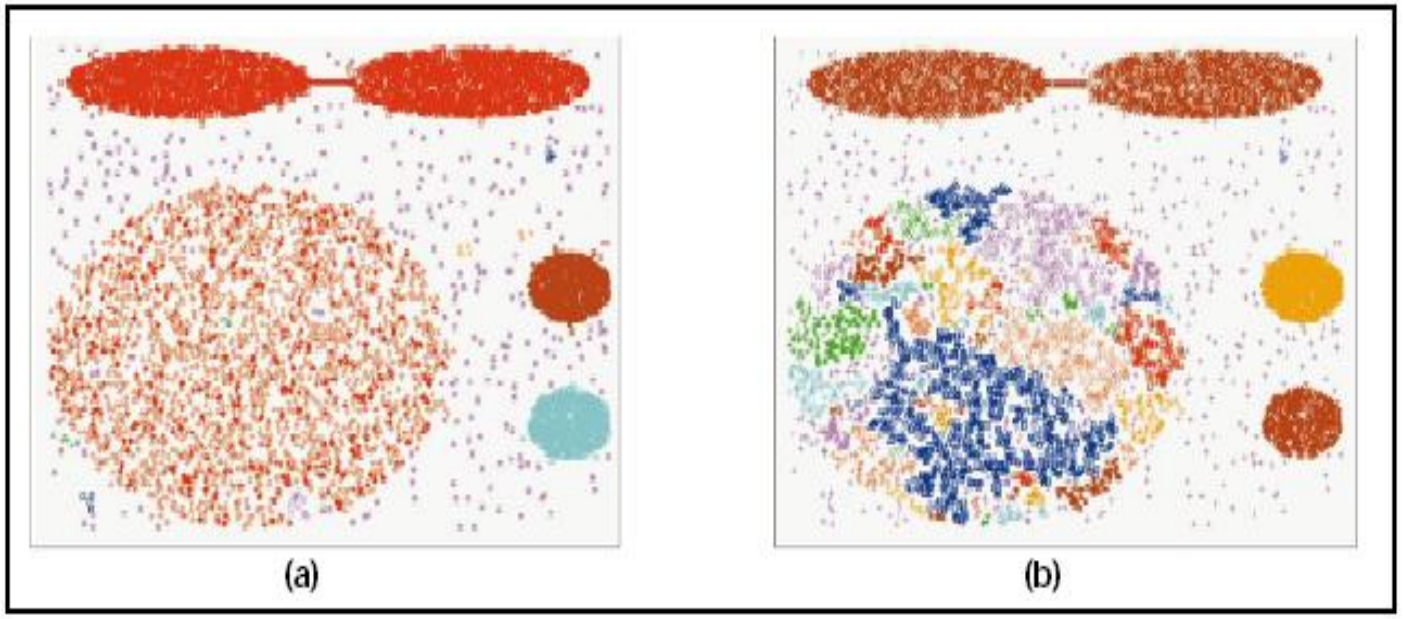
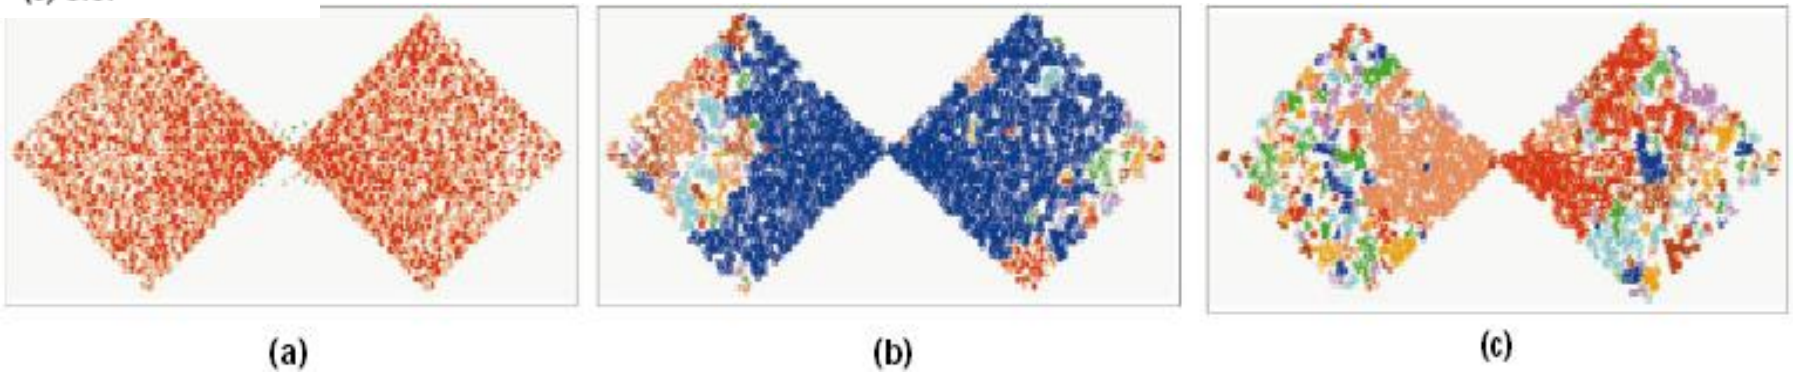


Figure 9. DBScan results for DS2 with MinPts at 4 and Eps at (a) 5.0, (b) 3.5, and (c) 3.0.

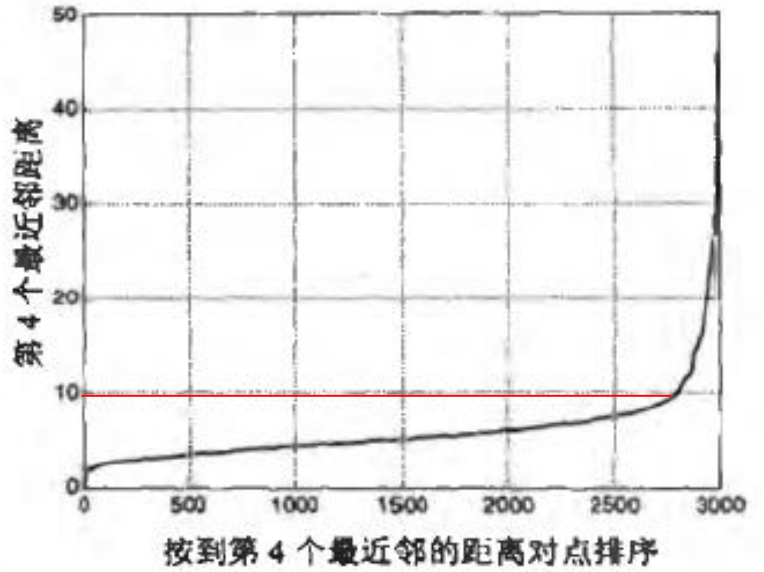


参数Eps和MinPts的确定方法

- 基本方法是观察点到它的k个最近邻的距离（称为k-距离）的特性。对于属于某个簇的点， 如果k不大于簇的大小的话，则k距离将很小。对于不在簇中的点（如噪声点），k-距离将相对较大
- 如果对于某个k，计算所有点的k-距离，以递增次序将它们排序，然后绘制排序后的值，则会看到k-距离的急剧变化，对应于合适的Eps值。
- 如果选取该距离为Eps参数，而取k的值为MinPts参数，则k-距离小于Eps的点将被标记为核心点，而其他点将被标记为噪声或边界点。



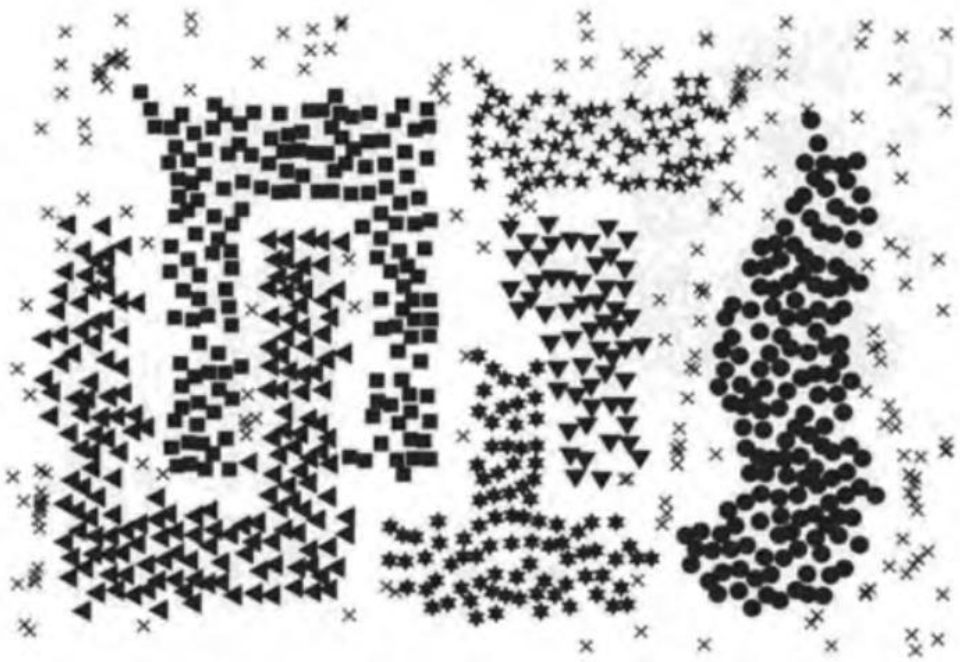
样本数据

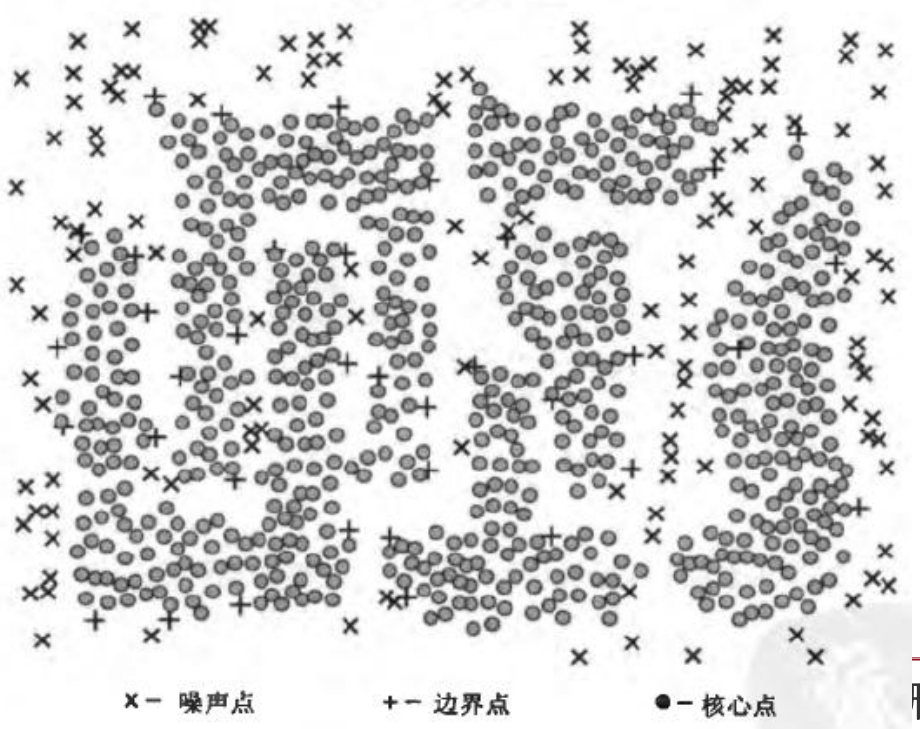


样本数据的 k-距离图

DBSCAN的计算例

- MinPts=4，Eps=10

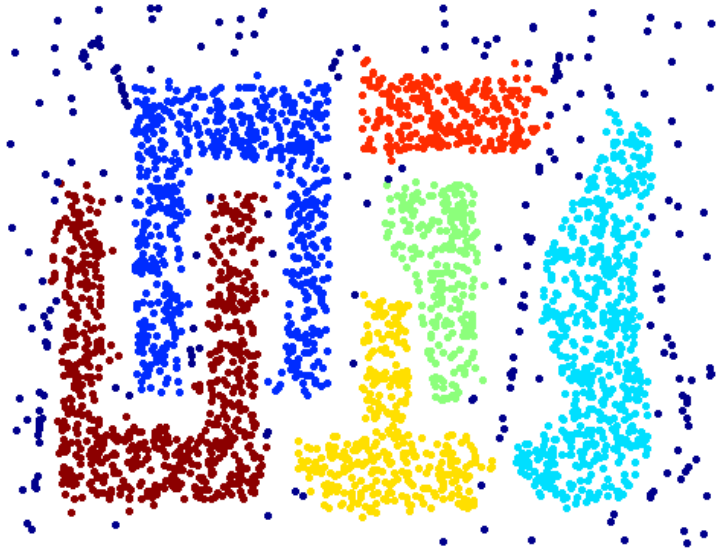




When DBSCAN Works Well



Original Points



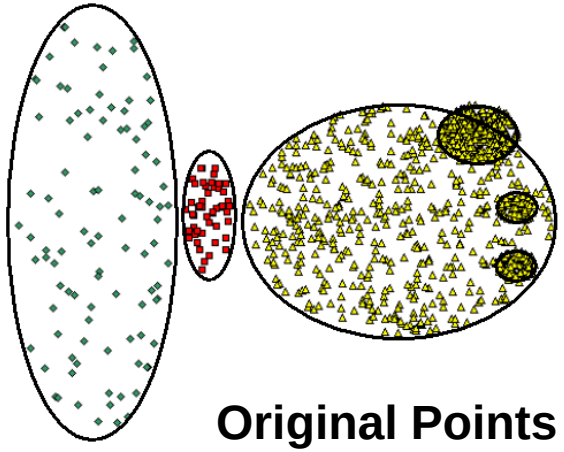
Clusters

- Resistant to Noise
- Can handle clusters of different shapes and sizes

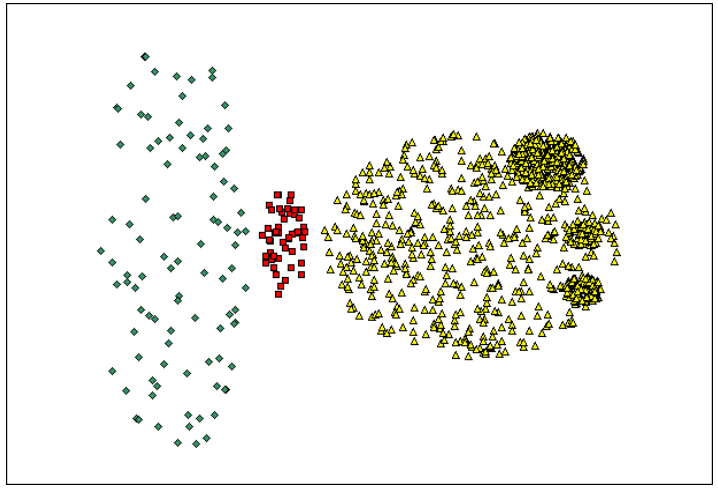
参数Eps和MinPts的确定方法

- 用这种方法决定的Eps值取决于k，但并不随k改变而剧烈变化。
  - 如果k的值太小，则少量邻近点的噪声或离群点将可能不正确地标记为簇。
  - 如果k的值太大，则小簇（尺寸小于k的簇）可能会被标记为噪声。
- 最初的DBSCAN算法取k=4，对于大部分二维数据，经验表明是一个合理值。

When DBSCAN Does NOT Work Well

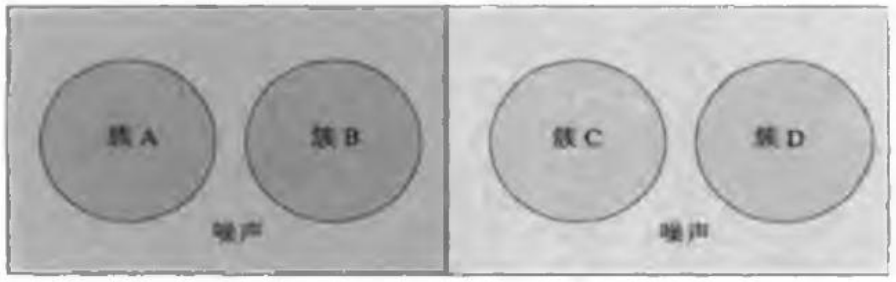


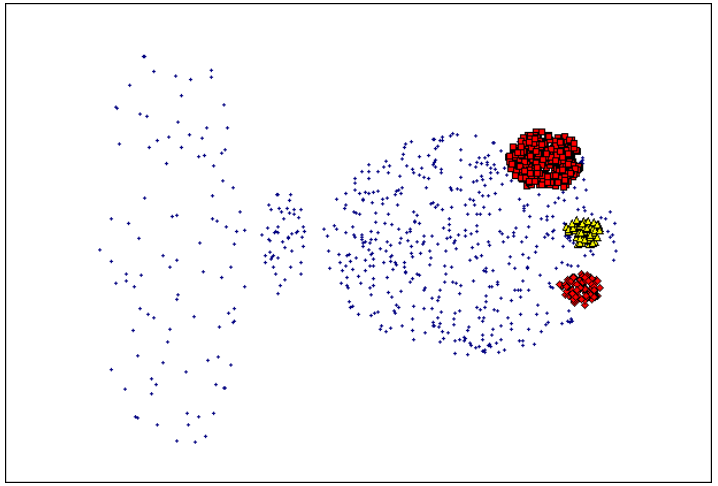
Original Points



(MinPts=4, Eps=9.75).

- **Varying densities**
- **High-dimensional data**（密度难以定义）





(MinPts=4, Eps=9.92)

Density-Based Clustering Methods
基于密度的聚类方法

- DBSCAN: Ester, et al. (KDD'96)
- OPTICS: Ankerst, et al (SIGMOD'99)
- DENCLUE: Hinneburg & D. Keim (KDD'98)

Chapter 1. Cluster Analysis 聚类

- Cluster Analysis: Basic Concepts 基本概念
- Partitioning Methods 划分方法
- Hierarchical Methods 分层方法
- Density-Based Methods 基于密度的方法
- **Grid-Based Methods 基于网格的方法**
- Evaluation of Clustering 聚类方法的评估

Grid-Based Clustering Method

基于网格的聚类方法基本原理

- 网格是一种组织数据集的有效方法，至少在低维空间中如此。
- 基本思想
  - 将每个属性的可能值分割成许多相邻的区间，创建网格单元的集合（我们假定属性值是序数的、区间的或连续的）。
  - 每个对象落入一个网格单元，网格单元对应的属性区间包含该对象的值。
  - 扫描一遍数据就可以把对象指派到网格单元中，并且还可以同时收集关于每个单元的信息，如单元中的点数。

Grid-Based Clustering Method

基于网格的聚类方法基本算法

- 1：定义一个网格单元集
- 2：将对象指派到合适的单元，并计算每个单元的密度
- 3：删除密度低于指定的阈值的单元
- 4：由邻近的稠密单元组形成簇

Grid-Based Clustering Method

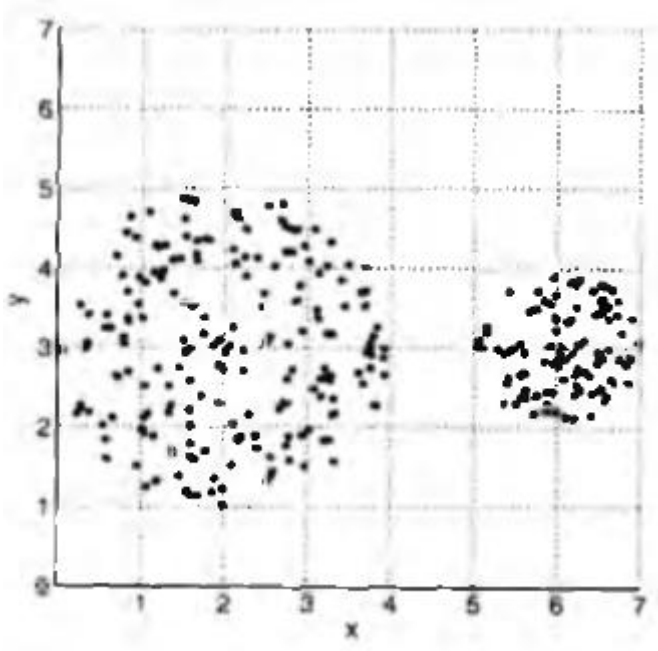
基于网格的聚类方法基本算法

- 1、定义网格单元
  - —这是过程的关键步骤，但是定义也最不严格，因为存在许多方法将每个属性的可能值分割成许多相邻的区间。
  - —对于连续属性，一种常用的方法是将值划分成等宽的区间。如果该方法用于所有的属性，则结果网格单元都具有相同的体积，而单元的密度可以方便地定义为单元中点的个数。
  - —然而，也可以使用更复杂的方法。
- 2、网格单元的密度
  - —定义网格单元密度的一种自然方法是：定义网格单元（或更一般形状的区域）的密度为该区域中的点数除以区域的体积。换言之，密度是每单位空间中的点数，而不管空间的维度。

Grid-Based Clustering Method

基于网格的聚类方法基本算法

- 显示了两个二维点的集合，使用7 乘7 的网格划分成49个单元。第一个集合包含200个点，由圆心在（2,3）、半径为2 的圆上的均匀分布产生。而第二个集合包含100个点，由圆心在（6,3）、半径为1的圆上均匀分布产生。
- 由于单元具有相等的体积（面积），可以将这些值看作单元的密度。



0	0	0	0	0	0	0
0	0	0	0	0	0	0
4	17	18	6	0	0	0
14	14	13	13	0	18	27
11	18	10	21	0	24	31
3	20	14	4	0	0	0
0	0	0	0	0	0	0

网格单元的点计数

基于网格的密度

3、由稠密网格单元形成簇

—由邻接的稠密单元组形成簇是相对简单

—使用密度之外的信息也可以加强基本的基于网格的聚类算法。在许多情况下，数据具有空间和非空间属性。换言之，某些属性描述对象的时间或空间位置，而另一些属性描述对象的其他方面。一个常见的例子是房子，它具有位置和许多其他特性，如价格或占地面积。由于空间（或时间）的的相关性，一个特定单元中的对象通常在其他属性上也具有类似的值。在这些情况下，有可能基于一个或多个非空间属性的统计性质（如平均房价〉对单元进行过滤，然后根据剩下的点的密度形成簇。

Grid-Based Clustering Method

基于网格的聚类方法优缺点

- 优点
  - 基于网格的聚类可能是非常有效的。给定每个属性的划分，单遍数据扫描就可以确定每个对象的网格单元和每个网格单元的计数
  - 尽管潜在的网格单元数可能很高，但是只需要为非空单元创建网格单元
- 缺点
  - 基于网格的聚类非常依赖于密度阈值的选择。如果阈值太高，则簇可能丢失。如果阈值太低，则本应分开的两个簇可能被合并。此外，如果存在不同密度的簇和噪声，则也许不能找到适用于数据空间所有部分的单个阈值
  - 矩形网格单元不能准确地捕获圆形边界区域的密度
  - 随着维度的增加，网格单元个数迅速增加随维度指数增加。尽管不必明显地考虑空网格单元，但是大部分网格单元都只包含单个对象的情况很容易发生。换言之，对于高维数据，基于网格的聚类效果将会很差。

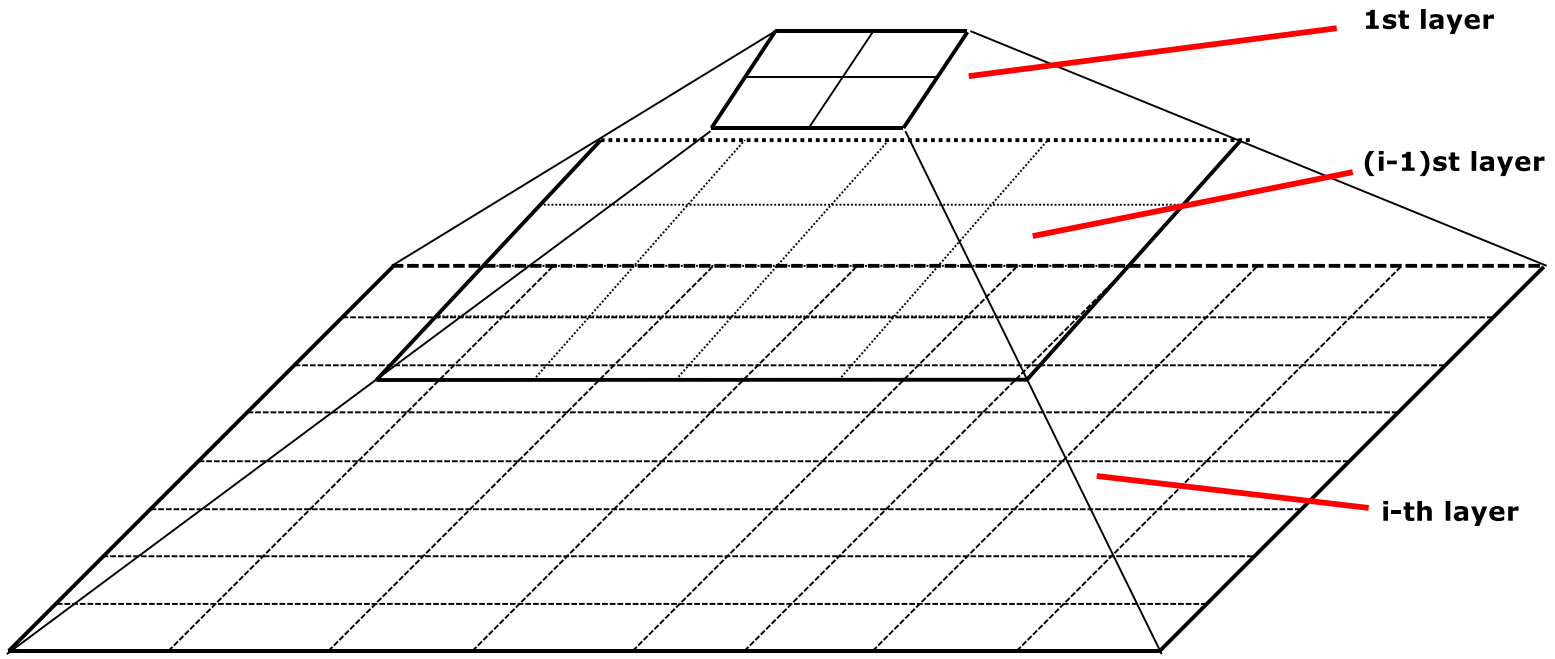
Grid-Based Clustering Method
基于网格的聚类方法

- 几种代表性的方法
  - **STING (a STatistical INformation Gridapproach) (1997年)**
  - **CLIQUE(SIGMOD'98)**
  - **WaveCluster(VLDB'98)**
    - 一个采用小波变换方法的多分辨率聚类算法
  - **……**

STING: A Statistical Information Grid Approach

STING: 统计信息网格方法

- 将空间区域划分成矩形单元
- 针对不同级别的分辨率，通常存在不同级别的矩形单元



The STING Clustering Method

STING:统计信息网格方法(2)

- 高层的每个单元被划分成多个低一层的单元
- 每个单元属性的统计信息被预先计算和存储
- 高层单元的统计参数很容易从低层单元的计算得到，这些参数包括：
  - Count(计数), mean(平均值), s(标准差), min(最小值), max(最大值)
  - 分布类型－正态分布，一致分布等等
- 使用自顶向下的方法回答空间数据的查询
- 从一个预先选择的层次开始－通常包含少量的单元
- 为当前层的每个单元计算置信区间

STING Algorithm and Its Analysis

STING:统计信息网格方法(3)

- 不相关的单元不再考虑
- 当检查完当前层，接着检查下一个低层次
- 重复这个过程直到达到底层
- 由于STING采用了一种多分辨率的方法来进行聚类分析，因此聚类质量取决于网格结构的最底层的粒度。如果最底层的粒度很细，则处理的代价会显著增加；然而，如果网格结构最底层的粒度太粗，则会降低聚类分析的质量。
- 优点:
  - 独立于查询，易于并行处理和增量更新
  - 查询处理时间O(K), 其中k是最低网格单元的数目
- 缺点:
  - STING在构建一个父亲单元时没有考虑子女单元和其相邻单元之间的联系。因此，结果簇的形状是Isothetic，即所有的簇边界不是水平的，就是竖直的，没有斜的分界线。尽管该技术有较快的处理速度，但可能降低簇的质量和精确性。

Grid-Based Clustering Method
基于网格的聚类方法

- 几种代表性的方法
  - **STING (a STatistical INformation Gridapproach) (1997年)**
  - **CLIQUE(SIGMOD'98)**
  - **WaveCluster(VLDB'98)**
    - 一个采用小波变换方法的多分辨率聚类算法
  - **……**

Chapter 1. Cluster Analysis 聚类

- Cluster Analysis: Basic Concepts 基本概念
- Partitioning Methods 划分方法
- Hierarchical Methods 分层方法
- Density-Based Methods 基于密度的方法
- Grid-Based Methods 基于网格的方法
- **Evaluation of Clustering 聚类方法的评估**

Measuring Clustering Quality
聚类评估

- **聚类评估主要任务**

  —估计聚类趋势

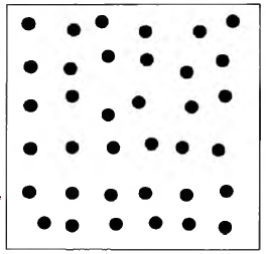
  对于给定的数据集，评估该数据集是否存在非随机结构
  仅当数据中存在非随机结构，数据集上的聚类分析是有意义的
  方法：霍普金斯统计量

  —确定数据集中的簇数

  在使用聚类算法导出详细的簇之前，估计簇数是可取的
  一个简单的经验方法：n个点的数据集，设置簇数p为 $\sqrt{\frac{n}{2}}$

  —测定聚类质量

霍普金斯统计量



- **霍普金斯统计量（ Hopkins Statistic）是一种空间统计量，检验空间分布的变量的空间随机性。给定数据集D，它可以看做随机变量o的一个样本，想要确定o在多大程度上不同于数据空间中的均匀分布。按以下步骤计算霍普金斯统计量：**

（1）均匀地从 D 的空间中抽取 n 个点 p_1，…，p_n。

也就是说，D 的空间中的每个点都以相同的概率包含在这个样本中。对于每个点 $p_i(1 \leqslant i \leqslant n)$，我们找出 p_i 在 D 中的最近邻，并令 x_i 为 p_i 与它在 D 中的最近邻之间的距离，即

$$x_i = \min_{v \in D} \{dist(p_i, v)\} \tag{10.25}$$

（2）均匀地从 D 中抽取 n 个点 q_1，…，q_n。对于每个点 $q_i(1 \leqslant i \leqslant n)$，我们找出 q_i 在 $D - \{q_i\}$ 中的最近邻，并令 y_i 为 q_i 与它在 $D - \{q_i\}$ 中的最近邻之间的距离，即

$$y_i = \min_{v \in D, v \neq q_i} \{dist(q_i, v)\} \tag{10.26}$$

（3）计算霍普金斯统计量 H

$$H = \frac{\sum_{i=1}^{n} y_i}{\sum_{i=1}^{n} x_i + \sum_{i=1}^{n} y_i} \tag{10.27}$$

“霍普金斯统计量告诉我们数据集 D 有多大可能遵守数据空间的均匀分布吗?”如果 D 是均匀分布的，则 $\sum_{i=1}^{n} y_i$ 和 $\sum_{i=1}^{n} x_i$ 将会很接近，因而 H 大约为 0.5。然而，如果 D 是高度倾斜的，则 $\sum_{i=1}^{n} y_i$ 将显著地小于 $\sum_{i=1}^{n} x_i$，因而 H 将接近于 0。

Determine the Number of Clusters

确定数据集中的簇数

- 经验方法

  # of clusters: $k \approx \sqrt{n/2}$ for a dataset of n points,

  e.g., n = 200, k = 10

- 肘方法

  使用簇内方差和关于簇数的曲线的拐点

- 交叉验证

  把给定的数据集D划分为m个部分，然后使用m-1个部分建立一个聚类模型

  检验集中所有点与它们的最近形心之间的距离的平方和来度量聚类模型拟合检验集的程度

Measuring Clustering Quality
测定聚类质量

- 根据是否有基准可用，常见方法分为两类
  - 外在方法 （有可用的基准）
  - 内在方法（没有可用基准，通过考虑簇分离情况评估聚类好坏）
- 外在方法
  - 把基准与聚类进行比较，来评估聚类
- 内在方法
  - 通过考察簇的分离情况和簇的紧凑情况来评估聚类
  - 许多内在方法都利用数据集的对象之间的相似度度量

Measuring Clustering Quality: External Methods
测定聚类质量

- 外在方法：给定基准，对聚类赋予一个评分 Q(C, T)
- 一般而言，一种聚类质量度量Q是有效的：
  - 簇的同质性
  - 簇的完全性
  - 碎布袋
  - 小簇保持性
- E.g., Bcubed精度和召回率

  一个对象的精度指，同一簇中有多少个其他对象与该对象同属一个类别

  一个对象的召回率反应有多少同一类别的对象被分配在相同的簇中
- 内在方法：轮廓系数