Lecture2 基于知识图谱的智能数据治理



蔡鸿明
hmcai@sjtu.edu.cn

目录

- 1 数据智能平台

  1.1 大数据定义-1.2数据分析特点-1.3 大数据处理过程

- 2 数据治理

  2.1 数据准备-2.2数据治理-2.3数据分类-2.4智能数据治理

- 3 知识图谱

  3.1 知识图谱发展-3.2知识图谱表示及存储-3.3 知识图谱构建-3.4 KG构建实例

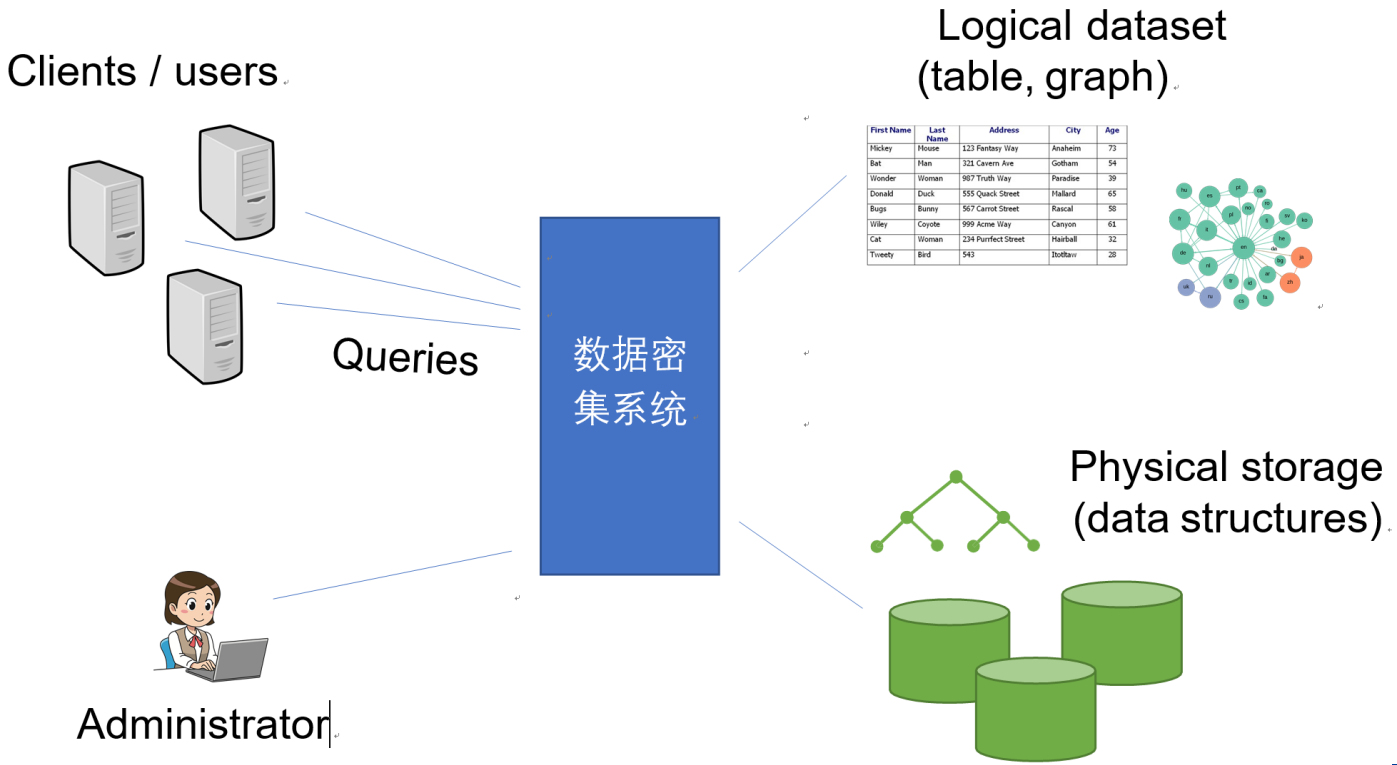
- 4 基于知识图谱的智能数据治理

  4.1 航天元器件应用实例-4.2其他实例

- 5 小结

1 数据智能平台

- 大多数计算机应用程序必须管理、更新和查询数据，这使得数据密集系统（Data-Intensive Systems）非常广泛。
- 随着智能化的发展，数据的质量、数量和及时性变得更加重要。
  - 某种程度来说，机器智能=从数据概括知识的算法



1.1 大数据的定义

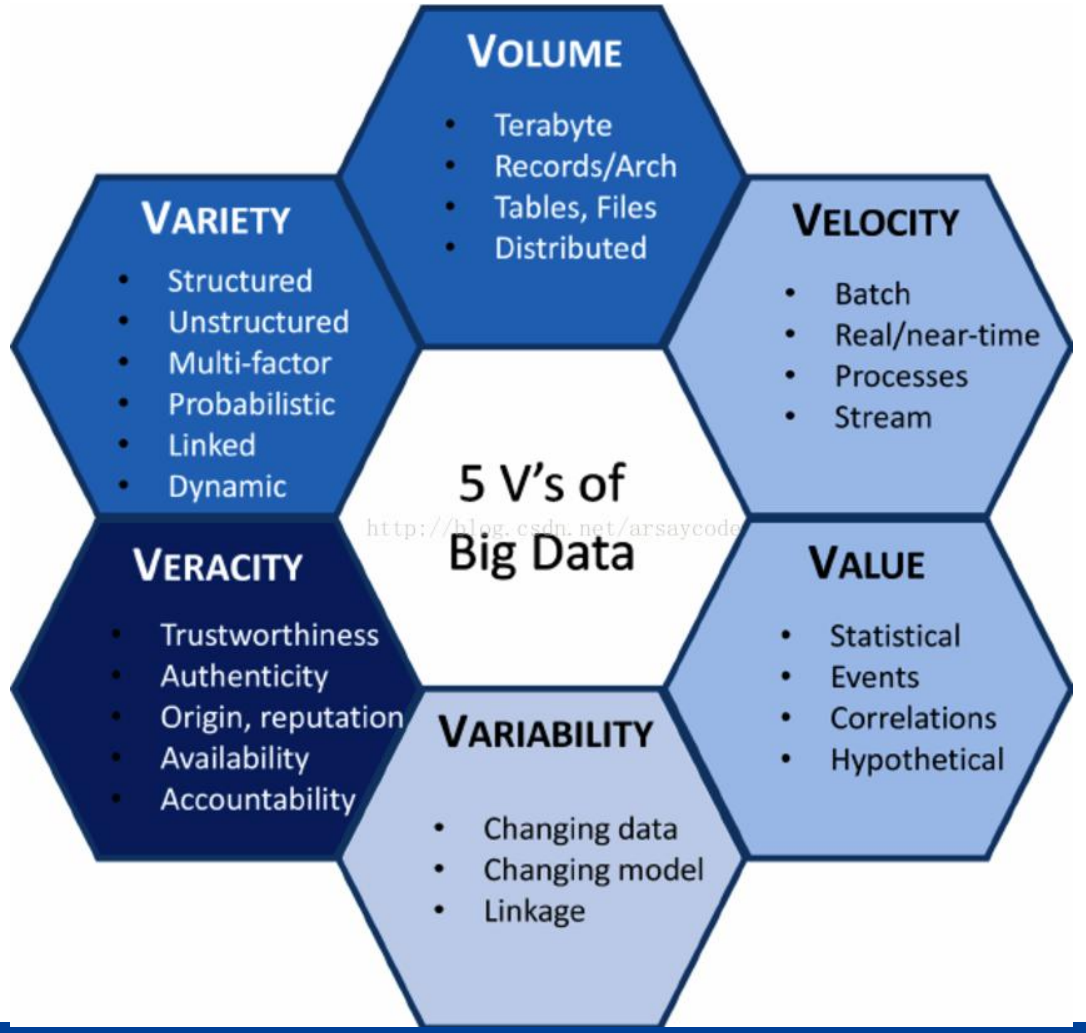
- “大数据”的概念起源于 2008 年自然杂志刊登的名为“Big Data”的专题。谷歌、雅虎、亚马逊等著名企业在此基础上，总结了他们利用积累的海量数据为用户提供更加人性化服务的方法，进一步完善“大数据”的概念。
  - 根据维基百科的定义，大数据是指无法在可承受的时间范围内用常规软件工具进行捕捉、管理和处理的数据集合。
  - 在维克托·迈尔-舍恩伯格及肯尼斯·库克耶编写的《大数据时代》中，大数据指不用随机分析法（抽样调查）这样捷径，而采用所有数据进行分析处理。

- 大数据（Big Data）是指规模庞大、结构复杂且传统数据处理工具难以处理的数据集合。其核心价值在于通过分析这些数据，挖掘出隐藏的模式、趋势或关联性，从而支持决策、优化流程或发现新机会。

大数据的5V

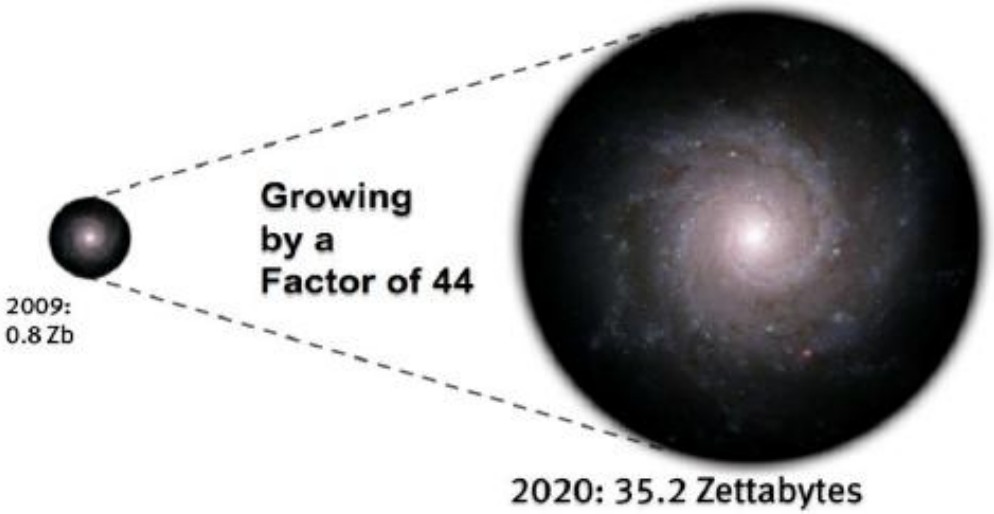
- 大数据是相对于一般数据而言的，目前对大数据尚缺乏权威的严格的定义，通常用“5V”来反映大数据的特征：

Volume（大量）
Velocity（高速）
Variety（多样）
Value（低价值密度）
Veracity（真实性）



大数据的特点-规模性

- Volume（规模性）：**大数据之“大”，体现在数据的存储和计算均需要耗费海量规模的资源上。规模大是大数据最重要的标志之一。**数据规模越大，通常对数据挖掘所得到的事物演变规律越来越可信，数据的分析结果也越具有代表性。
- 截至目前，人类生产的所有印刷材料的数量是200PB，而历史上全人类总共说过得话的数据量大约是5EB。当前，典型个人计算机硬盘的容量为TB量级，而一些大企业的数据量已经接近EB量级。
- 大数据的规模是超规模的，不是以TB、PB甚至EB为单位来衡量，而是往往超出了传统领域的边界。
- 从大数据的数据源的角度来看，它主要集中在互联网，物联网和传统信息系统三个渠道。
- 当前物联网数据的比例相对较大。相信在5G时代，物联网仍将是大数据的主要数据源。



大数据的特点-高速性

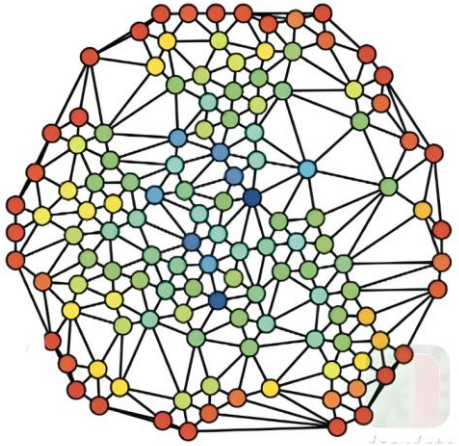
- Velocity（高速性）：**大数据的另外一特点在于数据增长速度快，需及时处理。**
- 例如，在一秒钟里，一个搜索引擎有超过 3 万次用户查询提交到服务器。
- 这就需要更快，更方便的方式来完成数据值提取过程。这是大数据分析区于传统数据挖掘的最显著特征。在如此海量的数据面前，处理数据速度就是企业的生命。



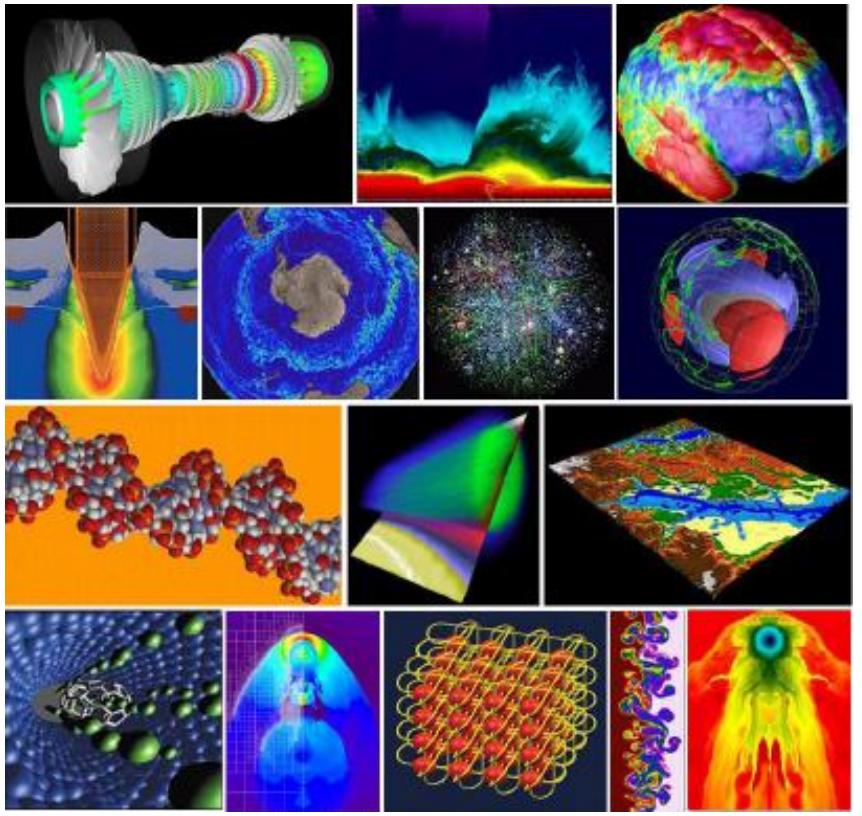


大数据的特点-多样性

- Variety（多样性）：在大数据背景下，数据在来源和形式上的多样性愈加突出。除结构化形式存在的关系数据，也存在大量的文本、视频、位置、图片、音频等非结构化数据，还有很多半结构化（JSON、XML）。
- 现在80%-90%的数据都是文本、语音、图像、视频，不再是整齐的结构化数据。
- 这种多样性对数据处理能力提出了更高的要求，也使得数据分析变得更加复杂和有趣。
- 多模态知识图谱开始兴起!
- 随着工业互联网兴起，IT/OT/CT数据融合也成为问题。

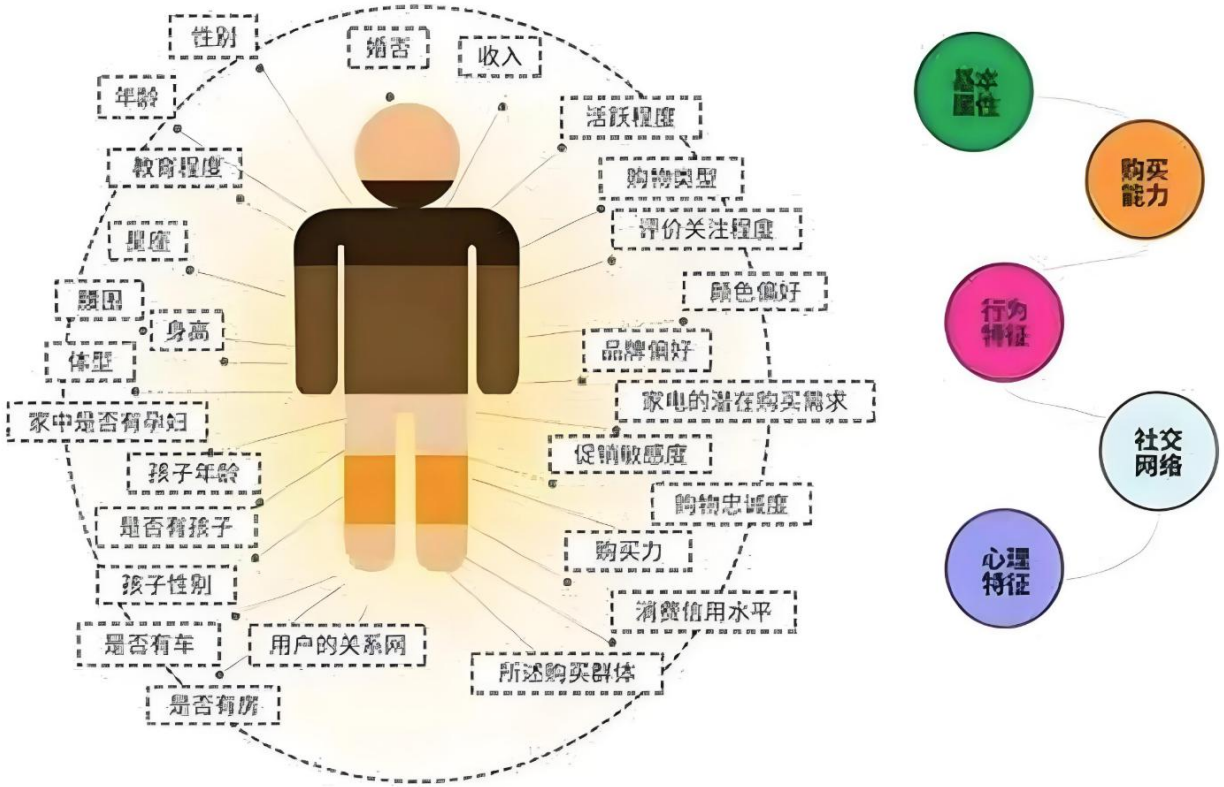


语音 图片 交易记录 文字 视频



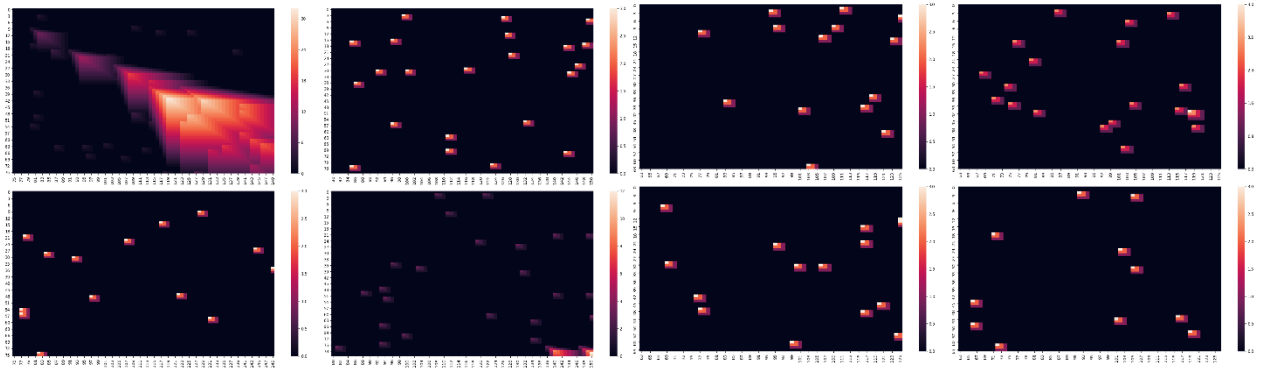
大数据的特点-高价值性

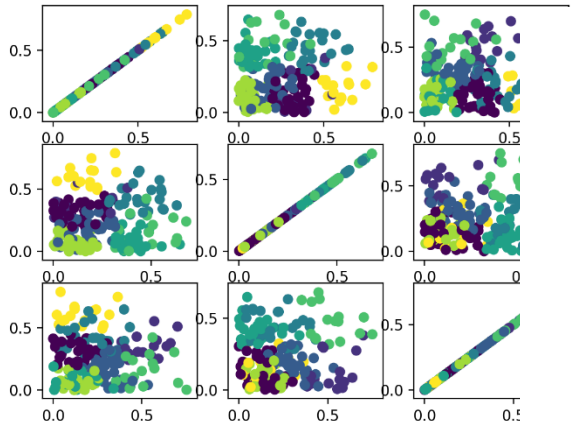
- Value（低价值密度）：大数据价值总量大，但价值稀疏，即知识密度低。
- 以视频为例，连续不间断监控过程中，可能有用的数据仅仅有一两秒，但是具有很高的商业或者其他价值。
- 数据本身价值密度低，需通过分析提炼有用信息（如从用户日志中提取购买偏好）

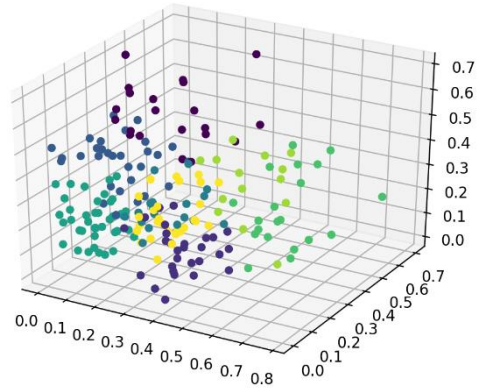


大数据的特点- 真实性

- 真实性（Veracity）：数据Veracity涵盖了数据的准确性、相关性以及数据质量。
- Veracity也指的是当数据的来源变得更多元时，这些数据本身的可靠度、质量是否足够，若数据本身就是有问题的，那分析后的结果也不会是正确的。
- 例如，2024年7月媒体报道，谷歌现在默认不再索引新网站内容（default to not index），转而寻求更有选择性的收录。旨在对抗日益泛滥的低质量内容和搜索引擎优化（SEO）问题，以区分高质量内容和机器生成内容。
- 大模型写作生成的参考文献是真实存在的吗？
- 怎么区分模拟数据和虚假数据?







大数据分析的应用

在**金融行业**方面，华尔街对冲基金依据购物网站的顾客评论，分析企业的销售情况；



一些企业利用大数据分析实现对采购和合理库存的管理，通过分析网上数据了解客户需求，掌握市场动向。(**例如前置仓的设置模式**)

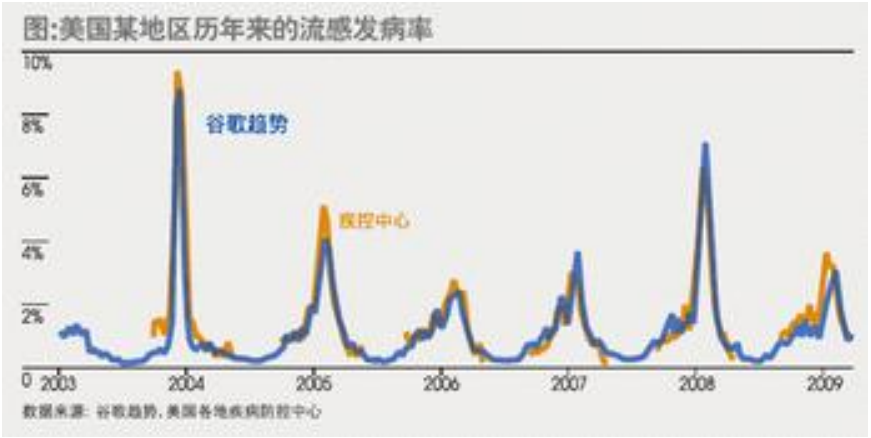
在HR方面，目前越来越多的企业借助大数据对特定人员进行画像，作为猎头或者招收的数据基础；

阿里巴巴根据淘宝网上中小型公司的交易情况，筛选出财务健康、诚信优良的企业，为他们免担保提供贷款达上千亿元，坏账率仅有 0.3%。



在**医疗卫生**领域，相关部门可以根据搜索引擎上民众对相关关键字的搜索数据建立数学模型分析，得出相应的预测进行预防。

例如，2009 年谷歌在甲型 H1N1 爆发前几周，就预测出流感形式，与随后的官方数据相关性高达 97%。



大数据产业

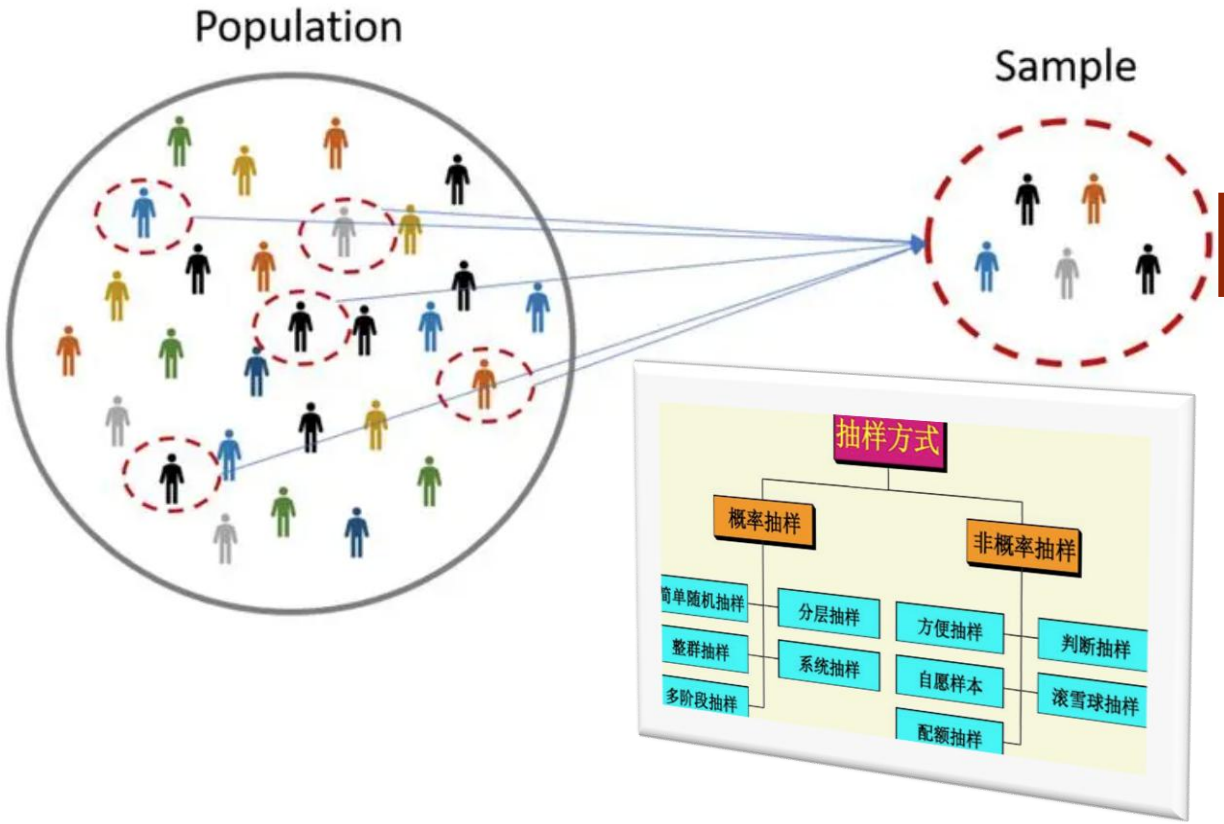
产业链环节	包含内容
IT基础设施层	包括提供硬件、软件、网络等基础设施以及提供咨询、规划和系统集成服务的企业，比如，提供数据中心解决方案的IBM、惠普和戴尔等，提供存储解决方案的 EMC，提供虚拟化管理软件的微软、思杰、SUN、Redhat等
数据来源层	大数据生态圈里的数据提供者，是生物大数据（生物信息学领域的各类研究机构）、交通大数据（交通主管部门）、医疗大数据（各大医院、体检机构）、政务大数据（政府部门）、电商大数据（淘宝、天猫、苏宁云商、京东等电商）、社交网络大数据（微博、微信、人人网等）、搜索引擎大数据（百度、谷歌等）等各种数据的来源
数据管理层	包括数据抽取、转换、存储和管理等服务的各类企业或产品，比如分布式文件系统（如 Hadoop 的 HDFS 和谷歌的 GFS）、ETL 工具（Informatica、Datastage、Kettle 等）、数据库和数据仓库（Oracle、MySQL、SQL Server、HBase、GreenPlum等）
数据计算层	包括提供分布式计算、数据挖掘、统计分析等服务的各类企业或产品，比如，分布式计算框架 MapReduce、统计分析软件 SPSS 和 SAS、数据挖掘工具 Weka、数据可视化工具Tableau、BI 工具（MicroStrategy、Cognos、BO）等等
数据平台层	包括提供数据分享平台、数据分析平台、数据租售平台等服务的企业或产品，比如阿里巴巴、谷歌、中国电信、百度等
数据应用层	提供智能交通、智慧医疗、智能物流、智能电网等行业应用的企业、机构或政府部门，比如交通主管部门、各大医疗机构、菜鸟网络、国家电网等

1.2智能互联时代的数据分析特点（1）

- “一叶窥秋”，一叶落而知天下秋；
- 小数据时代的随机采样，最少的数据获得最多的信息，
- 其原因往往是技术条件限制，因为记录、存储和分析数据的方式不够好，也为了分析过程简单。
  - 交通流量估计，人口普查，…
  - 样本选择的随机性比样本数据更重要。采样分析的精确性随着随机采样随机性的增加而大幅度提高，但与样本数据的增加关系不大；
  - 随机采样取得了巨大的成功，但本质上只是一条捷径，其具有很多固有局限；

智能互联时代的数据分析特点（1）

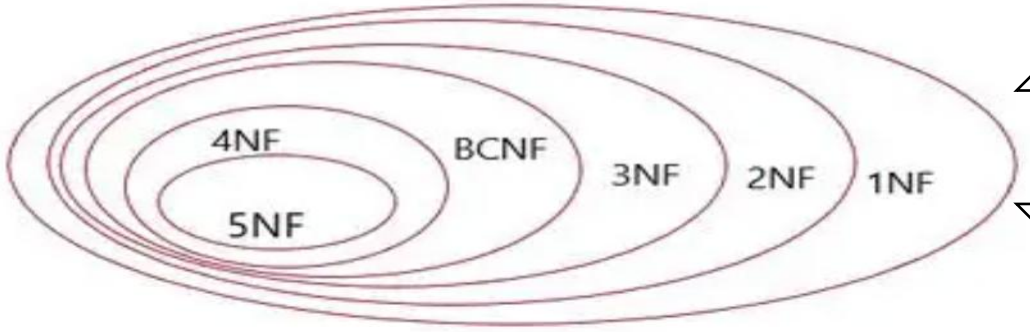
- 大数据时代，不是随机样本，而是全体数据；
- 样本=总体的全量数据模式是数据分析的出发点。

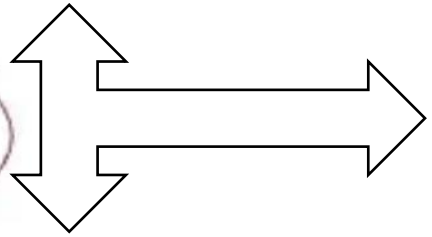


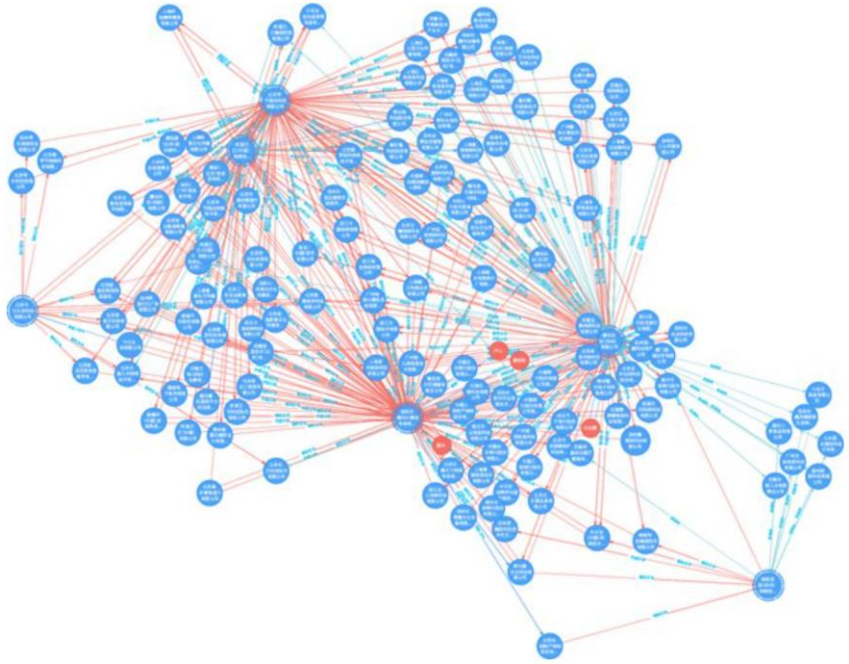


智能互联时代的数据分析特点（2）

- SQL、范式、一致性；
- **对单维度精确性的追求真的有必要吗？**
  - 现实中只有5%的数据是结构化的数据，95%的数据是半结构化和非结构化的数据；
  - 需要接受异构、模糊和不确定的混杂数据源；
  - 分析不严格的数据关系；





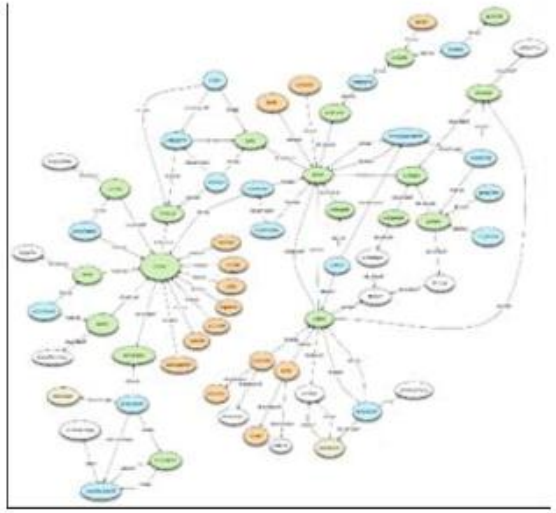


智能互联时代的数据分析特点（2）

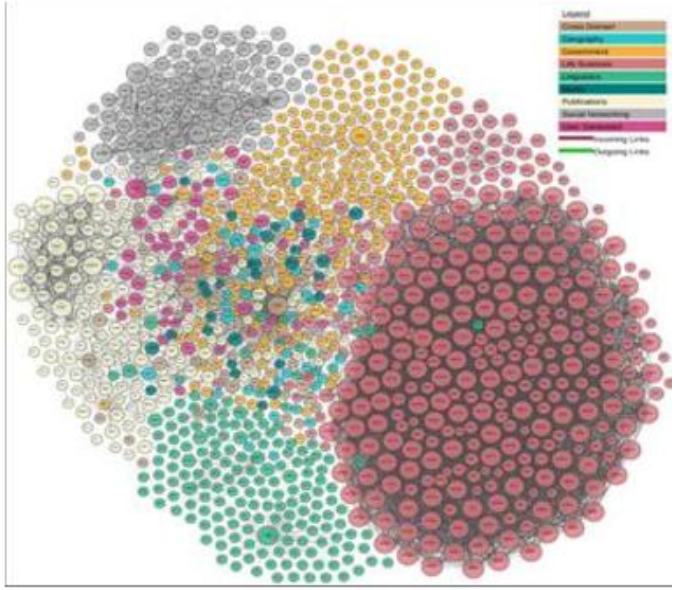
- 大量多模态/多维度的数据分析的简单算法，比小数据的单维度复杂算法更重要。
- 大量数据的简单算法，比小数据的复杂算法更重要；



Heterogeneous data sources



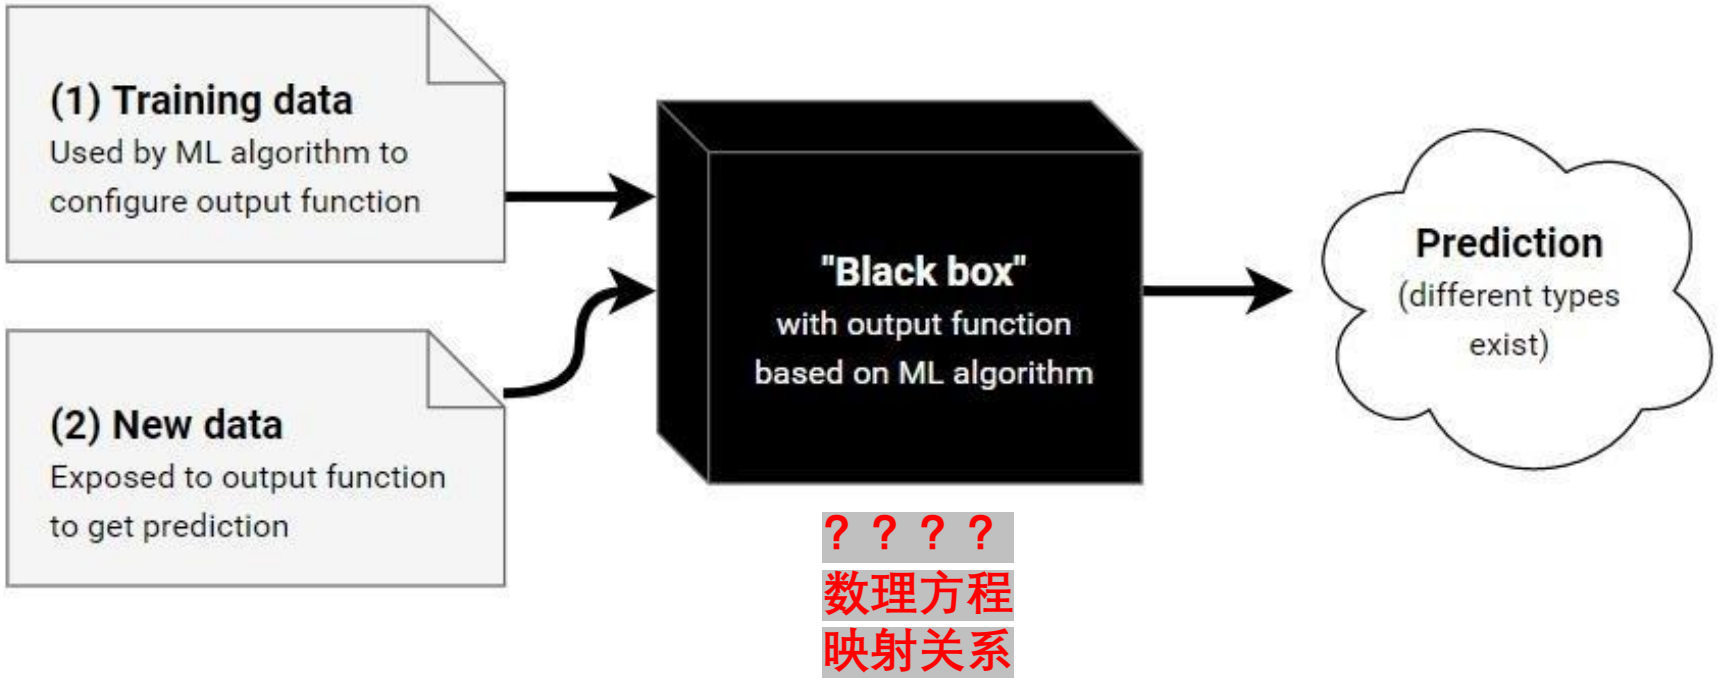
Knowledge formalizations: vocabularies, thesauri, domain ontologies, etc.



Web of Data

智能互联时代的数据分析特点（3）

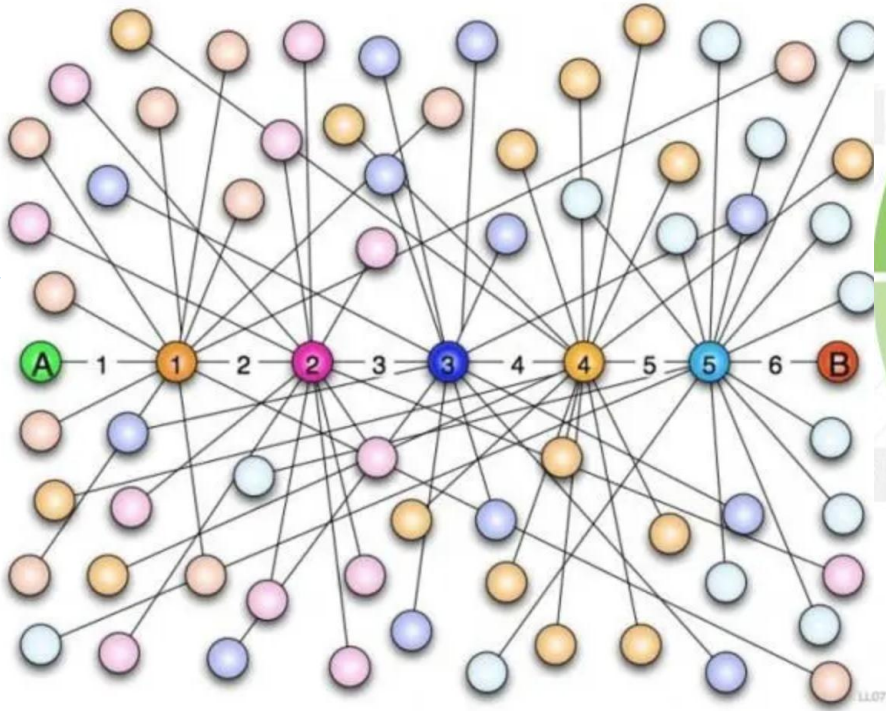
- 确定数据变量和数据结果的正相关或者负相关等数理关系很难；
- 很难找到数据之间的映射逻辑和理论（机理模型构建）；
- 白盒分析做不到，“为什么”很难得到，黑盒处理的“是什么”就够了！

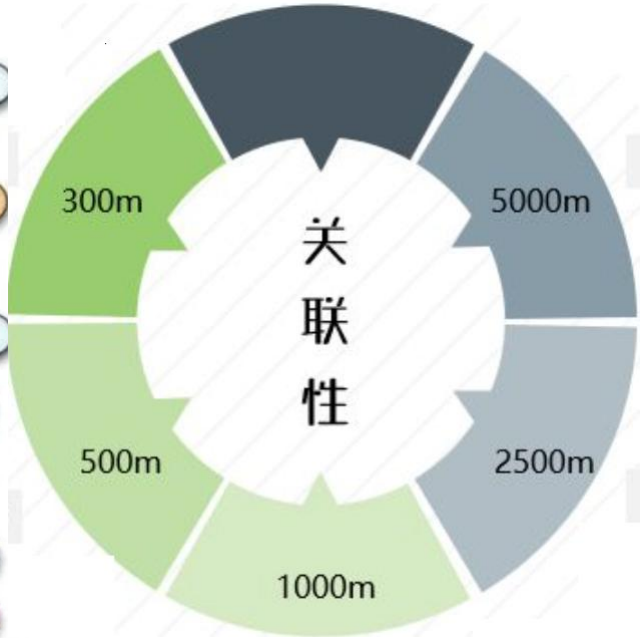


智能互联时代的数据分析特点（3）

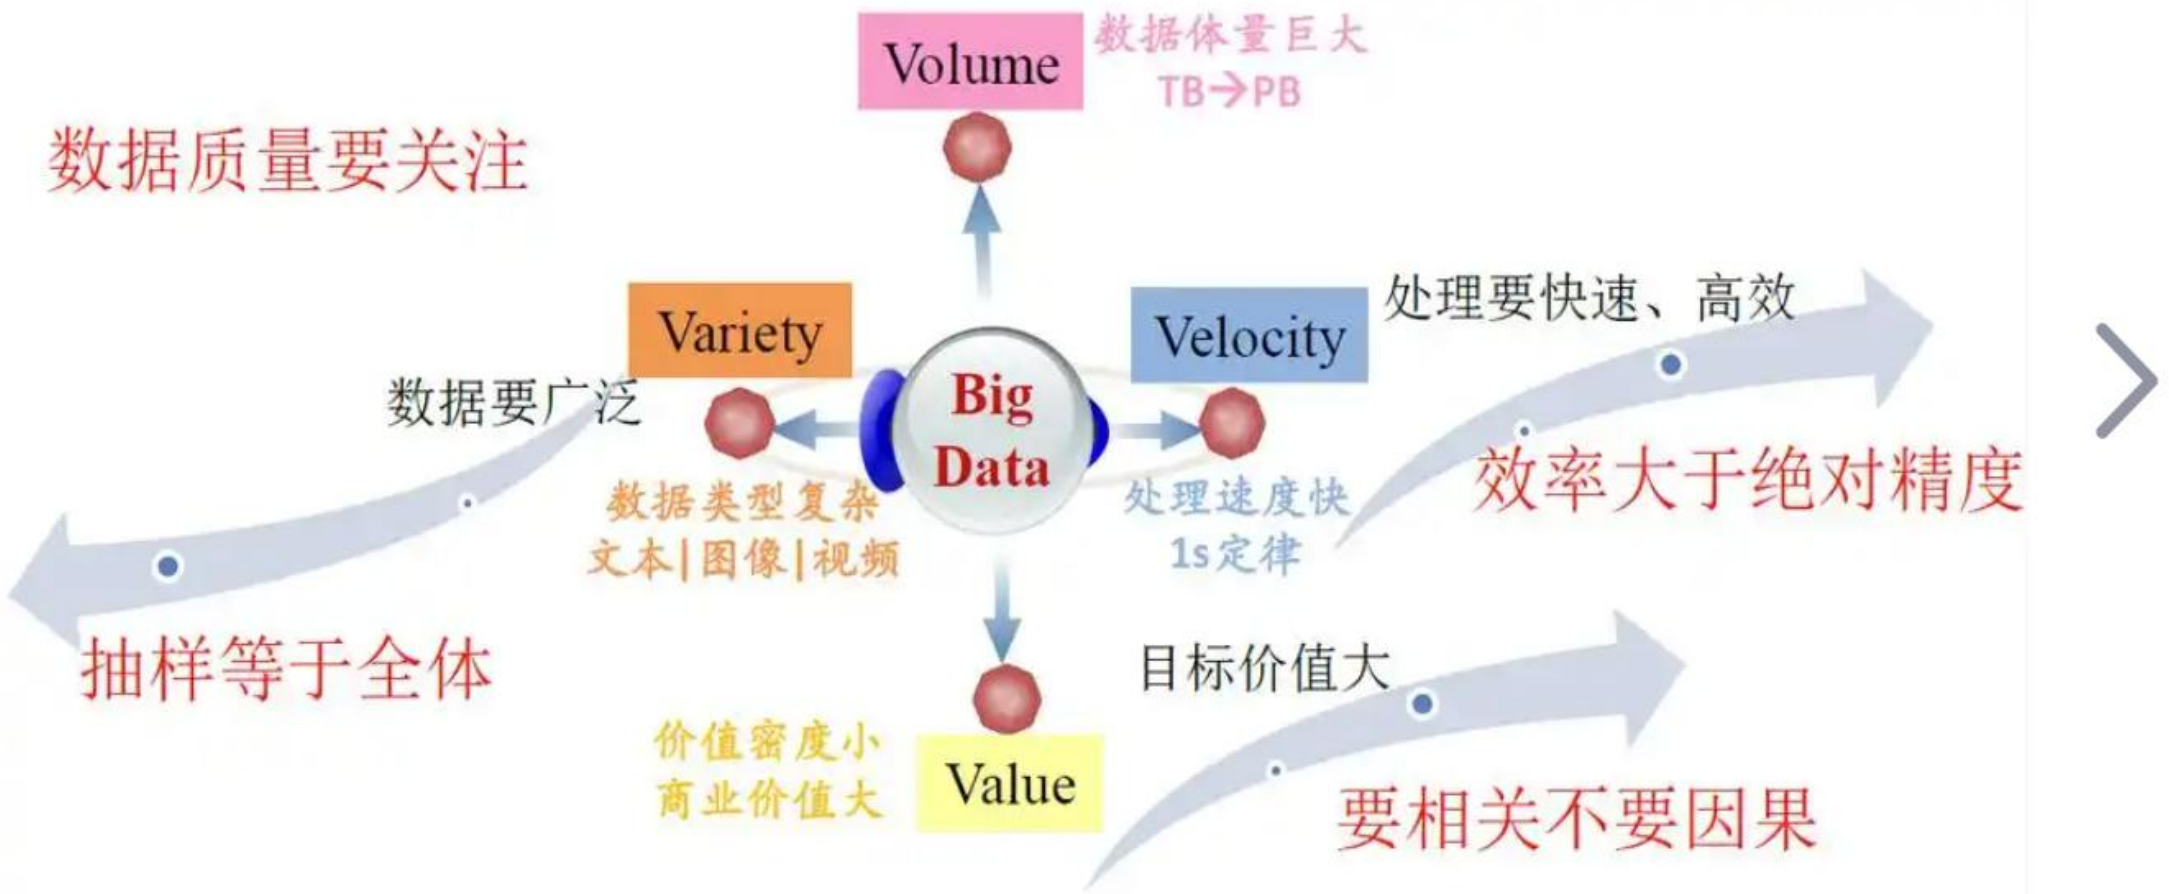
- 因果关系很少，数据的关联性更为重要；
- 要习惯百分之几的结果表述，而不是结果为是否的判断；
- “直觉”胜于逻辑推理。
- 因果关系很少，数据的关联性更为重要。







结合大数据4V的数据分析特点



数据分析的难点

- 大数据分析不是简单的数据分析的延伸。大数据规模大、更新速度快、来源多样等性质为大数据分析带来一系列挑战：
  - **可扩展性**：由于大数据的特点之一是“规模大”，利用大规模数据可以发现诸多新知识，因而大数据分析需要考虑的首要任务之一就是使得**分析算法能够支持大规模数据**，在大规模数据上能够在所要求的**时间约束**内得到结果。
  - **可用性**：大数据分析的结果应用到实际中的前提是分析结果的可用，这里的可用分为两个方面的含义：一方面，需要结果具有高质量，如结果完整、符合现实的语义约束等；另一方面，需要结果的形式适用于实际的应用。
  - **领域知识的结合**：大数据分析通常和具体领域密切结合，因而大数据分析的过程很自然的需要和领域知识相结合。一方面，需要与领域知识相适应的大数据分析方法；另一方面需要领域知识的内容和表示适用于大数据分析的过程。
  - **结果的检验**：有一些应用需要高可靠性的分析结果，否则会带来灾难性的后果。结果的检验需要对大数据分析结果需求的建模和检验的有效实现。

数据分析的三个层次

- 一般来说，数据分析指的是用适当的**统计类算法**对收集来的大量数据进行处理，提取有用信息和形成结论的过程。
- 数据分析可以分成三个层次：
  - **描述分析：**探索历史数据并描述发生了什么，这一层次包括发现数据规律的**聚类**、**相关规则挖掘**、**模式发现**和**描述数据规律的可视化分析**；
  - **预测分析：**预测未来的概率和趋势。例如基于**逻辑回归**的预测、基于**分类器**的预测等；
  - **规范分析：**根据**期望的结果**、**特定情景**、**资源**以及对**过去和当前事件**的了解对**未来的决策**给出建议。例如基于模拟的复杂系统分析和基于给定约束的优化解生成。

大数据分析的过程

① 业务理解：最初的阶段，理解项目目标和从业务的角度理解需求；同时将业务知识转化为数据分析问题的定义和规划上。

② 数据理解：数据理解阶段从初始的数据收集开始，通过一些活动的处理，目的是熟悉数据，识别数据的质量问题。通过发现数据的内部属性，或是探测引起兴趣的内容，以形成隐含信息的假设。

③ 数据准备：数据准备阶段包括从未处理数据中构造最终数据集的所有活动。这些数据是模型工具的输入值。这个阶段的任务有的能执行多次，没有任何规定的顺序。任务包括表、记录和属性的选择，以及为模型工具转换和清洗的数据。

④ 数据建模：在这个阶段，可以选择和应用不同的模型技术，模型参数被调整到最佳的数值。有些技术可以解决一类相同的数据分析问题；有些技术在数据形成上有特殊要求，因此需要经常跳回到数据准备阶段。

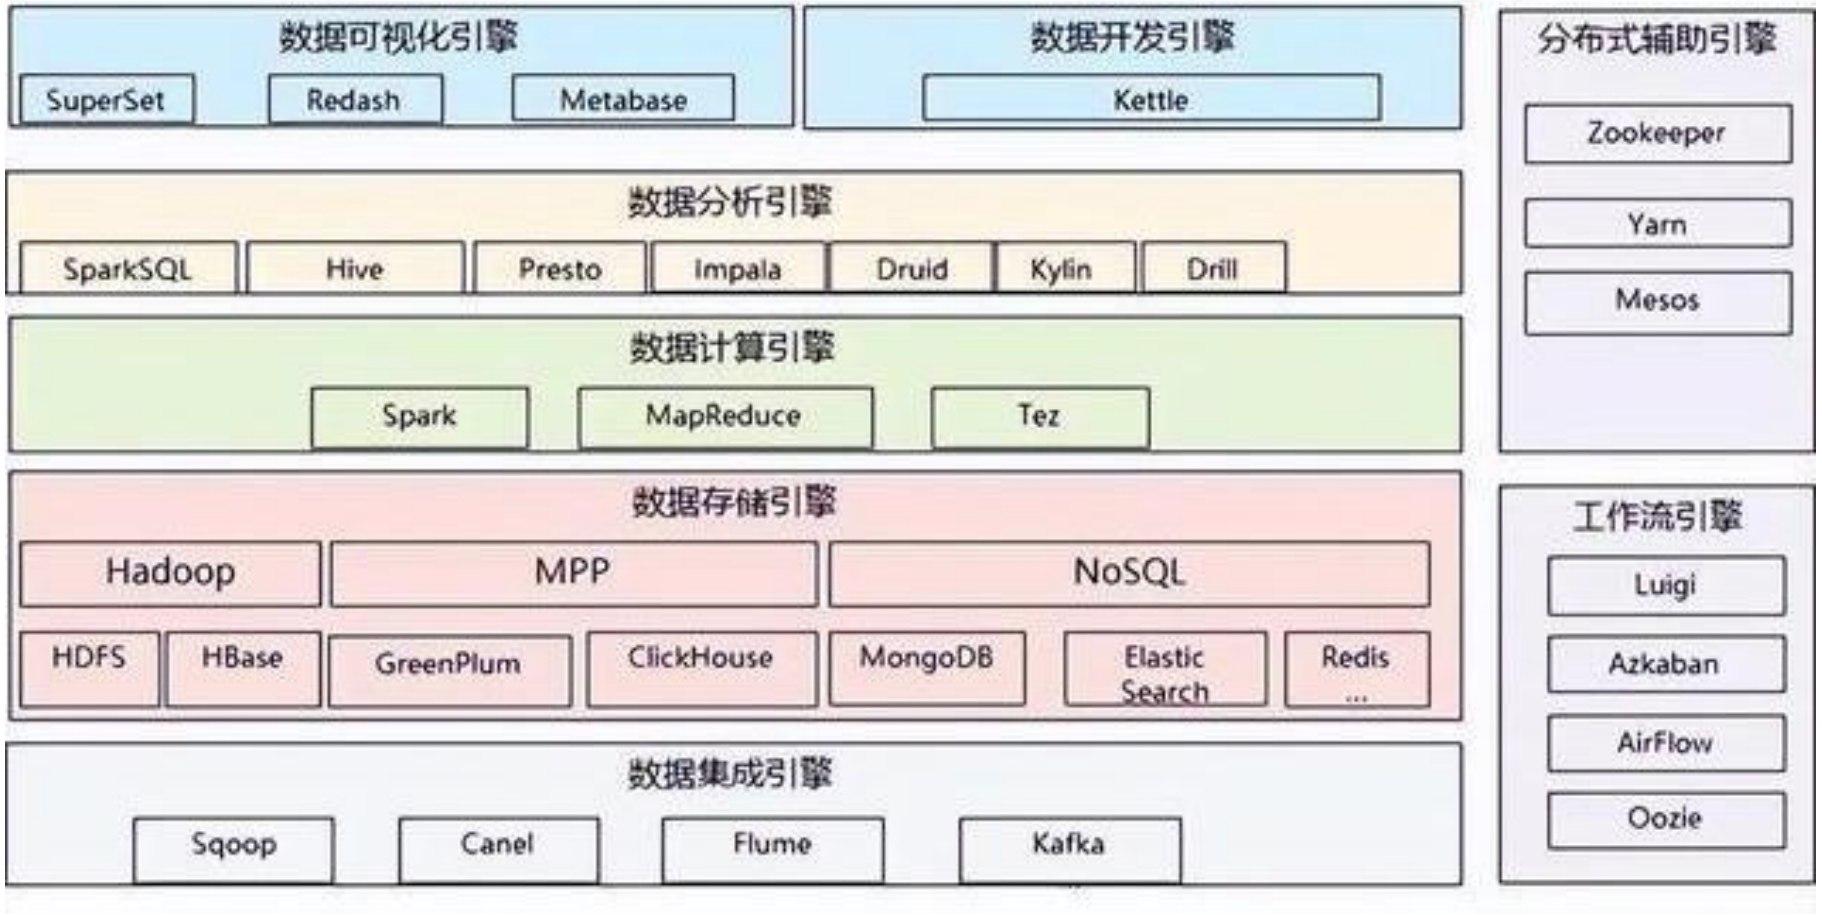
⑤ 模型评估：在这个阶段，已经从数据分析的角度建立了一个高质量的模型。在最后部署模型之前，重要的事情是彻底地评估模型，检测构造模型的步骤，确保模型可以完成业务目标。

⑥ 模型部署：通常模型的创建不是项目的结束。模型的作用是从数据中找到知识，获得的知识需要以便于用户使用的方式重新组织和展现。根据需求，这个阶段可以产生简单的报告，或是实现一个比较复杂的、可重复的数据分析过程。

1.3 大数据处理全过程

- 大数据处理过程主要包括：采集、治理、存储、计算、应用（可视化）过程。

开源大数据技术架构



一个大数据平台实例

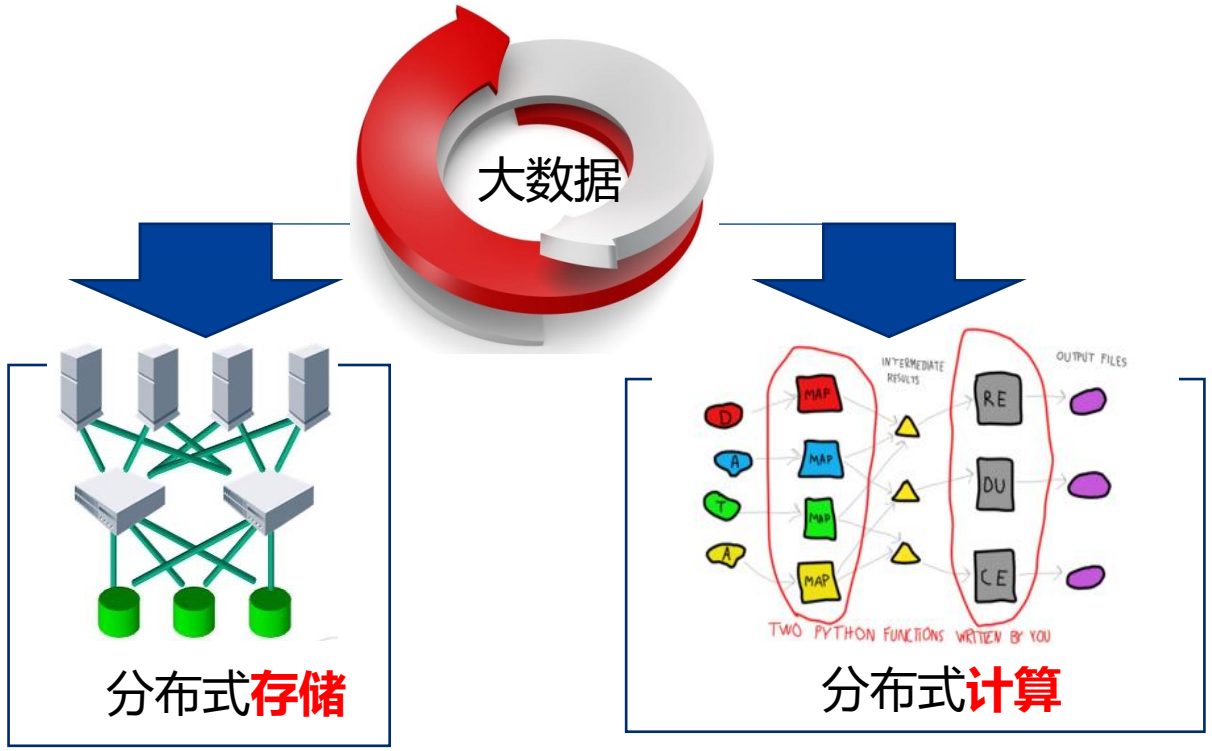
- 按照数据采集、治理、存储、计算、应用等方式构造的数据平台。



数据分析的技术框架

技术层面	功能
数据采集	利用 ETL 工具将分布的、异构数据源中的数据如关系数据、数据文件等，抽取到临时中间层后进行清洗、转换、集成，最后加载到数据仓库或数据集市中，成为联机分析处理、数据挖掘的基础；或者也可以把实时采集的数据作为流计算系统的输入，进行实时处理分析
数据治理 数据存储	利用分布式文件系统、数据仓库、关系数据库、NoSQL 数据库、云数据库等，实现对结构化、半结构化和非结构化海量数据的存储和管理
数据计算	利用分布式并行编程模型和计算框架，结合机器学习和数据挖掘算法，实现对海量数据的处理和分析
数据应用	对分析结果进行可视化呈现，帮助人们更好地理解数据、分析数据
数据隐私和安全	在从大数据中挖掘潜在的巨大商业价值和学术价值的同时，构建隐私数据保护体系和数据安全体系，有效保护个人隐私和数据安全

大数据分析的两大核心技术

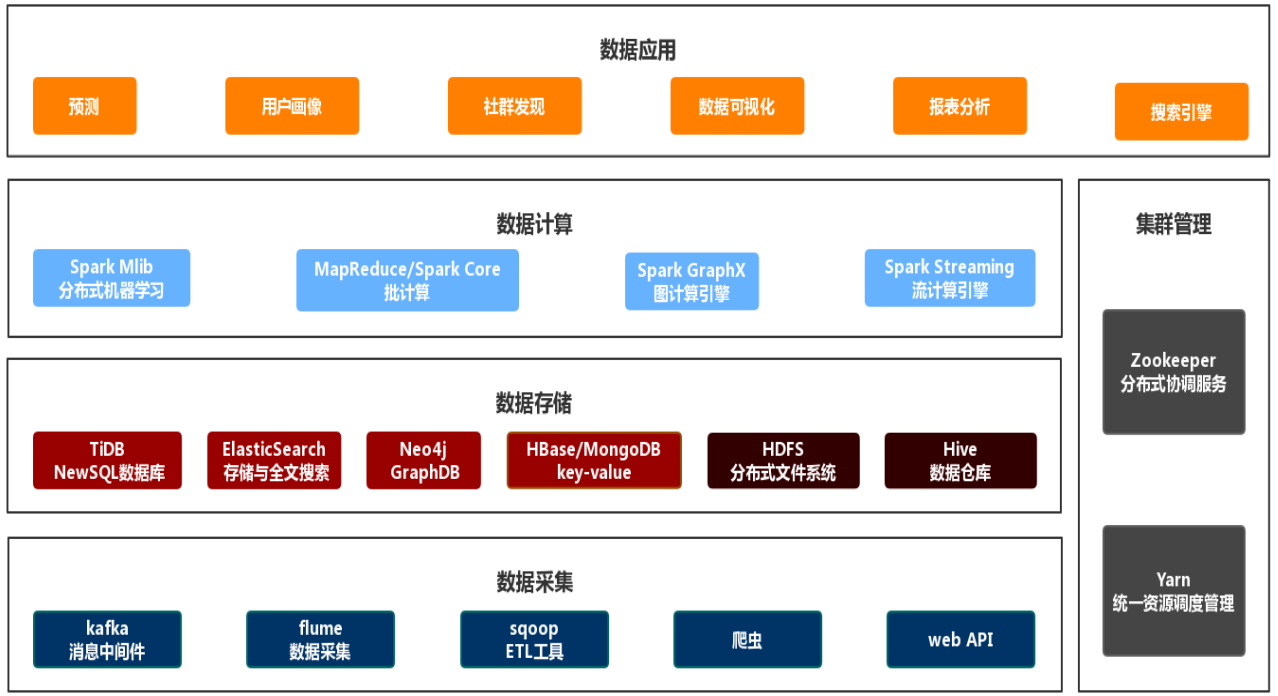


存储方式主要有：

- GFS\HDFS
- BigTable\HBase
- NoSQL（键值、列族、图形、文档数据库）
- NewSQL（如：SQL Azure）

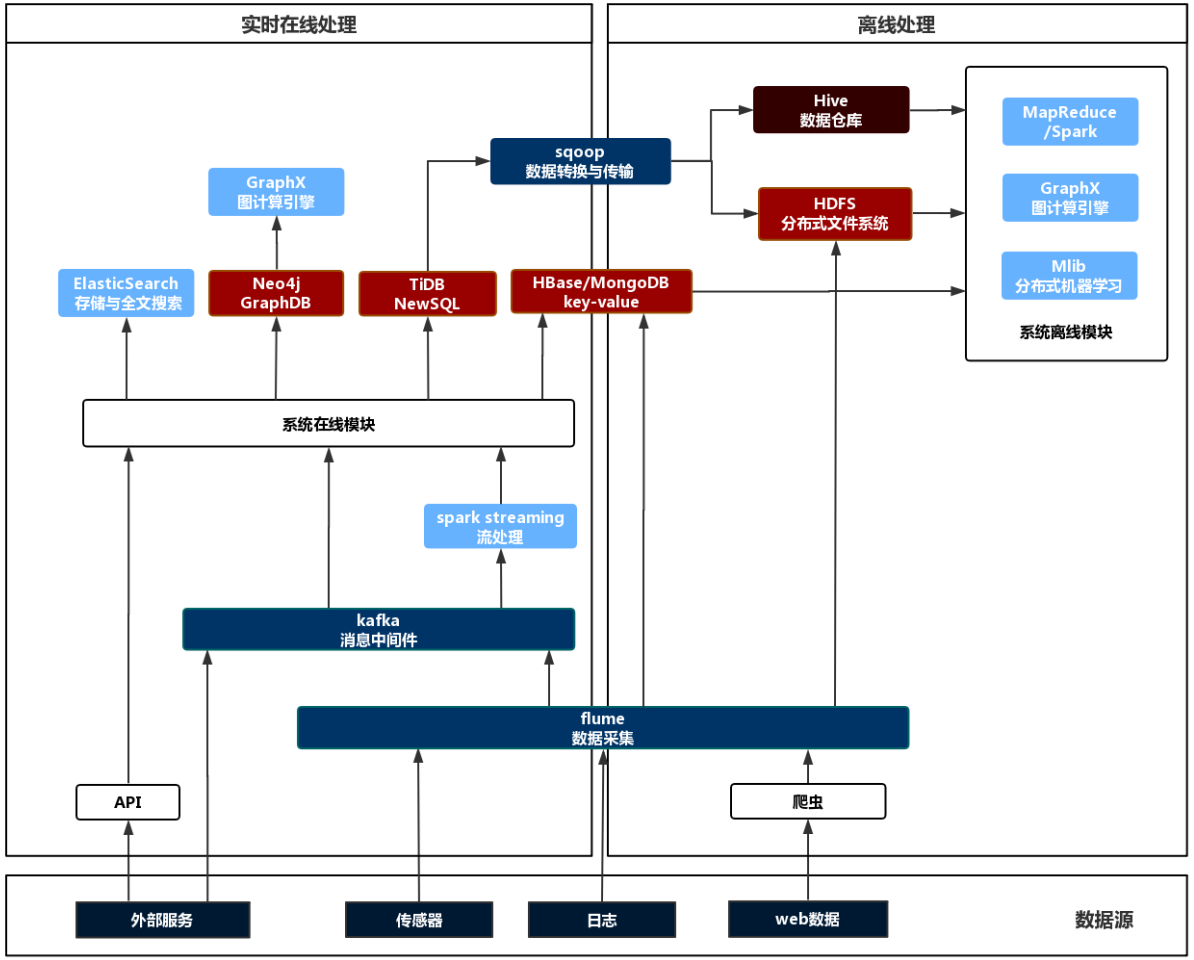
计算模式	解决问题	代表产品
批处理计算	针对大规模数据的批量处理	MapReduce、Spark 等
流计算	针对流数据的实时计算	Flink、Storm、S4、Flume、Streams、Puma、DStream、Super Mario、银河流数据处理平台等
图计算	针对大规模图结构数据的处理	Neo4J，Pregel、GraphX、Giraph、PowerGraph、Hama、GoldenOrb 等
查询计算	大规模数据的存储管理和查询分析	Dremel、Hive、Cassandra、Impala 等

大数据分析的典型技术架构



平台架构

数据处理流



目录

- 1 数据智能平台

  1.1 大数据定义-1.2数据分析特点-1.3 大数据处理过程

- 2 数据治理

  2.1 数据准备-2.2数据治理-2.3数据分类-2.4智能数据治理

- 3 知识图谱

  3.1 知识图谱发展-3.2知识图谱表示及存储-3.3 知识图谱构建-3.4 KG构建实例

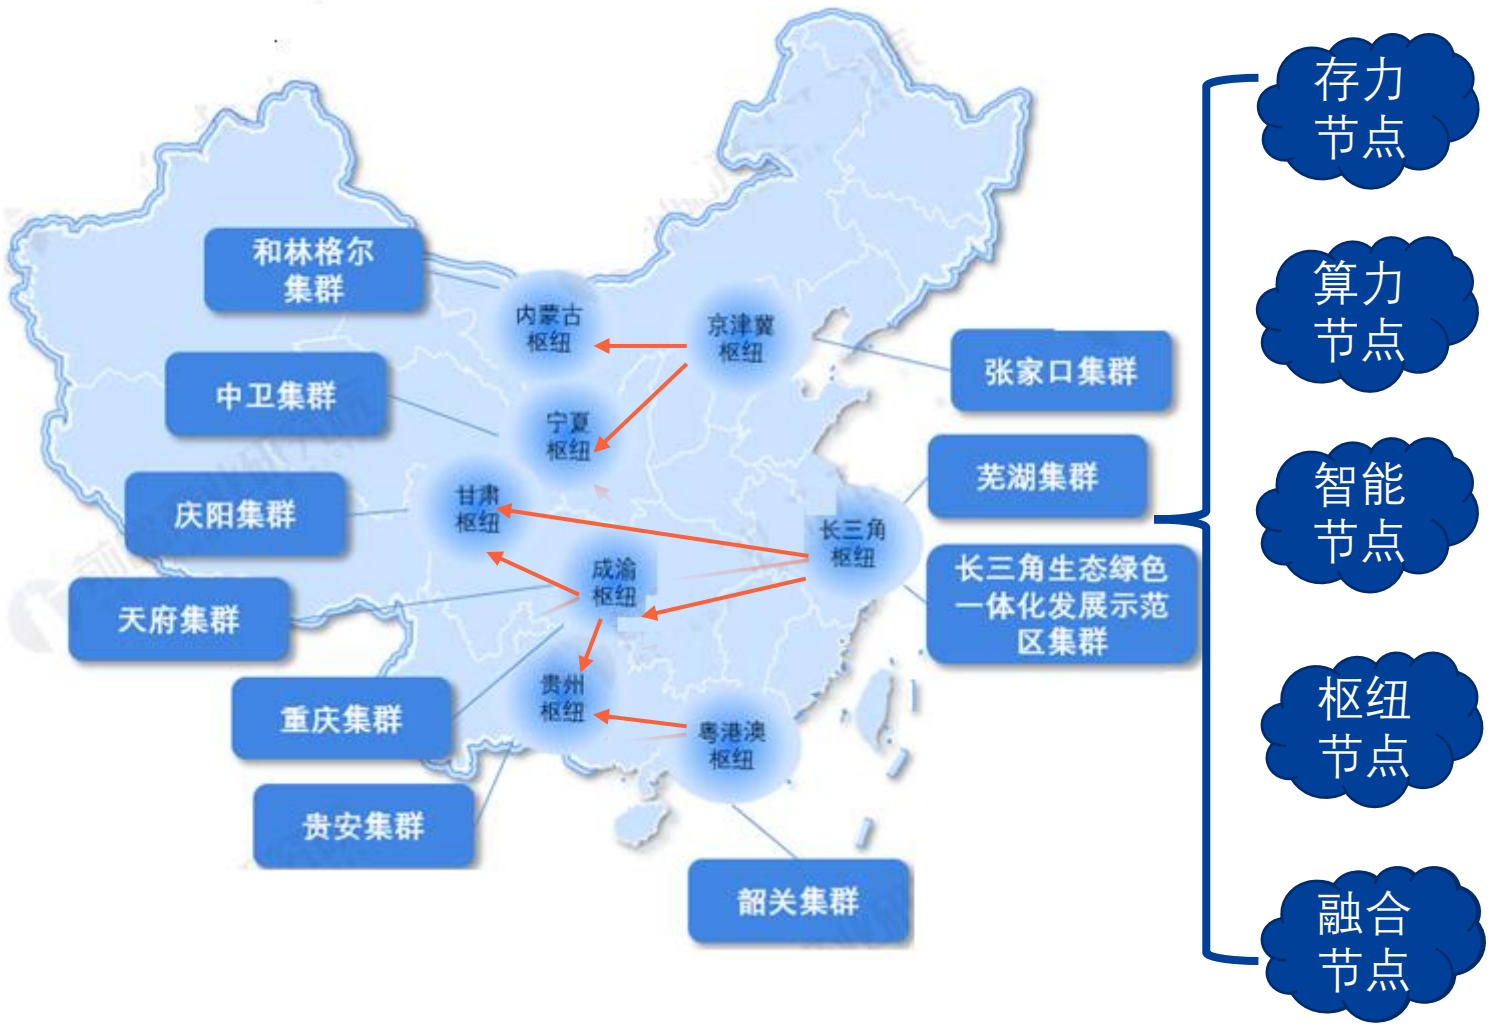
- 4 基于知识图谱的智能数据治理

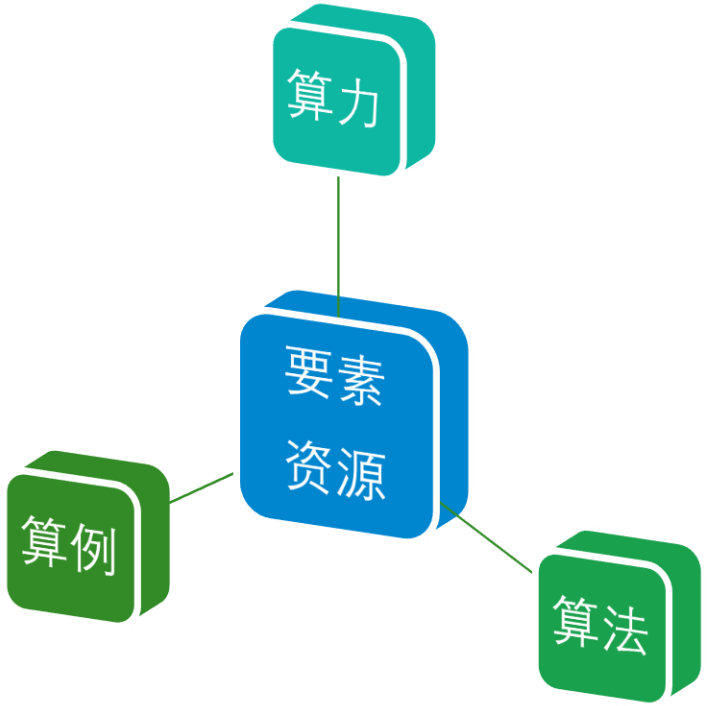
  4.1 航天元器件应用实例-4.2其他实例

- 5 小结

2 数据治理

- 智能互联大环境下，算例、算力、算法的三方面资源要素来说，发展不是均衡。



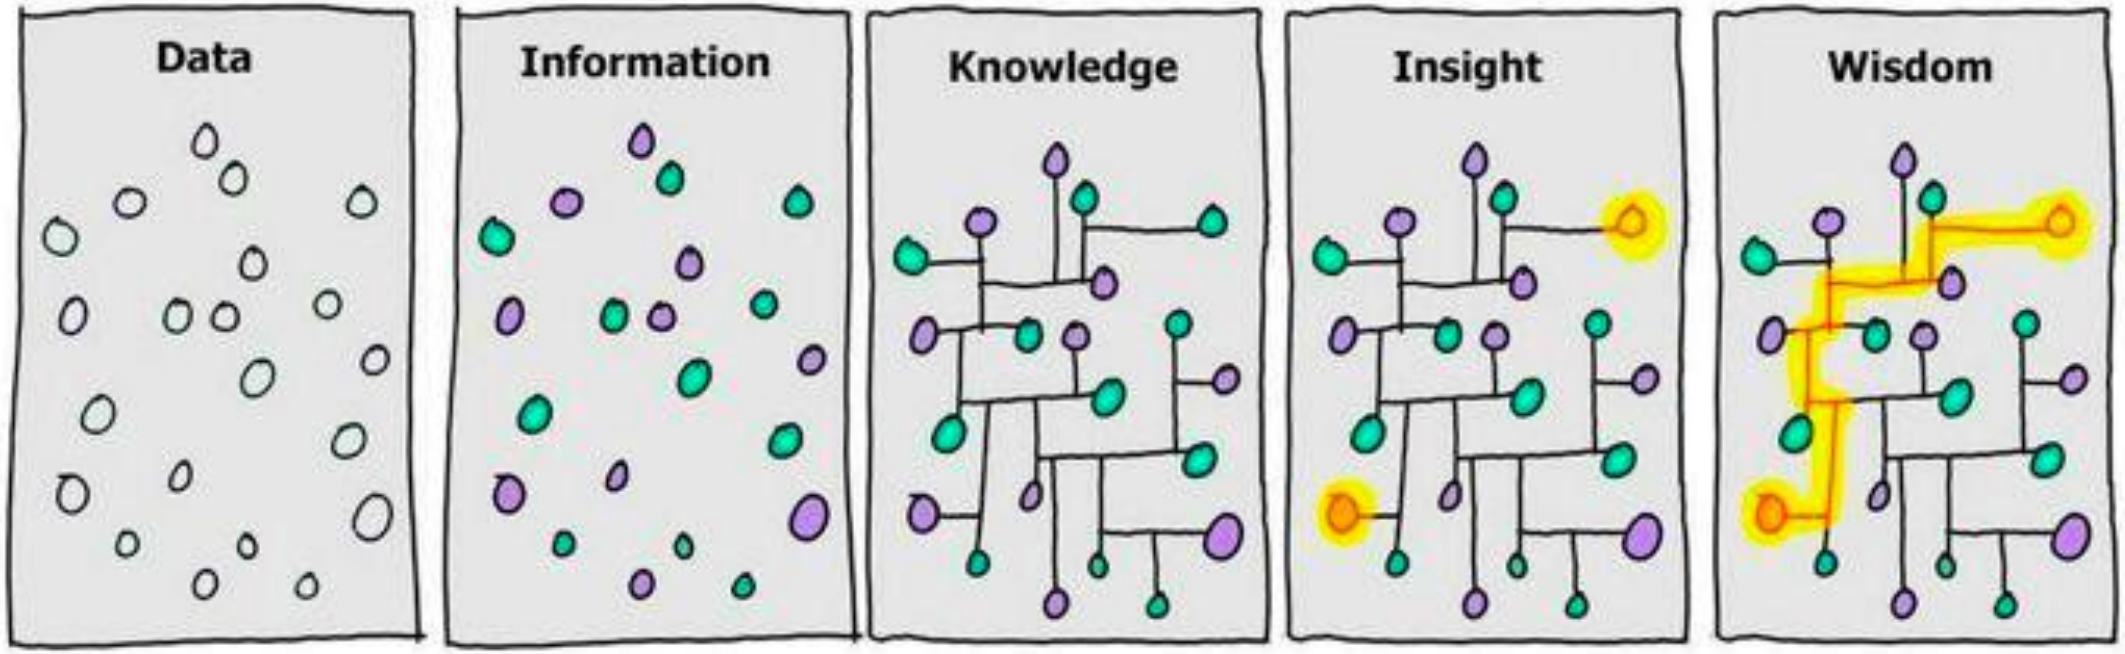


- 算力资源：无优势
- 智能算法：跟随而难领先
- 场景数据：丰富，利用率待提高

数据和模型

- 随着AI和数据的进一步结合，AI已经达到了数据比算法（模型）更重要的地步。
- 如果将AI视为一个有移动部件的系统，那么就应该保持模型的相对固定，专注于高质量的数据来微调模型，而不是继续推动模型的边际改进。

数据为中心的AI:



2.1 数据准备

各类数据分析之前，需要开展数据准备，主要包括数据采集和数据预处理等任务：

- 数据采集：
  - 内部数据库抽取，外部系统采集，网页，物联采集等；
- 数据预处理
  - 数据抽样和过滤
  - 数据标准化与归一化
  - 数据清理

(1)数据抽样和过滤

- 一般来说，处理大量数据的一个方法就是**减少要处理的数据量**，从而使处理的数据能够达到当前的**处理能力**能够处理的程度。
- 可以使用的方法包括**抽样**和**过滤**。
- 数据抽样的方法：
  - 随机抽样（抽签法、随机数法、水库抽样等）
  - 系统抽样
  - 分层抽样
  - 加权抽样
  - 整群抽样
- 数据过滤：除了采用抽样的方法减小数据量外，有时候还需要选择满足某种**条件的数据**，从而使得分析集中在具有某种条件的数据上。例如，可以通过简单的数据库SQL语句实现**过滤操作**。

(2)数据标准化与归一化

- 数据的标准化是**将数据按比例缩放，使之落入一个小的特定区间**。在某些比较和评价的指标处理中经常会用到，**去除数据的单位限制**，将其转化为**无量纲**的纯数值，**便于不同单位或量级的指标能够进行比较和加权**。其中最典型的就是数据的归一化处理，即将数据统一映射到[0,1]区间上。

- 标准化和归一化常用方法：
  - 0-1标准化
  - Z-score 标准化

标准化

- 0-1标准化也叫离差标准化，是对原始数据的**线性变换**，是结果落到[0, 1]区间，一种常用的转换函数是 $x = \frac{x - min}{\max - min}$，其中 max 为**样本数据的最大值**，min 为**样本数据的最小值**。这种方法的一个缺陷就是当有新数据加入时，可能导致 max 和 min 的变化，需要重新计算。

- 例如一组样本中有两个属性：身高和体重。这些样本的体重都在 50~70kg之间，身高在 160~185cm之间。如果直接使用欧式距离进行计算，会出现一定的偏差。此时，我们使用0-1标准化，将所有样本的每个属性都转化成0～1间的小数，就可以正常地使用欧式距离计算。

- 另外，模糊逻辑的参考值设定也可以使用标准化处理的结果。

Z-score 标准化

- Z-score 方法基于**原始数据的均值和标准差**进行数据的标准化。经过处理的数据符合**标准正态分布**，即均值为0，标准差为1，其转换函数为：$x = \frac{X-\mu}{\sigma}$，其中μ为所有样本数据的均值，σ为所有样本数据的标准差。

- 例如，我们想要获取一组电子元器件的使用寿命信息，已知均值为 15000h，方差为100，就可以通过这个变化，使用标准正态分布来方便我们进行后续的计算。

(3)数据清理

- 数据的质量直接影响着**数据的价值**，并且**直接影响着数据分析的结果**以及我们以此做出的**决策的质量**。
- 质量不高的数据不仅仅是数据本身的问题，还会影响着企业经营管理决策；错误的数据还不如没有数据，因为没有数据时，人们还会基于经验和基于常识的判断来做出不见得是错误的决策，而错误的数据会引导人们做出错误的决策。
- 因此**数据质量**是**企业经营管理数据治理**的关键所在。

数据质量概述

数据质量包括以下维度：

- **数据一致性**
  - 例如，数据（区号=“10”，城市=“上海”）含有一致性错误，因为10是北京区号而非上海区号。
- **数据完整性**
  - 例如，某医疗数据库中的数据一致且精确，但遗失某些患者的既往病史，从而存在不完整性，可能导致不正确的诊断。
- **数据准确性**
  - 例如，某城市人口数量为 4 130 465 人，而数据库中记载为 400 万人。
- **数据时效性**
  - 例如，某数据库中的用户地址在 2010 年是正确的，但在 2011 年未必正确，即这个数据已经过时。
- **数据唯一性**
  - 例如，企业的市场、销售和服务部门可能维护各自的数据库，如果这些数据库中的同一个实体没有相同的标识或数据不一致，将存在大量具有差异的重复数据，导致实体表达混乱。

数据缺失

- 在真实世界中，拥有完整无缺失的数据是小概率事件。
- 数据集的元素缺失会有各种可能性：**不适用**，**没有采集**，**数据处理中操作失误**。
- 处理数据缺失的第一步是找出缺失的原因，这样才能恰当处理。

处理方法	优点	缺点
忽略数据缺失	方法简单	引入样本偏差&减少大量样本数据
用中位数填补缺失数据	易操作	牺牲了“缺失性”信息
设定特殊值代替缺失数据	易操作	可能造成数据倾斜
用类似数据记录代替缺失数据	保证所有数据可用且最小化样本偏差	操作更复杂

实体识别

- 实体识别是数据管理中一项重要的技术，**实体识别**的结果可以在数据质量管理的各个阶段得到广泛的应用，如**真值发现**、**不一致数据的发现**、**去除冗余数据**等。

- 实体识别要解决的问题主要包括以下两类冲突：
  - 冗余问题：同一类实体可能由相同的名字指代。例如名字王明，用英文可能是 Wang Ming，也有可能是 Ming Wang。
  - 重名问题：不同类的实体可能由相同的名字替代。例如在 DBLP 中检索某个作者名会检索出不同的作者。

错误发现与修复

- 除了填充缺失值和解决描述同一实体数据的冲突和策略，数据中还有可能存在各种错误。
- 错误的发现与修复策略分为以下几类：
  - **格式内容清洗**
  - **逻辑错误清洗**
  - **非需求数据清洗**

格式内容清洗

- 格式内容清洗:
  - **显示格式不一致：**
    - 这种通常与输入端有关，在整个多源数据时也有可能会遇到。例如时间、日期、数值、全半角等表示的不一致等。
  - **内容中含有非法字符：**
    - 某些属性值只允许包括一部分字符，例如身份证号是数字+字母x，中国人姓名是汉字。
  - **内容与该字段应用内容不符**
    - 例如姓名写了性别，身份证号写了手机等。

逻辑内容清洗

逻辑错误清洗

- **去重**
  - 去掉数据中的重复信息，由于数据存在同名和异名，去重通常要通过实体识别技术来实现。
- **去除不合理值**
  - 有时候用户会输入一些不合理的值。例如，年龄 2000 岁，月收入 100 000万，需要有效的检测这种不合理的值。
- **修正矛盾内容**
  - 有些字段是可以相互验证的，例如如果某个用户电话的区号是 010，但是城市是上海，我们就可以知道区号和城市两个属性中有某一个是错误的。或者两个记录中邮编相同但是城市却不同，从中可以发现两条记录中邮编和城市中某一个是错误的。

非需求数据清洗

- 针对分析过程中不需要且有错误的数据，可以考虑直接删除。
- 这种处理方法看似简单，但是实际操作起来需要考虑许多问题。例如，一些情况下，可能删除看上去不需要，但实际上对业务很重要的字段。
- 考虑到这些情况，可以考虑在出现错误的数据上**增加错误标记**，这样在数据分析的过程中会**忽略这些错误值**或者针对存在的**错误值设计劣质容忍**的数据分析算法，从而**最小化**错误对分析结果的影响。

2.2 数据治理

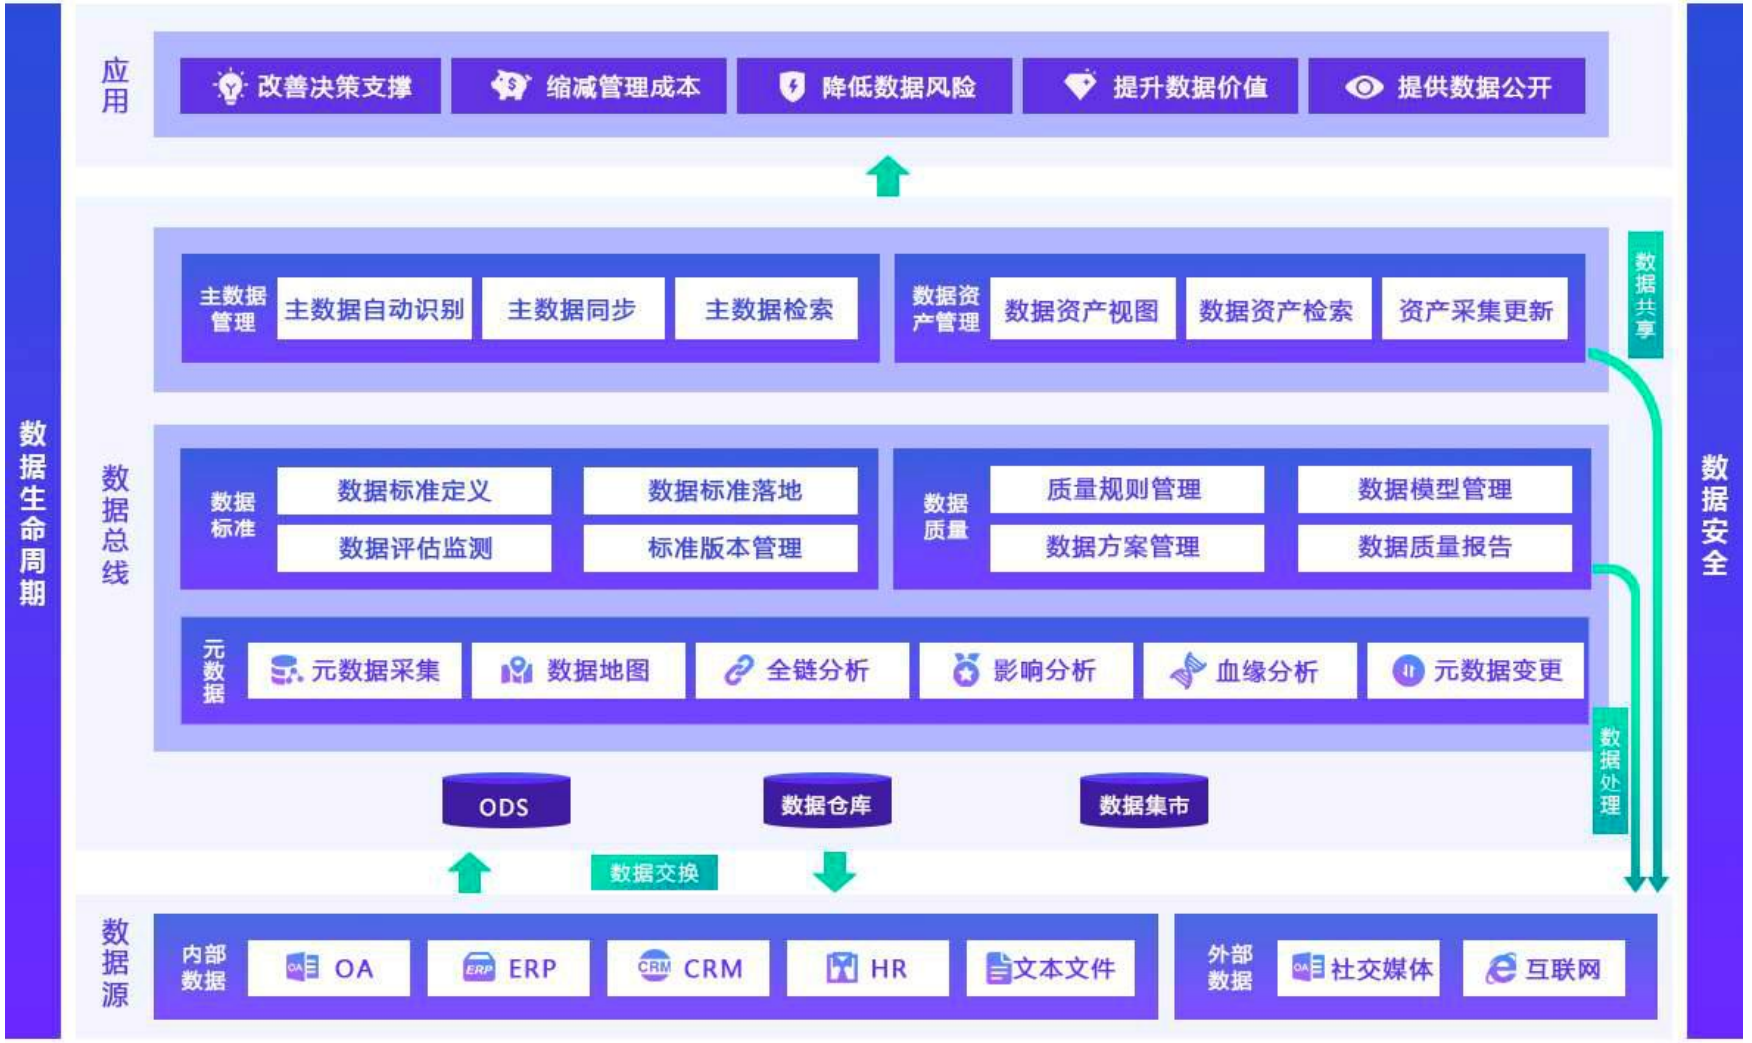
- 数据治理(Data Governance)，是企业数据治理部门发起并推行的，关于如何制定和实施针对整个企业内部数据的商业应用和技术管理的一系列政策和流程。
- 数据治理是专注于将数据作为企业的商业资产进行应用和管理的一套管理机制，能够消除数据的不一致性，建立规范的数据应用标准，提高组织的数据质量，实现数据广泛共享，并能够将数据作为组织的宝贵资产应用于业务、管理、战略决策中，发挥数据资产的商业价值。
- 数据治理是一套持续改善管理机制，通常包括了数据架构组织、数据模型、政策及体系制定、技术工具、数据标准、数据质量、影响度分析、作业流程、监督及考核等内容。

数据管理和数据治理

- 狭义的数据治理是以数据管理为主的数据资产管控体系。即通过制定数据治理政策并付诸实践，对组织内外的数据集开展一系列活动实现数据的管理应用。
- 广义的数据治理趋向于数据工程，趋向于技术平台的构建
- ISO 国际组织对数据治理和数据管理提出的差异化概念。
  - 数据治理履行数据管理的主要职能及数据治理规章，在管理的过程中哪些决策应被制定以及决策者是谁。
  - 而数据管理确保这些决策的制定和执行。
- 因此，数据管理侧重于数据内容本身被动式的管理，而数据治理既包含对数据的管理，也包含对相关利益主体的主动式管理，管理范围更广，体系更完善，效果也更显著

数据治理的架构

- 数据治理涉及的IT技术主题包括元数据、数据标准、数据质量、数据集成、主数据、数据资产、数据交换、生命周期、数据安全多产品组成的一整套解决方案。



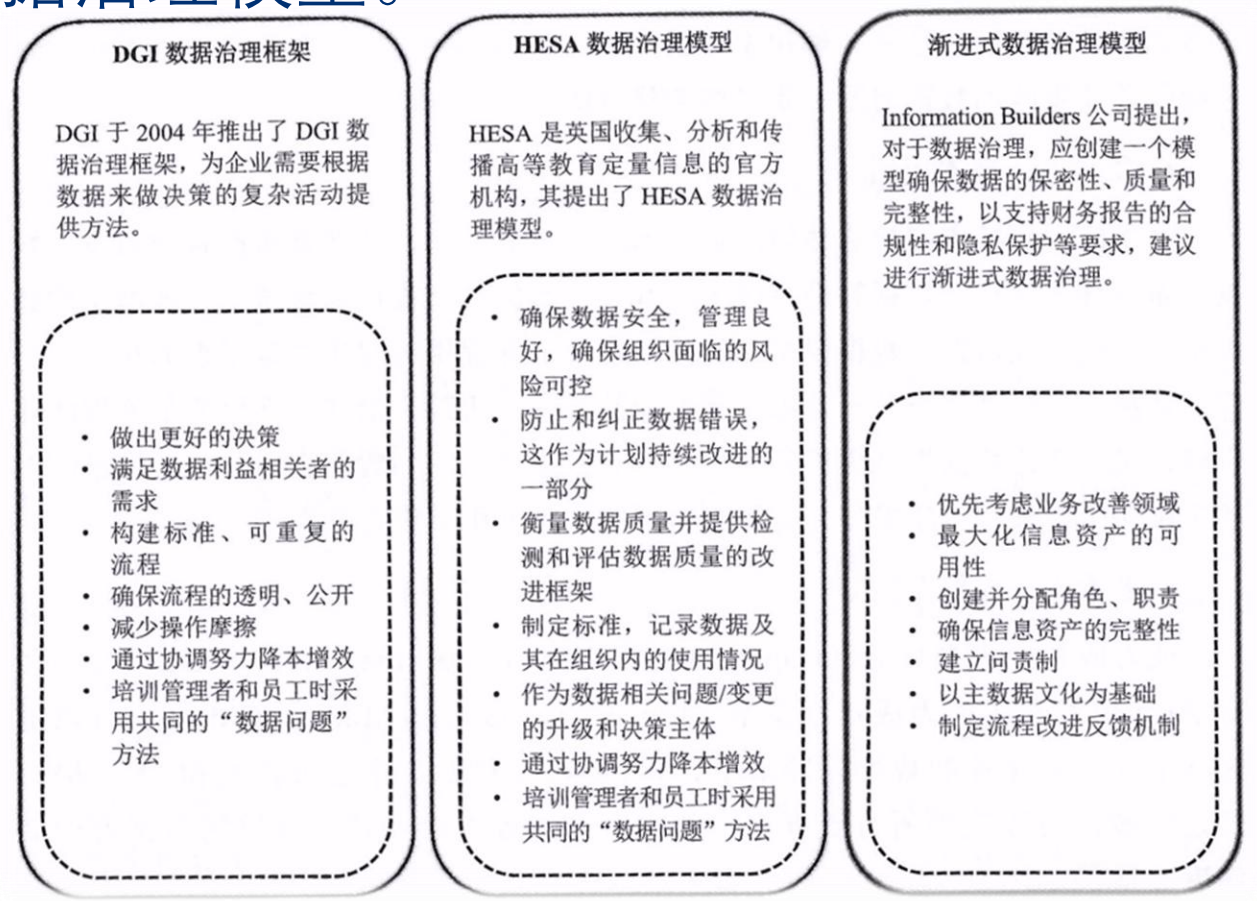
数据治理的6要素

数据治理要素主要取决于以下六个关键要素：

- 数据战略目标：数据战略目标是企业发展中的重要组成部分，是指导数据治理的最高原则。为提高数据的质量，保证数据的安全性、完整性以及存取规划而制定。
- 数据治理组织：包括制度组织和服务组织。制度组织通常是跨职能的，主要负责整体数据、战略数据、政策数据、管理度量指标等数据治理规程的规定。服务组织由数据管理专业人士构成，如数据质量分析师、严数据管理员等。
- 制度章程：具体包括。规章制度、管控方法、考核机制、技术规范等。其中一些是管理数据治理的职责，另一些是数据管理的职责。
- 流程管理：流程管理包括流程目标、流程任务、流程分级等。
- 技术应用：技术应用包括支持核心领域的数据治理工具和平台。
- 成熟度模型： CM模型包括5个联塑能力和25个提升的过程域，可以反映所有数据管理的内容，以促进企业建立自己的数据管理成熟度路线图。

数据治理模型

- 数据治理模型是一个框架，定义了数据创建、存储和维护以及数据处置的系统和流程，并明确了决策者的角色。
- 组织往往会使用多种类型的数据治理模型。
- 常见的数据治理模型有：
  - DGI数据治理框架
  - HESA数据治理模型
  - 渐进式数据治理模型



数据驱动概念

- 数据驱动的概念最早来自计算机科学领域及设计程序的过程中，以数据库中的数据为导向进行程序设计。
- 2013年，福斯特在数据科学与大数据数据驱动决策的关系中，将数据驱动决策定义为基于对数据的分析，而不是仅仅依靠直觉进行决策的实践。
- 大数据时代如何采用数据驱动的方式优化服务过程，提高服务效率及判断决策的科学性，至关重要。
- 由于现代工业高度发达，依靠物理、化学机理建立精确数学模型的传统控制理论方法已捉襟见肘。
- 数据治理的主要应用场景是商业智能，而商业智能是数据驱动的实现途径。

2.3 数据分类标准

- **数据分类是数据资产管理的第一步。不论是对数据资产进行编目、标准化，还是数据的确权、管理，或是提供数据资产服务，进行有效的数据分类都是其首要任务。**
- **数据分类的具体应用场景**
  - **行业维度**：根据不同行业的特点进行分类，例如金融、医疗、教育等。
  - **业务领域维度**：根据具体的业务领域进行分类，例如供应链管理、CRM等。
  - **数据来源维度**：根据数据的来源进行分类，例如内部系统、外部合作等。
  - **共享维度**：根据数据是否需要共享进行分类，例如公开数据、受限数据等。
  - **数据开放维度**：根据数据的开放程度进行分类，例如完全开放、部分开放等。

工业数据分类标准

- 业务域

产品设计	产品制造	产品测试	产品交付	产品运维	产品维修

- 概念域
- 逻辑域
- 物理域



数据智能在工业中的主要应用场景



以医疗影像为核心的医疗数据分类

医学影像检查报告

DICOM	放射类影像检查图像记录	其他影像检查图像记录
DB/XML	放射类检查报告记录	其他检查报告记录
JPG/PDF/MP4	放射类检查报告记录	其他检查报告记录
	放射类检查附件文件记录	其他影像检查附件文件记录

门诊就诊信息

DB/XML	门诊就诊记录	门诊医嘱明细记录	门诊收费明细记录

出院小结报告

XML	出院小结记录

诊断明细报告

XML	诊断明细记录

住院就诊信息

DB/ XML	住院护理记录	住院转诊记录	住院会诊记录	住院就诊记录	住院医嘱明细记录	住院费用结算明细记录

实验室检验报告

XML	实验室检验报表记录	检验结果指标记录	细菌结果记录	药敏结果记录

手术明细报告

XML	手术明细报告记录

电子票据

DB/ XML	电子票据记录	电子票据冲红记录

2.4 智能数据治理

- 智能数据治理引申于数据驱动的DSS，它是建立在数据仓库、数据挖掘和分布式多元数据分析基础上的一种数字化的，组织数据的管理方式。
- 通过构建智能数据架构来帮助决策者高效利用内部和外部多种类型、多种来源的结构化和非结构化数据，进而对数据进行挖掘和分析，识别某种数据训练模式，便于追溯、显示和分析历史数据，进而预测未来的发展方向和趋势。
- 智能数据治理从被动管控转为主动化服务，实现了自理能力的赋能应用可实现以下功能：
  - 破除部门壁垒。打通横向跨专业的分析挖掘通道。
  - 打通内部多层次数据通道，形成统一资源目录，实现上下级数据共享交换。
  - 消除内外数据的鸿沟，实现内外数据的关联分析。
  - 建立企业标准，实现统一管理统计口径。
  - 通过治理平台，统一对外提供数据服务和应用解决方案，以业务系统和数据应用充分协同。

传统治理与智能数据治理

- 传统数据治理和智能数据治理的任务、目标、技术有一些差异:
- 任务不同
  - 传统数据治理的定义是对于数据资产管理实施权利和进行控制的活动集合。IBM公司认为，传统数据治理是对数据中的可用性、相关性、完整性和安全性的全面管理。传统数据治理侧重数据管理，弱化价值创造。
  - 智能数据治理中，数据被视为一种资产，强调数据在推动智能应用中的巨大作用。应用大数据、云计算和人工智能等技术，可以有效管理组织的海量数据和繁多数据类型，实现智能治理手段的智能化，支持价值创造。
- 关注点不同
  - 传统数据治理的目的是保证**数据的准确性、一致性、可访问性和合规性**;
  - 而智能数据治理更强调发挥**数据的应用价值**，更关注如何将业务目标映射到数据分析任务上，如数据分类和数据建模。
- 总体来说，传统数据治理是智能数据治理的基础，智能数据治理则是传统数据治理以数据驱动为目标的技术演进。

智能数据治理的特点

智能数据处理主要涉及到三方面的特点：

从人工操作到可扩展的自动化

- 在传统的数据管理方法中，数据管理人员需要记录组织中的各领域的信息，并建立全面的数据字典。
- 针对大规模手工操作耗时费力的问题，可扩展的自动化技术可以帮助组织高效完成繁琐的基础数据管理操作。智能处理技术帮助组织完成前期的复杂工作，如基础数据在前期可以完成常见模式重复数据识别和名称匹配。在进行数据治理的核心流程是只需要进行数据管理和微调即可，节省了大量时间。

复杂性到一致性

- 数据治理需要整合多元异构的数据类型，并将其应用到各种跨学科业务领域中。一些传统的数据治理方法，使用完全开放的数据来记录资产类型和相互关系，但这种方法产生的问题比要解决的问题更多，反而增加了数据治理的复杂性。
- 自动化和智能化的过程中的一致性至关重要。事实上，任何行业和组织的业务构成要素都是相对一致的。为了避免重复工作，需要在一个更稳健的整体视图中操作面向不同组织的数据处理需求。组织保持的一致性越高，越能有效利用自动化和机器学习的智能技术。

孤立操作到可扩展模型

- 传统数据治理部门和操作往往和组织相互孤立，无法和组织的业务目标建立有效连接。随着治理需求和覆盖范围不断扩大，越来越多的组织赋予了数据治理更丰富的内涵，如数据智能、数据赋能。
- 而数据智能处理通过不同学科的融合技术，将不同的治理阶段与业务目标相连接，便于领导者依据这些数据进行分析和决策

目录

- 1 数据智能平台

  1.1 大数据定义-1.2数据分析特点-1.3 大数据处理过程

- 2 数据治理

  2.1 数据准备-2.2数据治理-2.3数据分类-2.4智能数据治理

- 3 知识图谱

  3.1 知识图谱发展-3.2知识图谱表示及存储-3.3 知识图谱构建-3.4 KG构建实例

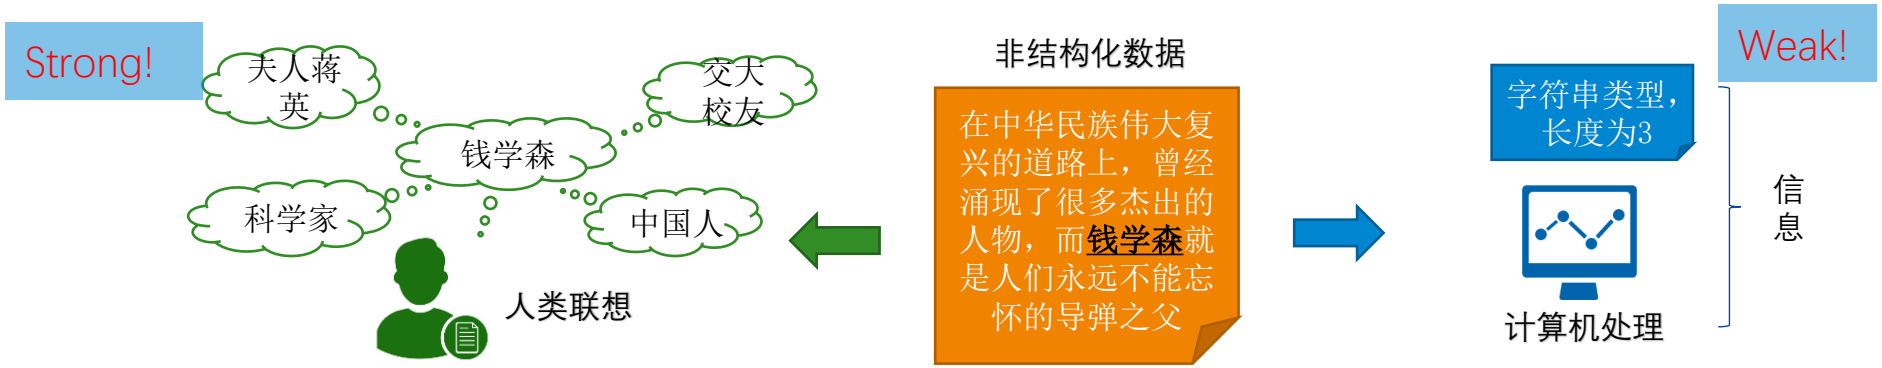
- 4 基于知识图谱的智能数据治理

  4.1 航天元器件应用实例-4.2其他实例

- 5 小结

3 知识图谱

- 知识图谱，作为一种人机可理解的信息表示和存储介质，成为智能化信息管理的重要解决方案。



知识图谱的优势：

（1）知识图谱用节点和关系组成图结构，“高保真”地表达这个多姿多彩世界的各种关系，具有直观、自然、直接和高效的特点。

（2）知识图谱的交互探索式分析，模拟人的思考过程，能够发现、求证、推理，不需要专业人员协助。

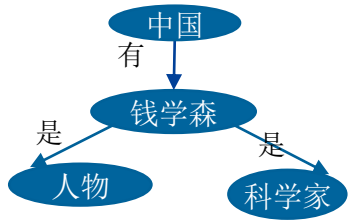
（3）知识图谱具有学习能力，利用机器学习技术，可以通过人机协同，不断训练提高其自主性。

数据管理技术的发展历程

专家系统
(1970s)

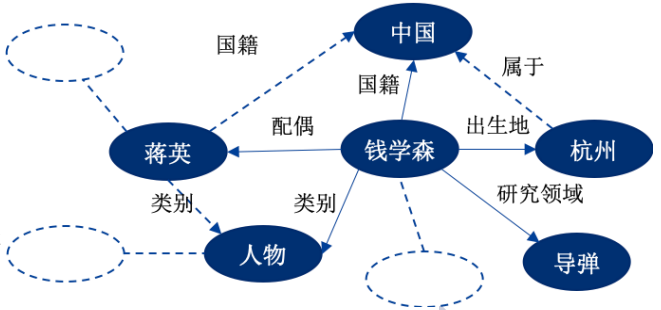
- 自上而下的
- 规则定义

语义网
(1998)



- 使用可以被计算机理解的方式描述事物的网络

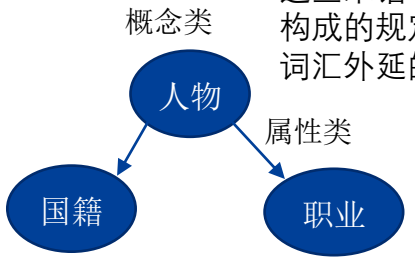
知识图谱
(2012)



- 包含海量实体资源与关联关系的超大型语义网络

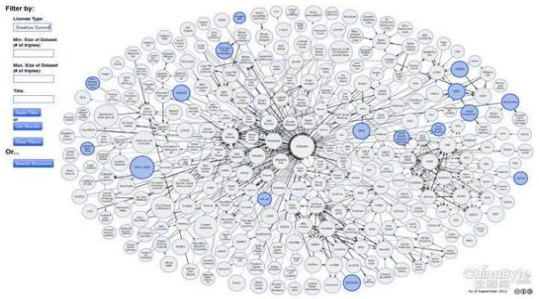
本体论
(1980s)

- 构成相关领域词汇的基本术语和关系，以及利用这些术语和关系构成的规定这些词汇外延的规则



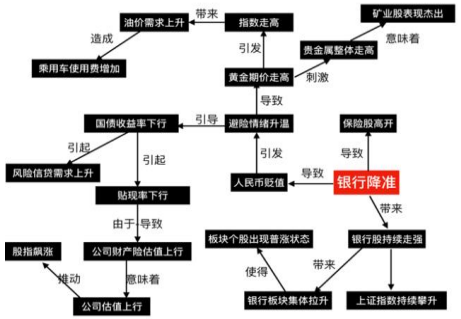
关联数据 (2006)

- 语义网的实践之一,通过URI发布、共享、连接Web资源



事理图谱
(2017)

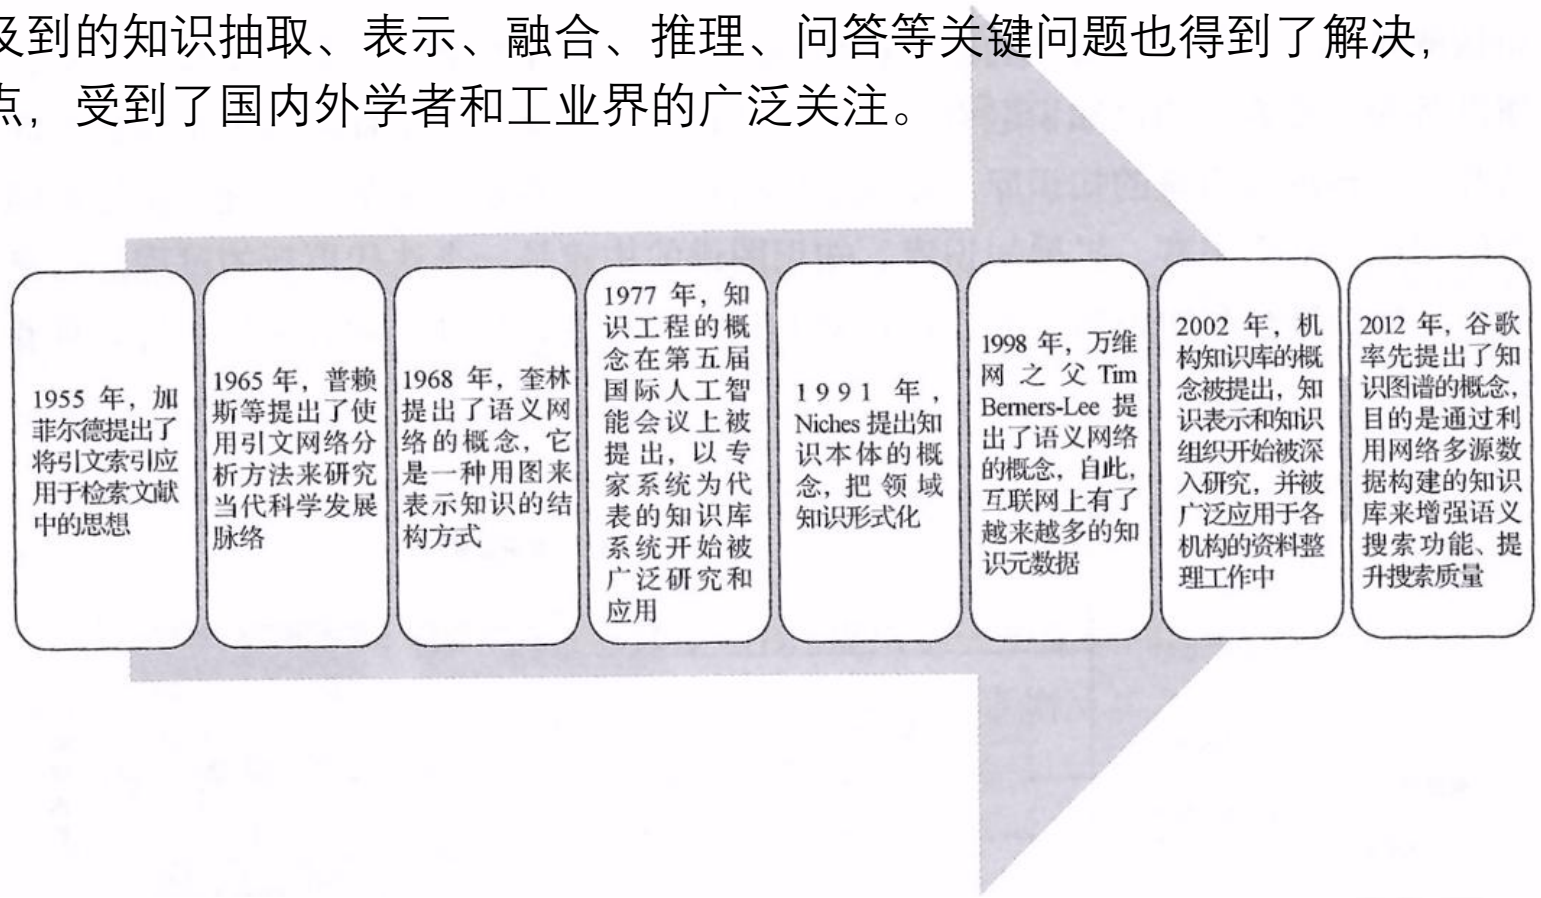
- 描述事件演化规律和模式的特殊知识图谱



3.1 知识图谱发展

- 知识图谱是在历史进程中有很多相关技术相互影响、传承、发展而来。
  - 1998年，万维网之父提出了以网络促使网络链接开放，link data规模剧增，互联网上有了越来越多的知识元数据。
  - 知识图谱就是在这样的一个大背景产生的一种知识表示和管理方法。最初由2012年Google提出，主要用于优化搜索引擎体验。
  - 随着人工智能的蓬勃发展，知识图谱涉及到的知识抽取、表示、融合、推理、问答等关键问题也得到了解决，知识图谱成为知识服务领域的一个新热点，受到了国内外学者和工业界的广泛关注。

知识图谱从人类对世界的认知角度，阐述世界万物的联系，赋予机器认识。智能成为知识服务领域的一个热点，被广泛应用于智能问答、语言与理解、大数据、决策分析等各种领域。



知识图谱的演进

- 知识图谱源于基于链接的思想，将点和线关联起来，并由点-线-面出发，慢慢理清其中的逻辑关系。
- 知识图谱的发展可以分为三个阶段：
  - 知识图谱起源：在此期间，引文网络分析是一种研究当前科学发展脉络的常用方法。
  - 知识图谱发展：以网络得到了快速发展，知识本体成为计算机科学领域的重要研究方向。知识图谱最新以网络本体在知识组织上和表达上的理念，使得知识更易于在计算机和人，计算机之间开展数据的交换、流通和加工。
  - 知识图谱的繁荣：2012年至今是知识图谱的繁荣阶段。2012年，谷歌知识图谱用来支持下一代引擎和在线广告，大大改善了搜索引擎的性能。在开放的互联环境下，以链接为中心的系统更容易生长和扩展。通过在网络使用本体模型来形式化的表达数据中的隐含语义RDF和owl，知识图谱具有很强的适应性，应用广泛。

知识图谱：连接数据与智能的桥梁

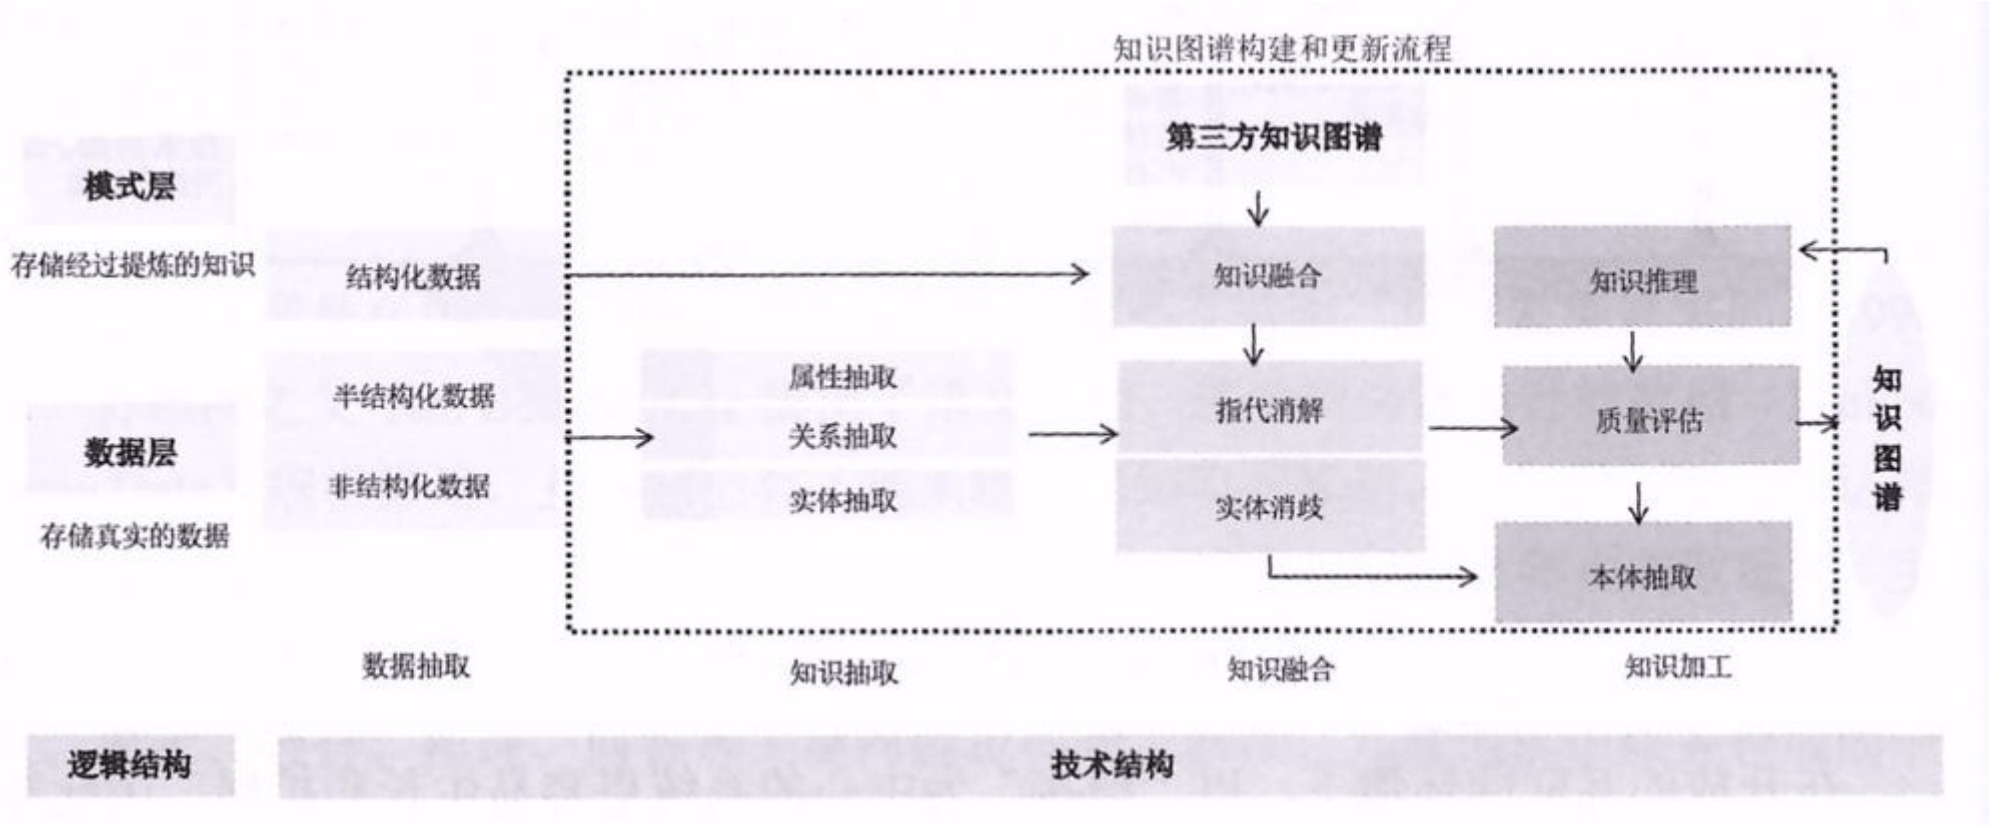
- 知识图谱的应用领域广泛，包括但不限于：
  - 智能搜索：通过理解查询的语义，提供更准确的搜索结果。
  - 推荐系统：基于用户的兴趣和行为，推荐相关的产品或内容。
  - 自然语言理解：作为聊天机器人和虚拟助手的知识库，提供更自然的交互体验。
  - 数据分析和决策支持：揭示数据间的隐藏模式和趋势，辅助商业决策。
  - 教育和研究：构建学科知识图谱，支持教育内容的个性化推荐和学术研究。

尽管知识图谱具有巨大的潜力，但在构建和应用过程中也面临一些挑战：

- 数据质量问题：数据的不完整性、不一致性和错误性会影响知识图谱的准确性。
- 动态更新问题：现实世界是不断变化的，知识图谱需要及时更新以反映这些变化。
- 隐私和安全性问题：知识图谱中可能包含敏感信息，需要确保数据的隐私和安全。

知识图谱体系

- 知识图谱的体系包含自身的逻辑架构和技术架构两部分。
- 逻辑架构又分为数据层和模式层：知识是以事实为单位进行存储的，
  - 数据层主要由一系列的事实构成。例如三元组，可选择RDF表结构和图数据库作为存储介质。
  - 模式层构建在数据层之上，其存储经过提炼的知识，通过本体库来规范数据层的一系列事实表达。



3.2 知识图谱的表示及存储

- 知识的存储包括知识表示和知识存储两部分：
- 知识图谱表示的要点包括：
  - RDF、RDFS、OWL都是基于以网络的知识表示框架，在节点和边的取值上做了约束，并且制定了统一标准，为多元数据的融合提供了便利。
  - 这三种数据模型都是基于XML的数据，主要用于建立计算机传输和认识处理数据的标准。
  - Spark是一种用于RDF的结构化查询语言

- 知识图谱技术是RDF和Owl两种技术的升级和演化，旨在利用图结构建模、识别和推断事物关系、事物之间的关系和沉淀领域知识。

知识表示

- 常用的知识表述主要有：三元组、RDF、向量表示、关联数据(Linked Data)…

本体层

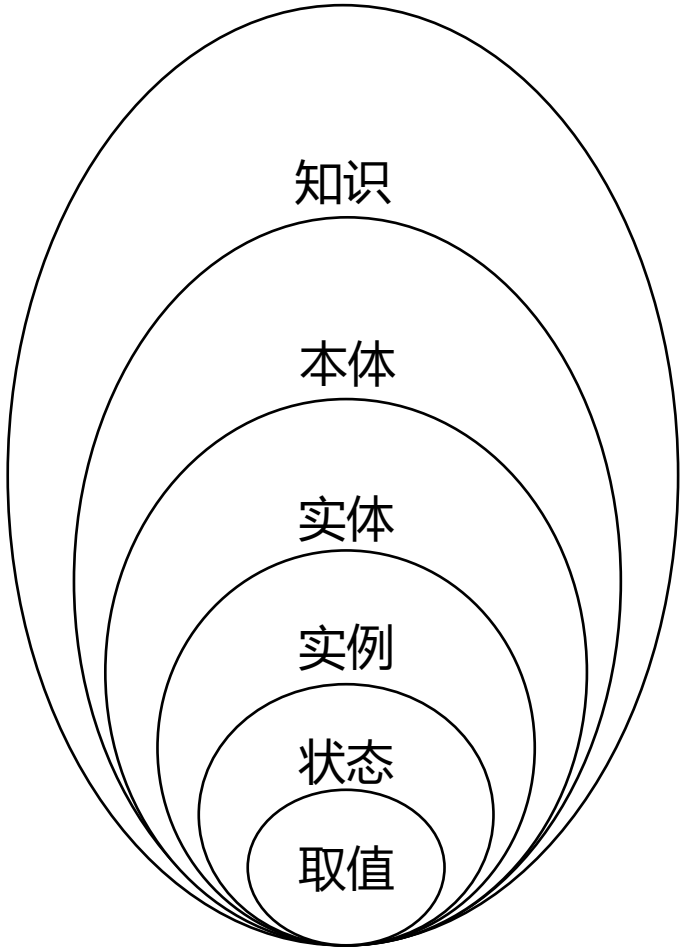
- 专家构建和本体演化：由新业务需求或数据模式变更本体。
- 本体对齐：基于本体语义、结构等相似度进行融合。

实体层

- 实体发现：
  - 实体消歧：基于关联关系语义和图结构推断实体词义；
  - 共指消解：结合基于实体属性相似度计算和等价推理方法，识别和合并相同实体的不同标识符。
- 关联发现：
  - 基于分类、聚类、关联分析的传统方法；
  - 基于深度学习的方法：卷积模型、循环模型、词法句法模型。

实例层

- 基于聚类的方法：基于图结构相似性挖掘实例中的数据模式。
- 基于规则映射的方法：基于本体实例关系、逻辑推理或外部知识库，将实例映射到本体，使实例数据获得语义。



知识存储（基于关系型数据库）

- 基于表结构的存储方案，利用关系型数据库的二维表数据表存储知识图谱的数据。根据不同的设计原则，将数据按照不同类型表进行存储。
- 基于表结构的存储可分为五类：
  - **三元组表**：每个三元组存储为DB一行记录

Subject	Predicate	Object
Caihm	就职于	SJTU

  - **属性表**：类型表

人物

姓名	姓名	年龄	体重/kg
Caihm	男	22	60

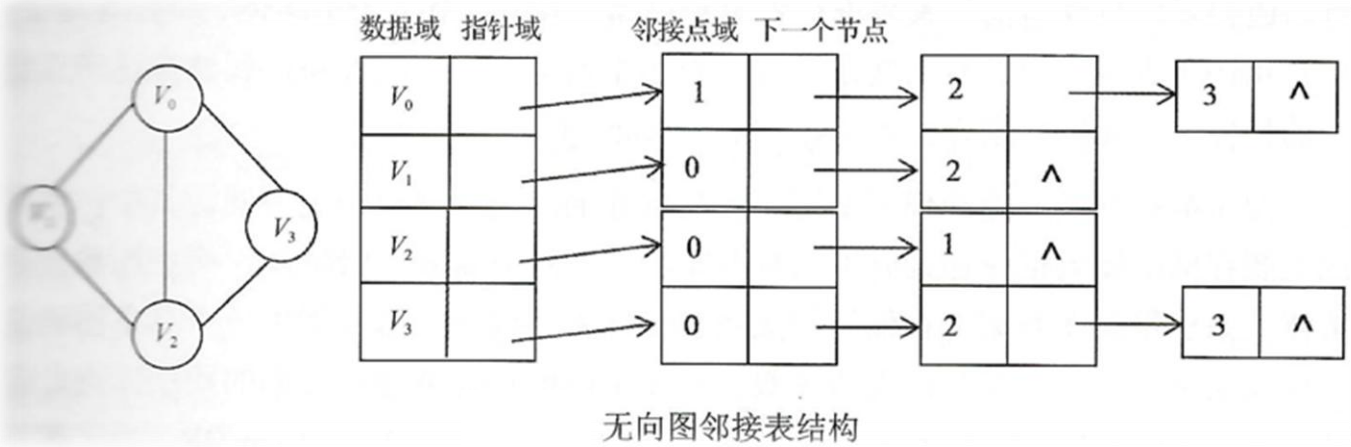
作品

书名	出版日期	出版社	ISBN
软件工程	2021.11	上海交通大学	99999999

  - **水平表**：按主语分表，每个表存储知识图谱一个主语的所有谓语和宾语；
  - **垂直表**：按谓语分表，每个表存储知识图谱一个谓语的所有主语和宾语；代表：SW-store
  - **全索引**：主语S、谓语P、宾语O的六种组合，SPO，SOP，PSO，POS，OSP，OPS，代表RDF-3X和Hexastore数据库

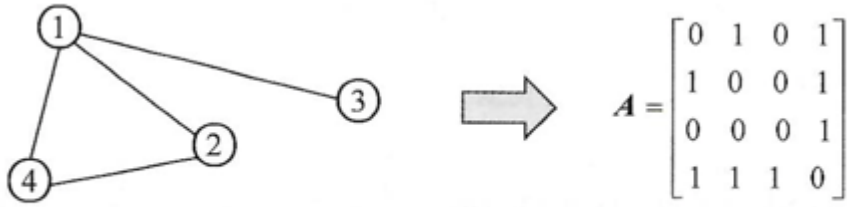
知识存储（基于图数据库）

- 利用图结构对知识图谱的实体和关系进行存储，对应图数据库，数据集模型是属性表。
- 常见的图存储模式有两种：
  - 邻接表



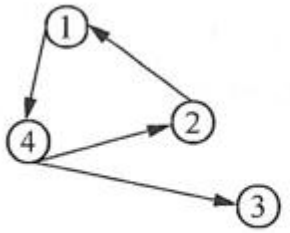
无向图邻接表结构

  - 邻接矩阵：用多个NXN维的矩阵来存放顶点间的关系。



$$A=\begin{bmatrix}0&1&0&1\\1&0&0&1\\0&0&0&1\\1&1&1&0\end{bmatrix}$$

无向图的邻接矩阵



$$A=\begin{bmatrix}0&0&0&1\\1&0&0&0\\0&0&0&0\\0&1&1&0\end{bmatrix}$$

有向图的邻接矩阵

3.3 知识图谱构建过程

知识图谱的数据整体上可以分为数据模型（本体）和具体数据，在此基础上，目前主要有两种知识图谱构建方式：

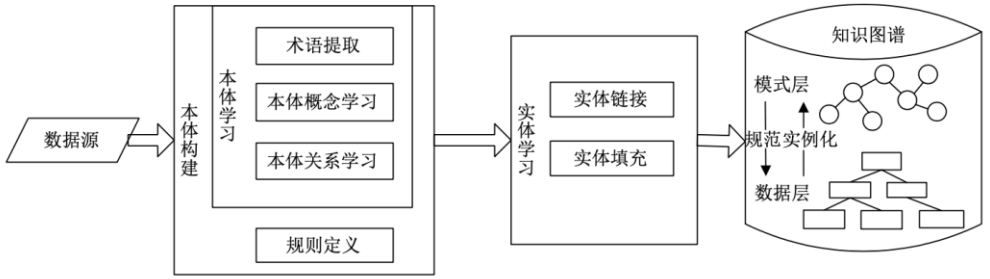
- 数据驱动的知识图谱构建（自底向上）：数据驱动的知识图谱构建方法具有重要意义。
- 本体导向的知识图谱构建（自顶向下）：需要大量的专家手动地构建，耗时耗力；发生变化，对知识的更新和演进也需要投入极高的成本。

- 一般来说，对于行业知识图谱来说，行业术语、行业数据都相对比较清晰，因此，构建数据组织框架（本体），然后采用自顶向下的方式来建设知识图谱。
- 再有丰富数据的基础上，可以开展数据的分类聚类等处理，以确定知识图谱的数据模型，然后根据数据模型约定的框架来补充数据，最后完成知识图谱的建设，即自底向上的方式。

上下结合的知识获取

➢ 自顶向下的知识获取模式

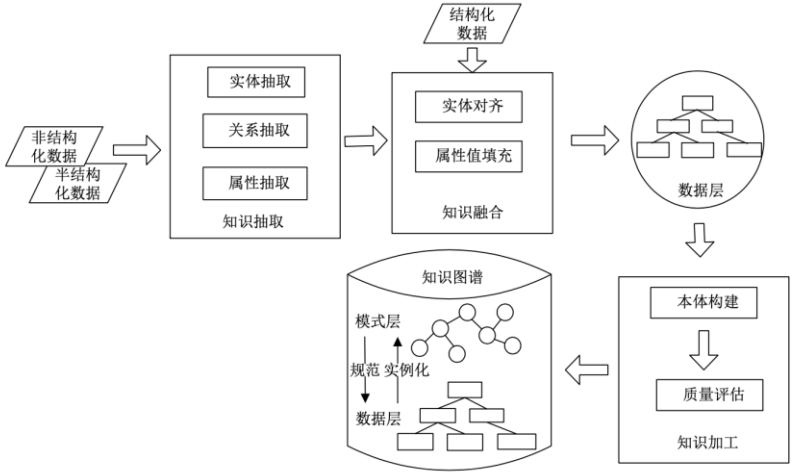
- 专家建立概念本体，提供顶层的知识抽取指导



自顶向下特点：
本体规范，但灵活度不足

➢ 自底向上的知识获取模式

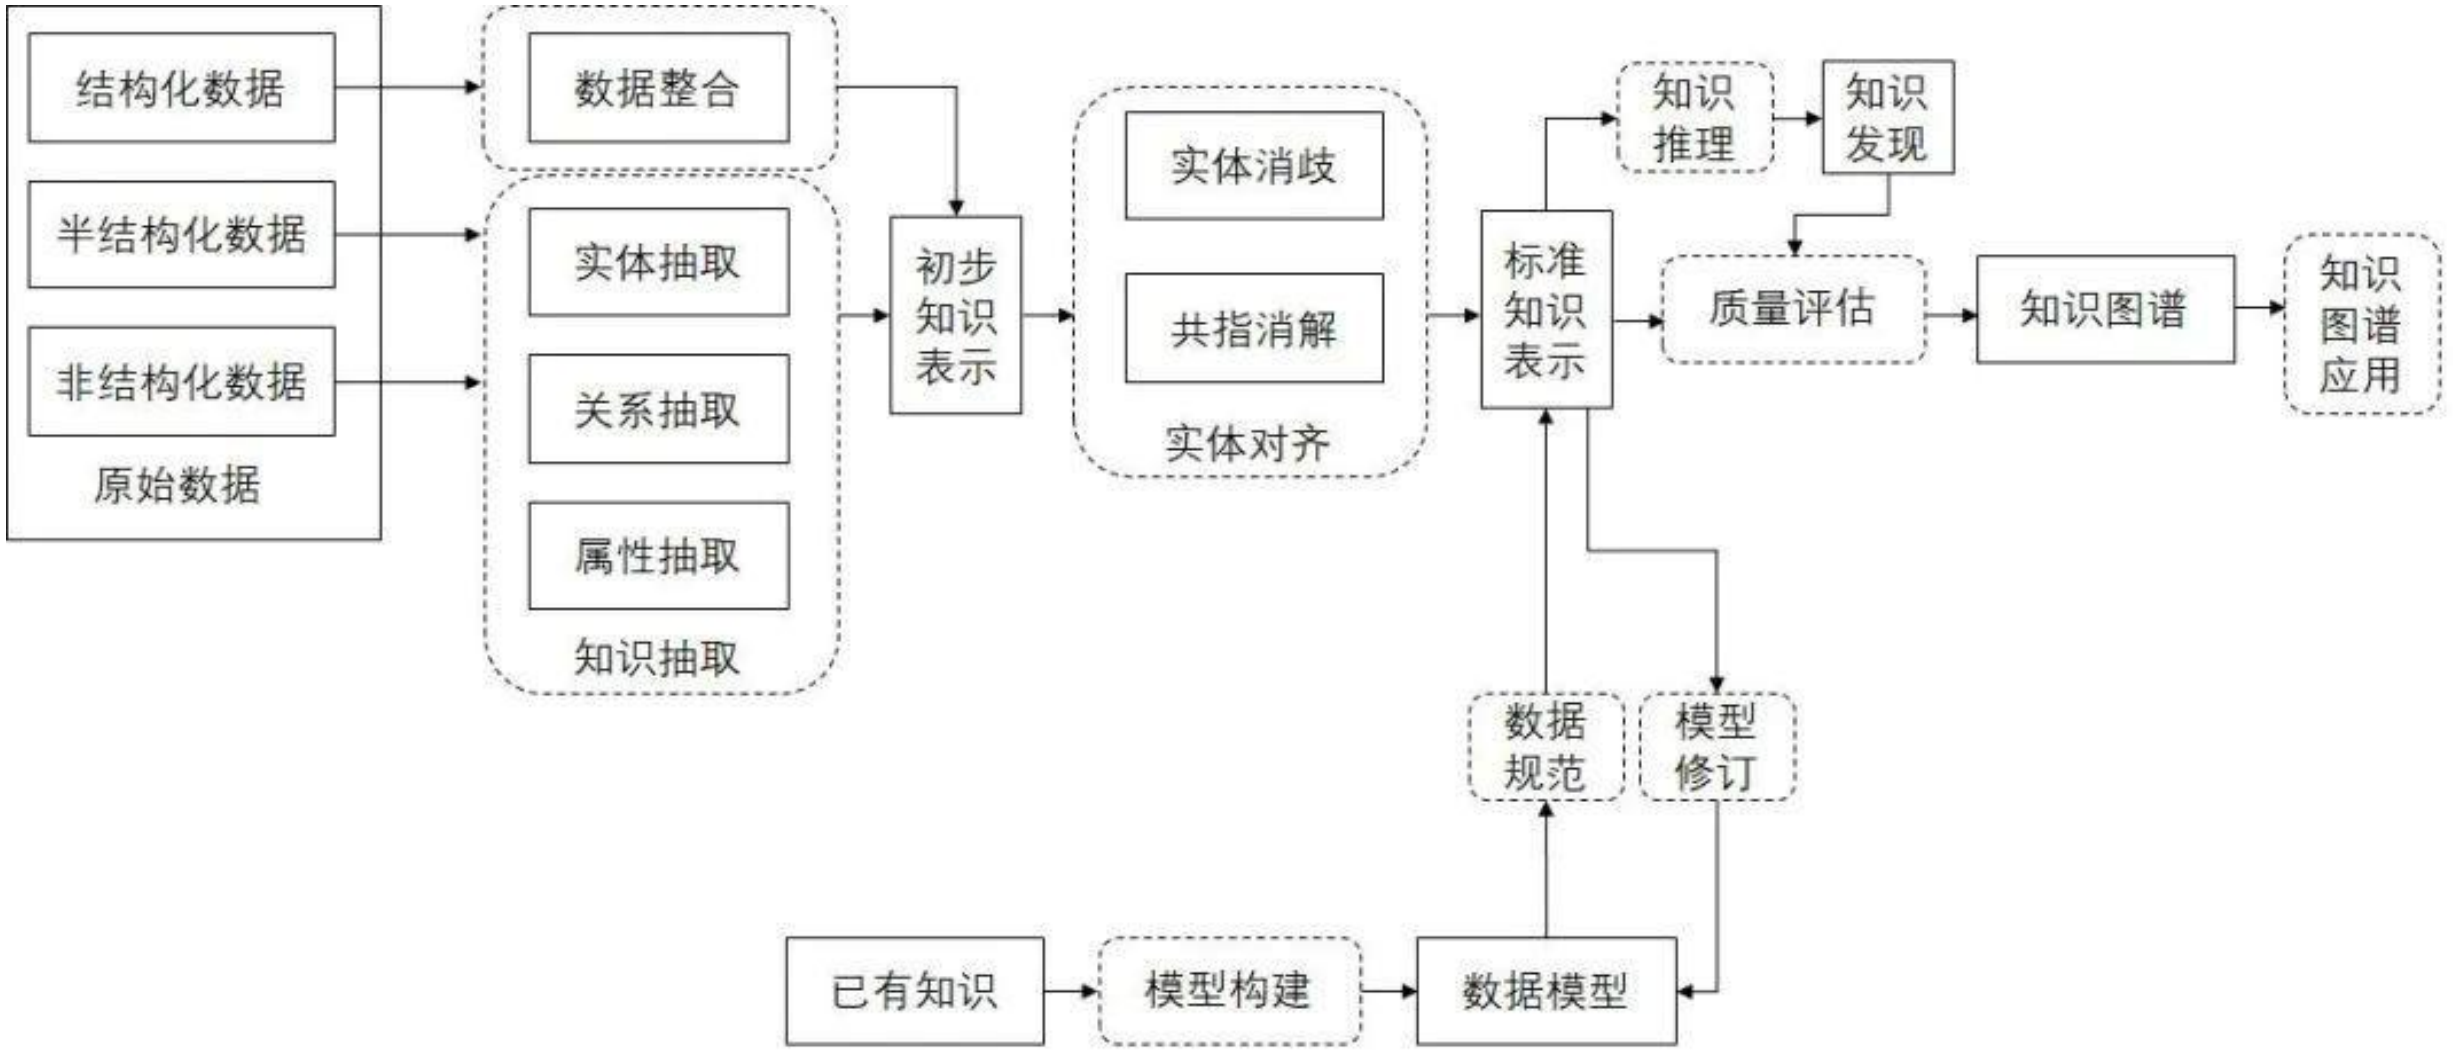
- 通过对数据源的启发式分析和上下文语义分析提取实体及关系，自底向上抽取知识



自底向上特点：
知识丰富，但规范性和可靠性不足

知识图谱构建过程

- 两种模式的差异主要在于驱动的要素不同：



（1）数据抽取

结构化数据

- 基于本体设计的理论方法，根据关系型数据库中的元数据中包含的实体和关系进行元数据规范化、概念对齐和知识融合，从中提取出本体、实体、关系、属性及约束。

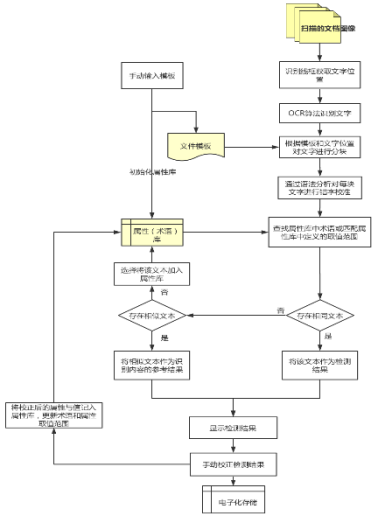
半结构化数据

- XML等格式文件的解析，获取实体、属性等。

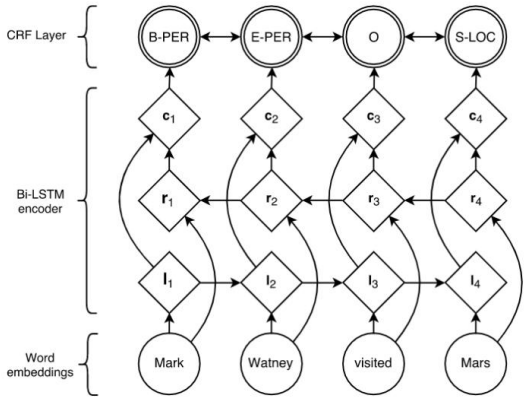
非结构化数据

- 通过语法词法分析提取实体关系，根据现有知识图基于OCR识别纸质表单中的历史数据，利用语义模版对实体识别和分型，通谱进行实体、属性、关系对齐。

- 基于自然语言处理，采用LSTM+CRF的端对端判别式模型自动提取实体关系：对大规模自由文本进行分词和语法分析，经过词嵌入后输入到LSTM以获取每个词对应的标签，最后CRF预测标签之间的关系，从而提取出实体关系。



基于OCR的数据抽取



基于自然语言处理NLP的知数据抽取

结构化数据抽取

- D2R:Database to RDF是从关系型数据库抽取知识的一种方式。数据库表名直接映射到RDF中的类，字段映射到类的属性。类之间的关系可以从表示关系的表中得出。

```
generate-mapping -u root -p root
-o kg_movie.ttl
jdbc:mysql:///kg_movie
```

SPARQL:

```
PREFIX : <http://www.Kg_movie.com#>
PREFIX rdf: <http://www.w3.org/1999/02/22-rdf-syntax-ns#>
PREFIX owl: <http://www.w3.org/2002/07/owl#>
PREFIX xsd: <http://www.w3.org/2001/XMLSchema#>
PREFIX rdfs: <http://www.w3.org/2000/01/rdf-schema#>
PREFIX map: <http://localhost:2020/resource/#>
PREFIX db: <http://localhost:2020/resource/>
SELECT ?n WHERE {
  ?s rdf:type  :actor.
  ?s :actor_actor_chName '周星驰'.
  ?o :movie_movie_chName ?n.
}
LIMIT 10
```

Results: Browse Go! Reset

SPARQL results:

n
"大话西游之月光宝盒"
"审死官"
"家有喜事"
"老鲁"
"西游伏妖篇"
"双子神偷"
"刀马旦"
"喜水红颜"
"满城尽带黄金甲"
"喜欢你"

数据抽取

半结构化数据抽取

- 网页：正则表达式（RPA）

非结构化数据抽取

- 从知识类型划分：实体抽取、关系抽取、属性抽取
- 从数据来源划分：文本、图像、视频、数据流
- 常用方法：
- 基于字典和规则
- 基于深度学习模型
- 基于大模型

（2）知识抽取

知识抽取主要技术包括：

- 实体识别：使用自然语言处理（NLP）技术，如命名实体识别（NER），从文本中识别出实体。
- 关系抽取：确定实体间的关系，这可以通过监督学习、无监督学习或远程监督学习方法实现。

（3）知识融合

- 知识融合的目的是解决实体和关系的歧义问题，合并同义词或不同来源的相同实体，确保知识图谱的一致性。
- 就是将多个知识库中的知识进行整合的过程。主要涉及到指代消解、实体消歧等处理，就是将不同知识库对实体的描述进行整合，从而获得实体的完整描述。
- 通过知识融合，可以将不同知识库中的知识进行互补融合，形成全面、准确、完整的实体描述。
- 知识融合过程中，主要涉及到的工作就是实体对齐，也包括关系对齐，属性对齐，可以通过相似度计算，聚合，聚类等技术来实现。

知识融合算法

- 实体相似度计算
  - 语义相似度
    - 余弦距离
    - 欧氏距离
    - 曼哈顿距离
    - 明可夫斯基距离
    - Jaccard 相似系数
    - 皮尔森相关系数
    - SimHash + 汉明距离
  - 结构相似度
    - 共同邻居相似度

(4)知识抽取和生成

- 针对不同类型的知识源，知识抽取设计的关键技术和需要解决的技术难点有所不同，但都包含三个主要工作，实体抽取、关系抽取和事件抽取。
  - 实体抽取：实体抽取也可以称为命名实体识别。从原始资料中自动识别命名实体，并帮并将其分类到定义的类别中，如人物、组织、地点、时间。实体抽取方法总体上可以分为基于规则的方法、基于统计模型的方法和基于深度学习的方法三类。
  - 关系抽取：是指从文本中抽取出两个或者多个实体的语义关系，以形成网状的知识结构。关系抽取与实体抽取密切相关，一般是在识别文体文本中的实体后，在抽取实体之间可能存在的关系。也可以通过联合模型同时实现两个任务。关系抽取通常面向非结构化文本数据。主要的方法有，基于模板的关系抽取方法及监督学习的关系抽取方法，基于深度学习的实体关系抽取方法。
  - 事件抽取：在知识图谱领域，事件只发生在某个特定点或者从某个时间段、某个特定区域内涉及到一个或者多个参与者的，由一个动作组成的事件或者状态变化。事件抽取只在从描述事件的文本中抽取用户感兴趣的事件信息，并以结构化的形式呈现出来，例如何人、何时何地做了何事。事件抽取的关键要素包括事件指称、事件触发时、事件元素、元素角色和事件类别等。
- 近年来，基于数据的本体抽取、规则生成成为知识抽取的重要方式和前沿。

（5）知识图谱推理

知识图谱应用的过程主要是基于知识图谱的推理：

- 关系推理：
  - 实体的分类包含关系，一个电脑椅是椅子，椅子是家具，可以说，一个电脑椅是家具。
- 常识规则的推理：
  - 一个男人的孩子是A，一个女人的孩子是A，可以知道，这个男人和女人是配偶。

- **知识推理的核心：分析应用的符号化、和按需提取**
- **本体层**

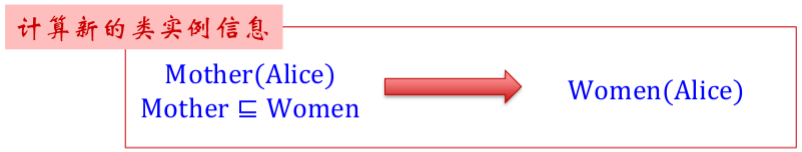
- 基于规则的推理：基于Tableaux运算的方法、基于逻辑编程改写的方法、基于一阶查询重写的方法、基于产生式规则的方法

- **实体层**

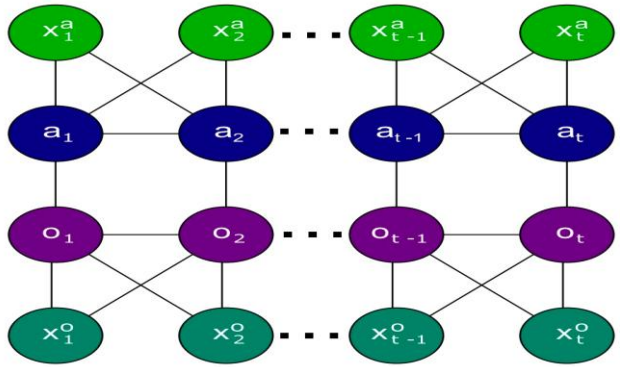
- 基于概率图进行实体推理补全：在关联中引入概率，运用不确定概率网络方法实现推理。
- 基于深度学习的关系补全

- **实例层**

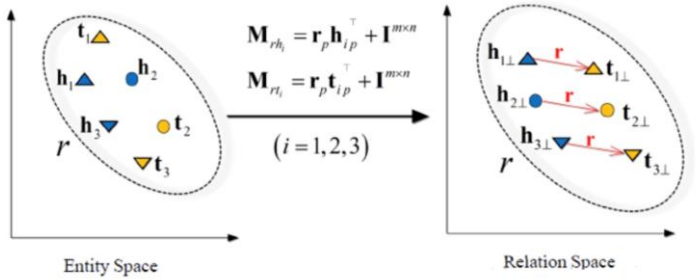
- 基于规则的实例推理
- 基于知识表达的关系推理：采用向量嵌入三元组知识，通过分类模型的训练，实现知识的推理



本体层：基于一阶逻辑的推理补全



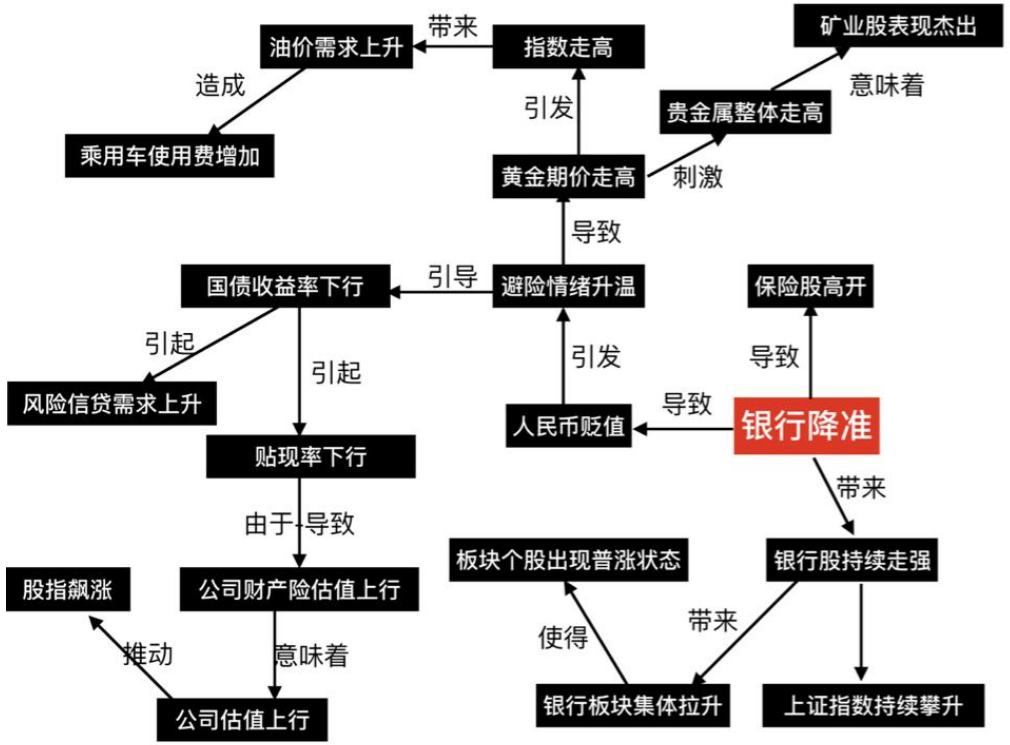
实体层：基于概率图的推理

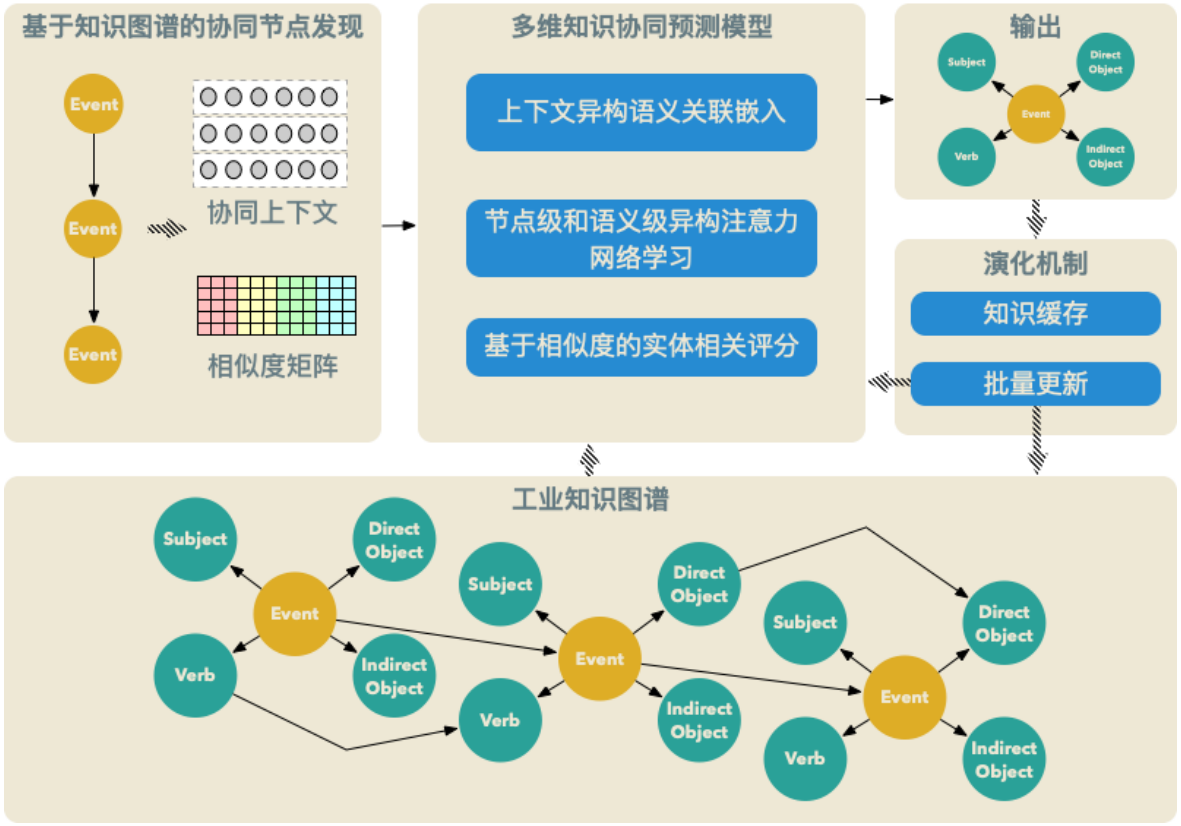


实例层：基于表示学习的关系发现

基于事理知识图谱的知识推理

- 事理图谱描述了活动事件之间的模式，是知识图谱之上发展而来，面向动态活动推理的知识基础。
- 基于事理知识图谱开展工业系统的诊断、分析、预测、决策，在不完备数据和不精确模型基础上，建立信息补全和似然推理机制，是未来构造智能制造的智能处理机制的重要方式。

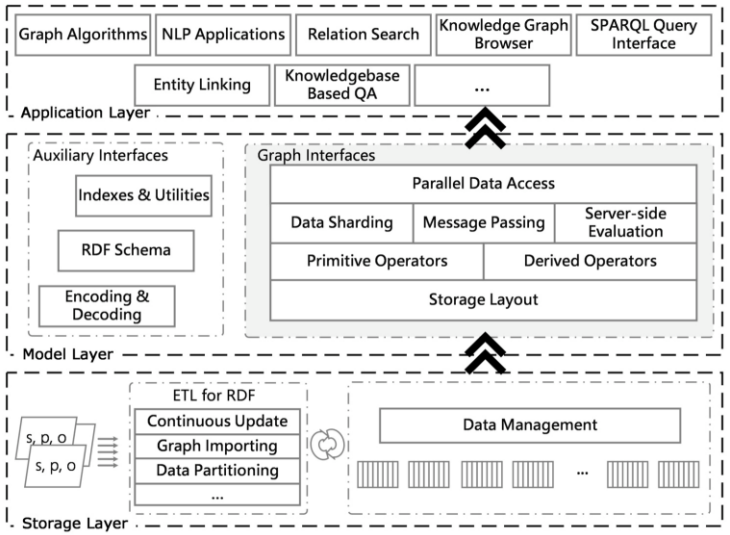




知识图谱应用

➢ 知识发布

- 在线查询服务
  - 针对实体、属性、关系、子图结构的查询
  - 针对查询的聚合
- 离线分析服务
  - 基于图结构的计算
  - 基于规则的推理
  - 基于整体信息的统计分析



知识服务管理框架

➢ 知识演化

- 构造RPA工具，实现对知识源的持续治理。

➢ 知识应用

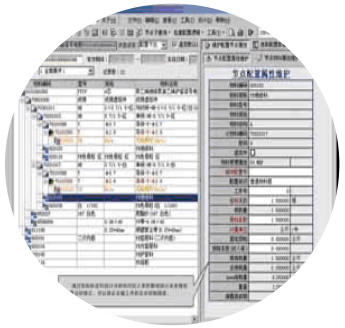
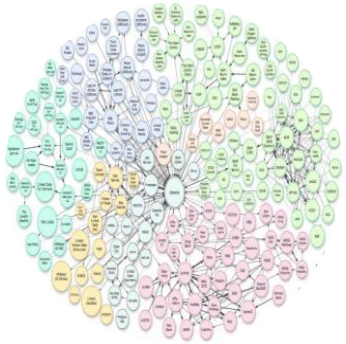
- 构造基于知识的RPA工具，实现多系统的智能协同。
- 具体应用：信息跨系统检索、元器件知识问答、元器件选型推荐、供应商系统对接、质量风险控制



RPA工具支撑知识的跨域应用

3.4 KG构建实例

数据管理和分析的高层目标是基于知识的智慧应用。

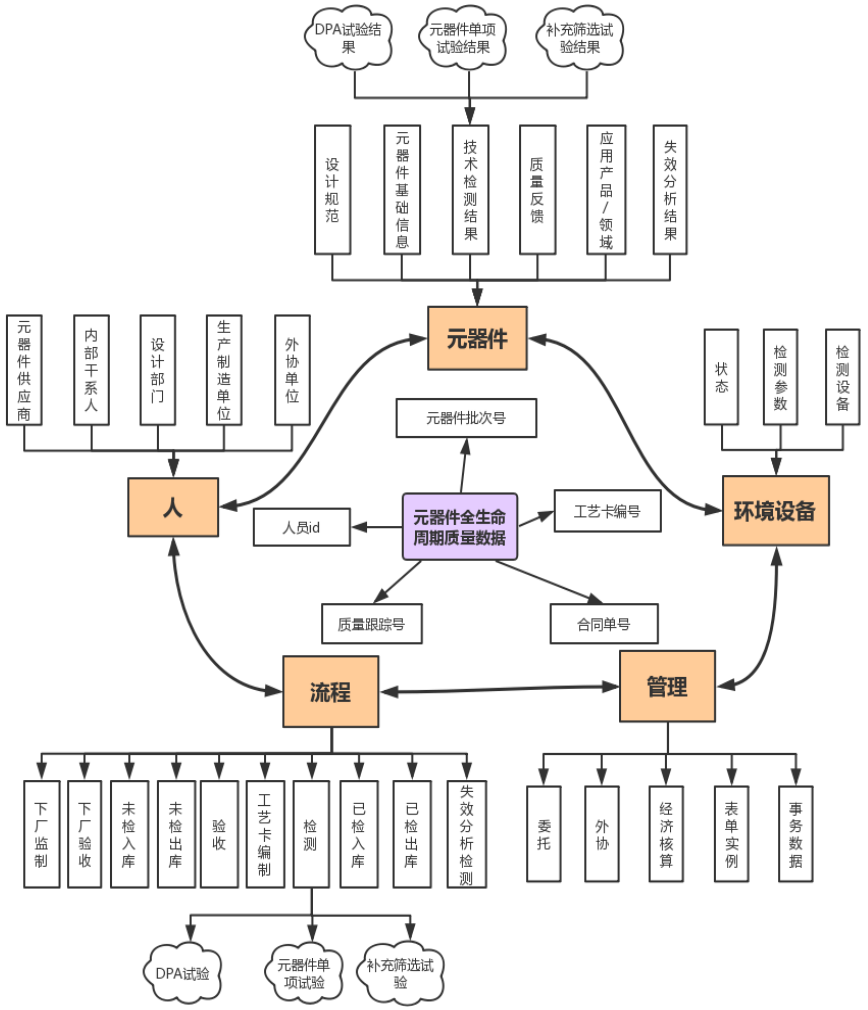

数据 → 加工 → **信息** → 发现 → **知识** → 应用 → **智慧**

定义	反应客观事物属性的原始材料	经过组织处理、具有业务含义的数据	对信息的过滤提炼而得的事物间联系	最佳地使用知识，做正确判断、决定和预测的能力
用途	保存、传递和处理	支持业务流程	知识推理、因果分析	外推性、探索性地认知
举例	”temperature”:”-40°C to +85°C“...	元器件BOM	<电阻，供应商，某某公司>	<电阻故障,故障源头，某某生产环节>

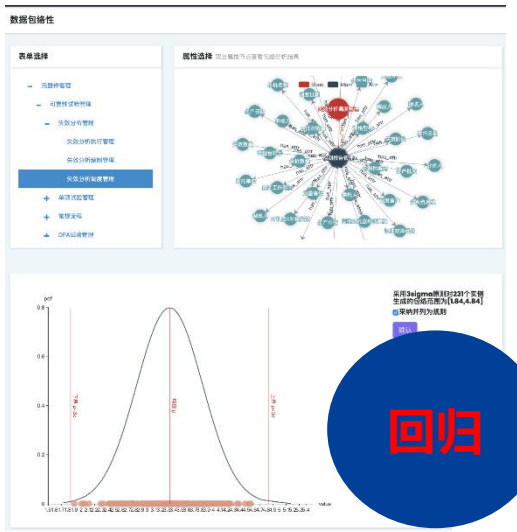
案例1：基于知识图谱的数据分析平台

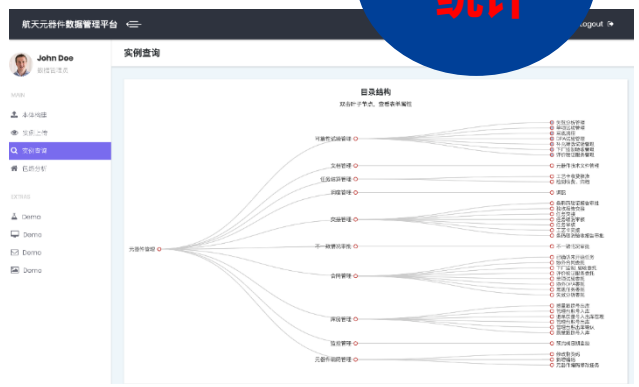
➢基于知识图谱的产品数据语义分析

- 基于OCR技术实现在线识别、离线批量处理等模式的历史数据抢救；
- 基于已有数据仓库数据字典构造元数据，根据人机物法环等维度定义业务主题；
- 根据初始元数据对历史数据进行抽取、清洗与转换，对不符合清洗规则的数据进行元数据的变更；
- 对新数据采用实时采集引擎进行标准化和校正，存入数仓；
- 根据元数据抽取元器件基本信息，形成元器件知识图谱；
- 基于元器件知识图谱，形成元器件语义分析引擎。

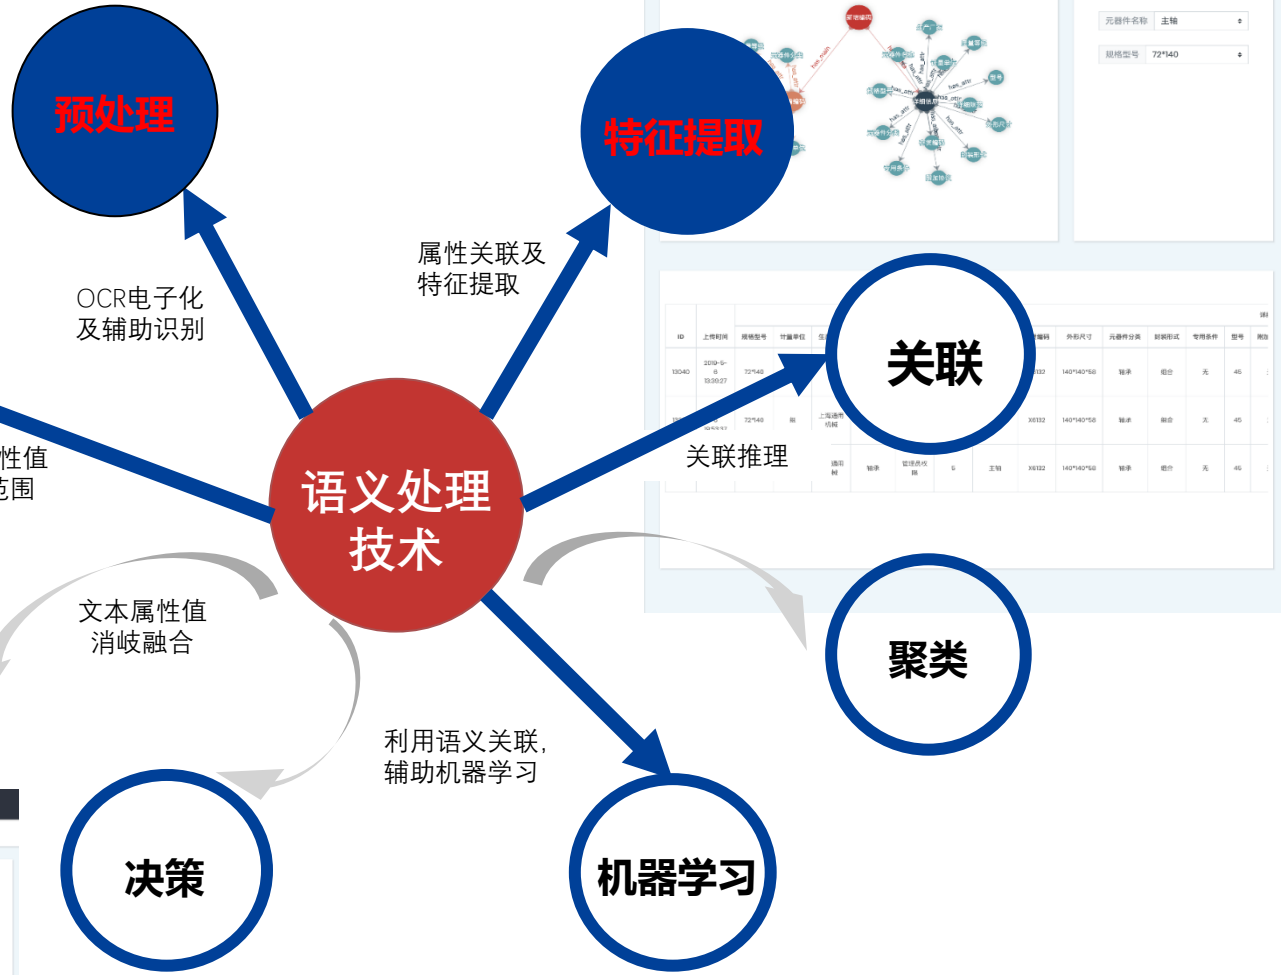


支持大数据处理的语义处理技术



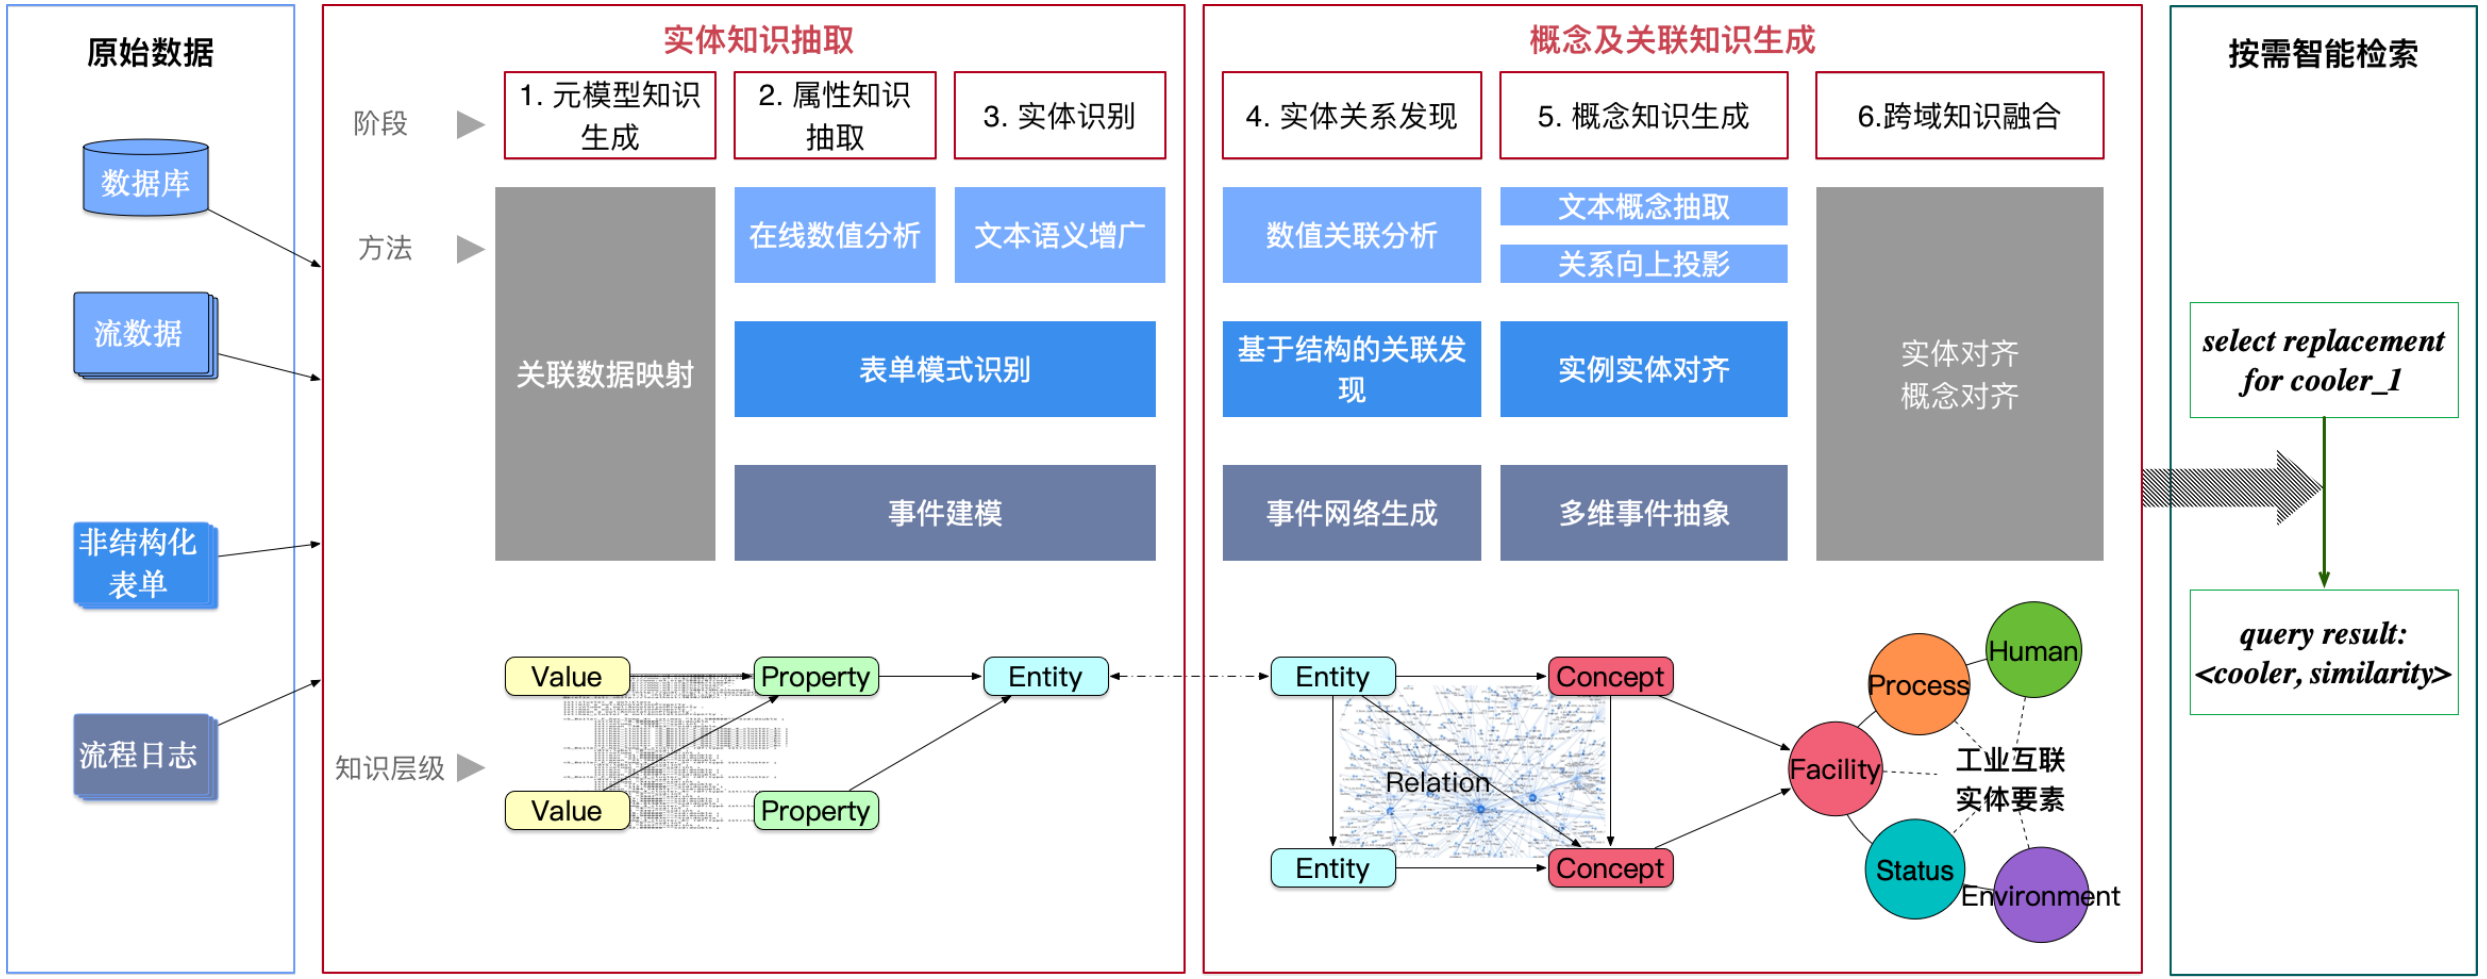






案例2：工业知识图谱构造实例

- 工业海量数据环境，一个节点宕机了如何找到合适的节点来替代它



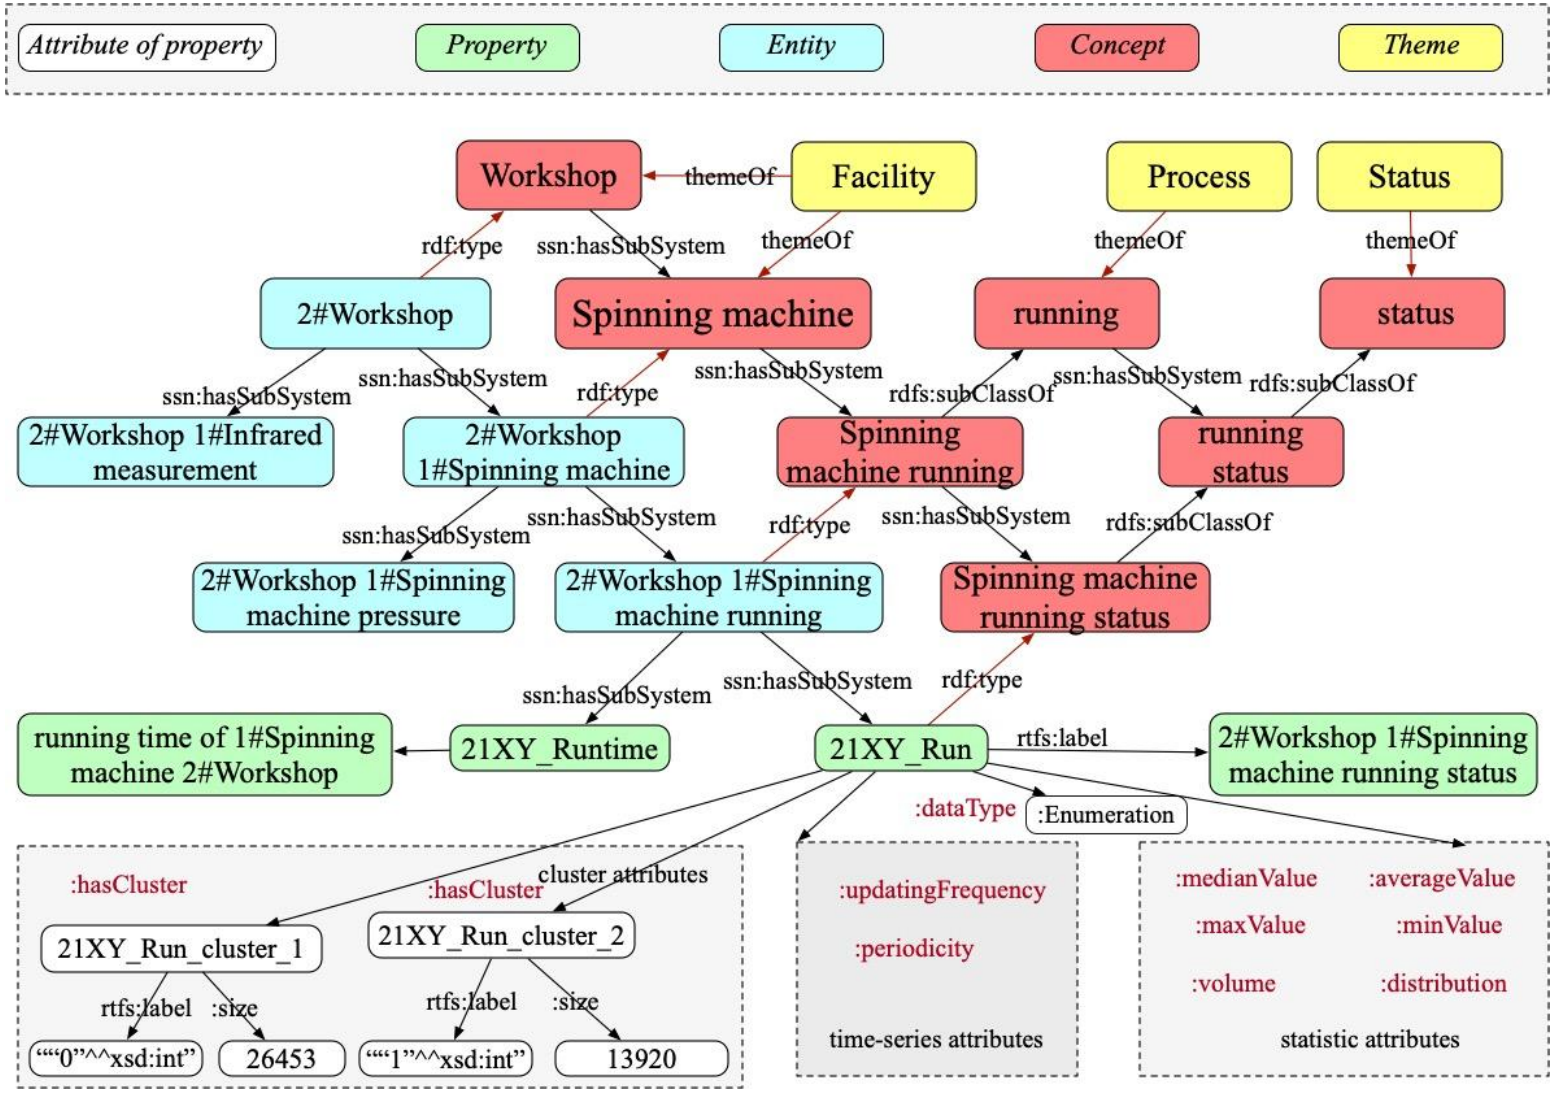
基于多层次工业知识图谱的智能应用

（1）元模型定义

工业知识图谱

元模型

- 取值
- 属性
- 实体
- 概念
- 主题
- 事件



根据上下位关系组织的层次化知识

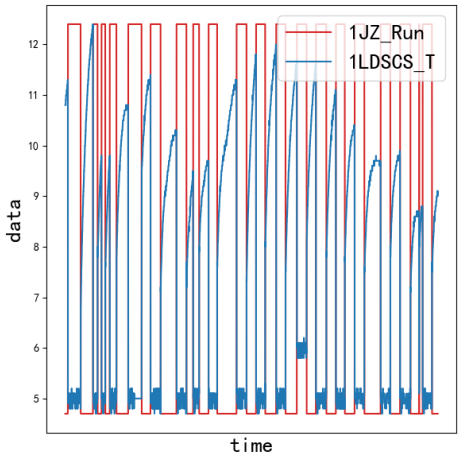
Yu Han, Hongming Cai, et al. “An Automated Metadata Generation Method for Data Lake towards industrial WoT Applications.” IEEE Transactions on Systems, Man, Cybernetics (2022).

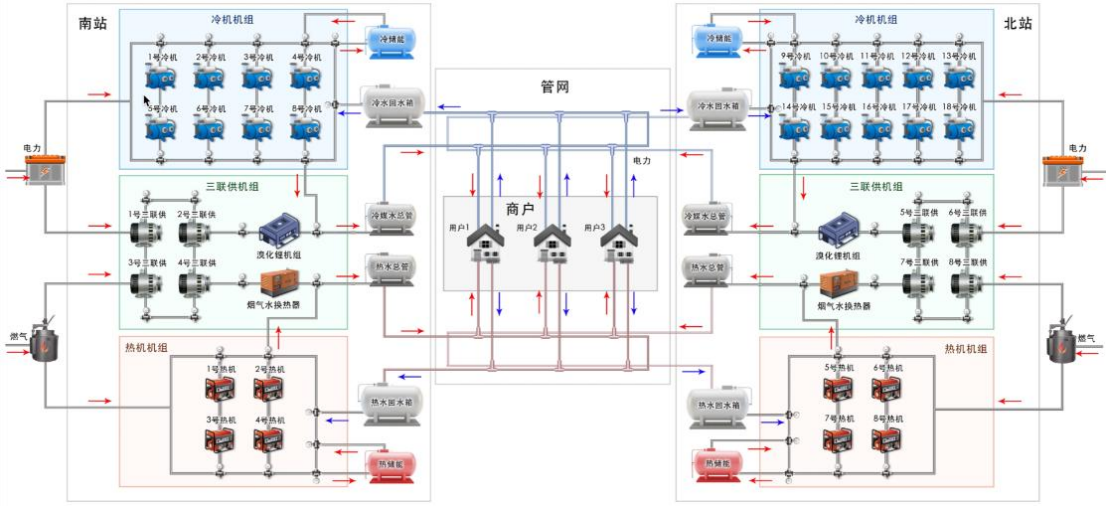
（2）知识抽取

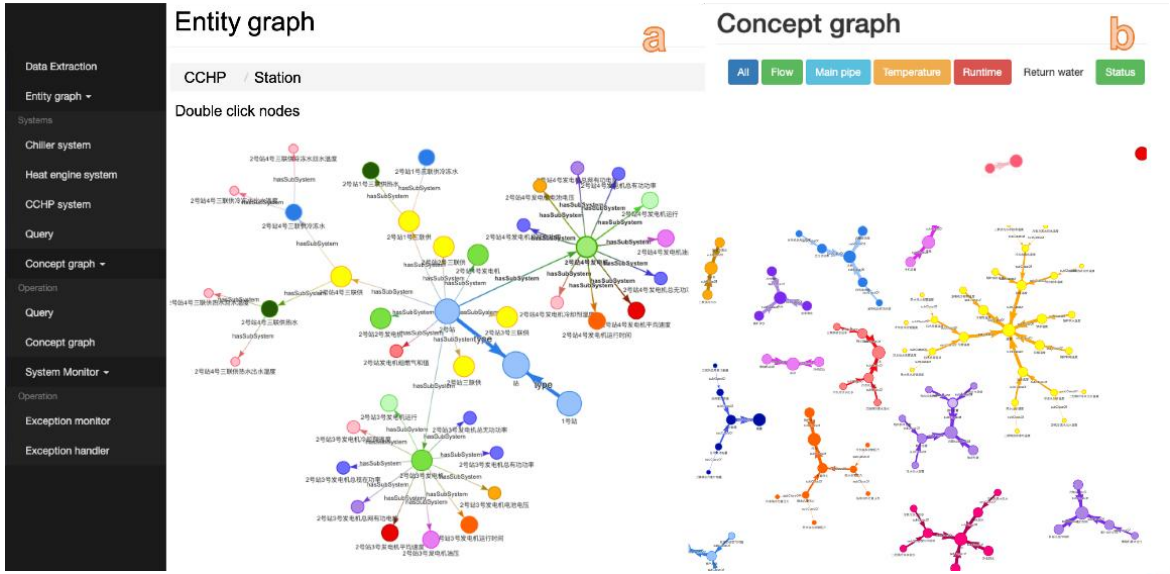
数据流知识抽取

- 属性值知识：在线聚类
- 实体知识：标签短文本协同抽取
- 实体关联：数值关联分析
- 概念知识：特征向上投影

句法依赖	增广的实体	原实体与增广实体的关系	实体样例	样例的概念类
N act VBG	[N VBG]	(N, hasSubSystem, [N VBG])	2#Workshop 1#Spinning machine [N] running [VBG]	Spinning machine [N] running [VBG]
VBG dobj N	[VBG N]	(VBG, hasSubSystem, [VBG N])	2#Workshop 1#Spinning machine running [VBG] status[N]	running [VBG] status [N]
N_1 dep N_2	[N_2 N_1]	(N_2, hasSubSystem, [N_2 N_1])	1#Spinning machine [N_1] 2#Workshop [N_2]	Spinning machine [N_1]
X mod N	[X N]	(N, hasSubSystem, [X N])	2# [X] Workshop [N]	Workshop [N]
N_1 compound N_2	[N_1 N_2]	–	m1 [N_1] Spinning machine [N_2]	Spinning machine [N_2]

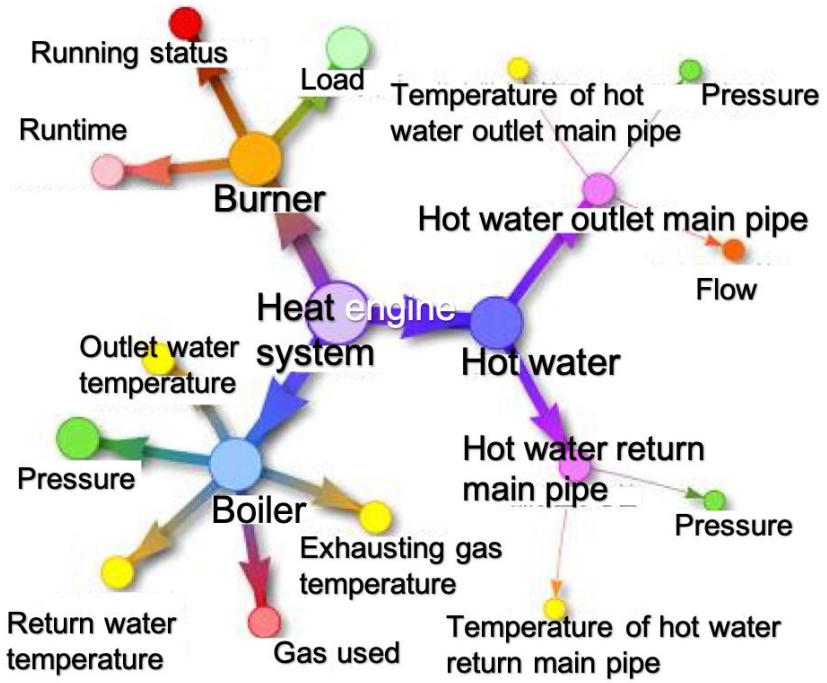




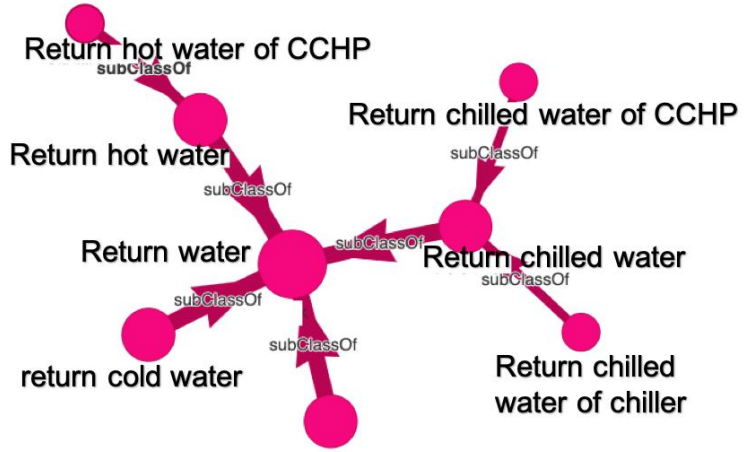


（3）知识融合

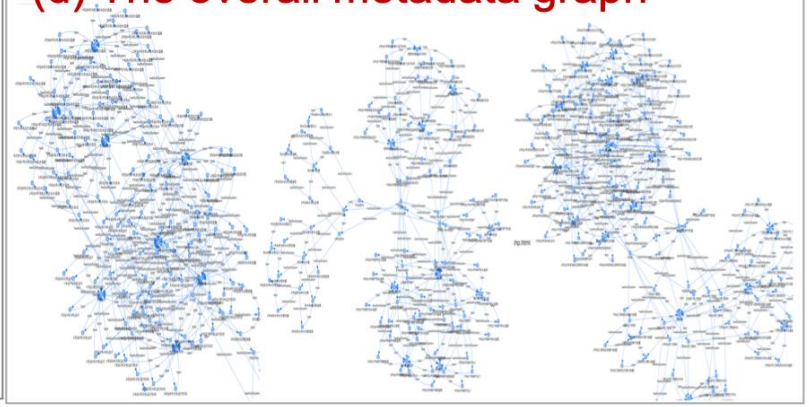
(a) Metadata of the heat engine system



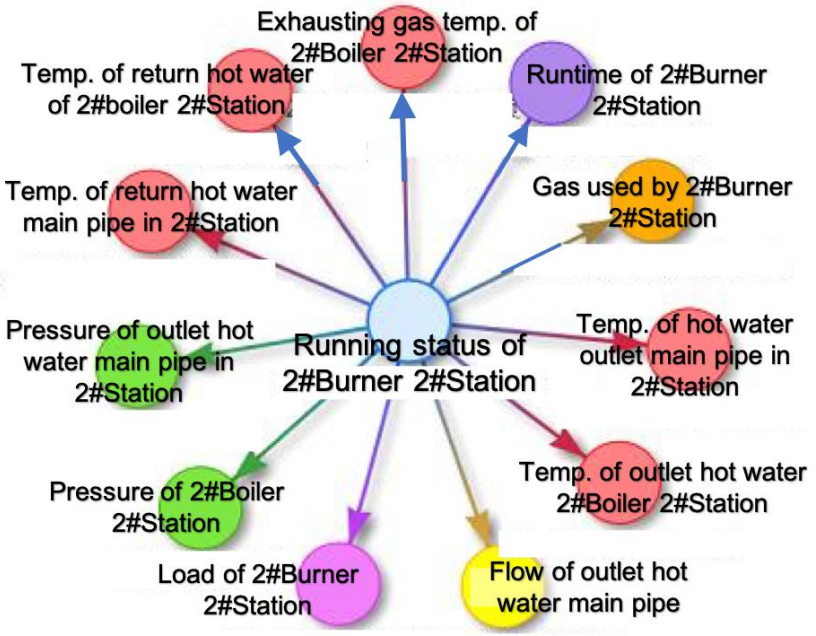
(b) Concept of return water



(d) The overall metadata graph



(c) Entities with ***affects*** relation



（4）知识推理

WoT metadata query

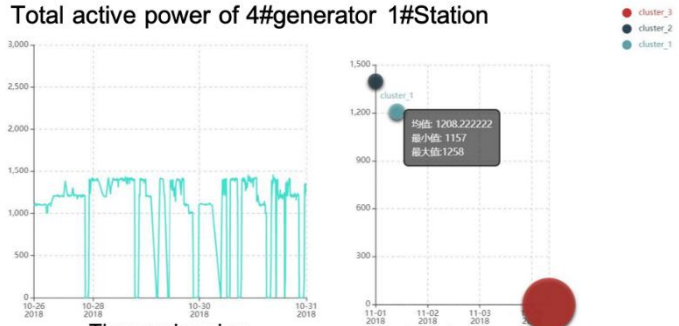
S_SLG_JZ4_P_YG_TOT query

```
<S_SLG_JZ4_P_YG_TOTAL> rdf:type <Total_active_power_of_generator> ;
        sosa:subSystemOf <4#generator1#Station> ;
        sosa:observes <Total_active_power> ;
        ist:Ptype <clique> ;
        ist:controlBy <S_4FDJ_RUN> .

<S_SLG_JZ4_P_YG_TOTAL> ist:mean "351.982891"^^xsd:double ;
        ist:has_cluster <S_SLG_JZ4_P_YG_TOTAL_cluster_1> ;
        ist:has_cluster <S_SLG_JZ4_P_YG_TOTAL_cluster_2> .

<S_SLG_JZ4_P_YG_TOTAL_cluster_1> rdf:type ist:cluster ;
        ist:relevanceStamp "25532880301.773490"^^xsd:double ;
        ist:mean "1218.266409"^^xsd:double ;
        ist:volume "2072"^^xsd:int .
<S_SLG_JZ4_P_YG_TOTAL_cluster_2> rdf:type ist:cluster ;
        ist:relevanceStamp "27200706949.199825"^^xsd:double ;
        ist:mean "0.023500"^^xsd:double ;
        ist:volume "5617"^^xsd:int .
```

Total active power of 4#generator 1#Station

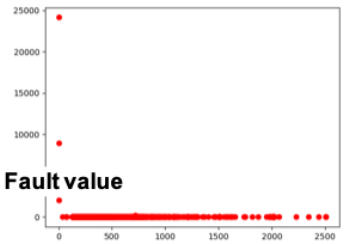


Time series view

Data cluster view

Exception data monitor

Flow of 1#chiller1#station



Show 10 entries

Entity name	Fault occurtime	Fault value
Flow of 1#chiller1#station	2018-07-06T17:20:44Z	
Flow of 1#chiller1#station	2018-07-23T09:49:19Z	2005.208
Flow of 1#chiller1#station	2018-07-23T09:54:19Z	2005.208

Replacement automatic discovery

Show 10 entries Search:

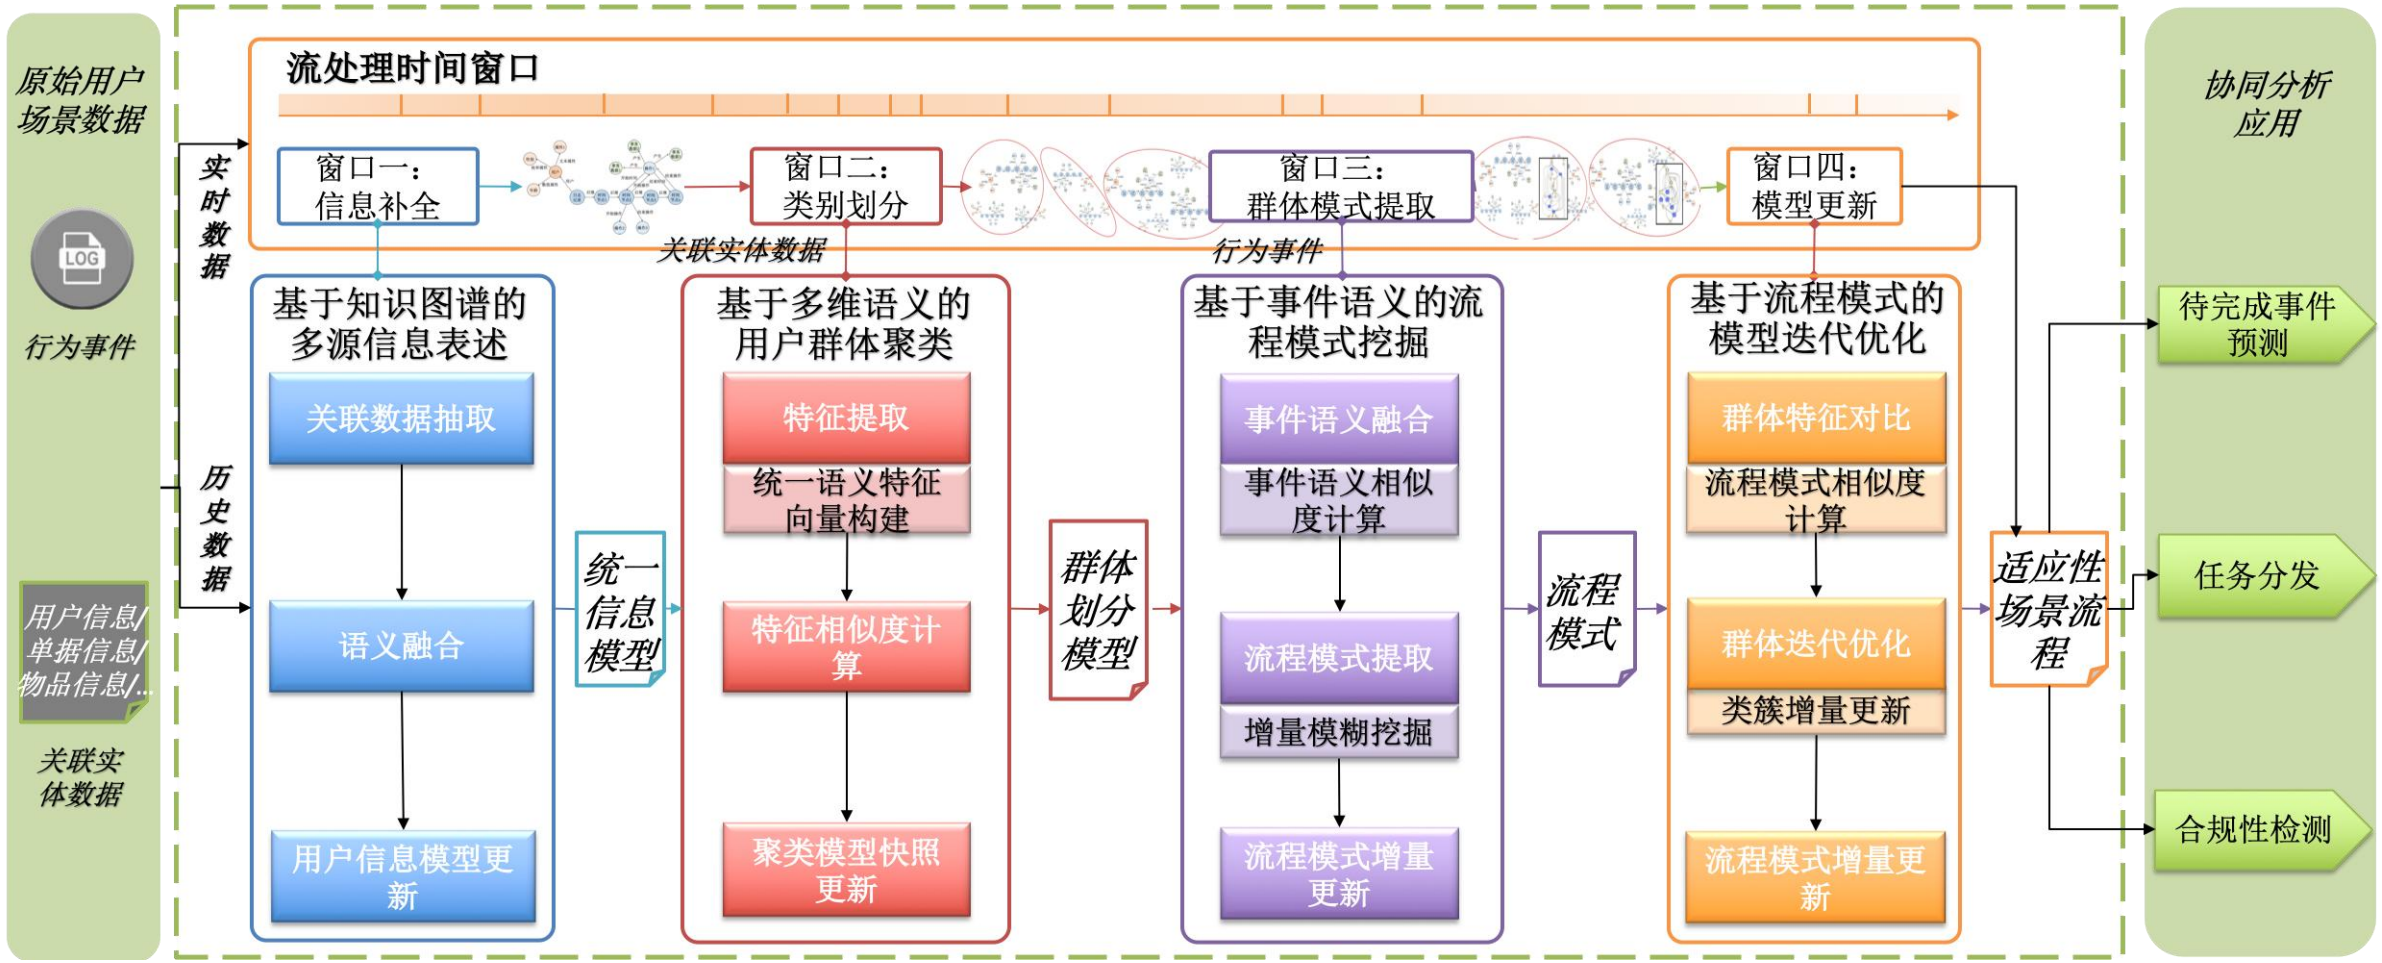
Entity name	Replacement	Similarity
Outlet chilled water temperature of 1#chiller 1#station	Outlet chilled water temperature of 8#chiller 1#station	0.7104540656972457
Outlet chilled water temperature of 1#chiller 1#station	Outlet chilled water temperature of 3#chiller 1#station	0.5748710680071129
Outlet chilled water temperature of 1#chiller 1#station	Outlet chilled water temperature of 2#chiller 1#station	0.5645517760057612
Outlet chilled water temperature of 1#chiller 1#station	Outlet chilled water temperature of 10#chiller 2#station	0.5600374966723419
Outlet chilled water temperature of 1#chiller 1#station	Outlet chilled water temperature of 7#chiller 1#station	0.5490201015089695
Outlet chilled water temperature of 1#chiller 1#station	Outlet chilled water temperature of 6#chiller 1#station	0.5147878476648678
Outlet chilled water temperature of 1#chiller 1#station	Outlet chilled water temperature of 5#chiller 2#station	0.4924010447980258
Outlet chilled water temperature of 1#chiller 1#station	Outlet chilled water temperature of 9#chiller 2#station	0.45864767570583337
Outlet chilled water temperature of 1#chiller 1#station	Outlet chilled water temperature of 4#chiller 1#station	0.45212791577284156
Outlet chilled water temperature of 1#chiller 1#station	Outlet chilled water temperature of 4#chiller 2#station	0.34812472910457526

Showing 1 to 10 of 17 entries

Previous 1 2 Next

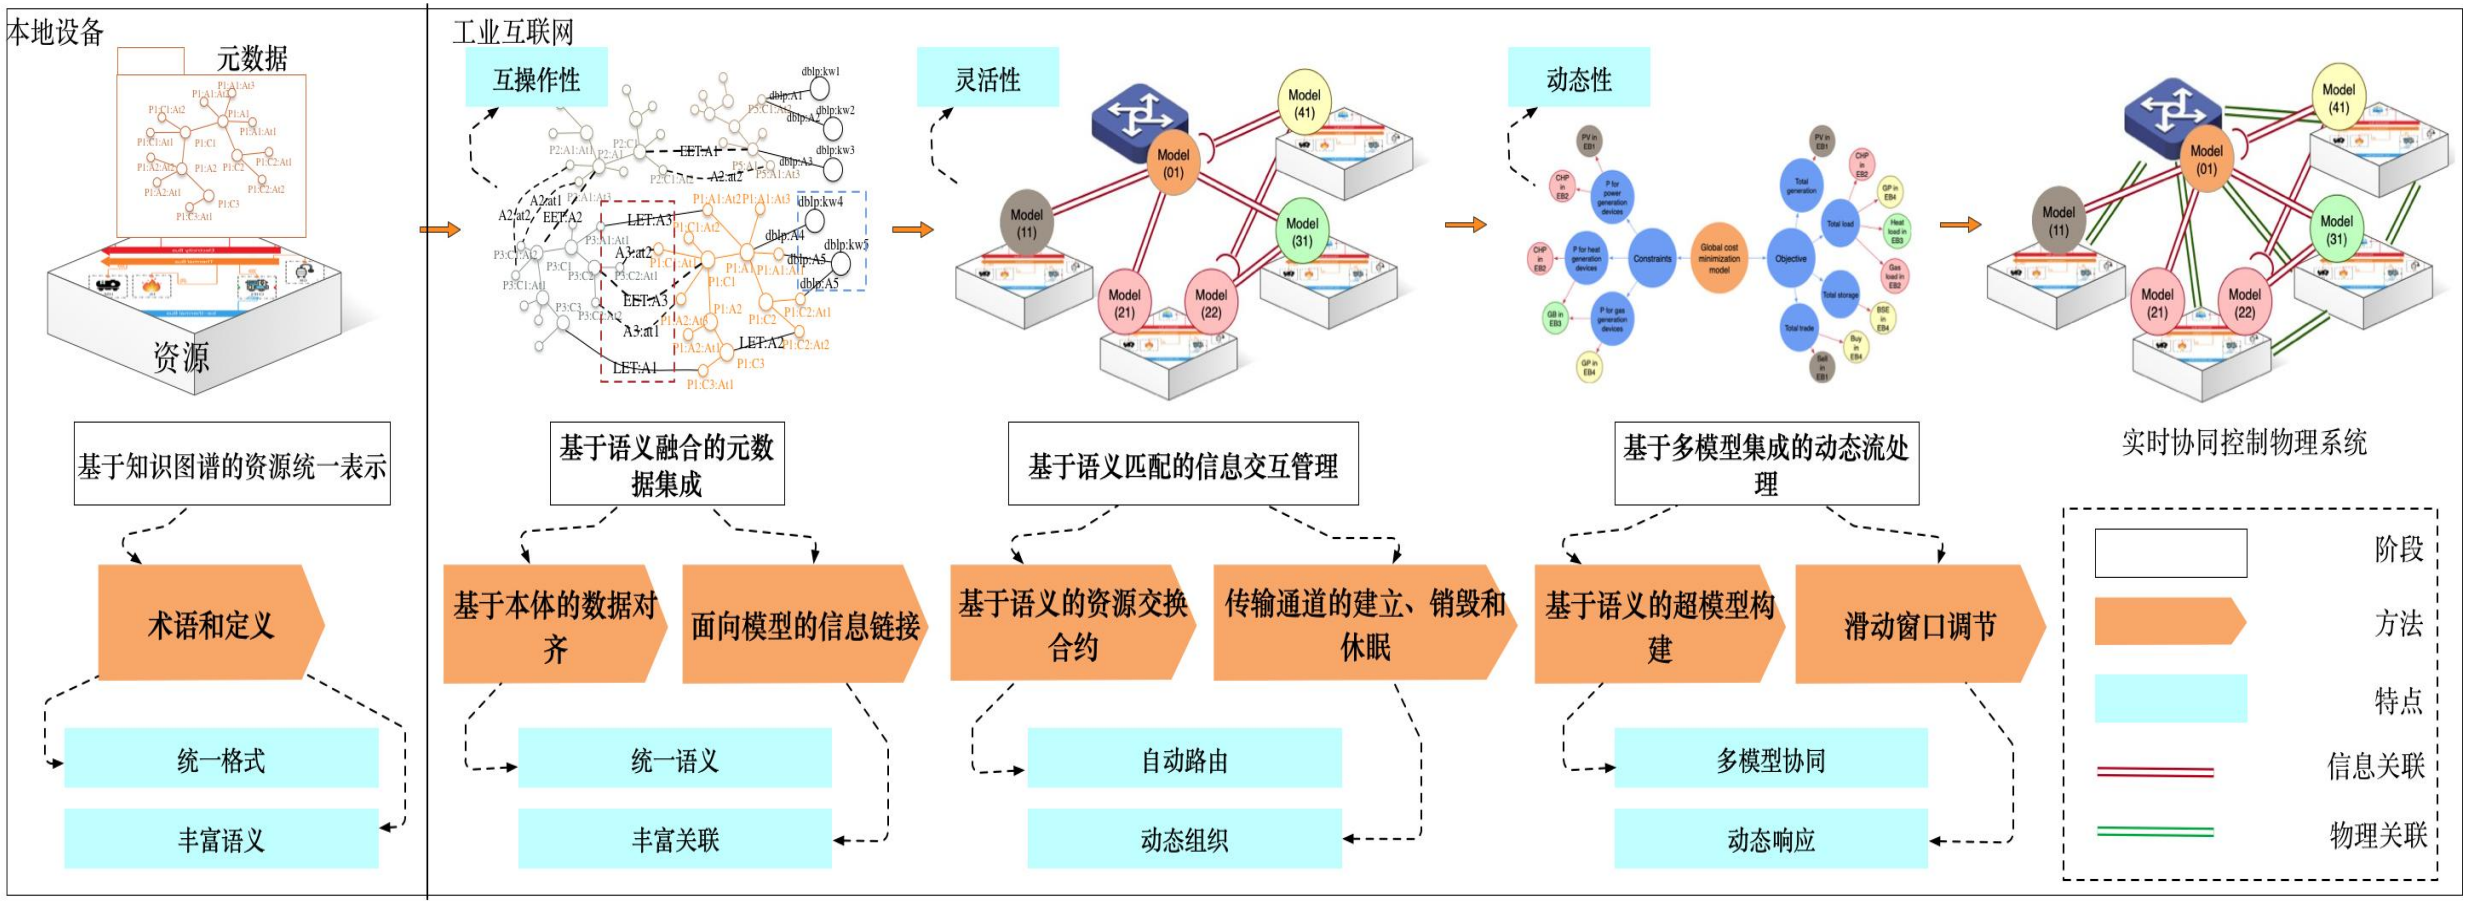
（5）知识应用

基于知识图谱的适应性用户场景构建

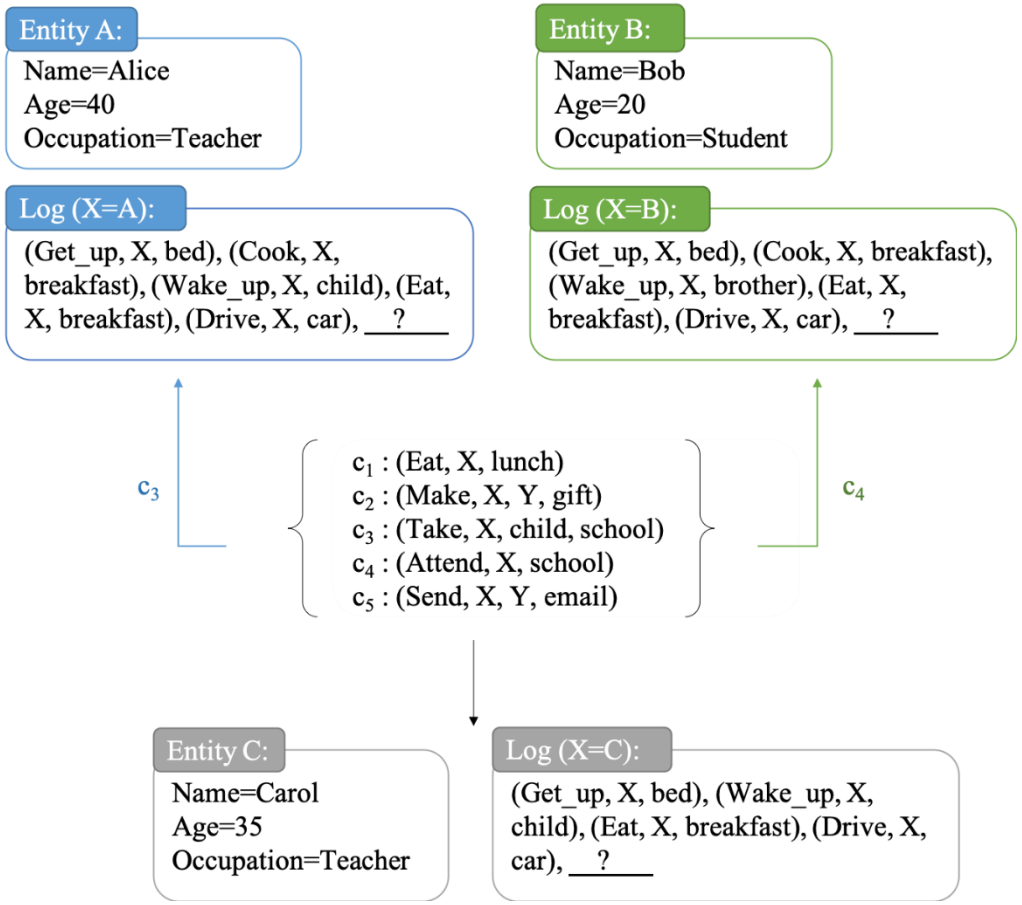


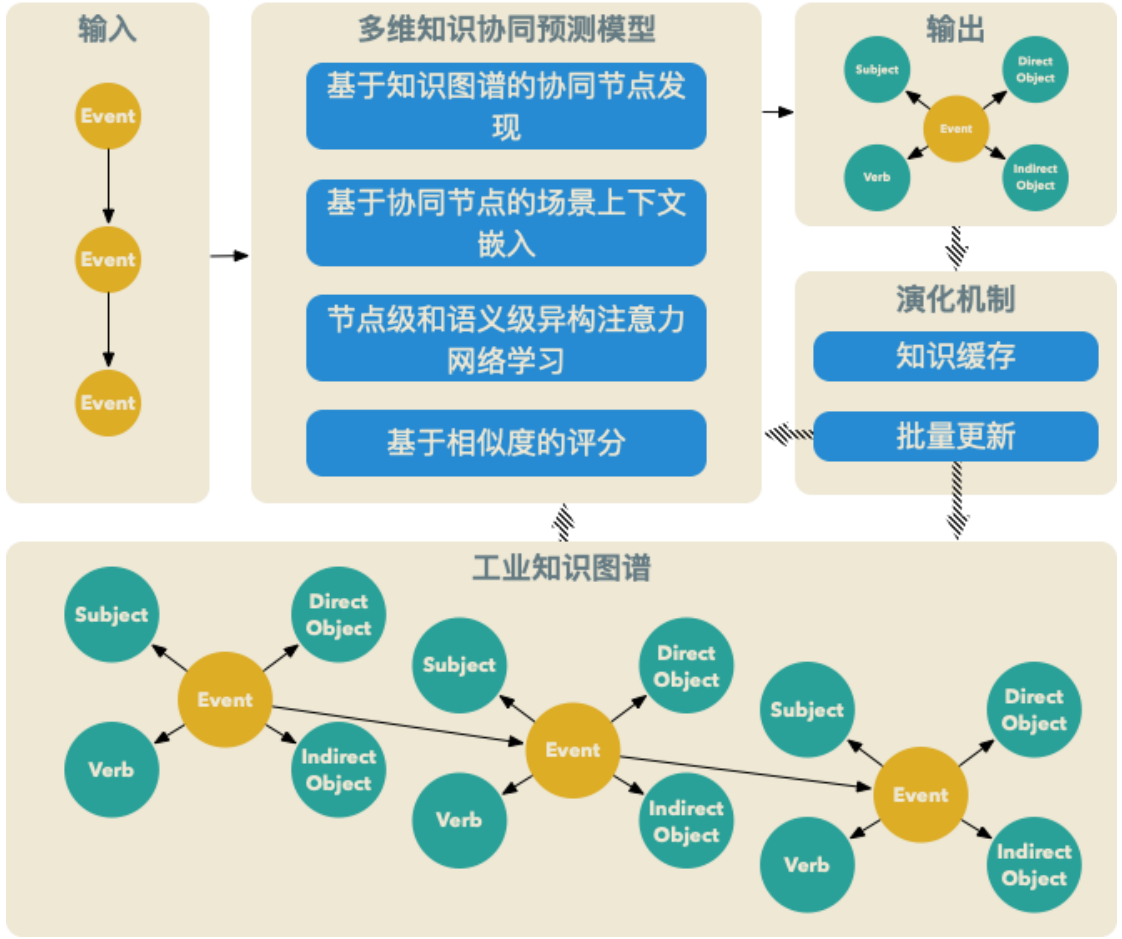
于晗, 蔡鸿明, 等. “基于增量式流处理的自适应群体划分方法”. 计算机学报, 2020, 12:2337-2351.

基于知识图谱的资源主动集成



基于知识图谱的行为事件预测





目录

- 1 数据智能平台

  1.1 大数据定义-1.2数据分析特点-1.3 大数据处理过程

- 2 数据治理

  2.1 数据准备-2.2数据治理-2.3数据分类-2.4智能数据治理

- 3 知识图谱

  3.1 知识图谱发展-3.2知识图谱表示及存储-3.3 知识图谱构建-3.4 KG构建实例

- 4 基于知识图谱的智能数据治理

  4.1 航天元器件应用实例-4.2其他实例

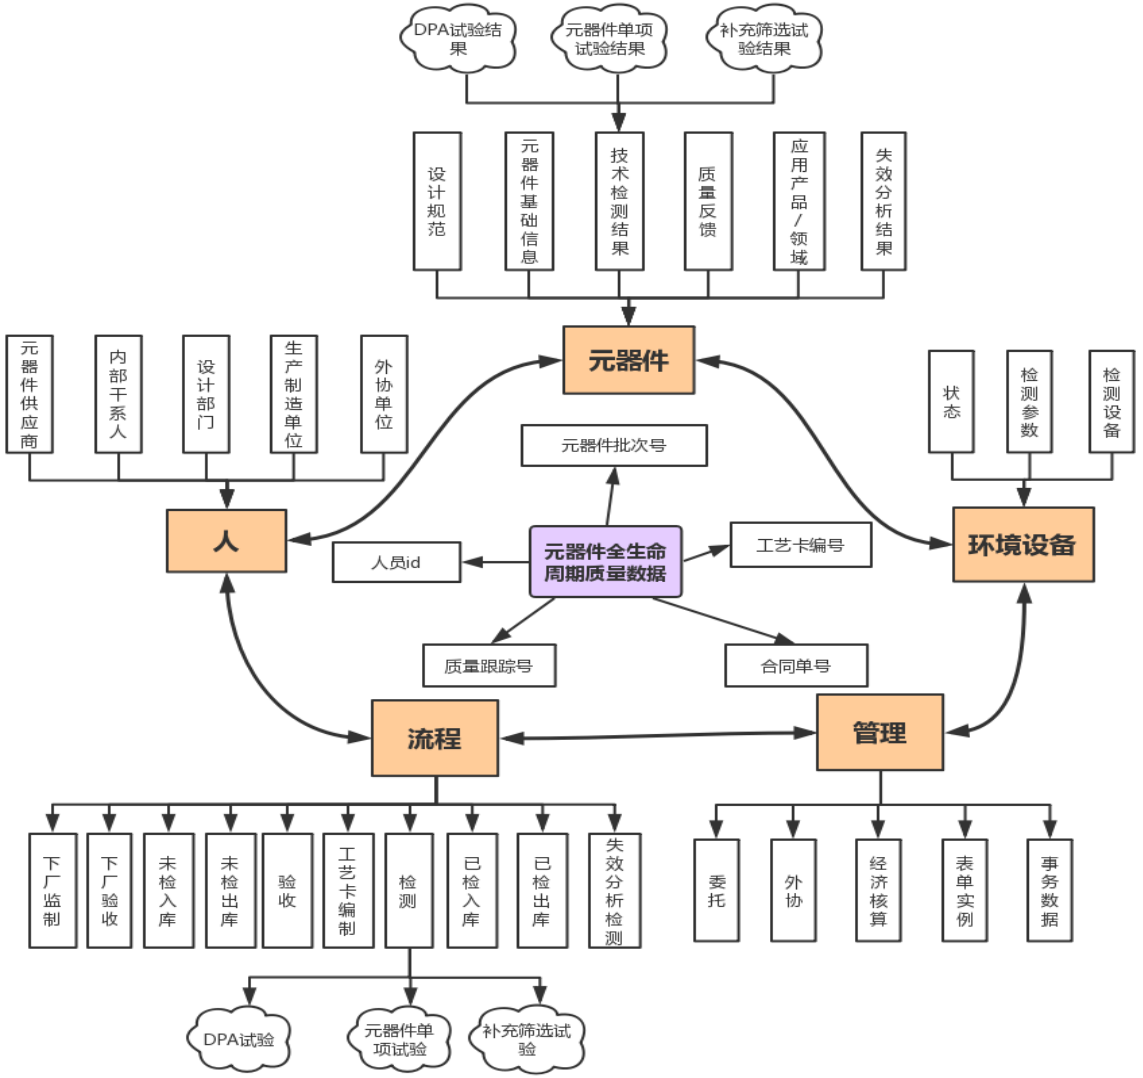
- 5 小结

4 基于知识图谱的智能数据治理

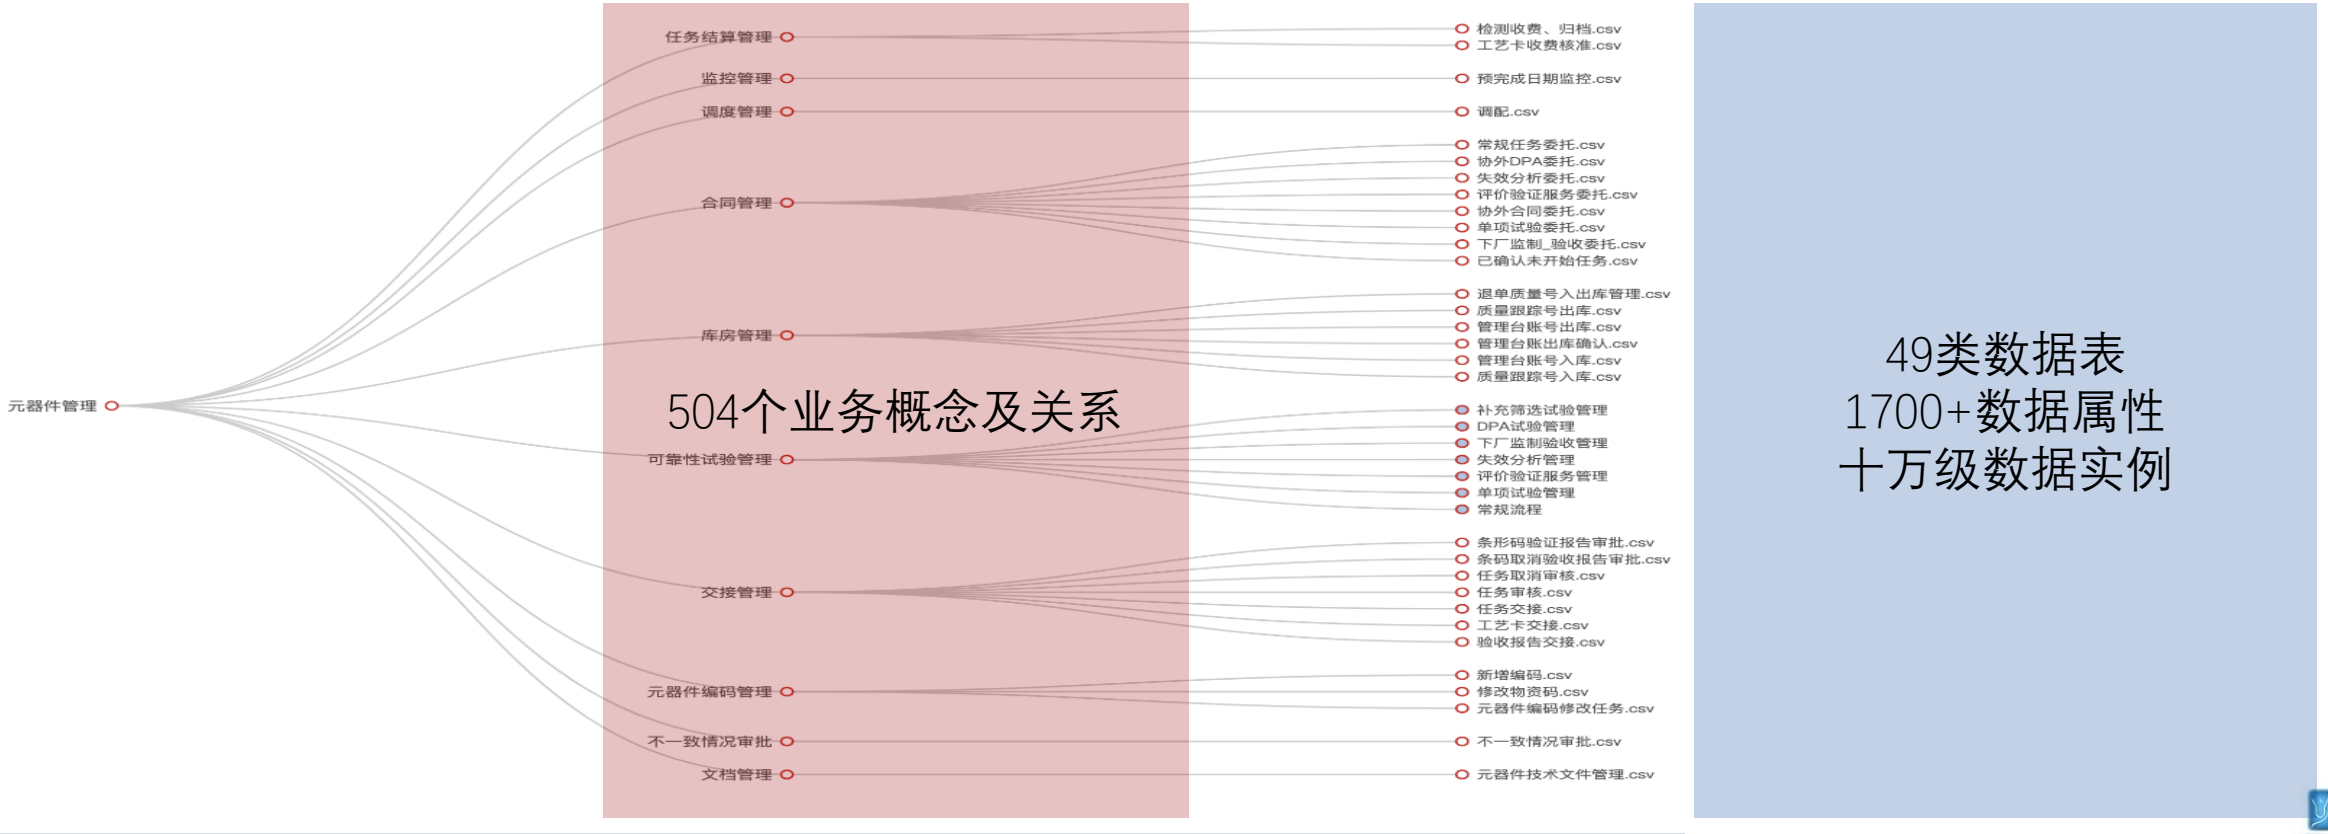
- 从数据治理角度，**“知识图谱改变的是企业关于数据存储的传统方式，本质上就是改变数据组织的形式，利用知识的组织形式完成行业数据逻辑性的保存”**
- 知识图谱可以帮助企业将分散在不同系统中的数据和知识整合到一个统一的知识图谱中，提高数据和知识的可发现性、可理解性和可用性，从而支持企业的决策和创新。
- 知识图谱管理工具在企业中具有以下几个方面的作用：
  - **数据整合和标准化：**知识图谱可以将这些分散的数据整合到一个统一的知识图谱中，并对数据进行标准化和语义化，使得数据的可发现性、可理解性和可用性得到了提高。
  - **知识发现和创新：**知识图谱可以帮助企业挖掘数据和知识中的潜在关联和规律，例如对客户行为和偏好进行分析，或者对供应链和生产流程进行优化，从而提高效率和降低成本。
  - **决策支持和风险管理：**知识图谱可以帮助企业对复杂的业务数据和知识进行分析和决策，从而降低决策的风险和提高决策的效果。
  - **人工智能和自动化：**知识图谱可以与人工智能和自动化技术结合使用，从而实现更加智能化和自动化的业务流程。

4.1 基于知识图谱的数据智能应用实例

- **自顶向下设计元器件知识图谱本体层**，利用元器件生命周期业务表单提取出元数据，构建数据元模型，从概念层面消除元器件部门数据表示的语义异构 。形成五类本体，表征不同维度的信息：
  - 人员
  - 元器件
  - 流程
  - 环境设备
  - 管理

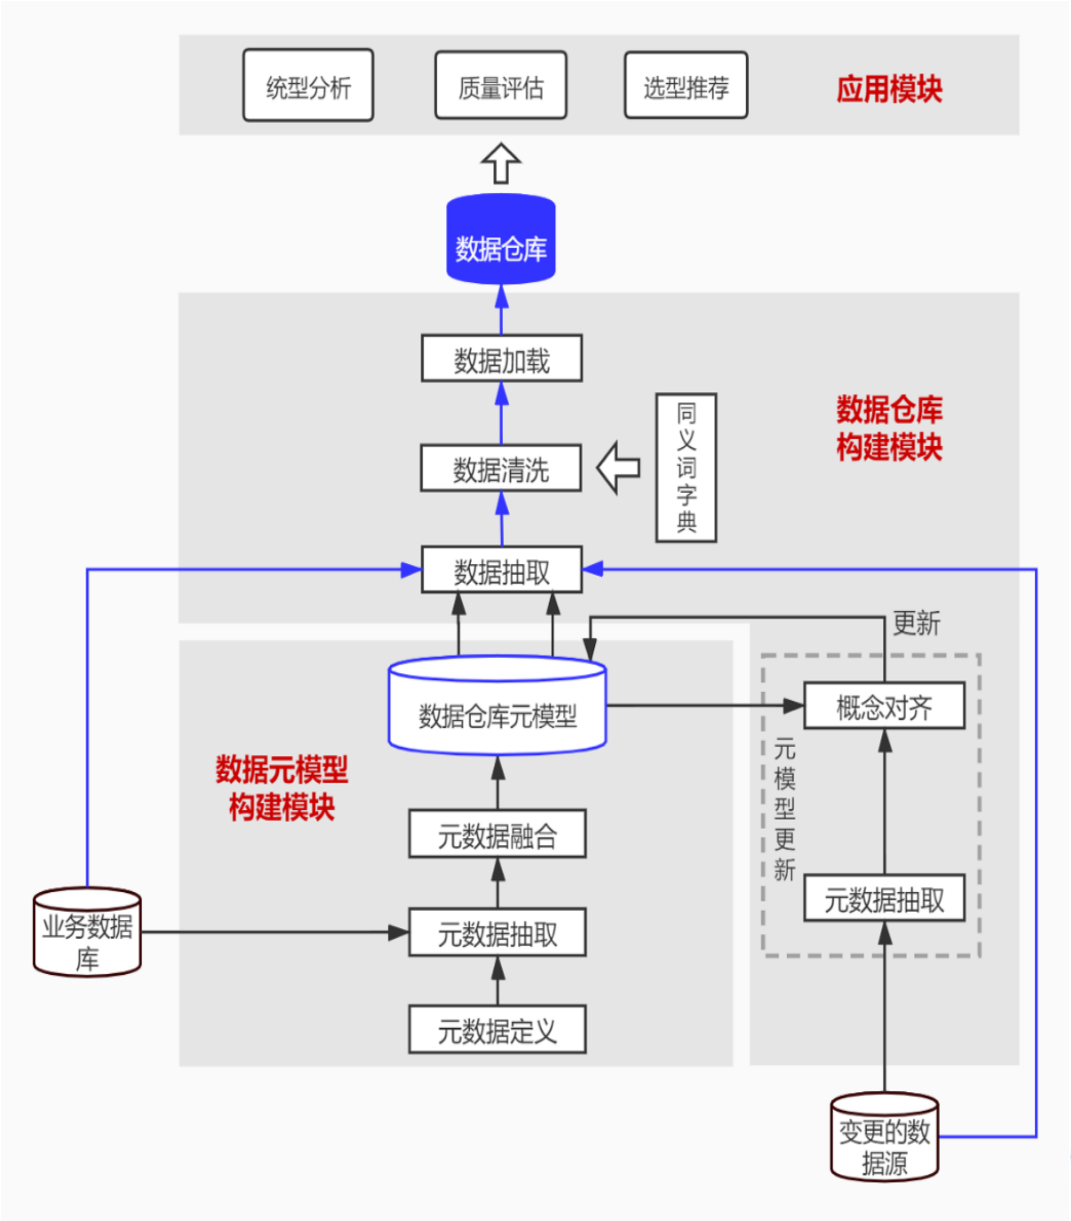


- **自底向上抽取实体知识**，面向元器件设计、采购、检测、使用的全生命周期，通过**自然语言处理和语义分析**的知识抽取方法，抽取出业务实体、概念及关系，形成实体层知识。



- **实例层数据清洗与语义提取**：利用业务实例构建同义词字典，从实例层面消除数据的语义异构，用同义词字典将业务数据库中的脏数据清洗，然后经过转换、加载到数据仓库，同时对知识图谱实体和本体层持续更新。

- 现已形成了元器件元数据知识图谱，构建了基于云平台的自动化知识抽取工具，实现了数仓数据的知识化

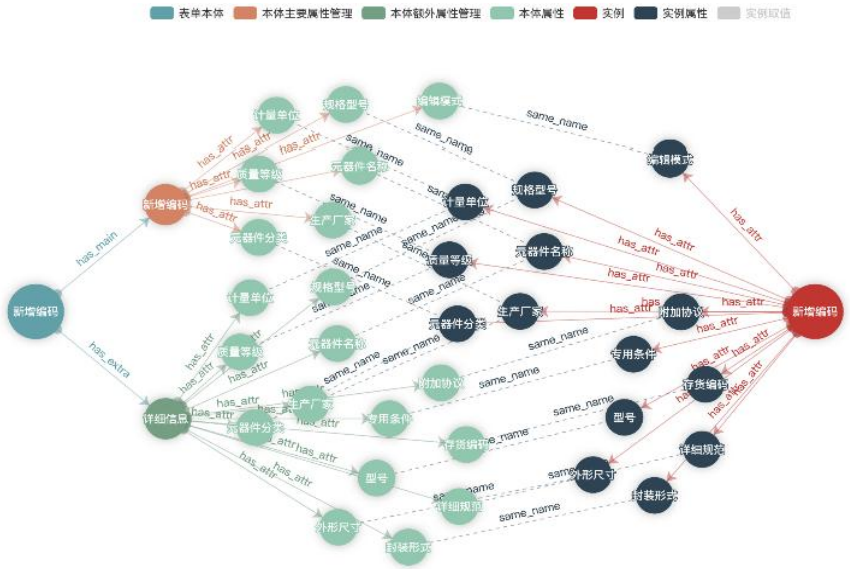


应用场景：元器件智能选型

- 基于构造的元器件元数据知识库，通过知识图谱特有的关联查询方法，对多源异构的元器件数据及其关联数据（属性、供应商等）进行一次性高效检索。

```
SELECT    D_StoreID,
Sum(D_Value)    AS    Last7DaysSaleVal
FROM (SELECT    D_StoreID,
                D_Value    FROM    Detection
        WHERE D_Date  >=  SystemDate()-7)
        UNION ALL
        (SELECT    DTmp_StoreID,
                DTmp_Value    FROM    DetectionTmp
                WHERE    DTmp_Date  >=  SystemDate()-7)
GROUP BY D_StoreID
```

传统的数据仓库查询：
数值匹配、脚本复杂、多次查询

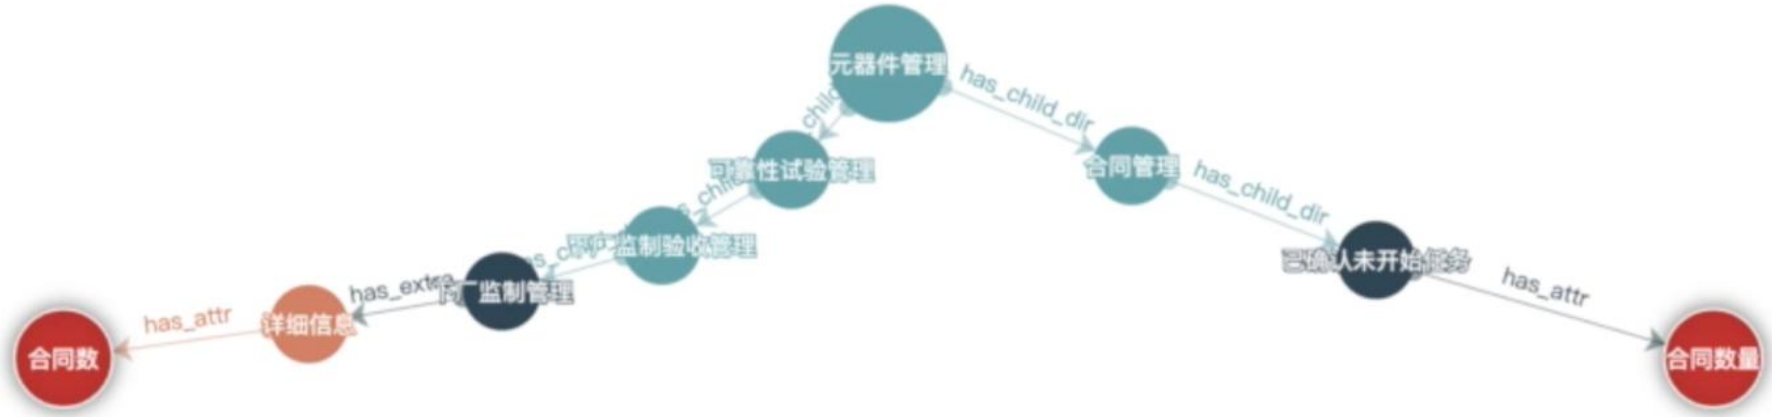


基于数据图谱的数据仓库智能查询：
匹配语义、脚本简单、多源同查

基于数据血缘分析的元器件质量追溯：对元器件从生产、出库、检验、入库等的全流程以及流程相关实体进行关联查询与监测，实现元器件质量追溯。

应用场景：元器件质量溯源

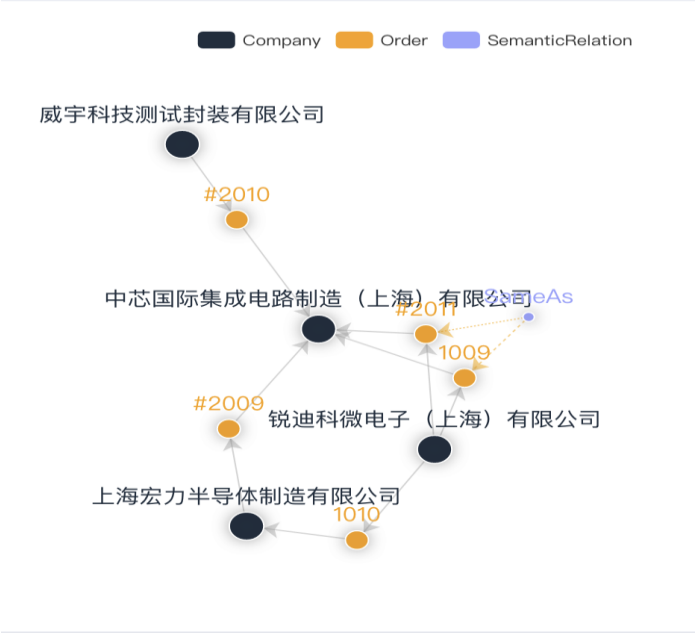
- 通过语义匹配、图结构匹配等信息融合和关联发现方法，在知识层面对数据前世今生进行关联，形成数据联想链。
- 在关键设备诊断、质量溯源中，基于数据联想链抽取数据，实现对设备问题、质量问题源头的定位。

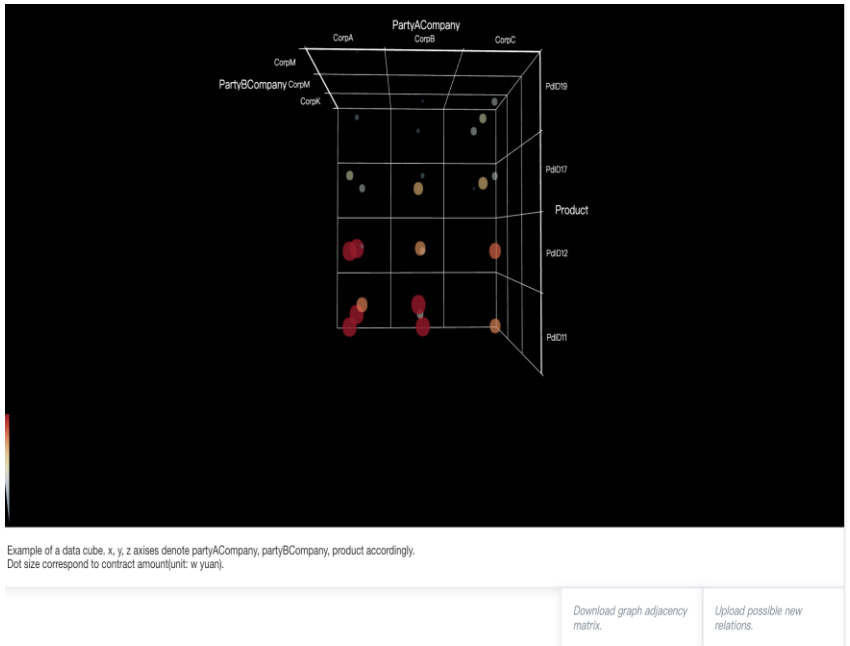


典型案例：对“合同数量”的数据血缘追溯

元器件统型分析

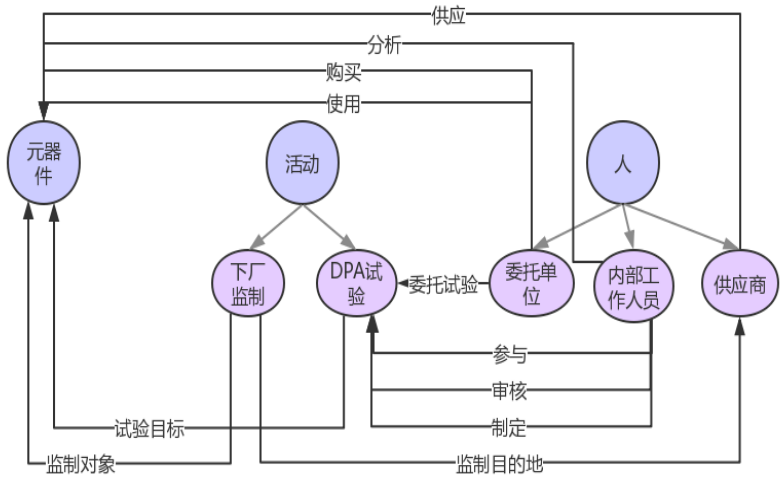
- 基于**社群发现**的统型分析：提取元器件属性、类别、应用场景等知识，通过图匹配、语义聚类等方法，得到相似元器件、统一功能元器件、同一应用场景元器件等组合，压缩优选目录范围。
- 基于**语义相关性分析**的元器件统型查询：对需要国产化或超目录的元器件，通过知识补全，支持相似元器件筛查，辅助完成国产替代和目录约束。

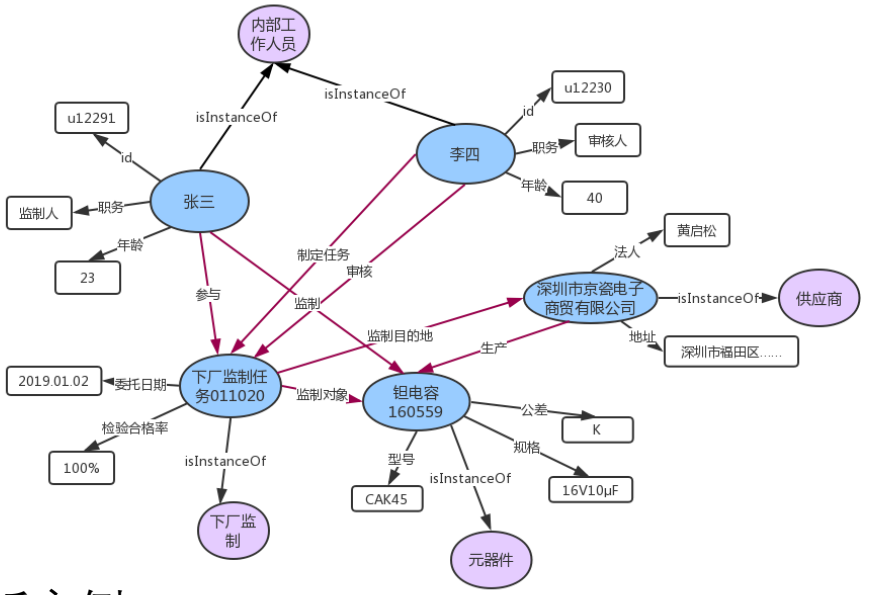




功能、性能近似关联分析

- 生产厂商多维评估
- **基于关联知识多维分析的厂商评估**：通过关联分析，确定厂商多维知识关联的影响力，形成带权重的生产厂商画像。
- **基于数据联想的历史合作分析：**对给定生产厂商，融合其相关联的检测任务、检测环境、干系人等，训练面向历史合作的综合评估模型，将厂商评分存入知识图谱。

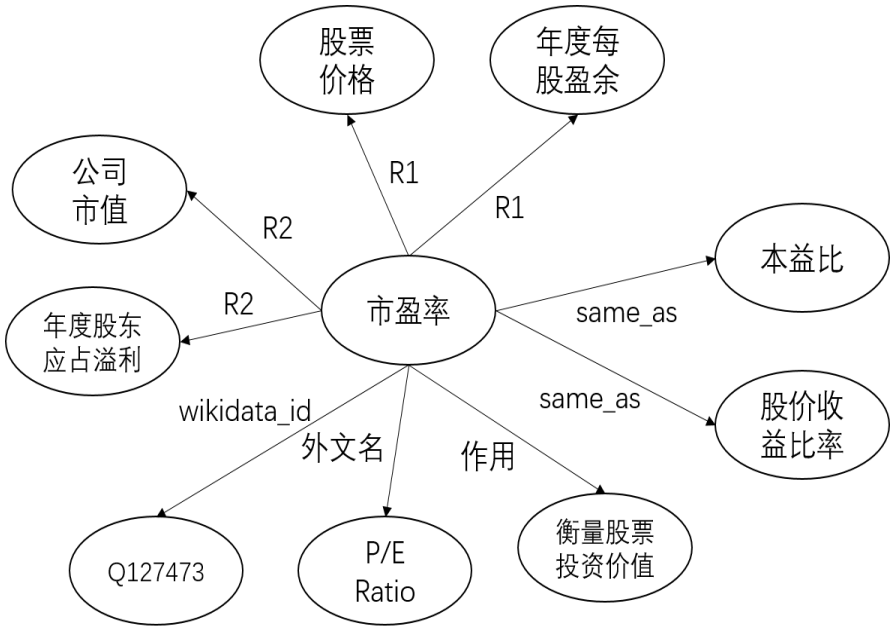


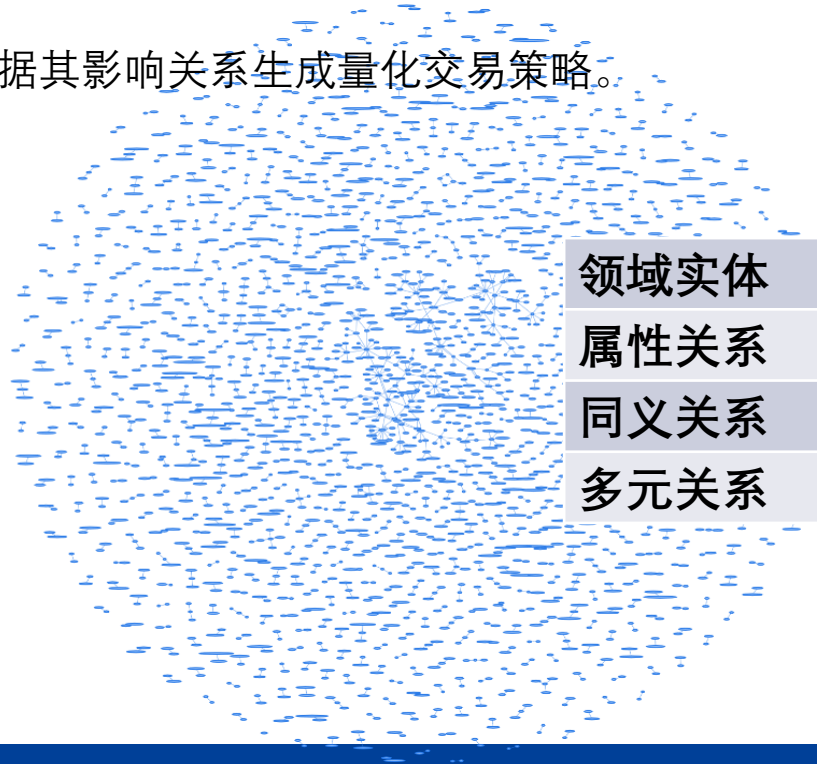


厂商多维分析实例

4.2 其他知识图谱应用实例

- 基于知识图谱的量化交易决策支持
- 离线阶段：
  - 通过互联网爬取领域相关开放数据，经数据预处理后，对数据进行可信度分析和融合，抽取领域实体；
  - 借助开放知识库抽取实体关系，包括同义、从属、多元关系等；
  - 构建基于关系的知识图谱存储结构。
- 在线阶段：
  - 通过实体、关系的语义检索，获取关联实体，根据其影响关系生成量化交易策略。

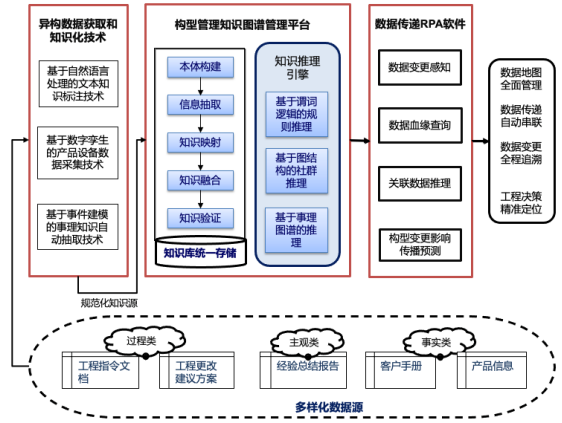


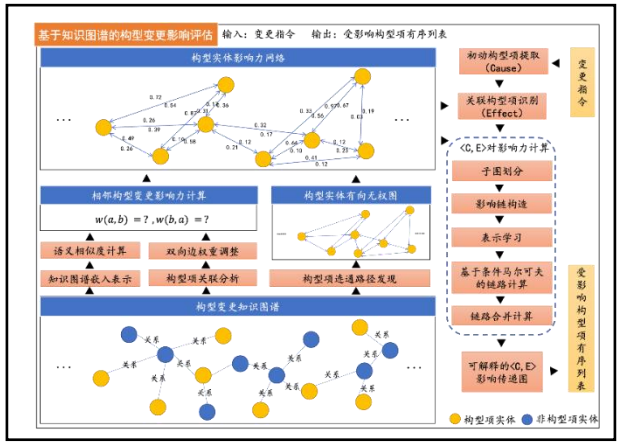


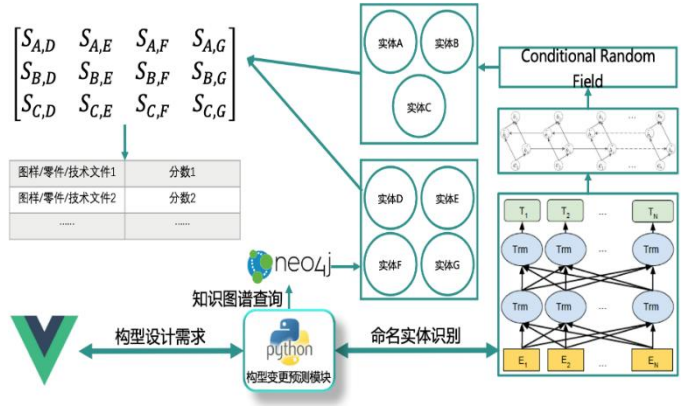
领域实体	1170（687）
属性关系	1857
同义关系	94
多元关系	389（101）

基于RPA的航空产品变更管理

- 研发基于RPA数据传递的构型差异评估报告编制工具，实现自动化的构型变更知识图谱构建及软件封装，作为产品设计管理的知识平台。

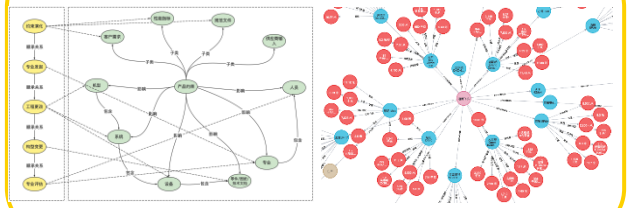






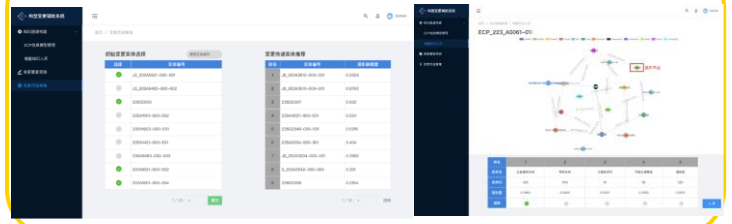
面向异构数据的RPA构型管理平台构建

数据定义与感知模块



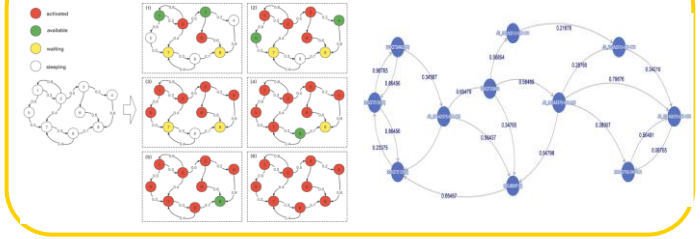
基于知识图谱的构型变更影响预测技术

软件开发与集成模块



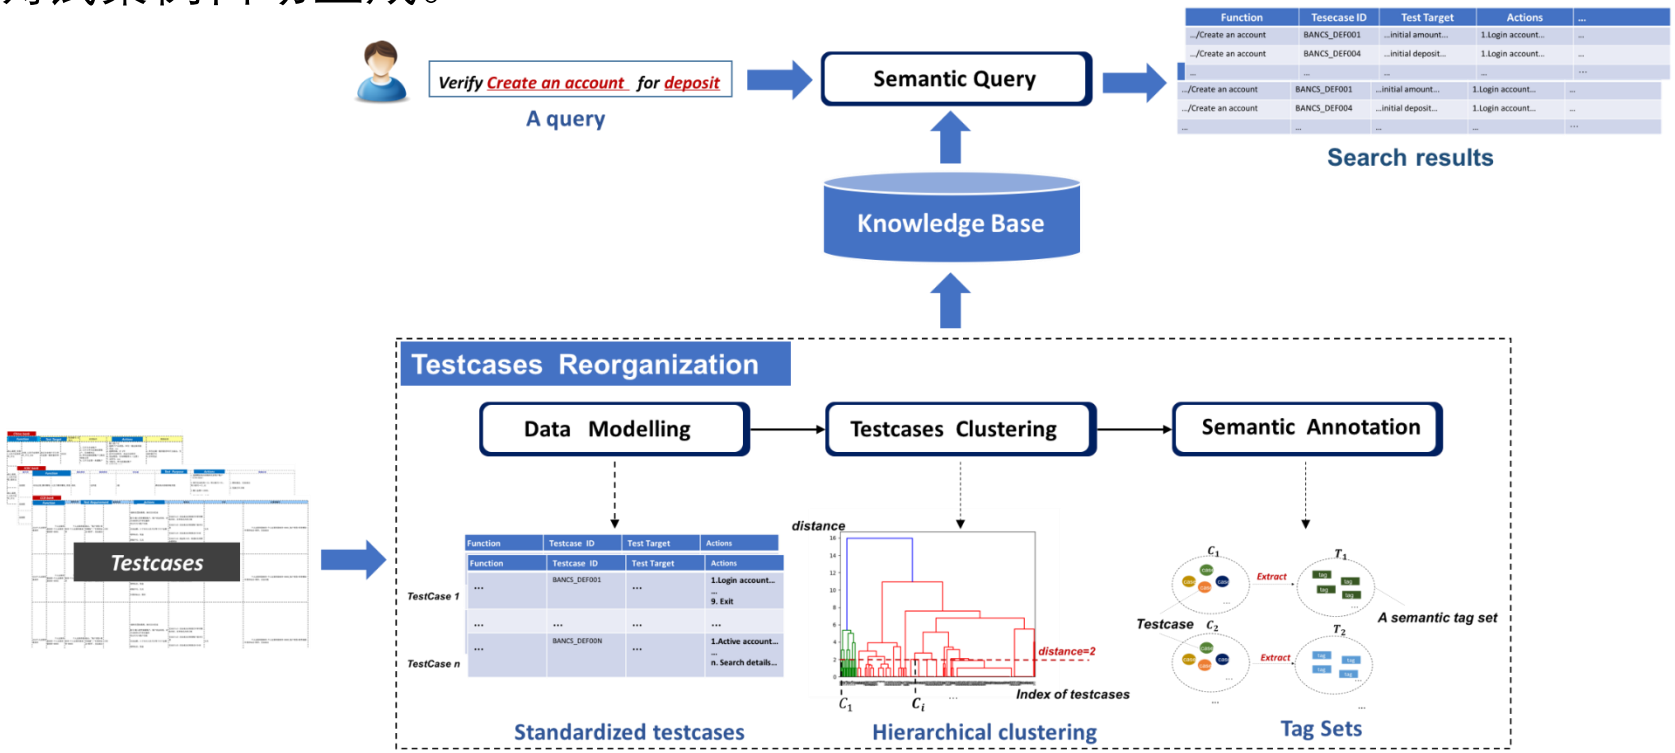
基于构型需求的语义解析及智能推荐技术

知识推理与应用模块



基于知识图谱的银行测试案例库

- 信息抽取层：面向海量银行测试案例文档，运用自然语言处理方法提取实体、关系，形成实体级知识图谱；
- 知识汇聚层：基于实体特征，采用语义聚类和文本特征提取方法，构造抽象语义类，形成概念级知识图谱；构造功能树，实现对业务规则的建模与应用；
- 资源应用层：构造语义查询系统，实现对银行测试案例的语义查询。形成业务规则模板，实现基于知识库的新测试案例自动生成。



基于知识图谱的能源互联网智慧监管

- 对能源点位实时进行知识抽取
- 形成能源网知识图谱
- 根据数值知识进行点位异常检测
- 根据实体相似度寻找替代设备

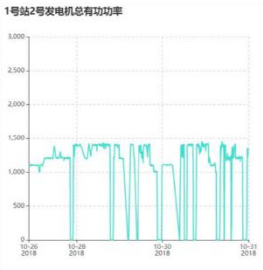
S_SLG_JZ4_P_YG_TOT query

```
<S_SLG_JZ4_P_YG_TOTAL> rdf:type <Total_active_power_of_generator> ;
        sosa:subSystemOf <4#generator1#Station> ;
        sosa:observes <Total_active_power> ;
        ist:Ptype <clique> ;
        ist:controlBy <S_4FDJ_RUN> .

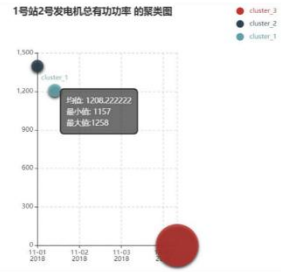
<S_SLG_JZ4_P_YG_TOTAL> ist:mean "351.982891"^^xsd:double ;
        ist:has_cluster <S_SLG_JZ4_P_YG_TOTAL_cluster_1> ;
        ist:has_cluster <S_SLG_JZ4_P_YG_TOTAL_cluster_2> .

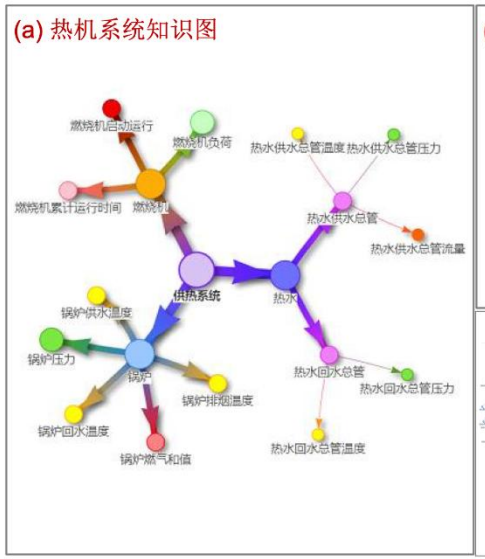
<S_SLG_JZ4_P_YG_TOTAL_cluster_1> rdf:type ist:cluster ;
        ist:relevanceStamp "25532880301.773490"^^xsd:double ;
        ist:mean "1218.266409"^^xsd:double ;
        ist:volume "2072"^^xsd:int .
<S_SLG_JZ4_P_YG_TOTAL_cluster_2> rdf:type ist:cluster ;
        ist:relevanceStamp "27200706949.199825"^^xsd:double ;
        ist:mean "0.023500"^^xsd:double ;
        ist:volume "5617"^^xsd:int .
```

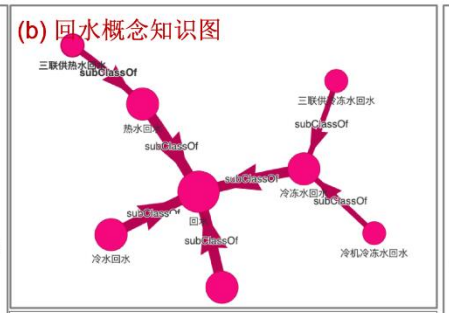
时间序列视图

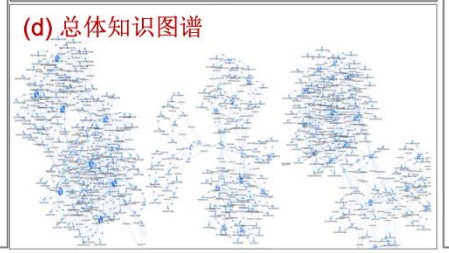


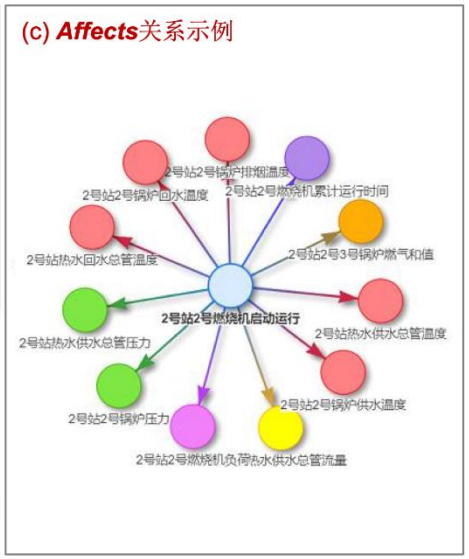
数值聚类视图

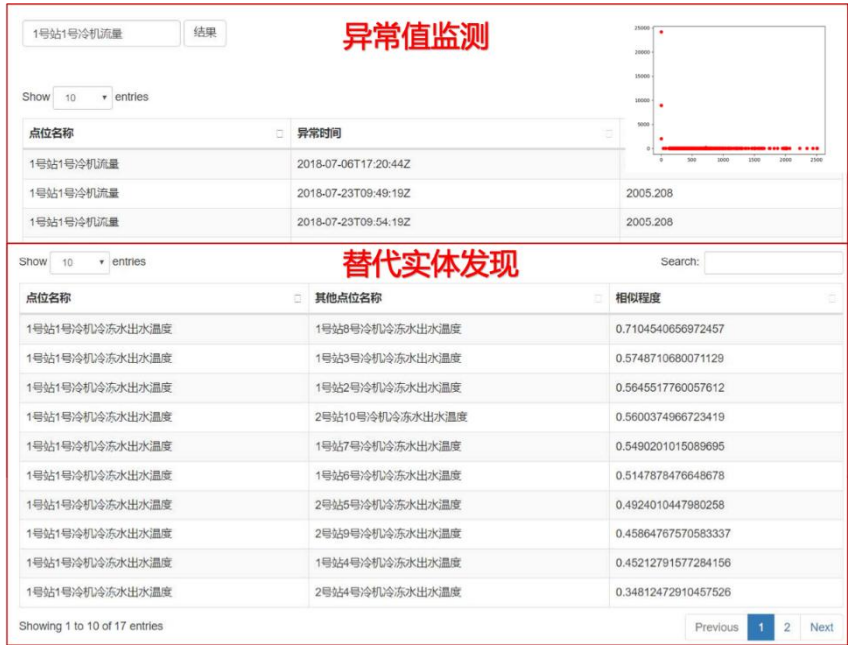








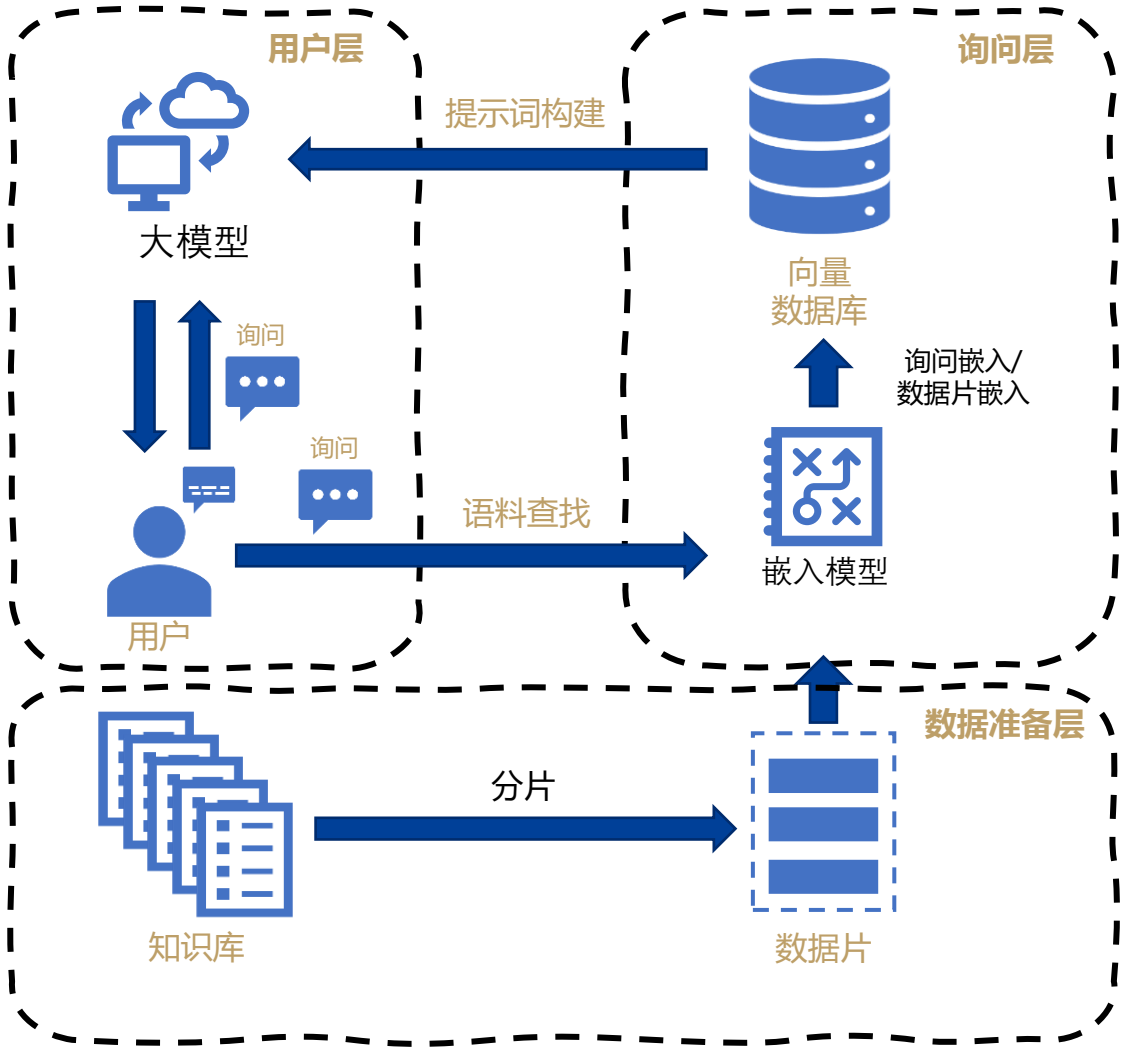




知识图谱+大语言模型LLM

• 知识图谱+LLM的新推理范式

- 基于知识图谱开展系统的诊断、分析、预测、决策，在不完备数据和不精确模型基础上，建立信息补全和似然推理机制，是未来构造智能制造的智能处理机制的重要方式。
- 模型可以根据提问，在指定知识库中进行检索，对检索得到的相关文档内容进行总结并生成问题回复。
- 模型可以对知识构建过程本身进行支持，支撑内容的演化更新。



目录

- 1 数据智能平台

  1.1 大数据定义-1.2数据分析特点-1.3 大数据处理过程

- 2 数据治理

  2.1 数据准备-2.2数据治理-2.3数据分类-2.4智能数据治理

- 3 知识图谱

  3.1 知识图谱发展-3.2知识图谱表示及存储-3.3 知识图谱构建-3.4 KG构建实例

- 4 基于知识图谱的智能数据治理

  4.1 航天元器件应用实例-4.2其他实例

- 5 小结

5 小结

- 从数据分析过程出发，以数据的采、治、存、算、用为主线，阐述了数据智能平台的构造思想和技术框架；
- 以数据治理及存储出发，阐述了数据的预处理过程和数据治理模型；
- 面向智能数据治理需要，阐述了知识图谱的定义、存储、构建、推理等技术；
- 阐述了基于知识图谱的智能数据治理方法，给出了智能应用的案例。