Lecture5 数据智能应用设计



于晗

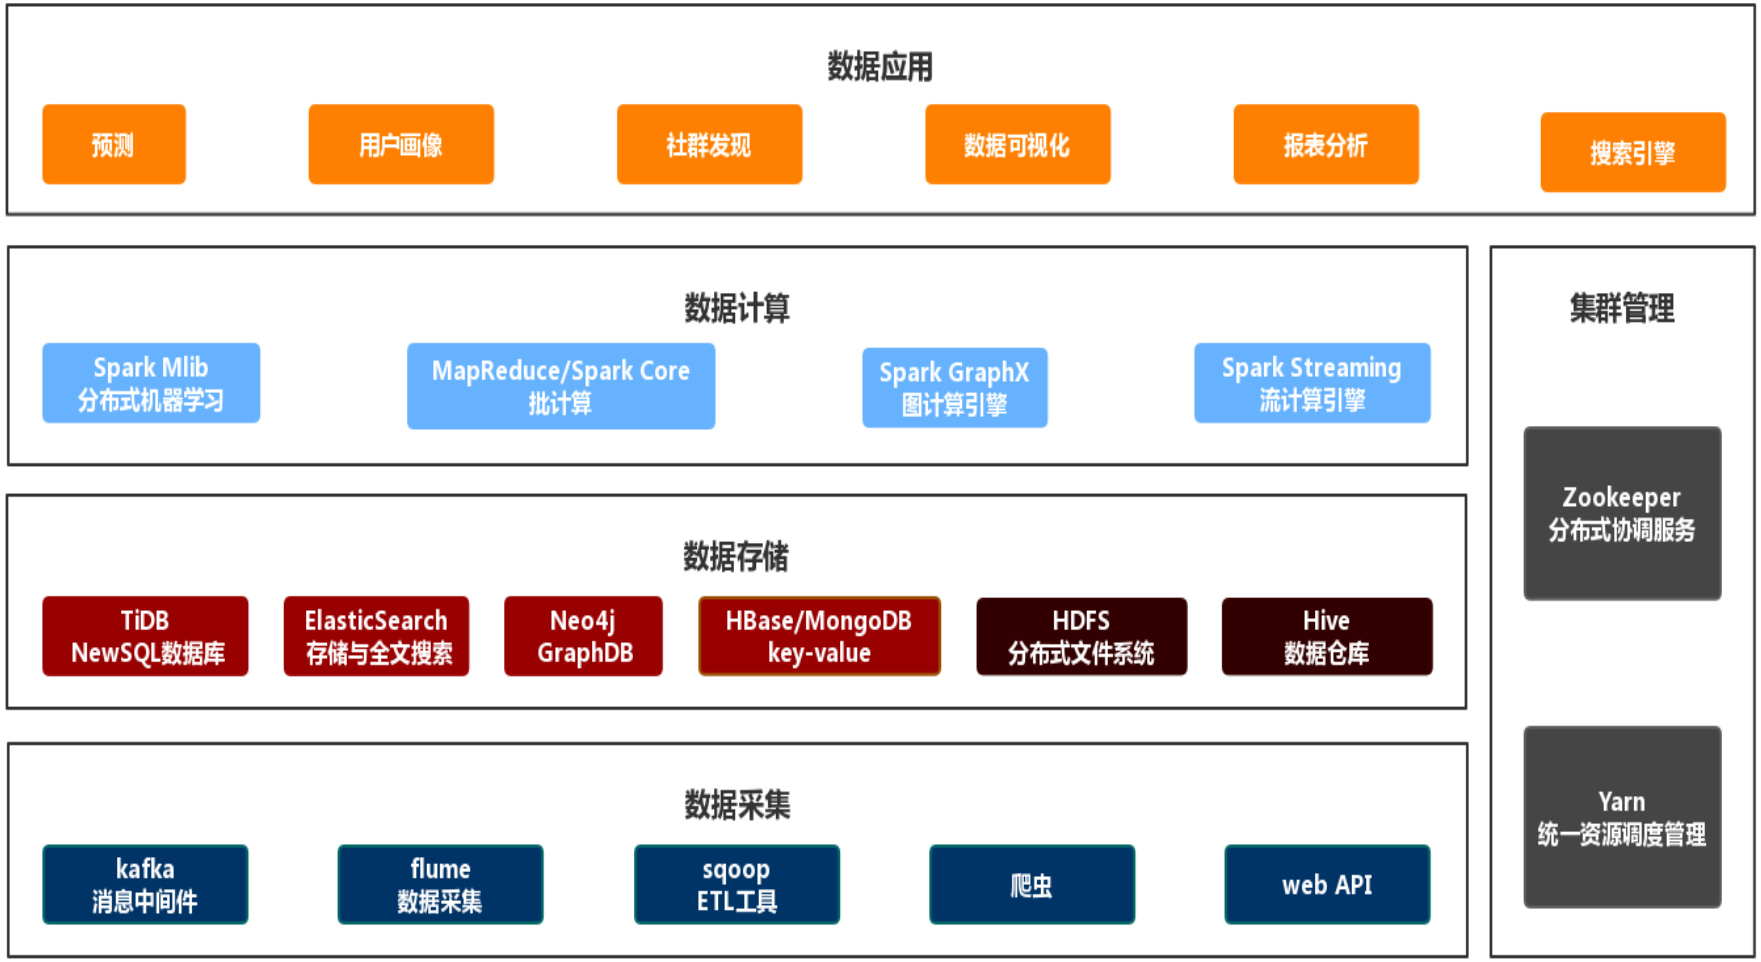
han_yu@sjtu.edu.cn

目录

- 1 数据智能应用回顾
- 2 基于机器学习的数据智能应用基础
- 3 基于机器学习的数据智能应用进阶
- 4 小结

1.1 智能数据应用实例

一个典型的大数据平台架构

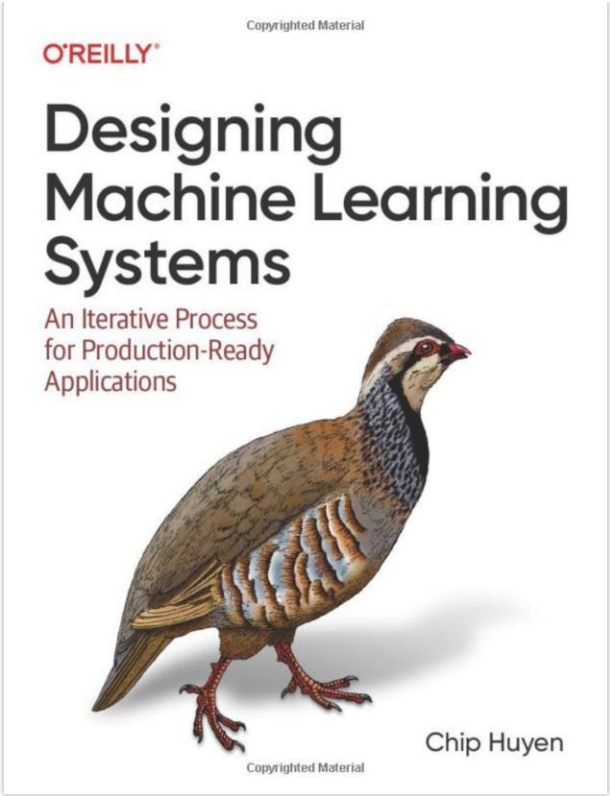


1.2 大数据分析算法

- 根据大数据分析算法对实时性的要求可以也分为三类：
  - **实时分析算法**：这类分析算法适用实时获取的数据，响应时间约束为秒级甚至毫秒级。
  - **弱实时分析算法：**这类分析算法面向有用户参与分析决策的分析任务，不要求实时响应，但是也存在响应时间约束，响应时间约束从分钟到小时。
  - **非实时分析算法：**这类分析算法适用数据仓库中的大规模数据，响应时间约束相对宽松，可以达到天甚至月。
- 根据大数据分析算法的功用可以分为四类：
  - **分类算法**
  - **聚类算法**
  - **关联算法**
  - **回归算法**

目录

- 1 数据智能应用回顾
- 2 基于机器学习的数据智能应用基础
- 3 基于机器学习的数据智能应用进阶
- 4 小结



Source from Standford CS329 by Dr.Chip Huyen

理想中的数据智能应用开发

- 1.收集数据
- 2.训练模型
- 3.部署模型



实际上的数据智能应用开发

1. 选择一个指标进行优化
2. 收集数据
3. 训练模型
4. 意识到许多标签是错误的 -> 重新标记数据
5. 训练模型
6. 模型在一个类别上表现不佳-> 为该类别收集更多的数据
7. 训练模型
8. 模型在最近的数据上表现不佳 -> 收集更多最近的数据
9. 训练模型
10. 部署模型
11. 开始做梦 $$$
12. 凌晨两点被投诉说模型对某一类别有偏差-> 恢复到旧版本

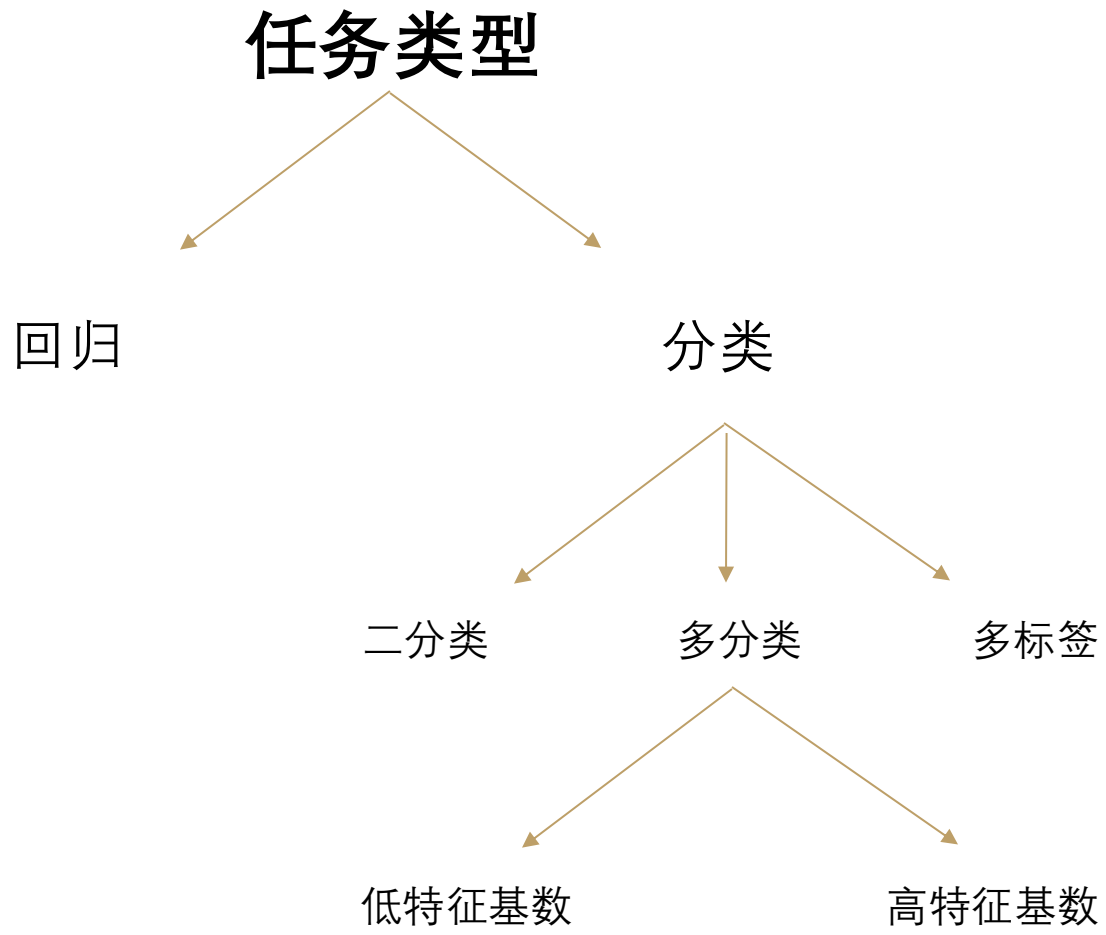
步骤15和步骤17非常重要

13. 获得更多的数据，训练更多的数据，做更多的测试
14. 部署模型
15. 祈祷
16. 模型表现良好但收入减少
17. 哭泣
18. 选择一个不同的指标
19. 重新开始

数据智能应用设计的考虑因素

- 1.任务类型
- 2.目标
- 3.限制因素
- 4.实施阶段

2.1 任务类型划分



多类别与多标签

任务类型

回归

分类

二分类　　多分类　　多标签

0	0	0	1

一个样本只能属于一个类别

0	1	0	1

一个样本可以属于多个类别

如何处理多标签问题

多标签问题

多分类问题

0	1	0	1

一组多重二分类问题

模型1：这属于第1类吗？

模型2：这属于第2类吗？

...

多标签比多分类更困难

多标签问题

多分类问题

0	1	0	1

一组多重二分类问题

模型1：这属于第1类吗？

模型2：这属于第2类吗？

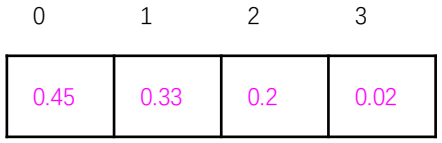
…

1. 如何创建ground truth labels?
2. 如何确定决策边界?

多标签：决策边界

多标签问题

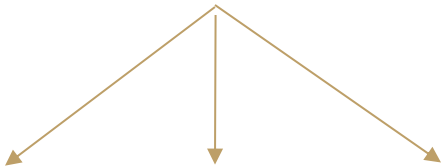
多分类问题



这个例子应该属于哪些类？

1. 0
2. 0, 1
3. 0, 1, 2

一组多重二分类问题



模型1：这属于第1类吗？

模型2：这属于第2类吗？

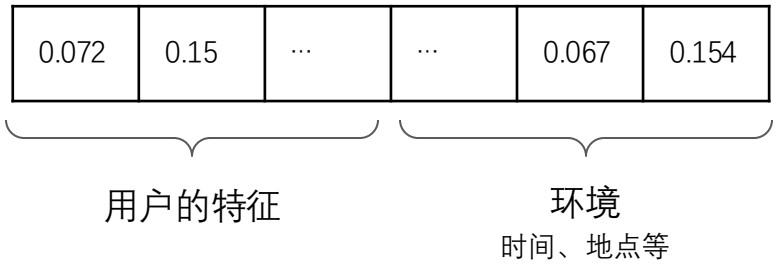
…

一个问题可以划分为不同的任务类型

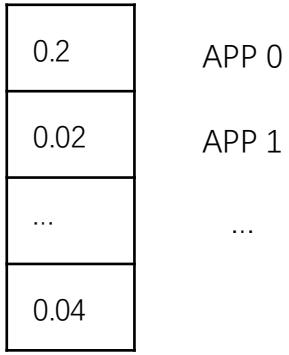
问题：预测用户接下来最有可能打开的app

分类

输入



输出

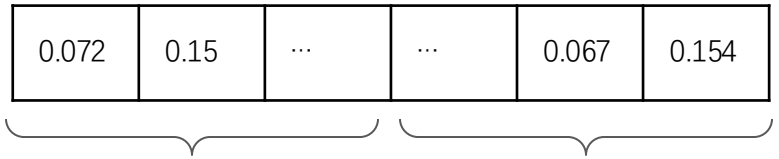


一个问题可以划分为不同的任务类型

问题：预测用户接下来最有可能打开的app

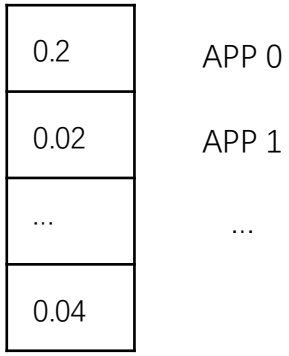
分类

输入



⚠每次添加/删除app时，都必须重新训练模型⚠

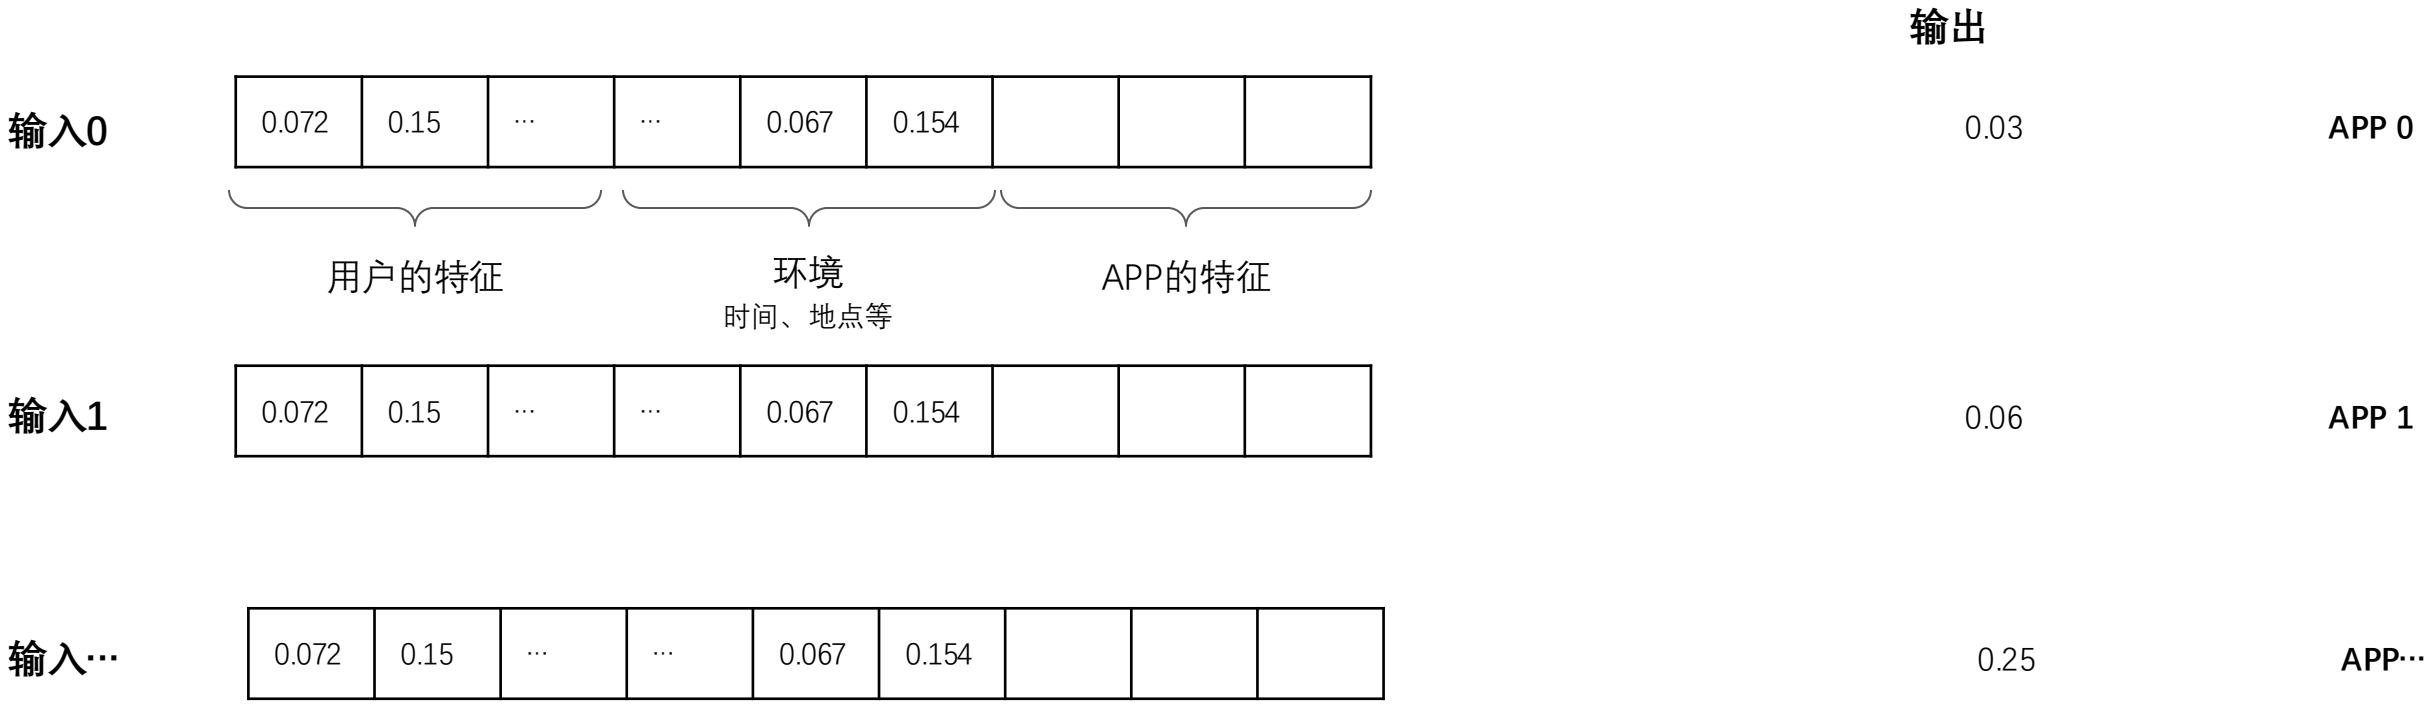
输出



类型划分可以使问题变容易/难

问题：预测用户接下来最有可能打开的app

回归

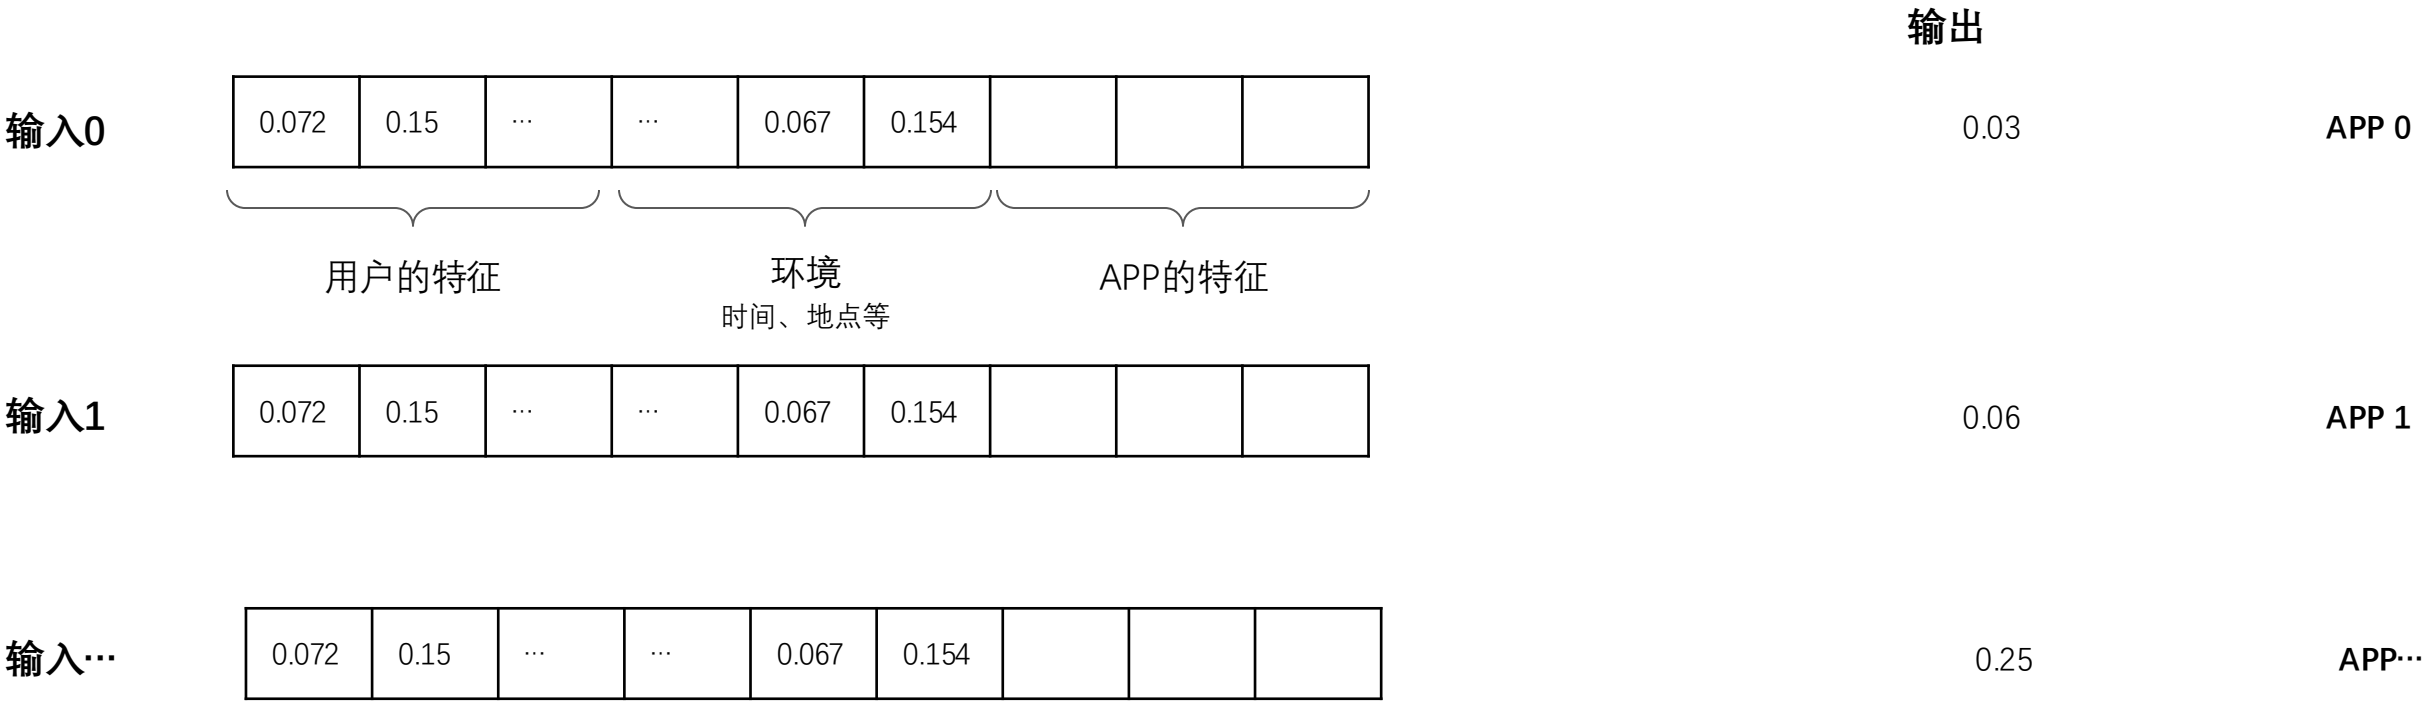


类型划分可以使问题变容易/难

问题：预测用户接下来最有可能打开的app

非常常见的推荐/广告CTR划分

回归



2.2 目标

- 1. 机器学习算法目标
- 2. 业务目标

2.2 目标

- 机器学习算法目标
  - 性能
  - 延迟
  - …

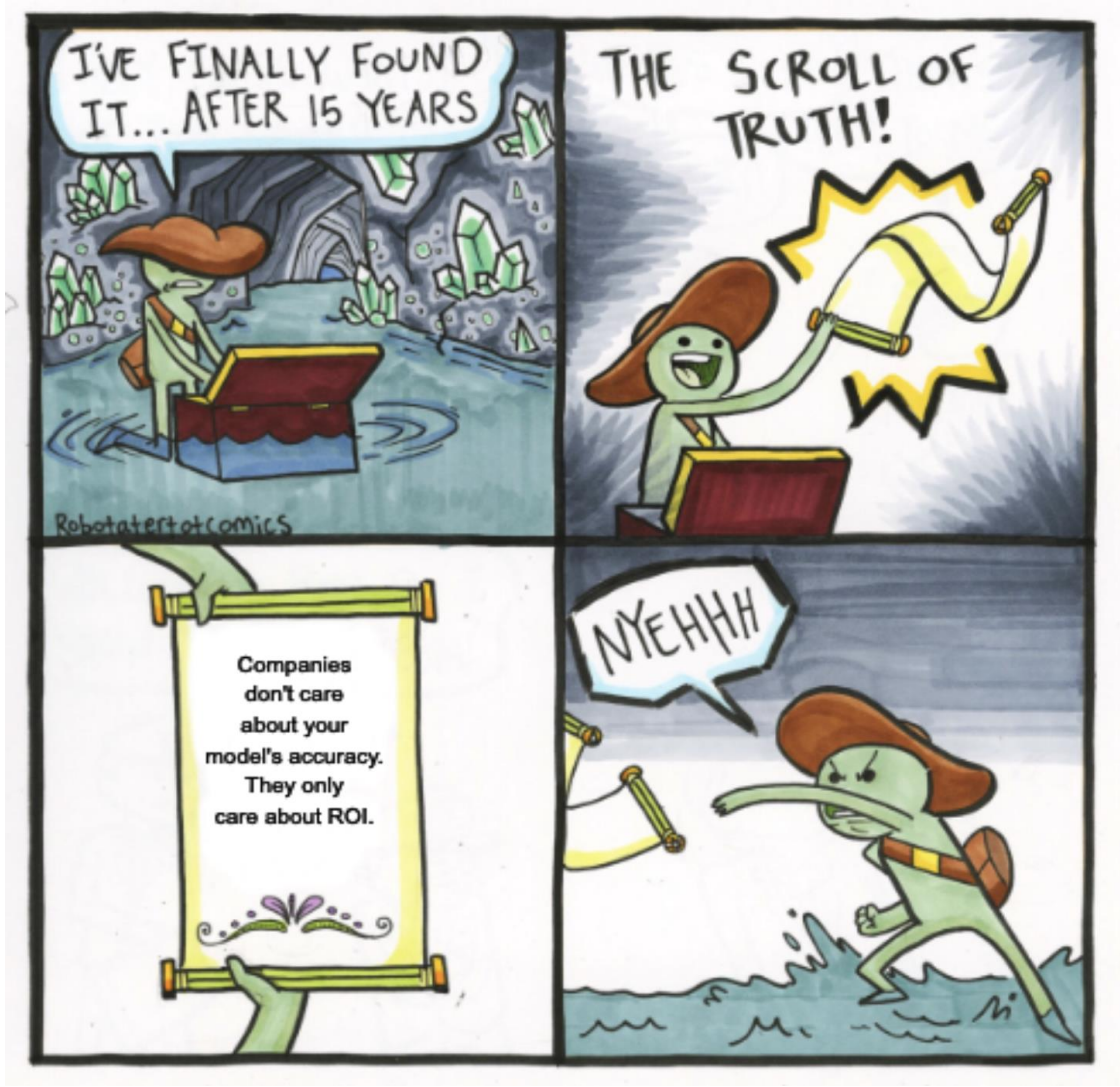
没有ground truth labels时,如何评估准确性/F1/..？

2.2 目标

- 机器学习目标
  - 性能
  - 延迟
  - …
- 业务目标
  - 费用
  - 投资回报率
  - 合规性

2.2 目标

- 机器学习目标
  - 性能
  - 延迟
  - …
- 业务目标
  - 费用
  - 投资回报率
  - 合规性



机器学习如何实现业务目标

这个机器学习项目如何直接或间接地增加利润?

- 直接地：增加销售（广告，转换率），削减成本
- 间接地：增加客户满意度，增加在网站上花费的时间

机器学习对业务的影响

机器学习模型给客户更个性化的解决方案

客户更高兴

更快解决客户的问题

客户花更多的钱

客户花更少的钱

Very tricky

机器学习业务目标如何确定

基线

- 现有解决方案、简单解决方案、专家、竞争对手解决方案等。

机器学习业务目标如何确定

- 基线
- 有用性阈值
  - 自动驾驶需要达到人类操作水平,但预测文本不需要。

机器学习业务目标如何确定

- 基线
- 有用性阈值
- False negatives vs. false positives
  - COVID检测：no false negative （患有COVID的患者不应归类为无COVID）
  - 指纹解锁：no false positive （未经授权的人不应获得访问权限）

机器学习业务目标如何确定

- 基线
- 有用性阈值
- False negatives vs. false positives
- 可解释性
  - 机器学习系统是否需要可解释？如果是，向谁解释？

机器学习业务目标如何确定

- 基线
- 有用性阈值
- False negatives vs. false positives
- 可解释性
- 置信度衡量（对预测的置信度）
  - 它需要置信度衡量吗？
  - 是否存在置信度阈值？如何处理低于该阈值的预测—丢弃它，在人们中传播，或向用户询问更多信息？

机器学习业务目标如何确定

- 基线
  - 现有解决方案、简单解决方案、专家、竞争对手解决方案等。
- 有用性阈值
  - 自动驾驶需要达到人类操作水平,但预测文本不需要。
- False negatives vs. false positives
  - COVID检测：no false negative （患有COVID的患者不应归类为无COVID）
  - 指纹解锁：no false positive （未经授权的人不应获得访问权限）
- 可解释性
  - 机器学习系统是否需要可解释？如果是，向谁解释？
- 置信度衡量（对预测的置信度）
  - 它需要置信度衡量吗？
  - 是否存在置信度阈值？如何处理低于该阈值的预测—丢弃它，在人们中传播，或向用户询问更多信息？

2.3 限制因素：时间和预算

- 时间
  - 经验法则：20%的时间用于构建初始系统，80%的时间用于迭代开发
- 预算
  - 数据，资源，人力

时间/预算权衡

- 使用更多（强大）的机器
- 雇佣更多的人来更快地标记数据
- 并行运行更多实验
- 购买现有解决方案

2.3 限制因素：隐私

- 标注
  - 是否可以将数据发送到组织外部进行标注?
- 存储
  - 可以存哪些类型的数据？能存多久?
- 第三方解决方案
  - 是否可以与第三方（例如管理服务）共享数据?
- 规章制度
  - 必须遵守什么规定?

2.3 限制因素：技术

- 1.竞争对手
- 2.落后的系统



2.4 实施阶段

- 阶段1:使用机器学习之前

“如果你认为机器学习会给你带来100%的提升，那么启发式学习会让你实现50%的目标。”

Martin Zinkevich, Google

2.4 实施阶段

➢ 阶段2:构建最简单的机器学习模型

- 从一个简单的模型开始，该模型工作过程对你可见:
  - 验证假设
  - 验证流程

2.4 实施阶段

阶段3:优化简单模型

- 不同的目标函数
- 特征工程
- 更多数据
- 集成学习（Ensembling）

2.4 实施阶段

- 阶段4:复杂的机器学习模型



回顾：数据智能应用设计的考虑因素

- 1.任务类型
- 2.目标
- 3.限制因素
- 4.实施阶段

目录

- 1 数据智能应用回顾
- 2 基于机器学习的数据智能应用基础
- 3 基于机器学习的数据智能应用进阶
- 4 小结

3.1 目标解耦

- 为新闻构建排名系统时可能的目标:
  - 尽量减少错误信息的传播
  - 从赞助中获得最大收益
  - 最大限度地提高参与度

你会选择哪个目标?

扩展阅读：最大化参与度的道德规范

Several current and former YouTube employees, who would speak only on the condition of anonymity because they had signed confidentiality agreements, said company leaders were obsessed with increasing engagement during those years. The executives, the people said, rarely considered whether the company's algorithms were fueling the spread of extreme and hateful political content.

Employee raises at Facebook depend on engagement, and newly leaked private Zuckerberg recordings show the Groups algorithm prioritizes enragement.

In data terms, anti-vaxx groups and QAnon hysteria are going to get far better engagement than your average drag queen or 'Vote Yes on Proposition Z' groups. Moreover, the group recommendations tool prioritizes the angriest and most out-to-lunch groups, because those tend to get more clicks when they appear in the recommended field.

Facebook Employee Raises Powered by 'Really Dangerous' Algorithm That Favors Angry Posts (SFist, 2019)
The Making of a YouTube Radical (NYT, 2019)

3.1 目标解耦：最大限度地提高参与度

- 分步目标：

1. 过滤垃圾内容
2. 过滤NSFW内容
3. 根据参与度对帖子进行排序：用户点击它们的可能性有多大

3.1 目标解耦：健康的新闻传播

目标：最大限度地提高用户参与度，同时最大限度地减少极端观点和错误信息的传播

- 分步目标：

1. 过滤垃圾信息
2. 过滤NSFW内容
3. 过滤错误信息
4. 根据质量对帖子进行排序
5. 根据参与度对帖子进行排序：用户点击它们的可能性有多大

3.1 目标解耦：健康的新闻传播

目标：最大限度地提高用户参与度，同时最大限度地减少极端观点和错误信息的传播

- 分步目标：

1. 过滤垃圾内容
2. 过滤NSFW内容
3. 过滤错误信息
4. 根据质量对帖子进行排序
5. 根据参与度对帖子进行排序：用户点击它们的可能性有多大

如何根据质量和参与度排序？

多目标优化（MOO）

- 根据质量排序
  - 预测帖子的质量
  - 最小化 **quality_loss**： 预测质量与真实质量之间的差异
- 根据用户点击的可能性排序
  - 预测帖子的参与度
  - 最小化 **engagement_loss**： 预测点击和真实点击之间的差异

一种优化联合损失的模型

- 根据质量排序
  - 预测帖子的质量
  - 最小化 **quality_loss**： 预测质量与真实质量之间的差异
- 根据用户点击的可能性排序
  - 预测帖子的参与度
  - 最小化 **engagement_loss**： 预测点击和真实点击之间的差异

$$\text{loss} = \alpha\ \text{quality_loss} + \beta\ \text{engagement_loss}$$

训练模型，调整α和β，
以最小化combined loss

ps：如果想了解如何选择α和β， 请参考Pareto优化

一种优化联合损失的模型

- 根据质量排序
  - 预测帖子的质量
  - 最小化 **quality_loss**： 预测质量与真实质量之间的差异
- 根据用户点击的可能性排序
  - 预测帖子的参与度
  - 最小化 **engagement_loss**： 预测点击和真实点击之间的差异

$$\text{loss} = \alpha\ \text{quality_loss} + \beta\ \text{engagement_loss}$$

训练模型以最小化combined loss

$$\mathcal{L}_{total}(\vec{p}, \vec{a}, \vec{x}) = \alpha\mathcal{L}_{content}(\vec{p}, \vec{x}) + \beta\mathcal{L}_{style}(\vec{a}, \vec{x})$$

A Neural Algorithm of Artistic Style (Gatys et al, 2017)

一种优化联合损失的模型

- 根据质量排序
  - 预测帖子的质量
  - 最小化 **quality_loss**： 预测质量与真实质量之间的差异
- 根据用户点击的可能性排序
  - 预测帖子的参与度
  - 最小化 **engagement_loss**： 预测点击和真实点击之间的差异

$$\text{loss} = \alpha\ \text{quality_loss} + \beta\ \text{engagement_loss}$$

训练模型以最小化combined loss

每次想调整α和β，都必须重新训练模型！

A Neural Algorithm of Artistic Style (Gatys et al, 2017)

一种优化联合损失的模型

- 根据质量排序
  - 预测帖子的质量
  - 最小化 **quality_loss**： 预测质量与真实质量之间的差异
- 根据用户点击的可能性排序
  - 预测帖子的参与度
  - 最小化 **engagement_loss**： 预测点击和真实点击之间的差异

M_q：优化 **quality_loss**
M_e：优化 **engagement_loss**

按α M_q(post)+ β M_e(post)排序

现在可以在不重新训练的情况下调整模型

3.1 目标解耦的几种思路

- 更易于训练
  - 优化一个目标比优化多个目标更容易
- 更易于调整
  - 例如， α % 质量优化+ β % 参与度优化
- 更易于维护
  - 不同的目标可能需要不同的维护方案
    - 垃圾内容生成技术的发展比质量评估技术更快
    - 垃圾内容过滤系统比质量排名系统更需要频繁的更新

课间练习

10分钟-4人小组

如何建立一个系统来显示热门话题标签?

- 需要考虑的方面:
  - 业务目标和机器学习目标
  - **如何衡量模型的性能? 有无参考标准?**
  - 约束
  - 最简单的模型是什么?
    - 提示: 基于规则, 基于计数
  - 热门话题标签的本地化/个性化

https://mlops-discord.github.io/blog/designing-twitters-trending-hashtags-solution/

3.2 模型选择

- 机器学习算法需要选择的内容

- 要学习的模型
  - 例如，模型结构、隐藏层的数量
- 优化的目标函数（最小化）
  - 损失函数
- 学习过程（优化器）
  - Adam, Momentum

模型选择的6个准则

准则1：避开SOTA的陷阱

SOTA的优势

- 当有新的解决方案时为什么要使用旧的解决方案？
- 运用最优秀的成果是令人兴奋的
- 市场



准则1：避开SOTA的陷阱

SOTA的现实

- 研究数据上的SOTA != 在您的数据上的SOTA
- 费用
- 延迟性
- 经过验证的行业成功
- 社区支持



准则2：从最简单的模型开始

- 更易于部署
  - 早期部署允许验证pipeline
- 更易于调试
- 更易于优化

准则2：从最简单的模型开始

- 更易于部署
  - 早期部署允许验证流程
- 更易于调试
- 更易于改进
- 最简单的模型 != 最省力的模型
  - BERT很容易从预训练的模型开始，但不是最简单的

准则3：避免人造偏差

人造偏差的例子

- 提出LSTM变体的论文表明，这些变体改进了普通的LSTM
- 它们真的改进了吗？

准则3：避免人造偏差

- 人造偏差的例子
  - 提出LSTM变体的论文表明，这些变体改进了普通的LSTM
  - 它们真的改进了吗？

LSTM: A Search Space Odyssey

Klaus Greff, Rupesh K. Srivastava, Jan Koutník, Bas R. Steunebrink, Jürgen Schmidhuber

We conclude that the most commonly used LSTM architecture (vanilla LSTM) performs reasonably well on various datasets. None of the eight investigated modifications significantly improves performance.

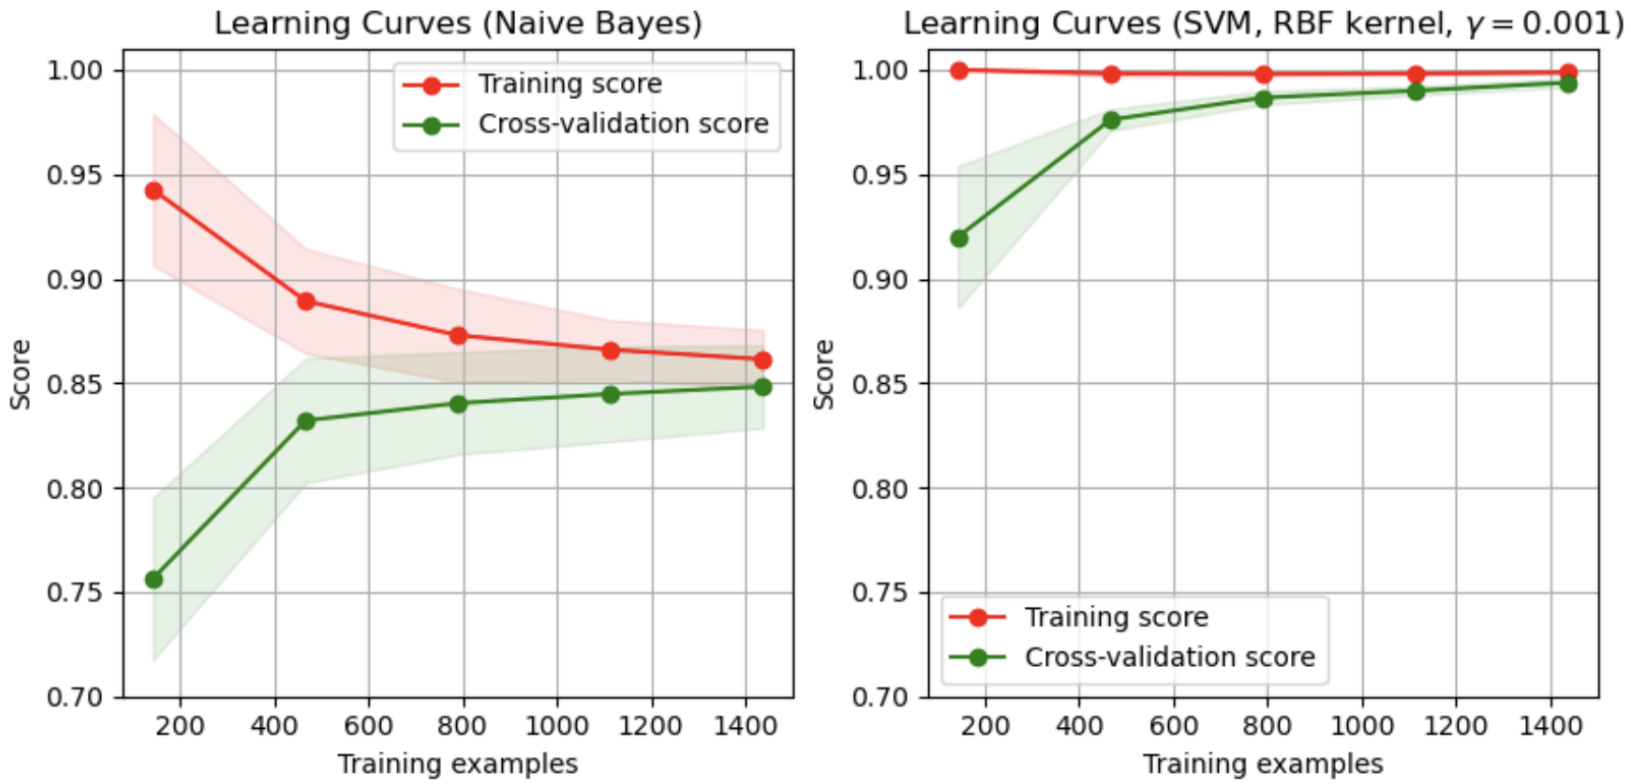
准则3：避免人造偏差

- 在可比条件下评估模型是很重要的
  - 当你对X更感兴趣时，你很可能对X做更多的实验。
- 几乎不可能笼统地声称X总是比Y好。

准则4：现在更好vs.以后更好

- 现在最好的模型 != 2个月内最好的模型
  - 使用更多数据后可以更好地改进性能
  - 易于更新

学习曲线



适用于评估使用更多数据是否可以提高性能

https://scikit-learn.org/stable/auto_examples/model_selection/plot_learning_curve.html

准则5：评估Trade-offs

- False positives vs. false negatives
- 准确性 vs. 计算/延迟
- 准确性 vs. 可解释性

Architecture	#Train/All Params (M)	FLOPs (G)	Top-1
RSB-ResNet-18	11.69/11.69	1.82	70.6
RegNetY-800M	6.30/6.30	0.8	76.3
ViT-T16	5.7/5.7	1.3	74.1
DeRy(4,10,3)-FZ†	1.02/7.83	2.99	41.2
DeRy(4,10,3)-FT†	7.83/7.83	2.99	76.9
DeRy(4,10,3)-FT	7.83/7.83	2.99	78.4
RSB-ResNet-50	25.56/25.56	4.12	79.8
RegNetY-4GF	20.60/20.60	4.0	79.4
ViT-S16	22.0/22.0	4.6	79.6
Swin-T	28.29/28.29	4.36	81.2
DeRy(4,30,6)-FZ†	1.57/24.89	4.47	60.5
DeRy(4,30,6)-FT†	24.89/24.89	4.47	79.6
DeRy(4,30,6)-FT	24.89/24.89	4.47	81.2
RSB-ResNet-101	44.55/44.55	7.85	81.3
RegNetY-8GF	39.20/39.20	8.1	81.7
Swin-S	49.61/49.61	8.52	82.8
DeRy(4,50,10)-FZ†	3.92/40.41	6.43	72.0
DeRy(4,50,10)-FT†	40.41/40.41	6.43	81.3
DeRy(4,50,10)-FT	40.41/40.41	6.43	82.3
RegNetY-16GF	83.6/83.6	16.0	82.9
ViT-B16	86.86/86.86	33.03	79.8
Swin-B	87.77/87.77	15.14	83.1
DeRy(4,90,20)-FZ†	1.27/ 80.66	13.29	78.6
DeRy(4,90,20)-FT†	80.66/ 80.66	13.29	82.4
DeRy(4,90,20)-FT	80.66/ 80.66	13.29	83.2

准则6：理解模型的假设

- IID
  - **神经网络**假设样本是**独立同分布**的。
- 平滑度
  - **监督算法**假设有一组函数可以将输入转换为输出，从而将**相似的输入转换为相似的输出**。
- 易处理性
  - 假设X是输入，Z是X的潜在表示。**生成模型**假设计算P（Z|X）是易处理的。
- 边界
  - **线性分类器**假设**决策边界是线性的**。
- 条件独立性
  - **朴素贝叶斯分类器**假设给定类的属性值**彼此独立**。

3.2 机器学习模型选择的6个准则

- 1.避开SOTA陷阱
- 2.从最简单的模型开始
- 3.避免人造偏差
- 4.现在好 vs. 以后好
- 5.评估Trade-offs
- 6.理解模型的假设

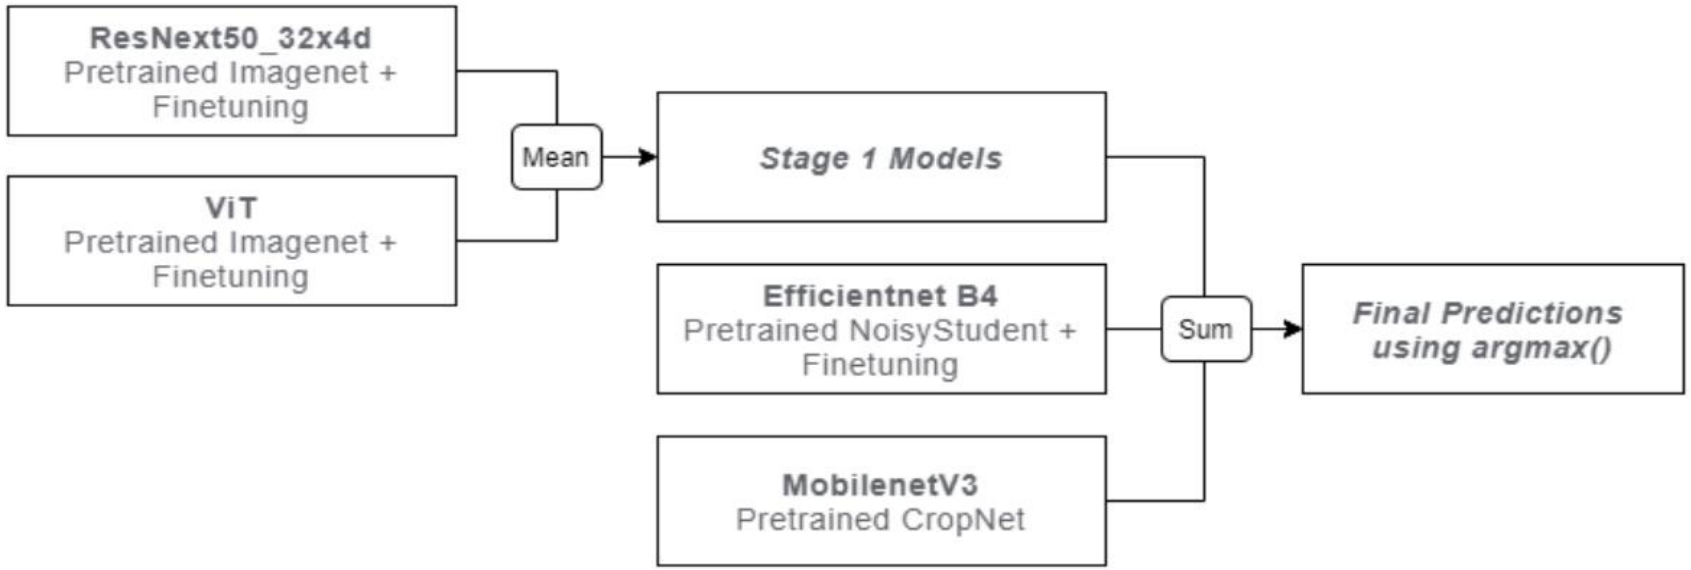
3.3 集成学习

- 从弱模型的集成中创建强模型

基础模型

集成学习：在排行榜中非常常见

- 2021年1月至8月Kaggle上的20/22获奖解决方案使用集成模型
- 一个解决方案使用33个模型!



https://farid.one/kaggle-solutions

为什么集成有效?

- 任务：电子邮件分类（垃圾邮件/非垃圾邮件）
- 3个不相关的模型，每个模型的准确率均为70%
- 整体：对这3个模型的结果进行多数投票算法
  - 如果至少有2个模型是正确的，那么 集成模型就是正确的。

为什么集成有效?

- 3个模型，每个模型的准确率为70%
- 如果至少有2个模型是正确的，那么集成模型就是正确的
- 至少2个模型正确的概率：34.3%+44.1%=78.4%

3个模型的输出	概率	Ensemble模型的输出
3个都正确	0.7 * 0.7 * 0.7 = 0.343	正确的
只有2个是正确的	(0.7 * 0.7 * 0.3) * 3 = 0.441	正确的
只有1个是正确的	(0.3 * 0.3 * 0.7) * 3 = 0.189	错误
没有正确的	0.3 * 0.3 * 0.3 = 0.027	错误

为什么集成有效?

- 3个模型，每个模型的准确率为70%
- 如果至少有2个模型是正确的，那么集成模型就是正确的
- 至少2个模型正确的概率：34.3%+44.1%=78.4%

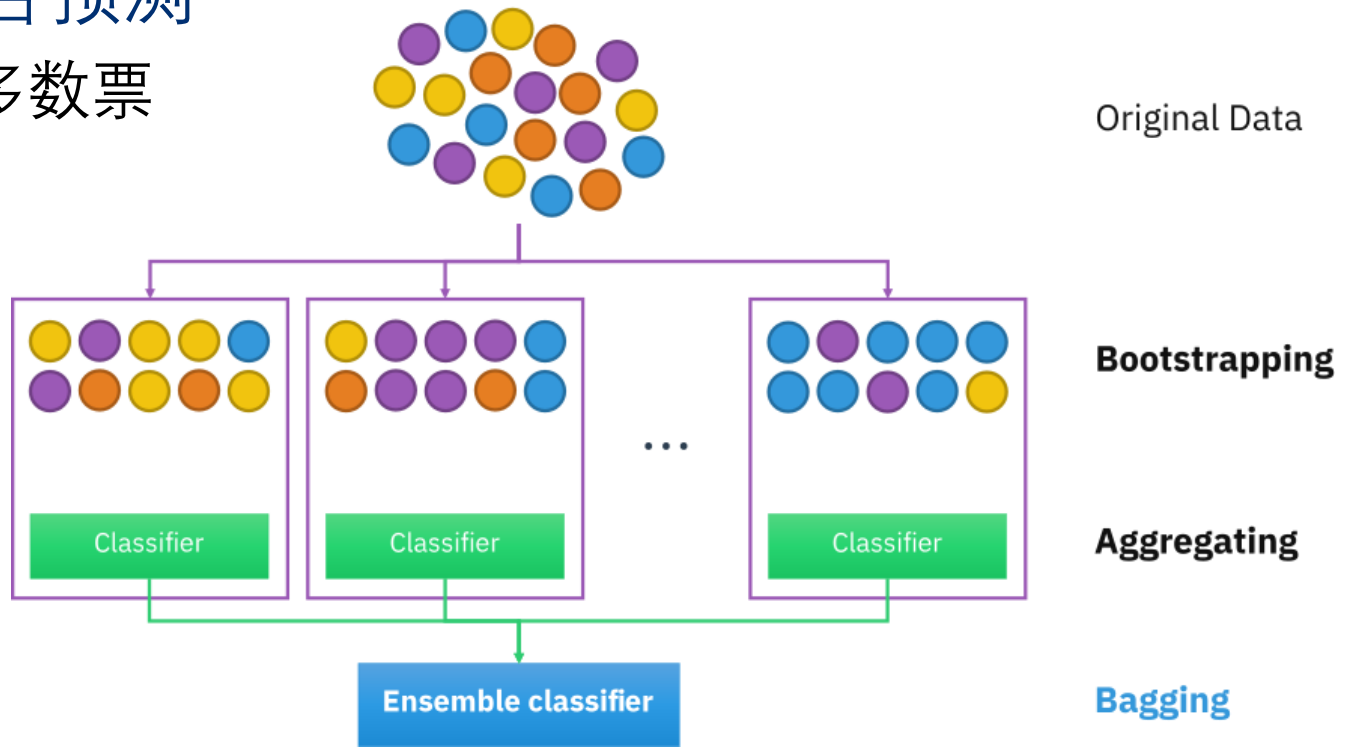
- 基础模型之间的相关性越小越好
- 基础模型通常具有不同的结构

集成学习的三种方法

- Bagging
- Boosting
- Stacking

Bagging

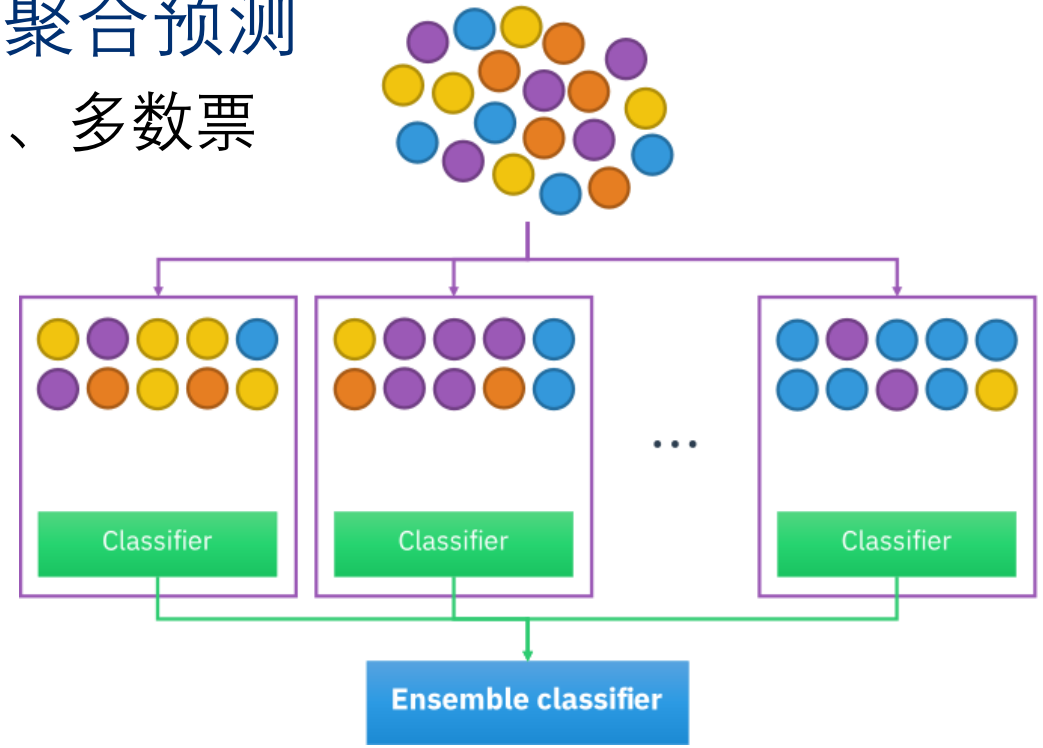
- 替换样例以创建不同的数据集
- 用每个数据集训练一个分类器
- 来自分类器的聚合预测
  - 例如，平均、多数票



插图：Sirakorn

Bagging

- 替换示例以创建不同的数据集
- 用每个数据集训练一个分类器
- 来自分类器的聚合预测
  - 例如，平均、多数票



- 可以改进不稳定的方法，例如神经网络、树
- 可以降低稳定的方法的误差，例如kNN

Original Data

Bagging Predictors (Leo Breiman, 1996)

Bootstrapping

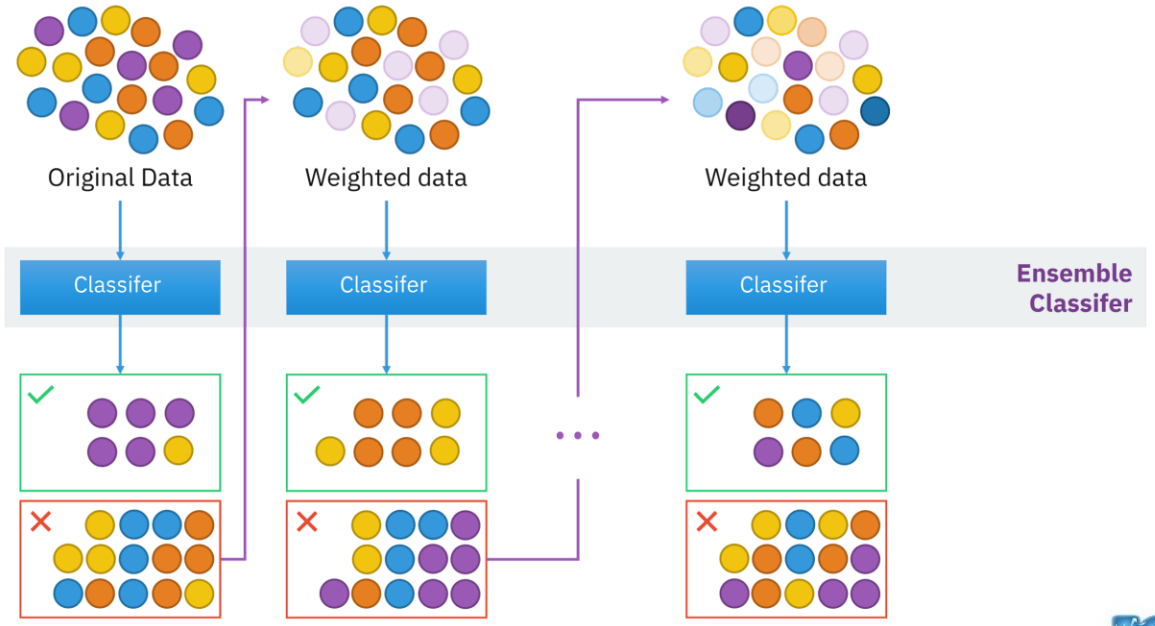
Aggregating

Bagging

插图：Sirakorn

Boosting

- 训练弱分类器
- 将弱分类器错分的样本赋予更高的权重
- 对此重新加权的数据重复第一步，迭代次数根据需要而定
- 最终的强分类器：现有分类器的加权组合
  - 训练误差较小的分类器具有较高的权重



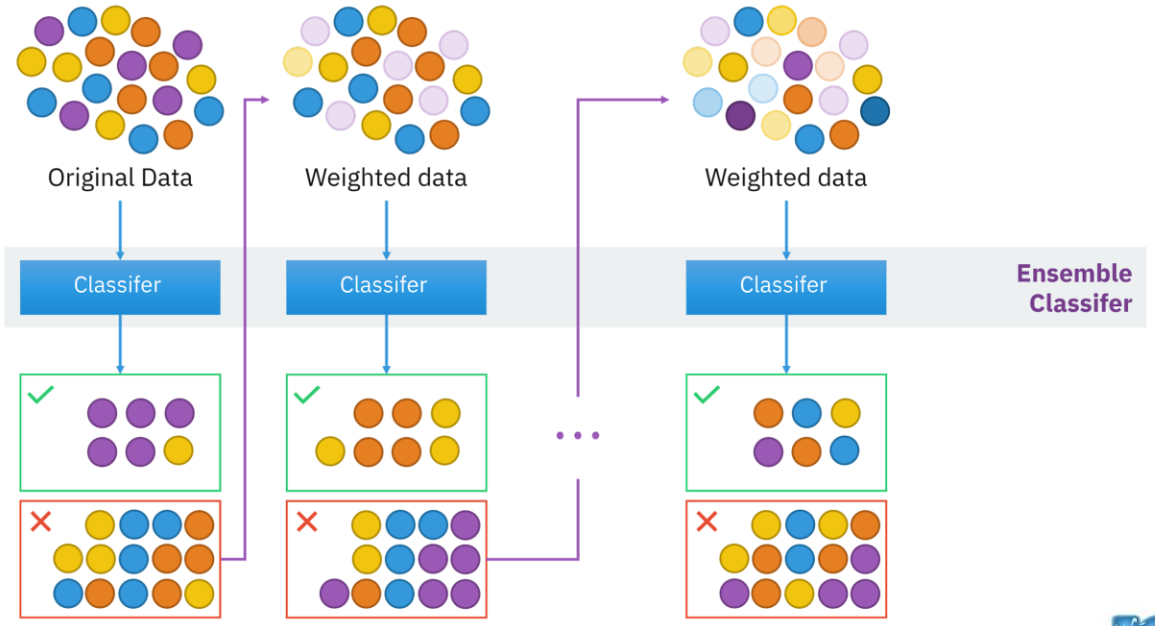
插图：Sirakorn

Boosting

- 训练弱分类器
- 将弱分类器错分的样本赋予更高的权重
- 对此重新加权的数据重复第一步，迭代次数根据需要而定
- 最终的强分类器：现有分类器的加权组合
  - 练误差较小的分类器具有较高的权重

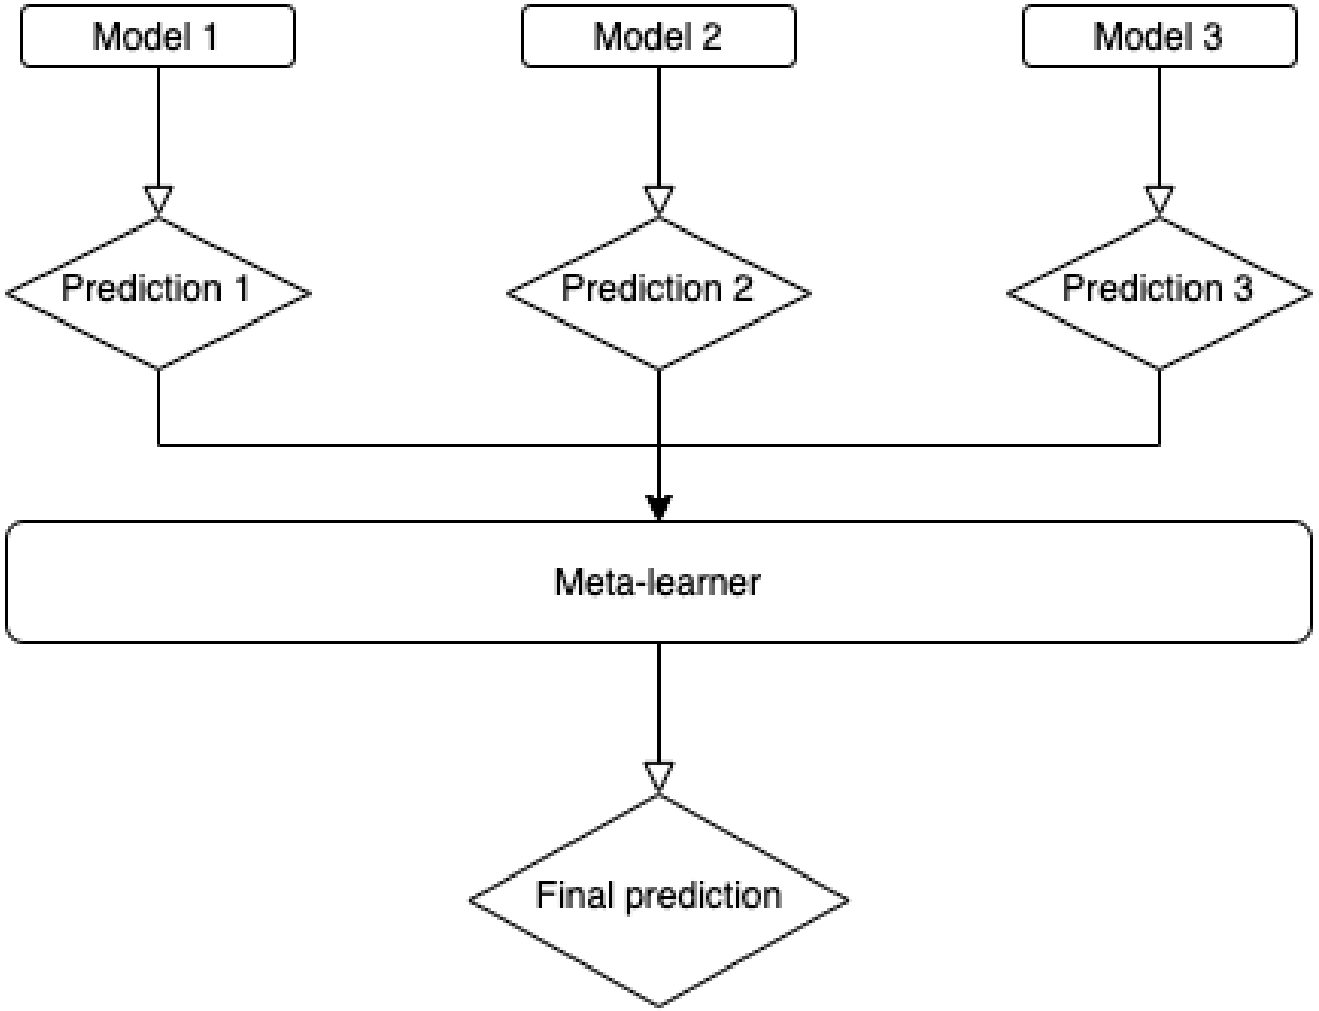
极受欢迎：

- XGBoost
- LightGBM



插图：Sirakorn

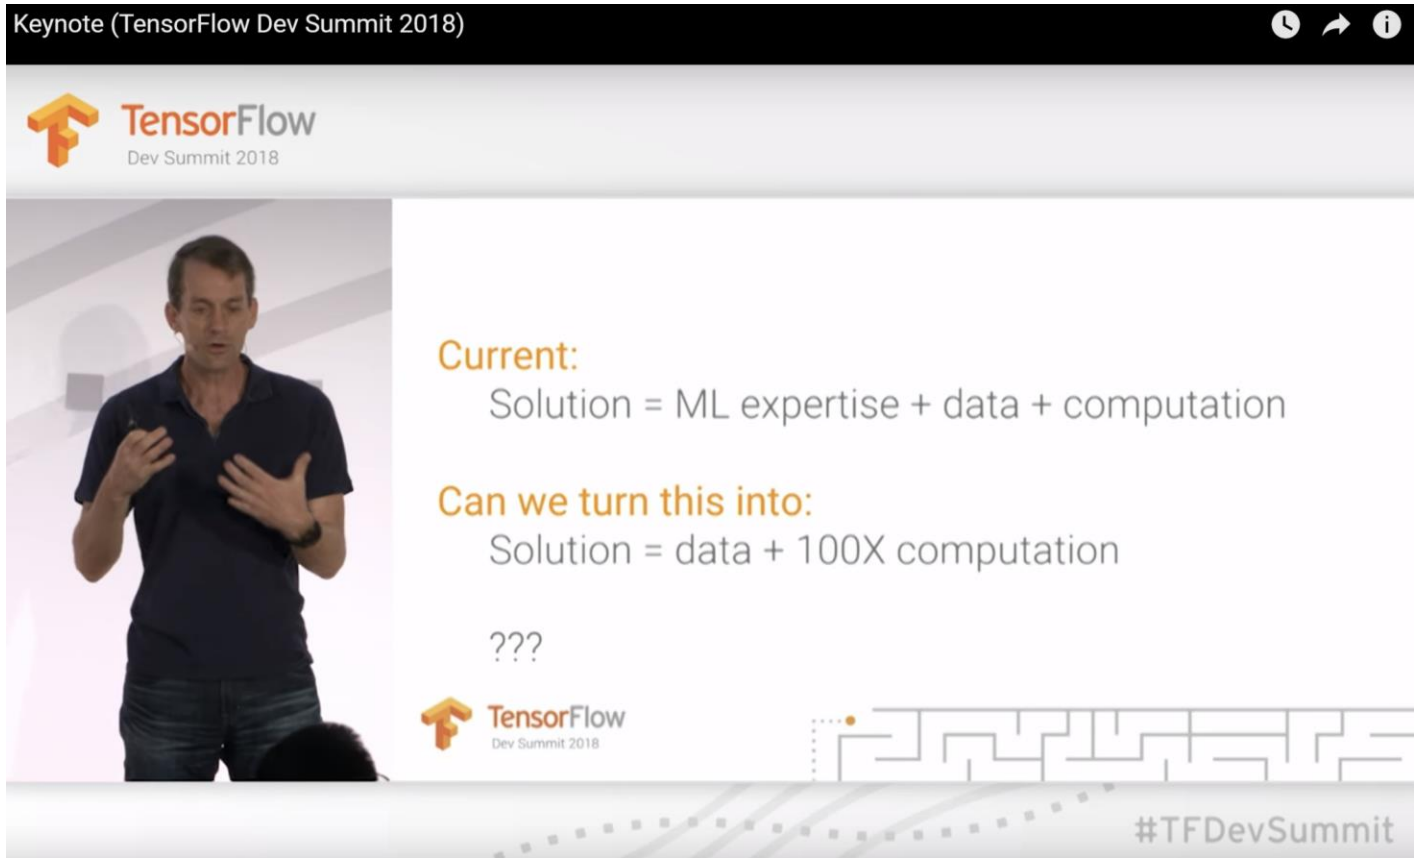
Stacking



多数投票，
逻辑回归，
简单神经网络

3.4 AutoML

- 一个好的ML研究人员是那些将自己从工作中自动化出来的人
- 谷歌：如果我们用100台计算机取代ML专家会怎样?



3.4 AutoML

- Soft AutoML
  - 超参数调整
- Hard AutoML
  - 神经结构搜索
  - 学习优化器

计算成本越来越高

Soft AutoML：超参数调整

- 较弱模型通过超参数的调整可以胜过较好的模型
  - On the State of the Art of Evaluation in Neural Language Models (Melis et al. 2018)

Soft AutoML：超参数调整

- 许多可以调整的超参数

```
model_type = "bert"

def __init__(
    self,
    vocab_size=30522,
    hidden_size=768,
    num_hidden_layers=12,
    num_attention_heads=12,
    intermediate_size=3072,
    hidden_act="gelu",
    hidden_dropout_prob=0.1,
    attention_probs_dropout_prob=0.1,
    max_position_embeddings=512,
    type_vocab_size=2,
    initializer_range=0.02,
    layer_norm_eps=1e-12,
    pad_token_id=0,
    position_embedding_type="absolute",
    use_cache=True,
    classifier_dropout=None,
    **kwargs
):
```

https://github.com/huggingface/transformers/blob/master/src/transformers/models/bert/configuration_bert.py

Soft AutoML：超参数调整

- 超参数调整已成为ML工作流的标准部分
- 内置框架
  - TensorFlow： Keras Turner
  - Scikit-Learn： auto-SKLearn
  - Ray Tune
- 流行算法
  - 随机搜索
  - 网格搜索
  - 贝叶斯优化

NAS：神经结构搜索

搜索空间

- 操作集
  - 例如，卷积、全连接、池化
- 如何连接操作

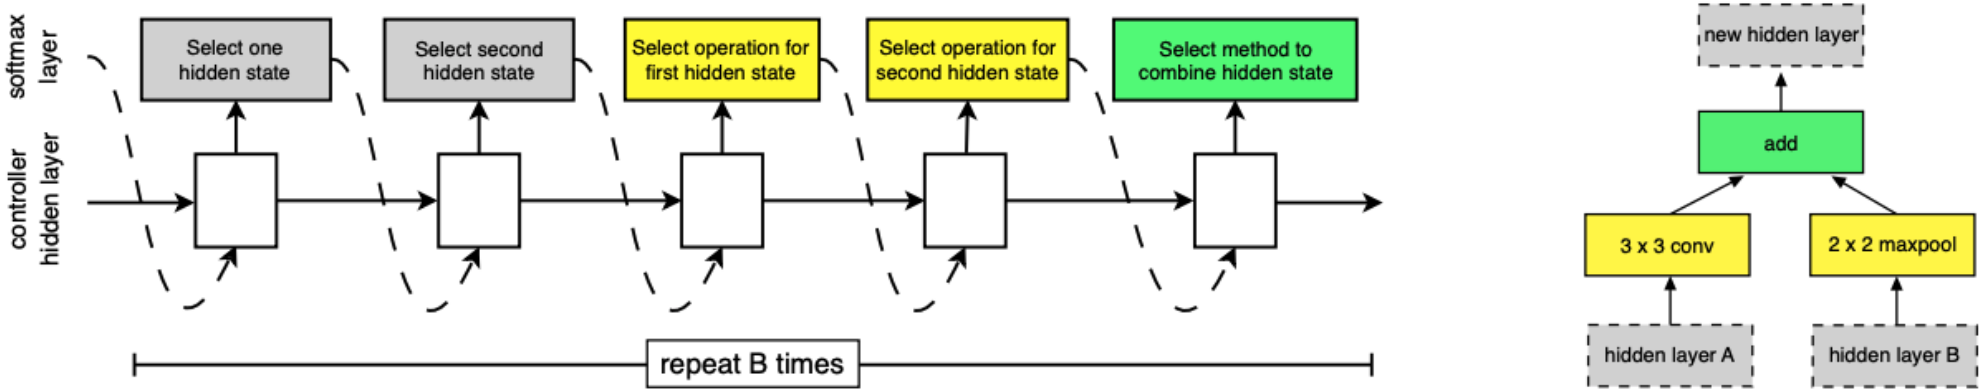


Figure 3. Controller model architecture for recursively constructing one block of a convolutional cell. Each block requires selecting 5 discrete parameters, each of which corresponds to the output of a softmax layer. Example constructed block shown on right. A convolutional cell contains B blocks, hence the controller contains $5B$ softmax layers for predicting the architecture of a convolutional cell. In our experiments, the number of blocks B is 5.

Learning Transferable Architectures for Scalable Image Recognition (Zoph et al., 2017)

NAS：神经结构搜索

- 搜索空间
- **性能估计策略**
  - 如何评估众多候选结构?
  - 理想状态：无需从头开始重新构建或重新训练。

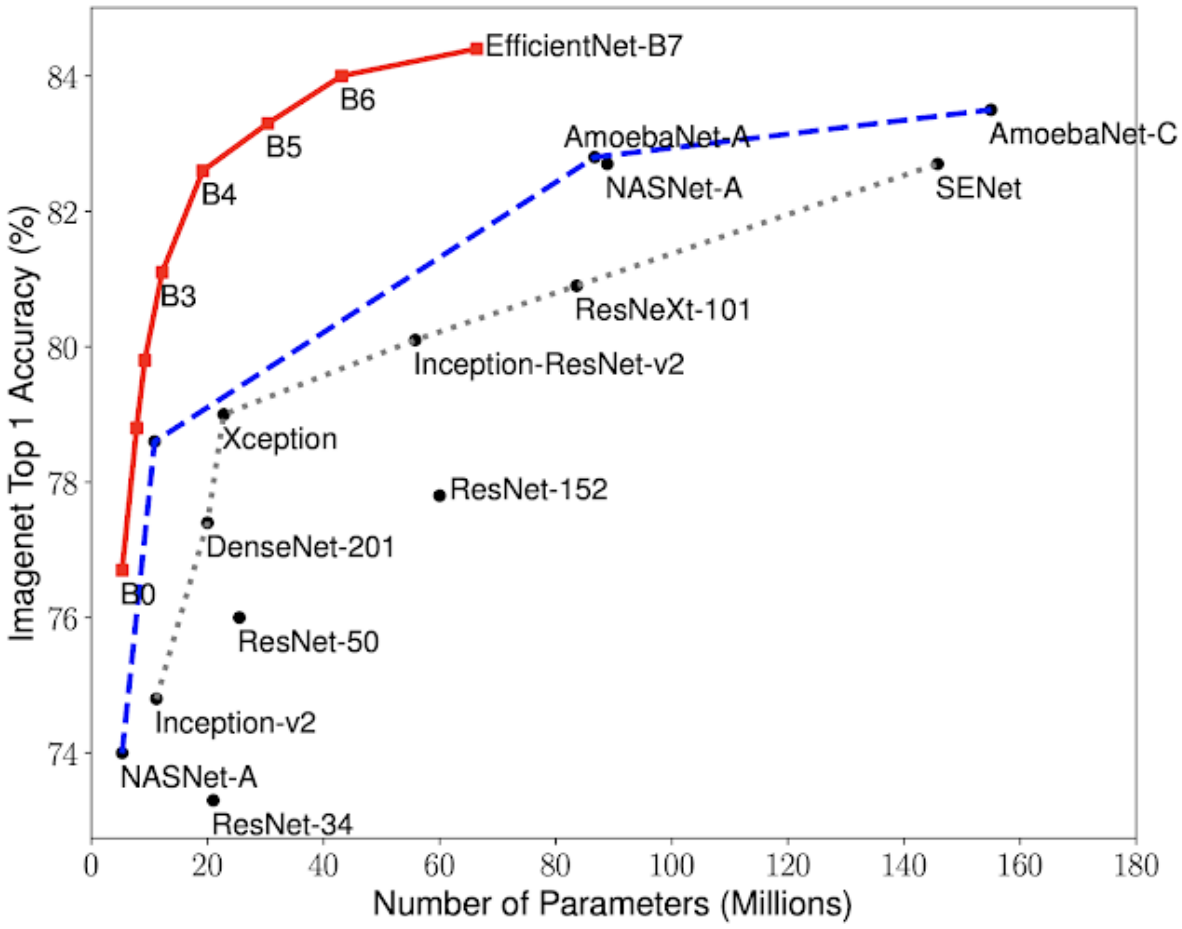
NAS：神经结构搜索

- 搜索空间
- 性能估计策略
- **搜索策略**
  - 随机的
  - 强化学习
    - 奖励改进绩效评估的选择
  - 进化
    - 改变结构
    - 选择表现最好的后代
    - ...

NAS：神经结构搜索

- 搜索空间
- 性能估计策略
- 搜索策略

非常成功



EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks (Tan et Le., 2019)

学习过程：结构+学习算法

- **学习算法**:
  - 指定如何更新权重的一组函数
  - 也称为优化器
    - Adam, Momentum, SGD

学习优化器

深度学习

工程特征 → 学习特征

SIFT (Lowe et. al. 1999)尺度不变特征
HOG (Dalal et. al. 2005)方向梯度直方图

LeNet (LeCun et. al. 1998)
AlexNet (Krizhevsky et. al. 2012)

元学习

工程学习 → 学会学习

SGD (Robbins et. al. 1951, Bottou 2010)
Autoencoders (Hinton et. al. 2006)

Learning To Learn (Hochreiter et. al. 2001)
Learned Optimizers (Andrychowicz et. al. 2016, Li et. al. 2016, Wichrowska et. al. 2017, Metz et. al. 2018, 2019)

Slide courtesy of Luke Metz

学习优化器

- 学习如何学习一组任务
- 泛化到新任务



Using a thousand optimization tasks to learn hyperparameter search strategies

Luke Metz [1] Niru Maheswaranathan [1] Ruoxi Sun [1] C. Daniel Freeman [1] Ben Poole [1] Jascha Sohl-Dickstein [1]

Slide courtesy of Luke Metz

学习优化器

- 学习如何学习一组任务
- 泛化到新任务
- 然后，可以使用学习的优化器来训练其自身的模型



Using a thousand optimization tasks to learn hyperparameter search strategies

Luke Metz [1] Niru Maheswaranathan [1] Ruoxi Sun [1] C. Daniel Freeman [1] Ben Poole [1] Jascha Sohl-Dickstein [1]

Slide courtesy of Luke Metz

目录

- 1 数据智能应用回顾
- 2 数据智能应用实现方法
- 3 数据智能应用实现框架
- 4 小结

小结

- 数据智能应用设计考虑的四个因素
  - 任务类型，目标，限制因素，实施阶段
- 数据智能应用实现的方法
  - 目标解耦
  - 模型选择（6准则）
  - 集成学习
  - AutoML